

Basi di dati

Alessandro Carella

Indice

1	Introduzione	3
1.1	Sistema organizzativo, informativo e informatico	3
1.2	Gestione delle informazioni	4
1.3	Dati e informazioni	5
2	Sistemi di gestione di basi di dati	6
2.1	Modelli di dati	8
2.1.1	Schemi e istanze	9
2.1.2	Livelli di astrazione nei DBMS	9
2.1.3	Indipendenza dei dati	10
2.2	Linguaggi e utenti delle basi di dati	10
2.2.1	Linguaggi per basi di dati	11
2.2.2	Utenti e progettisti	11
2.3	Vantaggi e svantaggi dei DBMS	12
3	Metodologie e modelli per il progetto	13
3.1	Il ciclo di vita dei sistemi informativi	13
3.2	Metodologie di progettazione e basi di dati	15
4	Il modello relazionale	18
4.1	Struttura del modello relazionale	18
4.1.1	Modelli logici nei sistemi di basi di dati	18
4.1.2	Relazioni e tabelle	19
4.1.3	Relazioni con attributi	20
4.1.4	Relazioni e basi di dati	21
4.1.5	Informazione incompleta e valori nulli	25
4.2	Vincoli di integrità	27
4.2.1	Vincoli di tupla	29

4.2.2	Chiavi	29
4.2.3	Chiavi e valori nulli	30
4.2.4	Vincoli di integrità referenziale	31
5	Algebra relazionale	33
5.1	Algebra relazionale	34
5.1.1	Unione, intersezione e differenza	34
5.1.2	Ridenominazione	35
5.1.3	Selezione	37
5.1.4	Proiezione	39
5.1.5	Join	40
5.1.6	Divisione	48
5.1.7	Interrogazioni in algebra relazionale	49
5.1.8	Equivalenza di espressioni algebriche	51
5.1.9	Algebra con valori nulli	55
5.1.10	Viste	57
5.2	Calcolo relazionale	59
5.2.1	Calcolo relazione su domini	60
5.2.2	Pregi e difetti del calcolo su domini	64
5.2.3	Calcolo su tuple con dichiarazioni di range	65
6	Il modello Entità-Relazione	69
6.1	I costrutti principali del modello	69
6.1.1	Entità	69
6.1.2	Relazioni o associazioni	70
6.1.3	Attributi	72
6.1.4	Costruzione di schemi con i costrutti di base	73
6.2	Altri costrutti del modello	74
6.2.1	Cardinalità delle relazioni	74
6.2.2	Cardinalità degli attributi	76
6.2.3	Identificatori delle entità	76
6.2.4	Generalizzazioni	78
7	Progettazione concettuale	80
7.1	La raccolta e l'analisi dei requisiti	80

Capitolo 1

Introduzione

1.1 Sistema organizzativo, informativo e informatico

DEFINIZIONE 1.1: SISTEMA ORGANIZZATIVO

Insieme di **risorse** e **regole** per lo svolgimento **coordinato** delle **attività** al fine di perseguire degli **scopi**

DEFINIZIONE 1.2: SISTEMA INFORMATIVO

Un sistema informativo è:

- **Componente** di una **organizzazione** che gestisce **informazioni** (di interesse)
 - è parte del sistema organizzativo
 - esegue/gestisce processi informativi ovvero processi che coinvolgono informazioni
 - ogni organizzazione ha un sistema informativo, eventualmente non esplicitato nella struttura
 - è spesso di supporto ad altri sottosistemi ed è da studiare nel contesto in cui è inserito
 - è spesso suddiviso in sottosistemi più o meno fortemente integrati

Esiste una dipendenza tra un sistema informativo e un **sistema informatico** per via dell'automatizzazione ed esistono organizzazioni la cui ragion d'essere è la gestione di informazioni e che operano da secoli.

Un sistema informatico è la porzione automatizzata del sistema informativo. Nel tempo c'è stata un'evoluzione di sistemi informativi verso **razionalizzazione** e **standardizzazione** e delle procedure e dell'organizzazione delle informazioni.

Una risorsa è una qualsiasi fonte o mezzo che valga a fornire aiuto.

1.2 Gestione delle informazioni

Ci sono diverse modalità di gestione delle informazioni:

- idee informali;
- linguaggio naturale;
- disegni, grafici, schemi;
- numeri e codici.

Inoltre, diversi sono i supporti sui quali memorizzare le informazioni:

- memoria umana;
- carta;
- dispositivi elettronici.

Nelle attività standardizzate di sistemi informativi complessi si è giunti ad una organizzazione e codifica, ad esempio nei servizi anagrafici dalle registrazioni discorsive si è giunti a:

- nome e cognome;
- estremi anagrafici;
- codice fiscale.

1.3 Dati e informazioni

Nei sistemi informatici, per ragioni tecnologiche e per la semplicità dei meccanismi di gestione, il concetto di rappresentazione e codifica delle informazioni viene portato all'estremo: le informazioni vengono rappresentate per mezzo di dati che hanno bisogno di essere interpretati per fornire informazioni. È difficile fare una distinzione tra dato e informazione ma per rappresentare in modo approssimativo il concetto possiamo dire che i dati da soli non hanno un significato ben definito ma una volta interpretati correttamente essi forniscono delle informazioni. Quindi l'informazione deriva da un processo di interpretazione e correlazione di dati, tutto ciò che produce variazione nel patrimonio conoscitivo di un soggetto è informazione.

Per fare un esempio di distinzione tra dato e informazione consideriamo la stringa 'BRINDISI 20 26 18', questi sono 4 dati e se correlati alla domanda 'Quali sono le temperature attuali, minime e massime di oggi?' allora i dati possono essere interpretati per fornire informazione e arricchire la conoscenza.

I sistemi informatici si sono limitati a gestire solo i dati e le informazioni da esse estratte.

Capitolo 2

Sistemi di gestione di basi di dati

L'attenzione ai dati ha caratterizzato le applicazioni dell'informatica fin dalle sue origini, ma software dedicati alla loro gestione sono stati realizzati a partire dalla fine degli anni Sessanta.

L'approccio convenzionale alla gestione dei dati sfrutta la presenza di archivi o *file* per memorizzare i dati in modo persistente sulla memoria di massa. Un file consente di memorizzare e ricercare dati, ma fornisce semplici meccanismi di accesso e condivisione. Secondo questo approccio, le procedure scritte in un linguaggio di programmazione sono autonome, ciascuna utilizza uno o più file privati e dati di interesse sono replicati con ridondanza e possibilità di incoerenza. Le basi di dati sono state concepite per superare questi inconvenienti, gestendo in modo integrato e flessibile le informazioni di interesse per diversi soggetti, limitando ridondanza e incoerenza.

Una base di dati è una collezione di dati, di interesse per una o più applicazioni. Un *sistema di gestione di basi di dati* (*Data Base Management System, DBMS*) è un sistema software in grado di gestire collezione di dati che siano *grandi, condivise e persistenti*, assicurando la loro *affidabilità e privacy*. Come ogni prodotto informatico, un DBMS deve essere *efficiente ed efficace*. Una base di dati è una collezione di dati gestita da un DBMS.

Chiariamo con precisione alcune caratteristiche dei DBMS e delle basi di dati:

- le basi di dati sono *grandi*, nel senso che possono avere dimensioni molto maggiori della memoria centrale disponibile, di conseguenza i DBMS devono prevedere una gestione dei dati in memoria secondaria, con architettura molto sofisticate;

- le basi di dati sono *condivise*, nel senso che diversi utenti e applicazioni possono accedervi secondo opportune modalità. In questo modo si riduce la ridondanza dei dati e la conseguente inconsistenza in quanto se esistono copie diverse di uno stesso dato è possibile che queste non siano uguali. Per garantire l'accesso condiviso ai dati, il DBMS dispone di un meccanismo apposito, detto *controllo di concorrenza*;
- le basi di dati sono *persistenti*, cioè hanno un tempo di vita non limitato a quello delle singole esecuzioni dei programmi che le utilizzano;
- i DBMS garantiscono *affidabilità*, cioè la capacità di conservare intatto il contenuto della base di dati in caso di malfunzionamenti hardware o software. A questo scopo i DBMS offrono funzionalità di *salvataggio e ripristino*;
- i DBMS garantiscono la *privatezza* dei dati; ciasun utente, opportunamente riconosciuto, viene abilitato a svolgere solo determinate azioni sui dati, attraverso meccanismi di *autorizzazione*;
- i DBMS sono *efficienti*, cioè sono capaci di svolgere le operazioni utilizzando un insieme di risorse, tempo e spazio, che sia accettabile per gli utenti;
- i DBMS sono *efficaci* in quanto sono capaci di rendere produttive le attività dei loro utenti.

La gestione di collezioni di dati grandi e persistenti è possibile anche con strumenti meno sofisticati dei DBMS, anche con i file, introdotti per gestire insiemi di dati localmente ad una specifica applicazione. I DBMS sono stati concepiti per estendere le funzioni del file system fornendo la possibilità di accesso condiviso agli stessi dati da parte di più utenti e applicazioni.

Inoltre, nei programmi tradizionali che accedono a file, ogni programma contiene una descrizione della struttura del file con rischi di incoerenza fra le varie descrizioni e i file stessi, nei DBMS, invece, c'è una porzione di basi di dati, chiamata *dizionario* o *catalogo* che contiene una descrizione centralizzata dei dati che è accessibile dai vari programmi.

Diverse sono le tipologie di basi di dati e DBMS, come:

- basi di dati multimediali;
- data warehouse;

- GIS;
- basi di dati in tempo reale;
- basi di dati attive;
- NoSQL;
- Access;
- Oracle;
- PostgreSQL;
- MySql

e tante altre.

2.1 Modelli di dati

Un *modello di dati* è un insieme di concetti utilizzati per organizzare i dati di interesse e descriverne la struttura in modo che risulti comprensibile a un elaboratore.

Ogni modello di dati fornisce *meccanismi di strutturazione* analoghi ai costruttori di tipo dei linguaggi di programmazione, che permettono di definire nuovi tipi sulla base di tipi predefiniti e costruttori di tipo.

Il *modello relazionale* dei dati, il più diffuso, permette di definire tipi per mezzo del costruttore *relazione*, che consente di organizzare i dati in insiemi di record a struttura fissa. Una relazione viene spesso rappresentata per mezzo di una tabella, le cui righe rappresentano dei record e le colonne corrispondono ai campi dei record, ad esempio:

Docenza	
Corso	NomeDocente
Basi di dati	Rossi
Reti	Neri
Linguaggi	Verdi

Oltre al modello relazionale sono stati definiti altri tipi di modelli:

- il *modello gerarchico* basato sull'uso di strutture ad albero;
- il *modello reticolare* basato sull'uso di grafi;
- il *modello a oggetti*, sviluppato come evoluzione del modello relazionale che estende alle basi di dati il paradigma di programmazione ad oggetti;
- il *modello XML* sviluppato come rivisitazione del modello gerarchico, in cui i dati vengono presentati assieme alla loro descrizione e non devono sottostare rigidamente a un'unica struttura logica;
- modelli semi-strutturati e flessibili, sviluppati nel contesto dei sistemi No-SQL che cercano di superare alcune limitazioni dei sistemi relazionali in termini di prestazioni e di rigidità di organizzazione.

I modelli dei dati vengono detti *logici* per sottolineare il fatto che le strutture utilizzate pur essendo astratte riflettono una particolare organizzazione (ad albero, grafo, ecc.). Più recentemente ai modelli logici, sono stati introdotti i modelli *concettuali* utilizzati per descrivere i dati indipendentemente dalla scelta del modello logico. Il loro nome deriva dal fatto che essi tendono a descrivere i *concetti* del mondo reale e vengono usati nella fase preliminare del processo di progettazione di basi di dati.

2.1.1 Schemi e istanze

Nelle basi di dati esiste una parte invariante nel tempo, detto *schema* della base di dati, costituita dalle caratteristiche dei dati, e una parte variabile nel tempo, detta *istanza* o *stato* della base di dati, costituita dai valori effettivi. Lo schema di una relazione è costituito dalla sua intestazione, ad esempio:

Docenza(Corso, NomeDocente)

Le righe della tabella, invece, variano nel tempo, l'istanza di una relazione è costituita dall'insieme delle sue righe,

2.1.2 Livelli di astrazione nei DBMS

La notazione di modello descritta in precedenza può essere sviluppata tenendo presente di altri fattori nella descrizione dei dati. In particolare, esiste un'architettura standard per DBMS articolata su tre livelli, detti: *esterno*, *logico* e *interno* e per ogni livello esiste uno schema.

- Lo *schema logico* costituisce una descrizione dell'intera base di dati per mezzo del modello logico adottato dal DBMS;
- Lo *schema interno* costituisce la rappresentazione dello schema logico per mezzo di strutture fisiche di memorizzazione, ad esempio una relazione può essere realizzata tramite file sequenziale, file hash o altri approcci;
- Uno *schema esterno* costituisce la descrizione di una porzione della base di dati di interesse, per mezzo del modello logico.

Nei sistemi moderni il livello esterno non è esplicitamente presente, ma è possibile definire relazioni derivate, o *viste*.

2.1.3 Indipendenza dei dati

L'architettura a livelli così definita garantisce l'*indipendenza dei dati* che è la principale proprietà dei DBMS. L'indipendenza dei dati permette a utenti e programmi applicativi che utilizzano una base di dati di interagire a un elevato livello di astrazione, cioè prescinde dai dettagli realizzativi.

L'indipendenza dei dati può essere caratterizzata come indipendenza fisica e logica:

- l'*indipendenza fisica* consente di interagire con il DBMS in modo indipendente dalla struttura fisica dei dati. È possibile modificare le strutture fisiche, come le modalità di organizzazione dei file gestiti dal DBMS, senza influire sulle descrizioni dei dati ad alto livello e quindi sui programmi che utilizzano i dati.
- l'*indipendenza logica* consente di interagire con il livello esterno della base di dati in modo indipendente dal livello logico. Ad esempio, è possibile aggiungere uno schema esterno in base alle esigenze di un nuovo utente o modificare uno schema esterno senza dover modificare lo schema logico e quindi l'organizzazione fisica dei dati.

Gli accessi alla base di dati avvengono solo attraverso il livello esterno ed è il DBMS che traduce le operazioni in termini dei livelli sottostanti.

2.2 Linguaggi e utenti delle basi di dati

I DBMS sono caratterizzati dalla presenza di diversi linguaggi per la gestione dei dati e dalla presenza di molteplici utenti.

2.2.1 Linguaggi per basi di dati

è possibile effettuare diverse operazioni su un DBMS, in particolare quelle relative agli schemi e alle istanze. I linguaggi per basi di dati si distinguono in due categorie:

- *linguaggi di definizione dei dati (Data Definition Language, DDL)*, utilizzati per definire gli schemi logici, esterni e fisici e le autorizzazioni per l'accesso;
- *linguaggi di manipolazione dei dati (Data Manipulation Language, DML)*, utilizzati per l'interrogazione e l'aggiornamento delle istanze di basi di dati.

L'accesso ai dati può essere effettuato con varia modalità:

- tramite linguaggi testuali interattivi, come il linguaggio SQL. Ad esempio, possiamo definire la struttura della relazione *Docenza*, sottoponendo a un interprete SQL la seguente istruzione che appartiene al DDL:

```
create table Docenza (  
    Corso          character (20) ,  
    NomeDocente    character (30)  
)
```

- tramite comandi simili a quelli interattivi immersi in linguaggi di programmazione. Questi linguaggi di programmazione si dicono *linguaggi ospite* perchè ospitando comandi scritti nel linguaggio per basi di dati. Questo approccio si utilizza spesso nella realizzazione di applicazioni parametriche e di farle eseguire ad un utente che non conosce SQL;
- tramite comandi simili a quelli interattivi immersi in linguaggi di sviluppo ad hoc, spesso con funzionalità specifiche;
- tramite interfacce amichevoli che permettono di sintetizzare interrogazioni senza usare un linguaggio testuale.

2.2.2 Utenti e progettisti

Diverse categorie di persone possono interagire con una base di dati o con un DBMS.

- l'*amministratore della base di dati (DataBase Administrator, DBA)* è la persona o gruppo di persone responsabile della progettazione, controllo e amministrazione della base di dati, l'acquisizione di software e risorse hardware e controlla l'efficienza delle operazioni;
- i *progettisti e programmatori di applicazioni* definiscono e realizzano i programmi che accedono alla base di dati. Essi utilizzano i linguaggi DML;
- gli *utenti* utilizzano la base di dati per le proprie attività e gli utenti si dividono in due categorie:
 - *utenti finali o terminalisti* che utilizzano *transazioni*, cioè programmi che realizzano attività predefinite e di frequenza elevata;
 - *utenti casuali* in grado di impiegare i linguaggi interattivi per l'accesso alla base di dati, formulando interrogazioni o aggiornamenti di vario tipo. Essi possono essere specializzati e interagire frequentemente con la base di dati.

2.3 Vantaggi e svantaggi dei DBMS

Dei DBMS possiamo elencare i seguenti vantaggi:

- I DBMS permettono di considerare i dati come una risorsa comune di un'organizzazione, a disposizione di tutte le sue componenti;
- la base di dati fornisce un modello unificato e preciso dalla parte del mondo reale di interesse per l'organizzazione;
- utilizzando un DBMS è possibile un controllo centralizzato dei dati, che può essere arricchito da forme di standardizzazione e beneficiare di "economie di scala";
- la condivisione permette di ridurre ridondanze e inconsistenze;
- l'indipendenza dei dati, fornisce lo sviluppo di applicazioni più flessibili e facilmente modificabili.

In casi di applicazioni con uno o pochi utenti, senza accessi concorrenti possono essere utilizzati file rispetto ai DBMS in quanto può risultare sconveniente.


Capitolo 3

Metodologie e modelli per il progetto

3.1 Il ciclo di vita dei sistemi informativi

La progettazione di una basd di dati costituisce solo una delle componenti del processo di sviluppo di un sistema informativo complesso e va quindi inquadrata in un contesto piu' ampio, quello del *ciclo del vita* dei sistemi informativi.

Il ciclo di vita di un sistema informativo comprende le seguenti attività.



- **Studio di fattibilità.** Serve a definire, nel modo piu' preciso possibile, i

costi delle varie alternative possibili e a stabilire le priorità di realizzazione delle varie componenti del sistema.

- **Raccolta e analisi dei requisiti.** Consiste nell'individuazione e nello studio delle proprietà e delle funzionalità che il sistema informativo dovrà avere. Questa fase richiede un'iterazione con gli utenti del sistema e produce una descrizione completa, ma informale, dei dati coinvolti e delle operazioni su di essi. Vengono inoltre stabiliti i requisiti software e hardware del sistema informativo.
- **Progettazione.** Si divide generalmente in *progettazione di dati* e *progettazione delle applicazioni*. Nella prima si individua la struttura e l'organizzazione che i dati dovranno avere, nell'altra si definiscono le caratteristiche dei programmi applicativi.
Le due attività sono complementari e possono procedere in parallelo o in cascata. Le descrizioni dei dati e delle applicazioni prodotti sono formali e fanno riferimento a specifici modelli.
- **Implementazione.** Consiste nella realizzazione del sistema informativo secondo la struttura e le caratteristiche definite nella fase di progettazione. Viene costruita e popolata la base di dati e viene prodotto il codice dei programmi.
- **Validazione e collaudo.** Serve a verificare il corretto funzionamento e la qualità del sistema informativo. La sperimentazione deve prevedere tutte le condizioni operative.
- **Funzionamento.** In questa fase il sistema informativo diventa operativo ed esegue i compiti per i quali era stato progettato. Se non si verificano malfunzionamenti delle funzionalità del sistema, questa attività richiede solo operazioni di gestione e manutenzione.

Il processo non è quasi mai strettamente sequenziale in quanto, durante l'attività di una delle attività citate, bisogna rivedere decisioni prese nell'attività precedente. Inoltre, oltre alle attività descritte, si aggiunge quella di *prototipizzazione*, che consiste nell'uso di specifici strumenti software per la realizzazione rapida di una versione semplificata del sistema informativo, con la quale sperimentare le sue funzionalità. La verifica del prototipo può portare ad un'eventuale revisione del progetto.

I dati hanno un ruolo centrale nei sistemi informativi e questo giustifica uno studio autonomo relativo alla progettazione delle basi di dati.

3.2 Metodologie di progettazione e basi di dati


Bisogna precisare cosa si intende per *metodologia di progettazione* e quali sono le proprietà che deve garantire. Una metodologia di progettazione consiste in:

- una *decomposizione* dell'intera attività di progetto in passi successivi indipendenti tra loro;
- una serie di *strategie* da seguire nei vari passi e alcuni *criteri* per la scelta in caso di alternative;
- alcuni *modelli di riferimento* per descrivere i dati di ingresso e uscita delle varie fasi.

Le proprietà che una metodologia deve garantire sono principalmente:

- la *generalità* rispetto alle applicazioni e ai sistemi di gioco (e quindi la possibilità di utilizzo indipendentemente dal problema allo studio e dagli strumenti a disposizione);
- la *qualità del prodotto* in termini di correttezza, completezza ed efficienza rispetto alle risorse impiegate;
- la *facilità d'uso* delle strategie e dei modelli di riferimento.

Nelle basi di dati, nel corso degli anni si è consolidata una metodologia di progetto che è articolata in tre fasi principali da effettuare in cascata. Questa metodologia separa le decisioni relative a *cosa* rappresentare in una base di dati, da quelle relative a *come* farlo.



- **Progettazione concettuale.** Il prodotto di questa fase viene chiamato *schema concettuale* e fa riferimento a un *modello concettuale* dei dati. I modelli concettuali ci consentono di descrivere l'organizzazione dei dati

a un alto livello di astrazione senza tenere conto degli aspetti implementativi. In questa fase, il progettista deve cercare di rappresentare il *contenuto informativo* delle base di dati non pensando a dettagli implementativi. Il modello concettuale piu' noto è il modello **Entity-Relationship**.

- **Progettazione logica.** Consiste nella traduzione dello schema concettuale definito nella fase precedente, adottando il modello di rappresentazione di dati del DBMS a disposizione. Il prodotto di questa fase viene denominato *schema logico* delle base di dati e fa riferimento a un *modello logico* dei dati. Il modello logico ci consente di descrivere i dati prescindendo ancora da dettagli fisici, ma concreta perchè disponibile nei sistemi di gestione di basi di dati. In questa fase, le scelte progettuali si basano su criteri di ottimizzazione delle operazioni da effettuare sui dati. Inoltre, si fa uso di tecniche formali di verifica della qualità dello schema logico ottenuto. Nel caso del modello relazione dei dati, la tecnica usata è quella della *normalizzazione*
- **Progettazione fisica.** In questa fase lo schema logico viene completato con la specifica dei parametri fisici di memorizzazione dei dati. Il prodotto di questa fase viene chiamato *schema fisico* e fa riferimento a un *modello fisico* dei dati che dipende dal DBMS scelto e si basa sui criteri di organizzazione fisica dei dati.

Analizziamo come i requisiti della base di dati vengono utilizzati nelle varie fasi della progettazione. Dobbiamo prima distinguere le *specifiche sui dati* che riguardano il contenuto della base di dati, e *specifiche sulle operazioni* che riguardano l'uso che utenti e applicazioni fanno della base di dati. Nella progettazione concettuale si fa uso delle specifiche sui dati mentre le specifiche sulle operazioni servono solo a verificare che lo schema concettuale sia completo, cioè che contenga le informazioni necessarie per eseguire tutte le operazioni previste.

Capitolo 4

Il modello relazionale

4.1 Struttura del modello relazionale

4.1.1 Modelli logici nei sistemi di basi di dati

Il *modello relazionale* si basa su due concetti fondamentali, quello di *relazione* e *tabella*.

La nozione di *relazione* proviene dalla teoria di insiemi in matematica mentre il concetto di *tabella* è intuitivo.

Il modello relazionale risponde al requisito d'indipendenza dei dati che prevede una distinzione, nella descrizione dei dati, fra il livello *fisico* e il livello *logico*; gli utenti che accedono ai dati e i programmatori che sviluppano le applicazioni fanno riferimento solo al livello logico e i dati descritti al livello logico sono concretamente organizzati per mezzo di strutture fisiche, ma non è necessario conoscerne i dettagli per accedervi. Invece, il modello reticolare e gerarchico, includevano riferimenti alla struttura realizzativa, attraverso l'uso di puntatori e l'ordinamento fisico dei dati.

Il termine *relazione* viene utilizzato in tre accezioni:

1. *relazione matematica* secondo la definizione della teoria degli insiemi;
2. *relazione* secondo la definizione del modello relazionale che presenta differenze a quella della teoria degli insiemi;
3. *relazione* come traduzione di *relationship* costruito del modello concettuale *Entità-Relazione* utilizzato per descrivere legami tra entità del mondo reale.

4.1.2 Relazioni e tabelle

In matematica, dati due insiemi $\mathcal{D}_1$ e $\mathcal{D}_2$, si chiama *prodotto cartesiano* di $\mathcal{D}_1$ e $\mathcal{D}_2$, l'insieme di coppie ordinate (v_1, v_2) , tali che v_1 è un elemento di $\mathcal{D}_1$ e v_2 è un elemento di $\mathcal{D}_2$.

Esempio : Prodotto cartesiano

Dati due insiemi $A = \{1, 2, 3, 4\}$ e $B = \{a, b\}$, il prodotto cartesiano è:

$$A \times B = \{(1, a), (1, b), (2, a), (2, b), (3, a), (3, b), (4, a), (4, b)\}$$

ovvero l'insieme di tutti le possibili coppie dove il primo elemento appartiene ad A e il secondo a B .

Una *relazione matematica* sugli insiemi $\mathcal{D}_1$ e $\mathcal{D}_2$, detti *domini* della relazione, è un sottoinsieme di $\mathcal{D}_1 \times \mathcal{D}_2$.

Le relazioni possono essere espresse graficamente sotto forma tabellare, ad esempio prendendo spunto dall'esempio del **prodotto cartesiano**, possiamo rappresentare la relazione così:

1	a
1	b
2	a
2	b
4	a
4	b

1	a
1	b
4	b

Le definizioni di prodotto cartesiano e relazione date precedentemente hanno fatto riferimento a due insiemi, ma possono essere generalizzate rispetto al numero di insiemi. Dati $n > 0$ insiemi $\mathcal{D}_1, \mathcal{D}_2, \dots, \mathcal{D}_n$, anche non distinti, il prodotto cartesiano di $\mathcal{D}_1 \times \mathcal{D}_2 \times \dots \times \mathcal{D}_n$ è costituito dalle n -uple $(v_1, v_2, \dots, v_n)$ tali che $v_i \in \mathcal{D}_i$ $1 \leq i \leq n$.

Una relazione matematica sui domini $\mathcal{D}_1, \mathcal{D}_2, \dots, \mathcal{D}_n$ è un sottoinsieme del prodotto cartesiano $\mathcal{D}_1 \times \mathcal{D}_2 \times \dots \times \mathcal{D}_n$. Il numero delle n componenti del prodotto cartesiano viene detto *grado* del prodotto cartesiano e della relazione. Il numero di elementi della relazione viene detto *cardinalità* della relazione.

4.1.3 Relazioni con attributi

Una relazione matematica è un insieme di n -uple ordinate $(v_1, v_2, \dots, v_n)$ ove $v_1 \in \mathcal{D}_1, v_2 \in \mathcal{D}_2, \dots, v_n \in \mathcal{D}_n$. Ciascuna n -upla contiene dati fra loro collegati, stabilisce un legame fra loro, ad esempio una n -upla siffatta: "Juventus, Lazio, 3, 1" indica che il risultato della partita tra Juventus e Lazio è 3 a 1.

Una relazione è un insieme quindi:

- non è definito un ordinamento fra le n -uple;
- le n -uple di una relazione sono distinte l'una dall'altra, in quanto tra gli elementi di un insieme non ce ne possono essere due uguali fra loro.

Ciascuna n -upla è, al proprio interno, *ordinata*: l' i -esimo valore di ciascuna proviene dall' i -esimo dominio. L'ordinamento appena descritto corrisponde ad una caratteristica insoddisfacente del concetto di relazione matematica rispetto alla possibilità di organizzare e utilizzare i dati. Infatti, in vari contesti dell'informatica, si tende a privilegiare notazioni *non-posizionali* rispetto a quelli posizionali: si tende a utilizzare quelli posizionali solo quando l'ordinamento corrisponde ad una esigenza intrinseca, come accade nei problemi di natura matematica, in cui gli array permettono di rappresentare in modo ovvio vettori e matrici. Le basi di dati, invece, hanno una struttura che si può ricondurre a quella dei record. Nel caso dei record, ad ogni campo, è associato un nome e allo stesso modo, ad ogni dominio possiamo associare un nome detto *attributo* che descrive il ruolo svolto dal dominio. Per esempio, nella relazione precedente delle squadre, possiamo usare nomi come "SquadraCasa, SquadraOspite, RetiCasa, RetiOspite".

Modificando la definizione di relazione con l'introduzione degli attributi e quindi l'ordinamento degli attributi risulta irrilevante, non è più necessario parlare di primo dominio, secondo dominio ecc.

Per formalizzare i concetti, indichiamo con $\mathcal{D}$ l'insieme dei domini e specifichiamo la corrispondenza fra attributi e domini, nell'ambito di una relazione, per mezzo di una funzione $dom : X \rightarrow \mathcal{D}$, che associa a ciascun attributo $A \in X$ un dominio $dom(A) \in \mathcal{D}$. Poi diciamo che una *tupla* su un insieme di attributi X è una funzione t che associa a ciascun attributo $A \in X$ un valore del dominio $dom(A)$. Quindi una *relazione* su X è un insieme di tuple su X . La differenza nella definizione precedente sta nel fatto che gli elementi delle tuple sono individuati per mezzo degli attributi e non per posizione.

Se t è una tupla su X e A un attributo nell'insieme X allora $t[A]$ indica il valore di t su A , ad esempio:

$$t[SquadraOspite] = Lazio$$

4.1.4 Relazioni e basi di dati

Una base di dati è costituita da piu' relazioni, le cui tuple, contengono valori comuni per stabilire delle corrispondenze. Ad esempio date le seguenti relazioni:

Studenti

Matricola	Cognome	Nome	Data di nascita
276545	Rossi	Maria	25/11/2000
485745	Neri	Anna	23/04/2001
200768	Verdi	Fabio	12/02/2001
587614	Rossi	Luca	10/10/2000
937653	Bruni	Mario	01/12/2000

Esami

Studente	Voto	Corso
276545	28	01
276545	27	04
937653	25	01
200768	24	04

Corsi

Codice	Titolo	Docente
01	Analisi	Giani
03	Chimica	Melli
04	Chimica	Belli

Studenti

Matricola	Cognome	Nome	Data di nascita
276545	Rossi	Maria	25/11/2000
485745	Neri	Anna	23/04/2001
200768	Verdi	Fabio	12/02/2001
587614	Rossi	Luca	10/10/2000
937653	Bruni	Mario	01/12/2000

Esami

Studente	Voto	Corso
276545	28	01
276545	27	04
937653	25	01
200768	24	04

Corsi

Codice	Titolo	Docente
01	Analisi	Giani
03	Chimica	Melli
04	Chimica	Belli

- la relazione *Studenti* contiene informazioni relative a un insieme di studenti, con numero di matricola, cognome, nome e data di nascita;
- la relazione *Esami* contiene informazioni relative a esami: il numero di matricola dello studente, il voto e il corso; questa relazione fa riferimento ai dati contenute nelle altre due, agli studenti con il numero di matricola e ai corsi con il codice di corso;
- la relazione *corsi* contiene relazioni relative ai corsi con il codice del corso, il titolo e il docente.

Questo esempio mostra una delle caratteristiche fondamentali del modello relazionale, il fatto che esso è basato su valori: i riferimenti fra dati in relazioni sono rappresentato per mezzo di valori che compaiono nelle tuple. Rispetto a un modello basato su record e puntatori, il modello relazionale, basato su valori, presenta diversi vantaggi:

- esso richiede di rappresentare solo ciò che è rilevante dal punto di vista dell'applicazione: i puntatori sono qualcosa di aggiuntivo legato ad aspetti realizzativi, nei modelli con puntatori, il programmatore fa riferimento a dati non significativi per l'applicazione;
- la rappresentazione logica dei dati non fa alcun riferimento con quella fisica che può anche subire cambiamenti, il modello relazionale permette di ottenere l'indipendenza fisica dei dati;
- dato che l'informazione è contenuta nei valori, è semplice trasferire i dati da un contesto ad un altro; con i puntatori l'operazione è più complessa perché i puntatori hanno un significato locale al singolo sistema.

Anche in una base di dati relazionale, a livello fisico, i dati possono essere rappresentati con modalità che prevedono l'uso dei puntatori. La differenza rispetto

ai modelli basati su puntatore è che qui i puntatori non sono visibili a modello logico.

Possiamo riassumere le definizioni relative al modello relazionale con più precisione, distinguendo il livello degli schemi a quello delle istanze.

- Uno *schema di relazione* è costituito da un simbolo R , detto *nome della relazione* e da un insieme di attributi $X = \{A_1, A_2, \dots, A_n\}$;
- Uno *schema di base di dati* è un insieme di schemi di relazione con nomi diversi:

$$\mathbf{R} = \{R_1(X_1), R_2(X_2), \dots, R_n(X_n)\}$$

- Un'istanza di relazione o *relazione* su uno schema $R(X)$ è un insieme di r di tuple su X . Talvolta si usa la notazione di $r(X)$;
- Un'istanza di base di dati o semplicemente *base di dati* è un insieme di relazioni $\mathbf{r} = \{r_1, r_2, \dots, r_n\}$ dove ogni r_i per $1 \leq i \leq n$ è uno schema di relazione $R_i(X_i)$

Il modello relazionale permette di rappresentare informazioni strutturate in modo articolato, nella figura sottostante, sono schematizzate tre ricevute emesse da un ristorante. Esse hanno una struttura che prevede alcune informazioni fisse come numero, data e totale e un numero di righe variabile ognuna relativa a un insieme di portate omogenee. Possiamo rappresentare queste informazioni per mezzo di due relazioni, la relazione Ricevute con numero, data e totale e la relazione Dettaglio con quantità, descrizione e importo, associate alla ricevuta stessa tramite il numero.

“DA MARIO”		
Ricevuta n. 1357		
del 5/5/2021		
3	coperti	6,00
2	antipasti	12,00
3	primi	27,00
2	bistecche	36,00
Totale		81,00

“DA MARIO”		
Ricevuta n. 2334		
del 4/7/2021		
2	coperti	4,00
1	antipasti	6,00
2	primi	15,00
2	orate	50,00
2	caffè	3,00
Totale		78,00

“DA MARIO”		
Ricevuta n. 3002		
del 4/8/2021		
3	coperti	6,00
2	antipasti	14,00
3	primi	20,00
1	orate	25,00
1	caprese	8,00
2	caffè	3,00
Totale		76,00

La base di dati che rappresenta le ricevute soprastanti è la seguente:

Ricevute

Num	Data	Totale
1357	5/5/2021	81,00
2334	4/7/2021	78,00
3002	4/8/2021	76,00

Dettaglio

Num	Q.tà	Descr	Costo
1357	3	coperti	6,00
1357	2	antipasti	12,00
1357	3	primi	27,00
1357	2	bistecche	36,00
2334	2	coperti	4,00
2334	1	antipasti	6,00
2334	2	primi	15,00
2334	2	orate	50,00
2334	2	caffè	3,00
3002	3	coperti	6,00
3002	2	antipasti	14,00
3002	3	primi	20,00
3002	1	orate	25,00
3002	1	caprese	8,00
3002	2	caffè	3,00

In questa situazione, la base di dati descritta non tiene traccia della riga dei singoli ordini come accade nelle ricevute, se vogliamo tener traccia dell'impaginazione della ricevuta basta aggiungere un attributo nella relazione Dettaglio che indica la posizione all'interno della ricevuta, come segue:

Dettaglio

Num	Riga	Q.tà	Descr	Costo
1357	1	3	coperti	6,00
1357	2	2	antipasti	12,00
1357	3	3	primi	27,00
1357	4	2	bistecche	36,00
2334	1	2	coperti	4,00
2334	2	1	antipasti	6,00
2334	3	2	primi	15,00
2334	4	2	orate	50,00
2334	5	2	caffè	3,00
3002	1	3	coperti	6,00
3002	2	2	antipasti	14,00
3002	3	3	primi	20,00
3002	4	1	orate	25,00
3002	5	1	caprese	8,00
3002	6	2	caffè	3,00

4.1.5 Informazione incompleta e valori nulli

La struttura del modello relazione è molto semplice e potente. Essa però impone un certo grado di rigidità, in quanto le informazioni devono essere rappresentate per mezzo di tuple di dati omogenee, in ogni relazione possiamo rappresentare solo tuple corrispondenti allo schema di relazione stessa. In molti casi, i dati disponibili possono non corrispondere al formato previsto, per esempio, data la relazione:

Persone(Cognome, Nome, Indirizzo, Telefono)

il valore dell'attributo Telefono potrebbe non essere disponibile per tutte le tuple. Quindi, non sarebbe opportuno utilizzare un valore del dominio per rappresentare l'assenza di informazione. In questo caso, supponendo che i numeri telefonici sono rappresentati per mezzo di numeri interi, potremmo utilizzare lo zero per

indicare l'assenza. In generale, questa scelta non risulta soddisfacente. In primo luogo perchè, richiede l'esistenza di un valore nel dominio mai utilizzato per valori significativi, in secondo luogo l'uso di valori del dominio può generare confusione: la distinzione fra valori veri e fittizi è nascosta e quindi, i programmatori che accedono alla base di dati devono tenerne conto distinguendo opportunamente.

Per rappresentare in modo semplice e comodo l'assenza di informazione, il concetto di relazione viene esteso prevedendo che una tupla possa assumere, su ciascun attributo, o un valore del dominio, o un valore speciale, detto *valore nullo*. Nelle rappresentazioni tabellari il valore nullo viene indicato con il simbolo *null*.

Nei sistemi di basi di dati relazionali è prevista una gestione molto semplice del valore nullo, sul quale non viene fatta alcuna ipotesi e quindi rappresenta il valore senza informazione.

Studenti

Matricola	Cognome	Nome	Data di nascita
276545	Rossi	Maria	null
null	Neri	Anna	23/04/2001
null	Verdi	Fabio	12/02/2001

Esami

Studente	Voto	Corso
276545	28	01
null	27	null
200768	24	null

Corsi

Codice	Titolo	Docente
01	Analisi	Giani
03	Chimica	null
null	Chimica	Belli

Il valore nullo sulla data di nascita è ammissibile perchè si può pensare che l'informazione non sia rilevante, ma un valore nullo sul numero di matricola o sul codice del corso genera problemi in quanto quei valori sono utilizzati per stabilire correlazioni fra tuple di relazioni diverse. Inoltre, la presenza di valori nulli rende inutilizzabili le informazioni. Infine, la presenza di molteplici valori nulli in una relazione può generare dubbi sulla significatività e identità delle tuple. È necessario quindi moderare opportunamente la presenza dei valori nulli nelle nostre relazioni, in genere, quando si definisce una relazione è possibile specifi-

care quali attributi possono assumere valori nulli o meno.

4.2 Vincoli di integrità

In molti casi, non è vero che l'insieme di tuple sullo schema rappresenti informazioni corrette per l'applicazione, dopo aver descritto i problemi relativi alla presenza di valori nulli, analizziamo i problemi relativi alla presenza di valori non nulli. Analizziamo la relazione in figura:

Studenti

Matricola	Cognome	Nome	Data di nascita
200768	Verdi	Fabio	12/02/2001
937653	Rossi	Luca	10/10/2000
937653	Bruni	Mario	01/12/2000

Esami

Studente	Voto	Lode	Corso
200768	36		05
937653	28	lode	01
937653	30	lode	04
276545	25		01

Corsi

Codice	Titolo	Docente
01	Analisi	Giani
03	Chimica	Melli
04	Chimica	Belli

- Nella prima tupla della relazione *Esami* abbiamo un voto pari a 36 che, nel sistema italiano, non è ammissibile;

- Nella seconda tupla della relazione *Esami* viene indicato che è stata attribuita la lode ad un voto di 28;
- Le ultime due tuple della relazione *Studenti* troviamo lo stesso numero di matricola che è impossibile in quanto univoco;
- La quarta tupla della relazione *Esami* presente, per l'attributo **Studente**, un numero di matricola che non compare nella relazione *Studenti*, analogamente compare un codice di corso non presente nella relazione *Corsi*.

In una base di dati, bisogna evitare situazioni di questo tipo, quindi è stato introdotto il concetto di *vincolo di integrità*, come proprietà che deve essere soddisfatta dalle istanze che rappresentano informazioni corrette per l'applicazione. Ogni vincolo può essere visto come un predicato che associa a ogni istanza il valore *vero* o *falso*. In uno schema a base di dati associamo un insieme di predicati e consideriamo corrette le istanze che soddisfano tutti i vincoli. In ciascuno dei casi discussi sopra possiamo introdurre un vincolo che vieti la situazione indesiderata.

Distinguiamo due categorie di vincoli a seconda degli elementi che sono coinvolti in una base di dati.

- Un vincolo è *intrarelazionale* se il soddisfacimento è definito rispetto a singole relazioni della base di dati; i primi tre casi corrispondono a vincoli intrarelazionali. Talvolta, il coinvolgimento riguarda le tuple separatamente le une dalle altre:
 - un *vincolo di tupla* è un vincolo che può essere valutato su ciascuna tupla indipendentemente dalle altre; i primi due casi rientrano in questa categoria.
 - un *vincolo su valori* o *vincolo di dominio* impone una restrizione sul dominio; il primo caso rientra in questa categoria.
- Un vincolo è *interrelazionale* se coinvolge più relazioni; questo è il caso del quarto esempio, in cui la situazione indesiderata può essere vietata richiedendo che un numero di matricola compaia nella relazione *Esami* solo se presente nella relazione *Studenti*.

4.2.1 Vincoli di tupla

I vincoli di tupla esprimono condizioni sui valori di ciascuna tupla indipendentemente dalle altre tuple.

Una possibile sintassi per esprimere condizioni di questo tipo è quella che permette di definire espressioni booleane, con connettivi *and*, *or* e *not* con atomi che confrontano, con operatori di uguaglianza, disuguaglianza e ordinamento, valori di attributo o espressioni aritmetiche su valori di attributo. Ad esempio i vincoli violati negli esempi precedenti possono essere descritti con le espressioni:

$$(Voto \geq 18) \text{ and } (Voto \leq 30)$$

$$(\text{not}(Lode = 'lod)) \text{ or } (Voto = 30)$$

Il secondo indica che è ammissibile la lode solo se il voto è pari a 30.

4.2.2 Chiavi

Analizziamo i vincoli di chiave che sono i più importanti del modello relazionale. Negli esempi precedenti il numero di matricola identifica univocamente uno studente, ma ci sono casi in cui anche un insieme di attributi identifica univocamente una tupla.

Quindi, intuitivamente, una chiave è un insieme di attributi utilizzato per identificare univocamente le tuple di una relazione. Per formalizzare la definizione, procediamo in due passi:

1. un insieme di K attributi è *superchiave* di una relazione r se r non contiene due tuple distinte t_1 e t_2 con $t_1[K] = t_2[K]$
2. K è *chiave* di r se è un superchiave minimale di r

Ad esempio, consideriamo la seguente relazione:

Matricola	Cognome	Nome	Nascita	Corso
4328	Rossi	Luigi	29/04/2000	Ing. Informatica
6328	Rossi	Dario	29/04/2000	Ing. Informatica
4766	Rossi	Luca	01/05/2001	Ing. Civile
4856	Neri	Luca	01/05/2001	Ing. Meccanica
5536	Neri	Luca	05/03/1999	Ing. Meccanica

- l'insieme $\{Matricola\}$ è superchiave ed è anche una superchiave minimale in quanto contiene un solo attributo;

- l'insieme $\{Cognome, Nome, Nascita\}$ è superchiave e nessuno dei suoi sottoinsiemi è superchiave; infatti esistono due tuple uguali su Cognome e Nascita, due uguali su Cognome e Nome e due uguali su Nome e Nascita;
- l'insieme $\{Matricola, Corso\}$ è superchiave, ma non è superchiave minimale perchè esiste un suo sottoinsieme proprio $\{Matricola\}$, che è superchiave minimale, e quindi $\{Matricola, Corso\}$ non è una chiave;
- l'insieme $\{Nome, Corso\}$ non è superchiave perchè nella relazione compaiono due tuple uguali su Nome e Corso.

Possiamo notare come ciascuna relazione e ciascuno schema di relazione abbiano sempre una chiave. Una relazione è un insieme e quindi, è costituita da elementi diversi tra loro; di conseguenza per ogni relazione $r(X)$, l'insieme X di attributi è una superchiave per la relazione. Ci possono essere due possibili casi: o l'insieme è anche chiave, oppure non è chiave, perchè esiste un'altra superchiave in esso contenuta; allora si può ripetere lo stesso ragionamento per questo sottoinsieme e così via.

Il fatto che su ogni schema di relazione possa essere definita almeno una chiave garantisce l'accessibilità a tutti i valori di una base di dati e la loro univoca identificabilità. Inoltre, permette di stabilire efficacemente quelle corrispondenze fra dati contenuti in relazioni diverse che caratterizzano il modello relazionale come modello basato su valori. I valori attraverso cui vengono stabilite le corrispondenze fra tuple di relazioni diverse sono valori delle chiavi delle relazioni cui si fa riferimento dall'esterno.

4.2.3 Chiavi e valori nulli

Consideriamo la relazione in figura:

Matricola	Cognome	Nome	Nascita	Corso
null	Rossi	Mario	null	Ing. Informatica
4766	Rossi	Luca	01/05/2001	Ing. Civile
4856	Neri	Luca	null	null
null	Neri	Luca	05/03/1999	Ing. Civile

Esaminando questa relazione, con due chiavi Matricola e (Cognome, Nome, Nascita), notiamo problemi di due tipi: la prima tupla ha valori nulli su Matricola e Nascita e quindi questa tupla non è identificabile in alcun modo. Inoltre, non

è possibile in altre relazioni, fare riferimento a questa tupla, visto che andrebbe fatto con il valore di una chiave. Anche le ultime due tuple presentano un problema: nonostante ciascuna delle due tuple abbia una chiave completamente specificata, la presenza di valori nulli rende impossibile capire se le due tuple facciano riferimento allo stesso studente.

Questo esempio suggerisce la necessità di porre dei limiti alla presenza di valori nulli nelle chiavi delle relazioni. In pratica, si adotta una soluzione semplice, che permette di garantire l'identificazione univoca di tutte le tuple e la possibilità di far riferimento a esse: su una delle chiavi, detta *chiave primaria*, si vieta la possibilità di avere valori nulli, sulle altre i valori nulli sono ammessi. Gli attributi che costituiscono la chiave primaria vengono evidenziati attraverso la sottolineatura. La maggior parte dei riferimenti tra relazioni avviene attraverso la chiave primaria.

In quasi tutti i casi reali è possibile trovare attributi i cui valori sono identificanti e sempre disponibili. Se questo non accade è necessario introdurre un attributo aggiuntivo, solitamente un codice, che viene generato e assegnato ad ogni tupla all'atto dell'inserimento.

4.2.4 Vincoli di integrità referenziale

Per discutere la più importante classe di vincoli interrelazionali, consideriamo la base di dati in figura:

Infrazioni

<u>Codice</u>	<u>Data</u>	<u>Agente</u>	<u>Articolo</u>	<u>Stato</u>	<u>Numero</u>
143256	25/10/2021	567	44	I	AB 234 ZK
987554	26/10/2021	456	34	I	AB 234 ZK
987557	26/10/2021	456	34	I	CB 123 AA
630876	15/10/2021	456	53	F	CB 123 AA
539856	12/10/2021	567	44	F	CB 123 AA

Agenti

<u>Matricola</u>	<u>CF</u>	<u>Cognome</u>	<u>Nome</u>
567	RSSM ...	Rossi	Mario
456	NREL ...	Neri	Luigi
638	NREP ...	Neri	Piero

Auto

<u>Stato</u>	<u>Numero</u>	<u>Proprietario</u>	<u>Indirizzo</u>
I	CB 123 AA	Verdi Piero	Via Tigli ...
I	DE 834 ZZ	Verdi Piero	Via Tigli ...
I	AB 234 ZK	Bini Luca	Via Aceri ...
F	CB 123 AA	Beau Marcel	Rue Louis XIV ...

La prima relazione, contiene informazioni relative a un insieme di infrazioni del codice della strada, la seconda agli agenti di polizia che le hanno rilevate e la terza a un insieme di autoveicoli di Paesi Europei. Le informazioni delle *Infrazioni* sono rese significative attraverso il riferimento alla relazione *Agenti* per mezzo della matricola di essi e alla relazione *Auto* per tramite degli attributi Stato e Numero. I riferimenti sono significativi in quanto i valori nella relazione *Infrazioni* sono uguali a quelli presenti nelle altre due relazioni.

Un *vincolo di integrità referenziale* o *foreign key* fra un insieme di attributi X di una relazione R_1 e un'altra relazione R_2 è soddisfatto se i valori di X di ciascuna tupla dell'istanza di R_1 compaiono come valori della chiave dell'istanza di R_2 . Questa definizione richiede particolare attenzione, nei casi in cui la relazione alla quale ci riferiamo è composta da più attributi e nel caso in cui vi siano più chiavi.

Vedendo prima il caso in cui la chiave di R_2 è unica e composta da un solo attributo B allora il vincolo di integrità referenziale fra l'attributo di A di R_1 e la relazione R_2 è soddisfatto se, per ogni tupla t_1 in R_1 per cui $t_1[A]$ non è nullo, esiste una tupla t_2 in R_2 tale che $t_1[A] = t_2[B]$. Nel caso più generale, dobbiamo fare attenzione al fatto che ciascuno degli attributi X deve corrispondere a un preciso attributo della chiave K in R_2 . È necessario specificare un ordinamento sia nell'insieme X sia di K . Indicando gli attributi $X = A_1A_2 \dots A_n$ e $K = B_1B_2 \dots B_n$ il vincolo è soddisfatto se per ogni tupla t_1 in R_1 senza nulli su X esiste una tupla t_2 in R_2 con $t_1[A_i] = t_2[B_i] \quad \forall i \in [1, n]$.

Una considerazione va fatta riguardo le relazioni con più chiavi. In questo caso, è opportuno identificarne una come chiave primaria e riferimenti vengono fatti attraverso essa. Però, va notato che non tutti i sistemi di gestione di base di dati permettono di indicare esplicitamente la chiave primaria. In questi casi, il vincolo di integrità referenziale deve indicare esplicitamente gli attributi che compongono la chiave cui si fa riferimento.

Capitolo 5

Algebra relazionale

Come detto precedentemente, i linguaggi per basi di dati si suddividono in due categorie.

- Operazioni sullo schema:
 - **DDL: Data Definition Language;**
- Operazioni sui dati:
 - **DML: Data Manipulation Language**

I linguaggi di interrogazione per basi di dati relazionali, invece, possono essere:

- **dichiarativi** che specificano le proprietà del risultato quindi cosa si vuole ottenere;
- **procedurali** che specificano le modalità di generazione del risultato quindi come ottenere il risultato.

I linguaggi di interrogazione possono essere:

- **Algebra relazione** che è di tipo procedurale;
- **Calcolo relazionale** che è dichiarativo e teorico;
- **SQL (Structed Query Language)** che è parzialmente dichiarativo (reale);
- **QBE (Query By Example)** che è di tipo dichiarativo (reale).

In questo capitolo analizzeremo l'algebra relazione che come abbiamo detto è un linguaggio di tipo procedurale basato su concetti di tipo algebrico. Esso è costituito da un insieme di operatori, definiti su relazioni e che producono ancora relazioni come risultati ed è possibile anche formare espressioni che coinvolgono più operatori allo scopo di formulare anche interrogazioni più complesse. Gli operatori sono:

- operatori insiemistici tradizionali: *unione*, *intersezione* e *differenza* che possono essere anche definiti, con qualche differenza, sulle relazioni;
- operatori di *ridenominazione*, *selezione* e *proiezione* che sono più specifici;
- operatore di *join* in varie forme: *join naturale*, *prodotto cartesiano*, *semijoin* e *theta-join*;
- operatore di *divisione*, che è ridondante perché esprimibile per mezzo di altri operatori.

5.1 Algebra relazionale

5.1.1 Unione, intersezione e differenza

Notiamo che le relazioni sono insiemi e quindi ha senso definire su di esse gli operatori insiemistici tradizionali di unione, differenza e intersezione, quest'ultima è esprimibile per mezzo della differenza in quanto $r \cap s = r - (r - s)$. Però, dobbiamo prestare attenzione sul fatto che una relazione non è genericamente un insieme di tuple, ma un insieme di tuple *omogenee*, quindi pur potendo, il linea di principio, definire delle operazioni insiemistiche sulle relazioni, non ha senso, dal punto di vista del modello relazionale, definirli con riferimento a relazioni su attributi diversi. Pertanto, consideriamo ammissibili, nell'algebra relazionale, solo applicazioni degli operatori di unione, differenza e intersezione a coppie di operandi definite sugli stessi attributi. La seguente figura mostra degli esempi di applicazione dei tre operatori, che confermano le classiche definizioni ma ridefinite sul nostro contesto:

- l'*unione* di due relazioni r_1 e r_2 definite sullo stesso insieme di attributi X è indicata con $r_1 \cup r_2$ ed è una relazione su X contenente le tuple che appartengono a r_1 oppure a r_2 o a entrambe;

- l'intersezione di $r_1(X)$ e $r_2(X)$ è indicata con $r_1 \cap r_2$ ed è una relazione su X contenente le tuple che appartengono sia a r_1 che a r_2 ;
- la differenza di r_1 e r_2 è indicata con $r_1 - r_2$ ed è una relazione su X contenente le tuple che appartengono a r_1 e non appartengono a r_2 .

Laureati

Matricola	Cognome	Età
7274	Rossi	37
7432	Neri	39
9824	Verdi	38

Dirigenti

Matricola	Cognome	Età
9297	Neri	56
7432	Neri	39
9824	Verdi	38

Laureati $\cup$ Dirigenti

Matricola	Cognome	Età
7274	Rossi	37
7432	Neri	39
9824	Verdi	38
9297	Neri	56

Laureati $\cap$ Dirigenti

Matricola	Cognome	Età
7432	Neri	39
9824	Verdi	38

Laureati $-$ Dirigenti

Matricola	Cognome	Età
7274	Rossi	37

5.1.2 Ridenominazione

La limitazione imposta agli operatori insiemistici, anche se giustificata, risulta molto restrittiva. Consideriamo infatti le relazioni in figura:

Paternità

Padre	Figlio
Adamo	Caino
Adamo	Abele
Abramo	Isacco
Abramo	Ismaele

Maternità

Madre	Figlio
Eva	Caino
Eva	Set
Sara	Isacco
Agar	Ismaele

Paternità $\cup$ Maternità ??

Sarebbe sensato eseguire su di esse una sorta di unione per avere tutte le coppie genitore-figlio ma questo non è possibile, perchè gli attributi sono diversi, in una troviamo l'attributo *Padre* e nell'altra troviamo l'attributo *Madre*.

Per risolvere il problema utilizziamo un operatore che ha lo scopo di adeguare il nome degli attributi in base alle necessità. Questo si chiama operatore di *ridenominazione* che cambia il nome degli attributi lasciando invariato il contenuto delle relazioni. Consideriamo le relazioni in figura:

Paternità		$\rho_{\text{Genitore} \leftarrow \text{Padre}}(\text{Paternità})$	
Padre	Figlio	Genitore	Figlio
Adamo	Caino	Adamo	Caino
Adamo	Abele	Adamo	Abele
Abramo	Isacco	Abramo	Isacco
Isacco	Giacobbe	Isacco	Giacobbe

Come possiamo notare, la ridenominazione agisce solo sullo schema, cambiando il nome dell'attributo *Padre* in *Genitore* e si denota con:

$$\rho_{\text{Genitore} \leftarrow \text{Padre}}$$

Ora definiamo questo operatore in forma generale. Sia r una relazione definita su un insieme di attributi X e sia Y un altro insieme di attributi con la stessa cardinalità. Siano $A_1, A_2, \dots, A_k$ e $B_1, B_2, \dots, B_k$ rispettivamente un ordinamento per gli attributi in X e un ordinamento per quelli in Y . Allora la ridenominazione:

$$\rho_{B_1 B_2 \dots B_k \leftarrow A_1 A_2 \dots A_k}(r)$$

contiene una tupla t' per ciascuna tupla t in r , definita come segue: t' è una tupla su Y e $t'[B_i] = t[A_i] \quad \forall i = 1, \dots, k$. La definizione conferma che ciò che cambia sono i nomi degli attributi, mentre i valori rimangono inalterati e vengono associati ai nuovi attributi. In pratica, nelle due liste $A_1 A_2 \dots A_k$ e $B_1 B_2 \dots B_k$ indicheremo solo gli attributi che vengono ridenominati, cioè quelli per cui $A_i \neq B_i$. Quindi ritornando alle relazioni precedenti, l'unione delle due relazioni è la seguente:


$$\rho_{\text{Genitore} \leftarrow \text{Padre}}(\text{Paternità}) \cup \rho_{\text{Genitore} \leftarrow \text{Madre}}(\text{Maternità})$$

Genitore	Figlio
Adamo	Caino
Adamo	Abele
Abramo	Isacco
Abramo	Ismaele
Eva	Caino
Eva	Set
Sara	Isacco
Agar	Ismaele

5.1.3 Selezione

Esaminiamo, ora, gli operatori più tipici dell'algebra relazionale, che permettono di manipolare le relazioni. Si tratta di tre operatori: selezione, proiezione e join con diverse varianti.

È bene precisare che la selezione e la proiezione svolgono funzioni “complementari”, sono entrambe definite su un operando e producono come risultato una porzione dell'operando. Più precisamente la selezione produce un sottoinsieme delle tuple, su tutti gli attributi, mentre la proiezione dà un risultato cui contribuiscono tutte le tuple, ma su un sottoinsieme degli attributi. Quindi, possiamo dire che la selezione genera “decomposizioni orizzontali” e la proiezione “decomposizioni verticali”. La situazione descritta è mostrata nella seguente figura:



La selezione è denotata dal simbolo σ a pedice del quale viene indicata la “condizione di selezione” opportuna. Il risultato contiene le tuple dell’operando che soddisfano la condizione di selezione. Le condizioni di selezione possono prevedere confronti tra attributi e confronti tra attributi e costanti e possono essere ottenute combinando condizioni semplici con i connettivi logici: $\vee$ (or), $\wedge$ (and) e $\neg$ (not).

In termini più precisi data una relazione $r(X)$, una *formula proposizionale* F su X è una formula ottenuta combinando, con i connettivi $\vee, \wedge$ e $\neg$, condizioni atomiche del tipo $A \Theta B$ o $A \Theta c$, dove:

- Θ è un operatore di confronto ($=, \neq, <, >, \leq, \geq$);
- A e B sono attributi in X sui cui valori il confronto Θ abbia senso;
- c è una costante con il dominio di A .

Seguono due esempi di selezione:

Cittadini

Cognome	Nome	CittàDiNascita	Residenza
Rossi	Mario	Roma	Milano
Neri	Luca	Roma	Roma
Verdi	Nico	Firenze	Firenze
Rossi	Marco	Napoli	Firenze

$\sigma_{\text{CittàDiNascita}=\text{Residenza}}(\text{Cittadini})$

Cognome	Nome	CittàDiNascita	Residenza
Neri	Luca	Roma	Roma
Verdi	Nico	Firenze	Firenze

Impiegati

Cognome	Nome	Età	Stipendio
Rossi	Mario	25	2000,00
Neri	Luca	40	3000,00
Verdi	Nico	36	4500,00
Rossi	Marco	40	3900,00

$\sigma_{\text{Età}>30 \wedge \text{Stipendio}>4000,00}(\text{Impiegati})$

Cognome	Nome	Età	Stipendio
Verdi	Nico	36	4500,00

Date una formula F e una tupla t , è definito un valore di verità per F su t :

- $A\Theta B$ è vera su t se $t[A]$ è in relazione Θ con $t[B]$, altrimenti è falsa;
- $A\Theta c$ è vera su t se $t[A]$ è in relazione Θ con c , altrimenti è falsa;
- $F_1 \vee F_2, F_1 \wedge F_2, \neg F_1$ hanno l'usuale significato.

Possiamo quindi completare la definizione di selezione: $\Theta_F(r)$, in cui r è una relazione e F è una formula proposizionale, produce una relazione sugli stessi attributi di r che contiene le tuple di r su cui F è vera.

Seguono le proprietà dell'operatore di selezione:

- *Cardinalità*: $|\Theta_F(r)| \leq |r|$
- *Grado*: $\text{grado}(\Theta_F(r)) = \text{grado}(r)$
- *Proprietà commutativa*: $\Theta_{F_1}(\Theta_{F_2}(r)) = \Theta_{F_2}(\Theta_{F_1}(r))$
- *Idempotenza*: $\Theta_{F_1}(\Theta_{F_2}(r)) = \Theta_{F_1 \wedge F_2}(r)$

5.1.4 Proiezione

L'operatore di proiezione presenta una definizione ancora più semplice di quella di selezione: dati una relazione $r(X)$ e un sottoinsieme Y di X , la *proiezione* di r su Y è l'insieme di tuple su Y ottenute dalle tuple di r considerando solo i valori su Y :

$$\pi_Y(r) = \{t[Y] \mid t \in r\}$$

Seguono due esempi di proiezione:

Impiegati				$\pi_{\text{Cognome, Nome}}(\text{Impiegati})$	
Cognome	Nome	Reparto	Capo	Cognome	Nome
Rossi	Mario	Vendite	Gatti	Rossi	Mario
Neri	Luca	Vendite	Gatti	Neri	Luca
Verdi	Mario	Personale	Lupi	Verdi	Mario
Rossi	Marco	Personale	Lupi	Rossi	Marco

In questo esempio viene illustrato chiaramente il concetto citato.

Impiegati				$\pi_{\text{Reparto, Capo}}(\text{Impiegati})$	
Cognome	Nome	Reparto	Capo	Reparto	Capo
Rossi	Mario	Vendite	Gatti	Vendite	Gatti
Neri	Luca	Vendite	Gatti	Personale	Lupi
Verdi	Mario	Personale	Lupi		
Rossi	Marco	Personale	Lupi		

In questo esempio, invece, troviamo un numero di tuple inferiore a quelle dell'operando, perchè alcune tuple, avendo valori uguali sugli attributi della proiezione, danno lo stesso contributo alla proiezione. Essendo le relazioni definite come insiemi, non possono apparire più tuple uguali fra loro. Esiste, quindi, un legame fra i vincoli di chiave e le proiezioni relativamente a questo problema: $\pi_Y(r)$ contiene lo stesso numero di tuple di r se e solo se Y è superchiave per r . Infatti:

- se Y è superchiave, allora r non contiene tuple uguali su Y , quindi ogni tupla dà un contributo diverso alla proiezione;
- se la proiezione ha tante tuple quante l'operando, allora ciascuna tupla contribuisce alla proiezione con valori diversi, quindi r non contiene coppie di tuple uguali su Y e questa è la definizione di superchiave.

5.1.5 Join

Esaminiamo l'operatore più caratteristico dell'algebra relazionale, l'operatore di join, che permette di correlare dati contenuti in relazioni diverse, confrontando i valori contenuti in esse e utilizzando la caratteristica fondamentale del modello, cioè quella di essere basato su valori. Esistono due versioni dell'operatore: il *join naturale* utile per riflessioni astratte e il *theta-join* che è più rilevante dal punto di vista pratico.

Join naturale

Il *join naturale* è un operatore che correla dati in relazioni diverse, sulla base di valori uguali in attributi con lo stesso nome. L'operatore è denotato con il simbolo $\bowtie$. Il risultato del join è costituito da una relazione sull'unione degli insiemi di attributi degli operandi e le sue tuple sono ottenute combinando le tuple degli operandi con valori uguali sugli attributi comuni. Un esempio di join è mostrato nella seguente figura:

r_1	Impiegato	Reparto	r_2	Reparto	Capo
	Rossi	vendite		produzione	Mori
	Neri	produzione		vendite	Bruni
	Bianchi	produzione			
$r_1 \bowtie r_2$					
	Impiegato	Reparto		Capo	
	Rossi	vendite		Bruni	
	Neri	produzione		Mori	
	Bianchi	produzione		Mori	

In generale, il join naturale $r_1 \bowtie r_2$ di $r_1(X_1)$ e $r_2(X_2)$ è una relazione definita su X_1X_2 come segue:

$$r_1 \bowtie r_2 = \{t \text{ su } X_1X_2 \mid \text{esistono } t_1 \in r_1 \text{ e } t_2 \in r_2 \text{ con } t[X_1] = t_1 \text{ e } t[X_2] = t_2\}$$

Più sinteticamente, possiamo scrivere:

$$r_1 \bowtie r_2 = \{t \text{ su } X_1X_2 \mid t[X_1] \in r_1 \text{ e } t[X_2] \in r_2\}$$

La definizione conferma che le tuple del risultato sono ottenute combinando tuple degli operandi con valori uguali su attributi comuni. Il grado della relazione ottenuta come risultato di un join è minore o uguale della somma dei gradi dei due operandi, perchè gli attributi omonimi degli operandi compaiono una sola volta nel risultato.

Molto frequentemente, si eseguono join sulla base di valori di una chiave delle relazioni coinvolte, esplicitando i riferimenti fra tuple. In molti di questi casi, è anche definito, fra gli attributi coinvolti, un vincolo di integrità referenziale. Consideriamo la relazione in figura:

Infrazioni	Codice	Data	Agente	Articolo	Stato	Numero	
	143256	25/10/2021	567	44	I	AB 234 ZK	
	987554	26/10/2021	456	34	I	AB 234 ZK	
	987557	26/10/2021	456	34	I	CB 123 AA	
	630876	15/10/2021	456	53	F	CB 123 AA	
	539856	12/10/2021	567	44	F	CB 123 AA	
Auto	Stato	Numero	Proprietario	Indirizzo			
	I	CB 123 AA	Verdi Piero	Via Tigli ...			
	I	DE 834 ZZ	Verdi Piero	Via Tigli ...			
	I	AB 234 ZK	Bini Luca	Via Aceri ...			
	F	CB 123 AA	Beau Marcel	Rue Louis ...			
Infrazioni $\bowtie$ Auto							
Codice	Data	Ag	Art	Stato	Numero	Proprietario	Indirizzo
143256	25/10/2021	567	44	I	AB 234 ZK	Bini Luca	Via Aceri ...
987554	26/10/2021	456	34	I	AB 234 ZK	Bini Luca	Via Aceri ...
987557	26/10/2021	456	34	I	CB 123 AA	Verdi Piero	Via Tigli ...
630876	15/10/2021	456	53	F	CB 123 AA	Beau Marcel	Rue Louis ...
539856	12/10/2021	567	44	F	CB 123 AA	Beau Marcel	Rue Louis ...

Notiamo che ciascuna delle tuple di *Infrazioni* è stata combinata con una e una sola delle tuple di *Auto*: una sola perchè **Prov** e **Numero** formano una chiave di

Auto, almeno una perchè è definito il vincolo di integrità referenziale fra **Prov** e **Numero** in *Infrazioni* e *Auto*. Il join, quindi, ha esattamente tante tuple quante la relazione *Infrazioni*.

Join completi e incompleti

Analizziamo diversi esempi di join, in modo da effettuare delle valutazioni sulla dimensione del risultato e al contributo a esso portato dalle tuple degli operandi. Nel primo esempio di join mostrato, ciascuna tupla di ciascuno degli operandi contribuisce ad almeno una tupla del risultato, quindi ci troviamo in un caso di *join completo*: per ogni tupla t_1 di r_1 , esiste una tupla t in $r_1 \bowtie r_2$ tale che $t[X_1] = t_1$, analogamente per r_2 . Questa proprietà non è sempre verificata, perchè richiede una corrispondenza fra le tuple delle due relazioni.

Consideriamo la relazione in figura:

r_1	Impiegato	Reparto	r_2	Reparto	Capo
	Rossi	vendite		produzione	Mori
	Neri	produzione		acquisti	Bruni
	Bianchi	produzione			

$r_1 \bowtie r_2$	Impiegato	Reparto	Capo
	Neri	produzione	Mori
	Bianchi	produzione	Mori

Figura 5.1: Un join con tuple *dangling*

La figura mostra un join in cui alcune tuple degli operandi non contribuiscono al risultato, perchè l'altra relazione non contiene tuple con gli stessi valori sull'attributo comune. Queste tuple vengono chiamate *dangling*. Inoltre, è possibile che nessuna tupla degli operandi sia combinabile, e allora il risultato del join è la relazione vuota.

r_1	Impiegato	Reparto	r_2	Reparto	Capo
	Rossi	vendite		concorsi	Mori
	Neri	produzione		acquisti	Bruni
	Bianchi	produzione			

$r_1 \bowtie r_2$	Impiegato	Reparto	Capo

Figura 5.2: Un join vuoto

All'estremo opposto, è possibile che ciascuna delle tuple di ciascuno degli operandi sia combinabile con tutte le tuple dell'altro. In tal caso, il risultato contiene un numero di tuple pari al prodotto della cardinalità degli operandi e cioè $|r_1| \times |r_2|$.

r_1	Impiegato	Progetto	r_2	Progetto	Capo
	Rossi	A		A	Mori
	Neri	A		A	Bruni
	Bianchi	A			

$r_1 \bowtie r_2$	Impiegato	Reparto	Capo
	Rossi	A	Mori
	Neri	A	Mori
	Bianchi	A	Mori
	Rossi	A	Bruni
	Neri	A	Bruni
	Bianchi	A	Bruni

Figura 5.3: Un join con $|r_1| \times |r_2|$ tuple

Quindi il join di r_1 e r_2 contiene un numero di tuple compreso fra 0 e $|r_1| \times |r_2|$. Inoltre:

- se il join di r_1 e r_2 è completo, allora contiene almeno un numero di tuple pari al massimo fra $|r_1|$ e $|r_2|$;

- se $X_1 \cap X_2$ contiene una chiave per r_2 , allora il join di $r_1(X_1)$ e $r_2(X_2)$ contiene al più $|r_1|$ tuple;
- se $X_1 \cap X_2$ coincide con una chiave per r_2 e sussiste il vincolo referenziale fra $X_1 \cap X_2$ in r_1 e la chiave di r_2 , allora il join di $r_1(X_1)$ e $r_2(X_2)$ contiene esattamente $|r_1|$ tuple.

Join esterni

La caratteristica dell'operatore di join di "tralasciare" le tuple di una relazione che non hanno controparte nell'altra è utile in molti casi ma pericolosa in altri in quanto potrebbe omettere informazioni utili. Consideriamo la figura 5.1, supponendo di essere interessati a tutti gli impiegati, con l'indicazione del capo, se noto. Per questo, è stata proposta una variante dell'operatore di join chiamata *join esterno* o *outer join*, che prevede che tutte le tuple diano un contributo al risultato, eventualmente estese con valori nulli ove non vi siano controparti opportune. Esistono tre varianti dell'operatore di join esterno:

1. il join esterno *sinistro*, che estende solo le tuple del primo operando;
2. il join esterno *destro*, che estende solo le tuple del secondo operando;
3. il join esterno *completo*, che le estende tutte.

La seguente figura mostra degli esempi di join esterno.

r_1	<table><tr><th>Impiegato</th><th>Reparto</th></tr><tr><td>Rossi Neri Bianchi</td><td>vendite produzione produzione</td></tr></table>	Impiegato	Reparto	Rossi Neri Bianchi	vendite produzione produzione	r_2	<table><tr><th>Reparto</th><th>Capo</th></tr><tr><td>produzione acquisti</td><td>Mori Bruni</td></tr></table>	Reparto	Capo	produzione acquisti	Mori Bruni
Impiegato	Reparto										
Rossi Neri Bianchi	vendite produzione produzione										
Reparto	Capo										
produzione acquisti	Mori Bruni										
$r_1 \bowtie_{\text{left}} r_2$	<table><tr><th>Impiegato</th><th>Reparto</th><th>Capo</th></tr><tr><td>Rossi Neri Bianchi</td><td>vendite produzione produzione</td><td>null Mori Mori</td></tr></table>			Impiegato	Reparto	Capo	Rossi Neri Bianchi	vendite produzione produzione	null Mori Mori		
Impiegato	Reparto	Capo									
Rossi Neri Bianchi	vendite produzione produzione	null Mori Mori									
$r_1 \bowtie_{\text{right}} r_2$	<table><tr><th>Impiegato</th><th>Reparto</th><th>Capo</th></tr><tr><td>Neri Bianchi null</td><td>produzione produzione acquisti</td><td>Mori Mori Bruni</td></tr></table>			Impiegato	Reparto	Capo	Neri Bianchi null	produzione produzione acquisti	Mori Mori Bruni		
Impiegato	Reparto	Capo									
Neri Bianchi null	produzione produzione acquisti	Mori Mori Bruni									
$r_1 \bowtie_{\text{full}} r_2$	<table><tr><th>Impiegato</th><th>Reparto</th><th>Capo</th></tr><tr><td>Rossi Neri Bianchi null</td><td>vendite produzione produzione acquisti</td><td>null Mori Mori Bruni</td></tr></table>			Impiegato	Reparto	Capo	Rossi Neri Bianchi null	vendite produzione produzione acquisti	null Mori Mori Bruni		
Impiegato	Reparto	Capo									
Rossi Neri Bianchi null	vendite produzione produzione acquisti	null Mori Mori Bruni									

Figura 5.4: Join esterni

Semijoin

Un operatore derivato da quello di join è il *semijoin*, che restituisce le tuple di una relazione che partecipano al join naturale di tale relazione con un'altra. La definizione formale dell'operatore, che viene indicato con il simbolo $\bowtie$, è la seguente:

date due relazioni di $r_1(X_1)$ e $r_2(X_2)$ il semijoin $r_1 \bowtie r_2$ è una relazione definita su X_1 come segue:

$$r_1 \bowtie r_2 = \{t \mid t \in r_1 \text{ ed esiste } t_2 \in r_2 \text{ con } t[X_1 \cap X_2] = t_2[X_1 \cap X_2]\}$$

Sulla base della definizione, è facile osservare che l'operatore può essere espresso per mezzo del join e della proiezione:

$$r_1 \bowtie r_2 = \pi_{X_1}(r_1 \Join r_2)$$

Un esempio di semijoin è mostrato nella seguente figura:

r_1	<table><tr><th>Impiegato</th><th>Reparto</th></tr><tr><td>Rossi</td><td>vendite</td></tr><tr><td>Neri</td><td>produzione</td></tr><tr><td>Bianchi</td><td>produzione</td></tr></table>	Impiegato	Reparto	Rossi	vendite	Neri	produzione	Bianchi	produzione	r_2	<table><tr><th>Reparto</th><th>Capo</th></tr><tr><td>produzione</td><td>Mori</td></tr><tr><td>acquisti</td><td>Bruni</td></tr></table>	Reparto	Capo	produzione	Mori	acquisti	Bruni
Impiegato	Reparto																
Rossi	vendite																
Neri	produzione																
Bianchi	produzione																
Reparto	Capo																
produzione	Mori																
acquisti	Bruni																
$r_1 \bowtie r_2$	<table><tr><th>Impiegato</th><th>Reparto</th></tr><tr><td>Neri</td><td>produzione</td></tr><tr><td>Bianchi</td><td>produzione</td></tr></table>	Impiegato	Reparto	Neri	produzione	Bianchi	produzione										
Impiegato	Reparto																
Neri	produzione																
Bianchi	produzione																

Figura 5.5: Semijoin

Join n-ario, intersezione e prodotto cartesiano

Vediamo alcune proprietà dell'operatore di join naturale. In primo luogo, osserviamo che l'operatore di join è commutativo e associativo. Pertanto, possiamo scrivere, ove necessario, sequenza di join senza parentesi:

$$r_1 \Join r_2 \Join \dots \Join r_n \text{ oppure } \Join_{i=1}^n r_i$$

Se gli insiemi degli attributi, X_1 e X_2 , sono uguali o disgiunti si applica la definizione generale vista sopra, ma in particolare, se $X_1 = X_2$ allora il join coincide con l'intersezione:

$$r_1(X_2) \Join r_2(X_2) = r_1(X_1) \cap r_2(X_2) \iff X_1 = X_2$$

Il caso in cui gli insiemi degli attributi sono disgiunti merita ancora maggiore attenzione. Il risultato è sempre definito sull'unione X_1X_2 , e ciascuna tupla deriva sempre da due tuple, una per ciascuno degli operandi, ma dato che le tuple non hanno attributi comuni, non viene richiesta a esse nessuna condizione per partecipare insieme al join. Quindi, il risultato del join contiene le tuple ottenute combinando, in tutti i modi possibili, le tuple degli operandi. In questo caso allora il join diventa un *prodotto cartesiano*.

Impiegati		Progetti	
Impiegato	Progetto	Codice	Nome
Rossi	A	A	Venere
Neri	A	B	Marte
Neri	B		

Impiegati $\bowtie$ Progetti			
Impiegato	Progetto	Codice	Nome
Rossi	A	A	Venere
Neri	A	A	Venere
Neri	B	A	Venere
Rossi	A	B	Marte
Neri	A	B	Marte
Neri	B	B	Marte

Figura 5.6: Un prodotto cartesiano

Theta-join ed equi-join

Osservando la figura 5.6 possiamo notare che un prodotto cartesiano di solito ha poca utilità, in quanto concatena tuple non correlate dal punto di vista semantico. Spesso, il prodotto cartesiano viene seguito da una selezione, che c'entra l'attenzione su tuple correlate secondo le esigenze. Per esempio, sulle relazioni *Impiegati* e *Progetti* ha senso definire un prodotto cartesiano seguito dalla selezione che mantiene solo le tuple con valori uguali sull'attributo **Progetto** di *Impiegati* e su **Codice** di *Progetti*, come mostrato nella seguente figura:

Impiegati		Progetti	
Impiegato	Progetto	Codice	Nome
Rossi	A	A	Venere
Neri	A	A	Venere
Neri	B	B	Marte

$\sigma_{\text{Progetto}=\text{Codice}}(\text{Impiegati} \bowtie \text{Progetti})$			
Impiegato	Progetto	Codice	Nome
Rossi	A	A	Venere
Neri	A	A	Venere
Neri	B	B	Marte

Figura 5.7: Un prodotto cartesiano seguito da una selezione

Per questo viene definito un operatore derivato, il *theta-join*, come prodotto cartesiano seguito da una selezione, nel modo seguente:

$$r_1 \bowtie_F r_2 = \sigma_F(r_1 \bowtie r_2)$$

ove F è una formula proposizionale. La relazione nella figura 5.7 può essere ottenuta per mezzo del theta-join:

$$\text{Impiegati} \bowtie_{\text{Progetto}=\text{Codice}} \text{Progetti}$$

Un theta-join in cui la condizione è una congiunzione di atomi di uguaglianza viene chiamato *equi-join*.

Il theta-join, in particolare l'equi-join, hanno un importante risvolto pratico, in quanto la maggior parte dei sistemi di basi di dati non utilizzano i nomi di attributi per correlare relazioni e quindi non utilizzano il join naturale ma il theta-join e l'equi-join. Il join naturale può essere simulato per mezzo della ridenominazione, dell'equi-join e della proiezione.

Esempio : Simulazione join naturale

Date due relazioni $r_1(ABC)$ e $r_2(BCD)$, il join naturale di r_1 e r_2 può essere espresso per mezzo degli altri operatori, in tre passi:

- ridenominando gli attributi in modo di ottenere relazioni su schemi disgiunti:

$$\rho_{B'C' \leftarrow BC}(r_2)$$

- effettuando l'equi-join, con condizioni di uguaglianza sugli attributi corrispondenti:

$$r_1 \bowtie_{B=B' \wedge C=C'} \rho_{B'C' \leftarrow BC}(r_2)$$

- concludendo con una proiezione che elimina gli attributi “doppioni”, che presentano valori identici a quelli di altri attributi:

$$\pi_{ABCD}(r_1 \bowtie_{B=B' \wedge C=C'} \rho_{B'C' \leftarrow BC}(r_2))$$

5.1.6 Divisione

L'operatore di divisione, da un certo punto di vista, può essere visto come l'inverso del prodotto cartesiano. Dati due insiemi di attributi disgiunti X_1, X_2 , una relazione r su $X_1 X_2$ e una relazione r_2 su X_2 , la divisione $r \div r_2$ è una relazione su X_1 che contiene le tuple ottenute come “proiezione” di tuple di r che si combinano con tutte le tuple di r_2 per formare tuple di r :

$$r \div r_2 = \{t_1 \text{ su } X_1 \mid \forall t_2 \in r_2 \exists t \in r \text{ con } t[X_1] = t_1 \text{ e } t[X_2] = t_2\}$$

Un esempio di divisione è mostrato nella seguente figura:

Sedi		Uffici		Sedi $\div$ Uffici
Filiale	Ufficio	Ufficio		Filiale
Roma	Acquisti	Acquisti Vendite Studi		Milano
Roma	Vendite			
Roma	Studi			
Milano	Acquisti	Acquisti Vendite Studi		Roma
Milano	Vendite			
Milano	Studi			
Napoli	Acquisti			
Napoli	Vendite			

L'operatore di divisione non è essenziale perchè può essere espresso in termini di altri operatori nel modo seguente:


$$r \div r_2 = \pi_{X_1}(r) - \pi_{X_1}((\pi_{X_1}(r) \times r_2) - r)$$

$\pi_{X_1}(r) \times r_2$ contiene le tuple di $\pi_{X_1}(r)$ estese con tutti i possibili valori di r_2 : quindi la differenza $(\pi_{X_1}(r) \times r_2) - r$ contiene le estensioni di $\pi_{X_1}(r)$ che non

compaiono in r e infine, la proiezione $\pi_{X_1}((\pi_{X_1}(r) \times r_2) - r)$ contiene le tuple di $\pi_{X_1}(r)$ per le quali un qualche completamento con r_2 non compare in r . Togliendo a queste $\pi_{X_1}(r)$ otteniamo le tuple di $\pi_{X_1}(r)$ che si combinano con tutte quelle di r_2 .

L'operatore di divisione è il suo rapporto con il prodotto cartesiano, è facile verificare che, se applichiamo la divisione al risultato di un prodotto cartesiano, riotteniamo le relazioni originarie. Specificatamente date due relazioni r_1 e r_2 , su insiemi di attributi disgiunti, abbiamo che $(r_1 \times r_2) \div r_2 = r_1$.

La seguente figura mostra i risultati della divisione ottenuta con l'operatore di proiezione e differenza:



5.1.7 Interrogazioni in algebra relazionale

Un'interrogazione può essere definita come una funzione che, applicata a istanze di base di dati, produce relazioni. Più precisamente, dato uno schema $\mathbf{R}$ di base di dati, un'interrogazione è una funzione che, per ogni istanza di $\mathbf{r}$ di $\mathbf{R}$, produce una relazione su un dato insieme di attributi X . Le espressioni dei vari linguaggi di interrogazione, come l'algebra relazionale, rappresentano delle interrogazioni: ogni espressione definisce una funzione. Indichiamo con $E(\mathbf{r})$ il risultato dell'applicazione dell'espressione E alla base di dati $\mathbf{r}$.

In algebra relazionale, le interrogazioni su uno schema di basi di dati **R** vengono formulate con espressioni i cui atomi sono relazioni in **R**.

Di seguito, sono mostrate alcune interrogazioni di crescente complessità, che fanno riferimento allo schema contenente le due relazioni:

Impiegati(Matr, Nome, Età, Stipendio)

Supervisione(Capo, Impiegato)

La prima interrogazione chiede di trovare matricola, nome ed età degli impiegati che guadagnano più di 40000 mila euro:

$$\pi_{Matr, Nome, Et}(\sigma_{Stipendio > 40}(\text{Impiegati}))$$

La seconda interrogazione coinvolge entrambe le relazioni, in modo molto naturale: trovare le matricole dei capi degli impiegati che guadagnano più di 40mila euro:

$$\pi_{Capo}(\text{Supervisione} \bowtie_{Impiegato=Matr} \sigma_{Stipendio > 40}(\text{Impiegati}))$$

La terza interrogazione chiede di trovare nome e stipendio dei capi degli impiegati che guadagnano più di 40mila euro. In questo caso, possiamo far uso dell'espressione precedente, ma dobbiamo poi produrre, per ciascuna tupla del risultato, le informazioni richieste sul capo che vanno estratte dalla relazione Impiegati. Ogni tupla del risultato è costruita a partire da tre tuple: la prima di Impiegati, relativa a un impiegato che guadagna più di 30mila euro, la seconda di Supervisione, che indica la matricola del capo dell'impiegato in questione, e la terza di Impiegati, con le informazioni relative al capo.

$$\pi_{NomeC, StipC} \left(\begin{array}{l} \rho_{MatrC, NomeC, StipC, EtaC \leftarrow Matr, Nome, Stip, Eta}(\text{Impiegati}) \\ \bowtie_{MatrC=Capo} \text{Supervisione} \\ \bowtie_{Imp=Matr} \sigma_{Stip > 40}(\text{Impiegati}) \end{array} \right)$$


La quarta interrogazione è una variante del precedente, in quanto richiede il confronto di due valori dello stesso attributo, di tuple diverse: trovare gli impiegati che guadagnano più del rispettivo capo, mostrando matricola, nome e stipendio di ciascuno di essi e del capo.

$$\pi_{Matr, Nome, Stip, MatrC, NomeC, StipC} \left(\sigma_{Stip > StipC} \left(\rho_{MatrC, NomeC, StipC, EtaC \leftarrow Matr, Nome, Stip, Eta}(\text{Impiegati}) \right) \right. \\ \left. \bowtie_{MatrC=Capo} \text{Supervisione} \bowtie_{Imp=Matr} \text{Impiegati} \right)$$

L'ultimo esempio richiede più attenzione: trovare matricola e nome dei capi i cui impiegati guadagnano tutti più di 40mila euro.

$$\pi_{\text{Matr, Nome}}(\text{Impiegati} \bowtie_{\text{Matr}=\text{Capo}} (\pi_{\text{Capo}}(\text{Supervisione}) - \pi_{\text{Capo}}(\text{Supervisione} \bowtie_{\text{Imp}=\text{Matr}} \sigma_{\text{Stip} \leq 40}(\text{Impiegati}))))$$

A volte, può essere conveniente utilizzare per l'algebra relazionale, una notazione grafica, in cui un'espressione è rappresentata per mezzo di un albero le cui foglie sono operandi e gli altri nodi corrispondono a degli operatori. Ogni nodo che non sia una foglia ha un numero di figli pari al numero di operandi dell'operatore, quindi i nodi con proiezione, selezioni e ridenominazioni hanno un solo figlio, mentre quelli relativi agli altri operatori ne hanno due. Di seguito viene mostrato un esempio di questa notazione:



5.1.8 Equivalenza di espressioni algebriche

L'algebra relazionale permette di formulare espressioni fra loro *equivalenti*, cioè che producono lo stesso risultato. Ad esempio vale la seguente equivalenza:

$$x \times (y + z) \equiv x \times y + x \times z$$

Nell'algebra relazionale possiamo dare una definizione analoga, ma dobbiamo fare attenzione al fatto che l'equivalenza dipende dallo schema, oppure essere assoluta:

- $E_1 \equiv_{\mathbf{R}} E_2 \iff E_1(\mathbf{r}) = E_2(\mathbf{r})$ per ogni istanza di $\mathbf{r}$ in $\mathbf{R}$.

- $E_1 \equiv E_2 \iff E_1 \equiv_{\mathbf{R}} E_2$ per ogni schema $\mathbf{R}$.

La distinzione è dovuta al fatto che gli schemi degli operandi non vengono esplicitati nelle espressioni e il comportamento può variare a seconda degli attributi nei vari schemi di relazione. Un esempio di equivalenza assoluta è:

$$\pi_{AB}(\sigma_{A>0}(R)) \equiv \sigma_{A>0}(\pi_{AB}(R))$$

mentre la seguente equivalenza:

$$\pi_{AB}(R_1) \bowtie \pi_{AC}(R_2) \equiv_{\mathbf{R}} \pi_{ABC}(R_1 \bowtie R_2)$$

sussiste se e solo se nello schema $\mathbf{R}$ l'intersezione fra gli insiemi di attributi R_1 e R_2 è pari ad A . Infatti, se ci fossero anche altri attributi, il join opererebbe solo su A nella prima espressione e su A e gli altri attributi nella seconda, con risultati diversi.

L'equivalenza di espressioni dell'algebra risulta molto importante dal punto di vista applicativo, infatti, le interrogazioni specificate in linguaggio SQL vengono tradotte in algebra relazionale e viene valutato il costo in termini di risultati intermedi. In presenza di alternative equivalenti, viene scelta quella con costo minore. Vengono, quindi, utilizzate *trasformazioni di equivalenza* cioè operazioni che sostituiscono un'espressione con un'altra a essa equivalente. In particolare, risultano interessanti le trasformazioni che riducono le dimensioni dei risultati intermedi e quelle che preparano un'espressione all'applicazione di una trasformazione che riduce le dimensioni dei risultati intermedi. Vediamo alcune trasformazioni interessanti.

1. **Atomizzazione delle selezioni:** una selezione congiuntiva può essere sostituita da una cascata di selezioni atomiche:

$$\sigma_{F_1 \wedge F_2}(E) \equiv \sigma_{F_1}(\sigma_{F_2}(E))$$

dove E è una qualunque espressione. Questa trasformazione permette di applicare successive trasformazioni che operano su selezioni con condizioni atomiche.

2. **Idempotenza delle proiezioni:** una proiezione può essere trasformata in una cascata di proiezioni che “eliminano” i vari attributi in fasi successive:

$$\pi_X(E) \equiv \pi_X(\pi_{XY}(E))$$

Anche questa è una trasformazione preliminare rispetto ad altre.

3. **Anticipazione della selezione rispetto al join**, detta anche *pushing selections down*, con riferimento al fatto che, nella rappresentazione di espressioni sotto forma di alberi, la selezione viene spostata verso il basso:

$$\sigma_F(E_1 \bowtie E_2) \equiv E_1 \bowtie \sigma_F(E_2)$$

se la condizione F fa riferimento solo ad attributi nella sottoespressione E_2 .

4. **Anticipazione della proiezione rispetto al join**, detta anche *pushing projections down*: siano E_1 e E_2 definite rispettivamente su X_1 e X_2 : se $Y_2 \subseteq X_2$ e $Y_2 \supseteq (X_1 \cap X_2)$, cioè gli attributi $X_2 - Y_2$ non sono coinvolti nel join, allora vale l'equivalenza:

$$\pi_{X_1, Y_2}(E_1 \bowtie E_2) \equiv E_1 \bowtie \pi_{Y_2}(E_2)$$

Combinando questa regola con quella dell'idempotenza, possiamo ottenere la seguente equivalenza:

$$\pi_Y(E_1 \bowtie_F E_2) \equiv \pi_Y(\pi_{Y_1}(E_1) \bowtie_F \pi_{Y_2}(E_2))$$

dove indicando con X_1 ed X_2 gli attributi di E_1 ed E_2 rispettivamente e con J_1 ed J_2 i rispettivi sottoinsiemi coinvolti nella condizione F di join:

$$Y_1 = (X_1 \cap Y) \cup J_1$$

$$Y_2 = (X_2 \cap Y) \cup J_2$$

In sostanza, possiamo eliminare da ciascuna relazione gli attributi che non compaiono nel risultato finale e non sono coinvolti nel join.

5. **Inglobamento di una selezione in un prodotto cartesiano a formare un join**:

$$\sigma_F(E_1 \bowtie E_2) \equiv E_1 \bowtie_F E_2$$

con $X_1 \cap X_2 = \emptyset$, indicando con X_1 ed X_2 rispettivamente gli attributi di E_1 ed E_2

Data la seguente base di dati:

Impiegati

Matr	Nome	Età	Stipendio
101	Mario Rossi	34	40
103	Mario Bianchi	23	35
104	Luigi Neri	38	61
105	Nico Bini	44	38
210	Marco Celli	49	60
231	Siro Bisi	50	60
252	Nico Bini	44	70
301	Sergio Rossi	34	70
375	Mario Rossi	50	65

Supervisione

Capo	Impiegato
210	101
210	103
210	104
231	105
301	210
301	231
375	252

Figura 5.8: Esempio di una base di dati per le espressioni

Supponiamo di voler trovare i numeri di matricola dei capi di impiegati con meno di trent'anni.

$$\pi_{Capo}(\sigma_{Matr=Imp \wedge Eta < 30}(\text{Impiegati} \bowtie \text{Supervisione}))$$

La qualità di quest'espressione è molto bassa, perchè per calcolare pochi valori effettua un prodotto cartesiano. Utilizzando le regole precedenti possiamo migliorarla significativamente. Con la regola 1. spezziamo la selezione:

$$\pi_{Capo}(\sigma_{Matr=Imp}(\sigma_{Eta < 30}(\text{Impiegati} \bowtie \text{Supervisione})))$$

Possiamo poi fondere la prima selezione con il prodotto cartesiano e formare un join, la regola 5., e anticipare la seconda selezione rispetto al join, la regola 3.:

$$\pi_{Capo}(\sigma_{Eta < 30}(\text{Impiegati}) \bowtie_{Matr=Imp} \text{Supervisione})$$

Infine, possiamo eliminare dal primo argomenti del join gli attributi non necessari, utilizzando la regola 4.:

$$\pi_{Capo}(\pi_{Matr}(\sigma_{Eta < 30}(\text{Impiegati})) \bowtie_{Matr=Imp} \text{Supervisione})$$

Vediamo ora altre trasformazioni interessanti:

6. Distributività della selezione rispetto all'unione:

$$\sigma_F(E_1 \cup E_2) \equiv \sigma_F(E_1) \cup \sigma_F(E_2)$$

7. Distributività della selezione rispetto alla differenza:

$$\sigma_F(E_1 - E_2) \equiv \sigma_F(E_1) - \sigma_F(E_2)$$

8. Distributività della selezione rispetto all'unione:

$$\pi_F(E_1 \cup E_2) \equiv \pi_F(E_1) \cup \pi_F(E_2)$$

Vale la pena notare che la proiezione non è distributiva rispetto alla differenza, come si può verificare applicando le espressioni:

$$\pi_A(R_1 - R_2) \neq \pi_A(R_1) - \pi_A(R_2)$$

a due relazioni su AB che contengano tuple uguali su A e diverse su B .

Un altro gruppo di trasformazioni contiene quelle che si basano sull'intersezione fra gli operatori insiemistici e le selezioni complesse:

$$9. \sigma_{F_1 \vee F_2}(R) \equiv \sigma_{F_1}(R) \cup \sigma_{F_2}(R)$$

$$10. \sigma_{F_1 \wedge F_2}(R) \equiv \sigma_{F_1}(R) \cap \sigma_{F_2}(R) \equiv \sigma_{F_1}(R) \bowtie \sigma_{F_2} R$$

$$11. \sigma_{F_1 \wedge \neg(F_2)}(R) \equiv \sigma_{F_1}(R) - \sigma_{F_2}(R)$$

Abbiamo poi la proprietà commutativa e associativa di tutti gli operatori binari, esclusa la differenza, e la proprietà distributiva del join rispetto all'unione:

$$12. E \bowtie (E_1 \cup E_2) \equiv (E \bowtie E_1) \cup (E \bowtie E_2)$$

Vale la pena notare che la presenza di risultati intermedi vuoti permette di semplificare le espressioni in modo abbastanza naturale. Notiamo che un join in cui uno degli operandi sia la relazione vuota produce un risultato vuoto, perchè non è possibile concatenare con alcuna tupla le tuple dell'altra relazione.

5.1.9 Algebra con valori nulli

Finora abbiamo supposto che le espressioni dell'algebra venissero applicate a relazioni prive di valori nulli, ma abbiamo studiato l'importanza dei valori nulli nelle applicazioni reali e quindi dobbiamo studiare l'impatto che essi hanno nei linguaggi trattati.

Consideriamo la seguente relazione:

Persone

Nome	Età	Reddito
Aldo	35	15
Andrea	27	21
Maria	null	42

Figura 5.9: Una relazione con valori nulli

Consideriamo la seguente selezione:

$$\sigma_{Eta>30}(\text{Persone})$$

Sappiamo che la prima tupla fa parte del risultato e la seconda no. Ma per quanto riguarda il terzo? A proposito di queste interrogazioni è stato proposto di utilizzare una logica a tre valori, in cui un predicato può essere vero oppure falso oppure assumere un terzo, nuovo valore di verità che chiameremo *unknown* e rappresentiamo il simbolo con *U*. Quindi ritornando al nostro esempio, la prima tupla appartiene al risultato quindi è vera, la seconda non appartiene quindi è falsa e la terza forse appartiene e forse no. Le tabelle dei connettivi logici *not*, *or* e *and* si estendono nel modo seguente:

<i>not</i>		<i>and</i>	V	U	F	<i>or</i>	V	U	F
F	V	V	V	U	F	V	V	V	V
U	U	U	U	U	F	U	V	U	U
V	F	F	F	F	F	F	V	U	F

Una selezione su relazioni con valori nulli produce come risultato le tuple per cui il risultato predicato risulta vero. Il valore *unknown* rappresenta un valore di verità intermedio tra vero e falso, e il significato dei tre connettivi in questo caso diventa: il *not* è vero solo se il valore di partenza è falso, l'*and* è vero solo se tutti i termini sono veri e l'*or* è vero se almeno uno dei termini è vero.

La logica a tre valori risulta significativa nel caso di espressioni complesse, in cui il risultato presenta proprietà poco soddisfacenti. Per esempio, consideriamo la seguente espressione:

$$\sigma_{Eta>30}(\text{Persone}) \cup \sigma_{Eta\leq 30}(\text{Persone})$$

Questa, a livello logico, dovrebbe restituire la relazione *Persone*, ma se le due sottoespressioni sono valutate separatamente, la terza tupla ha un'appartenenza sconosciuta a ciascuna sottoespressione e quindi all'unione.

Il modo migliore per superare gli inconvenienti appena discussi consiste nel trattare i valori nulli da un punto di vista meramente sintattico, tralasciando cosa essi potrebbero rappresentare. Allo scopo, si introducono due nuove forme di condizioni atomiche di selezione, che valutano se un valore è specificato oppure nullo:

- *A is null* assume valore vero se una tupla *t* se il valore di *t* su *A* è nullo e falso se esso è specificato;
- *A is not null* assume valore vero su una tupla *t* se il valore di *t* su *A* è specificato e falso se il valore è nullo.

Quindi, l'espressione:

$$\sigma_{Eta>30}(\text{Persone})$$

restituisce le persone la cui età è nota e maggiore di 30, mentre per ottenere quelle che hanno o potrebbero avere più di trent'anni possiamo utilizzare l'espressione:

$$\sigma_{Eta>30 \vee Eta \text{ is null}}(\text{Persone})$$

5.1.10 Viste

A volte può risultare mettere a disposizione degli utenti rappresentazioni diverse per gli stessi dati. Nel modello relazionale la tecnica prevista a questo scopo è quella delle *relazioni derivate*, relazioni il cui contenuto è funzione del contenuto di altre relazioni. In una base di dati relazionale, quindi, possono esistere le relazioni *di base*, il cui contenuto è autonomo, e relazioni derivate, il cui contenuto è funzione di quello di altre relazioni. È possibile che una relazione derivata sia funzione di altre relazioni derivate, a condizione che esista un ordinamento fra le relazioni derivate tale che ogni relazione sia definita solo in termini di relazioni di base e di relazioni derivate che la precedono nell'ordinamento.

Possono esistere due tipi di relazioni derivate:

- *viste materializzate*: relazioni effettivamente memorizzate nella base di dati;
- *relazioni virtuali*: esse sono anche chiamate *viste* e sono relazioni definite per mezzo di funzioni, non memorizzate nella base di dati, ma utilizzabili nelle interrogazioni come se le fossero.

Le viste materializzate hanno il vantaggio di essere immediatamente disponibili per le interrogazioni, ma spesso è oneroso mantenere il loro contenuto allineato con quello delle relazioni da cui derivano. Le relazioni virtuali devono essere calcolate per ogni interrogazione ma non presentano problemi di allienamento. Le viste materializzate sono convenienti quando gli aggiornamenti sono rari rispetto alle interrogazioni e il calcolo della vista è complesso. In generale, non esistono tecniche per mantenere l'allineamento e per questo, i sistemi attuali forniscono solo meccanismi per la gestione di relazioni virtuali che chiameremo *viste*.

Le viste vengono definite nei sistemi relazioni per mezzo di espressioni del linguaggio di interrogazione. Eventuali interrogazioni che si riferiscono alle viste vengono risolte sostituendo alla vista la sua definizione. Di solito, i sistemi relazionali stabiliscono la strategia di esecuzione delle interrogazioni dopo aver sostituito alla vista la sua definizione. Per esempio, supponiamo di avere una base di dati sulle seguenti relazioni:

$$R_1(ABC) \quad R_2(DEF) \quad R_3(GH)$$

con una vista definita per mezzo di un prodotto cartesiano seguito da una selezione:

$$R = \sigma_{A>D}(R_1 \bowtie R_2)$$

Su questo schema, l'interrogazione:

$$\sigma_{B=G}(R \bowtie R_3)$$

viene eseguita sostituendo a R la sua definizione:

$$\sigma_{B=G}(\sigma_{A>D}(R_1 \bowtie R_2) \bowtie R_3)$$

L'uso delle viste può essere vantaggioso per diversi motivi:

- Un utente interessato solo a una porzione della base di dati può evitare di considerare le componenti irrilevanti.
- Espressioni molto complesse possono essere definite tramite viste, con vantaggi rilevanti soprattutto se ci sono sottoespressioni ripetute.
- Attraverso la definizione di autorizzazioni di accesso rispetto alla viste, è possibile introdurre meccanismi di protezione della privacy.

- In occasione di ristrutturazione di una base di dati, può risultare conveniente definire viste che corrispondano a relazioni sostituite da altre e perciò non più presenti dopo la ristrutturazione, ma ricavabili dalle nuove relazioni. Ad esempio, se uno schema $R(ABC)$ viene sostituito dagli schemi $R_1(AB)$ e $R_2(BC)$ è possibile definire una vista $R = R_1 \bowtie R_2$ e mantenere inalterate le applicazioni che fanno riferimento a R .

Per quanto riguarda le interrogazioni le viste possono essere trattate come le relazioni di base, ma non si può dire lo stesso per le operazioni di aggiornamento. Infatti, in molti casi non è possibile definire una semantica degli aggiornamenti sulle viste: dato un aggiornamento su una vista, in generale non esiste uno e un solo aggiornamento delle relazioni di base che porti a un'istanza della base di dati cui corrisponda un'istanza della vista che sia il risultato effettivo dell'aggiornamento specificato sulla vista. Per questo, molti sistemi pongono forti limitazioni riguardo alla possibilità di specificare aggiornamenti sulle viste.

5.2 Calcolo relazionale

Il *calcolo relazionale* fa riferimento a una famiglia di linguaggi di interrogazione, basati sul calcolo dei predicati del primo ordine, che hanno la caratteristica di essere *dichiarativi*, cioè di specificare le proprietà del risultato delle interrogazioni, anziché la procedura seguita per generarlo. In contrasto, l'algebra relazionale è un linguaggio *procedurale*, in quanto le sue espressioni specificano passo passo la costruzione del risultato.

Esistono diverse versioni del calcolo relazionale:

- il **calcolo relazionale sui domini** che presenta in modo naturale tutte le caratteristiche originali di questi linguaggi;
- il **calcolo su tuple con dichiarazioni di range**, che costituisce la base per molti dei costrutti disponibili per le interrogazioni nel linguaggio SQL.

Rispetto alla definizione dei calcoli del predicato del primo ordine, nel calcolo relazionale ci sono alcune semplificazioni. Mentre nel calcolo dei predicati abbiamo simboli di predicato e di funzione, nel calcolo relazionale i simboli di predicato corrispondono alle relazioni nelle base di dati e non compaiono simboli di funzione perchè non sono necessari.

Inoltre, nel calcolo dei predicati interessano sia formule aperte, cioè con variabili libere, sia formule chiuse, con tutte variabili legate. Nel calcolo relazionale

interessano le formule aperte: un'interrogazione è definita per mezzo di una formula del calcolo e il risultato è costituito dalle tuple di valori che rendono vera la formula stessa.

5.2.1 Calcolo relazione su domini

Le espressioni del calcolo relazionale su domini hanno la forma:

$$\{A_1 : x_1, \dots, A_k : x_k \mid f\}$$

ove:

- $A_1, \dots, A_k$ sono attributi distinti, che possono anche non comparire nello schema della base di dati rispetto a cui viene formulata l'interrogazione;
- $x_1, \dots, x_k$ sono *variabili* che per comodità le consideriamo distinte ma non necessariamente sono distinte;
- f è una formula, secondo le seguenti regole:
 - Vi sono formule *atomiche* di due tipi:
 - * $R(A_1 : x_1, \dots, A_p : x_p)$, dove $R(A_1 \dots A_p)$ è uno schema di relazione e $x_1, \dots, x_p$ sono variabili;
 - * $x\theta y$ o $x\theta c$ con x e y variabili, c costante e θ operatore di confronto ($=, \neq, \leq, \geq, <, >$)
 - Se f_1 e f_2 sono formule, allora $f_1 \vee f_2$, $f_1 \wedge f_2$ e $\neg f_1$ sono formule;
 - Se f è una formula e x una variabile allora $\exists x(f)$ e $\forall x(f)$ sono formule.

La lista di coppie $A_1 : x_1, \dots, A_k : x_k$ viene chiamata *target list* in quanto definisce la struttura del risultato, che è costituito dalla relazione su $A_1, \dots, A_k$ che contiene le tuple i cui valori, sostituiti a $x_1, \dots, x_k$, rendono vera la formula rispetto a un'istanza di base di dati a cui l'espressione viene applicata.

Definiamo il concetto di *valore di verità* informalmente seguendo la struttura sintattica delle regole, ove per valore intendiamo “elemento del dominio”:

- una formula atomica $R(A_1 : x_1, \dots, A_p : x_p)$ è vera sui valori di $x_1, \dots, x_p$ che formano una tupla della relazione r sullo schema R nell'istanza di base di dati a cui l'espressione viene applicata;

- una formula atomica $x\theta y$ è vera sui valori a_1 e a_2 se il confronto $a_1\theta a_2$ è soddisfatto, analogamente per $x\theta c$;
- per congiunzione, disgiunzione e negazione valgono le usuali definizioni;
- per le formule con i quantificatori:
 - $\exists x(f)$ è vera se esiste almeno un valore a che sostituito alla variabile x rende vera f ;
 - $\forall x(f)$ è vera se, per ogni possibile valore a per la variabile x , la formula f risulta vera.

Con riferimento allo schema di base di dati sulle relazioni:

$\text{Impiegati}(\text{Matr}, \text{Nome}, \text{Età}, \text{Stipendio})$

$\text{Supervisione}(\text{Capo}, \text{Impiegato})$

La prima interrogazione chiede di trovare matricola, nome, età e stipendio degli impiegati che guadagnano più di 40 mila euro:

$\sigma_{\text{Stipendio} > 40}(\text{Impiegati})$

Nel calcolo relazionale questa interrogazione si formula con la seguente espressione:

$\{\text{Matr: } m, \text{Nome: } n, \text{Età: } e, \text{Stipendio: } s \mid$
 $\text{Impiegati}(\text{Matr} : m, \text{Nome: } n, \text{Età: } e, \text{Stipendio: } s) \wedge s > 40\}$

Notiamo la presenza di due condizioni nella formula:

- la prima, $\text{Impiegati}(\text{Matr} : m, \text{Nome: } n, \text{Età: } e, \text{Stipendio: } s)$, richiede che i valori rispettivamente sostituiti alle variabili m, n, e, s costituiscano una tupla della relazione Impiegati ;
- la seconda richiede che il valore della variabile s sia maggiore di 40;

Un'altra interrogazione, appena più complessa richiede di trovare matricola, nome ed età degli impiegati che guadagnano più di 40 mila euro, che in algebra relazione si esprime con:

$\pi_{\text{Matr}, \text{Nome}, \text{Età}}(\sigma_{\text{Stipendio} > 40}(\text{Impiegati}))$

Nel calcolo relazionale questa può essere formulata in vari modi. Il più diretto, ma non il più semplice, è basato sul fatto che ciò che ci interessa sono i valori di matricola, nome ed età che partecipano a tuple per le quali lo stipendio è maggiore di 40. Possiamo usare un quantificatore esistenziale:

$$\{\mathbf{Matr}: m, \mathbf{Nome}: n, \mathbf{Età}: e \mid \exists s(\text{Impiegati}(\mathbf{Matr}: m, \mathbf{Nome}: n, \mathbf{Età}: e, \mathbf{Stipendio}: s) \wedge s > 40)\}$$

L'uso del quantificatore, in realtà, non è necessario, perchè scrivendo semplicemente:

$$\{\mathbf{Matr}: m, \mathbf{Nome}: n, \mathbf{Età}: e \mid \text{Impiegati}(\mathbf{Matr}: m, \mathbf{Nome}: n, \mathbf{Età}: e, \mathbf{Stipendio}: s) \wedge s > 40\}$$

otteniamo lo stesso risultato.

La stessa struttura si estende a interrogazioni più complesse. Ad esempio, l'interrogazione che vuole trovare le matricole dei capi degli impiegati che guadagnano più di 40 mila euro, formulata in algebra relazionale come:

$$\pi_{\text{Capo}}(\text{Supervisione} \bowtie_{\text{Impiegato}=\text{Matr}} \sigma_{\text{Stipendio}>40}(\text{Impiegati}))$$

può essere formulata nel calcolo relazionale con:

$$\{\mathbf{Capo}: c \mid \text{Impiegati}(\mathbf{Matr}: m, \mathbf{Nome}: n, \mathbf{Età}: e, \mathbf{Stipendio}: s) \wedge \text{Supervisione}(\mathbf{Impiegato}: m, \mathbf{Capo}: c) \wedge s > 40\}$$

dove la variabile m , comune alle due condizioni atomiche, realizza la stessa correlazione fra tuple specificata nel join.

L'interrogazione che vuole trovare nome e stipendio dei capi degli impiegati che guadagnano più di 40 mila euro, scritta in algebra relazionale come:

$$\pi_{\text{NomeC}, \text{StipC}}(\rho_{\text{MatrC}, \text{NomeC}, \text{StipC}, \text{EtaC} \leftarrow \text{Matr}, \text{Nome}, \text{Stip}, \text{Eta}}(\text{Impiegati}) \bowtie_{\text{MatrC}=\text{Capo}} \text{Supervisione} \bowtie_{\text{Impiegato}=\text{Matr}} \sigma_{\text{Stipendio}>40}(\text{Impiegati}))$$

viene formulata nel calcolo, per ciascuna tupla del risultato, l'esistenza di tre tuple: una relativa a un impiegato che guadagna più di 40 mila euro, una seconda che indica chi è il suo capo e l'ultima che fornisce le informazioni di dettaglio sul capo:

$$\{\mathbf{NomeC}: nc, \mathbf{StipC}: sc \mid$$

$\text{Impiegati}(\mathbf{Matr: } m, \mathbf{Nome: } n, \mathbf{Et\grave{a}: } e, \mathbf{Stipendio: } s) \wedge s > 40$

$\text{Supervisione}(\mathbf{Impiegato: } m, \mathbf{Capo: } c) \wedge$

$\text{Impiegati}(\mathbf{Matr: } c, \mathbf{Nome: } nc, \mathbf{Et\grave{a}: } ec, \mathbf{Stipendio: } sc)\}$

L'ultimo esempio richiede una soluzione piÙ complessa. Dobbiamo trovare matricola e nome dei capi i cui impiegati guadagnano tutti piÙ di 40 mila euro. In algebra abbiamo utilizzato una differenza:

$\pi_{Matr, Nome}(\text{Impiegati} \bowtie_{Matr=Capo}$

$(\pi_{Capo}(\text{Supervisione}) -$

$\pi_{Capo}(\text{Supervisione} \bowtie_{Imp=Matr} \sigma_{Stip \leq 40}(\text{Impiegati})))$

Nel calcolo dobbiamo utilizzare un quantificatore. Seguendo la stessa logica dell'espressione in algebra relazionale possiamo utilizzare un quantificatore esistenziale negato, ognuno per ogni variabile coinvolta, trovando i capi per quali non esiste un impiegato che guadagna non piÙ di 40 mila euro:

$\{\mathbf{Matr: } c, \mathbf{Nome: } n \mid$

$\text{Impiegati}(\mathbf{Matr: } c, \mathbf{Nome: } n, \mathbf{Et\grave{a}: } e, \mathbf{Stip: } s) \wedge$

$\text{Supervisione}(\mathbf{Impiegato: } m, \mathbf{Capo: } c) \wedge$

$\neg \exists m' (\exists n' (\exists e' (\exists s' (\text{Impiegati}(\mathbf{Matr: } m', \mathbf{Nome: } n', \mathbf{Et\grave{a}: } e', \mathbf{Stip: } s') \wedge$

$\text{Supervisione}(\mathbf{Impiegato: } m', \mathbf{Capo: } c) \wedge s' \leq 40))))\}$

In alternativa, possiamo utilizzare quantificatori universali:

$\{\mathbf{Matr: } c, \mathbf{Nome: } n \mid$

$\text{Impiegati}(\mathbf{Matr: } c, \mathbf{Nome: } n, \mathbf{Et\grave{a}: } e, \mathbf{Stip: } s) \wedge$

$\text{Supervisione}(\mathbf{Impiegato: } m, \mathbf{Capo: } c) \wedge$

$\forall m' (\forall n' (\forall e' (\forall s' (\neg (\text{Impiegati}(\mathbf{Matr: } m', \mathbf{Nome: } n', \mathbf{Et\grave{a}: } e', \mathbf{Stip: } s') \wedge$

$\text{Supervisione}(\mathbf{Impiegato: } m', \mathbf{Capo: } c)) \vee s' > 40))))\}$

Questa espressione seleziona un capo c se, per ogni quadrupla di valori m', n', e' e s' relativi a impiegati di c , si ha che s' è maggiore di 40. La struttura $\neg f \vee g$

corrisponde alla condizione “se f allora g ” in quanto è vera in tutti i casi escluso in cui f è vera e g è falsa. Notiamo le leggi di De Morgan che valgono per gli operatori dell'algebra di Boole:

$$\neg(f \wedge g) = \neg(f) \vee \neg(g)$$

$$\neg(f \vee g) = \neg(f) \wedge \neg(g)$$

valgon allo stesso modo anche per i quantificatori:

$$\exists x(f) = \neg(\forall x(\neg(f)))$$

$$\forall x(f) = \neg(\exists x(\neg(f)))$$

5.2.2 Pregi e difetti del calcolo su domini

Il calcolo relazionale presenta aspetti interessanti, soprattutto per la dichiaratività, ma anche alcuni difetti e limitazioni. Innanzitutto, notiamo che il calcolo ammette espressioni che hanno veramente poco senso. Ad esempio l'espressione:

$$\{A_1 : x_1, A_2 : x_2 \mid R(A_1 : x_1) \wedge x_2 = x_2\}$$

produce come risultato una relazione su A_1 e A_2 costituita da tuple il cui valore su A_1 compare nella relazione R e il valore su A_2 è un qualunque valore del dominio. In particolare, se cambia il dominio, cambia anche la risposta all'interrogazione. Se il dominio è infinito, anche la risposta è infinita, il che è indesiderabile.

Pertanto, può essere utile introdurre un concetto: un'espressione di un linguaggio di interrogazione è *indipendente dal dominio* se il suo risultato, su ciascuna istanza di base di dati, non varia al variare del dominio rispetto al quale l'espressione è valutata. Un linguaggio è indipendente dal dominio se tutte le sue espressioni sono indipendenti dal dominio. Il requisito di indipendenza dal dominio è fondamentale per i linguaggi reali, perchè la maggior parte delle volte le espressioni dipendenti dal dominio non hanno utilità pratica e possono produrre risultati di grandi dimensioni.

Il calcolo relazionale, dagli esempi visti prima non è indipendente dal dominio, mentre, l'algebra relazionale lo è, perchè costruisce i risultati a partire dalle relazioni nella base di dati, senza far riferimento ai domini degli attributi.

Inoltre, l'algebra relazione il calcolo non sono equivalenti, perchè non hanno espressioni equivalenti, infatti, il calcolo relazione ammette espressioni dipendenti dal dominio.

Se limitiamo la nostra attenzione al sottoinsieme del calcolo relazionale costituito dalle sole espressioni indipendenti dal dominio, otteniamo un linguaggio equivalente all'algebra relazionale. Infatti:

- per ogni espressione del calcolo relazionale che sia indipendente dal dominio esiste un'espressione dell'algebra relazionale equivalente a essa;
- per ogni espressione dell'algebra relazionale esiste un'espressione del calcolo relazionale equivalente a essa.

Oltre al problema della dipendenza dal dominio, un altro svantaggio è quello di richiedere numerose variabili. Quando poi sono necessarie quantificazioni, anche i quantificatori si moltiplicano.

Per superare i limiti sul calcolo dei domini, è stata proposta un'altra versione del calcolo relazionale in cui le variabili, anziché denotare singoli valori, denotano tuple. Molto spesso il numero di variabili si riduce di tanto, perché si ha una variabile per ciascuna relazione coinvolta. Diventa poi necessario associare una struttura a ciascuna variabile e realizzare opportunamente le operazioni di confronto. Potremmo definire un *calcolo relazionale su tuple* perfettamente corrispondente al calcolo su domini, ma preferiamo passare a un linguaggio che, recependo le caratteristiche del calcolo su tuple, superi la dipendenza dal dominio, attraverso l'associazione delle variabili alle relazioni della base di dati.

5.2.3 Calcolo su tuple con dichiarazioni di range

Le espressioni del *calcolo su tuple con dichiarazioni di range* hanno la forma:

$$\{T \mid L \mid f\}$$

ove:

- T è la *target list*, con elementi del tipo $Y : x.Z$ (o semplicemente $x.Z$, abbreviazione per $Z : x.Z$) con x variabile e Y e Z sequenze di attributi; gli attributi in Z devono comparire nello schema della relazione che costituisce il *range* di x ; si può anche scrivere $x.*$, come abbreviazione di $X : x.X$, dove il range della variabile x è una relazione sull'insieme di attributi X ;
- L è la *range list*, che elenca le variabili libere della formula f con i relativi range: infatti, L è una lista di elementi del tipo $x(R)$, con x variabile e R nome di relazione;

- f è una formula con:
 - atomi del tipo $x.A\theta c$ o $x_1A_1\theta x_2A_2$, che confrontano, rispettivamente, il valore di x sull'attributo A con la costante c e il valore di x_1 su A_1 con quello di x_2 su A_2 ;
 - connettivi come nel calcolo su domini;
 - quantificatori che associano i range alle relativi variabili:

$$\exists x(R)(f) \quad \forall x(R)(f)$$

$\exists x(R)(f)$ significa “esiste nella relazione R una tupla x che soddisfa la formula f ”.

Le dichiarazioni di range specificano che la variabili possono assumere come valore solo tuple nella relazione rispettivamente associata e garantiscono così l'indipendenza dal dominio. Di conseguenza, quest linguaggio non ha bisogno di condizioni atomiche come quelle viste nel calcolo su domini, che specificano l'appartenenza di una tupla a una relazione.

Vediamo come possono essere espresse in questo linguaggio le varie interrogazioni già formulate in algebra e in calcolo su domini.

La prima interrogazione chiede matricola, nome, età e stipendio degli impiegati che guadagnano più di 40 mila euro:

$$\{i.* \mid i(\text{Impiegati}) \mid i.\text{Stipendio} > 40\}$$

Per produrre solo alcuni degli attributi, matricola, nome ed età degli impiegati che guadagnano più di 40 mila euro, è sufficiente modificare la target list:

$$\{i.(\text{Matr}, \text{Nome}, \text{Età}) \mid i(\text{Impiegati}) \mid i.\text{Stipendio} > 40\}$$

Per interrogazioni che coinvolgono più relazioni sono necessarie più variabili, con specifica delle condizioni di correlazione sugli attributi. L'interrogazione che vuole trovare la matricole dei capi degli impiegati che guadagnano più di 40 mila euro, può essere formulata con:

$$\{s.\text{Capo} \mid i(\text{Impiegati}), s(\text{Supervisione}) \mid i.\text{Matr} = s.\text{Impiegato} \wedge i.\text{Stipendio} > 40\}$$

Nel caso delle espressioni corrispondenti al join di una relazione con se stessa, abbiamo più variabili aventi la stessa relazione come range. L'interrogazione: trovare nome e stipendio dei capi degli impiegati che guadagnano più di 40 mila euro può essere realizzata con l'espressione:

$$\begin{aligned} & \{\mathbf{NomeC}, \mathbf{StipC} : i'.(\mathbf{Nome}, \mathbf{Stip}) \mid \\ & i'(\mathbf{Impiegati}), s(\mathbf{Supervisione}), i(\mathbf{Impiegati}) \mid \\ & i'.\mathbf{Matr} = s.\mathbf{Capo} \wedge s.\mathbf{Impiegato} = i.\mathbf{Matr} \wedge i.\mathbf{Stipendio} > 40\} \end{aligned}$$

Le interrogazioni con i quantificatori mostrano appieno la sinteticità e praticità del calcolo su tuple con dichiarazioni di range. L'interrogazione che richiede di trovare matricola e nome dei capi i cui impiegati guadagnano tutti più di 40 mila euro si può esprimere in diversi modi in base all'uso dei quantificatori e della negazione. Con quantificatori universali:

$$\begin{aligned} & \{i.(\mathbf{Matr}, \mathbf{Nome}) \mid i(\mathbf{Impiegati}), s(\mathbf{Supervisione}) \mid \\ & i.\mathbf{Matr} = s.\mathbf{Capo} \wedge \forall i'(\mathbf{Impiegati})(\forall s'(\mathbf{Supervisione}) \\ & (\neg(s.\mathbf{Capo} = s'.\mathbf{Capo} \wedge s'.\mathbf{Impiegato} = i'.\mathbf{Matr}) \vee i'.\mathbf{Stipendio} > 40))\} \end{aligned}$$

Con quantificatori esistenziali negati:

$$\begin{aligned} & \{i.(\mathbf{Matr}, \mathbf{Nome}) \mid i(\mathbf{Impiegati}), s(\mathbf{Supervisione}) \mid \\ & i.\mathbf{Matr} = s.\mathbf{Capo} \wedge \neg(\exists i'(\mathbf{Impiegati})(\exists s'(\mathbf{Supervisione}) \\ & (s.\mathbf{Capo} = s'.\mathbf{Capo} \wedge s'.\mathbf{Impiegato} = i'.\mathbf{Matr} \wedge i'.\mathbf{Stipendio} \leq 40)))\} \end{aligned}$$

Il calcolo su tuple con dichiarazioni di range non permette di esprimere tutte le interrogazioni che possono essere formulate in algebra relazionale. In particolare, le interrogazioni i cui risultati possono provenire indifferentemente da due o più relazioni, che in algebra realizziamo con l'operatore di unione, non possono essere espresse con questa versione del calcolo: infatti, i risultati sono costruiti a partire dalle variabili libere, i cui range sono definiti nella target list, e ogni variabile ha come range una sola relazione.

Consideriamo l'unione di due relazioni sugli stessi attributi: date $R_1(AB)$ e $R_2(AB)$, vogliamo formulare l'interrogazione che in algebra esprimeremmo con l'unione di R_1 e R_2 . Se l'espressione avesse due variabili libere, allora ogni tupla del risultato dovrebbe corrispondere a una tupla di ciascuna delle relazioni, il che non è necessario perchè l'unione richiede alle tuple di comparire in almeno uno degli

operandi.

Se potessimo associare a una variabile un range costituito da più relazioni, risolveremmo il problema dell'unione ma non riusciremmo a formulare unioni complesse i cui operandi siano sottoespressioni non direttamente corrispondenti a schemi di relazione. Ad esempio, date due relazioni $R_1(ABC)$ e $R_2(BCD)$, l'unione delle loro proiezioni su BC :

$$\pi_{BC}(R_1) \cup \pi_{BC}(R_2)$$

non potrebbe essere espressa, perchè le due relazioni hanno schemi diversi e una variabile non può essere associata ad entrambe.

Per quanto riguarda gli operatori di intersezione e differenza questi sono esprimibili.

- L'intersezione richiede che le tuple del risultato appartengano a entrambi gli operandi, quindi si può costruire il risultato a partire da una relazione, richiedendo l'esistenza di una tupla uguale nell'altra relazione. Ad esempio:

$$\pi_{BC}(R_1) \cap \pi_{BC}(R_2)$$

può essere espressa con:

$$\{x_1.BC \mid x_1(R_1) \mid \exists x_2(R_2)(x_1.B = x_2.B \wedge x_1.C = x_2.C)\}$$

- La differenza produce le tuple di un operando non contenute nell'altro. Ad esempio:

$$\pi_{BC}(R_1) - \pi_{BC}(R_2)$$

può essere espressa con:

$$\{x_1.BC \mid x_1(R_1) \mid \neg \exists x_2(R_2)(x_1.B = x_2.B \wedge x_1.C = x_2.C)\}$$

Capitolo 6

Il modello Entità-Relazione

Il modello Entità-Relazione, il modello E-R, è un modello *concettuale* di dati e fornisce una serie di strutture, dette *costrutti*, atte a descrivere la realtà di interesse in maniera facile da comprendere e che prescinde dall'organizzazione dei dati nei calcolatori.

Questi costrutti sono usati per definire *schemi* che descrivono l'organizzazione e la struttura delle *occorrenze* dei dati, ovvero i valori assunti dai dati al variare del tempo.

6.1 I costrutti principali del modello

Analizziamo i costrutti principali di questo modello:

- le entità;
- le relazioni;
- gli attributi.

6.1.1 Entità

Le entità rappresentano classi di oggetti che hanno proprietà comuni ed esistenza “autonoma” ai fini dell'applicazione di interesse: Città, Dipartimento, Impiegato sono esempi di entità di un'applicazione aziendale. Una occorrenza di un'entità è un oggetto della classe che l'entità rappresenta, come Roma per l'entità Città. Un'occorrenza di entità non è un valore che identifica un oggetto


ma è l'oggetto stesso. Una conseguenza di questo è che un'occorrenza di entità ha un'identità indipendente dalle proprietà ad esso associate.

In questo il modello E-R presenta una grande differenza rispetto al modello relazionale nel quale non possiamo rappresentare un oggetto senza conoscere alcune sue proprietà.

In uno schema, ogni entità ha un nome che la identifica univocamente e viene rappresentata graficamente mediante un rettangolo con il nome dell'entità all'interno.

6.1.2 Relazioni o associazioni

Le relazioni o associazioni rappresentano legami logici, significativi per l'applicazione di interesse, tra due o più entità. Residenza è un esempio di relazione che può sussistere tra le entità Città e Impiegato. Un'occorrenza di relazione è un'ennupla costituita da occorrenze di entità, una per ciascuna delle entità coinvolte. Segue un esempio di occorrenze della relazione Esame:



In uno schema E-R, ogni relazione ha un nome che la identifica univocamente e viene rappresentata graficamente mediante un rombo con il nome della relazione all'interno, e da linee che connettono la relazione con ciascuna delle sue componenti.





Figura 6.1: Esempi di relazioni tra entità nel modello E-R

Dalla figura notiamo che possono esistere relazioni diverse che coinvolgono le stesse entità. Nella scelta dei nomi di relazione è preferibile utilizzare sostantivi invece che verbi in modo da non “assegnare” un verso alla relazione.

L’insieme di occorrenza di una relazione del modello E-R è, a tutti gli effetti, una relazione matematica tra le occorrenze delle entità coinvolte, quindi, un sottoinsieme del loro prodotto cartesiano. Di conseguenza, non ci possono essere ennuple ripetute.

Inoltre, è anche possibile avere relazioni *ricorsive*, ovvero relazioni tra un’entità e se stessa, come mostrato nella seguente figura:



Per esempio la relazione *Collega* sull’entità *Impiegato* connette coppie di impiegati che lavorano insieme, mentre la relazione *Successione* sull’entità *Sovrano* associa a ogni sovrano di una dinastia il suo successore. In quest’ultimo esempio, però, è necessario stabilire i due *ruoli* che l’entità coinvolta gioca nella relazione.

Infine, è possibile avere relazioni n-arie, ovvero relazioni che coinvolgono più di due entità, come mostrato nella seguente figura:





Figura 6.2: Esempio di relazione che coinvolge tre entità


6.1.3 Attributi

Gli attributi descrivono le proprietà elementari di entità o relazioni che sono di interesse ai fini dell'applicazione, ad esempio **Cognome**, **Stipendio** ed **Età** sono possibili attributi dell'entità **Impiegato**. Un attributo associa a ciascuna occorrenza di entità un valore appartenente a un insieme, detto *dominio*, che contiene i valori ammissibili per l'attributo. La seguente figura mostra come vengono rappresentati graficamente gli attributi:



Di solito, i domini non vengono riportati nello schema, ma sono descritti nella documentazione associata.


A volte, può risultare comodo raggruppare attributi di una stessa entità che presentano affinità nel loro significato: l'insieme di attributi che si ottiene si chiama *attributo composto*. Un esempio di attributo composto viene mostrato nella seguente figura:



Tuttavia, per ridurre la complessità degli schemi, gli attributi composti vengono usati raramente utilizzando, preferibilmente, degli attributi atomici.

6.1.4 Costruzione di schemi con i costrutti di base

I tre costrutti descritti ci consentono già di costruire schemi per descrivere realtà di una certa complessità. Consideriamo, ad esempio, il seguente schema E-R:



Si comprende facilmente che questo schema rappresenta informazioni organizzative relative a un'azienda con diverse sedi. Partendo dall'entità Sede si può vedere che una sede dell'azienda è dislocata in una certa città con un certo indirizzo. Ogni sede è organizzata in dipartimenti con un nome e un telefono. A questi dipartimenti afferiscono, a partire da una certa data, gli impiegati dell'azienda e ci sono impiegati che dirigono i dipartimenti. Gli impiegati sono rappresentati tramite codice, cognome, stipendio ed età. Gli impiegati lavorano su progetti a partire da una certa data e ogni progetto ha un nome, un budget e una data di consegna.

6.2 Altri costrutti del modello

Esaminiamo altri costrutti del modello E-R:

- le cardinalità delle relazioni e degli attributi;
- gli identificatori delle entità;
- le generalizzazioni.

Le generalizzazioni è un costrutto *nuovo*, gli altri, invece, costituiscono dei *vincoli di integrità* sui costrutti visti.

6.2.1 Cardinalità delle relazioni

Le cardinalità delle relazioni vengono specificate per ciascuna partecipazione di entità a una relazione e descrivono il numero minimo e massimo di occorrenze di relazione a cui una occorrenza dell'entità può partecipare. Quindi, dicono quante volte, in una relazione tra entità, un'occorrenza di queste entità può essere legata a occorrenze delle altre entità coinvolte.

Consideriamo il seguente esempio:



Figura 6.3: Cardinalità di una relazione del modello E-R

In questo esempio, stiamo dicendo che un impiegato deve essere assegnato almeno un incarico ma non più di 5. Per quanto riguarda l'incarico, invece, l'incarico può non essere assegnato a nessun impiegato oppure può essere assegnato a un numero di impiegati ≤ 50 .

È possibile assegnare un qualunque intero non negativo a una cardinalità di una relazione, con l'unico vincolo che la cardinalità minima deve essere minore o uguale della cardinalità massima. Nella maggior parte dei casi si utilizzano solo tre valori: 0, 1 e il simbolo N.

- per la cardinalità minima, 0 o 1; se 0 si dice che la partecipazione alla relazione è *opzionale*, se 1 si dice che la partecipazione è *obbligatoria*;

- per la cardinalità massima, 1 o N; se 1 si dice che la partecipazione alla relazione può essere vista come una funzione che associa a un'occorrenza dell'entità una sola occorrenza dell'altra entità che partecipa alla relazione. Se N c'è un'associazione con un numero arbitrario di occorrenza dell'altra entità.

Osservando le cardinalità massime è possibile classificare le relazioni binarie in base al tipo di corrispondenza che viene stabilita tra le occorrenze delle entità coinvolte. Le relazioni aventi cardinalità massima pari a 1 per entrambe le entità coinvolte, definiscono una corrispondenza uno a uno tra le occorrenze di tali entità e quindi vengono chiamate *relazioni uno a uno*. Analogamente, le relazioni aventi un'entità con cardinalità massima pari a 1 e l'altra con cardinalità massima pari a N sono denominate *relazioni uno a molti*. Infine, le relazioni aventi cardinalità massima pari a N per entrambe le entità coinvolte sono denominate *relazioni molti a molti*.

Per quanto riguarda le cardinalità minime, va detto il caso di partecipazione obbligatoria è abbastanza raro, perché quando si aggiunge una nuova occorrenza di entità molto spesso non sono note le corrispondenti occorrenze delle entità a esse collegate.

Nelle relazioni n-arie le entità coinvolte partecipano quasi sempre con cardinalità massima pari a N. Nel caso in cui un'entità partecipa a una relazione n-aria con cardinalità massima pari a 1, significa che ogni sua occorrenza può essere legata a una sola occorrenza della relazione, e quindi ad un'unica coppia di occorrenze delle altre entità coinvolte nella relazione. Questo significa che è possibile eliminare la relazione n-aria e legare direttamente tale entità con le altre entità mediante delle relazioni binarie di tipo uno a molti.




Figura 6.4: Esempio di relazioni con cardinalità

6.2.2 Cardinalità degli attributi

Le cardinalità sugli attributi possono essere specificate per gli attributi di entità o relazioni e descrivono il numero minimo e massimo di valori dell'attributo associati a ogni occorrenza di entità o relazione. Nella maggiore parte dei casi la cardinalità è (1, 1) e viene omessa. Il valore per un certo attributo può essere però nullo, oppure possono esistere diversi valori di un certo attributo per un'occorrenza di entità. Queste situazioni si possono rappresentare associando all'attributo una cardinalità minima pari a 0 nel primo caso, e una cardinalità massima pari a molti N, nel secondo.

Come per le relazioni, un attributo con cardinalità minima pari a 0 è *opzionale* per la relativa entità o relazione, mentre è *obbligatorio* se la sua cardinalità minima è pari a 1. Un attributo si dice *multivalore* se la sua cardinalità massima è pari a N.





Figura 6.5: Esempio di attributi con cardinalità

6.2.3 Identificatori delle entità

Gli identificatori delle entità vengono specificati per ciascuna entità di uno schema e descrivono i concetti dello schema che permettono di identificare in maniera univoca ciascuna occorrenza delle entità. In molti casi, uno o più attributi di un'entità sono sufficienti ad individuare un identificatore e prende il nome di identificatore *interno*.


Alcune volte, però, gli attributi di un'entità non sono sufficienti a identificare univocamente le sue occorrenze. In questo caso, per identificare univocamente un'occorrenza di un'entità si fa riferimento a uno o più attributi di un'altra entità. Un'entità *E* può essere identificata da altre entità solo se tali entità sono coinvolte in una relazione a cui *E* partecipa con cardinalità (1, 1). Nei casi in cui l'identificazione di un'entità è ottenuta utilizzando altre entità si parla di identificatore *esterno*. Seguono degli esempi di rappresentazione di identificatore interno ed esterno:



Facciamo alcune considerazioni:

- un identificatore può coinvolgere uno o più attributi, ognuno dei quali deve avere cardinalità (1, 1).
- un'identificazione esterna può coinvolgere una o più entità, ognuna delle quali deve essere membro di una relazione alla quale l'entità da identificare partecipa con cardinalità (1, 1).
- un'identificazione esterna può coinvolgere un'entità che è a sua volta identificata esternamente, purchè non vengano generati cicli di identificazioni esterne.
- ogni entità deve avere almeno un identificatore, ma ne può avere in generale più di uno; nel caso di più identificatori, le restrizioni sopra descritte sono più concessive in quanto gli attributi e le entità coinvolte in alcune identificazioni, tranne una, possono essere opzionali.

Segue un esempio di schema con rappresentazione di identificatori interni ed esterni:



6.2.4 Generalizzazioni

Le generalizzazioni riguardano legami logici tra un'entità E , detta entità genitore, e una o più entità $E_1, \dots, E_n$ dette entità figlie, di cui E è generale, nel senso che le comprende come caso particolare. Si dice in questo caso che E è generalizzazione di $E_1, \dots, E_n$ e che le entità $E_1, \dots, E_n$ sono *specializzazioni* dell'entità E . Per esempio, l'entità Persona è una generalizzazione delle entità Uomo e Donna. Di conseguenza, esse sono delle specializzazioni dell'entità Persona.

Tra le entità coinvolte in una generalizzazione valgono le seguenti proprietà.

- Ogni occorrenza di un'entità figlia è anche occorrenza dell'entità genitore.
- Ogni proprietà dell'entità genitore, come attributi, identificatori, relazioni e altre generalizzazioni, è anche proprietà delle entità figlie. Questa proprietà è nota sotto il nome di *ereditarietà*.

Le generalizzazioni vengono rappresentate graficamente mediante delle frecce che congiungono le entità figlie con l'entità genitore. Per le entità figlie, le proprietà ereditate non vanno rappresentate esplicitamente.


Le generalizzazioni possono essere classificate sulla base di due proprietà tra loro ortogonali.

- Una generalizzazione è *totale* se ogni occorrenza dell'entità genitore è un'occorrenza di almeno una delle entità figlie, altrimenti è *parziale*;

- Una generalizzazione è *esclusiva* se ogni occorrenza dell'entità genitore è al più un'occorrenza di una delle delle entità figlie, altrimenti è *sovrapposta*.

Ad esempio, la generalizzazione tra Persona, Uomo e Donna è totale perchè gli uomini e le donne costituiscono tutte le persone, ed è anche esclusiva perchè una persona è uomo o donna. Una generalizzazione tra l'entità Professionista e le entità Ingegnere e Dottore è invece parziale ed esclusiva. Tra l'entità Persona e le entità Studente e Lavoratore esiste una generalizzazione parziale e sovrapposta, perchè esistono studenti che sono anche lavoratori.


Seguono degli esempi di generalizzazioni tra entità:



Le generalizzazioni sovrapposte possono essere facilmente trasformate in generalizzazioni esclusive aggiungendo una o più entità figlie per rappresentare i concetti che costituiscono le “intersezioni” delle entità che si sovrappongono. Nel caso degli studenti e dei lavoratori è sufficiente aggiungere l'entità StudenteLavoratore.

Una stessa entità può essere coinvolta in più generalizzazioni diverse. Possono anche esserci generalizzazioni su più livelli, in questo caso si parla di *gerarchia* di generalizzazioni. Infine, una generalizzazione può avere una sola entità figlia: si parla in questo caso di *sottoinsieme*.

Le proprietà di esclusività e sovrapposta e di generalizzazione totale e parziale vengono rappresentate nel seguente modo:



Capitolo 7

Progettazione concettuale

La progettazione concettuale di una base di dati consiste nella costruzione di uno schema Entità-Relazione in grado di descrivere al meglio le specifiche sui dati di un'applicazione. Anche nel caso di applicazioni non particolarmente complesse, lo schema che si ottiene può contenere molti concetti correlati in una maniera piuttosto complicata. La costruzione finale dello schema è un processo graduale: lo schema concettuale viene progressivamente raffinato e arricchito attraverso una serie di trasformazioni ed eventuali correzioni.

7.1 La raccolta e l'analisi dei requisiti

Il reperimento e l'analisi dei requisiti di un'applicazione sono attività difficilmente standardizzabili perchè dipendono molto dall'applicazione con cui si ha a che fare.

Per *raccolta dei requisiti* si intende la completa individuazione dei problemi che l'applicazione da realizzare deve risolvere e le caratteristiche che tale applicazione dovrà avere.

Per caratteristiche del sistema si intendono sia gli aspetti statistici, i dati, sia gli aspetti dinamici, le operazioni sui dati. I requisiti vengono inizialmente raccolti in specifiche espresse generalmente in linguaggio naturale e, per questo motivo, spesso ambigue e disorganizzate.

L'*analisi dei requisiti* consiste nel chiarimento e nell'organizzazione delle specifiche dei requisiti. Queste sono attività fortemente interconnesse: l'attività di analisi inizia con i primi requisiti ottenuti per poi procedere di pari passo con l'attività di raccolta.

I requisiti di un'applicazione provengono, nella maggior parte dei casi, da fonti diverse. Le principali fonti di informazione sono, in genere, le seguenti.

- Gli *utenti dell'applicazione*. In questo caso le informazioni si acquisiscono mediante opportune interviste, anche ripetute, oppure attraverso una documentazione scritta che gli utenti possono aver predisposto appositamente per questo scopo.
- Tutta la *documentazione esistente* che ha qualche attinenza con il problema allo studio come moduli, regolamenti interni, procedure aziendali e normative. È richiesta, in questo caso, un'attività di raccolta e selezione che viene assistita dagli utenti, ma è a carico del progettista.
- *Realizzazioni preesistenti*, ovvero applicazioni che si devono rimpiazzare o che devono interagire in qualche maniera con il software da realizzare. La conoscenza delle caratteristiche di questi pacchetti software può fornirci importanti informazioni anche in relazione ai problemi esistenti che è necessario risolvere.

Nella fase di acquisizione delle specifiche, gioca un importante ruolo l'interazione con gli utenti del sistema informativo. Durante questa interazione può avvenire che utenti diversi forniscano informazioni diverse, spesso complementari ma contraddittorie. Quindi, nel corso delle interviste, è opportuno effettuare con l'utente verifiche di comprensione e consistenza sulle informazioni che si stanno raccogliendo, attraverso esempi oppure richiedendo definizioni e classificazioni precise.

Inoltre, in questa fase, è importante individuare gli aspetti essenziali rispetto a quelli marginali e procedere per raffinamenti successivi.

La specifica dei requisiti avviene spesso, facendo uso di descrizioni in linguaggio naturale e, data la sua ambiguità, è bene effettuare una profonda analisi del testo che descrive le specifiche per filtrare eventuali inesattezze e i termini ambigui presenti. Ad esempio, supponiamo di dover progettare una base di dati per una società di formazione e di aver raccolto, sulla base di alcune interviste fatte al personale di questa società, le specifiche dei dati espresse in linguaggio naturale.

Esempio : Società di formazione

Società di formazione	
1	<i>Si vuole realizzare una base di dati per una società che eroga corsi, di</i>
2	<i>cui vogliamo rappresentare i dati dei partecipanti ai corsi e dei docenti.</i>
3	<i>Per i partecipanti (circa 5000), identificati da un codice, si vuole me-</i>
4	<i>morizzare il codice fiscale, il cognome, l'età, il sesso, il luogo di nascita,</i>
5	<i>il nome dei loro attuali datori di lavoro, i posti dove hanno lavorato</i>
6	<i>in precedenza insieme al periodo, l'indirizzo e il numero di telefono, i</i>
7	<i>corsi che hanno frequentato (i corsi sono in tutto circa 200) e il giudizio</i>
8	<i>finale. Rappresentiamo anche i seminari che stanno attualmente fre-</i>
9	<i>quentando e, per ogni giorno, i luoghi e le ore dove sono tenute le lezioni.</i>
10	<i>I corsi hanno un codice, un titolo e possono avere varie edizioni con</i>
11	<i>date di inizio e fine e numero di partecipanti. Se gli studenti sono liberi</i>
12	<i>professionisti, vogliamo conoscere l'area di interesse e, se lo possiedono,</i>
13	<i>il titolo. Per quelli che lavorano alle dipendenze di altri, vogliamo co-</i>
14	<i>noscere invece il loro livello e la posizione ricoperta. Per gli insegnanti</i>
15	<i>(circa 300), rappresentiamo il cognome, l'età, il posto dove sono nati, il</i>
16	<i>nome del corso che insegnano, quelli che hanno insegnato nel passato e</i>
17	<i>quelli che possono insegnare. Rappresentiamo anche tutti i loro recapiti</i>
18	<i>telefonici. I docenti possono essere dipendenti interni della società o</i>
19	<i>collaboratori esterni.</i>

È facile rendersi conto che tale testo presenta un certo problema di ambiguità e imprecisioni. Ad esempio, si utilizzano i termini *partecipante* e *studente* per indicare lo stesso concetto. La stessa cosa accade per i termini *docente* e *professore* e per i termini *corso* e *seminario*.

Proviamo a fissare alcune regole generali per ottenere una specifica dei requisiti più precisa e senza ambiguità.

- **Scegliere il corretto livello di astrazione.** È bene evitare di utilizzare termini troppo generici o troppo specifici che rendono poco chiaro un concetto. Nell'esempio della **società di formazione** sono stati utilizzati i termini *titolo*, alla riga 13, con riferimento ai partecipanti che sono liberi professionisti (che viene usato per indicare un concetto diverso alla riga 10) e *giudizio*, alla riga 7, con riferimento alla valutazione dei corsi, che andrebbero specificati meglio come *titolo professionale* o *votazione in decimi*.
- **Standardizzare la struttura delle frasi.** Nella specifica di requisiti è preferibile utilizzare sempre lo stesso stile sintattico. Per esempio, per “per

<dato> rappresentiamo <insieme di proprietà>”.

- **Evitare frasi contorte.** Le definizioni devono essere semplici e chiare. Per esempio, *lavoratori dipendenti*, o più semplicemente dipendenti, è da preferire a *quelli che lavorano alle dipendenze di altri* alla riga 13.
- **Individuare sinonimi/omonimi e unificare i termini.** I *sinonimi* indicano termini diversi con lo stesso significato, per esempio *docente* alla riga 2 e *insegnante* alla riga 14, oppure *partecipante* alla riga 2 e *studente* alla riga 11; gli *omonimi* indicano termini uguali ma con diversi significati, ad esempio *posto*, riferito a “impiego” alla riga 5, *città* alla riga 15 e *luogo* riferito a “città” e ad “aula” alla riga 4.
Queste situazioni possono generare ambiguità e vanno chiarite: nel caso di sinonimi unificando i termini, nel caso di omonimi utilizzando termini diversi o specificandoli meglio.
- **Rendere esplicito il riferimento tra termini.** Può succedere che l’assenza di un contesto di riferimento renda alcuni concetti ambigui: in questi casi bisogna esplicitare il riferimento tra termini. Per esempio, nella riga 6, non è chiaro se i termini *indirizzo* e *numero di telefono* sono relativi ai partecipanti o ai loro datori di lavoro; nella riga 13, nella frase *per quelli che lavorano...* si deve chiarire esplicitamente a chi ci stiamo riferendo, se ai partecipanti o ai docenti, per evitare confusione.
- **Costruire un glossario dei termini.** È molto utile, per la comprensione e la precisazione dei termini usati, definire un glossario che, per ogni termine, contenga: una breve descrizione, possibile sinonimi e altri termini contenuti nel glossario con i quali esiste un legame logico. Un glossario per la *società di formazione* può essere il seguente.

Esempio : Glossario della **società di formazione**

Termine	Descrizione	Sinonimi	Collegamenti
Partecipante	Partecipante ai corsi. Può essere un dipendente o un professionista	Studente	Corso, Datore
Docente	Docente dei corsi. Possono essere collaboratori esterni	Insegnante	Corso
Corso	Corsi offerti. Possono avere varie edizioni	Seminario	Docente, Partecipante
Datore	Datori di lavoro attuali e passati dei partecipanti ai corsi	Posto	Partecipante

Dopo aver individuato le varie ambiguità e le imprecisioni, esse vanno eliminate sostituendo i termini non corretti con i termini più adeguati. In caso di dubbio, è necessario intervistare nuovamente colui che ha fornito il dato o consultare la documentazione relativa.

Nell'esempio della **società di formazione** si possono apportare diverse modifiche. Il *luogo* di nascita dei partecipanti, alla riga 4, è un omonimo del luogo in cui si tengono le lezioni e va sostituito da *città* di nascita, così come *posto* alla riga 5 che va sostituito con *datore di lavoro*. Va poi chiarito che a riga 6 l'*indirizzo* e il *numero di telefono* fanno riferimento ai datori di lavoro dei partecipanti. Il *giudizio* alla riga 7 deve essere interpretato come *votazione in decimi*, mentre *periodo* alla riga 6 va interpretato come *dato di inizio e fine rapporto*. Bisogna inoltre specificare che i partecipanti frequentano o hanno frequentato specifiche *edizioni* di corsi. Per quanto riguarda gli altri termini che fanno riferimento ai corsi: *seminario* alla riga 8 è un sinonimo e va sostituito con *edizione di corso*; *giorno* alla riga 9, riferito alle lezioni, è troppo astratto e va utilizzato *giorno della settimana*; *luogo* alla riga 9 è un omonimo, che va sostituito da *aula*. Il termine *studente* alla riga 11, va sostituito con *partecipante*. Per *titolo*, alla riga 13, di un partecipante che è libero professionista si intende il suo *titolo professionale*. Per quello che riguarda i docenti abbiamo che *insegnante*, alla riga 14, è sinonimo di *docente*, *posto* indica la *città* di nascita, il *nome* del corso che insegnano, alla riga 16, è un sinonimo di *titolo* del corso e il *recapito telefonico*, alle righe 17-18, è sinonimo di *numero di telefono*.

A questo punto possiamo riscrivere le nostre specifiche apportando le modifiche proposte. È utile, in questa fase, decomporre il testo in gruppi di frasi omogenee, relative cioè agli stessi concetti. Otteniamo così la strutturazione delle specifiche

sui dati.

Esempio : Strutturazione delle specifiche della società di formazione

Fraasi di carattere generale

Si vuole realizzare una base di dati per una società che eroga corsi, di cui vogliamo rappresentare i dati dei partecipanti ai corsi e dei docenti.

Fraasi relative ai partecipanti

Per i partecipanti (circa 5000), identificati da un codice, rappresentiamo il codice fiscale, il cognome, l'età, il sesso, la città di nascita, i nomi dei loro attuali datori di lavoro e di quelli precedenti (insieme alle date di inizio e fine rapporto), le edizioni dei corsi che stanno attualmente frequentando e quelli che hanno frequentato in passato, con la relativa votazione finale in decimi.

Fraasi relative ai datori di lavoro

Relativamente ai datori di lavoro presenti e passati dei partecipanti, rappresentiamo il nome, l'indirizzo e il numero di telefono.

Fraasi relative ai corsi

Per i corsi (circa 180), rappresentiamo il titolo e il codice, le varie edizioni con date di inizio e fine e, per ogni edizione, rappresentiamo il numero di partecipanti e il giorno della settimana, le aule e le ore dove si sono tenute le lezioni.

Fraasi relative a tipi specifici di partecipanti

Per i partecipanti che sono liberi professionisti, rappresentiamo l'area di interesse e, se lo possiedono, il titolo professionale. Per i partecipanti che sono dipendenti, rappresentiamo invece il loro livello e la posizione ricoperta.

Fraasi relative ai docenti

Per i docenti (circa 300), rappresentiamo il cognome, l'età, la città di nascita, tutti i numeri di telefono, il titolo del corso che insegnano, di quelli che hanno insegnato in passato e di quelli che possono insegnare. I docenti possono essere dipendenti interni della società di formazione o collaboratori esterni.

Inoltre, accanto alle specifiche sui dati vanno raccolte le specifiche sulle operazioni da effettuare su questi dati. Bisogna cercare di impiegare la stessa terminologia usata per i dati e informarci anche sulla frequenza con la quale le varie operazioni vengono eseguite. Nell'esempio della **società di formazione**, le operazioni sui dati potrebbero essere le seguenti:

Esempio : Operazioni sui dati nella **società di formazione**

- **Operazione 1:** inserisci un nuovo partecipante indicando tutti i suoi dati (operazione da effettuare in media 40 volte al giorno).
- **Operazione 2:** assegna un partecipante a un'edizione di corso (circa 50 volte al giorno);
- **Operazione 3:** inserisci un nuovo docente indicando tutti i suoi dati e i corsi che può insegnare (2 volte al giorno).
- **Operazione 4:** assegna un docente abilitato a un'edizione di corso (15 volte al giorno).
- **Operazione 5:** stampa tutte le informazioni sulle edizioni passate di un corso con titolo, orari lezioni e numero partecipanti (10 volte al giorno).
- **Operazione 6:** stampa tutti i corsi offerti, con informazioni sui docenti che possono insegnarli (20 volte al giorno).
- **Operazione 7:** per ogni docente, trova i partecipanti a tutti i corsi da lui/lei insegnati (5 volte a settimana).
- **Operazione 8:** effettua una statistica su tutti i partecipanti a un corso con tutte le informazioni su di essi, sull'edizione alla quale hanno partecipato e sulla rispettiva votazione (10 volte al mese).

Dopo questa strutturazione dei requisiti si avvia la prima fase della progettazione che consiste nella costruzione di uno schema concettuale in grado di descrivere in maniera adeguata tutte le specifiche dei dati raccolte.