

Calcolo numerico

Alessandro Carella

Indice

1	Metodi numerici per zeri di funzione	3
1.1	Teoremi di localizzazione	3
1.1.1	Teorema degli zeri o di Bolzano	4
1.2	Metodi one-step	9
1.2.1	Notazioni e richiami	11
1.2.2	Convergenza	12
1.3	Metodo della direzione costante	19
1.4	Metodo di Newton (o delle tangenti)	22
1.4.1	Approccio analitico	22
1.4.2	Approccio geometrico	23
1.5	Ordine di convergenza	29
1.5.1	Metodo della direzione costante	33
1.5.2	Metodo di Newton	33
1.6	Metodo di Newton modificato	34
1.7	Metodo delle secanti	35
2	Richiami sui numeri complessi	39
3	Aritmetica di macchina e analisi degli errori	40
3.1	Considerazioni preliminari	40
3.2	Numeri di macchina	42
3.3	Standard IEEE-754	45
3.3.1	Semplice precisione	45
3.3.2	Doppia precisione	47
3.4	Rappresentazione dei numeri reali mediante i numeri di macchina	48
3.5	Errori di rappresentazione	50
3.5.1	Errore assoluto	50
3.5.2	Errore relativo	50

3.6	Operazioni di macchina	52
3.6.1	Proprietà dell'aritmetica di macchina	53
3.7	Analisi degli errori	56
3.8	Richiami su vettori e analisi	57
3.8.1	Prodotto scalare tra due vettori	57
3.8.2	Derivate parziali	58
3.8.3	Sviluppo di Taylor arrestato al primo ordine per funzioni scalari	59
3.8.4	Condizionamento di un problema	62
3.8.5	Stabilità di un algoritmo	62
3.9	Condizionamento delle operazioni elementari	63
3.9.1	Addizione	63
3.9.2	Sottrazione	64
3.9.3	Moltiplicazione	65
3.9.4	Divisione	65
3.10	Stabilità di un algoritmo	65
4	Matrici e sistemi lineari	68
4.1	Operazioni tra matrici	70
4.1.1	Addizione	70
4.1.2	Moltiplicazione di uno scalare per una matrice	70
4.1.3	Trasposta di una matrice	71
4.1.4	Sottomatrici o matrici estratte	71
4.1.5	Partizionamento di matrici	72
4.1.6	Prodotto di matrici	73
4.1.7	Inversa di una matrice quadrata	74
4.1.8	Determinante di una matrice quadrata	75
4.2	Sistema lineari di n equazioni in n incognite	78
4.2.1	Soluzione di un sistema lineare	78
4.3	Sistemi triangolari	79
4.3.1	Sistemi triangolari superiori	79
4.3.2	Algoritmo di sostituzione in avanti	81
4.3.3	Proprietà delle matrici triangolari	82
4.4	Fattorizzazione LU di una matrice	82

Capitolo 1

Metodi numerici per zeri di funzione

Traccia : Trovare gli zeri di una funzione

Data una funzione $f : [a, b] \rightarrow \mathbb{R}$, determinare gli zeri appartenenti all'intervallo $[a, b]$.

Ricordiamo che $\alpha \in [a, b]$ si dice zero di f se $f(\alpha) = 0$. Quindi, il problema della determinazione degli zeri di una funzione $f(x)$ è equivalente al problema della risoluzione dell'equazione:

$$f(x) = 0$$

Esempio

Siano:

$$f(x) = x - \cos x \quad g(x) = x - e^{-x}$$

α è zero di $f \iff f(\alpha) = 0 \iff \alpha$ è soluzione dell'equazione $f(x) = 0$

1.1 Teoremi di localizzazione

Richiamiamo dall'analisi i seguenti risultati.

1.1.1 Teorema degli zeri o di Bolzano

Teorema 1.1: Teorema degli zeri

Sia $f : [a, b] \rightarrow \mathbb{R}$, continua in $[a, b]$ e tale che $f(a)f(b) < 0$, ovvero cambia segno agli estremi dell'intervallo.

Allora:

$$\exists \alpha \in (a, b) \mid f(\alpha) = 0$$

cioè f ammette almeno uno zero $\alpha \in (a, b)$.

Il teorema di Bolzano esprime una condizione sufficiente per l'esistenza di uno zero di f , tuttavia non ne assicura l'unicità. Per ottenere l'unicità potremmo assumere ulteriormente che f sia strettamente monotona.

Teorema 1.2: Esistenza e unicità dello zero

Sia $f : [a, b] \rightarrow \mathbb{R}$, derivabile in $[a, b]$ e tale che:

$$f(a)f(b) < 0 \quad \text{e} \quad f'(x) \neq 0$$

Allora f ammette un unico zero α in (a, b) :

$$\exists! \alpha \in (a, b) \mid f(\alpha) = 0$$

In quanto se $f'(x)$ è sempre maggiore di zero allora f è monotona crescente, altrimenti se $f'(x)$ è sempre minore di zero allora f è monotona decrescente.

Metodo delle successive bisezioni

La dimostrazione del teorema degli zeri è di tipo costruttivo, cioè induce un algoritmo che può essere implementato sul calcolatore per approssimare α , che è lo zero di f .

Il metodo delle successive bisezioni definisce tre successioni numeriche:

$$\{a_n\} \quad \{b_n\} \quad \{c_n\}$$

così definite:

- inizialmente si pone:

$$a_0 = a \quad b_0 = b \quad c_0 = \frac{a_0 + b_0}{2}$$

Al primo passo, costruiamo $[a_1, b_1]$ a partire da $[a_0, b_0]$.

Se $f(c_0) = 0 \Rightarrow$ si esce dall'algoritmo e si pone $\alpha = c_0$.

Altrimenti si pone:

$$[a_1, b_1] = \begin{cases} [a_0, c_0] & f(a_0)f(c_0) < 0 \\ [c_0, b_0] & f(c_0)f(b_0) < 0 \end{cases}$$

Procedendo per induzione, supponiamo di aver definito l'intervallo $[a_{n-1}, b_{n-1}]$ e vediamo come costruire $[a_n, b_n]$.

Si pone:

$$c_{n-1} = \frac{a_{n-1} + b_{n-1}}{2}$$

Se $f(c_{n-1}) = 0 \Rightarrow$ ci si ferma e si pone $\alpha = c_{n-1}$.

Altrimenti:

$$[a_n, b_n] = \begin{cases} [a_{n-1}, c_{n-1}] & f(a_{n-1})f(c_{n-1}) < 0 \\ [c_{n-1}, b_{n-1}] & f(c_{n-1})f(b_{n-1}) < 0 \end{cases}$$

Nell'ipotesi che $f(c_n) \neq 0 \forall n$, si dimostra che:

$$\lim_{n \rightarrow \infty} a_n = \lim_{n \rightarrow \infty} b_n = \lim_{n \rightarrow \infty} c_n = \alpha.$$

Dimostriamo questo risultato.

Dimostrazione. Le successioni $\{a_n\}$ e $\{b_n\}$ verificano le seguenti proprietà:

1. $[a_n, b_n] \subset [a_{n-1}, b_{n-1}]$
2. $b_n - a_n = \frac{1}{2}(b_{n-1} - a_{n-1})$
3. $f(a_n)f(b_n) < 0 \quad \forall n$

Dalla proprietà 1. si ricava che:

- $a_n \geq a_{n-1} \quad a_n < b$
- $b_n \leq b_{n-1} \quad b_n > a$

Quindi $\{a_n\}$ è monotona crescente e limitata superiormente (b è un suo maggiorante).

Dall'analisi sappiamo allora che $\{a_n\}$ ammette limite finito:

$$\exists \lim_{n \rightarrow \infty} a_n = \bar{a} \in \mathbb{R}$$

Analogamente, $\{b_n\}$ è monotona decrescente e limitata inferiormente (a è un suo minorante). Ne consegue che ammetterà limite finito:

$$\exists \lim_{n \rightarrow \infty} b_n = \bar{b} \in \mathbb{R}$$

Proviamo ora che $\bar{a} = \bar{b}$. Infatti:

$$\begin{aligned} \bar{b} - \bar{a} &= \lim_{n \rightarrow \infty} b_n - \lim_{n \rightarrow \infty} a_n \\ &= \lim_{n \rightarrow \infty} (b_n - a_n) \\ &= \frac{1}{2} \lim_{n \rightarrow \infty} (b_{n-1} - a_{n-1}) \\ &= \dots = \lim_{n \rightarrow \infty} \frac{1}{2^n} (b - a) \\ &= 0 \end{aligned}$$

Proviamo ora che $\bar{a}(=\bar{b}) = \alpha$.

$$\begin{aligned} 0 \leq [f(\bar{a})]^2 &= \\ f(\bar{a})f(\bar{b}) &= f\left(\lim_{n \rightarrow \infty} a_n\right)f\left(\lim_{n \rightarrow \infty} b_n\right) \\ &= \lim_{n \rightarrow \infty} f(a_n) \lim_{n \rightarrow \infty} f(b_n) \\ &= \lim_{n \rightarrow \infty} f(a_n)f(b_n) \leq 0 \end{aligned}$$

Ne consegue che $f(\bar{a}) = 0 \Rightarrow \bar{a} = \alpha$.

Occorre infine provare che anche $\{c_n\}$ tende ad α . Essendo $\{c_n\}$ la successione dei punti medi, avremo:

$$a_n < c_n < b_n$$

Dal teorema dei due carabinieri deduciamo che:

$$\lim_{n \rightarrow \infty} c_n = \alpha$$

□

Criteri di arresto Non potendo costruire gli infiniti elementi delle successioni $\{a_n\}$, $\{b_n\}$ e $\{c_n\}$, termineremo l'iterazione quando avremo raggiunto un'accuratezza sufficiente.

Volendo scegliere c_n quale approssimante di α , andiamone a calcolare la distanza:

$$|c_n - \alpha| < b_n - a_n$$

La maggiorazione $b_n - a_n$ è calcolabile. Quindi, come criterio di arresto, possiamo usare:

$$b_n - a_n < \text{tol}$$

essendo tol la precisione richiesta dall'utente.

Seguono i codici Matlab e Python.

Richiamiamo le seguenti definizioni.

DEFINIZIONE 1.1: ERRORE ASSOLUTO

Siano $x \in \mathbb{R}$ una quantità teorica e $\bar{x}$ una sua approssimazione. Definiamo l'errore assoluto come:

$$E_a = |x - \bar{x}|$$

L'errore assoluto è quindi la distanza tra x e $\bar{x}$ sulla retta reale.

DEFINIZIONE 1.2: ERRORE RELATIVO

Siano $x \in \mathbb{R}$ una quantità teorica e $\bar{x}$ una sua approssimazione. Definiamo l'errore relativo come:

$$E_r = \frac{|x - \bar{x}|}{|x|} \quad \text{se } x \neq 0$$

L'errore relativo scala l'errore assoluto della grandezza della quantità da approssimare.

L'importanza dell'errore relativo è quella di fornirci un'informazione sul numero di cifre significative corrette contenute nell'approssimazione $\bar{x}$. Più precisamente, lavorando in base 10, se:

$$\frac{|x - \bar{x}|}{|x|} < \frac{1}{2} \cdot 10^{-d}$$

allora l'approssimazione $\bar{x}$ conterrà almeno d cifre significative corrette. Questo significa che gli arrotondamenti di x e $\bar{x}$ a d cifre significative coincidono.

DEFINIZIONE 1.3: ERRORE MISTO

Siano $x \in \mathbb{R}$ una quantità teorica e $\bar{x}$ una sua approssimazione. Definiamo l'errore misto come:

$$E_m = \frac{|x - \bar{x}|}{1 + |x|}$$

L'errore misto è utile sul calcolatore quando $|x| \approx 0$, per cui l'espressione dell'errore relativo causerebbe problemi. Può essere interpretato come una via intermedia tra l'errore assoluto e l'errore relativo. Infatti:

$$\frac{|x - \bar{x}|}{1 + |x|} = \begin{cases} |x - \bar{x}| & x \approx 0 \\ \frac{|x - \bar{x}|}{|x|} & x \gg 1 \end{cases}$$

Torniamo a discutere i criteri di arresto del metodo delle successive bisezioni. Abbiamo già esaminato quello sull'errore assoluto. Vediamo come ottenere un criterio di arresto basato sull'errore relativo. Facciamo riferimento ai seguenti grafici:



Poichè $\lim_{n \rightarrow \infty} a_n = \lim_{n \rightarrow \infty} b_n = \alpha$, per n grande, a_n e b_n avranno lo stesso segno di α . Pertanto, per $\alpha > 0$:

$$a_n < \alpha \Rightarrow \frac{1}{\alpha} < \frac{1}{a_n}$$

Per $\alpha < 0$:

$$\alpha < b_n \Rightarrow \frac{1}{-\alpha} < \frac{1}{-b_n} = \frac{1}{|\alpha|} < \frac{1}{|b_n|}$$

Volendo racchiudere in un unico caso:

$$\frac{1}{|\alpha|} < \frac{1}{\min\{|a_n|, |b_n|\}}$$

In definitiva, il criterio di arresto sull'errore relativo diventa:

$$\frac{b_n - a_n}{\min\{|a_n|, |b_n|\}} < \text{tol}$$

Infine, il criterio di arresto sull'errore misto è:

$$\frac{b_n - a_n}{1 + \min\{|a_n|, |b_n|\}} < \text{tol}$$

Nota

Lavorando con l'errore assoluto, è possibile stabilire a priori il numero di iterazioni necessarie per ottenere una certa accuratezza tol . Infatti, durante la dimostrazione della convergenza, avevamo stabilito che:

$$b_n - a_n = \frac{b - a}{2^n}$$

Dunque il criterio di arresto:

$$b_n - a_n < \text{tol}$$

diventa

$$\frac{b - a}{2^n}$$

che può essere risolto rispetto ad n :

$$2^n > \frac{b - a}{\text{tol}} \Rightarrow n > \log_2 \frac{b - a}{\text{tol}}$$

Quindi potremo scegliere $n = \left\lceil \log_2 \frac{b-a}{\text{tol}} \right\rceil$


1.2 Metodi one-step

DEFINIZIONE 1.4: PUNTO FISSO

Sia $\theta : [a, b] \rightarrow \mathbb{R}$. $\alpha \in [a, b]$ si dice *punto fisso* di θ se:

$$\theta(\alpha) = \alpha$$

L'interpretazione geometrica è la seguente:



Poichè la prima bisettrice è il luogo geometrico dei punti che hanno stesse ascisse e ordinate, i punti fissi di θ sono le ascisse dei punti di intersezione del grafico di θ con la prima bisettrice. In effetti:

$$x = \theta(x) \iff \begin{cases} y = x \\ y = \theta(x) \end{cases}$$

Trasformiamo il problema della ricerca degli zeri di una funzione $f(x)$ in un problema *equivalente* della ricerca dei punti fissi di un'opportuna funzione $\theta(x)$:

$$f(x) = 0 \iff x = \theta(x)$$

Dire che i due problemi sono equivalenti, significa dire che le due equazioni $f(x) = 0$ e $x = \theta(x)$ ammettono le stesse soluzioni.

Il vantaggio di operare con le θ è che l'equazione $x = \theta(x)$ suggerisce il seguente metodo risolutivo. Si genera la seguente successione:

$$\begin{cases} x_0 \text{ assegnato} \\ x_n = \theta(x_{n-1}) \end{cases}$$

ove x_0 è una stima iniziale di α .

Sotto opportune ipotesi, che studieremo in seguito, si ha:

$$\lim_{n \rightarrow \infty} x_n = \alpha$$

cioè, la successione $\{x_n\}$ converge a un punto fisso di θ .

Esempio

Consideriamo la funzione $f(x) = x - \cos x$ e abbiamo detto che:

$$f(x) = 0 \iff x - \cos x = 0 \iff x = \cos x$$

e quindi scegliamo $\theta(x) = \cos x$.

Partiamo da $x_0 = 0$ e calcoliamo la successione $\{x_n\}$:

$$\begin{aligned}x_0 &= 0 \\x_1 &= \cos(x_0) = \cos(0) = 1 \\x_2 &= \cos(x_1) = \cos(1) = 0.5403 \\x_3 &= \cos(x_2) = \cos(0.5403) = 0.8575 \\x_4 &= \dots \\&\vdots \\x_{20} &= \cos(x_{19}) \simeq 0.73893 \approx \alpha\end{aligned}$$

La successione $\{x_n\}$ è detta *metodo one-step* (la costruzione dell'elemento x_n dipende dall'elemento precedentemente calcolato x_{n-1}).

La funzione θ è detta *funzione iteratrice*.

Nota

Se θ è una funzione continua in $[a, b]$ ed esiste $\lim_{n \rightarrow \infty} x_n = \alpha$, necessariamente α dovrà essere punto fisso di θ . Infatti:

$$\begin{aligned}\alpha &= \lim_{n \rightarrow \infty} x_n \\&= \lim_{n \rightarrow \infty} \theta(x_{n-1}) \\&= \theta\left(\lim_{n \rightarrow \infty} x_{n-1}\right) \\&= \theta(\alpha)\end{aligned}$$

1.2.1 Notazioni e richiami

Denoteremo con:

$$C([a, b]) = \{f : [a, b] \rightarrow \mathbb{R} \mid f \text{ continua in } [a, b]\}$$

$$C^1([a, b]) = \{f : [a, b] \rightarrow \mathbb{R} \mid f \text{ continua in } [a, b] \text{ con } f'(x) \text{ continua in } [a, b]\}$$

Evidentemente:

$$C^1([a, b]) \subset C([a, b])$$

Più in generale:

$$C^k([a, b]) = \{f : [a, b] \rightarrow \mathbb{R} \mid f \text{ derivabile } k \text{ volte in } [a, b], \text{ con } f^{(k)}(x) \text{ continua in } [a, b]\}$$


e vale che:

$$C^k([a, b]) \subset C^{k-1}([a, b]) \subset \cdots \subset C^1([a, b]) \subset C([a, b])$$

DEFINIZIONE 1.5: INTORNO SFERICO

Siano $\alpha \in \mathbb{R}$ e $\delta > 0$. Si definisce *intorno sferico* di centro α e raggio δ e lo si denota con $B(\alpha, \delta)$:

$$B(\alpha, \delta) = (\alpha - \delta, \alpha + \delta)$$



ove B sta per *Ball*.

Vediamo di interpretare la scrittura $x \in B(\alpha, \delta)$:

$$\begin{aligned} x \in B(\alpha, \delta) &\iff x \in (\alpha - \delta, \alpha + \delta) \\ &\iff \alpha - \delta < x < \alpha + \delta \\ &\iff -\delta < x - \alpha < \delta \\ &\iff |x - \alpha| < \delta \end{aligned}$$

ove $|x - \alpha|$ è la distanza di x dal centro α e δ è il raggio.

In conclusione: $x \in B(\alpha, \delta) \iff$ la distanza di x dal centro α dell'intorno è minore del raggio δ .

1.2.2 Convergenza

DEFINIZIONE 1.6: CONVERGENZA LOCALE

Siano $\theta : [a, b] \rightarrow \mathbb{R}$ e $\alpha \in (a, b)$ punto fisso di θ . Il metodo one-step indotto

dalla funzione iteratrice θ si dice *localmente convergente* al punto fisso di α se:

$\exists B(\alpha, \delta)$, intorno sferico di centro α e raggio δ , tale che, $\forall x_0 \in B(\alpha, \delta)$:

- $x_n \in B(\alpha, \delta), n \geq 0$
- $\lim_{n \rightarrow \infty} x_n = \alpha$

Nota

Nel caso di convergenza locale si richiede che x_0 dia una stima sufficientemente buona di α .

DEFINIZIONE 1.7: CONVERGENZA GLOBALE

Siano $\theta : [a, b] \rightarrow \mathbb{R}$ e α punto fisso di θ .

Il metodo iterativo one-step definito dalla funzione iteratrice θ è detto *globalmente convergente* ad α in $[a, b]$ se, $\forall x_0 \in [a, b]$:

- $x_n \in [a, b], n \geq 0$
- $\lim_{n \rightarrow \infty} x_n = \alpha$.


Nota

La convergenza globale implica la convergenza locale.

Teorema 1.3: Condizione sufficiente per la convergenza locale

Siano $\theta \in C^1([a, b])$ e α punto fisso di θ in (a, b) . Allora, se $|\phi'(\alpha)| < 1$ il metodo one-step definito dalla funzione iteratrice θ risulta localmente convergente ad α .

Dimostrazione.



Sia $0 < L < 1 \mid |\theta'(\alpha)| < L < 1$

Essendo $\theta \in C'([a, b])$, $\theta'(x)$ è continua in $[a, b]$ così pure il suo valore assoluto $|\theta'(x)|$. Per il teorema della permanenza del segno vicino ad α , $|\theta'(x)|$ continua ad essere minore di L :


$$\exists B(\alpha, \delta) \mid |\theta'(x)| < L \quad \forall x \in B(\alpha, \delta)$$

Facciamo vedere che, all'interno di questo intorno, sono verificate le due proprietà della definizione di **convergenza locale**.

Dimostriamo la prima proprietà. Si procede per induzione sull'indice n . Per $n = 0$ l'asserto è vero in quanto, per definizione, sappiamo che $x_0 \in B(\alpha, \delta)$. Supponiamo l'asserto vero per $x_{n-1} \in B(\alpha, \delta)$ e proviamolo per n . Risulta:

$$\begin{aligned} |x_n - \alpha| &= |\theta(x_{n-1}) - \theta(\alpha)| \\ &\text{Per il teorema di Lagrange:} \\ &= |\theta'(\eta_{n-1})(x_{n-1} - \alpha)| \end{aligned}$$

dove η_{n-1} è un opportuno punto tra x_{n-1} e α :



Osserviamo che $\eta_{n-1} \in B(\alpha, \delta) \Rightarrow |\theta'(\eta_{n-1})| < L$. Dunque:

$$|x_n - \alpha| = |\theta'(\eta_{n-1})| \cdot |x_{n-1} - \alpha| < L|x_{n-1} - \alpha| < L\delta < \delta$$

Dimostriamo la seconda proprietà. Abbiamo visto che $|x_n - \alpha| < L|x_{n-1} - \alpha|$. Essendo n generico, possiamo iterare:

$$|x_n - \alpha| < L|x_{n-1} - \alpha| < L^2|x_{n-2} - \alpha| < \dots < L^n|x_0 - \alpha|$$

e per $n \rightarrow \infty$ $L^n \simeq 0$. Quindi, in conclusione:

$$0 \leq |x_n - \alpha| < L^n|x_0 - \alpha|$$

Per il teorema dei due carabinieri:

$$\lim_{n \rightarrow \infty} |x_n - \alpha| = 0 \Rightarrow \lim_{n \rightarrow \infty} x_n = \alpha$$

□

Nota

Se $|\theta'(\alpha)| > 1$ il metodo non può essere localmente convergente ad α . Infatti, vicino ad α , $|\theta'(x)| > L > 1$ e quindi se x_0 è sufficientemente vicino ad α :

$$|x_1 - \alpha| > L|x_0 - \alpha| > |x_0 - \alpha|$$

ci allontaniamo da α .

Se $|\theta'(\alpha) = 1|$, non si può dire nulla a priori circa la convergenza locale. Osserviamo ulteriormente che nell'ipotesi avremmo potuto scrivere $\theta \in C^1(B(\alpha, r))$ anzichè scrivere $\theta \in C^1([a, b])$.

Teorema 1.4: Condizione sufficiente per la convergenza globale

Sia $\theta \in C^1([a, b])$ tale che:

- $\theta([a, b]) \subset [a, b]$
- $|\theta'(x)| < 1, \forall x \in [a, b]$

Allora θ ammette un unico punto fisso $\alpha \in [a, b]$ e il metodo one-step definito dalla funzione iteratrice θ risulta essere globalmente convergente ad α nell'intervallo $[a, b]$.

Dimostrazione.

Proviamo innanzitutto l'esistenza e l'unicità del punto fisso α di θ . A tal fine consideriamo la seguente funzione ausiliaria $g(x)$:

$$g(x) = x - \theta(x)$$

Ovviamente $g \in C^1([a, b])$ e risulta:

$$g'(x) = 1 - \theta'(x) > 0 \quad \forall x \in [a, b]$$

cioè $g(x)$ è strettamente crescente in $[a, b]$. Inoltre:

$$g(a) = a - \theta(a) \leq 0$$

$$g(b) = b - \theta(b) \geq 0$$

Per un teorema di localizzazione, $g(x)$ ammette un unico zero $\alpha \in [a, b]$:

$$\exists! \alpha \in [a, b] \mid g(\alpha) = 0$$

$$\alpha - \theta(\alpha) = 0 \iff \alpha = \theta(\alpha)$$

Ora proviamo a dimostrare le proprietà 1. e 2. della definizione di **convergenza globale**.

Dimostriamo la prima proprietà. Dalla prima ipotesi sappiamo che:

$$\theta([a, b]) \subset [a, b]$$

ciò significa che:

$$\forall x \in [a, b] : \theta(x) \in [a, b]$$

e questo equivale alla prima proprietà.

Dimostriamo la seconda proprietà e sia:

$$M = \max_{a \leq x \leq b} |\theta'(x)| < 1$$

Il massimo M esiste per il teorema di Weirstrass, essendo $|\theta'(x)|$ continua in $[a, b]$.

$$\begin{aligned} 0 \leq |x_n - \alpha| &= |\theta(x_{n-1}) - \theta(\alpha)| \\ &= |\theta'(\eta_{n-1})| |x_{n-1} - \alpha| \\ &< M |x_{n-1} - \alpha| < M^2 |x_{n-2} - \alpha| < \dots \\ &< M^n |x_0 - \alpha| \end{aligned}$$

Per il teorema dei due carabinieri:


$$\lim_{n \rightarrow \infty} |x_n - \alpha| = 0$$

□

Esempio

Riprendiamo l'esempio: $x - \cos x = 0 \iff x = \cos x$ ove abbiamo definito $\theta(x) = \cos x$ e $x \in \left[0, \frac{\pi}{2}\right]$. Ne segue il grafico:

Grafico di $y = \cos(x)$



Quindi, notiamo che per $0 \leq x \leq \frac{\pi}{2} \Rightarrow 0 \leq \cos x \leq 1 < \frac{\pi}{2}$, quindi la prima proprietà del teorema della **condizione sufficiente per la convergenza globale** è soddisfatta. Inoltre:

$$|\theta'(x)| = |-\sin x| = \sin x$$

e notiamo che:

$$0 \leq \sin x \leq 1 \quad \forall x \in \left[0, \frac{\pi}{2}\right]$$

quindi anche la seconda proprietà del teorema della **condizione sufficiente per la convergenza globale** è verificata in $\left[0, \frac{\pi}{2}\right)$ dato che $\sin \frac{\pi}{2} = 1$.

Tuttavia, scegliendo $x_0 = \frac{\pi}{2}$ otteniamo $x_1 = \cos \frac{\pi}{2} = 0$ e quindi anche con questa scelta di x_0 otteniamo la convergenza ad α . Quindi il metodo risulta globalmente convergente in $\left[0, \frac{\pi}{2}\right]$.

Esercizio 1.2.1

Si consideri la funzione:

$$f(x) = x^3 - 2x - 5 \quad x \in [1, 3]$$

1. Provare che $f(x)$ ammette un unico zero $\alpha \in (1, 3)$.
2. Per l'approssimazione di α si considerino i seguenti due metodi iterativi one-step:

2.1. Il primo metodo è ottenuto andando a risolvere l'equazione:

$$x^3 - 2x - 5 = 0$$

isolando il secondo termine:

$$x = \frac{x^3 - 5}{2}$$

Ciò suggerisce la funzione iterativa:

$$\theta_1(x) = \frac{x^3 - 5}{2}$$

2.2. Il secondo metodo è ottenuto risolvendo rispetto al primo termine x^3 :

$$x = \sqrt[3]{2x + 5}$$

da cui la funzione iteratrice:

$$\theta_2(x) = \sqrt[3]{2x+5}$$

Studiare la convergenza locale e globale dei due metodi definiti da $\theta_1(x)$ e $\theta_2(x)$.

La risoluzione è la seguente.

$$\begin{aligned} 2.1. \quad & f(1) = 1^3 - 2 \cdot 1 - 5 = -6 < 0 \\ & f(3) = 3^3 - 2 \cdot 3 - 5 = 16 > 0 \\ & f'(x) = 3x^2 - 2 > 0 \quad \forall x \in [1, 3]. \end{aligned}$$

Per il teorema di **esistenza e unicità dello zero**, f ammette un unico zero $\alpha \in (1, 3)$.

2.2. Studiamo i due metodi separatamente.

$$2.2.1. \quad \theta_1(x) = \frac{x^3-5}{2} \text{ da cui:}$$

$$\theta'_1(x) = \frac{3}{2}x^2 \geq \frac{3}{2} > 1 \quad \forall x \in [1, 3]$$

per cui $\theta'_1(\alpha) > 1$.

Per cui il primo metodo non converge localmente e a maggior ragione non converge globalmente in $[1, 3]$.

$$2.2.2. \quad \theta_2(x) = \sqrt[3]{2x+5} \text{ da cui:}$$

$$\theta'_2(x) = \frac{1}{3}(2x+5)^{-\frac{2}{3}} \cdot 2 = \frac{2}{3} \frac{1}{\sqrt[3]{(2x+5)^2}}$$

Notiamo che $\theta'_2(x)$ decresce nell'intervallo di lavoro $[1, 3]$, pertanto:

$$0 < \theta'_2(x) \leq \max_{1 \leq x \leq 3} \theta'_2(x) = \theta'_2(1) = \frac{2}{3}(7)^{-\frac{2}{3}} \approx 0.18$$

Per cui:

$$0 < \theta'_2(x) < 1$$

Possiamo subito concludere che $|\theta'_2(\alpha)| < 1$ e quindi questo metodo converge localmente.

Per la convergenza globale, resta da provare la prima proprietà

del teorema della **condizione sufficiente per la convergenza globale**:

$$\theta_2([1, 3]) \subset [1, 3]$$

il che significa:

$$1 \leq x \leq 3 \Rightarrow 1 \leq \theta_2(x) \leq 3$$

Dovremo risolvere il sistema:

$$\begin{cases} \sqrt[3]{2x+5} \geq 1 \\ \sqrt[3]{2x+5} \leq 3 \end{cases}$$

Detto S l'insieme delle soluzioni dobbiamo verificare se $[1, 3] \subset S$.

Avevamo visto che $\theta'_2(x) > 0$ quindi è strettamente crescente in $[1, 3]$. Allora:

$$1 \leq x \leq 3 \Rightarrow 1 < \theta_2(1) \leq \theta_2(x) \leq \theta_2(3) < 3$$

Quindi abbiamo provato che $1 < \theta_2(x) < 3$ e quindi questo metodo risulta globalmente convergente in $[1, 3]$.

Nota

Abbiamo calcolato direttamente il valore di $\theta_2(1)$ e $\theta_2(3)$ senza risolvere il sistema in quanto $\theta_2(x)$ è monotona nell'intervallo $[1, 3]$. In particolare, se $\theta(x)$ è crescente in $[a, b]$:


$$a \leq x \leq b \Rightarrow \theta(a) \leq \theta(x) \leq \theta(b)$$

Se $\theta(x)$ è decrescente in $[a, b]$:

$$a \leq x \leq b \Rightarrow \theta(b) \leq \theta(x) \leq \theta(a)$$

1.3 Metodo della direzione costante

Introduciamo questo metodo mediante la sua interpretazione geometrica:



A partire da una stima iniziale x_0 di α , si considera la retta passante per il punto $(x_0, f(x_0))$ è di coefficiente angolare $\frac{1}{m}$ con $m \neq 0$. La sua equazione sarà:

$$y - f(x_0) = \frac{1}{m}(x - x_0)$$

Definiamo x_1 come l'intercetta di questa retta con l'asse delle ascisse:

$$\begin{cases} y - f(x_0) = \frac{1}{m}(x - x_0) \\ y = 0 \end{cases}$$

da cui

$$x_1 = x_0 - mf(x_0)$$

Iterando la procedura si perviene al metodo della direzione costante:

$$\begin{cases} x_0 \text{ assegnato} \\ x_n = x_{n-1} - m(fx_{n-1}) \end{cases}$$

La funzione iteratrice è:

$$\phi(x) = x - mf(x)$$

Essa dipende dal parametro m . Come deve essere scelto questo parametro per ottenere convergenza locale o globale? Risulta:

$$\phi'(x) = 1 - mf'(x)$$

Convergenza locale Dovremo imporre $|\phi'(\alpha)| < 1$.

$$\begin{aligned} -1 &< 1 - mf'(\alpha) < 1 \\ -2 &< -mf'(\alpha) < 0 \\ 0 &< mf'(\alpha) < 2 \end{aligned}$$

Questa è la condizione per la convergenza locale.

Convergenza globale Per la convergenza globale si ha il seguente risultato.

Teorema 1.5: Convergenza globale

Sia $f \in C^1([a, b])$ tale che:

- (a) $f(a)f(b) < 0$
- (b) $f'(x) \neq 0 \quad \forall x \in [a, b]$
- (c) $0 < mf'(x) \leq 1 \quad \forall x \in [a, b]$

Allora f ammette un unico zero $\alpha \in (a, b)$ e il metodo della direzione costante converge globalmente ad α in tutto l'intervallo $[a, b]$.

Dimostrazione. Dalla (c) ricaviamo:

$$\begin{aligned} 0 &< mf'(x) \leq 1 \\ -1 &\leq -mf'(x) < 0 \\ 0 &\leq 1 - mf'(x) < 1 \\ 0 &\leq \phi'(x) < 1 \end{aligned}$$



Quindi la seconda ipotesi del teorema di convergenza globale è soddisfatta.

Resta da provare $\phi([a, b]) \subset [a, b]$.

Poichè $\phi'(x) \geq 0$, $\phi(x)$ è monotona crescente e quindi

$$a \leq x \leq b \Rightarrow \phi(a) \leq \phi(x) \leq \phi(b)$$

Si possono presentare i due casi nelle due figure sottostanti:



Discutiamo il primo caso ($f'(x) > 0$). Risulta:

$$\phi(a) = a - mf(a) > a \quad \text{in quanto } m > 0 \text{ e } f(a) < 0$$

$$\phi(b) = b - mf(b) < b \quad \text{in quanto } m > 0 \text{ e } f(b) > 0$$

In conclusione:

$$a \leq x \leq b \Rightarrow a \leq \phi(x) \leq b$$

□

1.4 Metodo di Newton (o delle tangenti)

Definiamo questo metodo mediante due strategie diverse.

1.4.1 Approccio analitico

A partire da una stima iniziale x_0 , sviluppiamo $f(x)$ come polinomio di Taylor assestato al primo ordine in un intorno di x_0 :

$$f(x) = f(x_0) + f'(x_0)(x - x_0) + o(x - x_0)$$

dove $o(x - x_0)$ denota un infinitesimo di ordine superiore al primo per $x \rightarrow x_0$:

$$\lim_{x \rightarrow x_0} \frac{o(x - x_0)}{x - x_0} = 0$$

Se x è vicino ad x_0 , potremo trascurare l'infinitesimo $o(x - x_0)$ e scrivere

$$f(x) \approx f(x_0) + f'(x_0)(x - x_0)$$

Anzichè risolvere $f(x) = 0$, risolveremo:

$$f(x_0) + f'(x_0)(x - x_0) = 0$$

Denotando con x_1 la soluzione, si ottiene:

$$x_1 = x_0 - \frac{f(x_0)}{f'(x_0)}$$


Iterando la procedura si ottiene il metodo di Newton:

$$\begin{cases} x_0 \text{ assegnato} \\ x_n = x_{n-1} - \frac{f(x_{n-1})}{f'(x_{n-1})} \end{cases}$$

Da cui, la funzione iteratrice è:

$$\phi(x) = x - \frac{f(x)}{f'(x)}$$

1.4.2 Approccio geometrico



L'equazione della retta tangente al grafico di f nel punto di ascissa x_0 , è:

$$y - f(x_0) = f'(x_0)(x - x_0)$$

Denotiamo con x_1 l'intercetta della retta con l'asse x . Ponendo $y = 0$, si ottiene:

$$x_1 = x_0 - \frac{f(x_0)}{f'(x_0)}$$

Iterando la procedura si ottiene il metodo di Newton.

Studiamo la convergenza locale del metodo di Newton. Premettiamo la seguente definizione.

DEFINIZIONE 1.8: MOLTEPLICITÀ DI UNO ZERO

Sia $f \in C^d(B(\alpha, \delta))$ con α zero di f .

La molteplicità (o ordine) dello zero di α di f è un intero d tale che:

$$f(\alpha) = f'(\alpha) = \dots = f^{(d-1)}(\alpha) = 0 \wedge f^{(d)}(\alpha) \neq 0$$

Significato analitico Consideriamo lo sviluppo del polinomio di Taylor di f in un intorno di α :

$$f(x) = f(\alpha) + f'(\alpha)(x-\alpha) + f''(\alpha)\frac{(x-\alpha)^2}{2!} + \dots + f^{(d-1)}(\alpha)\frac{(x-\alpha)^{d-1}}{(d-1)!} + f^{(d)}(\eta_x)\frac{(x-\alpha)^d}{d!}$$

Poichè la molteplicità di α è d , risulta:

$$f(x) = \frac{f^{(d)}(\eta_x)}{d!}(x-\alpha)^d$$

con η_x opportuno punto tra x e α .


Poichè $f^{(d)}(\alpha) \neq 0$, per $x \approx \alpha$ anche $f^{(d)}(\eta_x) \neq 0$. Osserviamo che in un intorno di α , $f(x)$ si comporta come

$$f(x) \approx \text{cost.} \cdot (x-\alpha)^d$$


e quindi

$$f(x) = 0 \sim (x-\alpha)^d = 0$$


Interpretazione geometrica Se $d = 1$ allora $f(\alpha) = 0 \wedge f'(\alpha) \neq 0$



In tal caso α si dice zero semplice e questo è il caso più frequente.
 Se $d = 2$ allora $f(\alpha) = f'(\alpha) = 0 \wedge f''(\alpha) \neq 0$



In questo caso α si dice zero doppio.
 Se $d = 3$ allora $f(\alpha) = f'(\alpha) = f''(\alpha) \wedge f'''(\alpha) \neq 0$



Torniamo al metodo di Newton.

$$\phi(x) = x - \frac{f(x)}{f'(x)}$$

La sua derivata prima è:

$$\phi'(x) = 1 - \frac{[f'(x)]^2 - f(x) \cdot f''(x)}{[f'(x)]^2} = \frac{f(x) \cdot f''(x)}{[f'(x)]^2}$$

Distinguiamo due casi:

1. α zero semplice: $f(\alpha) = 0 \wedge f'(\alpha) \neq 0$

Possiamo calcolare:

$$\phi'(\alpha) = \frac{f(\alpha) \cdot f''(\alpha)}{[f'(\alpha)]^2} = 0$$

Dal teorema di convergenza locale, concludiamo che il metodo di Newton è localmente convergente.

2. α zero di molteplicità $d \geq 2$:

$$f(\alpha) = f'(\alpha) = \dots = f^{(d-1)}(\alpha) = 0 \wedge f^{(d)}(\alpha) \neq 0$$

$\phi'(x)$ non è definita in α poichè il denominatore si annulla. Tuttavia, è possibile dimostrare che:

$$\lim_{x \rightarrow \alpha} \phi'(x) = 1 - \frac{1}{d}$$

Possiamo prolungare la $\phi'(x)$ per continuità in α , ponendo, per definizione:

$$\phi'(\alpha) = \lim_{x \rightarrow \alpha} \phi'(x) = 1 - \frac{1}{d}$$

Anche in questo caso risulta che $|\phi'(\alpha)| < 1$ e otteniamo la convergenza locale.

Quindi, concludendo, il metodo di Newton è sempre localmente convergente, pertanto, studiamone la convergenza globale.

Teorema 1.6: Convergenza globale del metodo di Newton


Sia $f \in C^2([a, b])$ tale che:

- (a) $f(a) \cdot f(b) < 0$
- (b) $f'(x) \neq 0 \quad \forall x \in [a, b]$
- (c) $f''(x) \neq 0 \quad \forall x \in [a, b]$

Allora f ammette un unico zero $\alpha \in (a, b)$. Inoltre, scelto $x_0 \in [a, b]$ tale che $f(x_0) \cdot f''(x) > 0$, il metodo di Newton genera una successione $\{x_n\}$ che converge ad α monotonicamente.

Dimostrazione. L'esistenza e l'unicità dello zero $\alpha \in (a, b)$ di f discende dalle ipotesi (a) e (b).

Si distinguono quattro casi schematizzati nei grafici sottostanti:



Esaminiamo il primo caso, $f'(x) > 0$ e $f''(x) > 0$. Ricordiamo che:

$$\phi(x) = x - \frac{f(x)}{f'(x)} \quad \phi'(x) = \frac{f(x) \cdot f''(x)}{[f'(x)]^2}$$

Dall'enunciato del teorema, dovremo scegliere $x_0 \in (\alpha, b]$. Facciamo innanzitutto vedere che $\phi((\alpha, b]) \subset (\alpha, b]$

Poichè in $(\alpha, b]$ risulta $\phi'(x) > 0$, ne consegue che ϕ è strettamente crescente in $(\alpha, b]$, quindi:

$$\alpha < x \leq b \Rightarrow \phi(\alpha) < \phi(x) \leq \phi(b)$$

Ora:

$$\phi(\alpha) = \alpha$$

$$\phi(b) = b - \frac{f(b)}{f'(b)} < b \quad \text{in quanto } f(b) > 0 \text{ e } f'(b) > 0$$

Abbiamo provato che $\alpha < \phi(x) < b$

Facciamo infine vedere che $\{x_n\}$ converge ad α ed è una successione strettamente decrescente.

Dal punto precedente sappiamo che $x_n \in (\alpha, b] \quad \forall n \geq 0$.

$$x_n = x_{n-1} - \frac{f(x_{n-1})}{f'(x_{n-1})} < x_{n-1}$$

$\{x_n\}$ è strettamente decrescente e limitata inferiormente da α . Dall'analisi ammetterà limite finito:

$$\exists \lim_{n \rightarrow \infty} x_n = \beta \geq \alpha$$

Poichè β è punto fisso di ϕ , necessariamente dovrà essere $\beta = \alpha$. $\square$

Corollario 1.1

Nelle stesse ipotesi (a), (b) e (c) del teorema di **convergenza globale del metodo di Newton**, se $x_0 \in [a, b]$ e $x_1 = \phi(x_0) \in [a, b]$, allora la successione $\{x_n\}$ converge ad α .

Dimostrazione. Facendo riferimento sempre al primo caso, se scegliamo $x_0 \in [a, \alpha)$, essendo $\phi'(x) < 0$ in $[a, \alpha)$ segue che $\phi(x)$ è strettamente decrescente e quindi:

$$x_0 < \alpha \Rightarrow x_1 = \phi(x_0) > \phi(\alpha) = \alpha$$

e quindi, dall'ipotesi $x_1 \in [a, b]$ segue che $x_1 \in (\alpha, b]$ e da questo punto in poi vale il teorema precedente. $\square$

1.5 Ordine di convergenza

L'ordine di convergenza è uno strumento che ci consente di stimare la velocità con cui una successione convergente tende al suo valore limite. Questo strumento ci consentirà di confrontare i metodi iterativi in base alla rapidità di convergenza delle successioni che essi generano.

DEFINIZIONE 1.9: ORDINE DI CONVERGENZA

Sia $\{x_n\}$ una successione convergente ad $\alpha \in \mathbb{R}$:

$$\lim_{n \rightarrow \infty} x_n = \alpha \in \mathbb{R}$$

Si definisce *ordine di convergenza* della successione $\{x_n\}$ un reale positivo $p > 0$ tale che esista e sia finito il seguente limite:

$$\lim_{n \rightarrow \infty} \frac{|x_{n+1} - \alpha|}{|x_n - \alpha|^p} = c$$

con $0 < c < +\infty$

Analizziamone il significato. Per n abbastanza grande possiamo scrivere:

$$\frac{|x_{n+1} - \alpha|}{|x_n - \alpha|^p} \approx c$$

da cui:

$$|x_{n+1} - \alpha| \approx c \cdot |x_n - \alpha|^p$$

Tale uguaglianza relaziona l'errore assoluto a un generico passo con l'errore assoluto al passo precedente e quindi esprime la legge con cui l'errore si riduce, per n grande, ad ogni passo. Ne consegue che la riduzione dell'errore ad ogni passo sarà tanto maggiore:

- quanto più grande è il valore di p ;
- quanto più piccolo è il valore di c .

La costante c è detta *costante asintotica di convergenza*. La convergenza si dice:

- lineare se $p = 1$;
- superlineare se $p > 1$;
- quadratica se $p = 2$

Nota

Se $p = 1$, necessariamente $0 < c < 1$. Infatti per n grande, abbiamo:

$$|x_{n+1} - \alpha| \simeq c|x_n - \alpha|$$

Se $c \geq 1$, la distanza tra x_n e α non si ridurrebbe al crescere di n , e ciò contraddice l'ipotesi che $x_n \rightarrow \alpha$

DEFINIZIONE 1.10: ORDINE DI CONVERGENZA DI UN METODO ITERATIVO

Un metodo iterativo per la ricerca degli zeri di una funzione si dice di ordine p se, applicato a una data classe di funzioni, genera successioni che convergono allo zero con ordine p .

Esempio

Consideriamo due metodi iterativi one-step definiti dalle due iteratrici ϕ_1 e ϕ_2 , e supponiamo che, applicati per la ricerca di uno zero α di una funzione

f :

$$\phi_1 : p_1 = 1 \text{ (convergenza lineare) e } c_1 = \frac{1}{10}$$

$$\phi_2 : p_2 = 2 \text{ (convergenza quadratica) e } c_2 = 10$$

Stiamo avvantaggiando il primo metodo relativo al valore della costante asintotica in quanto:

$$c_2 = 100c_1$$

Ipotesi di lavoro: scegliamo, per i due metodi, una condizione iniziale x_0 tale che:

$$|x_0 - \alpha| = 10^{-2}$$

e supponiamo di trovarci in un intorno abbastanza piccolo di α , in modo tale che

$$|x_{n+1} - \alpha| \approx c|x_n - \alpha|^p$$

Generiamo le due successioni.

n	Errore Assoluto $\phi_1(x_n)$	Errore Assoluto $\phi_2(x_n)$
0	10^{-2}	10^{-2}
1	$\approx 10^{-3}$	$\approx 10^{-3}$
2	$\approx 10^{-4}$	$\approx 10^{-5}$
3	$\approx 10^{-5}$	$\approx 10^{-9}$
4	$\approx 10^{-6}$	$\approx 10^{-17}$

Nota

In caso di convergenza quadratica, se la costante asintotica $c \approx 1$, il numero di cifre significative dell'approssimazione allo zero α , definitivamente raddoppia da un passo al successivo

$$|x_{n+1} - \alpha| \approx c|x_n - \alpha|^2 \quad \text{con } c \approx 1$$

Se $\frac{|x_n - \alpha|}{|\alpha|} < 10^{-d}$, quindi x_n contiene d cifre significative corrette, abbiamo:

$$\frac{|x_n - \alpha|}{|\alpha|} \approx \frac{|x_n - \alpha|^2}{|\alpha|} = |\alpha| \cdot \left(\frac{|x_n - \alpha|}{|\alpha|} \right)^2 < |\alpha| 10^{-2d}$$

La seguente proposizione ci fornisce un modo per determinare l'ordine di convergenza p di un metodo iterativo nel caso di metodi iterativi one-step.

PROPOSIZIONE 1.1

Sia $\phi \in C^p(B(\alpha, \delta))$, con α punto fisso di ϕ , Sono equivalenti le seguenti due proposizioni

- (a) Il metodo iterativo one-step definito da ϕ ha ordine p .
- (b) $\phi'(\alpha) = \phi''(\alpha) = \dots = \phi^{(p-1)}(\alpha) = 0 \wedge \phi^{(p)}(\alpha) \neq 0$

Dimostrazione. Delle due implicazioni $(a) \Rightarrow (b)$ e $(b) \Rightarrow (a)$, mostreremo solo al seconda, che è la più importante.

$(b) \Rightarrow (a)$ Consideriamo lo sviluppo di Taylor della funzione iteratrice ϕ in un intorno di α :

$$\phi(x) = \phi(\alpha) + \phi'(\alpha)(x-\alpha) + \frac{\phi''(\alpha)}{2!}(x-\alpha)^2 + \dots + \frac{\phi^{(p-1)}(\alpha)}{(p-1)!}(x-\alpha)^{p-1} + \frac{\phi^{(p)}(\eta_x)}{p!}(x-\alpha)^p$$

Con η_x opportuno punto tra x e α .

Dall'ipotesi (b) possiamo semplificare come:

$$\phi(x) = \phi(\alpha) + \frac{\phi^{(p)}(\eta_x)}{p!}(x-\alpha)^p$$

Per la successione $\{x_n\}$ generata dal metodo possiamo scrivere:

$$x_{n+1} - \alpha = \phi(x_n) - \phi(\alpha) = \frac{\phi^{(p)}(\eta_n)}{p!}(x_n - \alpha)^p$$

dove η_n è un opportuno punto tra x_n e α .

Si noti che, poichè $x_n \rightarrow \alpha$, anche $\eta_n \rightarrow \alpha$. Otteniamo che:

$$\begin{aligned} \lim_{n \rightarrow \infty} \frac{|x_{n+1} - \alpha|}{|x_n - \alpha|^p} &= \lim_{n \rightarrow \infty} \frac{|\phi^{(p)}(\eta_n)|}{p!} \\ &= \frac{1}{p!} |\phi^{(p)}(\lim_{n \rightarrow \infty} \eta_n)| \\ &= \frac{1}{p!} |\phi^{(p)}(\alpha)| \end{aligned}$$

□

Nota

La costante asintotica di convergenza dei metodi one-step è:

$$\frac{1}{p!} |\phi^{(p)}(\alpha)|$$

In particolare, per $p = 1$,

$$c = |\phi'(\alpha)|$$

1.5.1 Metodo della direzione costante

Ricordiamo che:

$$\begin{aligned}\phi(x) &= x - mf(x) \\ \phi'(x) &= 1 - mf'(x) \\ \phi'(\alpha) &= 1 - mf'(\alpha)\end{aligned}$$

Distinguiamo due casi:

1. $m \neq \frac{1}{f'(\alpha)}$. Questo è il caso generale. Risulta $\phi'(\alpha) \neq 0$ e quindi l'ordine di convergenza è $p = 1$.
2. $m = \frac{1}{f'(\alpha)}$. In questo caso eccezionale risulta $\phi'(\alpha) = 0$ e quindi la successione $\{x_n\}$ generata con questa scelta converge ad α con ordine $p = 2$.

L'ordine di convergenza del metodo della direzione costante è $p = 1$.

1.5.2 Metodo di Newton

Ricordiamo che:

$$\begin{aligned}\phi(x) &= x - \frac{f(x)}{f'(x)} \\ \phi'(x) &= \frac{f(x) \cdot f''(x)}{[f'(x)]^2}\end{aligned}$$

Distinguiamo due casi:

1. α zero semplice. In questo caso generale:

$$\phi'(\alpha) = 0$$

In generale, $\phi'(\alpha) = 0$, quindi il metodo di Newton, in presenza di zeri semplici, ha ordine $p = 2$.

2. α zero di molteplicità $d > 1$. In tal caso, avevamo provato che:

$$\phi'(\alpha) = \lim_{x \rightarrow \alpha} \phi'(x) = 1 - \frac{1}{d} \neq 0$$

In presenza di zeri multipli, la successione $\{x_n\}$ generata dal metodo di Newton converge ad α linearmente.

Quindi il vantaggio del metodo di Newton è che esso converge con ordine $p = 2$. Tuttavia, per la sua implementazione, occorre preventivamente calcolare la derivata prima di f . Ciò può essere oneroso se f ha un'espressione complicata o addirittura impossibile se f non è nota. Inoltre, il costo computazionale per iterata del metodo di Newton è:

$$\frac{2 \text{ valutazioni di funzione}}{\text{iterata}}$$

quindi, ad esempio, costa il doppio rispetto al metodo della direzione costante. Si osservi che il numero di valutazioni di funzione è proporzionale al tempo di esecuzione sul calcolatore. Infine, la convergenza del metodo può rallentare molto se x_n non è abbastanza vicino ad α . In alcuni casi la regione di convergenza potrebbe essere molto piccola, il che richiederebbe una stima iniziale x_0 molto buona.

Per questo, si introducono alcune varianti del metodo di Newton che possono risolvere uno o più degli svantaggi sopra elencati. Ne analizziamo due.

1.6 Metodo di Newton modificato

Il metodo di Newton modificato non è altro che il metodo della direzione costante con la seguente definizione del parametro m :

$$m = \frac{1}{f'(x_0)}$$

Il metodo di Newton modificato è:

$$\begin{cases} x_0 \text{ assegnato} \\ x_n = x_{n-1} - \frac{f(x_n)}{f'(x_0)} \quad n \geq 1 \end{cases}$$

La derivata prima di f va calcolata solo nel punto iniziale. L'idea è che se $x_0 \approx \alpha$ allora $f'(x_0) \approx f'(\alpha)$ e quindi

$$m = \frac{1}{f'(x_0)} \approx \frac{1}{f'(\alpha)}$$

Ricordiamo che per $m = \frac{1}{f'(\alpha)}$ la convergenza sarebbe quadratica. Nel nostro caso, il metodo diventa lineare, ma la costante asintotica è piccola:

$$|\phi'(\alpha)| = |1 - mf'(\alpha)| = \left| 1 - \frac{f'(\alpha)}{f'(x_0)} \right| \ll 1$$

Il costo computazionale è pari a:

$$\frac{1 \text{ valutazione di funzione}}{\text{iterata}}$$

1.7 Metodo delle secanti

Il metodo delle secanti lo si ottiene dal metodo di Newton operando la seguente approssimazione della derivata prima di f in x_n :

$$f'(x_n) \approx \frac{f(x_n) - f(x_{n-1})}{x_n - x_{n-1}}$$

Il metodo delle secanti è così definito:

$$\begin{cases} x_0, x_1 \text{ assegnati,} \\ x_{n+1} = x_n - \frac{f(x_n)}{\frac{f(x_n) - f(x_{n-1})}{x_n - x_{n-1}}}, \quad n \geq 1 \end{cases}$$


È un metodo a due passi. Si può dimostrare che il suo ordine è:

$$p = \frac{1 + \sqrt{5}}{2}$$

Si tratta di un metodo superlineare $1 < p < 2$. Il costo computazionale è:

$$\frac{1 \text{ valutazione di funzione}}{\text{iterata}}$$

Vediamo il perchè di questo risultato.



Interpretazione geometrica Il punto x_2 lo si ottiene come intercetta della retta secante il grafico della funzione f nei punti di ascissa x_0 e x_1 . L'equazione di questa retta è:

$$y - f(x_0) = \frac{f(x_1) - f(x_0)}{x_1 - x_0}(x - x_0)$$

Criteri di arresto Poichè non possiamo calcolare gli infiniti elementi della successione $\{x_n\}$ ed inoltre, considerando che il calcolatore ha una precisione finita, arresteremo l'iterazione quando

$$|x_n - \alpha| < tol$$

dove tol è una tolleranza assegnata in input dall'utente. Un'analogia condizione possiamo scriverla per l'errore relativo e per l'errore misto. Per il momento consideriamo l'errore assoluto. Quando la condizione sopra scritta si realizza, il processo di iterazione ha termine e si considera l'ultimo elemento calcolato della successione quale approssimante di α :

$$x_n \approx \alpha$$

Poichè α non è noto, la condizione di arresto non è una condizione operativa. Si possono seguire due strade:

1. determinare una maggiorazione calcolabile dell'errore assoluto;
2. determinare una stima dell'errore assoluto.

Maggiorazione dell'errore assoluto Consideriamo

$$\begin{aligned}x_{n+1} - x_n &= x_{n+1} - \alpha + \alpha - x_n \\&= \phi(x_n) - \phi(\alpha) - (x_n - \alpha) \\&= \phi'(\eta_n)(x_n - \alpha) - (x_n - \alpha) \\&= (\phi'(\eta_n) - 1)(x_n - \alpha)\end{aligned}$$

Poichè $\eta_n \rightarrow \alpha$ per $n \rightarrow \infty$ ciò implica che $|\phi'(\eta_n)| < 1$ per n grande e quindi, per n grande

$$1 - \phi'(\eta_n) \geq 1 - |\phi'(\eta_n)| > 0$$

Dalle uguaglianze precedenti ricaviamo:

$$|x_n - \alpha| = \frac{1}{|1 - \phi'(\eta_n)|} |x_{n+1} - x_n| \leq \frac{1}{1 - |\phi'(\eta_n)|} |x_{n+1} - x_n|$$

Se si riesce a determinare un intervallo $[a, b]$ tale che:

- $\alpha \in (a, b)$
- $|\phi'(x)| < 1$ in $[a, b]$

Denotando con $M = \max_{a \leq x \leq b} |\phi'(x)| < 1$ per n grande $\eta_n \in (a, b)$ e quindi:

$$\begin{aligned}|\phi'(\eta_n)| &\leq M \\-|\phi'(\eta_n)| &\geq -M \\1 - |\phi'(\eta_n)| &\geq 1 - M \\\frac{1}{1 - |\phi'(\eta_n)|} &\leq \frac{1}{1 - M}\end{aligned}$$

Sfruttando questa maggiorazione otteniamo

$$|x_n - \alpha| \leq \frac{1}{1 - M} |x_{n+1} - x_n|$$

Abbiamo ottenuto due maggioranze valutabili dell'errore assoluto. Il criterio di arresto diventa

$$\frac{1}{1 - M} |x_{n+1} - x_n| < tol$$

Stima dell'errore Anzichè determinare una maggiorazione dell'errore, se ne determina una stima. In generale si sceglie:

$$|x_n - \alpha| \approx C|x_{n+1} - x_n|$$

C è una costante solitamente fissata ad 1 oppure $C > 1$. La scelta $C = 1$ è certamente appropriata per il metodo di Newton. Infatti sappiamo che, in presenza di zeri semplici, $\phi'(\alpha) \neq 0$; ciò significa che, per n grande, $\phi'(\eta_n) \approx 0$ e quindi

$$\frac{1}{1 - \phi'(\eta_n)} \approx 1$$

Scegliendo $C = 1$, il criterio di arresto si semplifica come:

$$|x_{n+1} - x_n| < tol$$

Per l'errore relativo, possiamo usare il seguente criterio di arresto:

$$\frac{|x_{n+1} - x_n|}{|x_{n+1}|} < tol$$

Infine, per l'errore misto:

$$\frac{|x_{n+1} - x_n|}{1 + |x_{n+1}|} < tol$$

Capitolo 2

Richiami sui numeri complessi

Capitolo 3

Aritmetica di macchina e analisi degli errori

3.1 Considerazioni preliminari

Per la rappresentazione dei numeri reali si utilizza, solitamente, una notazione posizionale. Ad esempio:

$$123.45 = 1 \cdot 10^2 + 2 \cdot 10 + 3 \cdot 10^0 + 4 \cdot 10^{-1} + 5 \cdot 10^{-2}$$

Più in generale, lavorando con una base $\beta \geq 2$:

$$d_m d_{m-1} \dots d_0 . d_1 d_2 \dots d_n = d_m \beta^m + d_{m-1} \beta^{m-1} + \dots + d_0 \beta^0 + d_1 \beta^{-1} + \dots + d_n \beta^{-n}$$

Consideriamo il seguente esempio.

Esempio

Supponiamo che, per la memorizzazione dei numeri reali abbiamo a disposizione un campo di memoria costituito da 5 celle, ciascuna delle quali può ospitare una cifra. Consideriamo il seguente esempio:

$$x = 0.00123456$$

Nel campo di memoria assegnato, il numero x verrà rappresentato dalla sua approssimazione

$$x_1 = 0.0012 \simeq x$$

Considerando invece la rappresentazione normalizzata di x :

$$x = 1.23456 \cdot 10^{-3}$$

Utilizzando questa notazione, potremo dedicare una cella per la memorizzazione dell'esponente, ottenendo così l'approssimazione

$$x_2 = 1.234 \cdot 10^{-3}$$

È evidente che x_2 risulta una migliore approssimazione di x rispetto a x_1 . Quindi, per la rappresentazione dei numeri reali converrà utilizzare la notazione normalizzata:

$$x = \pm d_0.d_1d_2 \cdots \beta^p$$

ove $d_0.d_1d_2 \cdots$ è la *mantissa*, β è la *base* e p è l'*esponente*, il cui significato è:

$$x = \pm \beta^p \sum_{i=0}^{\infty} d_i \beta^{-i}$$

con $d_0 \neq 0$

Teorema 3.1: Rappresentazione in base

Sia $\beta \geq 2$ ove β è un intero. Allora, ogni numero reale $x \in \mathbb{R}$, $x \neq 0$ può essere espresso in maniera univoca come

$$x = \pm \beta^p \sum_{i=0}^{\infty} d_i \beta^{-i}$$

dove:

- β è la *base della rappresentazione*;
- $p \in \mathbb{Z}$ è l'*esponente*;
- $\pm$ è il *segno*;
- $0 \leq d_i \leq \beta - 1$, $i = 0, 1, \dots$
- $d_0 \neq 0$ detta *condizione di normalizzazione*;
- le cifre d_i non sono definitivamente uguali a $\beta - 1$.

Nota

1. Abbiamo escluso lo zero poichè questo non ammette una notazione normalizzata.
2. L'ultima condizione impone che le cifre d_i non siano uguali a $\beta - 1$ da un certo indice in poi. Tale condizione è importante per avere l'unicità della rappresentazione.

Esempio

In base $\beta = 10$, scegliamo il numero

$$\begin{aligned}x &= 0.\overline{9} = 9.\overline{9} \cdot 10^{-1} \\&= 10^{-1} \sum_{i=0}^{\infty} 9 \cdot 10^{-i} = \frac{9}{10} \sum_{i=0}^{\infty} \left(\frac{1}{10}\right)^i \\&= \frac{9}{10} \frac{1}{1 - \frac{1}{10}} = 1\end{aligned}$$

In conclusione $0.\overline{9}$ e 1 rappresentano lo stesso numero reale. Analogamente:

$$1.23\overline{9} = 1.24$$

Il calcolatore, disponendo di memoria finita, non può rappresentare correttamente gli infiniti numeri reali. Le difficoltà nascono da due impedimenti:

- il numero arbitrariamente elevato delle cifre d_i
- l'esponente p può variare da $-\infty$ a $+\infty$

Dovremo quindi fissare un numero massimo di cifre d_i e una variabilità finita per l'esponente.

3.2 Numeri di macchina

Sono quei numeri reali che il calcolatore è in grado di rappresentare correttamente.

DEFINIZIONE 3.1: INSIEME DEI NUMERI DI MACCHINA

Siano $\beta \geq 2$, $t \geq 0$, M_1, M_2 interi.

Si definisce insieme dei numeri di macchina in base β , con $t + 1$ cifre significative e range per l'esponente $p \in (M_1, M_2)$, il seguente sottoinsieme di $\mathbb{R}$:

$$\mathbb{F} = \{x \in \mathbb{R} \mid x = \pm \beta^p \sum_{i=0}^t d_i \beta^{-i}\} \cup \{0\}$$

dove:

- β è la base della rappresentazione;
- $\pm$ è il segno;
- $0 \leq d_i \leq \beta - 1$, $d_0 \neq 0$
- $p \in (M_1, M_2)$

Osserviamone alcune proprietà.

1. $\text{card}(\mathbb{F}) < +\infty$, $\mathbb{F}$ è un sottoinsieme finito di $\mathbb{R}$.
2. Al fine di memorizzare numeri piccoli (con esponente negativo) e grandi (con esponente positivo), sceglieremo $M_1 < 0$ e $M_2 > 0$
3. Per la base β , i calcolatori utilizzano generalmente il sistema binario. Questa scelta è suggerita dalla natura fisica dei dispositivi elettronici che memorizzano ed elaborano i dati. Essi possono assumere due stati fisici. Ad esempio:

- passaggio o meno di corrente attraverso una resistenza;
- magnetizzazione o meno di un dispositivo magnetico.

4. Un vantaggio dell'uso del sistema binario è che, dovendo essere $d_i = 0, 1$, dalla condizione di normalizzazione:

$$d_0 \neq 0 \Rightarrow d_0 = 1$$

quindi è inutile memorizzare la cifra d_0 risparmiando così 1 bit.

5. I numeri di macchina sono disposti simmetricamente rispetto alla zero, tuttavia la loro distribuzione non è uniforme. Più in particolare consideriamo

un generico numero di macchina positivo:

$$a = \beta^p \sum_{i=0}^t d_i \beta^{-i}$$

Il numero di macchina successivo, lo denotiamo con b , lo si ottiene incrementando di una unità l'ultima cifra d_t :

$$\begin{aligned} b &= a + \beta^p \cdot 0.0 \dots 1 \\ &= a + \beta^p \beta^{-t} = a + \beta^{p-t} \end{aligned}$$

da cui, la distanza tra due numeri di macchina consecutivi è

$$b - a = \beta^{p-t}$$

Notiamo che questa distanza dipende dalla grandezza del numero di macchina considerato per la presenza dell'esponente p . Ne consegue che i numeri di macchina sono più densi vicino all'origine e si diradano man mano che ci allontaniamo dall'origine.

6. Utilizzando la notazione posizionale un numero di macchina non nulla ha l'espressione:

$$x = \pm \beta^p (d_0.d_1 \dots d_t)$$

Determiniamo il $\min \mathbb{F}_+^*$, $\max \mathbb{F}_+^*$ dove $\mathbb{F}_+^*$ denota l'insieme dei numeri di macchina positivi.

Siano $\omega = \min \mathbb{F}_+^*$, $\Omega = \max \mathbb{F}_+^*$.

ω lo si ottiene minimizzando i valori dell'esponente p e della mantissa. Pertanto:

$$\omega = \beta^{M_1+1} 1.0 \dots 0 = \beta^{M_1+1}$$

Per determinare Ω premettiamo la seguente proprietà. Sia $z \neq 1$; risulta:

$$\begin{aligned} 1 + z + \dots + z^t &= \frac{(1-z)(1+z+\dots+z^t)}{1-z} \\ &= \frac{1+z+z^2+\dots+z^t - z - z^2 - \dots - z^{t+1}}{1-z} \\ &= \frac{1-z^{t+1}}{1-z} \end{aligned}$$

Questa è la formula di una progressione geometrica di ragione z . Passiamo al calcolo di Ω :

$$\begin{aligned}\Omega &= \beta^{M_2-1} \sum_{i=0}^t (\beta - 1) \beta^{-i} = \beta^{M_2-1} (\beta - 1) \sum_{i=0}^t (\beta^{-1})^i \\ &= \beta^{M_2-1} (\beta - 1) \frac{1 - \beta^{-t-1}}{1 - \beta^{-1}} \\ &= \beta^{M_2} (1 - \beta^{-t-1}) \text{ oppure } \beta^{M_2-1} (\beta - \beta^{-t})\end{aligned}$$

3.3 Standard IEEE-754

Lo standard IEEE-754 è uno standard per l'implementazione dell'aritmetica di macchina sui calcolatori, al fine di rendere compatibili i codici sulle varie piattaforme. Questo standard prevede le seguenti due modalità fondamentali:

- Semplice (o singola) precisione;
- Doppia precisione.

La doppia precisione è la modalità più frequentemente utilizzata. In ogni caso la base utilizzata è $\beta = 2$.

3.3.1 Semplice precisione

In semplice precisione, per la memorizzazione di un numero di macchina, viene predisposto un campo di memoria costituito da 32 bit così suddivisi:

- 1 bit per il segno;
- 8 bit per l'esponente;
- 23 bit per la mantissa.

Il segno viene rappresentato mediante 0 per il più e 1 per il meno. Con un'esponente di 8 bit possiamo realizzare $2^8 = 256$ configurazioni distinte. Si sceglie:

$$M_1 = -127 \quad M_2 = 128$$

Anzichè memorizzare l'esponente con il suo segno, si applica una tecnica di traslazione (bias) in base alla quale viene memorizzata la cosiddetta *caratteristica* p^* che è relazionata all'esponente p mediante l'equazione

$$p^* = p - M_1 \iff p = p^* + M_1$$

La seguente tabella chiarisce meglio i termini di questa relazione.

Fare tabella

La configurazione vuota ($p^* = 0$) e quella piena ($p^* = 255$) sono state lasciate libere. Esse sono utilizzate per altri scopi:

- lo zero si rappresenta con caratteristica nulla e mantissa nulla.
- la caratteristica piena serve per gestire le cosiddette eccezioni previste dallo standard IEEE:
 - $p^* = 255$ e mantissa nulla identificano il simbolo $+Inf$
 - $p^* = 255$ e mantissa non nulla identificano il simbolo NaN

Questi simboli sono l'output di alcune operazioni non consentite in aritmetica reale e il loro scopo è evitare l'arresto dell'esecuzione di un codice in corrispondenza di queste operazioni. Ad esempio:

$$\begin{aligned} \frac{1}{0} &= +Inf & \tan \frac{\pi}{2} &= +Inf \\ \arctan(+Inf) &= \frac{\pi}{2} \\ \frac{0}{0} &= NaN; & Inf - Inf &= NaN \\ 1^{Inf} &= NaN & \frac{Inf}{Inf} &= NaN \end{aligned}$$

- Scegliendo caratteristica nulla e mantissa non nulla, si identificano i cosiddetti **numeri subnormali** o non normalizzati. I numeri subnormali sono numeri non normalizzati, quindi con $d_0 = 0$ più piccoli ma molto prossimi a ω .

Sono utilizzati per memorizzare numeri reali più piccoli ma molto prossimi ad ω meglio di quanto non facciano lo zero e lo stesso ω .

L'espressione generica di un numero subnormale è:

$$\pm \beta^{M_1+1} 0.d_1 d_2 \dots d_t$$

Ad esempio, il più grande numero subnormale lo si ottiene scegliendo $d_1 = d_2 = \dots = d_t = \beta - 1$

Il più piccolo numero subnormale positivo è: β^{M_1+1-t}

3.3.2 Doppia precisione

A ogni numero di macchina viene riservato un campo costituito da 64 bit così suddivisi:

- 1 bit per il segno;
- 11 bit per l'esponente;
- 52 bit per la mantissa.

Per l'esponente p si sceglie il seguente range:

$$M_1 = -1023 \quad M_2 = 1024$$

Ne consegue che, in doppia precisione:

$$\omega = 2^{-1022} \approx 2.2 \cdot 10^{-308}$$

$$\Omega = 2^{1024}(1 - 2^{-53}) \approx 1.7 \cdot 10^{308}$$

In doppia precisione, i numeri subnormali sono:

$$\omega = 2^{-1022} \cdot 1.0 \dots 0$$

$$\text{subnormali } 2^{-1022} \cdot 0.1 \dots 1$$

$$\vdots$$

$$2^{-1022} \cdot 0.0 \dots 01$$

$$= 2^{-1074}$$

Nota

I numeri subnormali hanno un numero di cifre significative minore di $t + 1$. In effetti la presenza degli zeri all'inizio della mantissa serve per perfezionare l'esponente permettendogli di assumere valori minori di $M_1 + 1$ a discapito di una perdita di accuratezza in termini di cifre significative.

3.4 Rappresentazione dei numeri reali mediante i numeri di macchina

Ogni numero reale verrà approssimato sul calcolatore mediante un opportuno numero di macchina. Occorre definire una funzione;

$$fl : \mathbb{R} \rightarrow \mathbb{F}$$

Distinguiamo i seguenti casi. Sia $x \in \mathbb{R}$ e, senza ledere la generalità, supponiamo $x > 0$, sfruttando la simmetria di $\mathbb{F}$. Possiamo scrivere:

$$x = \beta^p \sum_{i=0}^{\infty} d_i \beta^{-i}$$

1. $x \in \mathbb{F}$. In tal caso, ovviamente, porremo $fl(x) = x$
In altri termini,

$$fl|_{\mathbb{F}} = \text{identità}$$

2. $p \geq M_2$. L'esponente di x è più grande del numero esponente consentito in $\mathbb{F}(M_2 - 1)$. Si genera una condizione di *overflow* e si pone

$$fl(x) = +Inf$$

3. $p \leq M_1$. L'esponente di x è più piccolo del minimo esponente consentito in $\mathbb{F}(M_1 + 1)$. Si genera una condizione di *underflow* e si pone

$$fl(x) = \begin{cases} \text{subnormale} & M_1 - t + 1 \leq p \leq M_1 \\ 0 & p \leq M_1 - t \end{cases}$$

Ora analizziamo il caso più frequente.

4. $M_1 < p < M_2, x \in \mathbb{F}$. Ciò significa che $\exists i > t$ tale che $d_i \neq 0$
Si possono presentare due sottocasi

- 4.1. $x \in (\omega, \Omega)$

- 4.2. $p = M_2 - 1, d_0 = d_1 = \dots = d_t = \beta - 1$ e $\exists i > t \mid d_i \neq 0$

Nel secondo sottocaso x è subito a destra di Ω . Nel seguito analizziamo il primo sottocaso: nel secondo si utilizzerà un ragionamento analogo. Quindi supponiamo $x \in (\omega, \Omega)$
In tal caso x sarà composto tra due numeri di macchina consecutivi, che denotiamo con a e b . Evidentemente:

$$a = \beta^p \sum_{i=0}^t d_i \beta^{-i} \quad b = a + \beta^{p-t}$$

Lo standard IEEE contempla due tecniche.

Tecnica del troncamento

$$fl(x) = trn(x) = a$$

Tecnica dell'arrotondamento

$$fl(x) = \begin{cases} a & x < \frac{a+b}{2} \\ b & x > \frac{a+b}{2} \end{cases}$$

Nel caso in cui $x = \frac{a+b}{2}$

$$fl(x) = \begin{cases} a & \text{se } d_t \text{ è pari} \\ b & \text{se } d_t \text{ è dispari} \end{cases}$$

In questo modo si evita di creare una direzione privilegiata (polarizzazione), mantenendo la simmetria della procedura. In particolare, in base $\beta = 2$, l'ultima relazione diventa

$$fl(x) = \begin{cases} a & d_t = 0 \\ b & d_t = 1 \end{cases}$$

Nota

Nel secondo sottocaso, si ragiona in modo analogo scegliendo

$$a = \Omega \quad b = a + \beta^{M_2-1-t}$$

Se $x > \frac{a+b}{2}$ si pone $fl(x) = +Inf$

Se $x < \frac{a+b}{2}$ si pone $fl(x) = \Omega$

■ Se $x = \frac{a+b}{2}$ e β è pari: $fl(x) = +Inf$.

3.5 Errori di rappresentazione

Gli errori di rappresentazione sono gli errori che si generano quando un numero reale viene approssimato da un numero di macchina. Anche qui analizziamo il caso $x > 0$. Supponiamo che non si incorra in condizioni di overflow o underflow e in particolare che $x \in [\omega, \Omega]$. Analizziamo, qui di seguito, gli errori assoluto e relativo in corrispondenza delle due tecniche di approssimazione: troncamento e arrotondamento.

3.5.1 Errore assoluto

Nella tecnica del troncamento:

$$E_a = |fl(x) - x| = |a - x| < b - a = \beta^{p-t}$$

Nella tecnica dell'arrotondamento:

$$E_a = |arr(x) - x| \leq \frac{1}{2}\beta^{p-t}$$

■ Nota

L'errore assoluto dipende dalla grandezza di x , cioè dal suo esponente p .

3.5.2 Errore relativo

■ Nota

Notiamo che:

$$x = \beta^p \cdot d_0.d_1 \dots \geq \beta^p \cdot 1.0 \dots 0 = \beta^p$$

Passando ai reciproci:

$$\frac{1}{x} \leq \frac{1}{\beta^p} = \beta^{-p}$$

Con la tecnica del troncamento:

$$E_r = \frac{|fl(x) - x|}{|x|} < \beta^{p-t} \cdot \beta^{-p} = \beta^{-t}$$

Con la tecnica dell'arrotondamento:

$$E_r = \frac{|arr(x) - x|}{|x|} \leq \frac{1}{2} \beta^{p-t} \beta^{-p} = \frac{1}{2} \beta^{-t}$$

Osserviamo che l'uguaglianza potrebbe verificarsi quando, contemporaneamente

$$\begin{cases} |arr(x) - x| = \frac{1}{2} \beta^{p-t} \\ x = \beta^p \end{cases} \iff x = \frac{a+b}{2}$$

Tuttavia, le due condizioni sono incompatibili perché:

$$\frac{a+b}{2} \notin \mathbb{F} \quad \beta^p \in \mathbb{F}$$

In conclusione, possiamo scrivere:

$$E_r < \frac{1}{2} \beta^{-t}$$

Nota

Nel caso dell'errore relativo, la maggiorazione ottenuta è indipendente dalla grandezza del numero x . Ulteriormente, la maggiorazione ci dice che $fl(x)$ contiene almeno t cifre significative corrette.

DEFINIZIONE 3.2: PRECISIONE DI MACCHINA

Lavorando con l'arrotondamento, la quantità:

$$u = \frac{1}{2} \beta^{-t}$$

è detta *precisione di macchina*.

È la più piccola maggiorazione sull'errore relativo in fase di rappresentazione dei numeri reali mediante i numeri di macchina.

In doppia precisione:

$$u = \frac{1}{2} 2^{-52} = 2^{-53} \approx 1.1 \cdot 10^{-16}$$

Ciò significa che, operando in doppia precisione, possiamo fidare in 15/16 cifre significative corrette.

Nota

Un modo equivalente per esprimere il fatto che l'errore relativo è minore della precisione di macchina è il seguente.

Poniamo

$$\epsilon = \frac{fl(x) - x}{x} \quad \text{quindi } |\epsilon| < u$$

Ricavando $fl(x)$:

$$fl(x) = x(1 + \epsilon) \quad \text{con } |\epsilon| < u$$

3.6 Operazioni di macchina

Consideriamo il seguente esempio.

Esempio

Consideriamo un insieme di numeri di macchina in base $\beta = 10$ con $t = 1$ (due cifre significative). Dati i numeri di macchina:

$$x_1 = 1.2 \cdot 10^0 \quad x_2 = 3.4 \cdot 10^{-1}$$

determinare la somma:

$$x_1 + x_2 = \frac{1.2 \cdot 10^0 + 0.34 \cdot 10^0}{1.54 \cdot 10^0}$$

Evidentemente $x_1 + x_2 \notin \mathbb{F}$.

Questo esempio mostra che il calcolatore non può implementare le quattro operazioni elementari:

$$op : +, -, *, /$$

in modo esatto, ma dovrà approssimarle mediante altrettante operazioni di macchina

$$\textcircled{op} : \textcircled{+}, \textcircled{-}, \textcircled{*}, \textcircled{/}$$

ove $op : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$, mentre

$$\textcircled{op} : \mathbb{F} \times \mathbb{F} \rightarrow \mathbb{F}$$

Nell'esempio precedente, potremmo porre

$$x_1 \textcircled{+} x_2 = fl(x_1 + x_2) = arr(x_1 + x_2) = arr(1.54 \cdot 10^0) = 1.5 \cdot 10^0$$

In fase di ogni singola operazione elementare, si richiederà la medesima accuratezza che si ottiene in fase di rappresentazione:

$$\forall x_1, x_2 \in \mathbb{F} : x_1 \bigcirc x_2 = (x_1 \text{ op } x_2)(1 + \epsilon) \quad \text{con } |\epsilon| < u$$

Un'aritmetica che soddisfi questa proprietà è detta *aritmetica floating-point* o in *virgola mobile*.

Ad esempio, è un'aritmetica floating-point quella che si ottiene ponendo:

$$x_1 \bigcirc x_2 = fl(x_1 \text{ op } x_2)$$

3.6.1 Proprietà dell'aritmetica di macchina

Le seguenti proprietà dell'aritmetica reale continuano a valere per l'aritmetica di macchina.

1. Permanenza degli elementi neutri.

$\forall x \in \mathbb{F}$:

$$x \bigoplus 0 = x$$

$$x \bigodot 1 = x$$

2. Proprietà commutativa.

$\forall x_1, x_2 \in \mathbb{F}$:

$$x_1 \bigoplus x_2 = x_2 \bigoplus x_1$$

$$x_1 \bigodot x_2 = x_2 \bigodot x_1$$

3. Legge di annullamento del prodotto.

$\forall x_1, x_2 \in \mathbb{F}$ se $x_1 \bigodot x_2$ non genera underflow oppure overflow:

$$x_1 \bigodot x_2 = 0 \Rightarrow x_1 = 0 \vee x_2 = 0$$

Le seguenti proprietà non sono più valide in aritmetica di macchina.

1. Proprietà associativa.

In generale, non è vero che $\forall x_1, x_2, x_3 \in \mathbb{F}$:

$$(x_1 \bigoplus x_2) \bigoplus x_3 = x_1 \bigoplus (x_2 \bigoplus x_3)$$

$$(x_1 \bigodot x_2) \bigodot x_3 = x_1 \bigodot (x_2 \bigodot x_3)$$

Esempio : Primo controesempio

Consideriamo $\beta = 10, t = 1$ con arrotondamento, e i tre numeri di macchina:

$$x_1 = 1.2 \cdot 10^0 \quad x_2 = 1.3 \cdot 10^{-1} \quad x_3 = 1.4 \cdot 10^{-1}$$

Risulta:

$$\begin{aligned} x_1 \oplus x_2 &= \frac{1.2 \cdot 10^0 \oplus 0.13 \cdot 10^0}{fl(1.33 \cdot 10^0)} \\ &= 1.3 \cdot 10^0 \\ (x_1 \oplus x_2) \oplus x_3 &= \frac{1.3 \cdot 10^0 \oplus 0.14 \cdot 10^0}{fl(1.44 \cdot 10^0)} \\ &= 1.4 \cdot 10^0 \end{aligned}$$

Ora calcoliamo:

$$\begin{aligned} x_2 \oplus x_3 &= \frac{0.13 \cdot 10^0 \oplus 0.14 \cdot 10^0}{fl(0.27 \cdot 10^0)} \\ &= 0.27 \cdot 10^0 \\ x_1 \oplus (x_2 \oplus x_3) &= \frac{1.2 \cdot 10^0 \oplus 0.27 \cdot 10^0}{fl(1.47 \cdot 10^0)} \\ &= 1.5 \cdot 10^0 \end{aligned}$$

Esempio : Secondo controesempio

In doppia precisione, con arrotondamento, consideriamo i numeri di macchina:

$$x_1 = 1 \cdot 2^0 \quad x_2 = 1.0 \dots 0 \cdot 2^{-53} \quad x_3 = x_2$$

Calcoliamo:

$$\begin{aligned}
 x_1 \oplus x_2 &= arr(1 + 2^{-53}) \\
 &= arr(1.0 \dots 01) = 1 \cdot 2^0 \\
 (x_1 \oplus x_2) \oplus x_3 &= 1 \cdot 2^0 \oplus 1 \cdot 2^{-53} \\
 &= 1 \cdot 2^0
 \end{aligned}$$

D'altra parte:

$$\begin{aligned}
 x_2 \oplus x_3 &= 1 \cdot 2^{-53} \oplus 1 \cdot 2^{-53} \\
 &= 1 \cdot 1 \cdot 2^{-52} \\
 x_1 \oplus (x_2 \oplus x_3) &= arr(1.0 \dots 01) \\
 &= 1.0 \dots 01 \cdot 2^0 \\
 &= 1 + 2^{-52}
 \end{aligned}$$

2. Proprietà distributiva della moltiplicazione rispetto all'addizione.

In generale, non è vero che, $\forall x_1, x_2, x_3 \in \mathbb{F}$:

$$x_1 \otimes (x_2 \oplus x_3) = (x_1 \otimes x_2) \oplus (x_1 \otimes x_3)$$

3. Semplificazione.

In generale, non è vero che, $\forall x_1, x_2, x_3 \in \mathbb{F}$ con $x_2 \neq 0$:

$$\begin{aligned}
 (x_1 \oslash x_2) \otimes x_2 &= x_1 \\
 x_1 \otimes x_2 = x_3 \otimes x_2 &\Rightarrow x_1 = x_3
 \end{aligned}$$

In ogni caso, tutte le proprietà dell'aritmetica reale continuano a valere in aritmetica di macchina a meno di errori dell'ordine della precisione di macchina. Ad esempio:

$$(x_1 \oslash x_2) \otimes x_2 = x_1(1 + \epsilon) \quad \text{con } |\epsilon| < u$$

Conseguentemente, per verificare se, in aritmetica di macchina, due numeri $x, y \in \mathbb{F}$ sono uguali, bisogna evitare di utilizzare l'uguaglianza logica, ma è bene confrontare i due numeri in termini della loro distanza, ad esempio:

$$|x - y| < tol$$

dove tol è un'accuratezza prefissata, ad esempio $tol = 10 \cdot u$.

3.7 Analisi degli errori

Abbiamo visto che gli errori relativi introdotto in fase di rappresentazione dei numeri reali mediante i numeri di macchina e in fase di elaborazione dei dati mediante le operazioni elementari sono dell'ordine della precisione di macchina. Tuttavia, ciò non garantisce che cambiando le due fasi, l'errore nel risultato di un'operazione sia anch'esso dell'ordine della precisione di macchina. Il seguente esempio chiarisce la questione.

Esempio

Consideriamo $\beta = 10$, $t = 4$ e arrotondamento. Risolvere il seguente problema: *determinare, in $\mathbb{F}$, la differenza dei seguenti numeri reali:*

$$x_1 = 1.23456 \cdot 10^0 \quad x_2 = 1.23456 \cdot 10^0$$

e calcolare l'errore relativo nel risultato.

Osserviamo che $x_1, x_2 \notin \mathbb{F}$. Prima di tutto dovremo rappresentarli in $\mathbb{F}$:

$$fl(x_1) = 1.2346 \cdot 10^0; fl(x_2) = 1.2345 \cdot 10^0$$

Effettuiamo la sottrazione in $\mathbb{F}$:

$$\begin{aligned} fl(x_1) \ominus fl(x_2) &= \frac{1.2346 \cdot 10^0 \ominus 1.2345 \cdot 10^0}{arr(0.0001 \cdot 10^0)} \\ &= arr(1.0000 \cdot 10^{-4}) \\ &= 1.0000 \cdot 10^{-4} \end{aligned}$$

Al fine di valutare l'errore, determiniamo il risultato teorico:

$$x_1 - x_2 = 2 \cdot 10^{-5}$$

Risulta quindi:

$$\begin{aligned} E_r &= \frac{|fl(x_1) \ominus fl(x_2) - (x_1 - x_2)|}{x_1 - x_2} \\ &= \frac{1 \cdot 10^{-4} - 2 \cdot 10^{-5}}{2 \cdot 10^{-5}} \\ &= \frac{10 \cdot 10^{-5} - 2 \cdot 10^{-5}}{2 \cdot 10^{-5}} \\ &= 4 \cdot 10^0 \end{aligned}$$

Il risultato in $\mathbb{F}$ contiene zero cifre significative corrette.

Nota

: In questo esempio, l'unica fonte di errore è quella in fase di rappresentazione: la sottrazione è esatta.

La precisione di macchina è $u = \frac{1}{2} \cdot 10^{-4}$ e, in effetti, $fl(x_1)$ e $fl(x_2)$ contengono 4 cifre significative corrette. Questo piccolo errore si amplifica a seguito della sottrazione portando alla perdita di tutte le cifre significative nel risultato.

3.8 Richiami su vettori e analisi

3.8.1 Prodotto scalare tra due vettori

Consideriamo due vettori di $\mathbb{R}^n$, cioè, insiemi dei vettori ad n componenti. Sia:

$$\underline{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \quad \underline{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

Per convenzione i vettori saranno matrici a una colonna; per riguardarli come vettori riga se ne considererà il trasposto:

$$\underline{x}^T = [x_1, x_2, \dots, x_n]$$

Si definisce il prodotto scalare tra $\underline{x}$ e $\underline{y}$, il seguente numero reale:

$$\begin{aligned} \underline{x}^T \underline{y} &= [x_1, x_2, \dots, x_n] \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \\ &= x_1 y_1 + x_2 y_2 + \dots + x_n y_n \\ &= \sum_{i=1}^n x_i y_i \end{aligned}$$

Geometricamente coincide con:

$$||\underline{x}||_2 \cdot ||\underline{y}||_2 \cdot \cos \alpha$$

dove $||\underline{x}||_2$ e $||\underline{y}||_2$ rappresentano le lunghezze euclidee dei due vettori, mentre α è l'angolo che essi formano.

3.8.2 Derivate parziali

Le derivate parziali sono l'estensione delle derivate classiche al caso di funzioni a più variabili.

Sia $f : \mathbb{R}^n \rightarrow \mathbb{R}$, funzione scalare ad n variabili, ad esempio:

$$f(x_1, x_2) = x_1 + x_2$$

$$f(x_1, x_2) = x_1 \text{ op } x_2$$

$$f(x_1, x_2, x_3) = x_1 \cdot x_2^2 - x_2 \log x_3$$

Si definisce derivata parziale di f rispetto alla variabile x_i , il seguente limite se esiste finito:

$$\frac{\partial f}{\partial x_i} = \lim_{h \rightarrow 0} \frac{f(x_1, \dots, x_i + h, \dots, x_n) - f(x_1, \dots, x_i, \dots, x_n)}{h}$$

cioè è il limite del rapporto incrementale definito sulla variabile x_i e lasciando fisse tutte le altre variabili.

Operativamente, si effettua la derivata rispetto alla variabile x_i assumendo che tutte le altre variabili siano delle costanti.

Esempio

Sia $f(x_1, x_2) = \frac{x_1}{x_2}$.

Allora:

$$\frac{\partial f}{\partial x_1} = \frac{1}{x_2} \quad \frac{\partial f}{\partial x_2} = -\frac{x_1}{x_2^2}$$

Sia $f(x_1, x_2, x_3) = x_1 \cdot x_2^2 - x_2 \log x_3$

Allora:

$$\frac{\partial f}{\partial x_1} = x_2^2 \quad \frac{\partial f}{\partial x_2} = 2x_1x_2 - \log x_3 \quad \frac{\partial f}{\partial x_3} = -\frac{x_2}{x_3}$$

Il vettore contenente le derivate parziali di una funzione si chiama *gradiente*. Esso individua la direzione di massima crescita della funzione. Si denota con il simbolo:

$$\nabla f(\underline{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1}(\underline{x}) \\ \frac{\partial f}{\partial x_2}(\underline{x}) \\ \vdots \\ \frac{\partial f}{\partial x_n}(\underline{x}) \end{bmatrix}$$

Si osservi che, con f , anche:

$$\frac{\partial f}{\partial x_i} : \mathbb{R}^n \rightarrow \mathbb{R}$$

è una funzione scalare.

3.8.3 Sviluppo di Taylor arrestato al primo ordine per funzioni scalari

Ricordiamo che se $f : \mathbb{R} \rightarrow \mathbb{R}$ è sufficientemente regolare, possiamo considerare lo sviluppo di Taylor arrestato al primo ordine in un intorno di x :

$$f(x+h) = f(x) + f'(x) \cdot h + o(h)$$

Per h piccolo, possiamo trascurare $o(h)$ e approssimare f mediante la sua parte lineare:

$$f(x+h) \simeq f(x) + f'(x) \cdot h$$

Stiamo approssimando $f(x)$, in un intorno di x , mediante la retta tangente a f nel punto x .

Generalizziamo al caso di funzioni a più variabili:

$$f : \mathbb{R}^n \rightarrow \mathbb{R}$$

f è una funzione a n variabili $x_1, x_2, \dots, x_n$.

Denoteremo con:

$$\underline{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

Se f è sufficientemente regolare, possiamo considerare lo sviluppo di Taylor arrestato al primo ordine in un intorno di $\underline{x}$:

$$f(\underline{x} + \underline{h}) = f(\underline{x}) + \underline{\nabla}^T f(\underline{x}) \cdot \underline{h} + o(\underline{h})$$

Per $\underline{h}$ piccolo possiamo trascurare $o(\underline{h})$ e scrivere:

$$\begin{aligned} f(\underline{x} + \underline{h}) &\simeq f(\underline{x}) + \underline{\nabla}^T f(\underline{x}) \cdot \underline{h} \\ &= f(\underline{x}) + \sum_{i=1}^n \frac{\partial f}{\partial x_i}(\underline{x}) \cdot h_i \end{aligned}$$

Per $n = 2$, stiamo approssimando la superficie descritta da f mediante il piano tangente ad f nel punto $\underline{x}$.

Ci proponiamo da studiare il seguente problema da generalizzare l'esempio visto sopra.

Traccia

Data una funzione razionale:

$$g : \mathbb{R}^n \rightarrow \mathbb{R}$$

valutare questa funzione in aritmetica di macchina e stimare l'errore che ne risulta.

Facciamo alcune osservazioni.

1. Nel risolvere questo problema sul calcolatore distinguiamo due fasi. Il dato di input, un vettore $\underline{x}$ di dato deve essere rappresentato nella memoria del calcolatore; i dati devono successivamente essere combinati mediante le operazioni descritte dall'espressione di g .
Nella prima fase si generano gli errori di rappresentazione; nella seconda fase si generano gli errori di arrotondamento durante i calcoli.
2. Abbiamo scelto g quale funzione razionale (cioè rapporto di due polinomi) poichè le funzioni razionali sono tutte e sole le funzioni che possono essere valutate mediante una sequenza finita di operazioni elementari.
In effetti tutte le altre funzioni sono approssimate all'interno del calcolatore mediante opportune funzioni razionali. Un esempio di funzione razionale che a noi interesserà è:

$$g(x_1, x_2) = x_1 \text{ op } x_2$$

con op: +, -, *, /

Il seguente diagramma riassume le due fasi descritte sopra.

$$\begin{array}{ccc} \underline{x} \in \mathbb{R}^n & \xrightarrow{g} & g(\underline{x}) \in \mathbb{R} \\ \downarrow \text{ERRORI DI RAPPRESENTAZIONE} & & \\ fl(\underline{x}) = \underline{x} + \Delta \underline{x} \in \mathbb{F}^n & \xrightarrow[\tilde{g}]{\text{ERRORI NEI CALCOLI}} & \tilde{g}(\underline{x} + \Delta \underline{x}) \in \mathbb{F} \end{array}$$

dove $\tilde{g}$ ha la medesima espressione di g con l'unica differenza che le operazioni in essa definite sono operazioni di macchina. Ad esempio:

$$g(x_1, x_2) = \frac{x_1}{x_2} \Rightarrow \tilde{g}(x_1, x_2) = x_1 \bigcirc x_2$$

Osserviamo che:

$$fl(\underline{x}) = \begin{bmatrix} fl(x_1) \\ fl(x_2) \\ \vdots \\ fl(x_n) \end{bmatrix} = \begin{bmatrix} x_1(1 + \epsilon_1) \\ x_2(1 + \epsilon_2) \\ \vdots \\ x_n(1 + \epsilon_n) \end{bmatrix}$$

con $|\epsilon_i| < u$ con $i = 1, \dots, n$

Liberando dalle parentesi e dividendo in due vettori, si ottiene:

$$fl(\underline{x}) = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} + \begin{bmatrix} x_1\epsilon_1 \\ x_2\epsilon_2 \\ \vdots \\ x_n\epsilon_n \end{bmatrix}$$

Introduciamo i seguenti errori.

Errore totale

$$E_{TOT} = \frac{\tilde{g}(\underline{x} + \underline{\Delta x}) - g(\underline{x})}{g(\underline{x})}$$

nell'ipotesi che $g(\underline{x}) \neq 0$. È l'errore nel risultato che tiene conto di entrambe le fonti di errore prima descritte.

Errore inerente

$$E_{IN} = \frac{g(\underline{x} + \underline{\Delta x}) - g(\underline{x})}{g(\underline{x})}$$

È l'errore nel risultato che tiene conto unicamente degli errori di rappresentazione dei dati. In altri termini vengono trascurati gli errori nei calcoli cioè si ritiene che i calcoli vengano eseguiti esattamente.

Errore algoritmico

$$E_{ALG} = \frac{\tilde{g}(\underline{x} + \underline{\Delta x}) - g(\underline{x} + \underline{\Delta x})}{g(\underline{x} + \underline{\Delta x})}$$

È l'errore nel risultato che tiene conto univocamente dagli errori di arrotondamento introdotti dalle operazioni floating-point. Si lavora direttamente su dati

che siano numeri di macchina.
Sussiste la seguente relazione:

$$E_{TOT} = E_{IN} + E_{ALG}(1 + E_{IN})$$

Ne consegue che possiamo studiare indipendentemente i problemi più semplici da stimare E_{IN} e E_{ALG} per poi combinare i risultati e ottenere una stima di E_{TOT} . In particolare:

- se $|E_{IN}| \ll 1$ e $|E_{ALG}| \ll 1$ lo sarà anche l'errore totale. In questo caso:

$$E_{TOT} = E_{IN} + E_{ALG} + E_{ALG} \cdot E_{IN} \simeq E_{IN} + E_{ALG}$$

In questo caso vale il principio di sovrapposizione.

- Se $|E_{IN}| \gg 1$ oppure $|E_{ALG}| \gg 1$ potremo concludere che anche $|E_{TOT}| \gg 1$.

L'errore inerente studia il condizionamento di un problema.
L'errore algoritmico studia la stabilità di un algoritmo.

3.8.4 Condizionamento di un problema

Studiare il condizionamento di un problema significa analizzare in che misura, piccole perturbazioni dei dati di input si riflettono nel risultato (dati di output). In particolare

- un problema si dice ben condizionato se a piccole perturbazioni dei dati di input corrispondono piccole perturbazioni dei dati di output.
- Un problema si dice malcondizionato se a piccole perturbazioni dei dati di input possono corrispondere grandi perturbazioni dei dati di output. L'effetto del malcondizionamento si traduce in una significativa perdita di cifre significative corrette.

3.8.5 Stabilità di un algoritmo

Per uno stesso problema possono esserci più tecniche risolutive, cioè più algoritmi.

- Un algoritmo si dice stabile se la sequenza di operazioni di macchina che lo definisce non amplifica notevolmente l'errore nel risultato a causa dell'accumularsi degli errori di arrotondamento durante i calcoli. Viceversa, un algoritmo si dirà instabile.

Studiamo ora il condizionamento delle operazioni elementari.

3.9 Condizionamento delle operazioni elementari

3.9.1 Addizione

Sia $g(x_1, x_2) = x_1 + x_2$ con $x_1, x_2 > 0$

Per studiare il condizionamento dovremo valutare l'errore inerente. A tal fine riprendiamo lo sviluppo di Taylor arrestato al primo ordine, trascurando gli infinitesimi di ordine superiore:

$$g(\underline{x} + \underline{\Delta x}) \simeq g(\underline{x}) + \underline{\nabla}^T g(\underline{x}) \cdot \underline{\Delta x}$$

da cui:

$$\begin{aligned} E_{IN} &= \frac{g(\underline{x} + \underline{\Delta x}) - g(\underline{x})}{g(\underline{x})} \simeq \frac{1}{g(\underline{x})} \cdot \underline{\nabla}^T g(\underline{x}) \cdot \underline{\Delta x} \\ &= \frac{1}{g(\underline{x})} \sum_{i=1}^n \frac{\partial g}{\partial x_i}(\underline{x}) x_i \epsilon_i \end{aligned}$$

Portando $\frac{1}{g(\underline{x})}$ dentro la somma:

$$E_{IN} \simeq \sum_{i=1}^n \frac{x_i}{g(\underline{x})} \frac{\partial g}{\partial x_i}(\underline{x}) \cdot \epsilon_i$$

Poniamo $k(x_i, g) = \frac{x_i}{g(\underline{x})} \frac{\partial g}{\partial x_i}(\underline{x})$, allora:

$$E_{IN} = \sum_{i=1}^n k(x_i, g) \epsilon_i$$

I coefficienti $k(x_i, g)$ prendono il nome di “numeri di condizionamento” o “coefficienti di amplificazione”. Possiamo concludere che:

- Se $|k(x_i, g)|$ non sono eccessivamente grandi, l'errore inerente sarà piccolo e il problema è ben condizionato.
- viceversa, se $|k(x_i, g)| \gg 1$ per qualche i , $|E_{IN}| \gg 1$ e il problema sarà mal condizionato.

Torniamo all'addizione $g(x_1, x_2) = x_1 + x_2$

$$\begin{aligned}
 E_{IN} &= k(x_1, g)\epsilon_1 + k(x_2, g)\epsilon_2 \\
 &= \frac{x_1}{g(x_1, x_2)} \frac{\partial f}{\partial x_1}(x_1, x_2)\epsilon_1 + \frac{x_2}{g(x_1, x_2)} \frac{\partial g}{\partial x_2}(x_1, x_2)\epsilon_2 \\
 &= \frac{x_1}{x_1 + x_2} \cdot 1 \cdot \epsilon_1 + \frac{x_2}{x_1 + x_2} \cdot 1 \cdot \epsilon_2
 \end{aligned}$$

Passando ai valori assoluti e sfruttando la disuguaglianza triangolare $|a + b| \leq |a| + |b|$:

$$|E_{IN}| \leq \frac{x_1}{x_1 + x_2}u + \frac{x_2}{x_1 + x_2}u = u$$

Quindi, concludendo, l'addizione tra due numero dello stesso segno è sempre ben condizionato. Infatti l'errore inerente è maggiorato dalla precisione di macchina.

3.9.2 Sottrazione

Sia $g(x_1, x_2) = x_1 - x_2$ con $x_1, x_2 > 0$

L'errore inerente è pari a:

$$E_{IN} = \frac{x_1}{x_1 - x_2} \cdot \epsilon_1 + \frac{x_2}{x_1 - x_2} \cdot (-1) \cdot \epsilon_2$$

Non possiamo maggiorare $|k(x_i, g)|$ mediante una quantità indipendente da x_1 e x_2 . In effetti:

$$\lim_{x_2 \rightarrow x_1} |k(x_i, g)| = +\infty$$

Se x_1 e x_2 sono vicini, il problema diventa mal condizionato poichè l' $|E_{IN}|$ diventa grande.

Concludendo, quindi, la sottrazione tra due numeri dello stesso segno è mal condizionato se i due numeri sono molto vicini tra loro. In questo caso si ha il cosiddetto fenomeno di "cancellazione numerica" cioè perdita di cifre significative nel risultato.

3.9.3 Moltiplicazione

Sia $g(x_1, x_2) = x_1 * x_2$ con $x_1, x_2 \neq 0$

L'errore inerente è pari a:

$$E_{IN} = \frac{x_1}{x_1 * x_2} x_2 \epsilon_1 + \frac{x_2}{x_1 * x_2} x_1 \epsilon_2 = \epsilon_1 + \epsilon_2$$

e passando ai valori assoluti:

$$|E_{IN}| \leq |\epsilon_1| + |\epsilon_2| \leq 2u$$

Concludendo, quindi, la moltiplicazione è sempre ben condizionata.

3.9.4 Divisione

Sia $g(x_1, x_2) = \frac{x_1}{x_2}$ con $x_1, x_2 \neq 0$

Si vede che $|E_{IN}| < 2u$ e quindi la divisione tra due numeri non nulli è sempre ben condizionata.

3.10 Stabilità di un algoritmo

Studiamo la stabilità di un algoritmo che effettua la somma di n numeri di macchina positivi.

Dati $x_1, x_2, \dots, x_n \in \mathbb{F}$, determinare la somma in aritmetica di macchina e studiare l'errore algoritmico. Come algoritmo considereremo:

$$\begin{cases} S_1 = x_1 \\ S_i = S_{i-1} + x_i \quad i = 2, \dots, n \end{cases}$$

È chiaro che:

$$S_i = x_1 + x_2 + \dots + x_i$$

e quindi:

$$S_n = \sum_{i=1}^n x_i$$

In aritmetica di macchina avremo:

$$\begin{cases} \tilde{S}_1 = x_1 \\ \tilde{S}_i = \tilde{S}_{i-1} \bigoplus x_i \quad i = 2, \dots, n \end{cases}$$

ovvero:

$$\begin{cases} \tilde{S}_1 = x_1(1 + \epsilon_1) \\ \tilde{S}_i = (\tilde{S}_{i-1} + x_i)(1 + \epsilon_i) \quad i = 2, \dots, n \end{cases}$$

con $\epsilon_1 = 0$ e $|\epsilon_i| < u$ con $i = 2, \dots, n$

Possiamo scrivere

$$\begin{aligned} \tilde{S}_n &= (\tilde{S}_{n-1} + x_n)(1 + \epsilon_n) \\ &= \tilde{S}_{n-1}(1 + \epsilon_n) + x_n(1 + \epsilon_n) \\ &= (\tilde{S}_{n-2} + x_{n-1})(1 + \epsilon_{n-1})(1 + \epsilon_n) + x_n(1 + \epsilon_n) \\ &= \tilde{S}_{n-2}(1 + \epsilon_{n-1})(1 + \epsilon_n) + x_{n-1}(1 + \epsilon_{n-1})(1 + \epsilon_n) + x_n(1 + \epsilon_n) \\ &\vdots \\ \tilde{S}_n &= x_1(1 + \epsilon_1)(1 + \epsilon_2) \cdots (1 + \epsilon_n) + \cdots + x_n(1 + \epsilon_n) \\ &= \sum_{i=1}^n \left(x_i \cdot \prod_{k=i}^n (1 + \epsilon_k) \right) \end{aligned}$$

Studiamo il generico prodotto:

$$\begin{aligned} \prod_{k=1}^n (1 + \epsilon_k) &= (1 + \epsilon_i)(1 + \epsilon_{i+1}) \cdots (1 + \epsilon_n) \\ &= 1 + \sum_{k=i}^n \epsilon_k + o(u) \simeq 1 + \sum_{k=i}^n \epsilon_k \\ &= 1 + \delta_i, \text{ avendo posto } \delta_i = \sum_{k=1}^n \epsilon_k \end{aligned}$$

Possiamo osservare che:

$$\begin{aligned} |\delta_i| &\leq \sum_{k=i}^n |\epsilon_k| \leq u \sum_{k=i}^n 1 \\ &= (n - i + 1)u \leq nu \end{aligned}$$

Introduciamo l'approssimazione δ_i nell'espressione di $\tilde{S}_n$:

$$\tilde{S}_n = \sum_{i=1}^n x_i(1 + \delta_i) = \underbrace{\sum_{i=1}^n x_i}_{S_n} + \sum_{i=1}^n x_i \delta_i$$

da cui:

$$E_{ALG} = \frac{\tilde{S}_n - S_n}{S_n} = \frac{1}{S_n} \sum_{i=1}^n x_i \delta_i$$

Passando ai valori assoluti

$$|E_{ALG}| \leq \frac{1}{S_n} \sum_{i=1}^n x_i |\delta_i| \leq nu$$

Concludendo, quindi, l'errore cresce al più linearmente rispetto ad n e quindi l'algoritmo è stabile.

In generale, per un algoritmo generico, se l'errore algoritmico è maggiorato da un'espressione della forma

$$|E_{ALG}| \leq p(n)u$$

dove n indica la dimensione del problema da risolvere e $p(n)$ denota un polinomio in n , l'algoritmo può ritenersi stabile se il grado di $p(n)$ è basso, ad esempio 1, 2, 3.

Capitolo 4

Matrici e sistemi lineari

DEFINIZIONE 4.1: MATRICE REALE

Dati due interi positivi m ed n , una matrice A reale $m \times n$ è un array bidimensionale avente m righe ed n colonne così definito:

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & \cdots & a_{2n} \\ \vdots & \vdots & & & \vdots \\ a_{m1} & a_{m2} & \cdots & \cdots & a_{mn} \end{pmatrix}$$

Più formalmente possiamo dire che una matrice è un'applicazione

$$A : \{1, 2, \dots, m\} \times \{1, 2, \dots, n\} \rightarrow \mathbb{R}$$

tale che $A(i, j) = a_{ij} \in \mathbb{R}$.

Una matrice verrà solitamente denotata con le lettere minuscole, ad esempio la scrittura:

$$A = \{a_{ij}\} \text{ ovvero } A = \{a_{ij} \mid i = 1, \dots, m \quad j = 1, \dots, n\}$$

denoterà una matrice ad m righe ed n colonne il cui generico elemento è a_{ij} . Denotiamo con $\mathbb{R}^{m \times n}$ l'insieme delle matrici con m righe ed n colonne. Analizziamo alcuni casi.

1. Se $m = n$, la matrice è detta *quadrata* di dimensione n , altrimenti è detta *rettangolare*.

2. Se $m = n = 1$, la matrice si riduce ad un unico elemento e dunque coincide con uno scalare: $A = (a_{11})$
3. Se $m = 1$, la matrice possiede un'unica riga, pertanto si riduce ad un vettore riga: $A = (a_{11} \ a_{12} \ \cdots \ a_{1n})$
4. Se $n = 1$, la matrice possiede un'unica colonna, pertanto si riduce ad un vettore colonna:

$$A = \begin{pmatrix} a_{11} \\ a_{21} \\ \vdots \\ a_{m1} \end{pmatrix} \equiv (a_{11} \ a_{21} \ \cdots \ a_{m1})^T$$

5. La matrice $m \times n$ i cui elementi sono tutti nulli si chiama matrice nulla e si denota con $0_{m \times n}$ o più semplicemente con 0.
6. Si chiama diagonale principale di una matrice quadrata di dimensione n , il vettore:

$$\text{diag}(A) = (a_{11} \ a_{21} \ \cdots \ a_{nn})^T$$

7. Si chiama matrice identica, ogni matrice quadrata aventi elementi diagonali uguali ad 1 ed elementi extra-diagonali nulli:

$$I = \begin{pmatrix} 1 & 0 & \cdots & \cdots & 0 \\ 0 & 1 & \cdots & \cdots & 0 \\ \vdots & \vdots & & & \vdots \\ 0 & 0 & \cdots & \cdots & 1 \end{pmatrix}$$

Vediamo alcune proprietà delle matrici quadrate.

1. Una matrice quadrata è diagonale se tutti i suoi elementi extra-diagonali sono nulli:

$$a_{ij} = 0, \forall i, j = 1, \dots, n \text{ con } i \neq j$$

2. Una matrice quadrata è triangolare inferiore se tutti i suoi elementi al di sopra della diagonale principale sono nulli:

$$a_{ij} = 0 \quad \forall i < j$$

3. Una matrice quadrata è triangolare superiore se tutti i suoi elementi al di sotto della diagonale principale sono nulli:

$$a_{ij} = 0 \quad \forall i > j$$

4.1 Operazioni tra matrici

4.1.1 Addizione

DEFINIZIONE 4.2: ADDIZIONE TRA MATRICI

Se $A = \{a_{ij}\}$ e $B = \{b_{ij}\}$ sono matrici $m \times n$ si definisce somma tra A e B la matrice

$$A + B = \{a_{ij} + b_{ij}\} \in \mathbb{R}^{m \times n}$$

Si osservi che:

$$+ : \mathbb{R}^{m \times n} \times \mathbb{R}^{m \times n} \rightarrow \mathbb{R}^{m \times n}$$

Vediamo alcune proprietà dell'addizione.

1. **Commutativa:** $\forall A, B \in \mathbb{R}^{m \times n}$:

$$A + B = B + A$$

2. **Associatività:** $\forall A, B, C \in \mathbb{R}^{m \times n}$

$$(A + B) + C = A + (B + C)$$

3. **Esistenza dell'elemento neutro:** $\forall A \in \mathbb{R}^{m \times n}$:

$$A + 0 = 0 + A = A$$

4. **Esistenza del simmetrico:** $\forall A \in \mathbb{R}^{m \times n} \exists B \in \mathbb{R}^{m \times n} \mid A + B = 0$.

L'opposto di A si denota con $-A$.

Nota

Il gruppo $(\mathbb{R}^{m \times n}, +)$ è un gruppo abeliano.

4.1.2 Moltiplicazione di uno scalare per una matrice

DEFINIZIONE 4.3: MOLTIPLICAZIONE DI UNO SCALARE PER UNA MATRICE

Se $A = \{a_{ij}\} \in \mathbb{R}^{m \times n}$ e $\lambda \in \mathbb{R}$, si definisce prodotto di λ per A la matrice:

$$\lambda \cdot A = \{\lambda a_{ij}\} \in \mathbb{R}^{m \times n}$$

L'applicazione:

$$\cdot : \mathbb{R} \times \mathbb{R}^{m \times n} \rightarrow \mathbb{R}^{m \times n}$$

■ è una legge di composizione esterna.

Elenchiamone alcune proprietà.

Per ogni $\lambda, \mu \in \mathbb{R}$ e $\forall A, B \in \mathbb{R}^{m \times n}$ risulta:

1. $\lambda \cdot (\mu \cdot A) = (\lambda\mu) \cdot A$;
2. $(\lambda + \mu) \cdot A = \lambda \cdot A + \mu \cdot A$;
3. $\lambda \cdot (A + B) = \lambda \cdot A + \lambda \cdot B$;
4. $1 \cdot A = A$

Per semplicità si scriverà λA in luogo di $\lambda \cdot A$.

4.1.3 Trasposta di una matrice

Se $A \in \mathbb{R}^{m \times n}$, la trasposta di A , denotata con A^T , è la matrice ottenuta da A scambiando le righe con le colonne, ovvero:

$$A^T = \{a_{ji}\} \quad i = 1, \dots, m \quad j = 1, \dots, n$$

Pertanto $A^T \in \mathbb{R}^{n \times m}$.

4.1.4 Sottomatrici o matrici estratte

Se $A = \{a_{ij}\} \in \mathbb{R}^{m \times n}$, una sottomatrice di A è una matrice ottenuta sopprimendo in A un certo numero di righe e di colonne.

Esempio

Considerata $A = \begin{pmatrix} 1 & 2 & 3 & 0 & 1 \\ -1 & 0 & 1 & -1 & -2 \\ \frac{2}{3} & 1 & -2 & 2 & -1 \end{pmatrix}$ sono sottomatrici di A :

$$B = (-2), C = \begin{pmatrix} 1 & 2 \\ -1 & 0 \end{pmatrix}, E = \begin{pmatrix} 3 \\ 1 \\ \frac{2}{3} \end{pmatrix}, G = A, H = ()$$

DEFINIZIONE 4.4: SOTTOMATRICE PRINCIPALE

Si chiama *sottomatrice principale* di una matrice A una sottomatrice di A i cui elementi diagonali sono anche elementi diagonali di A .

Esempio

$$\text{Se } A = \begin{pmatrix} 1 & 2 & 3 & 0 & 1 \\ -1 & 0 & 1 & -1 & -2 \\ 2/3 & 1 & -2 & 2 & -1 \\ -1 & -1/4 & 1/2 & 0 & -1 \end{pmatrix},$$

$$B = \begin{pmatrix} 1 & 3 & 0 \\ 2/3 & -2 & 2 \\ -1 & 1/2 & 0 \end{pmatrix}$$

è ottenuta da A considerando la prima, terza e quarta riga e la prima, terza e quarta colonna di A .

DEFINIZIONE 4.5: SOTTOMATRICI PRINCIPALI DI TESTA

Si chiama *sottomatrice principale di testa* di A di ordine k una sottomatrice di A ottenuta considerando le prime k righe e colonne di A .

Esempio

$$\text{Se } A = \begin{pmatrix} 1 & 2 & 3 & 0 & 1 \\ -1 & 0 & 1 & -1 & -2 \\ 2/3 & 1 & -2 & 2 & -1 \\ -1 & -1/4 & 1/2 & 0 & -1 \end{pmatrix},$$

$$B = \begin{pmatrix} 1 & 2 & 3 \\ -1 & 0 & 1 \\ \frac{2}{3} & 1 & -2 \end{pmatrix}$$

è la sottomatrice principale di testa di A di ordine 3.

4.1.5 Partizionamento di matrici

DEFINIZIONE 4.6: PARTIZIONAMENTO DI MATRICI

Una matrice A si dice *partizionata* se è riguardata in termini di sue sottomatrici, dette **blocchi** di A .

Esempio

$$\text{Se } A = \left(\begin{array}{cc|c} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ \hline a_{31} & a_{32} & a_{33} \end{array} \right), \quad e$$

$$A_{11} = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix},$$

$$A_{12} = \begin{pmatrix} a_{13} \\ a_{23} \end{pmatrix},$$

$$A_{21} = \begin{pmatrix} a_{31} & a_{32} \end{pmatrix},$$

$$A_{22} = \begin{pmatrix} a_{33} \end{pmatrix}.$$

possiamo allora scrivere $A = \begin{pmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{pmatrix}$.

Esistono due tipologie di partizionamento:

- **Partizionamento per righe.** Se $A \in \mathbb{R}^{m \times n}$ e denotiamo con $\mathbf{a}_1^T, \mathbf{a}_2^T, \dots, \mathbf{a}_m^T$ le righe di A , potremo scrivere:

$$A = \begin{pmatrix} \mathbf{a}_1^T \\ \mathbf{a}_2^T \\ \vdots \\ \mathbf{a}_m^T \end{pmatrix}$$

- **Partizionamento per colonne.** Se $B \in \mathbb{R}^{m \times n}$ e denotiamo con $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n$ le colonne di A , potremo scrivere:

$$A = (\mathbf{a}_1 \quad \mathbf{a}_2 \quad \dots \quad \mathbf{a}_n)$$

4.1.6 Prodotto di matrici

Ricordiamo che se $\mathbf{a}$ e $\mathbf{b}$ sono due vettori di lunghezza n , il prodotto scalare di $\mathbf{a}$ e $\mathbf{b}$ denotato con $\mathbf{a}^T \mathbf{b}$ è così definito:

$$\mathbf{a}^T \mathbf{b} = \sum_{k=1}^n a_k b_k$$

DEFINIZIONE 4.7: PRODOTTO DI MATRICI

Siano $A \in \mathbb{R}^{m \times p}$ e $B \in \mathbb{R}^{p \times n}$. Si definisce *prodotto* (righe per colonne) tra A e B la matrice $C = A \cdot B \in \mathbb{R}^{m \times n}$ il cui elemento generico c_{ij} è il prodotto scalare tra la riga i -esima di A e la colonna j -esima di B :

$$c_{ij} = \mathbf{a}_i^T \mathbf{b}_j = \sum_{k=1}^p a_{ik} b_{kj} \quad i = 1, \dots, m \quad j = 1, \dots, n$$

ove $\mathbf{a}_i^T$ è la i -esima riga di A e $\mathbf{b}_j$ è la j -esima riga di B .

Nota

Il prodotto tra due matrici è possibile solo se il numero di colonne del primo fattore coincide col il numero di righe del secondo fattore.

Dunque, se A e B sono quadrate dello stesso ordine, $A \cdot B$ e $B \cdot A$ sono ben definite, tuttavia, in generale A e B non sono permutabili cioè, in generale, $A \cdot B \neq B \cdot A$

Ne segue che la moltiplicazione tra matrici **non** è commutativa.

Proprietà della moltiplicazione di matrici quadrate L'operazione di moltiplicazione tra matrici quadrate è la seguente:

$$\cdot : \mathbb{R}^{n \times n} \times \mathbb{R}^{n \times n} \rightarrow \mathbb{R}^{n \times n}$$

è una legge di composizione interna su $\mathbb{R}^{n \times n}$ che verifica le seguenti proprietà:

- **Associatività:** $(A \cdot B) \cdot C = A \cdot (B \cdot C)$
- **Esistenza dell'elemento neutro:** $A \cdot I = I \cdot A = A$
- **Esistenza dell'elemento assorbente:** $A \cdot 0 = 0 \cdot A = 0$
- **Distributività a sinistra:** $A \cdot (B + C) = A \cdot B + A \cdot C$
- **Distributività a destra:** $(A + B) \cdot C = A \cdot C + B \cdot C$
- $\lambda(A \cdot B) = (\lambda A)B = A(\lambda B)$
- $(A \cdot B)^T = B^T \cdot A^T$

Nota

La terna $(\mathbb{R}^{n \times n}, +, \cdot)$ è un anello unitario non commutativo.

4.1.7 Inversa di una matrice quadrata

DEFINIZIONE 4.8: MATRICE INVERSA

Una matrice quadrata $A \in \mathbb{R}^{n \times n}$ si dice *invertibile* se esiste $B \in \mathbb{R}^{n \times n}$ tale che:

$$AB = I = BA$$

l'inversa di A , se esiste, è denotata con A^{-1} .

Nota

L'inversa di una matrice, se esiste, è unica. Infatti, se:

$$AB = I = BA \quad \text{e} \quad AC = I = CA$$

segue che:

$$B = IB = (CA)B = C(AB) = CI = C$$

Se A è invertibile, $(A^{-1})^{-1} = A$.

4.1.8 Determinante di una matrice quadrata

Se $A = \{a_{ij}\} \in \mathbb{R}^{n \times n}$, denotiamo con A_{ij} la sottomatrice quadrata di A di dimensione $n - 1$ ottenuta da A sopprimendone la i -esima riga e la j -esima colonna.

DEFINIZIONE 4.9: DETERMINANTE DI UNA MATRICE

Si definisce *determinante* di A e lo si denota con $\det(A)$ il seguente scalare:

$$\det(A) = \begin{cases} a_{11}, & \text{se } n = 1 \\ \sum_{j=1}^n (-1)^{j+1} a_{1j} \det(A_{1j}) & \text{se } n > 1 \end{cases}$$

Nota

La definizione appena data va sotto il nome di *regola di Laplace* per il calcolo del determinante. In letteratura esistono diverse altre definizioni equivalenti. Il vantaggio da quella noi adottata è che essa induce in maniera naturale ad un semplice algoritmo ricorsivo.

Il determinante di una matrice quadrata $A = \{a_{ij}\} \in \mathbb{R}^{n \times n}$, può essere equivalentemente calcolato mediante una delle seguenti formule che generalizzano quella precedentemente data:

- **Sviluppo lungo la riga i -esima:**

$$\det(A) = \sum_{j=1}^n (-1)^{i+j} a_{ij} \det(A_{ij}) \quad (n > 1)$$

- **Sviluppo lungo la colonna j -esima:**

$$\det(A) = \sum_{i=1}^n (-1)^{i+j} a_{ij} \det(A_{ij}) \quad (n > 1)$$

Nota

La quantità $(-1)^{i+j} \det(A_{ij})$ prende il nome di *complemento algebrico* dell'elemento a_{ij} .

Teorema 4.1: Secondo teorema di Laplace

La somma dei prodotti degli elementi di una riga (colonna) per i complementi algebrici di un'altra riga (colonna) è nulla, cioè:

$$\sum_{j=1}^n (-1)^{k+j} a_{ij} \det(A_{kj}) = 0 \quad \forall i \neq k$$

ovvero

$$\sum_{i=1}^n (-1)^{i+k} a_{ij} \det(A_{ik}) = 0 \quad \forall j \neq k$$

Proprietà del determinante

- $\det(A^T) = \det(A)$
- $\det(A) = 0$ se:
 - gli elementi di una riga sono tutti nulli;
 - esistono due righe di A che sono uguali;
 - esiste una riga di A che è una combinazione lineare di altre righe (vale anche il viceversa).
- Aggiungendo ad una riga una combinazione lineare di altre righe, si ottiene una nuova matrice il cui determinante coincide con quello di A .

Nota

Una *combinazione lineare* tra vettori $\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_k$ è una somma della forma:

$$c_1 \mathbf{a}_1 + c_2 \mathbf{a}_2 + \dots + c_k \mathbf{a}_k$$

- Se per la i -esima riga di A risulta $a_{ij} = b_{ij} + c_{ij}$, dette B e C le matrici che si ottengono sostituendo in A la i -esima riga con $[b_{i1}, \dots, b_{in}]$ e $[c_{i1}, \dots, c_{in}]$ risulta:

$$\det(A) = \det(B) + \det(C)$$

- Se B è ottenuta da A scambiando due sue righe, risulta $\det(B) = -\det(A)$

- Se B è ottenuta da A moltiplicandone gli elementi di una riga per uno scalare α , risulta $\det(B) = \alpha \det(A)$
- Se A e B sono quadrate dello stesso ordine, $\det(AB) = \det(A)\det(B)$
In particolare, se A è invertibile, $\det(A^{-1}) = \frac{1}{\det(A)}$
- Poichè $\det(A^T) = \det(A)$, le precedenti proprietà continuano a valere se riferite alle colonne piuttosto che alle righe di A .
- $\det(\alpha A) = \alpha^n \det(A)$
- Se A è una matrice triangolare, allora:

$$\det(A) = \prod_{i=1}^n a_{ii}$$

cioè il determinante di A è il prodotto dei suoi elementi diagonali. In particolare se I è la matrice identica, risulta $\det(I) = 1$

Esistenza dell'inversa Una matrice quadrata A si dice non singolare se $\det(A) \neq 0$. Si definisce matrice aggiunta di A e si denota con $agg(A)$, la trasposta della matrice dei componenti algebrici di A :

$$[agg(A)]_{ij} = \{(-1)^{i+j} \det(A_{ij})\}^T = \{(-1)^{i+j} \det(A_{ji})\}$$

Teorema 4.2

A è invertibile $(\exists A^{-1}) \iff A$ non è singolare $(\det(A) \neq 0)$

Inoltre risulta:

$$A^{-1} = \frac{1}{\det(A)} agg(A)$$

Dimostrazione. Posto $B = \frac{1}{\det(A)} agg(A)$, sarà sufficiente provare che $C = AB = I$. Gli elementi di C sono:

$$c_{ij} = \frac{1}{\det(A)} (a_{i1}(-1)^{j+1} \det(A_{j1}) + a_{i2}(-1)^{j+2} \det(A_{j2}) + \dots + a_{in}(-1)^{j+n} \det(A_{jn}))$$

Distinguiamo due casi:

1. per $i = j$, per la regola di Laplace:

$$c_{ii} = \frac{1}{\det(A)} \det(A)$$

2. per $i \neq j$, per il secondo teorema di Laplace, segue che:

$$c_{ij} = 0$$

□

4.2 Sistema lineari di n equazioni in n incognite

Un sistema lineare di n equazioni in n incognite ha la seguente forma:

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1 \\ \vdots &\vdots \\ a_{i1}x_1 + a_{i2}x_2 + \cdots + a_{in}x_n &= b_i \\ \vdots &\vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n &= b_n \end{cases} \quad (4.1)$$

La matrice $A = \{a_{ij}\}$ prende il nome di *matrice dei coefficienti*. Il vettore $\mathbf{x} = [x_1, x_2, \dots, x_n]^T$ prende il nome di *vettore delle incognite*. Il vettore $\mathbf{b} = [b_1, b_2, \dots, b_n]^T$ prende il nome di *vettore dei termini noti*.

Il sistema lineare sopra riportato può scriversi come:

$$A\mathbf{x} = \mathbf{b}$$

4.2.1 Soluzione di un sistema lineare

Consideriamo il sistema lineare:

$$A\mathbf{x} = \mathbf{b}$$

Se supponiamo che la matrice dei coefficienti A non è singolare, allora A sarà invertibile: moltiplicando ambo i membri a sinistra per A^{-1} otteniamo:

$$\mathbf{x} = A^{-1}\mathbf{b}$$

dunque possiamo concludere che:

Teorema 4.3

Se la matrice dei coefficienti di un sistema lineare di n equazioni in n incognite è non singolare, il sistema lineare ammette una ed una sola soluzione (vale anche il viceversa).

Metodo di Cramer Da:

$$\mathbf{x} = A^{-1}\mathbf{b} = \frac{1}{\det(A)} \text{agg}(A)\mathbf{b}$$

eguagliando le i -esime componenti dei due vettori ad ambo i membri si ha:

$$x_i = \frac{1}{\det(A)} ((-1)^{i+1} b_1 \det(A_{1i}) + \dots + (-1)^{i+n} b_n \det(A_{ni}))$$

Detta A_i la matrice che si ottiene sostituendo in A la i -esima colonna con il vettore dei termini noti, si riconosce immediatamente che:

$$x_i = \frac{\det(A_i)}{\det(A)} \quad i = 1, \dots, n$$

4.3 Sistemi triangolari

DEFINIZIONE 4.10: SISTEMA TRIANGOLARE

Un sistema lineare si dice *triangolare* se la matrice dei coefficienti è triangolare.

I sistemi triangolari si risolvono facilmente mediante gli algoritmi di sostituzione all'indietro, se triangolare superiore, e in avanti, se triangolare inferiore.

4.3.1 Sistemi triangolari superiori

Un sistema triangolare superiore si presenta nella seguente forma:

$$\left\{ \begin{array}{l} a_{11}x_1 + a_{12}x_2 + \dots + \dots + a_{1n}x_n = b_1 \\ \quad a_{22}x_2 + \dots + \dots + a_{2n}x_n = b_2 \\ \qquad \qquad \ddots \qquad \qquad \qquad \vdots \qquad \vdots \\ \qquad \qquad \qquad a_{ii}x_i + a_{in}x_n = b_i \\ \qquad \qquad \qquad \qquad \ddots \qquad \vdots \\ \qquad \qquad \qquad \qquad \qquad a_{nn}x_n = b_n \end{array} \right.$$

Consideriamo la seguente ipotesi di lavoro:

$$\det(A) \neq 0$$

Nota

Essendo A triangolare superiore, il determinante è pari a:

$$\det(A) = a_{11} \cdot a_{22} \cdots a_{nn}$$

Quindi

$$\det(A) \neq 0 \iff a_{ii} \neq 0 \quad i = 1, \dots, n$$

Cioè gli elementi diagonali sono non nulli.

Per risolvere questo sistema, cominciamo con l'osservare che l'ultima equazione contiene la sola incognita x_n . Dunque ricaviamo:

$$x_n = \frac{b_n}{a_n}$$

Osserviamo poi che la penultima equazione è:

$$a_{n-1,n-1}x_{n-1} + a_{n-1,n}x_n = b_{n-1}$$

Essendo x_n nota, quest'equazione conterrà la sola incognita x_{n-1} . Quindi ricaviamo:

$$x_{n-1} = \frac{b_{n-1} - a_{n-1,n}x_n}{a_{n-1,n-1}}$$

Si procede a ritroso. Dalla i -esima equazione $a_{ii}x_i + a_{i,i+1}x_{i+1} + \cdots + a_{in}x_n = b_i$ avendo già calcolato $x_{i+1}, x_{i+2}, \dots, x_n$. Ricaviamo:

$$x_i = \frac{b_i - \sum_{j=i+1}^n a_{ij}x_j}{a_{ii}}$$

Quindi, l'**algoritmo di sostituzione all'indietro** è il seguente. Per $i = n, \dots, 1$ otteniamo:

$$x_i = \frac{b_i - \sum_{j=i+1}^n a_{ij}x_j}{a_{ii}}$$

Costo computazionale Fissiamo l'indice i :

molt / div. $n - i + 1$

add / sottr $n - i$

Consegue che:

$$\begin{aligned}
C_{m/d} &= \sum_{i=1}^n (n - i + 1) \\
&= \sum_{k=n-i+1}^n k \\
&= \frac{n(n+1)}{2} \\
&= \frac{n^2}{2} + \frac{n}{2} = \frac{n^2}{2} + O(n)
\end{aligned}$$

ove $O(n)$ può essere trascurato per n grande.

Consideriamo la seguente notazione.

$O(n^p)$ denota un polinomio di grado al più p in n

Calcoliamo il costo delle addizioni/sottrazioni.

$$C_{a/2} = \sum_{i=1}^n (n - i) = \frac{n^2}{2} + O(n)$$

Quindi il costo totale è:

$$C_{TOT} = n^2 + O(n) \text{ floating point operations}$$

4.3.2 Algoritmo di sostituzione in avanti

Questo algoritmo viene applicato per la risoluzione di un sistema triangolare inferiore.

$$\begin{cases}
a_{11}x_1 = b_1 \\
\vdots \quad \ddots \\
a_{i1}x_1 + \cdots + a_{ii}x_i = b_i \\
\vdots \quad \ddots \\
a_{n1}x_1 + \cdots + a_{nn}x_n = b_n
\end{cases}$$

Per $i = 1, \dots, n$ la soluzione di un'incognita è data da:

$$x_i = \frac{b_i - \sum_{j=1}^{i-1} a_{ij}x_j}{a_{ii}}$$

Ove il costo computazionale totale è:

$$C_{TOT} = n^2 + O(n) \text{ floating point operations}$$

4.3.3 Proprietà delle matrici triangolari

Siano A e B due matrici triangolari inferiori. Valgono le seguenti proprietà.

- $A \cdot B$ è triangolare inferiore.
- Se A è invertibile ($a_{ii} \neq 0, \forall i = 1, \dots, n$) allora A^{-1} è triangolare inferiore.

Nota

In altre parole, l'insieme delle matrici triangolari inferiori è chiuso rispetto alle operazioni di moltiplicazione e di inversione.

DEFINIZIONE 4.11: MATRICE TRIANGOLARE SPECIALE

Una matrice triangolare si dice *speciale* se i suoi elementi diagonali sono uguali a 1.

Naturalmente il suo determinante sarà pari a 1.

Le proprietà sopra elencate si estendono a:

- matrici triangolari superiori;
- matrici triangolari speciali.

Ricordiamo un'ulteriore proprietà che riguarda l'inversa di un prodotto.

- Siano A e B due matrici quadrate invertibili. Allora il loro prodotto è ancora invertibile e risulta:

$$(AB)^{-1} = B^{-1}A^{-1}$$

Inoltre:

$$\det(AB) = \det(A)\det(B)$$

4.4 Fattorizzazione LU di una matrice

DEFINIZIONE 4.12: MATRICE FATTORIZZABILE IN FORMA LU

Una matrice quadrata A di dimensione n si dice *fattorizzabile in forma LU*, se

possiamo riguardare A come prodotto di due matrici;

$$A = L \cdot U$$

ove:

- L è una matrice triangolare inferiore speciale;
- U è una matrice triangolare superiore.

Cominciamo col discutere l'unicità della fattorizzazione LU.

PROPOSIZIONE 4.1 – «UNICITÀ DELLA FATTORIZZAZIONE LU»

Sia A una matrice quadrata invertibile. Allora, se A è fattorizzabile in forma LU, la fattorizzazione è unica.

Dimostrazione. Siano:

$$A = L_1 \cdot U_1 = L_2 \cdot U_2$$

due fattorizzazioni LU di A . Vogliamo provare che:

$$L_1 = L_2 \text{ e } U_1 = U_2$$

Da $L_1 \cdot U_1 = L_2 \cdot U_2$ premoltiplichiamo ambo i membri per L_1^{-1}

$$\underbrace{L_1^{-1} \cdot L_1}_{\text{matrice identica}} \cdot U_1 = L_1^{-1} \cdot L_2 \cdot U_2$$

Per ipotesi $\det(A) \neq 0$. Ma:

$$0 \neq \det(A) = \begin{cases} \det(L_1 \cdot U_1) = \det(U_1) \\ \det(L_2 \cdot U_2) = \det(U_2) \end{cases}$$

Quindi U_2 è invertibile. Moltiplicando a destra per U_2^{-1} otteniamo:

$$U_1 \cdot U_2^{-1} = L_1^{-1} L_2$$

Per le proprietà viste in precedenza:

U_2^{-1} è triangolare superiore

$U_1 \cdot U_2^{-1}$ è triangolare superiore

L_1^{-1} è triangolare inferiore speciale

$L_1^{-1} L_2$ è triangolare inferiore speciale

In definitiva, al primo membro abbiamo una triangolare superiore, mentre, al secondo membro, una triangolare inferiore speciale.

Graficamente:

$$U_1 \cdot U_2^{-1} = L_1^{-1} \cdot L_2$$

(Fare grafico)

Ne consegue che i due membri dovranno necessariamente coincidere con la matrice identica:

$$U_1 U_2^{-1} = I \Rightarrow U_1 U_2^{-1} \cdot U_2 = I \cdot U_2 \Rightarrow U_1 = U_2$$

$$L_1^{-1} L_2 = I \Rightarrow L_1 \cdot L_1^{-1} L_2 = L_1 I \Rightarrow L_1 = L_2$$

□

Per poter provare l'esistenza, faremo uso delle “matrici elementari di Gauss”.