Ingegneria della conoscenza

Alessandro Carella

Indice

1. Ingegneria della conoscenza 7
   - 1.1. Sistemi intelligenti basati su Conoscenza 7
   - 1.2. Dimensioni dello spazio di progettazione 8
     - 1.2.1. Modularità 9
     - 1.2.2. Schema di Rappresentazione 9
   - 1.3. Progettazione si Sistemi Intelligenti 14
     - 1.3.1. Semplificazione di Ambienti e Sistemi 14
     - 1.3.2. Compiti e Problemi 14
     - 1.3.3. Rappresentazione interna 14
   - 1.4. Soluzioni 15
     - 1.4.1. Modelli: Livelli di Astrazione 15
   - 1.5. Sistemi Intelligenti basati su Conoscenza 16
   - 1.6. Domini applicativi 17
2. Ricerca di soluzioni in spazi di stati 17
   - 2.1. Risoluzione di problemi mediante ricerca 17
   - 2.2. Spazi di stati 18
   - 2.3. Ricerca su Grafo 20
   - 2.4. Algoritmo di ricerca generico 21
   - 2.5. Strategie di ricerca non informate 23
     - 2.5.1. Ricerca in ampiezza 23
     - 2.5.2. Ricerca in profondità 24
     - 2.5.3. Approfondimento iterativo 25
     - 2.5.4. Ricerca di soluzioni a costo minimo 26
   - 2.6. Ricerca Informata (Euristica) 27
     - 2.6.1. Euristica 27
     - 2.6.2. DFS Euristica e Greedy best-First Search 28
     - 2.6.3. Ricerca A^* 28
     - 2.6.4. Algoritmo Branch and Bound 30
     - 2.6.5. Progettazione della funzione Euristica 32
   - 2.7. Potatura dello Spazio di Ricerca 33
     - 2.7.1. Potatura dei Cicli 33
     - 2.7.2. Potatura di Percorsi Multipli 33
     - 2.7.3. Consuntiva sulle Strategie di Ricerca 36
   - 2.8. Strategia di Ricerca più sofisticate 36
     - 2.8.1. Direzione della ricerca 36
     - 2.8.2. Ricerca bidirezionale 36

2.8.3. Ricerca in una gerarchia di astrazioni 37
2.8.4. Uso della programmazione dinamica 37
3. Ragionamento con vincoli 38
3.1. Variabili e vincoli 38
3.1.1. Variabili e Assegnazioni 39
3.1.2. Vincoli 39
3.1.3. Problema di soddisfacimento di vincoli 40
3.2. Risoluzione di CSP tramite ricerca 41
3.2.1. Algoritmi su Grafo di Ricerca 41
3.3. Algoritmi basati su Consistenza 42
3.4. Separazione dei domini 43
3.5. Eliminazione di Variabili 45
3.6. Ricerca Locale 47
3.6.1. Miglioramento Iterativo 48
3.6.2. Algoritmi stocastici 49
3.7. Varianti della ricerca Locale 50
3.7.1. Tabu Search 50
3.7.2. Passo di Massimo Miglioramento 50
3.7.3. Scelta a due fasi 51
3.7.4. Algoritmo Any-Conflict 51
3.7.5. Simulated Annealing 51
3.7.6. Ripartenza casuale 53
3.8. Algoritmi basati su popolazioni 53
3.9. Beam Search 53
3.9.1. Beam Search Stocastica 54
3.9.2. Algoritmi Genetici 54
3.10. Ottimizzazione 56
3.10.1. Metodi Sistematici per il Caso Discreto 56
3.10.2. Ricerca locale per l'ottimizzazione 57
3.10.3. Domini Continui: Discesa di Gradiente 57
4. Rappresentazione e Ragionamentoi Proposizionale 58
4.1. Proposizioni 58
4.1.1. Sintassi del Calcolo Proposizionale 58
4.1.2. Semantica del Calcolo Proposizionale 59
4.1.3. Semantica: punto di vista del progettista 61
4.1.4. Semantica: Punto di vista della Macchina 61
4.2. Vincoli Proposizionali 62
4.2.1. Forma Clausale per CSP 62
4.3. Clausole Definite Proposizionali 63
4.3.1. Domande e Risposte 65

4.3.2. Dimostrazioni ... 66
4.3.3. Procedura Bottom-Up ... 66
4.3.4. Procedura Top-Down ... 68
4.4. Interrogare l'utente ... 72
4.5. Debugging a Livello di Conoscenza ... 73
4.5.1. Risposte Errate ... 73
4.5.2. Risposte mancanti ... 74
4.6. Dimostrazione per Contraddizione ... 74
4.6.1. Clausole di Horn ... 74
4.6.2. Assumibili e Conflitti ... 75
4.6.3. Diagnosi basata sulla consistenza ... 76
4.6.4. Ragionamento con Assunzioni e Clausole di Horn ... 77
4.7. Assunzione di Conoscenza Completa ... 79
4.7.1. Ragionamento Non Monotono ... 82
4.7.2. Procedure di Dimostrazione per la NAF ... 82
4.8. Abduzione ... 85
5. Rappresentazione e Ragionamento Relazionale ... 87
5.1. Simboli e Semantica ... 88
5.2. Calcolo dei Predicati ... 88
5.2.1. Sematica delle formule logiche di base ... 89
5.2.2. Semantica: Interpretazione delle Variabili ... 89
5.2.3. Semantica: la Prospettiva Umana ... 90
5.3. Datalog: Linguaggio Relazione a Regole ... 91
5.4. Sostituzioni e Dimostrazioni ... 94
5.4.1. Istanze e Sostituzioni ... 94
5.4.2. Procedura Bottom-up con Variabili ... 96
5.4.3. Unificazione ... 97
5.4.4. Risoluzione Definita con Variabili ... 98
5.5. Simboli di Funzione e Strutture dati ... 101
5.5.1. Procedure di Dimostrazioni con Funzioni ... 103
5.6. Uguaglianza ... 105
5.6.1. Ammettere Asserzioni d'Uguaglianza ... 106
5.6.2. Unique Names Assumption ... 106
5.7. Assunzione di Conoscenza Completa ... 106
6. Knowledge Graph e Ontologie ... 110
6.1. Knowledge Graph ... 110
6.1.1. Triple ... 110
6.1.2. Individui e Identificatori ... 112
6.1.3. Rappresentazioni Grafiche ... 113
6.2. Classi e Proprietà ... 114

6.2.1. Gerarchie di Classi e Proprietà 114
6.2.2. Progettazione delle Classi 116
6.3. Ontologie e Condivisione della Conoscenza 117
6.3.1. Web Semantico 119
6.3.2. Logiche Descrittive e Rappresentazioni per Ontologie 122
6.3.3. Ontologie Top-Level 127
7. Apprendimento Supervisionato 127
7.1. Problematiche dell'Apprendimento 128
7.2. Fondamenti 130
7.2.1. Problema Supervisionato 130
7.2.2. Valutazione delle Predizioni 133
7.2.3. Stime Puntuali di Riferimento senza Feature di Input 137
7.2.4. Tipi di Errore 138
7.3. Modelli-Base 140
7.3.1. Alberi di Decisione 140
7.3.2. Regressione e Classificazione Lineari 147
7.4. Sovradattamento 154
7.4.1. Pseudoconteggi 155
7.4.2. Regolarizzazione 156
7.4.3. Validazione incrociata 158
7.5. Modelli Compositi 160
7.5.1. Estensioni dei Modelli Lineari 160
7.5.2. Ensamble Learning 161
8. Reti Neurali e Apprendimento Profondo 164
8.1. Reti Neurali Artificiali Feed Forward 165
8.1.1. Apprendimento dei parametri 168
8.2. Estensione 172
8.2.1. Migliorare l'Ottimizzazione 172
8.2.2. Migiorare la Generalizzazione 173
8.2.3. Reti convolutive 174
8.2.4. Modelli per Sequenze 174
8.2.5. Altri Modelli Neurali Generativi 175
9. Ragionamento su Modelli di Conoscenza Incerta 177
9.1. Probabilità 177
9.2. Semantica della Probabilità 178
9.2.1. Probabilità Condizionata 179
9.2.2. Valori Attesi 181
9.3. Indipendenza 182
9.4. Belief Network 183
9.4.1. Osservazioni e Query 185

9.4.2. Costruzione di Belief Network ... 185
9.4.3. Probabilià Condizionate e Fattori ... 188
9.5. Inferenza Probabilistica ... 192
9.5.1. Inferenza Esatta ... 193
9.5.2. Inferenza Approssimata ... 193
9.6. Modelli Probabilistici Sequenziali ... 193
9.6.1. Catene di Markov ... 193
9.6.2. Modelli di Markov Nascosti ... 195
9.7. Simulazione Stocastica ... 195
9.7.1. Campionamento di una Variabile ... 196
9.7.2. Forward Sampling su BN ... 196
9.7.3. Markov Chain Monte Carlo ... 197
10. Apprendimento e Incertezza ... 200
10.1. Apprendimento Probabilistico ... 200
10.2. Apprendimento Bayesiano ... 201
10.2.1. Appredere Probabilità ... 202
10.2.2. Classificatori Probabilistici ... 205
10.2.3. Apprendimento MAP di Alberi di Decisione ... 207
10.2.4. Lunghezza delle Descrizioni ... 207
10.3. Apprendimento non Supervisionato ... 208
10.3.1. Hard Clustering ... 208
10.3.2. Soft Clustering ... 210
10.4. Apprendimento di Reti Bayesiane ... 213
10.4.1. Variabili Latenti ... 214
10.4.2. Dati Mancanti ... 215
10.4.3. Apprendimento della Struttura ... 216
10.4.4. Caso Generale ... 217

Ingegneria della conoscenza

Definizione 1 *(Ingegneria della conoscenza)* **.** L'Ingegneria della Conoscenza è il processo di acquisizione, strutturazione e rappresentazione delle competenze umane in un formato che le macchine possono comprendere e utilizzare. Può essere vista come l'arte e la scienza di costruire sistemi basati sulla conoscenza in grado di ragionare, prendere decisioni e risolvere problemi complessi in modi che rispecchiano il pensiero umano.

Nel contesto dell'*intelligenza artificiale* che sta rimodellando ogni settore, l'ingegneria della conoscenza rappresenta il ponte fondamentale tra le competenze umane e l'intelligenza artificiale. Gli ingegneri della conoscenza possono essere considerati come traduttori della conoscenza imp;licita che *vive* nella mente degli esperti: essi la convertono in formati espliciti e strutturati che le macchine possono elaborare e sulle quali possono agire.

1.1. Sistemi intelligenti basati su Conoscenza

L'ingegneria della conoscenza è una disciplina ingegneristica atta a progettare e sviluppare *sistemi intelligenti* basati su conoscenza *esplicita*.
L'intelligenta artificiale può essere definita come la disciplina che studia sintesi e analisi degli *agenti computazionali*, ossia dei sistemi che agiscono in modo *intelligente*. Essi possono svolgere azioni in un *ambiente* e vanno giudicati **solo** per tali azioni.
Aspetti salienti dell'*azione intelligente* sono i seguenti:

- l'appropriatezza rispetto alle circostanze, agli obiettivi, ai limiti;
- la considerazione delle conseguenza a breve/lungo termine delle azioni;
- l'apprendimento dall'esperienza;
- la flessibilità rispetto ai cambiamenti.

Un **agente computazionale** è un agente le cui decisioni/azioni siano spiegabili in termini di calcolo automatico. Esso è implementato su sistema *fisico* e presenta le seguenti *limitazioni*:

- non è onnisciente né onnipotente;
- le capacità di osservazione sono specializate e vincolate dal dominio applicativo;
- la sua memoria è finita e a tempo limitato.

La disciplina dell'AI può essere inquadrata sotto diverse prospettive:

- la prospettiva *scientifica* considera l'AI come displina finalizzata a comprendere i principi del comportamento intelligente:
  - analizzando sistemi naturali e artificiali;
  - formulando *teorie* sulla costruzione di agenti intelligenti che possano essere supportate da *implementazioni* per la loro *verifica sperimentale*;
- la prospettiva *ingegneristica* inquadra l'AI come lo studio di nuove tecnologie atte risolvere specifici problemi tipicamente risolti da agenti umani:
  - progetto e sintesi di *sistemi* intgelligenti *basati su conoscenza* (KBS) *testabili*: qualità valutabili attraverso metrodi standard dell'ing. informatica;
  - applicazioni costruite per la loro *utilità* in un dato dominio.

Altri obiettivi dell'AI:

- **intelligence augmentation**: accrescimento dell'intelligenza e della creatività umane. Alcuni esempi:
  - sistema diagnostico: aiuta i medici a prendere decisioni migliori;
  - motore di ricerca: aiuta a superare i limiti della memoria umana;
  - traduzione automatica: aiuta la gente a comunicare.
- **integrazione** dei compiti di agenti umani e sistemi intelligenti che collaborano alla soluzione di problemi; si parla di modalità **human-in-the-loop**.

C'è differenza tra la definizione di intelligenza *naturale* e l'intelligenza *artificiale*. L'intelligenza *naturale* emerge spontanaemente in natura mentre, quella *artificiale*, viene progettata per specifici scopi.
L'ipotesi fondamentale può essere riassunta con la seguente formula:

$$\text{ragionamento} \approx \text{computazione}$$

Tale ipotesi è collegata alla *tesi di Church-Turing*: esiste un livello di astrazione nel quale il ragionamento coincide con la manipolazione di simboli.
In termini generali potremmo definire la **conoscenza** un'informazione stabile, non transitoria.

1.2. Dimensioni dello spazio di progettazione

La *complessità* dei sistemi intelligenti varia e dipende dalle finalità e dai diversi contesti in cui sono immersi. Ciò vale dai casi semplici a quelli più complessi.
Le **dimensioni della complessità** nella progettazione:

- definiscono uno *spazio di progettazione*: si hanno diversi sistemi a seconda delle loro tipologie;
- forniscono forme di *decomposizione sommaria* dello spazio, cui andranno aggiunte altre scelte da fare;
- interagiscono fra loro: dimensioni combinabili anche se studiate separatamente.

Dimensione	**Valori**
Modularità	piatta | modulare | gerarchica
Orizzonte della pianificazione	nessuna pianificazione | #tappe finito (miopia) | indefinito | infinito (processo)
Rappresentazione del mondo	stati | (tuple di) feature | individui + relazioni (binarie) #mondi: n_s | 2^{n_f} | $2^{n_i^2} \cdot n_r$ (n_s = #stati, n_f = #feature, n_i = #individui e n_r = #relazioni)
Incertezza	*osservabilità del mondo:* totale | parziale *effetto:* deterministico | stocastico
Preferenze	obiettivi (da raggiungere | mantenere) | compromessi (preferenze cardinali | ordinali)
Apprendimento	*conoscenza data / appresa*
Limiti delle risorse	*razionalità perfetta / limitata*
Numero di attori	singolo | multipli agenti (distribuiti, cooperativi | competitivi)
Interattività	*ragionamento (computazione) online / offline*

1.2.1. Modularità

Il tipo di **modularità** indica il grado di decomposizione di un sistema in *moduli* interagenti da prendere in considerazione separatamente. Ciò serve a *dominare la complessità*, nei sistemi software ma anche nelle organizzazioni. Tipicamente la modularità viene espressa attraverso una decomposizione gerarchica: ogni modulo è organizzato in sotto-mopduli a loro volta organizzati gerarchicamente fino al livello base; astrazione procedurale e OOP servono a sfruttare modularità e astrazione.
Le strutture possibili sono: *piatta*, ossia senza struttura organizzativa; *modulare*, se il sistema viene decomposto in moduli interagenti considerabili separatamente; *gerarchica* quando nel sistema i moduli possono essere decomposti in sotto-moduli interagenti, a loro volta decomponibili.
Le modalità di *ragionamento* dipendono dal tipo di struttura: con uno struttura piatta o modularesi ha un singolo livello di astrazione; con una gerarchica si hanno multipli livelli di astrazione.

1.2.2. Schema di Rappresentazione

Lo **schema di rappresentazione** riguarda la *descrizione del mondo*. Le rappresentazioni alternative possibili sono: a *stati*, con *caratteristiche / proposizioni* oppure con individui e *relazioni*.

Stati

Gli **stati** distinti del mondo hanno un impatto sul comportamento del sistema. Essi sono fattorizzabili in stati *interni* e stati dell'*ambiente*.

> **Esempio 1.** Un termostato può essere modellato usando 6 stati:
> - stati *interni*: **spento**, **riscaldamento**,
> - stati *ambiente*: **freddo**, **confortevole**, **caldo**;
>   - ambiente freddo: passare o restare in modalità riscaldamento;
>   - ambiente molto caldo: può passare nello stato spento;
>   - ambiente confortevole: rimanere nello stato corrente;
> - *azioni*: scaldare nello stato riscaldamento, altrimenti passare nello stato spento.

Caratteristiche

Il ragionamento si basa su **caratteristiche**, dette *feature*, degli stati o *proposizioni* booleane invece della loro enumerazione. Uno stato può essere descritto in termini di caratteristiche, con un valore per ogni stato.

> **Esempio 2** *(Domotica)* **.** In un sistema per la domotica le caratteristiche potrebbero essere:
> - posizione degli interruttori;
> - stato di ogni interruttore (*in_funzione, in_corto, fuori_uso*);
> - stato dei punti luce, ad esempio *pos_s2* con valore *up* se l'interruttore *s2* è accesso e *down* se spento;
> - stato della casa descritto in termini dei valori di ciascuna delle caratteristiche.

Proposizioni

Una **proposizione** è una caratteristica *booleana*. Risulta una rappresentazione *compatta*: sono state comprese *regolarità* importanti sul dominio. Ad esempio con 30 proposizioni codificano $2^{30} \approx 10^9$ stati quindi è più facile specfiicare e ragione con 30 proposizioni che con oltre un miliardo di stati.

Relazioni e individui

Nella descrizione di mondi complessi una relazione su un singolo individuo è una **proprietà**. Si può definire una *caratteristica* per ogni possibile relazione tra individui, come ad esempio $R(a, b)$, che potrebbe corrispondere a «Nico studia Informatica», ossia $studia(Nico, Informatica)$. Le *descrizioni relazionali* sono più convenienti di caratteristiche e proposizioni:

- ad esempio, con una sola relazione binaria e 100 indvidui si possono rappresentare $100^2 = 10000$ proposizioni e 2^{10000} stati;
- si possono considerare intere classi di individui senza enumerarne caratteristiche/ proposizioni, o addirittura i numerossisimi stati;

- permettono di ragione su infiniti individui; ad esempio l'insieme dei numeri, o l'insieme di tutte le stringhe, cosa impossibile in termini di stati.

Incertezza

Si progetta anche tenendo conto dell'**incertezza** insita nel dominio considerato:

1. percezione / osservazione;
2. effetti delle decisioni / azioni.

Osservazione incerta

A volte è possibile l'*osservazione diretta* dello stato del mondo. Più spesso accade che la percezione dello stato sia *difettosa* o *parziale / indiretta*: al più si può disporre di una *distribuzione* di probabilità sull'insieme degli stati possibili su quanto si osserva.

L'**incertezza sulla percezione** riguarda la possibilità di determinare lo stato del mondo attraverso osservazioni. Uno stato può essere:

- *pienamente osservabile*: si può riconoscere dalle osservazioni, assunzione spesso fatta per ragioni di trattabilità dei problemi;
- *parzialmente osservabile*: non osservato direttamente; è possibile che più stati portino alle stesse osservazioni oppure le osservazioni sono *rumorose*.

Effetto incerto

In certi casi è possibile conoscere sempre l'effetto delle azioni/decisioni: dato uno stato e un'azione/decisione, si può predire *precisamente* lo stato risultante dall'applicazione dell'azione. A volte è difficile fare tale previsioni: al più si avere una *distrubuzione di probabilità* sugli effetti possibili.

L'*incertezza sugli effetti* prevede che la loro *dinamica* possa essere:

- *deterministica* e lo stato risultante viene determinato esattamente dall'azione e dallo stato precedente;
- *aleatoria*, con una probabilità sui possibili stati risultanti: ha senso solo se il mondo è completamente osservabile.

Preferenza

Gli agenti sono spesso *utilitaristici*: la scelta di un'azione è dettata dai risultati attesi più desiderabili; ci possono essere le finalità *semplici* o anche preferenze *complesse*.

Le **preferenze** si caratterizzano come:

- *finalità*, da raggiungere, detto *achievement goal*, o di conservazione, detto *mainenance goal*, in ogni stato visitato;
- *preferenze complesse*: sono compromessi sul vantaggio derivante dei vari risultati, eventualemten anche in momenti diversi. Si distinguono:
  - preferenze *ordinali*: conta solo l'ordine;
  - preferenze *cardinali*: conta anche la grandezza del valore.

Apprendimento

Non sempre il progettista dispone di un buon modello del sistema e del suoi ambiente: si devono usare dati da esperienze passate e altre sorgenti di conoscenza per migliorare il modello e prendere migliori decisioni.

La dimensione dell'**apprendimento** determina se la conoscenza sia data oppure se vada appresa.

Apprendere significa trovare il modello migliore che si adatti ai dati e si possono presentare diversi casi:

- caso *semplice*: regolare un insieme fisso di *parametri*;
- caso più difficile: scegliere preliminarmente la migliore *rappresentazione*, ad esempio feature o relazioni.

Si possono presentare diverse problematiche:

- utilizzo di *conoscenza di fondo*;
- *selezione* dei dati da raccogliere;
- *rappresentazione* dei dati e dei modelli;
- selezione dei *learning bias* appropriati;
- uso della conoscenza appresa per modificare decisioni / azioni dell'agente.

Limitatezza delle Risorse Computazionali

Le **limitazioni** sulle risorse computazionali disponibili spesso impediscono di prendere le migliori decisioni. Si fanno compromessi quindi sulla qualità della soluzione da cercare spesso necessari: spesso è preferibile una soluzioner ragionevole ma rapida che una migliore calcolata quando è troppo tardi perchè il mondo esterno nel frattempo è cambiato.

Tale dimensione determina se il sistema ragione per prender la migliore decisione: senza tener conto dei limiti, *razionalità perfetta*, oppure tenenendo conto dei limiti, *razionalità limitata*.

I *limiti* riguardano il *tempo*, la *memoria* e la *precisione*, il grado di approssimazione.

Un **algoritmo anytime** produce soluzioni che migliorano con il tempo:

- in qualunque momento produce la *miglior soluzione corrente*;
- si assicura che la qualità non decresca, si conserva la migliore soluzione trovata da restituire su richiesta;
- l'attesa può avere un *costo*: a volte meglio decidere/agire subito anzichè di aspettare una soluzione probabilemente migliore.

Orizzonte

L'**orizzonte** misura quanto lontano sia prevista la pianificazione del lavoro, ossia quanto in avanti ci si spinga a considerare le conseguenze delle azioni. Si possono distinguere sistemi/agenti software:

- *senza pianificazione*: nelle decisioni non considerano il futuro e il fattore-tempo non è preso in considerazione;

- a *orizzonte finito*: interessano solo un numero prefissato di passi;
- a *orizzonte indefinito*: numero di passi finito, ma non predeterminato;
- a *orizzonte infinito*: sempre attivo.

Numero di agenti

Difficoltà aggiuntive degli ambienti con altri agenti / sistemi sono:

- occorre ragionare sugli altri agenti secondo *strategie*: potrebbero cercare di confondere e manipolare o potrebbero cooperare; conviene agire in modo casuale se gli altri adottano strategie deterministiche;
- anche quando si cooperi e vi sia un file comune, il problema della *coordinazione* e della *comunicazione* rende il ragionamento multi-agente più complesso.

Dal punto di vista del singolo agente, la dimensione del **numero di agenti** prevede:

- ragionamento da *agente singolo*: gli altri come parte dell'ambiente;
- ragionevole se non ci sono altri agenti o se gli altri non cambieranno il comportamento in base alle sue azioni;
- ragionamento *multi-agente*: si prende in considerazione il ragionamento altrui;
- in caso di agenti intelligenti con *fini / preferenze* che dipendano da quello dalla *comunicazione* con gli altri;
- più difficile se gli agenti possono agire *simultaneamente* o se l'ambiente è solo *parzialmente osservabile*.

Interazione delle Dimensioni

Non si possono studiare le dimensioni separatamente perchè sono soggette a *interazioni complesse*:

- *Rappresentazione e modularità*: avendo una gerarchia di moduli semplici, il ragionamento può essere svolto su insieme finito di stati; altri livelli di astrazione richiedono il ragionamento su relazioni.
- *Orizzonte e modularità*: ad esempio, un cane robotico può ricevere una ricompensa quando risponde al richiamo; quando decide sui singoli movimenti, il momento del premio potrebbe essere lontano quindi l'orizzonte risulta potenzialmente indefinito.
- *Incertezza sull'osservazione e complessità del ragionamento*: molto più facile ragionare quando si conosce lo stato del mondo; l'incertezza su individui e relazioni è più complicata da trattare.
- *Incertezza sugli effetti e modularità*: ad un dato livello della gerarchiua, una decisione può essere *deterministica* mentre ad un altro potrebbe essere *stocastica*.
- *Molteplicità e modularità*: agente progettato attraverso più sistemi che interagiscono condvidendo il *fine comune* di rendere intelligente il comportamente dell'agente al livello superiore.
- *Apprendimento e rappresentazione*: spesso l'apprendimento lavora sulla rappresentazione di feature: determina modelli che portano a miglioir predizioni dei

valori di una specifica feature-obiettivi; ma si può lavorare anche su individui e relazioni, ovveroi l'apprendimento di gerarchie di modelli, in domini parzialmente osservabili e attraverso sistemi multipli.

- *Modularità e razionalità limitata* per un ragionamento più efficiente; il formalismo può diventare più complicato ma per costruire sistemi complessi servono: la decomposizione in componenti più piccole e delle approssimazioni per poter decidere in tempo accettabili anche in regime di memoria limitata.

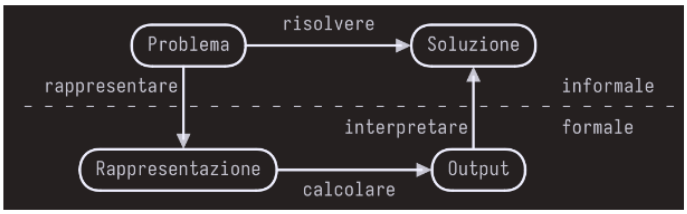


Figura 1.1: Risoluzione dei problemi

Figura 1: Risoluzione dei problemi

1.3. Progettazione si Sistemi Intelligenti

1.3.1. Semplificazione di Ambienti e Sistemi

La conoscenza del KBS non corrisponde a quella nella mente dell'esperto e/o del progettista.
Vi sono due casi-limite possibili:

- *sistema specializzato* nel suo dominio/task, poco utile fuori dal suo contest;
- *sistema flessibile* che si adatta ai contesti e accetta nuovi task.

Le strategie di costruzioni alternative sono:

- creazione di un modello dell'ambiente *semplificato* utile a costruire sistemi di ragionemento *complessi*
- sistemi *semplici* per contesti *complessi*.

1.3.2. Compiti e Problemi

In AI è importante **cosa** vada fatto/calcolato e non **come** ridotto a ricerca nello spazio di soluzioni possibili. Una descrizione di un **problema** dev'essere disponibile a livello informale.

1.3.3. Rappresentazione interna

La **conoscenza** può essere definita come informazione *stabile*, a *lungo termine* su un dominio, a differenza delle **credenze** sull'ambiente che sono più *transitorie*. Per poterci ragionare essa va rappresentata formalizzandola in termini di un **linguaggio di rappresentazione**. Una **base di conoscenza** risulterà come rappresentazione

interna al sistema, codificata attraverso idonee strutture dati.
Le *proprietà* principali degli schemi di rappresntazione sono le seguenti:

- *richezza espressiva* sufficiente alla risoluzione del problema;
- *vicinanza* ai termini naturali del problema; esiste una relazione fra il dominio e la sua rappresentazione il che permette verifiche di correttezza; la vicinanza è anche correlata alla *spiegabilità* dei meccanismi di ragionemento interni;
- *trattabilità*, propensione a un'elaborazione efficiente;
- *acquisibilità* a partire da dati e/o da esperienza pregressa da parte degli utenti.

1.4. Soluzioni

Come nell'ingegneria del software, dato un problema, il progettista deve definire cosa costituisca una **soluzione**. Le soluzioni possono essere di diverso tipo:

- *ottimali*: la migliore secondo una *misura di qualità*:
  - *ordinale*, tipica;
  - *cardinale*, se contano anche le grandezze relative;
  - combinazione di criteri multipli.
- *soddisfacente*: buona secondo una specifica delle risposte *adeguate*;
- *approssimata*: soluzione di qualità *prossima* a quella ottimale, sulla base di una misura *cardinale*; conveniente per ragioni di efficienza anche in virtù degli algoritmi adottati;
- *probabile*: *verosimilimente* una soluzione, con un determinato grado di certezza:
  - forma di approssimazione precisa di soluzione soddisfacente;
  - si possono distinguere i tassi di errori di *falsi-positivi* o di *falsi-negativi*.

1.4.1. Modelli: Livelli di Astrazione

Un **modello** è una rappresentazione del mondo che può essere statica, ciò che si crede vero, ovvero dinamica, il suo *funzionamento*. È utile lavorare a vari lvielli di dettaglio, ossia di **astrazione**: si rappresenta la parte del mondo di interesse trascurando i dettagli inutili. Il **livello di astrazione** determina un *ordine parziale*. Sono spesso ammissibili *più modelli* a diversi livelli di astrazione, anche in contraddizione tra loro: andranno giudicato in base alla loro utilità che per la loro correttezza.
Livelli d'astrazione comuni fra sistemi *biologici* e *computazionali* sono i seguenti:

- **livello della conoscenza** sul mondo esterno: considera quello che il sistema assume di sapere e i suoi obiettivi, ma non come ragiona, ossia non come calcolare la soluzione;
- **livello simbolico** interno: descrizione del modo di ragionare del sistema utile a implementare il livello precedente, manipolando simboli per produrre risposte.

1.5. Sistemi Intelligenti basati su Conoscenza

Un **agente intelligente** è un modello capace di percezione - ragionamento - aszione che si trova immerso in un **ambiente**. Un possibile schema è il seguente:

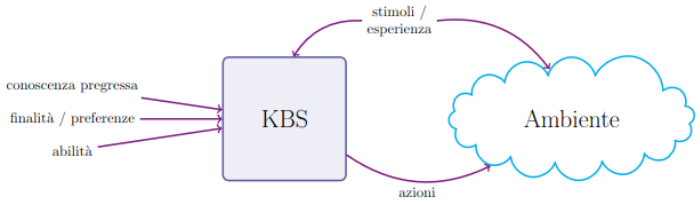


Figura 1.2: Schema di KBS / agente

Figura 2: Schema di un KBS

Il comportamento del KBS si basa su:

- **conoscenza pregressa** riguardo l'agente e il suo ambiente;
- **storia** dell'interazione con l'ambiente: **stimoli** ed **esperienza passata**;
- **obiettivi** da raggiungere o **preferenze** sugli stati del mondo;
- **abilità**, azioni primitivi di cui è capace.

Nella scatola nera si rappresenta un suo *stato interno delle credenze*, o **belief state**, comprendente la rappresentazione delle cose che si ritengono vere circa l'ambiente, cosa si è imparato, obiettivi intermedi presenti e futuri.
Il funzionamento di un KBS intelligente può essere schematizzato in due fasi, come nella seguente figura:

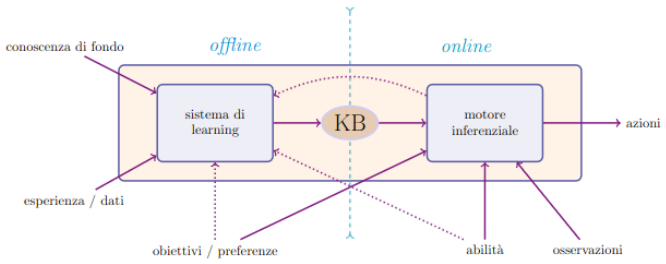


Figura 3: Funzionamento di un KBS

La KB viene coinvolta in momenti diversi:

- *Offline*, viene costruita/integrata usando conoscenza pregressa ed esperienze passate: spesso servono molti dati e conoscenza generale. Tale attività nei sistemi esperti non è automatizzata;
- *Onliune*, si prendono decisioni/compiono azioni e si aggiorna la KB; nel ragionamento si usano KB, osservazioni, obiettivi e abilità del sistema.

Una KB è utile nel futuro come *long-term memory*: viene appresa dai dati e dall'esperienza pregressa; un belief state, *short-term memory*, è un modello dell'ambiente attuale necessario tra successivi intervalli di tempo.
Uno schema di un KBS dettagliato è il seguente:

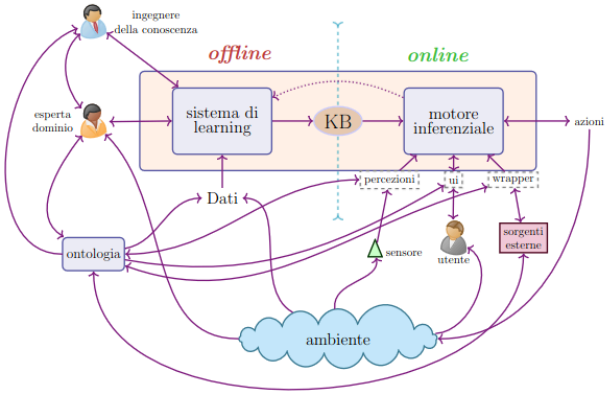


Figura 4: Schema dettagliato di un KBS

1.6. Domini applicativi

Tipici domini applicativi sono i seguenti:

- *robotica*;
- *diagnostica*: *assistente* che aiuta a capire i problemi di altri sistemi software e suggerisce rimedi;
- *tutoring*: *sistema* di aiuta agli studenti che interagisce fornendo informazioni su un argomento di interesse, assegnando compiti/test e valutando le capacità; deve comprendere la materia, lo studente e come questo impari;
- *e-commerce*: assistente agli acquisti di beni e servizi per conto dell'utente che sa riconoscere richieste e preferenze; sa trovare compromessi tra obiettivi distinti.

Ricerca di soluzioni in spazi di stati

2.1. Risoluzione di problemi mediante ricerca

La risoluzione di diversi problemi spesso consiste nella *ricerca* in uno specifico modello del mondo. Considernado il caso di un sistema che, dato un *obiettivo* da raggiungere, ragiona su un *modello* del mondo fatto di *stati*, in *assenza di incertezza*.

Per raggiungere questo scopo, si adotta una rappresentazione *piatta*, ovvero relativa a un singolo livello in una gerarchia.
L'*astrazione* del problema prevede la ricerca di un *percorso* che vada da un nodo di partenza a uno dei nodi-obiettivo, detto *goal*, in un *grafo orientato*.

> **Esempio 3** *(Navigatore)* **.** L'obiettivo è la ricerca del *miglior percorso* da un luogo a un altro: il più corto; quello di minimo costo; il più veloce; il più attrattivo, ecc.
> Ogni *stato* include informazioni su: localizzazione, direzione, velocità, mezzo di trasporto utilizzato e così via.

Una strategia di ricerca comune a molti problemi in AI è la seguente: il sistema computa su una *rappresentazione interna*. Il sistema riceve solo una descrizione di *cosa* rappresenti una soluzione; *come* ottenerla sarà il compito di un algoritmo di ricerca. Spesso questi problemi e i relativi algoritmi risolutivi sono NP-completi.
Tali problemi risultano *difficili* anche per agenti umani. Spesso non esistono soluzioni ottimali per cui ci si accontenta di soluzioni *soddisfacenti* in mancanza d'una *struttura* mappabile su caratteristiche del mondo fisico.

2.2. Spazi di stati

Possiamo formulare la nozione di azione intelligente in termini di uno **spazio di stati**. Uno *stato* contiene tutte le informazioni necesserie per predirre gli effetti di un'azione e per determinare se soddisfi l'obiettivo. Una ricerca su uno spazio di stati assume le seguenti nozioni:

- Gli agenti hanno una conoscenza perfetta dello spazio di stati.
- In qualsiasi momento, conosce in quale stato si trova; il mondo è quindi pienamente osservabile.
- L'agente ha un insieme di azioni con effetti deterministici conosciuti.
- L'agente ha un obiettivo da raggiungere e può determinare se uno stato soddisfa l'obiettivo.

Una **soluzione** di un problema di ricerca è una sequenza di azioni che porterà l'agente dallo stato corrente allo stato obiettivo.
Un **problema di ricerca su uno spazio di stati** comprende:

- un insieme di stati
- uno stato distinto detto *stato di partenza*
- per ogni stato, un insieme di azioni disponibili all'agente che si trova in tale stato
- una **funzione di azione** che, dato uno stato corrente e un'azione *(s, a)*, ritorna un nuovo stato in cui si transita per effetto dell'azione
- un **goal** che è una funzione booleana, *goal(s)*, che ritornerà *true* se s è uno stato che soddisfa l'obiettivo e, in tal caso, s è lo **stato obiettivo**

- un criterio che specifica la qualità di una soluzione accettabile; una **soluzione ottimale** massimizza tale criterio, ad esempio se ammette *qualsiasi* sequenza di azioni che porti a uno stato-obiettivo; ad esempio associando *costi* alle diverse azioni da cui discende un criterio del *minimo costo totale* delle azioni; a volte, sono soddisfacenti anche soluzioni sub-ottimali, ad esempio quelle con un costo aggiuntivo del +10% rispetto a quello di una soluzione ottimale.

Esempio 4 *(Robot-consegne)* **.** Un robot che debba effettuare consegne in un edificio dovrà essere in grado di risolvere *problemi di ricerca* di percorsi da un luogo ad un altro in un dato piano.
Occorrerà definire:
- gli *stati*: posizioni distinte;
- le *azioni*: spostamenti da un luogo a un altro nelle vicinanze;
- il *problema* specifico: portarsi da `A` a `G` (unico stato-obiettivo);
- la *soluzione*: sequenza di spostamenti.

Possibili *estensioni* dei problemi di ricerca riguardano:
- la possibilità di sfruttare una *struttura interna* agli stati: ad esempio nei videogame;
- il caso di stati *non* completamente *osservabili*: ad esempio il robot-consegne non conosce la posizione iniziale delle consegne, oppure un sistema di tutoring può non conoscere bene le attitudini di uno studente;
- l'aggiunta di azioni *stocastiche*: ad esempio possibilità di commettere errori oppure mancato apprendimento da parte dello studente di un argomento;
- la possibilità di definire, invece degli stati finali, *preferenze aggiuntive* complesse, in termini di *ricompense* o *punizioni*.

Esempio 5 *(Videogame)* **.** Si consideri lo spazio nella seguente figura.

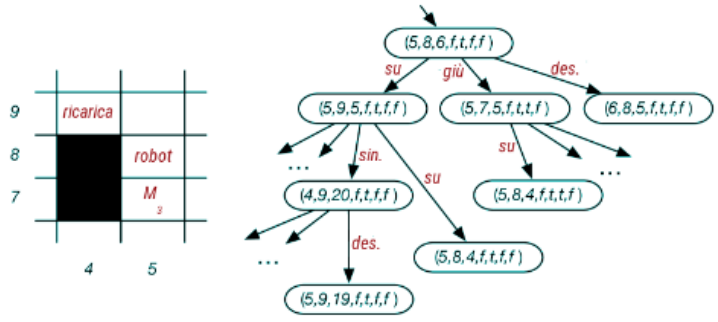


Figura 5: Spazio di stati del problema.

In tal caso definiamo:

- il *modello*: griglia nella quale ci si può muovere di una casella nelle 4 direzioni se non si è bloccati da un muro (caselle scure);
- l'*obiettivo*: raccogliere 4 monete $M_1, ..., M_4$, ognuna in una posizione iniziale nota, ad esempio C_3 in (5, 7);
- il *costo*: un'unità di energia per ogni passo: nessuna mossa è possibile senza energia; ricarica (+16 unità) presso una casella *ricarica*, ad esempio in (4, 9);
- lo *stato*: dato da una posizione x, y, dalle unità di carburante u possedute e da 4 flag c_i che indicano il possesso della relativa moneta: $(x, y, u, m_1, m_2, m_3, m_4)$;
- possibili stato-obiettivo $(5, 7, ?, t, t, t, t)$ dove ? indica un quantitativo qualsiasi di carburante.

2.3. Ricerca su Grafo

Per risolvere il problema, si definisce lo spazio di ricerca e si applica un algoritmo di ricerca. Come detto precedentemente, molti compiti possono essere ricondotti alla *ricerca* di percorsi in un grafo. Un modello *astratto* della soluzione sarà *indipendente* dal particolare dominio applicativo di interesse. Dato un *grafo orientato* fatto di nodi connessi da archi, si dovrà trovare un *percorso* da un nodo di partenza a uno boiettivo. Ci possono essere più modi per rappresentare uno stesso problema.

Un **grafo orientato** *esplicito* consiste di:

- un insieme di *nodi N*, anche non finito;
- un insieme di *archi A*, ossia di coppie *ordinate* di nodi, anche non infinito;
  - l'arco n_1, n_2 si dirà **uscente** da n_1 ed **entrante** in n_2
  - si dirà che il nodo n_2 è un **vicino** del nodo n_1 se e solo se $\exists \langle n_1, n_2 \rangle \in A$
- un **percorso** dal nodo s al nodo g, denotato da $\langle n_0, n_1, ..., n_k \rangle$, è una *sequenza* di nodi tale che se $s = n_0, g = n_l$ e $\forall i = 1, ..., k : \langle n_{i-1}, n_i \rangle \in A$; in alternativa, si può indicare una *sequenza di archi* $\langle n_0, n_1 \rangle, \langle n_1, n_2 \rangle, ..., \langle n_{k-1}, n_k \rangle$ o anche *sequenza di etichette* su tali archi: $\langle n_0, ..., n_i \rangle$ *parte iniziale* di $\langle n_0, n_1, ..., n_k \rangle$, con $i \leq k$.

Nel grafo esiste un insieme di *nodi-obiettivo* che si possono identificare anche tramite il predicato *goal(·)*, funzione booleana definita sui nodi. Una **soluzione** è un percorso dal nodo di partenza a uno obiettivo.
In alcuni casi è associato un **costo** a ogni arco: dato $\langle n_i, n_j \rangle$

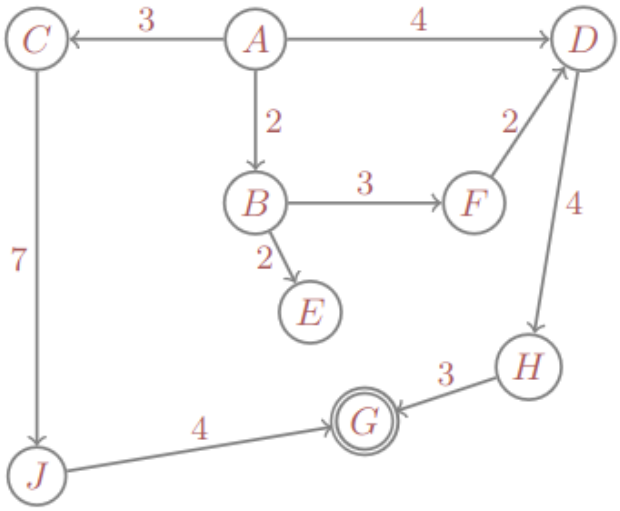
$$cost\big(\langle n_i, n_j \rangle\big) \in [0, +\infty[$$

estendibile anche ai percosi: dato $p = \langle n_0, n_1, ..., n_k \rangle$

$$cost(p) = \sum_{i=1}^{k} cost(\langle n_{i-1}, n_i \rangle)$$

Una soluzione **ottimale** p avrà costo minimo: $\nexists p'$ soluzione con $cost(p') < cost(p)$.

Esempio 6 *(Robot consegne, continuo.)* **.** Ricerca di un percorso da A a G nel mondo rappresentato nella seguente figura.



- $N = \{A, B, C, D, E, F, G, H, J\}$
- $A = \{\langle A, B\rangle, \langle A, C\rangle, \langle A, D\rangle, \langle B, E\rangle\langle B, F\rangle, \langle C, J\rangle, ...\}$ dove: E non ha vicini; C ha come vicino solo J; A ha i vicini B, C e D;
- vi sono 3 percorsi da A a G: $\langle A, D, H, G\rangle, \langle A, C, J, G\rangle, \langle A, B, F, D, H, G\rangle$; se A fosse nodo di partenza e G il nodo-obiettivo, ognuno di tali percorsi sarebbe una soluzione.

Un **ciclo** è un percorso non vuoto in cui primo e ultimo nodo coincidono: $\langle n_0, n_1, ..., n_k\rangle$ tale che $k > 0$ e $n_0 = n_k$.

Un **grafo aciclico orientato** (*directed acyclic graph*, DAG) è un grafo orientato senza cicli. Un **albero** è un DAG con un solo nodo, la **radice**, senza archi entranti. I nodi senza archi uscenti sono le sue **foglie**.

2.4. Algoritmo di ricerca generico

Un algoritmo di ricerca generico è un algoritmo indipendente dalla strategia di ricercadal grafo. Dato un grafo, si esplorano *incrementalmente* percorsi dai nodi di partenza verso nodi-obiettivo.

Si una una struttura dati per rappresentare la **frontiera**, detta *fringe*, dei percorsi già esplorati. Inizialmente la frontiera contiene percorsi costituiti dai soli *nodi di partenza*. Successivamente si effettua l'*espanzione* dei percorsi nella frontiera verso nodi inesplorati, fino a incontrare un nodo-obiettivo:

- si seleziona un percorso (rimuovendolo dalla frontiera);
- si estende il percorso con ogni arco uscente dall'ultimo nodo;
- si aggiungono alla frontiera i percorsi ottenuti.

ALGORITMO 1 — *Algoritmo di ricerca generico*

```
1:  procedure Search(G, s, goal)
2:  Input
3:      G: grafo con insiemi di nodi N e di archi A
4:      s: nodo di partenza
5:      goal: funzione booleana sui nodi
6:  Output
7:      percorso da s a un nodo per il quale goal sia vera
8:      oppure ⊥ quando non ci sono percorsi / soluzioni
9:  Local
10:     frontiera: insieme di percorsi
11: frontiera ← {⟨s⟩}
12: while frontiera ≠ ∅ do
13:     selezionare (e rimuovere) ⟨n_0, ..., n_k⟩ da frontiera
14:     if goal(n_k) then
15:         return ⟨n_0, ..., n_k⟩
16:     frontiera ← frontiera ∪ {⟨n_0, ..., n_k, n⟩ : ⟨n_k, n⟩ ∈ A}
17: return ⊥
```

Come descritto nell'Algoritmo di ricerca generico, l'inizializzazione parte dal nodo s.

La selezione *non è deterministica*, ha solo impatto sull'efficienza quindi una data strategia di selezione determina il percorso da scegliere. Il `return` annidato può essere interpretato come *temporaneo*, continuando si trovano strade alternative; $\perp$ indica che non vi sono soluzioni; la condizione *goal(n_k)* viene testata doo la selezione della frontiera e non all'aggiunta del nuovo nood:

1. a volte esiste un *arco* vers un nodo-obiettivo ma di *costo elevato*: non sempre conviene terminare restituendo subito il percorso trovato in quanto potrebbe esserci un percorso di costo inferiore;
2. va tenuto conto del fatto che lo stesso test *goal()* può essere *costoso*; un percorso che termini con un nodo che non sia un nodo-obiettivo e che non abbia vicini andrebbe rimosso.

2.5. Strategie di ricerca non informate

Il problema specifica il grafo e l'obiettivo mentre la **strategia di ricerca** determina il percorso da selezionare dalla frontiera. Le *strategie* **non informate** non prendono in considerazione la posizione dell'obiettivo. Se si considera un costo unitario per ogni arco, possibili strategia sono al ricerca *in ampiezz*, quella in *profondità* o l'*approfondimento iterativo*. Se è disponibileuna funzione di costo, allora si unano strategie dei *costi minimi*.

2.5.1. Ricerca in ampiezza

Nella **ricerca in ampiezza**, detta *breadth-first search, BFS* la frontiera è implementata cn una *coda*, ossia una struttura FIFO. Si seleziona il *primo* percorso aggiunto. I percorsi sono generati nell'ordine del numero di archi contenuti. A ogni passo, si seleziona uno dei percorsi più corti.

Esempio 7. Dal grafo in figura Figura 6, ignorando i costi, si ottiene il grafo nella seguente figura:

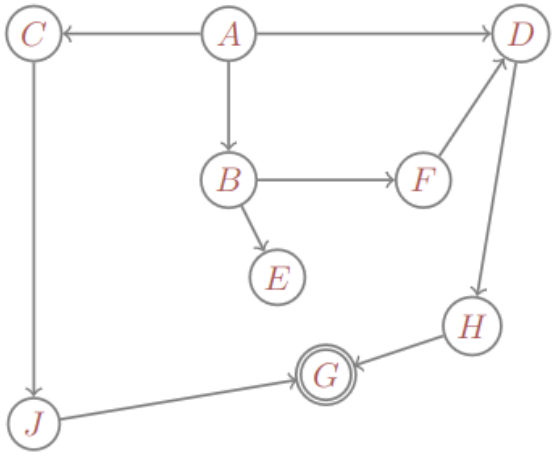


Figura 7: Grafo della figura Figura 6 ma senza informazioni sul costo

In questa figura A è il nodo di partenza e G è il nodo obiettivo. Con la BFS:

- frontiera iniziale: $[\langle A\rangle]$;
- estendendo $\langle A\rangle$ con i suoi vicini si ottiene:

$$[\langle A, B\rangle, \langle A, C\rangle, \langle A, D\rangle]$$

nodi a un arco di distanza da A;

- espandendo questi perocrsi, nell'ordine si ha:

$$[\langle A, B, E\rangle\langle A, B, F\rangle, \langle A, C, J\rangle, \langle A, D, H\rangle]$$

percorsi da A di lunghezza 2;

- dopo l'espansiuone dei percorsi del passo precedente la frontiera diventa:

$$[\langle A, B, F, D\rangle, \langle A, C, J, G\rangle, \langle A, D, H, G\rangle]$$

- selezionando, ad esempio, $\langle A, C, J, G\rangle$ questo percorso viene restituito come soluzione.

La BFS risulta utile quando:
- non si hanno problemi di spazio;
- si cerca una soluzione con numero di archi *minimale*.

La BFS è *poco utile* quando:
- tutte le soluzioni sono associate a percorsi lunghi;
- è disponibile conoscenza euristica;
- il grafo viene generato dinamicamente.

2.5.2. Ricerca in profondità

Nella **ricerca in profondità**, detta *depth-first search*, DFS, la frontiera è implementata con uno *pila*, struttura LIFO: gli elementi vengono aggiunti uno alla volta e quello selezionato e prelevato sarà l'ultimo aggiunto.
Partendo dalla radice, i nodi sono considerati come ordinati da sinistra a destra: il vicino più a sinistra sarà aggiunto in cima per *ultimo*. L'ordine di espansione non dipende dalla posizione dei nodi-obiettivo.
Con una pila, la ricerca procede in profondità:
- *completamento* di un *singolo percorso* prima di provare alternative;
- questo comporta il **backtracking**: si seleziona una prima alternativa per ogni nodo, *tornando indietro* all'opzione successiva solo dopo aver tentato tutti i completamenti;
- l'*ordine di aggiunta* dei vicini alla frontiera/pila non è specificato: questo impatta sull'efficienza e può essere *statico*, ossia prefissato, ovvero *dinamico*, dipendendo dall'obiettivo;
- per una procedura DFS alternativa si veda la figura (inserire figura slide).

Esempio 8 *(DFS sul grafo in Figura 7)* **.** La frontiera come lista con il primo percorso in *cima*. Si parte da $[\langle A\rangle]$. Le frontiere successive sono:
- $[\langle A, B\rangle, \langle A, C\rangle, \langle A, D\rangle]$
- $[\langle A, B, E\rangle, \langle A, B, F\rangle, \langle A, C\rangle, \langle A, D\rangle]$
- $[\langle A, B, F\rangle, \langle A, C\rangle, \langle A, D\rangle]$
- $[\langle A, B, F, D, H\rangle, \langle A, C\rangle, \langle A, D\rangle]$
- $[\langle A, B, F, D, H, G\rangle, \langle A, C\rangle, \langle A, D\rangle]$

Il percorso in cima viene restituito come *soluzione*.

La DFS è *appropriata* in caso di:

- limitazioni di spazio;
- presenza di molteplici soluzioni, anche se costituite da percorsi lunghi;
- ideale quando *tutti* portano a una soluzione;
- oppure se l'ordine di aggiunta dei vicini può essere variato in modo da trovare una soluzione al *primo tentativo*.

La DFS risulta *inefficiente* quando:

- sono possibili percorsi infiniti in caso di grafo infinito o contenente cicli;
- pur esistendo soluzioni alternative poco profonde, la ricerca si attarda su percorsi più lunghi.

2.5.3. Approfondimento iterativo

L'obiettivo dell'algoritmo **ITERATIVE DEEPENING** della DFS è combinare l'efficienza in spazio di DFS con l'ottimalità di BFS. L'idea è quella di non memorizza ma ricalcolare gli elementi della frontiera di BFS usando DFS che usa meno spazio.
DFS effettua una ricerca limitata fino a una data *profondità* come per le iterazioni di BFS. In caso di fallimento si eliminano i percorsi via via calcolati ripartendo, se necessario, dopo aver aumentato il limite. Si parte cercando fino a profondità 1, poi si costruiscono i cammini fino a lunghezza 2, poi quelli di lunghezza 3, ecc.... Se essiste, una soluzione verrà trovata, esplorando percorsi in tale ordine: uno con il numero minimo di archi sarà individuato per primo.
Il *fallimento* della ricerca in profondità limitata può essere:

- *innaturale*: per raggiungimento del limite di profondità e in tal caso la ricerca riparte, dopo aver incrementato il limite;
- *naturale*: quando l'intero spazio di ricerca è esaurito non esiste soluzione a nessun livello di profondità.

Algoritmo 2 — *Ricerca Iterative Deepening*

```
1:  procedure ID_search(G, s, goal)
2:  Input
3:      G: grafo con insiemi di nodi N e di archi A
4:      s: nodo di partenza
5:      goal: funzione booleana sugli stati
6:  Output
7:      cammino da s a un nodo per il quale goal sia vero
8:      ovvero ⊥ altrimenti
9:  Local
10:     raggiunta_max_profondita: boolean
11:     limite_profondita: integer
```

```
12: procedure Ricerca_a_profondita_limitata(⟨n_0, ..., n_k⟩, b)
13:     Input
14:         ⟨n_0, ..., n_k⟩: percorso
15:         b: integer {b ≥ 0}
16:     Output
17:         percorso fino a nodo-obiettivo di lunghezza k + b
18:     if b > 0 then
19:         for each ⟨n_k, n⟩ ∈ A do
20:             risultato ← Ricerca_a_profondita_limitata(⟨n_0, ..., n_k, n⟩, b − 1)
21:             if risultato ≠ ⊥ then
22:                 return risultato
23:     else if goal(n_k) then
24:         return ⟨n_0, ..., n_k⟩
25:     else if n_k ha vicini then {fallimento innaturale}
26:         raggiunta_max_profondita ← true
27:     return ⊥
28: limite_profondita ← 0
29: repeat
30:     raggiunta_max_profondita ← false
31:     risultato ← Ricerca_a_profondita_limitata(⟨s⟩, limite_profondita)
32:     if risultato ≠ ⊥ then
33:         return risultato
34:     limite_profondita ← limite_profondita + 1
35: until not raggiunta_max_profondita
36: return ⊥ {fallimento naturale}
```

La procedura Ricerca_a_profondita_limitata implementa una DFS a profondità limitata: trova percorsi di lunghezza $k + b$, dove k è la lunghezza del percorso e $b \geq 0$; viene chiamato a profondità crescenti. I percorsi vengono trovati nello stesso ordine della BFS: si controlla di aver trovato un obiettivo solo se $b = 0$.
Per assicurare di fallire quando anche la BFS fallirebbe, si tiene traccia dei casi in cui un limite amggiore potrebbe aiutare a trovare una soluzione. La ricerca *fallisce inaturalmente* se ha esaurito tutto lo spazio di ricerca e non sono stati tagliati percorsi per limite raggiungo; se raggiunta_max_profondita, falsa al momento della chiamata, diventa vera alla fine, il limite può essere incrementato per la successiva iterata.

2.5.4. Ricerca di soluzioni a costo minimo

In caso di archi con *costi* non unitari si cerca la soluzione di *minimo costo totale*. Gli algoritmi precedenti non garantiscono soluzioni di costo minimo: il costo non viene preso in considerazione. BFS minimizza solo il *numero* degli archi: potrebbe

esistere una soluzione alternativa, come un percorso più lungo ma di costo inferiore. L'algoritmo **LOWEST COST-FIRST SEARCH** (LcFS), detto anche *least-cost search* o *uniform-cost search*, si comporta come BFS ma con la selezione dei percorsi di costo minimo. Viene implementato usando una *coda con priorità* come frontiera ordinata da *cost*.

> **Esempio 9.** Si consideri il grafo in figura Figura 6. Si espanderà sempre il percorso più a sinistra nella frontiera (costi dei percorsi indicati come pedici):
>
> - $[\langle A\rangle_0]$ frontiera iniziale
> - $[\langle A,B\rangle_2, \langle A,C\rangle_3, \langle A,D\rangle_4]$
> - $[\langle A,C\rangle_3, \langle A,B,E\rangle_4, \langle A,D\rangle_4, \langle A,B,F\rangle_5]$
> - $[\langle A,B,E\rangle_4, \langle A,D\rangle_4, \langle A,B,F\rangle_5, \langle A,C,J\rangle_{10}]$
> - $[\langle A,D\rangle_4, \langle A,B,F\rangle_5, \langle A,C,J\rangle_{10}]$
> - $[\langle A,B,F\rangle_5, \langle A,D,H\rangle_8, \langle A,C,J\rangle_{10}]$
> - $[\langle A,B,F,D\rangle_7, \langle A,D,H\rangle_8, \langle A,C,J\rangle_{10}]$
> - $[\langle A,D,H\rangle_8, \langle A,C,J\rangle_{10}, \langle A,B,F,D,H\rangle_{11}]$
> - $[\langle A,C,J\rangle_{10}, \langle A,D,H,G\rangle_{11}, \langle A,B,F,D,H\rangle_{11}]$.
>
> Dopo l'espansione di $\langle A,C,J\rangle$, si selezionerà $\langle A,D,H,G\rangle$, percorso di costo minimale da A a G.

Il fattore di ramificazione è *finito* se i *costi* sono *limitati* inferiormente da una costante positiva: ciò garantisce la soluzione ottimale, quando esiste. Il primo percorso trovato termina in un nodo-obiettivo ed è ottimale perchè si procede in ordine di costo.
In mancanza di un limite inferiore allora sono possibili percorsi *infiniti*, ad esempio con nodi $n_0, n_1, n_2, ...$ con $\forall i > 0 : \langle n_{i-1}, n_i$ di costo $\frac{1}{2^i}$ esistono infiniti percorsi $\langle n_0, n_1, ..., n_k\rangle$, con costo < 1; se $\exists\langle n_0, g\rangle, goal(g)$ con costo ≥ 1, l'arco non verrebbe mai selezionato.
La complessità è esponenziale in spazio e tempo: genera tutti i percorsi con costo inferiore a quello della soluzione.

2.6. Ricerca Informata (Euristica)

2.6.1. Euristica

Tale tipo di ricerca prende in considerazione *informazioni sull'obiettivo*, nella selezione dei nodi da esplorare, attraverso l'uso di una **funzione euristica** h che associa a ogni nodo n un numero reale *non-negativo*, una stima del costo minimale di un perocorso da n fino a un nodo-obiettivo.
L'euristica h si dice **ammissibile** se *sottostima* il costo reale: $h(n)$ minore o uguale rispetto al costo minimale effettivo del percorso da ciascun nodo a un nodo-obiettivo.

Tale informazione approssimata è spesso immediatamente disponibile trovando un *compromesso* tra efficienza del suo calcolo e accuratezza della stima. Tipicamente, risolvendo una forma semplificata del problema, si possono poi usare i costi effettivi del problema semplificato come euristica nella soluzione del problema originario.

Esempio 10 *(Problema nel grafo in Figura 6)* **.** Considerando come *euristica* la distanza in linea retta tra nodo e obiettivo più vicino, quindi supponendo che tali distanze siano ad esempio:

	A	B	C	D	E	F	G	H	J
$h(\cdot)$	7	5	9	6	3	5	0	3	4

h risulta ammissibile e in particolare: essa è

- *esatta* per il nodo H;
- *molto sottostimata* per il nodo B: sembra vicino al nodo-obiettivo (costo 5), ma raggiungere l'obiettivo costa molto di più;
- *ingannevole* per il nodo E: sembra vicino al nodo-obiettivo (costo 3) ma non permette di raggiungere l'obiettivo.

2.6.2. DFS Euristica e Greedy best-First Search

L'euristica h può essere *estesa* al caso dei percorsi:

$$h(\langle n_0, ..., n_k \rangle) = h(n_k)$$

La **DFS Euristica** usa h per ordinare i *vicini* aggiunti alla pila/frontiera della DFS standard. I vicini vengono aggiunti in modo che il *migliore* vada in cima. Tale scelta è comunque *locale*: si esplorano i percorsi che estendono quello selezionato prima di tentarne altri. Si presentano problemi analoghi al caso della DFS: non c'è garanzia di terminazione e ritrovamento di una soluzione ottimale.
Si potrebbe considerare la *best-first search* che sfrutta un'euristica h da minimizzare nella scelta del prossimo cammino da espandere. In particolare, nella *greedy best-first search*, GbFS, si sceglie il percorso della frontiera con valore di h minimo. Purtroppo potrebbe seguire cammini apparantemente promettenti che, però, potrebbero continuare a estendersi indefinitamente.

2.6.3. Ricerca A^*

L'algoritmo A^* combina idee da LcFS e GbFS. Nella selezione del percorso da espandere si considerano: il costo effettivo del percorso parziale che dal nodo iniziale arriva al nodo corrente e l'euristica, ossia una stima del percorso dal nodo corrente fino a un obiettivo.
Per ogni percorso $p = \langle s, ..., n \rangle$ della frontiera, si stima il costo di un percorso che passi per p e progesua fino a un nodo-obiettivo g:

$$f(p) = cost(p) + h(p)$$

dove $cost(p)$ rappresenta il costo effettivo di p e $h(p)$ è una stima del costo del cammino da n a g.
Si segue lo schema dell'algoritmo di ricerca generico in Algoritmo di ricerca generico e si rappresenta la *frontiera* con una coda con priorità, ordinata da $f(p)$. Se h è ammissibile allora $f(p)$ non sovrastima il cost d'un percorso completo che includa p. A^* può seguire molti perocrsi ma alla fine ne trova uno di costo minimo. Altri possono semprare (provvisoriamente) di costo inferiore. A^* migliora le prestazioni degli algoritmi da cui origina.

Esempio 11 *(A^* su grafo ed euristica)* **.** Si consideri il grafo in figura:

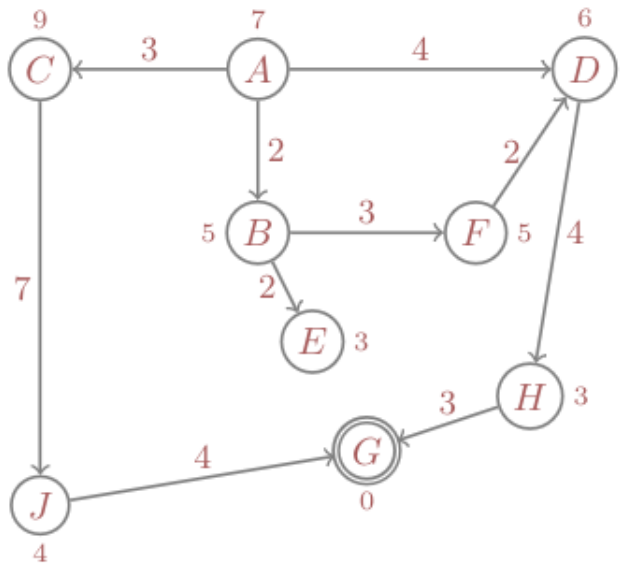


Figura 8: Problema con costi effettivi sugli archi e valori dell'euristica sui nodi

Sequenza delle frontiere. Il pedice indica il valore di $f(p)$.

- $[\langle A\rangle_7]$ iniziale, essendo $h(A) = 7$ e $cost(\langle\rangle) = 0$
- $[\langle A, B\rangle_7, \langle A, D\rangle_{10}, \langle A, C\rangle_{12}]$
- $[\langle A, B, E\rangle_7, \langle A, B, F\rangle_{10}, \langle A, D\rangle_{10}, \langle A, C\rangle_{12}]$
- $[\langle A, B, F\rangle_{10}, \langle A, D\rangle_{10}, \langle A, C\rangle_{12}]$
- $[\langle A, D\rangle_{10}, \langle A, C\rangle_{12}, \langle A, B, F, D\rangle_{13}]$
- $[\langle A, D, H\rangle_{11}, \langle A, C\rangle_{12}, \langle A, B, F, D\rangle_{13}]$
- $[\langle A, D, H, G\rangle_{11}, \langle A, C\rangle_{12}, \langle A, B, F, D\rangle_{13}]$

La soluzione è $\langle A, D, H, G\rangle$ di costo 11.

Un algoritmo è **ammissibile** se, quando esistono soluzioni, ne trova sempre una ottimale.

Proposizione 1. *A^* è ammissibile se:*

- *il fattore di ramificazione è limitato;*
- *i costi degli archi sono maggiori di un certo $\varepsilon > 0$*
- *h è ammissibile, non supera il costo minimale di percorsi da ciascun nodo a un obiettivo.*

A^* garantisce che la prima soluzione sarà ottimale, anche in presenza di cicli*, ma non assicura che ciascun nodo intermedio selezionato dalla frontiera sia un cammino ottimo.*

Importanza dell'euristica

Il miglioramento dell'efficienza in A^* è dato dall'uso di h. Sia c il costo del percorso di costo minimo. Se h è ammissibile, A^* espande ogni percorso dal nodo di partenza nell'insieme

$$\{p \mid cost(p) + h(p) < c\}$$

più alcuni percorsi nell'insieme

$$\{p \mid cost(p) + h(p) = c\}$$

Per l'efficienza di A^*, h è tanto migliore quanto più ridce la cardinalità del primo insieme.

2.6.4. Algoritmo Branch and Bound

L'idea di questo algoritmo è combinare l'effic ienza in spazio delle strategie in profondità con informazione euristica. Risulta efficace quando esistono molti cammini verso un nodo-obiettivo. Questo algoritmo assume che $h(n)$ sia ammissibile.
Questo algoritmo memorizza il percorso di costo minimo verso un nodo-obiettivo trovato e il suo costo che diventa un *limite*: un percorso $p : cost(p) + h(p) \geq limite$ aggiorando *limite*; si continua poi a cercare un'eventuale soluzione migliore.
Si genera così una sequenza di soluzioni via via migliori restituendo quella finale: l'algoritmo viene tipicamente implementato usando la DFS per la ricerca in profondità limitata dal valore di *limite*.

Algoritmo 3 — *Ricerca Depth-First Branch and Bound*

```
1: procedure DFBranchAndBound(G, s, goal, h, limite_0)
2: Input
3:     G: grafo con nodi N e archi A
4:     s: nodo di partenza
5:     goal: funzione di test dei nodi
```

```
    h: euristica sui nodi
    limite_0: limite iniziale (∞ se non specificato)
Output
    percorso di costo minimo da s a un nodo obiettivo se esiste una
    soluzione di costo minore di limite_0, oppure ⊥
Local
    percorso_migliore: percorso o ⊥
    limite: numero reale non negativo
procedure cbsearch(⟨n_0, ..., n_k⟩)
    if cost(⟨n_0, ..., n_k⟩) + h(n_k) < limite then
        if goal(n_k) then
            percorso_migliore ← ⟨n_0, ..., n_k⟩
            limite ← cost(⟨n_0, ..., n_k⟩)
        else
            for each ⟨n_k, n⟩ ∈ A do
                cbsearch(⟨n_0, ..., n_k, n⟩)
{main}
percorso_migliore ← ⊥
limite ← limite_0
cbsearch(⟨s⟩)
return percorso_migliore
```

La procedura *cbsearch*, *cost-bounded search*, comunica attraverso variabili globali; inizialmente, *limite* è impostata a limite_0, stima per eccesso del costo d'una soluzione ottimale.
DFBranchAndBound restituirà, se esiste, una soluzione ottimale con costo inferiore a limite_0. Se limite_0 supera di poco il costo minimo, l'algoritmo non espanderà più archi di A^*. La variabile limite_0 serve a far eliminare percorsi di costo maggiore: trovato un percorso completo, si esplorano solo percorsi con valore di f inferiore a quello del percorso trovato, ossia esattamente i percorsi esplorati da A^* quando trova una soluzione. Quando restituisce $\bot$, se $\text{limite}_0 = \infty$ allora non ci sono soluzioni, se invece limite_0 è finito allora non ci sono soluzioni di costo inferiore a limite_0.
Combinato con ID l'algoritmo può incrementare via via il limite fino a trovare una soluzione ovvero può mostrare che non c'è soluzione.

Esempio 12 *(Robot-consegne)* **.** In un problema più complesso, si considerino:

- *stati* comprendenti le consegne da fare;
- il *costo* dato dalla distanza totale per tutte le consegne;
- un'*euristica* possibile pari al massimo tra:
  1. la distanza massima per consegne ancora da fare non caricate: per ognina, la distanza dalla sua posizione e, da qui, fino alla destinazione;

2. la distanza della destinazione più lontana per le consegne trasportate.

Tale massimo non sovrastima il costo: è la soluzione per un problema semplificato che non considera muri e tutte le altre consegne da fare tranne la più difficile; è appropriato: vanno consegnate quelle trasportate, passate aprendere quelle ancora non caricate e portate a destinazione.
Se il robot può trasportare una sola consegna, un'euristica dovrebbe sommare le distanze per il trasporto di ognuna più la distanza dalla più vicina: non è detto che sarà effettuata per prima.

Esempio 13 *(Navigatore)* **.** Per la minimizzazione del tempo:

- possibile euristica: distanza in linea retta dalla locazione corrente al nodo-obiettivo divisa per la velocità massima, assumendo che ci si possa dirigere a destinazione alla massima velocità;
- euristica più sofisticata: date velocità massime diverse per autostrade e strade locali, si sceglie il massimo tra:
  1. minimo tempo stimato per andare a destinazione su strade locali lente;
  2. minimo tempo utile a raggiungere un'autostrada da una strada locale, per poi raggiungere un luogo vicino alla destinazione e arrivarci da strada locale.

2.6.5. Progettazione della funzione Euristica

Un'**euristica ammissibile** è una funzione non negativa h definita sui nodi, tale che dato un nodo n, $h(n)$ non è mai superiore al costo reale del percorso ottimale da n a un nodo-obiettivo.
Una *procedura standard* per definire un'euristica può essere descritta come segue:

- Si trovano soluzioni di un problema più semplice, ossia con *meno vincoli*, quindi spesso molto più facile da risolvere; una sua soluzione ottimale avrà un costo pari o inferiore a una soluzione del problema originario.
- Si considerino problemi di ricerca su mappe semplificate rappresentati da grafi, in cui si sia *vincolati* a muoversi lungo i dati archi: supponendo che il loro costo sia proporzionale alla lunghezza dei collegamenti stradali, un'euristica ammissibile è costituita dalla *distanza euclidea* tra punti/nodi.

Inserire esempi slide

Un problema in forma semplificata può essere risolto anche attraverso una ricerca più semplice rispetto al problema originario: ricerca ripetuta anche più volte e per tutti i nodi.
Conviene memorizzare (in una memoria cache) tali risultati in un **DB di pattern** che associ ai nodi del problema semplificato il valore dell'euristica.
Nel problema semplificato, spesso si hanno meno nodi: più nodi originari sono mappati su uno stesso nodo di quello semplificato come fosse una *classe d'equivalenza.*

2.7. Potatura dello Spazio di Ricerca

Si possono migliorare gli algoritmi di ricerca considerando i diversi percorsi che possono attraversare un nodo. Non tutti sono utili a risolvere il problema per cui gli altri possono essere subito eliminati.
Essenzialmente vi sono due tipi di **pruning**, ovvero *potatura*, con relative strategie:

- *potare i cicli* per trovare percorsi dal costo minimo;
- *potare cammini molteplici*: per ogni nodo si considererà un solo percorso che lo attraversi, eliminando tutti gli altri.

2.7.1. Potatura dei Cicli

Alcuni dei metodi di ricerca visti in precedenza potrebbero rimanere intrappolati in cicli senza possibilità di uscita anche nel caso di grafi finiti.
Per avere la garanzia di trovare una soluzione in caso di *grafo finito* non andranno presi in considerazione vicini già presenti nel percorso corrente.
Nella **potatura dei cicli**, detta *cycle / loop pruning, CP*, si prevede un controllo addizionale preventivo: dato un nodo da aggiungere, va testata l'occorrenza nel percorso.
Nello shema di **Algoritmo di ricerca generico** si aggiungono alla frontiera solo percorsi $\langle n_0, ..., n_k, n \rangle$, tali che $n \notin \{n_0, ..., n_k\}$, scartando il percorso selezionato; in alternativa si può effettuare il controllo dopo la selezione del nodo.
La compelssità dei controlli aggiuntivi per la verifica della presenza di un nodo nel percorso corrente dipende dal metodo di ricerca adottato:

- *costante* permetodi (DF) che memorizzano un *unico percorso*; si può usare una funzione *hash* oppure si può associare un *bit* a ogni ndoo, che sarà acceso quando viene aggiunto a un percorso e viene spento in caso di backtracking; per cui basterà non espandere nodi con il bit acceso; tale metodo funziona perchè si lavora su un solo percorso;
- *lineare* nella lunghezza del percorso corretne per metodi che gestiscono più percorsi (esponenziali in spazio): serve una ricerca per evitare di aggiungere al percorso parziale un nodo già presente.

2.7.2. Potatura di Percorsi Multipli

Spesso più di un percorso porta a uno stesso nodo. Occorre quindi *eliminare* dalla fronteira ogni percorso che porti a un nodo per il quale ne esista già un altro (di costo inferiore).
Una strategia di **multiple-path pruning** (MPP) può essere implementata gestendo una lista di nodi terminali di percorsi già esplorati, detta **closed list** o *explored set*: inzialmente essa è buota poi, selezionato un percorso $\langle n_0, ..., n_k \rangle$ della frontiera, se n_k è già nella lista esso può essere scartato, altrimenti si aggiunge n_k alla lista e si prosegue.

ALGORITMO 4 — *Ricerca con Multiple-Path Pruning*

```
1:  procedure SearchMPP(G, s, goal)
2:  Input
3:      G: grafo con nodi N e archi A
4:      s: nodo di partenza
5:      goal: funzione booleana sui nodi
6:  Output
7:      cammino da s a un nodo per cui goal è vero
8:      oppure ⊥ se non ci sono cammini soluzione
9:  Local
10:     frontier: insieme di cammini
11:     explored: insieme di nodi esplorati
12: frontier ← {⟨s⟩}
13: explored ← ∅
14: while frontier ≠ ∅ do
15:     selezionare e rimuovere ⟨n_0, ..., n_k⟩ da frontier
16:     if n_k ∉ explored then
17:         explored ← explored ∪ {n_k}
18:         if goal(n_k) then
19:             return ⟨n_0, ..., n_k⟩
20:         frontier ← frontier ∪ {⟨n_0, ..., n_k, n⟩ : ⟨n_k, n⟩ ∈ A}
21: return ⊥
```

Si noti che questa strategia non garantisce che non eliminato un percorso di costo minimo. Per garantire di preservare le soluzioni ottimali vi sono alcune alternative:

- assicurare che il primo percorso trovato per un dato nodo si ottimale quindi gli altri si possono eliminare;
- se nella frontiera si dovesse inserire un percorso $p = \langle s, ..., n, ..., m \rangle$, ma fosse già presente $p' = \langle s, ..., n \rangle$ meno costoso della parte fino a n in p, si può eliminare p oppure sostituire in p tale parte con p'.

In LcFS, il primo percorso verso un dato nodo è quello di costo minimo. Pertanto potare altri percorsi non elimina un cammino a costo minimo per il nodo. Ciò assicura di ptoer trovare una soluzione ottimale.
A^* non garantisce che quando si seleziona un percorso verso un nodo per la prima volta, questo sia quello di costo minimo: il teorema sull'ammissibilità lo garantisce solo per i percorsi verso nodi-obiettivo; per quelli verso altri nodi dipende dalle proprietà dell'euristica.
Un'**euristica consistente** h (non negativa) soddisfa il vincolo:

$$h(n) \leq cost(n, n') + h(n')$$

per ogni coppia di nodi n e n'.
Se $h(g) = 0$ per ogni nodo-obiettivo g, allora h sarà consistente e non sovrastimerà mai il costo dei percorsi da un nodo verso un obiettivo.
La consistenza è garantita se h soddisfa la **restrizione di monotonicità**:

$$h(n) \leq cost(n, n') + h(n')$$

per ogni arco $\langle n, n' \rangle$. Ciò è più facile da testare: dipende solo dagli archi, non dalle coppie di nodi considerate.

strategia	**selezione dalla frontiera**	**garanzia soluzione**	**complessità (spazio)**
BFS	primo nodo aggiunto	con meno archi	$O(b^d)$
DFS	ultimo nodo aggiunto	no	$O(bd)$
ID	n/a	con meno archi	$O(bd)$
G_{BFS}	$h(p)$ minimale	no	$O(b^d)$
LcFS	$cost(p)$ minimale	costo minimo	$O(b^d)$
A^*	$cost(p) + h(p)$ minimale	costo minimo	$O(b^d)$
DF B&B	n/a	costo minimo	$O(bd)$
IDA*	n/a	costo minimo	$O(bd)$

Tabella 1: Consuntivo dei diversi algoritmi: si considera la complessità in spazio, con d profondità e b limite superiore per il *fattore di ramificazione*.

> **Proposizione 2.** *Data un'euristica consistente, MPP non impedisce ad A^* di trovare una soluzione ottimale.*

Quindi, nelle condizioni della proposizione sull'ammissibilità di A^* che garantiscono solo il ritrovamento di una soluzione ottimale, se l'euristica è consistente, anche A^* con MPP la potrà trovare.
Nella pratica, A^* include MPP per default.

Confronto fra MPP e CP

- MPP è più generale di CP: un ciclo può essere considerato come un altro percorso verso un dato nodo, destinato a essere potato;
- MPP può essere implementato in modo da poter richiedere un tempo costante;
- MPP è preferibile con metodi in ampiezza: virtualmente tutti i nodi considerati vanno memorizzati;
- CP è preferibile con le strategie in profondità, ad esempio DFS con Branch-and-Bound; con MPP+DFS c'è il rischio di crescita esponenziale per la lista chiusa.

2.7.3. Consuntiva sulle Strategie di Ricerca

Un consuntivo schematico sulle diverse strategie di ricerca e la relativa complessità in spazio è disponibile nella (linkare la tabella inserita prima).

Un'**algoritmo** di ricerca **completo** garantisce il ritrovamento di una soluzione quando esiste. Le strategie che trovano percorsi con numero archi o costo minimale sono complete: nel caso pessimo serve un tempo esponenziale nel numero di archi dei percorsi esplorati. L'esistenza di algoritmi completi con minore complessità dipende dalla risposta alla domanda

$$P \neq NP?$$

2.8. Strategia di Ricerca più sofisticate

Sono possibili alcune estensioni delle strategie di ricerca presentate:

- dato che decidere la direzione della ricerca impatta sull'efficienza, si può pensare a una ricerca retrograda per soluzioni ottimali da qualunque nodo;
- per determinare una buona euristica si può usare la *programmazione dinamica*: metodi basati sulla *decomposizione* del problema in un numero di problemi equivalenti ma di minore complessità.

2.8.1. Direzione della ricerca

Nella **ricerca in avanti**, *forward search*, si comincia da un nodo di partenza e si prosegue fino a raggiungere i nodi-obiettivo. Nella **ricerca retrograda**, *backward search*, si parte da un nodo-obiettivo e si usa il *grafo inverso* alla ricerca del non di partenza; i vicini del nodo-obiettivo considerati per inizializzarela fronteira sono tutti gli altri nodi-obiettivo: $\{n : goal(n)\}$.

La direzione di ricerca è indifferente quando:

1. il numero di nodi-obiettivi è finito;
2. per ogni nodo n si possono generare i *vicini* del **grafo inverso** $\{n' : \langle n', n\rangle \in A\}$.

Le dimensioni dello spazio di ricerca sono date da b^d, dove b è il fattore di ramificazione e d la lunghezza del cammino. Riducendo questi parametri si abbassa la complessità aumentando l'*efficienza*. È possibile che vi sia una differenza tra i fattori da ramificazione uscente ed entrante; in tal caso un principio generale per la scelta della direzione della ricerca è quello di considerare la direzione per cui b risulta inferiore.

2.8.2. Ricerca bidirezionale

Nella **ricerca bidirezionale** si riduce il tempo di ricerca procedendo in entrambe le direzioni: quando le due frontiere si intersecano, si deve ricostruire un in singolo cammino dal nodo di partenza al nodo-obiettivo.

Come si è sicuro che le due frontiere s'incantrano ? Nel caso della DFS è difficile

date le ridotte dimensioni delle frontiere mentre nel caso della BFS è garantito.
Combinando DFS e BFS in direzioni opposte, si garantirebbe l'intersezione, ma la scelta per la direzione del cammino dipende. Per la BFS il fattore di tale scelta è il costo del mantenimento della frontiera (tempo proporzionale a b^k) mentre per la DFS è il costo della ricerca nella frontiera per avere un'intersezione; se si tratta di una ricerca simmetrica bidirezionale si è nell'ordine di $2b^{\frac{k}{2}}$, con risparmi in tempo, ma la complessità rimane esponenziale.

2.8.3. Ricerca in una gerarchia di astrazioni

L'idea è quella di astrarre la definizione del problema, rimuovendo dettagli: una soluzuone parziale del problema potrà essere ottenuta da una soluzione per la versione astratta. Con l'astrazione si punta a risolvere un problema in generale, lascaindo da risolvere problemi più semplici e specifici.
Diverse sono le modalità di astrazione di problemi. Tutte le strategie di ricerca presentate sono utilizzabili ma le specifiche decomposizioni utili non risultano facili da individuare.

> **Esempio 14** *(Ricerca a isole)* **.** Si consideri una ricerca fra i diversi piani di un edificio. Trovata la soluzione a livello di isola si passa a risolvere ricorsivamente i sotto-problemi in modo analogo:
> - informazioni sulle soluzioni trovate a livelli più bassi possono servire a quelle per livelli più alti;
> - ai livelli più alti si può usare tale informazione per riformulare un piano di ricerca;
> - il processo tipicamente non garantisce soluzioni ottimali perchè considera solo alcune delle decomposizioni possibili.

2.8.4. Uso della programmazione dinamica

La **programmazione dinamica, PD,** fornisce un metodo generale di ottimizzazione basato sulla memorizzazione di soluzioni parziali: una soluzione per un problema più semplice già prodotta dev'essere solo ritrovata e non ricalcolata.
Si può ricorrere alla PD per la costruzione offline di un'**euristica perfetta**, *coast_to_goal()*, che fornisca il costo esatto di un cammino completo di costo minimo su frafi finiti:

$$\text{cost_to_goal}(n) = \begin{cases} 0 & \text{se goal}(n) \\ \min_{\langle n,m\rangle \in A}[cost(\langle n,m\rangle) + \text{cost_to_goal}(m)] & \text{altrimenti} \end{cases}$$

calcolato uasndo LcFS + MPP sul grafo inverso a partire dai nodi-obiettivo: si cerca il cammino di costo minimo da ogni nodo verso i nodi-obiettivo e si converva il valore di *coast_to_goal* per ogni nodo.
Una **policy** è una politica da seguire nella specifica dell'arco da considerare per

ogni nodo; essa è **ottimale** se i suoi costi non sono mai superiori ai costi calcolati usando altre policy.

- *coast_to_goal* viene calcolata offiline e usata nella costruzione di una policy: da n si dovrebbe andare al vicino m che minimizza $cost(\langle n, m\rangle) + \text{cost_to_goal}(m)$. Questa policy porta sempre a un obiettivo con un cammino di costo minimo partendo da qualsiasi nodo;
- sono presenti della alternative:
  1. memorizzare il vicino per tutti i nodi offline, sfruttando le associazioni tra nodi nelle decisioni online sulle azioni, oppure
  2. fornire *cost_to_goal* pre-calcolata e calcolare i vicini online.

Riguardo la complessità si può dire in breve che:

1. PD è lineare in tempo e spazio rispetto alle dimensioni del granfo nella costruzione di *cost_to_goal*, tipicamente esponenziali nella lunghezza del percorso;
2. Data *cost_to_goal*, determinare l'arco migliore richiede tempo costante rispetto alla grandezza del grafo, essendoci un numero limitato di vicini per nodo.

La PD può servire a costruire euristiche per A^* e Branch-and-Bound: semplificando il problema fino a ottenere spazi di ricerca ridotti e trovando in tali spazi soluzioni di lunghezza ottimale; ciò definisce un DB di pattern usato nell'euristica per il problema originale.
La PD è utile quando i nodi-obiettivo possono essere elencati esplicitamente, la soluzione cercata è un cammino di costo minimo, il grafo ridotto è finito, con memoria sufficiente per contenere la tabella, l'obiettivo non cambia. La policy può essere riusata per i diversi nodi-obiettivo: si ammortizza il costo per produrre la tabella su diverse istanze dello stesso problema; tuttavia essa va calcolata per ogni diverso nodo-obiettivo.

Ragionamento con vincoli

3.1. Variabili e vincoli

Vedremo come passare da problemi definiti su spazi di stati a problemi su spazi definiti da caratteristiche. Le *caratteristiche*, o *feature*, vengono descritte attraverso l'uso di **variabili**, spesso non indipendenti fra loro, e di **vincoli rigidi** che specificano combinazioni lecite di assegnazioni alle variabili, e/o **vincoli flessibili**, ossia funzioni che codificano le preferenze fra le diverse assegnazioni.

Il *ragionamento* si svolge generando assegnazioni che soddisfino i vincoli rigidi e ottimizzino i vincoli flessibili.

3.1.1. Variabili e Assegnazioni

Si considereranno problemi descritti in termini di variabili *algebriche* ossia simboli usati per denotare caratteristiche del mondo (reale o immaginario).
La notazione adotta nomi che iniziano per maiuscola: ogni variabile ha un **dominio** associato, denotato con $dom(X)$. Si considereranno *variabili discrete* con dominio finito o almeno enumerabile. Un altro tipo è quello delle *variabili continue*, ad esempio variabili con dominio $\mathbb{R}$.
Un'**assegnazione** è una funzione da un insieme di variabili ai loro domini: dato $\{X_1, X_2, ..., X_k\}$ a X_i si assegna $v_i \in dom(X_i)$ per ogni $i = 1, ..., k$:

$$X_1 = v_1, X_2 = v_2, ..., X_k = v_k$$

Essendo una funzione a ogni variabile viene assegnato un solo valore. Un'**assegnazione totale** riguarda tutte le variabili, altrimenti si dice **parziale**. Un'assegnazione totale rappresenta uno stato del mondo, detto *mondo possibile*.
Date n variabili con domini di cardinalità d, si hanno d^n assegnazioni totali. L'uso delle variabili offre un *vantaggio*: con poche variabili si possono descrivere molti stati:

- con 10 variabili binarie: $2^{10} \approx 10^3$ stati;
- con 20 variabili binarie: $2^{20} \approx 10^6$ stati;
- con 30 variabili binarie: $2^{30} \approx 10^9$ stati;
- con 100 variabili binarie: $2^{100} \approx 10^{30}$ stati.

Ragionare con 30 variabili è più facile che con un miliardo di stati ma anche con 100 variabili non ci sarebbero grossi problemi, mentre è impraticabile ragionare esplicitamente con 2^{100} stati.
Tuttavia molti problemi reali possono essere definiti solo in termini di migliaia o anche milioni di variabili, come le previsioni del meteo.

3.1.2. Vincoli

Dato un problema, le assegnazioni possono essere *ammissibili* o *non ammissibili*.
Un **vincolo rigido** (*hard constraint*) specifica le assegnazioni lecite per una o più variabili e comprende:

- un **ambito**, detto *scope*, ossia l'insieme S di variabili coinvolte con una sua arietà $|S|$
- la **condizione**, una funzione booleana sulle assegnazioni alle variabili del vincolo che dovrà risultare vera solo per assegnazioni lecite.

Seguono alcuni esempi di vincoli di diverse arietà:

- $B \leq 3$ *unario*;
- $A \leq B$ *binario*;

- $A + B = C$ *ternario.*

La *definizione* di un vincolo può essere: **intensionale**, ossia in termini di formule logiche; **estensionale**, come elencazione delle assegnazioni lecite, come con le relazioni ovvero le tabelle di tuple nei DB relazionali.
Dati il vincolo c con ambito S e l'assegnazione A su variabili contenute in S, anche non tutte, si dirà che A soddisfa c se la condizione è vera per A ristretta all'ambito di c ovvero che A **viola** c in caso contrario.

Esempio 15 *(Gita)* **.** In una gita di quattro giorni, tre *attività* da svolgere possono essere rappresentate da variabili A, B, C tutte con identico dominio $\{1, 2, 3, 4\}$.
Si consideri il seguente vincolo in forma intensionale su $\{A, B, C\}$:

$$(A \leq B) \wedge (B < 3) \wedge (B < C) \wedge \neg(A = B \wedge C \leq 3)$$

esso richede che A non possa seguire B, B sia svolta prima del 3° giorno e comunque prima di C e, infine, che se A è concomitante con B, C si svolga dopo il 3° giorno.
Lo steso vincolo, definito estensionalmente elenca le assegnazioni lecite:

A	B	C
2	2	4
1	1	4
1	2	3
1	2	4

Ad esempio è soddisfatto da $\{A = 1, B = 2, C = 3, D = 3, E = 1$ in quanto in tabella si trova $\{A = 1, B = 2, C = 3\}$, ristretta al suo ambito.

3.1.3. Problema di soddisfacimento di vincoli

Un **problema di soddisfacimento di vincoli (CSP)** è definito da un insieme di variabili ognuna con un proprio *dominio* e un insieme di *vincoli*. Una sua **soluzione** è un'assegnazione totale che soddisfa tutti i vincoli.
Un *CSP finito* ha un numero finito di variabili di dominio finito. Oltre a metodi per CSP finiti, si prenderanno in considerazione anche algoritmi per casi con variabili dal dominio continuo. Molti esempi vengono dal mondo dei giochi, come il Sudoku o la Criptoaritmetica.

Esempio 16 *(Robot consegne)* **.** Si può costruire un CSP definendo:
- le attività da svolgere: a, v, c, d, e e i *momenti* possibili: $1, 2, 3, 4$;
- le rispettive variabili A, B, C, D, E, tutte con lo stesso dominio, ossia con $dom(A) = dom(B) = dom(C) = dom(D) = dom(E) = \{1, 2, 3, 4\}$;

- l'insieme dei *vincoli*:

$\{B \neq 3; C \neq 2; A \neq B; B \neq C; C < D; A = D; E < A; E < B; E < C; E < D; B \neq D\}$

Legati ai CSP, si possono definire diversi problemi di complessità crescente:
- determinare se esista una soluzione o meno;
- trovare una soluzione;
- contare il numero di soluzioni;
- enumerare tutte le soluzioni;
- trovare la soluzione migliore, rispetto a una data misura di qualità;
- determinare se alcuni enunciati siano veri per tutte le soluzioni.

I CSP possono risultare difficili per il loro carattere multidimensionale; il compito base è quello di trovare una soluzione. Già nel caso di CSP con domini finiti tale problema è NP-completo; metodi sistematici hanno una complessità esponenziale ma, ove possibile, si sfrutta la struttura dello spazio di ricerca.

3.2. Risoluzione di CSP tramite ricerca

Un algoritmo **Generate-And-Test** è un algoritmo *esaustivo* per CSP finiti semplce ma inefficiente. Per trovare una soluzione si generano e controllano in modo sistematico, una alla volta, le possibili assegnazioni totali; si restituirà la prima che soddisfa tutti i vincoli. Per trovare tutte le soluzioni si deve continuare a iterare, conservando le soluzioni via via trovate.
Si osservi che con n domini di cardinalità d si hanno d^n possibili assegnazioni totale; con e vincoli il numero totale di test è $O(ed^n)$: al crescere di n diventa rapidamente intrattabile, servono quindi soluzioni alternative.

3.2.1. Algoritmi su Grafo di Ricerca

In alternativa, si possono sfruttare *algoritmi di ricerca su grafo* per spazi di stati determinati dalle assegnazioni parziali. L'idea conduttrice è quella di testare i vincoli su assegnazioni parziali di ambito limitato crescente: se un'assegnazione parziale viola un vincolo, anche le assegnazioni totali che la estendono lo violeranno quindi è possibile potare lo spazio di ricerca.
Si può usare la DFS per cercare tutte le soluzioni di un CSP con variabili V_s e vincoli C_s, estendendo via via l'assegnazione parziale *contesto_parziale*, dove:
- V_s insieme delle variabili senza assegnazione in *contesto_parziale*;
- C_s insieme dei vincoli che coinvolgono almeno una variabile in V_s;
- chiamata iniziale: `DFS_solver` $(V_s, C_s, \emptyset)$.

Rispetto a Generate-And-Test, i test anticipati consentono di potare sotto-alberi, risparmiando lavoro.

Algoritmo 5 — *Risolutore di CSP tramite DFS*

```
1:  procedure DFS_solver(V_s, C_s, contesto_parziale)
2:  ce ← {c ∈ C_s | c  valutabile in  contesto_parziale}
3:  if contesto_parziale viola un vincolo in ce then
4:  |  return ∅
5:  else if V_s = ∅ then
6:  |  return contesto_parziale
7:  else
8:  |  selezionare una variabile var ∈ V_s
9:  |  sols ← ∅
10: |  for val ∈ dom(var) do
11: |  |  sols ← sols ∪
12: |  |       DFS_solver(V_s \ {var}, C_s \ ce, {var = val} ∪ contesto_parziale)
13: |  return sols
```

L'albero di ricerca risultante ha dimensioni che dipendono dall'ordine di scelta delle variabili. Un ordine *statica*, ad esempio sempre prima A, poi B, poi C, risulterà meno efficiente di uno *dinamico*. Ma l'ordine ottimale potrebbe essere più difficile da trovare.

3.3. Algoritmi basati su Consistenza

Si introduce una nozione di **consistenza** intesa come compatibilità, o coerenza logica, fra assegnazioni e vincoli. Una **rete di vincoli** (*constraint network*) indotta da un CSP è costituita da un *grafo bipartito*:

- un nodo *(circolare)* per ogni variabile, con un dizionario *dom* che, per ogni variabile X, contenga l'insieme $dom[X]$ di valori possibili, inizialmente impostato con l'intero suo dominio;
- un nodo *(rettangolare)* per ogni vincolo c;
- un arco $\langle X, c\rangle$ per ogni variabile X nell'ambito del vincolo c.

Un arco $\langle X, c\rangle$ si dice **consistente** *rispetto ai domini (domain consistent)* se e solo se $\forall x \in dom[X] : \{X = x\}$ soddisfa c.
Dato il vincolo c su $\{X, Y_1, ..., Y_k\}$, l'arco $\langle X, c\rangle$ è **consistente** se e solo se $\forall x \in dom[X], \exists y_1, ..., y_k : y_i \in dom[Y_i]$ tale che $\{X = x, Y_1 = y_1, ..., Y_k = y_k$ soddisfi c.
Una **rete consistente** contiene solo archi consistenti. Se $\langle X, c\rangle$ non è consistente allora per qualche valore di $dom[X]$ non ci sono valori di $Y_1, ..., Y_k$ tali che l'assegnazione risultante soddisfi c, quindi *eliminando* tali valori da $dom[X]$ si può ripristinare la consistenza di $\langle X, c\rangle$. È bene notare, però, che l'eliminazione di valori

da un dominio può rendere altri archi non consistenti.
L'idea di base è quella di rendere la rete consistente restringendo i domini. A tale scopo, si considera l'insieme *inconsistenti* degli archi potenzialmente non consistenti:

- si inizializza *inconsistenti* con tutti gli archi del grafo;
- si ripete fino a svuotare *inconsistenti*: estratto un arco $\langle X, c\rangle$ da *inconsistenti* se $\langle X, c\rangle$ non è consistente, si deve restringere $dom[X]$. Si devono, poi, aggiungere a *inconsistenti* gli archi resi non consistenti dal passo precedente: $\langle Z, c'\rangle, c' = c$, con ambito che comprende X e una diversa Z.

Algoritmo 6 — *Generalized Arc Consistency (GAC)*

```
1:  procedure GAC(V_s, dom, C_s, inconsistenti)
2:  while inconsistenti ≠ ∅ do
3:      selezionare e rimuovere ⟨X, c⟩ da inconsistenti
4:      {Y_1, ..., Y_k} ← ambito(c) \ {X}
5:      ND ← {x | x ∈ dom[X] ∧ ∃y_1 ∈ dom[Y_1], ..., y_k ∈ dom[Y_k] :
6:            c(X = x, Y_1 = y_1, ..., Y_k = y_k)}
7:      if ND ≠ dom[X] then
8:          inconsistenti ← inconsistenti ∪ {⟨Z, c'⟩ | {X, Z} ⊆ ambito(c'), c' ≠ c, Z ≠ X}
9:          dom[X] ← ND
10: return dom
```

GAC termina con una rete consistente con variabili dai domini *ridotti*. Tre casi sono possibili:

1. un dominio è vuoto quindi non ci sono soluzioni: se uno è vuoto, lo saranno anche altri domini ridotti ad esso connessi, già prima della terminazione;
2. i domini sono tutti ridotti a un solo valore, quindi la *soluzione è unica*;
3. altrimenti, si è ottenuto CSP semplificato cui applicare altri metodi.

Dei metodi alternativi sono algoritmi basati sulla **consistenza dei percorsi**.

3.4. Separazione dei domini

L'idea base degli algoritmi di **separazione dei domini** è quella di decomporre il CSP in una serie di *casi disgiunti* da risolvere separatamente; le soluzioni sono ricostruire riunendo quelle trovate per i diversi casi. Ad esempio:

- X binaria, dominio $\{t, f\}$, due problemi ridotti: trovare le soluzioni con $X = t$ e quelle con $X = f$; se ne basta una, secondo caso considerato solo se il primo non ha soluzione;
- A con dominio $\{1, 2, 3, 4\}$, ci sono diverse maniere per separare i valori:

- un caso per ciascun valore; ciò fa fare più strada con una sola suddivisione alla volta;
- due sottoinsiemi disgiunti: $A \in \{1, 2\}$ e $A \in \{3, 4\}$; questo taglia di più in meno passi.

Nel seguente schema di algoritmo si integra l'approccio basato sulla consistenza in un algoritmo ricorsivo:

1. si semplifica il CSP in input tramite `GAC()`
2. se non è risolto direttamente:
   1. si seleziona una variabile, con dominio almeno binario;
   2. si partiziona il dominio ottenendo (2+) problemi semplificati;
   3. si risolvono ricorsivamente tali problemi.

ALGORITMO 7 — *Risolutore ricorsivo basato su consistenza*

```
1:  procedure Con_Solve(V_s, dom, C_s, inconsistenti)
2:  dom_0 ← GAC(V_s, dom, C_s, inconsistenti)
3:  if ∃X : dom_0[X] = ∅ then
4:  |  return false
5:  else if ∀X : |dom_0[X]| = 1 then
6:  |  return soluzione con X = x ∈ dom_0[X]   ∀X
7:  else
8:  |  selezionare X tale che |dom_0[X]| > 1
9:  |  partizionare dom_0[X] in D_1 e D_2
10: |  dom_1 ← copia di dom_0 con dom_1[X] = D_1
11: |  dom_2 ← copia di dom_0 con dom_2[X] = D_2
12: |  inconsistenti ← {⟨Z, c'⟩ | {X, Z} ⊆ ambito(c'), Z ≠ X}
13: |  return Con_Solve(V_s, dom_1, C_s, inconsistenti) or
14: |       Con_Solve(V_s, dom_2, C_s, inconsistenti)
```

L'algoritmo fornisce tutte le soluzioni:

- se un dominio è vuoto non ci sono soluzioni;
- se il dominio ha un solo valore si ha una sola soluzione;
- ritornando dalla ricorsione restituisce l'unione delle soluzioni dei 2 casi;
- c'è modo di usare anche algoritmi di ricerca su grafo, ma qui contano le soluzioni e non i cammini.

Un possibile miglioramento è il seguente: se un'assegnazione rende il grafo *non connesso*, ogni componente può essere risolta separatamente. Si ricava facilmente una soluzione ricombinando le soluzioni delle componenti. Il conteggio del numero di soluzioni è fattibile in modo efficiente.

3.5. Eliminazione di Variabili

L'**eliminazione di variabili**, *variabile elimination (VE)*, è una tecnica che semplifica la rete dei vincoli rimuovendo variabili. L'idea di base è quella di eliminare progressivamente le variabili, una alla volta, ottenendo CSP semplificati da risolvere e infine, a partire dalle loro soluzioni, ricostruire quelle dei CSP più complessi: quando si elimina la variabile X si deve costruire un nuobo vincolo sulle rimanenti che rifletta gli effetti dei vincoli su X; esso sostituisce tutti i vincoli su X producendo una rete semplificata; alla fine, ogni soluzione di un CSP ridotto va estesa per ottenere una soluzione del CSP che ricomprenda anche X.
Per eliminare una variabile X:

1. considerate le relazioni relative a tutti i vincoli su X, sia $r_X\left(X, \overline{Y}\right)$ quella ottenuta dal join di tali relazioni, vincolo che codifica l'*influenza* di X su $\overline{Y}$, insieme delle altre variabili nell'ambito di r_X, vicine di X nel grafo dei vincoli;
2. la *proiezione* di r_X su $\overline{Y}$ sostituisce tutte le relazioni in cui occorre X;
3. si ottiene un CSP ridotto, senza la X, da risolvere ricorsivamente. Al ritorno delle chiamate ricorsive si estendono le tabelle-soluzioni per il CSP ridotto tramite join con r_X, per aggiungere la colonna delle assegnazioni a X. Nel caso-base resta una sola variabile, per cui la soluzione da restituire è la tabella con i valori del dominio consistenti con i vincoli.

Esempio 17. Si consideri un CSP con le variabili A, B, C di dominio $\{1, 2, 3, 4\}$ e sia B la variabile da eliminare, inclusa nei vincoli: $A < B$ e $B < C$. Per eliminarla, si fa il join tra le relazioni dei vincoli su B:

A	B
1	2
1	3
1	4
2	3
2	4
3	4

$\bowtie$

B	C
1	2
1	3
1	4
2	3
2	4
3	4

$=$

A	B	C
1	2	3
1	2	4
1	3	4
2	3	4

La proiezione della tabella-join su A e C induce una nuova relazione senza la B:

A	C
1	3
1	4

2	4

Tale vincolo sostituisce gli originari e contiene tutte le informazioni utili al resto della rete; con VE poi si risolve il resto della rete semplificata.
Per avere una o tutte le soluzioni a partire dalla soluzione del CSP ridotto: si memorizza la relazione del join su A, B, C per estendere la soluzione della rete ridotta includendo B.

Algoritmo 8 — *Eliminazione di Variabili*

```
1:  procedure VE_CSP(V_s, C_s)
2:  Input
3:      V_s: insieme di variabili
4:      C_s: insieme di vincoli su V_s
5:  Output
6:      relazione contenente tutte le assegnazioni consistenti
7:  if |V_s| = 1 then
8:      return join di tutte le relazioni in C_s
9:  else
10:     selezionare X ∈ V_s da eliminare
11:     CX ← {c ∈ C_s | X ∈ ambito(c)}
12:     R ← join di tutti i vincoli in CX
13:     NR ← proiezione di R sulle variabili V_s \ {X}
14:     S ← VE_CSP(V_s \ {X}, (C_s \ CX) ∪ {NR})
15:     return R ⋈ S
```

Seguono alcune osservazioni:

- *caos base*: rimane una sola variabile, quindi una soluzione esiste se ci sono righe nelle relazioni finali e saranno tutte relative a una sola variabile basterà intersecarle;
- caso *ricorsivo*: l'ordine di selezione delle variabili ha un impatto sull'efficienza; al ritorno se bastasse una soluzione, si restituisce solo una tupla di $R \bowtie S$. È garantito che sia parte d'una soluzione; se un valore di R non avesse tuple, non ci sarebbero soluzioni con tale valore.

VE può essere combinato con algoritmi basati su consistenza da usare per semplificare il problema quando si elimina una variabile. Le tabelle intermedie risulteranno più piccole.

3.6. Ricerca Locale

Nel caso di spazi molto grandi, o infiniti, non è pensabile una ricerca sistematica sull'intero spazio. Si può puntare su metodi *mediamente efficienti* per trovare soluzioni, ma *senza garanzie* di ritrovamento anche quando esistono. Perciò tali metodi sono utili quando si sa che, verosimilmente, ce ne sono.
La classe dei metodi di **ricerca locale**, comunemente investigati nell'ambito della *ricerca operativa* e dell'*AI*, comprende molte tecniche, con uno stesso schema-base:

ALGORITMO 9 — *Schema della Ricerca Locale*

```
1:  procedure Local_search(V_s, dom, C_s)
2:  Input
3:      V_s: insieme di variabili
4:      dom: funzione che restituisce il dominio di una variabile
5:      C_s: insieme di vincoli da soddisfare
6:  Output
7:      assegnazione totale che soddisfa i vincoli
8:  Local
9:      A: dizionario di valori indicizzato dalle variabili in V_s
10: repeat {try}
11:     for each X ∈ V_s do
12:         A[X] ← valore (casuale) da dom(X)
13:     {walk}
14:     while not ferma_walk() and A non soddisfa C_s do
15:         selezionare Y ∈ V_s e un valore w ∈ dom(Y)
16:         A[Y] ← w
17:     if A soddisfa C_s then
18:         return A
19: until terminazione
```

- si inizia con un'assegnazione totale di un valore a ciascuna variabile;
- si tenta di migliorare l'assegnazione iterativametne effettuando passi di *miglioramento*, passi *casuali* e *ripartenze* da assegnazioni iniziali differenti.

Ogni iterazione della `repeat` rappresenta un **tentativo** (*try*): con il primo ciclo `for each` si ha l'**inizializzazione casuale** di A; per ogni assegnazione casuale successiva si ha una **ripartenza casuale** in alternativa anche congetture più informate basate su euristiche o conoscenza pregressa, poi migliorate iterando. Nel ciclo `while` si effettua una **ricerca locale** (*walk*) nello spazio delle assegnazioni:

- si seleziona una assegnazione tra i possibili **successori** di A che differiscono per il valore assegnato a una sola variabile;
- si ha lo stop se si è trovata una soluzione o si avvera il criterio di `ferma_walk()`, ad esempio è stato raggiunto un numero massimo di iterate.

La fermata non è garantita: l'algoritmo può divergere se il CSP non ha soluzione. In alcuni casi, anche se ne esistessero, potrebbe rimanere intrappolato in una regione; una garanzia di *completezza* dipende dai criteri di selezione e di stop.
Random Sampling e la versione della ricerca locale in cui:

- `ferma_walk()` risulta sempre vera quindi il ciclo `while` non viene mai eseguito: si continua indefinitamente a provare assegnazioni casuali che possano soddisfare tutti i vincoli;
- l'algoritmo è completo ossia garantisce di trovare la soluzione se questa esiste, tuttavia il tempo richiesto non può essere limitato e tipicamente risulta molto lento;
- la sua efficienza dipende dalle dimensioni dei domini e dal numero di soluzioni esistenti.

Random Walk è la versione della ricerca locale in cui:

- `ferma_walk()` risulta sempre falsa per cui non si hanno ripartenze casuali: si esce dal ciclo `while` solo se si trova una soluzione e, nel ciclo, si ripete la selezione casuale di una variabile e un valore da assegnarle;
- l'algoritmo è completo con passi più veloci rispetto al resampling di tutte le variabili, ma può richiedere più passi, in base alla distribuzione delle soluzioni;
- in alternativa, quando le dimensioni dei domini delle variabili differiscono, si può selezionare a caso una variabile e poi un valore del suo dominio oppure selezionare casualmente una coppia variabile-valore, il che favorisce la selezione di variabili con dominio più grande.

3.6.1. Miglioramento Iterativo

L'approccio del **miglioramento iterativo** è un tipo di ricerca locale che prevede la selezione del *miglior successore* vicino all'assegnazione corrente in termini di una **funzione obiettivo**. Quando la funzione è da minimizzare (una funzione di *costo* o di *perdita*), il metodo prende il nome di *Greedy Descent*, *discesa sbrigativa*. Se, invece, è da massimizzare, il metodo prende il nome di *Greedy Ascent*, o anche **Hill Climbing**. Nel seguito si considereranno solo funzioni da *minimizzare*, per l'altro criterio sarà sufficiente cambiare il segno della funzione. Nei casi di parità di valore della funzione si opera una scelta casuale.
Si distinguono:

- **ottimi locali**, ossia assegnazioni non migliorabili da alcun successore, come i *minimi* o *massimi locali* trovati, rispettivamente, con *greedy descent* o *ascent*;

- **ottimi globali**, quelli con valutazione massima fra tutte le assegnazioni, che risultano comunque anche ottimi locali.

Una funzione di valutazione tipica per i CSP è il numero di **conflitti**, come i vincoli violati: un'assegnazione totale con 0 conflitti è una soluzione. Tale funzione può essere raffinata pesando i vincoli in maniera differenziata. Adottando il *numero di conflitti*, si dirà che un CSP è *soddisfacibile* se si trova un minimo globale con valore nullo ovvero è non soddisfacibile se il minimo globale ha valore positivo: se si trova un minimo locale con valore positivo, non è detto che esso sia globale, e quindi che il CSP non sia soddisfacibile.
Si considera il miglior successore anche quando questo non ha una migliore valutazione rispetto all'assegnazione corrente. È possibile che l'algoritmo trovi ottimi locali che risultano successori reciproci e che continui a passare da uno all'altro senza poter trovare una soluzione. Questo rende l'algoritmo *incompleto*.

3.6.2. Algoritmi stocastici

Per evitare minimi locali che non siano anche globali, negli **algoritmi stocastici** si ricorre a una maggiore casualità. Le mosse casuali previste saranno:

1. il **random restart**, in cui valori scelti a caso per tutte le variabili: costituisce una mossa casuale globale che consente di ripartire da regione anche completamente diverse dello spazio;
2. il **random step**, una mossa casuale locale da alternare a passi di ottimizzazione: utilizzata nel *Greedy descent / ascent* permette pasasi in direzione opposta in modo da sfuggire a minimi / massimi locali.

Integrando *massimo miglioramento iterativo* e mosse *casuali* si definiscono algoritmi per la **ricerca locale stocastica**.

Esempio 18 *(Spazi 2D)* **.** Si veda la seguente figura:

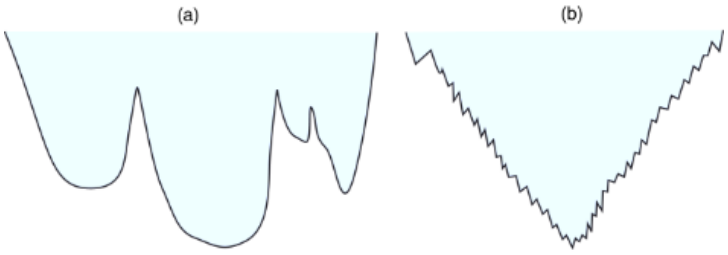


Figura 9: Due spazi di ricerca con caratteristiche diverse

Il *successore* si ottiene tramite un piccolo passo dall'attuale posizione verso sinistra o destra.

- spazio di ricerca (a): *Greedy descent* può trovare facilmente minimi locali, serve un *random restart* che porti nella parte centrale nella quale si converge

rapidamente verso uno globale; invece *random walk* non funzionerebbe bene; richiederebbe molti piccoli passi casuali per uscire da un minimo locale;
- spazio di ricerca (b): *random restart* rimane bloccato a cercare tra numerosi minimi locale mentre *random walk* con *greedy descent* potrebbe evitare tali minimi locali.

Con spazi con diverse caratteristiche in regioni differenti si può pensare di ricorrere a un **catalogo di algoritmi** da cui scegliere.

3.7. Varianti della ricerca Locale

Molte altre varianti sono possibili nella *scelta del successore* e nelle scelte *casuali*. Con domini *limitati* tutti i valori possono essere scelti per i successori. COn domini più estesi si possono considerare solo alcuni valori, risparmiando tempo, in genere si considerano solo quelli più vicini ai precedenti, ma esistono metodi più sofisticati di selezione.

3.7.1. Tabu Search

La **tabu search** è una forma di ricerca locale con memoria che evita la modifica di assegnazioni introdotte di recente. Si memorizzano le variabili modificate negli ultimi t passi (**tenure**) che andranno considerate non selezionabili. In tal modo si evitano i cicli dopo poche assegnazioni. Va ottimizzato il parametro t. Nella sua implementazione, se è piccolo si può considerare una lista delle variabili modificate di recente, invece se è grande si memorizza per ogni variabile il passo in cui si è avuto l'ultima sua modifica.

3.7.2. Passo di Massimo Miglioramento

In questo metodo di ricerca locale, si seleziona una coppia variabile-valore che porta al miglioramento di valutazione massimale. In caso di più coppie si opera una scelta casuale.
Nella sua implementazione «ingenua» data l'assegnazione totale corrente, per ogni variabile X e ogni valore $v \in dom(X)$ diverso da quello corrente, si confronta l'assegnazione corrente con quella in cui si assegna $X = v$. Si seleziona quindi una delle coppie di *massimo miglioramento*. Si noti che la modifica potrebbe portare a *differenze negative* nella valutazione, ossia a peggioramenti. Inoltre, le variabili non coinvolte in vincoli possono essere trascurate.
In un'implementazione alternativa si adotta una coda con priorità fatta di coppie variabile-valore pesate. Per ogni X e ogni $v \in dom(X)$ non assegnato in A, in coda ci sarà una coppia $\langle X, v \rangle$ con peso $w = h(A') - h(A)$. Si considera allora il miglioramento dell'assegnazione A' ottenuta sostituendo $X = v$ rispetto ad A. Questo dipenderà dai valori assegnati a X e dai suoi vicini nella rete dei vincoli, non da

quelli assegnati alle altre variabili. A ogni iterata si seleziona una *coppia-successore* di massimo miglioramento, ossia con *peso minimale*. Ogni nuova assegnazione comporta il ricalcolo dei pesi e il riordimento della coda, ma solo per coppie con variabili presenti in vincoli il cui soddisfacimento è mutato.

3.7.3. Scelta a due fasi

L'algoritmo di **scelta a due fasi** prevede la selezione della coppia articolata in:
1. selezione della variabile per la riassegnazione;
2. selezione del valore.

Si gestisce una coda con priorità di variabili con associato un peso pari al numero dei conflitti in cui ognuna sia coinvolta. Ad ogni passo:
1. si seleziona X che partecipa a più conflitti;
2. le si cambia il valore assegnato, scegiendolo fra quelli che minimizzano il numero di conflitti oppure casualmente.

Vanno infine ricalcolati i pesi per le variabili coinvolte in vincoli il cui soddisfacimento è mutato.

3.7.4. Algoritmo Any-Conflict

L'idea-base dell'algoritmo **Any-Conflict** è quella di scegliere, per la modifica, una **variabile conflittuale** ossia una che partecipa a uno o più conflitti. A ogni iterata: si seleziona casualmente una variabile conflittuale, non necessariamente quella con più conflitti, quindi le si assegna, in alternativa, un valore che minimizzi il numero di conflitti oppure un valore casuale.
Sono possibili alcune varianti, ad esempio cambiando il criterio di selezione casuale della variabile: si può scegliere prima un conflitto e poi una variabile coinvolta oppure si opera una semplice scelta casuale di una variabile conflittuale. La differenza fra i due criteri sta nella probabilità di selezione di una variabile: nel primo essa dipende dal numero di conflitti in cui la variabile è coinvolta, nel secondo si ha la stessa probabilità per tutte le variabili.

3.7.5. Simulated Annealing

Il **simulated annealing** prende in prestito una metafora dal dominio della *metallurgia* (ovvero della *termodinamica*): ad alte temperature l'algoritmo deve comportarsi con maggiore casualità o plasticità mentre a basse temperature deve consentire minore casualità in conseguenza una maggiore durezza. Come funzione di valutazione si adotta un'euristica basata sul numero di conflitti.
L'algoritmo riduce lentamente la temperatura cui è legata una misura di probabilità:
- ad *alte temperature* si deve comportare come *random walk* per poter evitare i minimi locali, alla ricerca di regioni con bassi valori dell'euristica, quindi i passi peggiorativi dovranno risultare più probabili;

- a *basse temperature* si deve comportare come *greedy descent*, portando direttamente verso i minimi (locali).

A ogni passo, data l'assegnazione corrente A: si sceglie a caso una variabile e un valore ottenendo una nuova assegnazione A'; se A' non peggiore l'euristica andrà a rimpiazzare l'assegnazione corrente, altrimenti può farlo ma con una probabilità che dipende dalla temperatura e dal valore dell'euristica.
Si consideri la seguente figura:

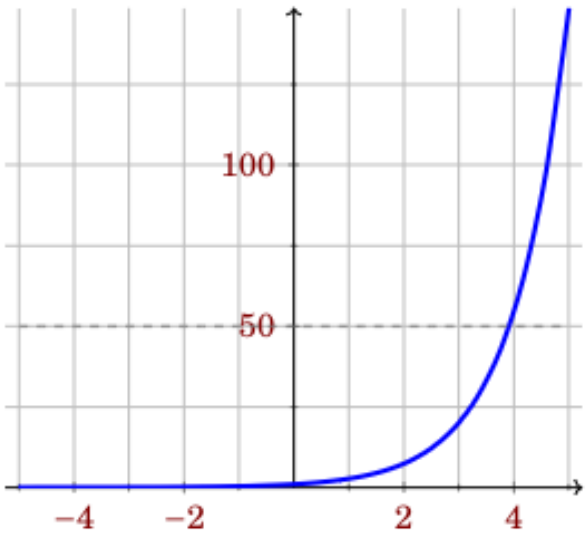


Figura 10: Una funzione esponenziale

Sia la **temperatura** $T \in \mathbb{R}_+$. Si consideri l'andamento della Figura 10.

- Sia $h(A)$ l'euristica da minimizzare, il numero di conflitti legati ad A;
- Se $h(A') \leq h(A)$, si accetta direttamente la nuova A' altrimenti, la si può accettare con probabilità (**distribuzione di Gibss / Boltzmann**):

$$\exp\left[-\frac{h(A') - h(A)}{T}\right]$$

Si noti che quando A' è peggiorativa, quindi l'esponente è negativo. Tendendo $h(A') - h(A)$ a 0, sarà più probabile accettare A'. Infatti ad alte temperature l'argomento dell'esponenziale tende a 0 e la probabilità a 1, mentre a basse temperature, l'esponente tende a $-\infty$ e la probabilità a 0.
Il cosidetto **problema di annealing** specifica cme ridurre la temperatura al progredire della ricerca: spesso si usa il *raffreddamento geometrico* che, ad esempio parte da $T = 10$ e si moltiplica per 0.99 ad ogni passo, arrivando a 0.07 dopo 500 passi. - a temperature alte, come $T = 10$, si tende ad accettare passi che peggiorano di poco, con una leggera preferenza rispetto a passi che migliorano;

- a temperature ridotte, come $T = 1$, i passi peggiorativi sono accettati molto meno frequentamente;
- a temperature basse, come $T = 0.1$, i passi peggiorativi sono accetti molto raramente.

3.7.6. Ripartenza casuale

L'algoritmo di **ripartenza casuale**, *random restart*, permette di migliorare le prestazioni di un *algoritmo causale debole*, uno che abbia successo in pochi casi specifici. Nel seguito sarà indicata con p la probabilità di successo d'una singola esecuzione. Per stimare le prestazioni di *random restart*, si considera una sequensza di n sue esecuzioni indipendenti.
La probabilità di successo in almeno una di tali esecuzioni sarà $1 - (1 - p)^n$ essendo $(1 - p)^n$ la probabilità di fallimento in tutti gli n tentativi.
Random restart risulta computazionalmente costoso quando sono coinvolte molte variabili. Nella sua variante *partial restart* si fanno assegnazioni solo ad alcune variabili, per consentire di spostarsi verso un'altra regione. In tal caso le esecuzioni non sono più indipendenti fra loro quindi si richiede un'analisi teorica più complessa.

3.8. Algoritmi basati su popolazioni

A differenza degli algoritmi esaminati in precedenza che considerano un'assegnazione alla volta, tali metodi gestiscono **popolazioni** di **individui**, ossia insiemi di assegnazioni. Nella *beam search* si considerano le migliori k assegnazioni, numero che può variare casualmente nella loro variante stocastica. Anche negli algoritmi evoluzionistici si considerano i migliori k individui nella metafora riproduttiva.

3.9. Beam Search

La **beam search** si comporta in maniera simile agli algoritmi di massimo miglioramento iterativo, con la differenza di lavorare simultaneamente su più assegnazioni (fino a k) anziché una sola. Essa ha successo quando viene trovata un'assegnazione che soddisfa tutti i vincoli. A ogni passo, si selezionano i migliori k successori. La selezione è casuale in caso di parità di valutazione. Si continua con il nuovo insieme di k assegnazioni.
In caso di *memoria limitata* si sceglie k in base alla memoria disponibile. È possibile usre le diverse varianti di ricerca locale viste in precedenza. Occorrerà ovviamte più tempo nel cercare i migliori k successori. Per una ricerca più rpida, si può ricorrere ad approssimazioni dei migliori k individui.

3.9.1. Beam Search Stocastica

In questa variante si selezionano k individui casualmente favorando quelli con valutazione migliore. La probabilità di selezione sarà definita in funzione dell'euristica: per un individuo A la probabilità di selezione (*distribuzione di Gibbs/Boltzmann*) proporzionale a:

$$\exp\left[\frac{-h(A)}{T}\right]$$

dove $h(A)$ è la funzione obiettivo e T una misura della temperatura. Questa variante consente più diversità nella popolazione: h riflette la capacità di *adattamento* come in biologia dove vale il principio di *sopravvivenza dei più adatabbili* per cui un individuo più adattabile ha maggiori probabilità di passare il proprio materiale genetico alle future generazioni.
Questa è interpretabile come una forma di *riproduzione asessuata* in cui si produce una discendenza leggermente mutata. Si osservi che gli stessi individui potranno essere selezionati casulamente anche più volte.

3.9.2. Algoritmi Genetici

Anche questi metodi sono definiti per gestire *popolazioni* di individui. Restando nella metafora evoluzionistica, il loro patrimonio genetico è rappresentato da un'assegnazione. Nuovi individui vengono creati dalla *combinazione* di *coppie* di *genitori* della generazione precedente. I migliori sono poi selezionati per far parte della generazione successiva.

Algoritmo 10 — *Schema di algoritmo genetico*

```
1:  procedure Genetic_algorithm(V_s, C_s, S, k)
2:  Input
3:      V_s: insieme di variabili
4:      C_s: insieme di vincoli da soddisfare
5:      S: programma di raffreddamento della temperatura
6:      k: dim. popolazione - intero pari
7:  Output
8:      assegnazione totale che soddisfa i vincoli
9:  Local
10:     Pop, NPop: insieme di assegnazioni
11:     T: numero reale
12: Pop ← insieme di k assegnazioni totali casuali
13: T inizializzato in base a S
14: repeat
15:     if ∃A ∈ Pop che soddisfa tutti i vincoli in C_s then
```

```
        return A
    NPop ← ∅
    repeat k/2 volte
        A_1 ← Random_selection(Pop, T)
        A_2 ← Random_selection(Pop, T)
        N_1, N_2 ← Crossover(A_1, A_2)
        NPop ← NPop ∪ {mutate(N_1), mutate(N_2)}
    Pop ← NPop
    T viene aggiornato in base a S
until terminazione
procedure Random_selection(Pop, T)
    selezionare A da Pop con probabilità proporzionale a e^{-h(A)/T}
    return A
procedure Crossover(A_1, A_2)
    selezionare casualmente un intero i, 1 ≤ i < |V_s|
    N_1 ← {(X_j = v_j) ∈ A_1 | j ≤ i} ∪ {(X_j = v_j) ∈ A_2 | j > i}
    N_2 ← {(X_j = v_j) ∈ A_2 | j ≤ i} ∪ {(X_j = v_j) ∈ A_1 | j > i}
    return N_1, N_2
```

Sono possibili diverse tecniche di selezione:

- *Selezione proporzionale alla fitness*: a ogni iterata, si generano k nuovi individui. Si opera una seleezione casuale delle coppie, che favorisca gli individui più adatti con probabilità dipendente dall'incremento della misura di fitness apportato e da una misura della temperatura. Per ogni coppia, si opera un *crossover* e si fanno *mutare* casualmente alcuni valori, per alcune variabili scelte a caso. Si passa infine a considerare la successiva generazione.
- *Selezione a torneo*: a ogni iterata si selezionano casualmente t individui (misura di *greediness*) e poi si scelgono i più adattabili fra questi.

Un'operazione di combinazione tipicamente utilizzata è il **crossover** che prevede la selezione di una coppia di individui e la conseguente generazione della loro prole ossia di individui ottenuti copiando parte delle assegnazioni da un genitore e il resto dell'altro. Si tratta di un'operazione aggiuntiva rispetto alla mutazione. Vi sono diverse forme di crossover:

- **crossover uniforme**: si considerano due individui genitore e si generano due figli; per ogni variabile, si copia nel primo figlio il valore da uno dei genitori scelto in maniera casuale, quello dell'altro genitore sarà copiato nel secondo figlio;
- **one-point crossover**: assumendo un *ordinamento* sulle variabili, si seleziona casualmente un indice i per generare ciascun figlio selezionando i valori per le variabili fino a i da un genitore e per le successive dall'altro. L'efficacia dipenderà dall'ordinamento scelto in fase di progettazione.

3.10. Ottimizzazione

A volte si hanno informazioni sulla preferibilità delle assegnazioni. Un **problema di ottimizzazione** richiede di trovare le migliori assegnazioni totali. Esso può essere formalizzato come segue, dati:

- un insieme di variabili con dominio associato;
- una **funzione-obiettivo** dalle assegnazioni totali a $\mathbb{R}$, tipicamente una funzione di costo/errore/loss;
- un **criterio di ottimalità**, tipicamente *minimizzare* la funzione-obiettivo.

Bisogna trovare un'assegnazione totale **ottimale** per il criterio adottato.
Un **problema di ottimizzazione vincolato** prevede anche *vincoli rigidi* che specificano le assegnazioni ammissibili. L'obiettivo è quello di trovare un'assegnazione ottimale ammissibile.
Sul tema dell'ottimizzazione esiste una vasta letturatura scientifica, con molte tecniche proposte: ad esmepio nella programamzione lineare sono coinvolte variabili continue, funzioni-obiettivo lineari e diseguaglianze lineari come vincoli. Quando un problema da risolvere, prevedendo anche qualche trasformazione, rientra in categorie classiche, allora converrà preferire algoritmi specifici.
Rispetto ai CSP, l'ottimizzazione presenta un'ulteriore difficoltà: riconoscere le soluzioni solo per confronto fra assegnazioni. Si possono trattare i vincoli rigidi come quelli flessibili ma assegnando un costo infinito in caso di violazione: se il costo è finito non vi sarà stata nessuna violazione. In alternativa si può associare alla violazione di vincolo rigido un costo elevato maggiore della somma di tutti i costi di vincoli flessibili. L'algoritmo di ottimizzazione dovrà trovare una soluzione con il minor numero di vincoli rigidi violati e, tra questi,, quelli di costo minimo.

3.10.1. Metodi Sistematici per il Caso Discreto

Si parla di **ottimizzazione discreta** in caso di problema che coinvolge solo variabili *discrete*. Possono essere adattati i metodi di ricerca di percorsi ottimali su grafo visti in precedenza. In questo caso il grafo avrà nodi contenenti assegnazioni a un insieme di variabili. I vicini di un nodo n si trovano scegliendo una variabile *var* non presente in n e le relative assegnazioni di valori, consistenti con gli eventuali vincoli rigidi. Il costo di un arco è dato dalla somma dei costi dei vincoli valutati dopo l'assegnazione a *var*.
Il nodo di partenza conterrà l'assegnazione vuota metnre un nodo-goal conterrà un'assegnazione totale. I costi sono assengati solo quando un vincolo flessibile può essere valutato. Per usare gli algoritmi A^*, *Branch-and-Bound* i costi-arco devono essere non-negativi.

3.10.2. Ricerca locale per l'ottimizzazione

L'uso della ricerca locale nel caso di problemi di ottimizzazione mira a minimizzare la funzione-obiettivo. Gli algoritmi di ricerca lcoale aggiornano via via e infine restituiscono la *migliore assegnazione trovata*. La terminazione può essere garantita fissando un numero massimo di iterate.
È difficile stabilire se un'assegnazione totale trovata sia ottimale: si ha un **ottimo locale** trovando un'assegnazione non peggiore di tutte le successive possibili; un **ottimo globale** è dato da un'assegnazione non peggiore di tutte le assegnazioni. Senza la ricerca sistematica non si può sapere se la migliore assegnazione trovata localmente costituisca un ottimo globale o se ne esiste altrove una migliore.
Per arrivare a una soluzione si può consentire la violazione di vincoli rigidi, ad esempio adottando costi di violazione alti ma finiti.

3.10.3. Domini Continui: Discesa di Gradiente

In questo caso, la ricerca locale è più complicata: bisogna stabilire come definire il *successore* di un'assegnazione.
L'idea dell'algoritmo di *Discesa del Gradiente (Gradient Descent)* è quella di minimizzare la funzione di valutazione (purchè continua e differenziabile). Come in un percorso in discesa, si fanno passi nelle direzioni più ripide. Il successore di un'assegnazione viene calcolato facendo un passo in discesa di lunghezza proporzionale alla *pendenza* della funzione, ossia alla sua derivata.
Esiste anche una ricerca di massimi di funzione obiettivo tramite *Risalita del Gradiente (Gradient Ascent)* facendo passi di segno positivo.
Nel caso *monodimensionale* se a X è assegnato $v \in \mathbb{R}$ il valore successivo sarà:

$$v - \eta \cdot \frac{df}{dX}(v)$$

dove η è la misura del pass che determina la rapidità della discesa; la derivata viene valutata in v:

$$\lim_{\varepsilon \to 0} \frac{f(X = v + \varepsilon) - f(X = v)}{\varepsilon}$$

Nel caso *multidimensionale* si fanno passi in tutte le direzioni, proporzionali a ogni *derivata parziale*. Date le variabili $\langle X_1, ..., X_n \rangle$ e un'assegnazione iniziale di valori $\langle v_1, ..., v_n \rangle$, l'assegnazione successiva si ottiene muovendosi lungo ogni direzione, in proporzione alla relativa pendenza di h. Il nuovo valore per X_i si ottiene calcolando:

$$v_i \leftarrow v_i - \eta \cdot \frac{\partial h}{\partial X_i}(\vec{v}) \quad \forall i = 1, ..., n$$

dove $\frac{\partial h}{\partial X_i}$ è la *derivata parziale* rispetto a X_i (le altre vengono trattate come costanti):

$$\frac{\partial h}{\partial X_i}(\vec{v}) = \lim_{\varepsilon \to 0} \frac{h(v_1, ..., v_i + \varepsilon, ..., v_n) - h(v_1, ..., v_i, ..., v_n)}{\varepsilon}$$

L'utilità dell'algoritmo sarà evidente nell'apprendimento automatico del valore dei parametri di un modello, anche nel caso di modelli complessi con 10^{12} parametri da ottimizzare.
Vi sono numerose **varianti**, ad esempio per η si può usare una forma di ricerca binaria per cercare un valore ottiamle, oppure potrebbe variare in funzione delle diverse iterate.
Per quanto riguarda la convergenza in caso di funzioni regolari con un minimo, GD converge a un minimo locale se η è sufficientemente piccolo. Qunado è troppo grande allora è possibile che diverga, se, invece è troppo piccolo esso converge molto lentamente. Se il minimo locale è unico allora sarà anche un minimo globale. In caso di più minimi locali è necessaria un'ulteriore ricerca per trovare il minimo globale. Ad esempio, si può usare *random restart* o *random walk*. È garantito il minimo globale solo quando sarà stato attraversato l'intero spazio di ricerca.

Rappresentazione e Ragionamentoi Proposizionale

4.1. Proposizioni

Le **proposizioni** sono *enunciati* che possono essere veri o falsi. Esse sono espresse in un linguaggio formale che si può descrivere in termini di sintassi e semantica, la **logica proposizionale**.
Il *ragionamento*, che potrà essere definito in termini di proposizioni, si propone obiettivi quali trovare modelli, trovare conseguenze logiche, formulare ipotesi e fare debugging della conoscenza descritta per correggere eventuali errori.

4.1.1. Sintassi del Calcolo Proposizionale

A ciascun enunciato, se formulato correttamente in un linguaggio basato su variabili booleano e connettivi logici, potrà poi essere associato un valore di verità.
Una **proposizione atomica**, o **atomo** viene rappresntato da un simbolo, condizionalmente una stringa alfanumerica, contenente eventuali «_», che inizi con una lettera minuscola. Esempi di atomi ben formati sono: *ai_divertente*, *piove*, *soleggiato*. Una **proposizione** o **formula logica** è costituita da atomo oppure da una proposizione **composta** formata usando connettivi logici e proposizioni più semplici. Nella seguente tabella sono elencate le diverse proposizioni composte che si possono formare a partire da due generiche proposizioni p e q:

sintassi	lettura	definizione
$\neg p$	«non p»	*negazione di p*
$p \wedge q$	«p e q»	*congiunzione di p e q*
$p \vee q$	«p o q»	*disgiunzione di p e q*
$p \rightarrow q$	«p implica q»	*implicazione di q da p*
$p \leftarrow q$	«p se q»	*implicazione di p da q*
$p \leftrightarrow q$	«p se e solo se q»	*equivalenza di p e q*
$p \oplus q$	«p XOR q»	*or esclusivo di p e q*

Vale il classico ordine di *precedenza* fra connettivi: $\neg, \wedge, \vee, \rightarrow, \leftarrow, \leftrightarrow, \oplus$. Si possono usare le parentesi per disambiguare e avere una maggiore leggibilità, ad esempio la proposizione

$$\neg a \vee b \wedge c \rightarrow d \wedge \neg e \vee f$$

si potrà scrivere nella forma equivalente

$$((\neg a) \vee (b \wedge c)) \rightarrow ((d \wedge (\neg e)) \vee f)$$

4.1.2. Semantica del Calcolo Proposizionale

La **semantica** definisce il significato degli enunciati, fornendo la corrispondenza tra simboli e stato del mondo che viene rappresentato. Ogni proposizione sarà *interpretabile* come vera o falsa rispetto allo stato del mondo: le proposizioni vere determinano il mondo conosciuto dal sistema, essendo un *atomo* l'unità minima che possa essere dotata di significato. Il significato delle proposizioni più complesse discenderà da quello degli atomi.

Un'**interpretazione** è definita come funzione: π : Atomi $\rightarrow$ {true, false}

- se $\pi(\alpha) =$ true, si dice che α **vero** nell'interpretazione π;
- se $\pi(\alpha) =$ false, si dice che α **falso** nell'interpretazione π.

Un'interpretazione si può anche definire come l'insieme I di tutti e soli gli atomi veri, ossia associati al valore di verità true. Tutti gli altri atomi saranno interpretati come associati a false.

Per associare i valori di verità alle proposizioni non atomiche, si dovranno considerare le tavole di verità dei connettivi, mostrate di seguito:

p	q	$\neg p$	$p \wedge q$	$p \vee q$	$p \leftarrow q$	$p \rightarrow q$	$p \leftrightarrow q$	$p \oplus q$
true	*true*	*false*	*true*	*true*	*true*	*true*	*true*	*false*
true	*false*	*false*	*false*	*true*	*true*	*false*	*false*	*true*
false	*true*	*true*	*false*	*true*	*false*	*true*	*false*	*true*
false	*false*	*true*	*false*	*false*	*true*	*true*	*true*	*false*

Si noti che la verità di una proposizione dipende solo dall'interpretazione dei suoi atomi. Una stessa proposizione ammette diverse interpretazioni per gli atomi contenuti, quindi potrà avere assegnati valori di verità diversi.
Una **base di conoscenza** (KB, *knowledge base*) è costituita da un insieme di proposizioni dette **assiomi**: essi sono dichiarati come veri. La base di conoscenza può essere vista come una congiunzione implicita degli assiomi, quindi sarà vera se tutti i suoi assiomi sono veri.
Gli assiomi servono a specificare il mondo da rappresentare attraverso quella che si dice la sua **interpretazione intesa**, ossia quella che dovrebbe risidere nella mente ell'esperto di dominio e che va formalizzata dall'ingegnere della conoscenza fornendo la sua assiomatizzazione. Nella **teoria dei modelli**, un **modello** di una base di conoscenza KB è un'interpretazione per la quale sia vero ogni assioma di KB.
La proposizione g, *goal*, è **conseguenza logica** di KB, ovvero g segue logicamente da KB se e solo se g vera in ogni modello di KB, in simboli:

$$KB \models g$$

In inglese questa relazione fra KB e g si dice *entailment*.
Quindi, se vale $KB \models g$, non esistono modelli di KB nei quali g sia falsa. In caso contrario, si può scrivere $KB \not\models g$ per dire che «g non è conseguenza logica di KB», ciò significa che esiste un modello di KB in cui g è falsa. Un caso da distinguere è quello in cui $KB \models \neg g$.
È bene notare che non vengono prese in considerazione altre possibili interpretazioni di g che non siano modelli di KB.

Esempio 19 *(Base di conoscenza)* **.** Data la KB contenente gli assiomi:

- *sam_felice*;
- *ai_divertente*;
- *vermi_vivono_sottoterra*;
- *sera*;
- *bruco_mangia_mela*;
- *mela_mangiata* $\leftarrow$ *bruco_mangia_mela*;
- *interruttore_acceso* $\leftarrow$ *sam_nella_stanza* $\wedge$ *sera*

si può scrivere:

- $KB \models$*bruco_mangia_mela*
- $KB \models$ *mela_mangiata*

mentre $KB \not\models$*interruttore_acceso* ossia esiste un modello di KB in cui *interruttore_acceso* è falso; tale modello, dovendo risultare vero l'ultimo assioma in KB, può essere definito assumento che *sam_nella_stanza* sia falso.

4.1.3. Semantica: punto di vista del progettista

Per caratterizzare un dominio / mondo, il progettista della KB lo definisce come **interpretazione intesa**: il significato dei simboli viene definito attraverso proposizioni, ossia assiomi che si possono assumere veri rispetto a tale stato del mondo, quindi le conseguenze logiche di KB saranno vere rispetto all'*interpretazione intesa*. Il significato viene così condiviso e potrà essere usato per interpretare le risposte a interrogazioni della KB.

Metodologia di Costruzione di Basi di Conoscenza

Il progetto della base di conoscenza KB si sviluppa nelle seguenti fasi:

1. SI sceglie il dominio/mondo da rappresentare, ossia l'interpretazione intesa. Questo può comprendere sia aspetti del mondo reale, un mondo immaginario oppure un dominio astratto come quello numero e/o dell'insiemistica.
2. Si scelgono gli atomi per rappresentare le proposizioni d'interesse, la cosiddetta **concettualizzazione**, cui associare un significato preciso rispetto all'interpretazione intesa.
3. Si definiscono gli assiomi di KB, ossia proposizioni vere nell'interpretazione intesa, l'**assiomatizzazione** del dominio applicativo per il sistema.
4. Si pongono al sistema domande sull'interpretazione intesa; le sue risposte dovranno essere interpretate in base ai significati associati ai simboli.

4.1.4. Semantica: Punto di vista della Macchina

Il sistema elabora la KB per decidere se g è vera nell'interpretazione intesa. I modelli di KB rappresentano tutti e soli i modi in cui il mondo potrebbe essere fatto. Data una concettualizzazione e un'assiomatizzazione corrette, l'interpretazione intesa sarà uno dei modelli di KB, ma il sistema non sa determinarlo esattamente.

Il sistema deve determinare se $KB \models g$: se $KB \models g$, esso potrà concludere che g sarà vera nell'interpretazione intesa, essendo g vera in tutti i modelli di KB. Se, invece, $KB \not\models g$, allora non può trarre conclusioni: g potrebbe essere falsa proprio nell'interpretazione intesa ma il sistema non può stabilirlo dato che non la conosce. Queste forme di inferenza sono implementate dalle procedure di dimostrazione trattate nel seguito.

È bene notare che $KB \not\models g$ non comporta necessariamente che $KB \models \neg g$.

Inoltre, si noti che il progettista può sbagliare e codificare nella KB assiomi falsi nell'interpretazione intesa. In tali casi non può essere garantito che le risposte della macchina siano vere in tale interpretazione.

4.2. Vincoli Proposizionali

Si considereranno ora CSP con vincoli rappresentati come *formule logiche* dalla struttura concisa e formale per consentire l'elaborazione automatica.
Un *problema* di **soddisfacibilità proposizionale (SAT)** è definito da:

- un insieme di *variabili booleane*; si usa la sintassi $X = true$ abbreviata in x, e $X = false$ oppure $\neg x$.
- un insieme di *vincoli clausali* o **clausole**, ossia espressioni logiche della forma:

$$l_1 \vee l_2 \vee \cdots \vee l_k$$

  in cui ogni **letterale** l_i è un atomo a o la sua negazione $\neg a$, ossia un'assegnazione a una variabile booleana; si dirà che a *occorre negativamente* (risp. *positivamente*) nel letterale $\neg a$ (risp. a).

La clausola $l_1 \vee l_2 \vee \cdots \vee l_k$ è vera in un'interpretazione se e solo se $\exists i \in \{1, ..., k\}$: l_i vero in tale interpretazione. In tal casol, si dice anche che il vincolo clausale è *soddisfatto*.
In Logica Proposizionale, una clausola è una forma logica in una forma ristretta. Esiste un algoritmo di conversione per cui ogni proposizione può essere convertita in forma di clausola.
Nei CSP, una clausola è un vincolo su un insieme di variabili booleane che è soddisfatto se almeno uno dei suoi letterali è vero: $l_1 \vee l_2 \vee \cdots \vee l_k$ equivale a $\neg(\neg l_1 \wedge \neg l_2 \wedge \cdots \wedge \neg l_k)$, ciò esclude che le assegnazioni in cui tutti i letterali risultino falsi.

4.2.1. Forma Clausale per CSP

Un CSP finito si può trasformare in un problema di soddisfabilità di una KB proposizionale in cui:

- per ogni variabile Y del CSP, con $dom(Y) = \{v_1, ..., v_k\}$ si considerano le **variabili indicatrici** booleane $\{Y_1, ..., Y_k\}$ tali che $\forall i = 1, ..., k : Y_i$ vera se $Y = v_i$ e falsa altrimenti; quindi per rappresentare Y in KB si considereranno gli atomi $y_1, ..., y_k$;
- si aggiungeranno a KB le seguenti clausole:
  - $\neg y_i \vee \neg y_j \big(\equiv \neg\big(y_i \wedge \neg y_j\big)\big)$ per ogni $i, j \in \{1, ...k\}$ con $i < j$, poichè y_i e y_j non possono essere entrambi veri;
  - $y_1 \vee \cdots \vee y_k$, poichè uno degli y_i dev'essere necessariamente vero, ossia Y avrà un certo valore i nell'assegnazione totale;
- per ogni vincolo del CSP, si definirà una clausola per ogni assegnazione che lo violi:
  - $\neg(l_1 \wedge l_2 \wedge \cdots \wedge l_k)$ che equivale a $\neg l_1 \vee \neg l_2 \vee \cdots \vee \neg l_k$, ad esempio letterali per le assegnazioni alle Y_i non ammesse dal vincolo;

- per semplificare, si possono combinare le clausole; ad esempio, combinando $a \vee b \vee c$ con $a \vee b \vee \neg c$ si ha $a \vee b$.

Esempio 20. Considerando le variabili A e B con dominio $\{1, 2, 3, 4\}$
- per A, le variabili indicatrici saranno a_1, a_2, a_3 e a_4 con a_i vera se e solo se $A = i$, variabili disgiunte che coprono tutti i casi per cui, in tutto, 7 clausole:

$$\neg a_1 \vee \neg a_2, \neg a_1 \vee \neg a_3, \neg a_1 \vee \neg a_4, \neg a_2 \vee \neg a_3, \neg a_2 \vee \neg a_4, \neg a_3 \vee \neg a_4, a_1 \vee a_2 \vee a_3 \vee a_4$$

- analogamente per B;
- il vincolo $A < B$ implica che a_4 sika falsa, b_1 falsa e le coppie che lo violano siano parimenti false quindi un totale di 5 clausole: $\neg a_4, \neg b_1, \neg a_2 \vee \neg b_2, \neg a_3 \vee \neg b_3, \neg a_3 \vee \neg b_2$. Si noti che non serve $\neg a_1 \vee \neg b_1$ già implicata da $\neg b_1$.

L'algoritmo **DPLL Davis-Putnam-Logemann-Loveland** prevede:
- la riduzione dei domini e dei vincoli;
- la separazione dei domini;
- l'assegnazione di letterali *puri*.

L'algoritmo risulta efficiente con strutture dati indicizzate ad hoc.

4.3. Clausole Definite Proposizionali

Il linguaggio delle **clausole definite proposizionali** è un sottolinguaggio della logica proposizionale con la stessa semantica. Esso ammette una forma più specifica di proposizioni, le clausole con un unico letterale positivo della forma seguente:

$$a \vee \neg b_1 \vee \cdots \vee \neg b_m$$

Le *proposizioni atomiche* o *atomi* sono gli stessi della logica proposizionale. Valendo l'equiivalenza $A \vee \neg B \equiv A \leftarrow B$, una **clausola definita** proposizionale si può scrivere come segue:

$$h \leftarrow a_1 \wedge \cdots \wedge a_m$$

formula che si legge «h se a_1 e $\cdots$ e a_m». In tale formula, h si dice **testa** (*head*) e $a_1 \wedge \cdots \wedge a_m$ si dice **corpo** della clausola.
Una clausola definita è una **regola** se $m > 0$ (ossia ha un corpo che rappresenta una condizione), altrimenti è un **fatto** o **clausola atomica** quando $m = 0$ nel qual caso si può omettere $\leftarrow$.
Una **base di conoscenza** può essere specificata come insieme di clausole definite.
La clausola $h \leftarrow a_1 \wedge \cdots \wedge a_m$ è falsa nell'interpretazione I se $a_1, ..., a_m$ sono tutti veri in I ma h è falsa, altrimenti essa è vera in I.
La clausola definita è una forma ristretta di clausola nella quale compare esattamente un letterale positivo. Ad esempio, $a \leftarrow b \wedge c \wedge d$ è equivalente a $a \vee \neg b \vee \neg c \vee$

$\neg d$. Essa non può rappresentare una qualunque disgiunzione3 di atomi, nemmeno se tutti negati.

Esempio 21 *(Scheda impianto elettrico)* **.** Si consideri un ambiente intelligente per la simulazione (diagnostica) come quello nella figura sottostante:

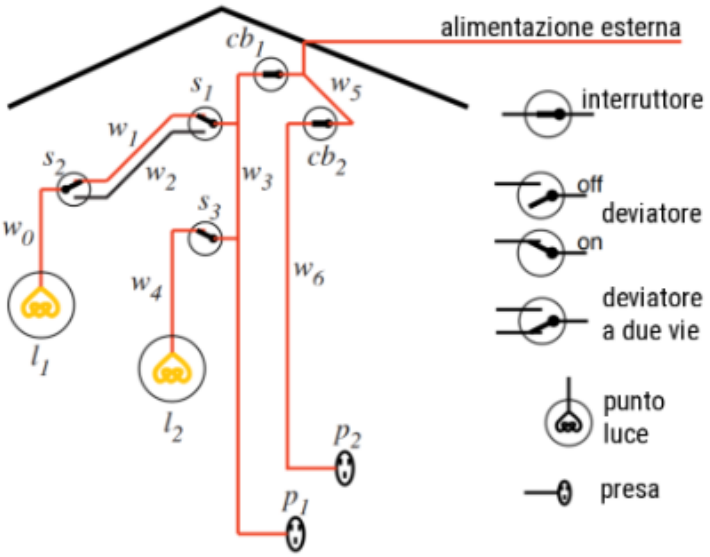


Figura 11: Impianto elettrico

- si definisce una *rappresentazione* dello stato di cavi (*wire*), prese (*outlet*), luci, deviatori (*switch*) e fusibili (*circuit breaker*), ecc.. I dettagli trascurabili non verranno modellati (ad es. colori, peso, lunghezze, altezze, ecc.);
- bisogna decidere il *livello di astrazione* per la rappresentazione: per *specialisti* (i voltaggi, le correnti, le frequenze, …) oppure comprensibile anche a non specialisti (in base al *senso comune*);
- poi si decide *cosa* rappresentare: proposizioni su accensione luci, funzionamento cavi, stato deviatori, ecc.;
- si definiscono *atomi* con significati precisi per il mondo da modellare: nomi descrittivi come *su_d2* per indicare che il deviatore *d2* è in posizione *su* oppure *alimentata_l1* che indica che il punto-luce *l1* è sotto tensione.
- si definisce anche la *conoscenza di fondo* (*background knowledge*, BK) che fornisce altri fatti veri riguardo il mondo, ed è rappresentata nel sistema attraverso altre clausole definite, spesso in forma semplice, come fatti:
  - *luce_l1.*
  - *luce_l2.*
  - *ok_l1.*
  - *ok_l2.*
  - *ok_f1.*
  - *ok_f2.*
  - *alimentazione_esterna.*

- si può anche considerare una parte del dominio e definire altre *regole*:
  - alimentata_l1 ← alimentato_c0.
    «(luce) « *l1* « alimentata se (cavo) « *c0* « sotto tensione»
  - alimentato_c0 ← alimentato_c1 ∧ su_d2.
  - alimentato_c0 ← alimentato_c2 ∧ giu_d2.
  - alimentato_c1 ← alimentato_c3 ∧ su_d1.
  - alimentato_c2 ← alimentato_c3 ∧ giu_d1.
  - alimentata_l2 ← alimentato_c4.
  - alimentato_c4 ← alimentato_c3 ∧ su_d3.
  - alimentata_p1 ← alimentato_c3.
  - alimentato_c3 ← alimentato_c5 ∧ ok_f1.
  - alimentata_p2 ← alimentato_c6.

  - alimentato_c6 ← alimentato_c5 ∧ ok_f2.
  - alimentato_c5 ← alimentazione_esterna.
  - accesa_l1 ← luce_l1 ∧ alimentata_l1 ∧ ok_l1.
  - accesa_l2 ← luce_l2 ∧ alimentata_l2 ∧ ok_l2.
- a run-time, si forniranno al sistema delle *osservazioni*, ad es. fatti sullo stato dei deviatori, come:
  - *giu_d1.*
  - *su_d2.*
  - *su_d3.*

4.3.1. Domande e Risposte

Si deve determinare la verità di fatti riguardanti il mondo ossia il dominio rappresentato:

- un utente può porre domande sulle conseguenze logiche della base di conoscenza fornita alla macchina;
- il sistema è in grado di dare risposte decidendo se date proposizioni seguano logicamente dalla base di conoscenza o meno;
- l'utente potrà comprendere il significato di tali risposte, se conosce la semantica degli atomi utilizzati.

A tale scopo si definisce una **query**, ossia una domanda utile a sapere se una data proposizione segua logicamente da una base di conoscenza, denotata con:

ask *b*

dove b è un atomo o una congiunzione di atomi il che corrisponde al corpo di una regola: $\leftarrow b_1 \wedge \cdots \wedge b_m$.
Le risposte possibili sono:

- yes se b è conseguenza logica, $KB \models b$;
- no altrimenti, $KB \not\models b$: ciò significa che b sia falso in un modello della KB, non necessariamente nell'interpretazione intesa, ma non è possibile determinarlo con la conoscenza disponibile.

4.3.2. Dimostrazioni

La relazione $\models$ definisce le risposte corrette secondo la *teoria dei modelli*. La **teoria ella dimostrazione**, *proof theory*, si occupa invece di come calcolare tqali risposte, ossia della dimostrazione delle conseguenza logiche. Si tratta di un problema di *deduzione*, una forma di *inferenza*.
Una **prova**, (*proof*), è una dimostrazione, derivabile anche *automaticamente*, del fatto che una proposizione seuga logicamente da un insieme di assiomi. Una proposizione dimostrabile si dice anche **teorema**.
Una **procedura di dimostrazione**, *proof procedure*, è un algoritmo, eventualmente non deterministico, utile a costruire prove. Data una procedura di dimostrazione, si denota con

$$KB \vdash g$$

la possibilità di produrre attraverso al procedura una prova del fatto che g sia conseguenza di KB.
Le proprietà più importanti delle procedure riguardano le relazioni tra prove e modelli:

- una procedura è **corretta** (*sound*) se e solo se ogni proposizione dimostrata dalla procedura è conseguenza logica di KB:

$$\text{se } KB \vdash g \text{ allora } KB \models g$$

- una procedura è **completa** se e solo se ogni conseguenza logica di KB può essere dimostrata dalla procedura:

$$\text{se } KB \models g \text{ allora } KB \vdash g$$

Esistono due tipi principali di procedure: le *bottom-up (BU)* e le *top-down (TD)*.

4.3.3. Procedura Bottom-Up

L'obiettivo di una procedura *bottom-up* è quello di derivare tutte le conseguenze logiche di una base di conoscenza. A tal fine si costruisce la prova gradualmente, basandosi su quanto è stato già dimostrato. Si procede per **concatenazione in avanti** (*forward chaining*) su clausole definite, derivando fati nuovi a partire da quanto è già stato dimostrato.

A tal fine si impiega una sola *regola di derivazione* che costituisce una generalizzazione della **regola d'inferenza** detta **modus ponens**

$$\frac{p \to q \quad p}{q}$$

Se $h \leftarrow a_1 \wedge \cdots \wedge a_m$ è in KB e ogni a_i è già stato provato, allora si potrà derivare h. Ogni fatto $(m = 0)$ in KB è un assioma quindi viene considerato immediatamente provato.
La seguente procedura trova C, l'*insieme delle conseguenze* di KB:

ALGORITMO 11 — *Procedura bottom-up*

```
1:  procedure Prove_DC_BU(KB)
2:  Input
3:  |  KB: insieme di clausole definite
4:  Output
5:  |  insieme di tutte le conseguenze logiche di KB
6:  Local
7:  |  C: insieme di atomi
8:  C ← ∅
9:  repeat
10: |  selezionare h ← a_1 ∧ ... ∧ a_m da KB
11: |      tale che ∀i : a_i ∈ C e h ∉ C
12: |  C ← C ∪ {h}
13: until nessuna clausola selezionabile
14: return C
```

La risposta restituita è `yes` ossia $KB \vdash g$ quando $g \in C$, se g atomica, ovvero quando $\{g_1, ..., g_k\} \subseteq C$ se g è una congiunzione di atomi $g_1 \wedge \cdots \wedge g_k$.

ESEMPIO 22. KB con gli assiomi:

- $a \leftarrow b \wedge c.$
- $b \leftarrow d \wedge e.$
- $b \leftarrow g \wedge e.$
- $c \leftarrow e.$
- $d.$
- $e.$
- $f \leftarrow a \wedge g.$

La traccia dei valori (insiemi) assegnati via via a C è la seguente:

- $\{\}$
- $\{d\}$
- $\{e, d\}$
- $\{c, e, d\}$
- $\{b, c, e, d\}$
- $\{a, b, c, e, d\}$

Da $C = \{a, b, c, e, d\}$ si può concludere che $KB \vdash a$, $KB \vdash b$, ecc.
Si noti che:

- non viene mai usata l'ultima regola di KB;
- non si riesce a provare né f né g, difatti c'è un modello della KB in cui f e g sono entrambe false.

La procedura bottom-up gode delle seguenti proprietà:

- *Punti Fissi*: C restituito è un **minimo punto fisso**:
  - ogni ulteriore applicazione della regola di derivazione non lo cambia;
  - detta I l'interpretazione in cui ogni atomo in C è vero e tutti gli altri sono falsi, I dev'essere un modello di KB;
  - I è un modello minimale di KB: ha il minor numero di proposizioni vere tra tutti i suoi modelli.
- *Correttezza*: ogni atomo in C è la conseguenza logica di KB
  - se $KB \vdash g$ allora $KB \models g$
- *Completezza*: tutte le conseguenze logiche sono derivabili
  - se $KB \models g$ allora g è vera in ogni modello di KB quindi anche in quello minimo, ovvero in C, per cui $KB \vdash g$.

4.3.4. Procedura Top-Down

Tale procedura effettua una ricerca *retrogada top-down* a partire da una query per determinare se questa segua logicamente dalle clausole di KB. Essa si basa su una diversa regola di ragionamento detta **risoluzione**:

$$\frac{l_1 \vee \cdots \vee a \vee \cdots \vee l_r \quad l'_1 \vee \cdots \vee \neg a \vee \cdots \vee l'_m}{l_1 \vee \cdots \vee l_r \vee l'_1 \vee \cdots \vee l'_m}$$

si noti che si applica alla forma generale delle clausole: basta individuare un atomo che compare positivamente in una delle due premesse e negativamente nell'altra.
In particolare, si usa la **risoluzione SLD** (Selezione di un atomo usando una strategia Lineare su clausole Definite):

$$\frac{a \leftarrow a_1 \wedge \cdots \wedge \underline{a_i} \wedge \cdots \wedge a_r \quad a_i \leftarrow b_1 \wedge \cdots \wedge b_m}{a \leftarrow a_1 \wedge \cdots \wedge \underline{b_1 \wedge \cdots \wedge b_m} \wedge \cdots \wedge a_r}$$

versione *proposizionale* di una forma più generale presentata in seguito.

Procedura Top-Down con Clausole di Risposta

Una **clausola di risposta** ha la forma

$$\text{yes} \leftarrow a_1 \wedge a_2 \wedge \cdots \wedge a_m$$

dove *yes* è un atomo *speciale*, vero se la risposta alla query è *yes*.
Data la query ask $q_1 \wedge \cdots \wedge q_m$, si parte dalla clausola di risposta iniziale

$$\text{yes} \leftarrow q_1 \wedge \cdots \wedge q_m$$

successivamente si ripete:

- la *selezione* di un atomo del corpo da dimostrare;
- la *scelta* di una clausola definita in KB avente come testa l'atomo selezionato per effettuare un passo di **risoluzione**; qualora non vi fossero altre clausole per dimostrare l'atomo selezionato, la dimostrazione *fallisce*.

Il **risolvente** della clausola di risposta e della clausola scelta sarà una nuova clausola di risposta:

$$\frac{\text{yes} \leftarrow \underline{a_1} \wedge a_2 \wedge \cdots \wedge a_m \quad a_1 \leftarrow b_1 \wedge \cdots \wedge b_p}{\text{yes} \leftarrow b_1 \wedge \cdots \wedge b_p \wedge a_2 \wedge \cdots \wedge a_m}$$

In sostanza l'atomo *goal* selezionato (a_1) viene sostituito dal corpo della clausola scelta.
In una dimostrazione di successo si raggiunge la **risposta**, ossia una clausola di risposta con corpo vuoto (tutti i goal sono stati dimostrati):

$$\text{yes} \leftarrow$$

Nella **derivazione SLD** per una query ask $q_1 \wedge \cdots \wedge q_k$ da KB si avrà una sequenza di clausole di risposta $\gamma_0, \gamma_1, ..., \gamma_n$ tali che:

- γ_0 è la clausola di risposta che ingloba la *query originaria* $\text{yes} \leftarrow q_1 \wedge \cdots \wedge q_k$;
- γ_i è il *risolvente* di γ_{i-1} con una clausola definita in KB;
- γ_n è la *risposta*.

Procedura Top-Down Alternativa

Si parte da un insieme G (*goal*) di *atomi da dimostrare*, quindi:

- si inizializza G con tutti gli atomi della query (*sotto-goal*) quindi G corrisponde a $\text{yes} \leftarrow \bigwedge_{g_i \in G} g_i$;
- selezionato a, la clausola scelta $a \leftarrow b_1 \wedge \cdots \wedge b_p$ indica che a può essere sostituito in G dai sotto-goal $b_1, ..., b_p$;
- si ha una terminazione con successo se $G = \emptyset$

ALGORITMO 12 — *Algoritmo Top-Down*

```
1: non-deterministic procedure Prove_DC_TD(KB, Query)
2: Input
3:     KB: insieme di clausole definite
4:     Query: insieme di atomi da dimostrare
5: Output
6:     yes se KB ⊨ Query, altrimenti fallisce (no)
```

```
Local
    G: insieme di atomi
G ← Query
repeat
    selezionare un atomo a ∈ G
    scegliere da KB una clausola definita a ← B con a come testa
    {se possibile, altrimenti il tentativo fallisce}
    G ← (G \ {a}) ∪ B
until G = ∅
return yes
```

Qualsiasi atomo di G può essere selzionato (tutti lo saranno). Se una seleziona non porta a terminare la prova, non serve tentarne selezionarne un altro, l'intera dimostrazione fallisce.
La procedura di *scelta* della clausola per la risoluzione è non deterministica. Se ci sono scelte che portano a G vuoto, l'algoritmo ha successo, altrimenti il tentativo fallisce.
Il corpo della clausola B e G sono considerati come insiemi di atomi. In alternativa G può essere costituito da una lista ordinata di atomi che possono occorrere più volte.

Esempio 23. Data la base di conoscenza con le seguenti clausole:

- $a \leftarrow b \wedge c.$
- $b \leftarrow d \wedge e.$
- $b \leftarrow g \wedge e.$
- $c \leftarrow e.$
- $d.$
- $e.$
- $f \leftarrow a \wedge g.$

e la query: *ask* a.
Si userà un insieme di goal G in luogo del corpo della clausola di risposta $yes \leftarrow G$, inizialmente gli atomi (della query) da dimostrare: $G = \{a\}$; si seleziona sempre l'atomo *più a sinistra* del corpo. I passi sono i seguenti:

risolventi γ_i	clausole da KB
$yes \leftarrow \underline{a}$	$a \leftarrow b \wedge c$
$yes \leftarrow \underline{b} \wedge c$	$b \leftarrow d \wedge e$
$yes \leftarrow \underline{d} \wedge e \wedge c$	d
$yes \leftarrow \underline{e} \wedge c$	e
$yes \leftarrow \underline{c}$	$c \leftarrow e$
$yes \leftarrow \underline{e}$	e

$$yes \leftarrow$$

Una sequenza *alternativa* di scelte in cui si sceglie la seconda clausola per b è la seguente:

- $yes \leftarrow a$
- $yes \leftarrow b \wedge c$
- $yes \leftarrow g \wedge e \wedge c$

ma selezionando g non ci sono regole da scegliere, per cui *questo tentativo fallisce*: occorre scegliere altre alternative, se ve ne sono.

Algoritmo TD su Grafo di Ricerca

Si può anche pensare a un algoritmo alternativo indotto dalla strategia di selezione basato su *grafo di ricerca* in cui:

- i *nodi* contengono clausole di risposta (bastano gli atomi nei loro corpi);
- i *vicini* di yes $\leftarrow \underline{a_1} \wedge \cdots \wedge a_m$ rappresentano tutte le possibili clausole di risposta ottenute risolvendo su a_1 e possono essere generati dinamicamente, uno per ogni clausola definita con testa a_1;
- i *nodi obiettivo* sono del tipo yes $\leftarrow$
- si può usare qualsiasi metodo di ricerca su grafo: basta trovare un percorso di successo perchè la query sia conseguenza logica della base di conoscenza; per ogni nodo, lo spazio viene determinato dalla query e dall'atomo selezionato.

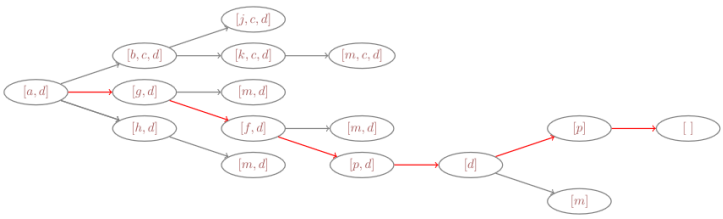


Figura 12: Albero di ricerca generato dall'algoritmo alternativo

Confronto fra procedure

Le dimostrazioni TD e BU sono interscambiabili: ciò può essere utile a provare la correttezza e la completezza della TD. La BU prova ogni atomo una sola volta mentre TD potrebbe provare lo stesso atomo più volte, ma si concentra su quelli rilevanti per la query. Con TD sono possibili cicli infiniti.

Esempio 24. Data la base di conoscenza

$$KB = \{g \leftarrow a. \quad a \leftarrow b. \quad b \leftarrow a. \quad g \leftarrow c. \quad c.$$

e la query ask g., si ha che:

- le uniche conseguenze logiche sono g e c;

- la procedura BU termina con il punto fisso $\{c, g\}$
- la procedura TD con DFS semplice potrebbe continuare indefinitamente a meno che non sia prevista la potatura dei cicli

La *strategia di selezione* dell'atomo per la risoluzione condiziona *efficienza* e *terminazione*:

- negli esempi precedenti: atomo più a sinistra, il che risulta problematico senza controllo sui cicli;
- una strategia migliore seleziona l'atomo che porti al fallimento più rapidamente;
- una strategia comune prevede l'ordinamento degli atomi per la selezione; ciò consente l'uso di un'euristica.

4.4. Interrogare l'utente

A run-time il sistema riceve **osservazioni** dagli utenti, da sensori o altre sorgenti. Esse sono rappresentate come *insiemi di atomi*. Le osservazioni interagiscono con la **conoscenza di fondo** (*background knowledge, BK*): possono esservi aggiunte o essere tenute separate dalla BK (base knowledge).
Le informazioni fornite dall'utente sono incomplete: è possibile che non sappia usare il vocabolario o non sappia giudicarne la rilevanza. Per questo servirebbero:

1. un'*ontologia* che specifichi il significato dei simboli
2. un'*interfaccia* che possa aiutare a fornire informazioni rilevanti.

Analogamente, i *sensori* possono essere *passivi*, quando raccolgono osservazioni dirette oppure *attivi*, se atti a raccogliere risposte a esplicite richieste di informazioni necessarie.
Per l'*acquisizione* si può pensare a un meccanismo **ask-the-user** integrato nella procedura di ragionamento: si considerano atomi dichiarati come **askable** per rappresentare fatti veri acquisibili a run-time dall'utente. Nella procedura TD, selezionato un atomo da dimostrare, si usa una clausola della base di conoscenza oppure, se è askable si chiede all'utente se sia vero o falso. Si noti che ciò vale solo per atomi rilevanti per la risposta, quindi si considerano tre diverse classi di atomi:

1. non askable;
2. askable senza risposta-utente: si può chiedere e memorizzare;
3. askable con risposta-utente memorizzata: usati senza chiedere di nuovo.

Si può adottare un meccanismo simile anche con procedure bottom-up, ma vanno evitate troppe richieste all'utente.

4.5. Debugging a Livello di Conoscenza

Data una semantica esplicita si possono realizare spiegazione e debugging a livello di conoscenza. Il **knowledge-level-debugging** consiste nel trovare errori nelle basi di conoscenza facendo riferimento solo al significato dei simboli e a quanto risulta vero nel mondo codificato e non ai passi di ragionamento.
I diversi tipi di errori possibili sono:

1. risposta *errata*: derivazione di atomo falso nell'interpretazione intesa;
2. risposta *mancante*: dimostrazione fallita per qualche atomo vero nell'interpretazione intesa;
3. *loop infinito*: solo con procedure TD, in base alla strategia di selezione. Ma si può evitare con meccanismi di potatura dei cicli.

4.5.1. Risposte Errate

Si tratta di risposte fornite dalla procedura di dimostrazione che sono *false* nell'interpretazione intesa, cioè casi di **falsi positivi**. Se la procedura è corretta allora nella dimostrazione sarà stata impiegata una clausola errata.
Per il *debugging dei falsi positivi*, si considerano l'atomo g dimostrato che, invece, dovrebbe essere falso nell'interpretazione intesa e la clausola usata per dimostrarlo $g \leftarrow a_1 \wedge \cdots \wedge a_k$. I casi possibili sono i seguenti:

- tutti gli a_i sono veri nell'interpretazione intesa, quindi la clausola $g \leftarrow a_1 \wedge \cdots \wedge a_k$ è errata;
- uno o più a_i dimostrati sono a loro volta falsi nell'interpretazione intesa, per cui si ha un analogo problema da risolvere.

L'algoritmo da usare può essere schematizzato come segue:

Algoritmo 13 — *Debug dei falsi positivi*

```
1: procedure Debug_false(g, KB)
2: Input
3:     KB: base di conoscenza
4:     g: atomo tale che KB ⊢ g ma falso nell'interpretazione intesa
5: Output
6:     clausola in KB che risulta falsa
7: trovare g ← a_1 ∧ ··· ∧ a_k ∈ KB usata per dimostrare g
8: chiedere all'utente se ogni a_i sia vero o meno
9: if l'utente indica un a_i falso then
10:     return Debug_false(a_i, KB)
11: else if l'utente risponde che tutti gli a_i sono veri then
```

```
12:  | return g ← a_1 ∧ ··· ∧ a_k
```

4.5.2. Risposte mancanti

In tal caso una risposta positiva attesa (ossia un goal vero nell'interpretazione intesa) non viene derivata dal sistema. Il *fallimento* dipende da un atomo g vero nell'interpretazione intesa ma tale che $KB \nvdash g$, si tratta, cioè, di un caso di **falso negativo**.

Tale atomo segnala il caso di una o più *clausole mancanti* tra gli assiomi della base di conoscenza e si può individuare con una procedura, come quella riportata, per trovare atomi cui manchino clausole utili alla loro dimostrazione:

Algoritmo 14 — *Debug dei falsi negativi*

```
1:  procedure Debug_missing(g, KB)
2:  Input
3:  |  KB: base di conoscenza
4:  |  g: atomo tale che KB ⊬ g ma g vero nell'interpretazione intesa
5:  Output
6:  |  atomo per il quale manchi una clausola utile
7:  if ∃g ← a_1 ∧ ··· ∧ a_k ∈ KB con tutti gli a_i veri nell'interpretazione intesa then
8:  |  selezionare a_i che non può essere dimostrato
9:  |  return Debug_missing(a_i, KB)
10: else
11: |  return g
```

4.6. Dimostrazione per Contraddizione

4.6.1. Clausole di Horn

Si intende estendere il ragionamento ammettendo regole che producano *contraddizioni*, ossia utili a specificare casi *impossibili*. Ciò ha anche lo scopo di implementare successvimente forme di *diagnostica*. A tale scopo il linguaggio delle clausole definite può essere esteso per esplicitare le contraddizioni. Definiti un atomo speciale, detto *false*, che codifica la contraddizione, ossia che è falso in tutte le interpretazioni, saranno amesse regole, dette **vincoli d'integrità**, rappresentate da clausole con l'atomo *false* come testa:

$$\text{false} \leftarrow a_1 \wedge \cdots \wedge a_k$$

Una **clausola di Horn** è una clausola definita o un vincolo d'integrità, ossia la sua testa è un atomo normale oppure l'atomo speciale *false*.
Da una base di conoscenza di clausole di Horn si possono derivare **negazioni** di atomi tramite la regola di ragionamento detta *modus tollens*:

$$\frac{p \rightarrow q \quad \neg q}{\neg p}$$

Esempio 25. Data la base di conoscenza KB_1:
1. false $\leftarrow a \wedge b$;
2. $a \leftarrow c$.
3. $b \leftarrow c$.

c è falso in tutti i modelli di KB_1. Pertanto si può scrivere $KB_1 \models \neg c$

Inoltre, valendo le seguenti equivalenze:

$$(\text{false} \leftarrow a_1 \wedge \cdots \wedge a_k) \equiv \neg(a_1 \wedge \cdots \wedge a_l) \equiv \neg a_1 \vee \cdots \vee \neg a_k$$

dimostrare che una *congiunzione di atomi* sia falsa in tutti i modelli di KB equivale a provare una **disgiunzione** di *negazione di atomi*.
Un insieme di clausole KB è **insoddisfacibile** se non ha modelli:

$$KB \models \text{false}$$

Un insieme di clausole KB è **inconsistente** rispetto a una procedura di dimostrazione $\vdash$ se consente di derivare false:

$$KB \vdash \text{false}$$

Se la procedura $\vdash$ è corretta e completa allora KB è inconsistente se e solo se è insoddisfacibile.
Una base di conoscenza di clausole definite è sempre soddisfacibile, per esempio basta considerare l'interpretazione che assegna il valore *true* a tutti gli atomi. Ciò non vale per le basi di clausole di Horn.

4.6.2. Assumibili e Conflitti

Le *contraddizioni* sono utili a individuare combinazioni di assunzioni incompatibili, ossia ipotesi fatte (per mancata conoscenza) che possono dimostrarsi false.
Si definisce **assumibile** un atomo che può essere assunto in una *dimostrazione per contraddizione*. In diagnostica, sarà utile a determinare una *disgiunzione di negazioni* di assumibili, provando la contraddizione a partire da una base di conoscenza e una combinazione di assumibili.
Si dice **conflitto** di KB l'insieme di assumibili $C = \{c_1, ..., c_r\}$ tale che $KB \cup C \models$ false. Si tratta di una **risposta** per una dimostrazione per contraddizione del

tipo: $KB \models \neg c_1 \vee \cdots \vee \neg c_r$. Un conflitto è **minimale** se nessun suo sottoinsieme costituisce, a sua volta, un conflitto.

Esempio 26. Data KB_2 e l'insieme di atomi assumibili $\{c, d, e, f, g, h\}$:

$$KB_2 = \begin{cases} \text{false} \leftarrow a \wedge b. \\ a \leftarrow c. \\ b \leftarrow d. \\ b \leftarrow e. \end{cases}$$

- $\{c, d\}$ e $\{c, e\}$ sono conflitti minimali;
- $\{c, d, e, h\}$ è un conflitto non minimale.

4.6.3. Diagnosi basata sulla consistenza

Lo scopo della diagnosi è quello di determinare possibili guasti in base a un modello del sistema, una base di conoscenza, e a osservazioni aggiuntive sul sistema stesso. In sostanza si fanno assunzioni sul funzionamento normale, considerando quindi assumibili in assenza di guasti. Si derivano i componenti *anormali*, ossia i conflitti, le anomalie nel sistema.

Esempio 27. (impianto elettrico, cont.) Si riconsideri la base di conoscenza *Scheda impianto elettrico* . Si aggiungono:

- *assunzioni* di normalità tramite *assumibili*: atomi ok^* per ogni componente (dev'essere in buono stato per funzionare);
- *osservazioni* fornite dall'utente che specificano le posizioni effettive (*su* / *giu*) dei deviatori, lo stato delle luci (*lit* / *spenta*),...;
- *vincoli d'integrità* utili a definire stati reciprocamente incompatibili come, ad esempio, che sia possibile un solo stato per i punti-luce:
  false ← *spenta_l1* ∧ *accesa_l1*.

KB risultante:

- *luce_l1*.
- *luce_l2*.
- *alimentazione_esterna*.
- *alimentata_l1* ← *alimentato_c0*.
- *alimentato_c0* ← *alimentato_c1* ∧ *su_d2* ∧ *ok_d2*.
- *alimentato_c0* ← *alimentato_c2* ∧ *giu_d2* ∧ *ok_d2*.
- *alimentato_c1* ← *alimentato_c3* ∧ *su_d1* ∧ *ok_d1*.
- *alimentato_c2* ← *alimentato_c3* ∧ *giu_d1* ∧ *ok_d1*.
- *alimentata_l2* ← *alimentato_c4*.
- *alimentato_c4* ← *alimentato_c3* ∧ *su_d3* ∧ *ok_d3*.
- *alimentata_*p_1 ← *alimentato_c3*.

- *alimentato_c3* ← *alimentato_c5* ∧ *ok_f1.*
- *alimentata_*p_2 ← *alimentato_c6.*
- *alimentato_c6* ← *alimentato_c5* ∧ *ok_f2.*
- *alimentato_c5* ← *alimentazione_esterna.*
- *accesa_l1* ← *luce_l1* ∧ *alimentata_l1* ∧ *ok_l1.*
- *accesa_l2* ← *luce_l2* ∧ *alimentata_l2* ∧ *ok_l2.*

vincoli d'integrità:

- *false* ← *spenta_l1* ∧ *accesa_l1.*
- *false* ← *spenta_l2* ∧ *accesa_l2.*

osservazioni:

- *su_d1.*
- *su_d2.*
- *su_d3.*
- *spenta_l1.*
- *spenta_l2.*

dichiarazioni:

- assumable *ok_f1,ok_f2,ok_d1,ok_d2,ok_d3,ok_l1,ok_l2.*

Tutto considerato, ci sono due conflitti minimali:

1. {*ok_f1,ok_d1,ok_d2,ok_l1*}
2. {*ok_f1,ok_d3,ok_l2*}

Pertanto:

1. $KB \models \neg$ *ok_f1* $\vee \neg$ *ok_d1* $\vee \neg$ *ok_d2* $\vee \neg$ *ok_l1*
   quindi almeno un componente fra *f1,*d_1*,*d_2*,l1* ha un guasto;
2. $KB \models \neg$ *ok_f1* $\vee \neg$ *ok_d3* $\vee \neg$ *ok_l2*
   ossia almeno uno tra *f1,*d_3*,l2* non funziona.

Dato l'insieme dei conflitti, l'utente può diagnosticare il problema: ciò è anche utile a farsi un'idea della numerosità dei possibili guasti.
Nella **diagnosi basata su consistenza** (CBD) dato un insieme di conflitti, cioè un insieme di assumbili con almeno un elemento in ogni conflitti, si costruisce una diagnosi che sarà **minimale** se nessun suo sotto-insieme è una diagnosi. Intuitivamente, una sola delle diagnosi minimali è quella giusta: qualla contenente solo conflitti falsi nell'interpretazione intesa.

4.6.4. Ragionamento con Assunzioni e Clausole di Horn

L'*obiettivo* è la ricerca dei *conflitti* in basi di conoscenza di clausole di Horn attraverso dimostrazioni per contraddizione dei due tipi considerati in precedenza.

Implementazione Bottom-Up

Si estende l'algoritmo bottom-up per clausole definite:

- le conclusioni sono *coppie* $\langle a, A\rangle$, con A insiemi di assumibili che implicano l'atomo a rispetto a KB;
- nell'inizializzazione, l'insieme di conclusioni sarà $C \leftarrow \{\langle a, \}a\}\rangle\} \mid a$ assumibile$\}$;
- si usano poi le clausole in KB per derivare nuove conclusioni: se $\exists h \leftarrow b_1 \wedge \cdots \wedge b_m \in KB$ tale che ogni $\langle b_i, A_i\rangle \in C$, allora si può aggiungere $\langle h, A_1 \cup ... \cup A_m$ a C

ALGORITMO 15 — *Algoritmo bottom-up per la dimostrazione di conflitti*

```
1:  procedure Prove_conflict_BU(KB, As)
2:  Input
3:  |  KB: insieme di clausole di Horn
4:  |  As: insieme di atomi che si possono assumere veri
5:  Output
6:  |  insieme di conflitti
7:  Local
8:  |  C: insieme di coppie atomo/insieme di assumibili
9:  C ← {⟨a, {a}⟩ | a ∈ As}
10: repeat
11: |  selezionare la clausola h ← b_1 ∧ ... ∧ b_m ∈ KB tale che:
12: |      per ogni i, ⟨b_i, A_i⟩ ∈ C e ⟨h, A⟩ ∉ C, dove A = A_1 ∪ ... ∪ A_m
13: |  C ← C ∪ {⟨h, A⟩}
14: until nessun'altra selezione possibile
15: return {A | ⟨false, A⟩ ∈ C}
```

Implementazione Top-Down

L'implementazione top-down deriva dall'omologa per clausole definite, con due *differenze*:

- la query da provare è dall'atomo speciale *false*;
- nella dimostrazione, gli atomi assumibili non vanno dimostrati ma semplicemente raccolti via via assunti come veri.

ALGORITMO 16 — *Algoritmo top-down per la dimostrazione di conflitti*

```
1: non-deterministic procedure Prove_conflict_TD(KB, As)
2: Input
3: |  KB: insieme di clausole di Horn
4: |  As: insieme di atomi che si possono assumere veri
5: Output
```

```
    | un conflitto
Local
    | G: insieme di atomi (che implicano false)
G ← {false}
repeat
    | selezionare un atomo a ∈ G tale che a ∉ As
    | scegliere una clausola a ← B di KB con a come testa
    | G ← (G \ {a}) ∪ B
until G ⊆ As
return G
```

Si osservi che l'algoritmo contiene diverse scelte *non deterministiche* in corrispondenza delle quali si ptoranni trovare diversi conflitti: in mancanza di scelte, l'algoritmo fallisce.

4.7. Assunzione di Conoscenza Completa

Nella semantica dele basi di dati quello che non è derivabile viene considerato falso: la conoscenza su un dominio viene considerata *completa*. In Logica la mancanza di conoscenza non consente di trarre conclusioni dal fallimento delle dimostrazioni.
Assumendo la **completezza della conoscenza**, le clausole con uno stesso atomo come testa coprono tutti e soli i casi in cui esso è vero. Tale assunzione si dice anche **closed-world (CWA)**. In base ad essa, se non si riesce a dimostrare che a sia vero, si conclude che è falso, ossia che la sua negzione $\neg a$ è vera. Si assume quindi che tutto quello che è rilevante sia stato asserito esplicitamente nella base di conoscenza.
In Logica normalmente si può assumere che una base di conosceza possa definire tutta la conoscenza su un dato diminio nella sua completezza, si parla pertanto di **open-world assumption (OWA)**. Quindi, non potendo trarre conclusioni dalla mancanza di conoscenza, la base di conoscenza di clausole definite non può avere $\neg a$ come conseguenza logica.

Completare la Base di Conoscenza

Per codificare l'assunzione di conosceza completa negli assiomi della base di conoscenza essa dev'essere trasfomrata ossia *completata*.
Dato l'atomo a, si considerino tutte le clausole della base di conoscenza che lo definiscono:

$$a \leftarrow b_1. \quad \ldots \quad a \leftarrow b_n.$$

dove b_i è una congiunzione di atomi oppure *true*. In mancanza di clausole per a si considera: $a \leftarrow$ false.
Tali clausole possono essere riassunte da un'unica proposizione:

$$a \leftarrow b_1 \vee \cdots \vee b_n$$

Se a è vero allora, per la CWA, dovrà necessariamente essere vero uno dei corpi b_i quindi si può aggiungere:

$$a \rightarrow b_1 \vee \cdots \vee b_n$$

Il significato delle clausole per l'atomo a sotto CWA è la congiunzione delle due proposizioni, ossia l'equivalenza:

$$a \Leftrightarrow b_1 \vee \cdots \vee b_n$$

detta *complemnto di Clark* delle clausole per a. Si noti che se non ci sono regole per a, il complemento sarà $a \Leftrightarrow$ false.
Il **complemento di Clark** della base di conoscenza ricomprende i complementi di tutti gli atomi della base.

Esempio 28. Si consideri la base di conoscenza precedente con le clausole:

- *giu_d1.*
- *su_d2.*
- *ok_f1.*
- *alimentata_l1* $\leftarrow$ *alimentato_c0.*
- *alimentato_c0* $\leftarrow$ *alimentato_c1* $\wedge$ *su_d2.*
- *alimentato_c0* $\leftarrow$ *alimentato_c2* $\wedge$ *giu_d2.*
- *alimentato_c1* $\leftarrow$ *alimentato_c3* $\wedge$ *su_d1.*
- *alimentato_c2* $\leftarrow$ *alimentato_c3* $\wedge$ *giu_d1.*
- *alimentato_c3* $\leftarrow$ *alimentazione_esterna* $\wedge$ *ok_f1.*
- *alimentazione_esterna.*

Si noti che non sono definite clausole per *su_d1* e *giu_d2*.
Completamento della base di conoscenza:

- *giu_d1* $\Leftrightarrow$ *true.*
- *su_d1* $\Leftrightarrow$ *false.*
- *su_d2* $\Leftrightarrow$ *true.*
- *giu_d2* $\Leftrightarrow$ *false.*
- *ok_f1* $\Leftrightarrow$ *true.*
- *alimentata_l1* $\Leftrightarrow$ *alimentato_c0.*
- *alimentato_c0* $\Leftrightarrow$ (*alimentato_c1* $\wedge$ *su_d2*) $\vee$ (*alimentato_c2* $\wedge$ *giu_d2*).
- *alimentato_c1* $\Leftrightarrow$ *alimentato_c3* $\wedge$ *su_d1.*
- *alimentato_c2* $\Leftrightarrow$ *alimentato_c3* $\wedge$ *giu_d1.*

- *alimentato_c3* $\Leftrightarrow$ *alimentazione_esterna* $\wedge$ *ok_f1.*
- *alimentazione_esterna* $\Leftrightarrow$ *true.*

Così, ad esempio, *su_d1* è falso, *alimentato_c1* è falso e *alimentato_c2* è vero.

Negazione come Fallimento

Un **letterale** è un atomo o la negazione di un atomo. Con il completamento si possono dimostrare negazioni di proposizioni, quindi la negazione può essere ammessa anche nel corpo delle clausole. Si considereranno clausole definite estese contenenti nel corpo letterali. La *negazione sotto assunzione di conoscenza completa*, detta anche **negation as failure (NaF)**, verrà denotata con $\sim a$ per distinguerla dalla negazione classica. Sotto CWA, il corpo g è una conseguenza di KB se e solo se $KB' \models g$, dove KB' è il completamento di KB. Si noti come $\sim a$ nel corpo di una clausola diventi $\neg a$ nel completamento.

Esempio 29. Si consideri l'assiomatizzazione vista in precedenza. Si semplifica la rappresentazione chiedendo all'utente di indicare solo i deviatori *su*, gli altri saranno *giu* per default. Analogamente, si potrebbe specificare che i fusibili sono *funzionanti* a meno che non risultino *rotti*.
Regole da aggiungere:

- *giu_d1* $\leftarrow\sim$ *su_d1.*
- *giu_d2* $\leftarrow\sim$ *su_d2.*
- *giu_d3* $\leftarrow\sim$ *su_d3.*
- *ok_f1* $\leftarrow\sim$ *rotto_f1.*
- *ok_f2* $\leftarrow\sim$ *rotto_f2.*

Per rappresentare lo stato della figura, l'utente specifica:

- *su_d2.*
- *su_d3.*

Il sistema può inferire che d_1 dev'essere in posizione *giu* e i due fusibili non sono guasti. Completamento:

- *giu_d1* $\Leftrightarrow \neg$ *su_d1.*
- *giu_d2* $\Leftrightarrow \neg$ *su_d2.*
- *giu_d3* $\Leftrightarrow \neg$ *su_d3.*
- *ok_interruttore1* $\Leftrightarrow \neg$ *rotto_interruttore1.*
- *ok_interruttore2* $\Leftrightarrow \neg$ *rotto_interruttore2.*
- *su_d1* $\Leftrightarrow$ *false.*
- *su_d2* $\Leftrightarrow$ *true.*
- *su_d3* $\Leftrightarrow$ *true.*
- *rotto_interruttore1* $\Leftrightarrow$ *false.*
- *rotto_interruttore2* $\Leftrightarrow$ *false.*

Con la NAF, le basi di conoscenza non acicliche diventa problematiche dal punto di vista semantico. Ad esempio, data la base non aciclica:

- $a \leftarrow\sim b$
- $b \leftarrow\sim a$

il completamento equivalente a $a \Leftrightarrow \neg b$, indica che a e b hanno valori di verità opposti: solo uno può essere vero.
Un altro esempio di base di conoscenza non aciclica è una con l'assioma:

- $a \leftarrow\sim a$

con completamento:

- $a \Leftrightarrow \neg a$

che risulta *inconsistente* dal punto di vista logico. Il completamento di una base aciclica è sempre consistente e prevede un solo valore di verità per ogni atomo.

4.7.1. Ragionamento Non Monotono

In una logica **monotona** ogni proposizione derivabile da una base di conoscenza rimane derivabile dopo l'aggiunta di altre proposizioni: aggiungendo assioni non si riduce l'insieme delle proposizioni derivabili. In una *Logica non monotona* alcune conclusioni possono essere invalidate con l'aggiunta di altri assiomi.

Default ed Eccezioni

Una logica non monotona è utile a rappresentare casi predefiniti. Si dice **default** una regola che resta valida fintantochè non si verifichi un'eccezione. Ad esempio per asserire che normalmente b è vera se c è vera si può definire la regola:

$$b \leftarrow c \wedge \sim ab_a$$

con ab_a che indica l'anormalità rispetto a qualche aspetto di a. Dato c si può derivare b, a meno che non venga asserito ab_a, in quanto l'aggiunta di ab_a inibisce la possibilità di concludere b. Le regole che implicano ab_a possono inibire il default, sotto le condizoni del corpo della regola. Ad esempio, nella maggior parte dei casi gli uccelli (c) sono volatili (b), ma i pinguini fanno eccezione (ab_a).

4.7.2. Procedure di Dimostrazione per la NAF

Procedura Bottom-Up + NAF

La procedura BU per clausole definite va modificata: quando p fallisce va aggiunto il letterale $\sim p$ all'insieme C delle conseguenze derivate.
Si ha una definzione ricorsiva del **fallimento**: p fallisce se fallisce il corpo di ogni clausola che abbia p coem testa; un corpo fallisce se almeno uno dei suoi letterali fallisce; un atomo b_i fallisce se si può derivare $\sim b_i$ e la negazione $\sim b_i$ fallisce se si può derivare b_i.

Algoritmo 17 — *Algoritmo bottom-up di dimostrazione con NAF*

```
1: procedure Prove_NAF_BU(KB)
```

Input
  KB: insieme di clausole che possono includere NAF
Output
  insieme di letterali che seguono dal completamento di KB
Local
  C insieme di letterali
  $C \leftarrow \{\}$
repeat
  either
    selezionare $(h \leftarrow b_1 \wedge \cdots \wedge b_m) \in KB$ tale che: $h \notin C$ e $\forall i : b_i \in C$
    $C \leftarrow C \cup \{h\}$
  or
    selezionare h con $\sim h \notin C$ tale che:
      $\forall (h \leftarrow b_1 \wedge \cdots \wedge b_m) \in KB : \exists i : \sim b_i \in C$ oppure $b_i = \sim g$ e $g \in C$
    $C \leftarrow C \cup \{\sim h\}$
until non ci sono altre selezioni possibili

Esempio 30. Si considerino le clausole:

1. $p \leftarrow q \wedge \sim r.$
2. $p \leftarrow s.$
3. $q \leftarrow \sim s.$

1. $r \leftarrow \sim t.$
2. $t.$
3. $s \leftarrow w.$

Una possibile sequenza di letterali aggiunti a C è la seguente:

- $C = \{t\}$ — 5. (fatto)
- $C = \{t, \sim r\}$ — $t \in C$ e 4.
- $C = \{t, \sim r, \sim w\}$ — non ci sono clausole per w
- $C = \{t, \sim r, \sim w, \sim s\}$ — $\sim w \in C$ e 6.
- $C = \{t, \sim r, \sim w, \sim s, q\}$ — $\sim s \in C$ e 3.
- $C = \{t, \sim r, \sim w, \sim s, q, p\}$ — $q \in C$, $\sim r \in C$ e 1.

Procedura Top-Down + NAF

La procedura TD è analoga a quella delle clausole definite, ma procede per NAF. È non-deterministca e, come tale, si può implementare come ricerca di scelte di successo: selezionato un atomo $\sim a$, parte una nuova dimostrazione per a; se questa fallisce allora $\sim a$ ha successo altrimenti l'algoritmo fallisce: deve tentare altre scelte se possibile.

Algoritmo 18 — *Algoritmo top-down di dimostrazione con NAF*

```
1: non-deterministic procedure Prove_NAF_TD(KB, Query)
2: Input
3:     KB: insieme di clausole che includono la NAF
4:     Query: insieme di letterali da dimostrare
5: Output
6:     yes se Query segue dal completamento di KB, "fail" altrimenti
7: Local
8:     G: insieme di letterali
9: G ← Query
10: repeat
11:     selezionare il letterale l ∈ G
12:     if l =∼ a then
13:         if Prove_NAF_TD(KB, a) = 'fail' then
14:             G ← G \ {l}
15:         else
16:             return "fail"
17:     else
18:         scegliere una clausola l ← B ∈ KB
19:         G ← G \ {l} ∪ B
20: until G = ∅
21: return yes
```

Esempio 31. Data la base di conoscenza nell'Esempio 30 la query `ask` p:

- $G = \{p\}$ – inizializzazione
- $G = \{q, \sim r\}$ – sostituzione con il corpo di 1.;
- $G = \{\sim s, \sim r\}$ – sostituendo q con il corpo della 3.;
- $G = \{\sim r\}$ – selezionato ed eliminato $\sim s$ la dim. di s *fallisce*;
- $G = \{\}$ – selezionato $\sim r$, la dim. di r *fallisce* poiché, usando la 4., si deve provare il sotto-goal $\sim t$, si tenta quindi di dimostrare t; data 5., tale dim. ha *successo* immediato, e quella di $\sim t$ *fallisce*. non ci sono altre regole per r. da cui il successo di $\sim r$ che può essere eliminato.

Essendo G vuoto l'output sarà `yes`.

Quanto detto vale solo enl caso di fallimento finito: nessuna conclusione è possibile in caso di divergenza. Ad esempio, data una base di conoscenza con la sola regola $p \leftarrow p$ e la query ask p, l'algoritmo non converge: il completamento è $p \Leftrightarrow p$ ma, pur potendosi accertare l'indimostrabilità di p, una procedura corretta non può concludere $\sim p$ poichè non segue logicamente dal completamento.

4.8. Abduzione

L'**abduzione** è una forma di ragionamento nella quale si fanno ipotesi, ossia assunzioni, al fine di spiegare osservazioni. Le ipotesi da farsi possono implicare le osservazioni fatte: se verificate, esse giustificano quanto osservato ma non si devono introdurre *contraddizioni* poichè queste giustificherebbero qualsiasi conclusione.
L'abduzione si differenzia dalla deduzione la quale mira alle conseguenze logiche di un set di assiomi e dall'induzione che comporta l'inferenza di relazioni generali da casi particolari.

Scenari e Spiegazioni

Possiamo schematizzare questa forma di ragionamento come segue. I dati sono i seguenti:

- una base KB di Horn;
- un insieme A di atomi utili a costruire ipotesi, detti assumibili o anche abducibili,

dobbiamo trovare delle spiegazioni per delle osservazioni.
Si dice **scenario** di $\langle KB, A\rangle$ un insieme di abducibili $H \subseteq A$ tale che $KB \cup H$ sia soddisfacibile. In tal caso deve esistere un modello in cui tutti gli elementi di KB e di H sono veri, quindi nessun sottoinsieme di H deve essere un conflitto per KB.
Una **spiegazione** della proposizione g da $\langle KB, A\rangle$ è uno scenario $H \subseteq A$ che, assieme a KB, abbia g come conseguenza, quindi:

- $KB \cup H \models g$ e
- $KB \cup H \not\models \text{false}$

Essa è **minimale** se H non contiene altre spiegazioni: per ogni altra H' di g da $\langle KB, A\rangle$ deve risultare $H' \not\subset H$.

> **Esempio 32.** Si consideri una base di conoscenza con assumibili per la *diagnosi medica*:
>
> - *bronchite* ← *influenza.*
> - *bronchite* ← *fumatore.*
> - *tosse* ← *bronchite.*
> - *affanno* ← *bronchite.*
> - *febbre* ← *influenza.*
> - *febbre* ← *infezione.*
> - *mal_di_gola* ← *influenza.*
> - *false* ← *fumatore* ∧ *non_fumatore.*
> - assumable *fumatore, non_fumatore, influenza, infezione.*
>
> Se si osserva *affanno* (respiro affannoso), due spiegazioni minime, {*influenza*} e {*fumatore*}, che implicano *bronchite* e *tosse* (tosse).
> Se si osservano *affanno* ∧ *febbre*, spiegazioni minimali: {*influenza*} e {*fumatore,infezione*}.
> Se si osservano *affanno* ∧ *non_fumatore*, spiegazione minimale: {*influen-*

za,non_fumatore}. Anche {*fumatore*} potrebbe spiegare *affanno*, ma il vincolo la rende inconsistente rispetto a *non_fumatore* osservato.

Esempio 33. Si consideri la base di conoscenza:

- *allarme* ← *manomissione.*
- *allarme* ← *incendio.*
- *fumo* ← *incendio.*

Se si osserva *allarme*, spiegazioni minimali sono: {*manomissione*} e {*incendio*}. Se si osservano *allarme* ∧ *fumo*, la spiegazione minimale è solo {*incendio*}. Difatti avendo osservato *fumo* non c'è bisogno di ipotizzare *manomissione* per spiegare *allarme*, è già spiegato da *incendio.*

Diagnosi Abduttiva

La *diagnosi abduttiva (AbD)* formula iptoesi su problemi riscontrati e funzionamento normale.
Confrontandola con quella basata su consistenza (CbD):

- al livello di *rappresentazione*, la CbD mira solo al comportamento normale quindi le ipotesi saranno assunzioni sul comportamento normale, mentre con la AbD si modella anche il comportamento anomalo, si devono prevedere assumibili anche per ciascun guasto;
- per quanto riguarda le osservazioni, la CbD le aggiunge alla base di conoscenza per poi dimostrare *false* mentre la AbD le considera come goal da spiegare attraverso ipotesi;
- in termini di qualità, la AbD risulta più dettagliata,le diagnosi sono migliori: si distinguono base di conoscenza e assunzioni consentono di dimostrare le osservazioni, anche per casi in cui non sia definibile la normalità.

Ragionamento Abduttivo: Procedure

Il ragionamento abduttivo è basato su assunzioni e si realizza mediante le procedure su clausole di Horn:

- con la procedura BU si calcolano spiegazioni minimali per ogni atomo, essa è ulteriormente specialzizabile con il pruning delle spiegazioni dominate;
- con la procedura TD si trovano spiegazioni di un g generando i conflitti, ma mirando a dimostrare g anzichè *false*: la spiegazione minimale di g sarà un insieme minimale di assumibili raccolti nella prova.

Rappresentazione e Ragionamento Relazionale

Nel rappresentare la struttura del mondo, è utile ragionare in termini di individui e relazioni.
Gli **individui** sono entità, cose, oggetti del dominio, e potranno essere *concreti* (persone, edifici, ecc.), *immaginari* (unicorni, programmi che superano il Turing test, ecc.) o anche *concetti astratti*, come i processi (ad esempio la lettura di un libro) o altri concetti (come corsi di studio, istanti di tempo, ecc.).
Le **relazioni** specificano verità riguardanti gli individui. Possono essere *proprietà*, vere o false, dei singoli individui oppure *proposizioni* che possono vere o false indipendentemente da specifici individui, e anche associazioni che possono intercorrere tra più individui.
Con questa rappresentazione il ragionamento su più istanze potrà risultare più semplice in quanto più generale.

> **Esempio 34.** Nella rappresentazione proposizionale della domotica, si consideravano atomi senza una vera struttura interna, come su_d_2, su_d_3 e ok_d_2. La rappresentazione non risulta sufficiente a esprimere ad esempio che:
> - su_d_2, su_d_3 riguardano la stessa proprietà ma individui diversi;
> - su_d_2, ok_d_2 riguardano proprietà diverse dello stesso individuo.
>
> In alternativa si possono rappresentare esplicitamente e separatamente gli individui d_1, d_2, d_3 e le rispettive proprietà *su* e *ok*. Inoltre si potrà usare la relazione binaria $a_3_p_1$ per collegare individui, indipendentemente dalle loro proprietà.

I vantaggi della nuova rappresentazione sono molteplici:
- essa è più naturale poichè sfrutta la struttura delle feature come proprietà degli individui;
- è utile anche nel caso di *domini sconosciuti* per i quali non vi sia nessuna conoscenza sugli individui, sul loro numero e carattteristiche: si deve interagire con l'ambiente per apprendere la rappresentazione;
- consente forme di ragionamento più generali e indipendenti dai singoli invidui, con obiettivo quali la derivazione di conclusioni che valgono per tutti gli individui senza conoscerli necessariamente, la scoperta dell'esistenza di nuovi individui e le loro proprietà, a prescindere dagli altri e, inoltre, la possibilità di rispondere a query che riguardano intere popolazioni e non singoli invidui;
- rende possibile il trattamento dell'esistenza incerta di individui: nno si conoscono completamente invidui attuali e futuri, nonchè le loro proprietà;
- rende possibile il ragionamento su un infinito numero di invidui.

5.1. Simboli e Semantica

La logica può risultare molto utile nella progettazione di basi di conoscenza. I progettisti devono caratterizzare un particolare mondo formalizzando la cosiddetta **interpretazione intesa**: scegliendo significati per i simboli in base a tale interpretazione e descrivendo ciò che dev'essere vero attraverso una base di conoscenza fatta di clausole. Chiunque conosca il significato dei simboli può interpretare, rispetto a tale modello, le conseguenze logiche derivata dalla base: ciò che è vero in tutti i modelli della base sarà vero, in particolare, nell'interpretazione intesa.
Estendendo il linguaggio delle clausole proposizionali si possono definire atomi con una struttura interna descritti in termini di relazioni e individui.
Una **concettualizzazione** è un'associazione fra simboli nella mente e gli individui e le relazioni da essi denotati.
Vi è una separazione tra l'aspetto semantico e quello computazionale: la correttezza della base di conoscenza e delle risposte alla query è definita dalla semantica indipendentemente dall'algoritmo di ragionamento, che si può ottimizzare a patto di rimanere semanticamente corretto.

5.2. Calcolo dei Predicati

Il **calcolo dei predicati** (*logica dei predicati* o *logica del primo ordine*) estende il calcolo proposizionale in due modi: gli atomi sono dotati di una loro struttura con la possibilità di includere variabili; inoltre, le variabili logiche sono quantificate.

Sintassi
Per definire la sintassi, occorre specificare le seguenti nozioni preliminari:

- **simbolo**: stringa alfanumerica che può includere anche «_»;
- **variabile logica**: simbolo che inizia con maiuscola o «_»;
- **costante**: simbolo che inizia con una minuscola o numero o stringa;
- **simbolo di predicato**: simbolo che inizia con una minuscola. Le costanti e i predicati sono distinguibili in base al contesto;
- **termine**: variabile o costante;
- **atomo**: forma p oppure $p(t_1, ..., t_n)$ con p simbolo di predicato e ogni t_i è un termine.

Una **formula logica** viene definita costruttivamente a partire dagli atomi, usando connettivi logici e quantificatori. Date la variabile X e la formula logica p:

- $\forall X \quad p$: si dice che X è quantificata **universalmente**;
- $\exists X \quad p$: si dice che X è quantificata **esistenzialmente**.

5.2.1. Sematica delle formule logiche di base

Un'espressione **ground**, o di lviello base, non contiene variabili. Essa è un atomo o, più in generale, una formula che si riferisce solo a precisi individui.
Un'**interpretazione** delle espressioni ground è definita da una tripla:

$$I = \langle D, \varphi, \pi \rangle$$

ove

- il **dominio** D è un insieme non vuoto di **individui**;
- la funzione $\varphi : c \mapsto \varphi(c)i \in D$ assegna a ogni costante c un individuo di D;
- la funzione $\pi : p \mapsto \pi(p)$ assegna a ogni simbolo di predicato n-ario p una funzione $\pi(p) : D^n \mapsto \{\text{true, false}\}$ che per ogni n-pla di individui $\langle i_1, ..., i_n \rangle \in D^n$, $\pi(p)$ specifica se la relazione p sia vera o falsa: $\pi(p)(\langle i_1, ..., i_n \rangle) \in \{\text{true, false}\}$;
  - π è una **funzione di ordine superiore** in quanto associa un nome di predicato a una funzione;
  - se p non ha argomenti (arietà $n = 0$) allora $\pi(p)$ sarà una funzione costante: true o false.

Semantica degli atomi ground

Nell'interpretazione I, ogni termine ground c denota un individui $\varphi(c)$. Nell'interpretazione I, l'atomo ground $p(t_1, ..., t_n)$ è **vero** se $\pi(p)(\langle t'_1, ..., t'_n \rangle) = \text{true}$ ed è **falso**, altrimenti.

5.2.2. Semantica: Interpretazione delle Variabili

Un'**assegnazione** di variabili ρ è una funzione dall'insieme delle variabili a D che associa un elemento del dominio a ogni variabile.
Data l'interpretazione $I = \langle D, \varphi, \pi, \rangle$ e l'assegnazione ρ, ogni termine denota un individuo in D interpretato da φ se costante, da ρ se variabile. La semantica degli atomi è definita come visto in precedenza, ottenuti associando invidui ai termini.

Semantica della Quantificazione

Una formula *universalmente quantificata* $\forall X \quad p$ è **vera** in un'interpretazione se p è vera per ogni assegnazione di X e sarà falsa se c'è un'assegnazione a X per la quale la formula risulti falsa: la formula p costituisce l'**ambito** di X.
Una formula esistenzialmente quantificata $\exists X \quad p$ è **vera** in un'interpretazione se e solo se p è vera per qualche assegnazione di X: l'individuo assegnato può dipendere da variabili universalmente quantificate nel cui ambito compaia $\exists X \quad p$:

- in $\forall Y(\exists X \quad p)$, X può dipendere da Y;
- in $\exists X(\forall Y \quad p)$, X non può dipendere da Y poichè X non è nell'ambito di Y.

Semantica delle Formule e Conseguenza Logica

Una **formula** con variabili è **vera** in I se e solo se per qualsiasi assegnazione ρ la formula ground ottenuta applicando ρ alle sua variabili risulta vera.

Una formula si dice **aperta** se ha almeno una variabile non quantificata, per cui la sua semantica non può essere determinata.
La nozione di modello e la relazione di **conseguenza logica** fra una data base di conoscenza KB e un goal g si estende al caso delle formule logiche del calcolo dei predicati:

$$KB \models g \text{ se } g \text{ è vera in ogni modello di } KB$$

5.2.3. Semantica: la Prospettiva Umana

Estendendo la metodologia introdotta per le basi di conoscenza proposizionali:

1. si seleziona il dominio del task ossia il mondo da rappresentare, definendo:
   - D insieme di tutti gli individui cui si farà riferimento e sui quali ragionare
   - le *relazioni* da rappresentare;
     - aspetti specifici del mondo reale (ad esempio la struttura dei cordi e studenti presso un'università);
     - mondi immaginari o ipotetici;
     - mondi astratti (ad esempio numeri e insiemi).
2. si associano le *costanti* del linguaggio a individui del mondo da nominare:
   - a ogni elemento di D si assegna una costante per riferirvisi, ad esempio *gino* per un particolare docente, *inf322* per un corso, ecc;
3. si associa un simbolo di *predicato* a ogni relazione da rappresentare, associazioni simbolo-significato per costituire l'**interpretazione intesa**:
   - un simbolo (n-ario) denota una funzione $D^n \to \{\text{true, false}\}$, basta specificare le n-ple per le quali la relazione sia vera. Ad esempio il predicato *insegna* binario rappresenta una relazione vera tra un individuo e un corso insegnato.
   - le relazioni possono avere qualunque arietà (anche nulla), ad esempio *is_red* è un predicato unario;
4. si definisce l'**assiomatizzazione del dominio**, ossia *formule* vere nell'interpretazione intesa
   - **assiomi** del dominio in forma di clausole, ad esempio se la persona denotata da *gino* insegna il corso denotato da *inf322*, la formula *insegna(gino, inf322)* sarà vera nell'interpretazione intesa;
5. si possono formulare *query* riguardanti l'interpretazione intesa:
   - risposte del sistema da interpretare nella semantica attribuita ai simboli.

> **Esempio 35.** concettualizzazioni diverse di un colore: il *rosa*.
> - colore come simbolo di predicato unario: atomo vero se l'individuo dell'argomento è rosa: *rosa(i)*;
> - colore come *individuo*: rosa rappresenta il colore rosa, secondo argomento per un predicato binario *colore(i, c)*;

- a basso livello di dettaglio: le diverse sfumature di rosso risultano indistinguibili, non si considera il colore rosa ma solo *rosso*;
- aumentando il dettaglio; si considera rosa come termine generale, prevedendo anche *corallo* o *salmone*.

5.3. Datalog: Linguaggio Relazione a Regole

Il **Datalog** estende il linguaggio delle clausole definite proposizionali con la sintassi del calcolo dei predicati.
Una **clausola definita** si scrive nella forma:

$$h \leftarrow a_1 \wedge ... \wedge a_m$$

e si legge «h se a_1 e ... e a_m», dove:

- l'atomo h è la **testa** della clausola;
  - se $m > 0$ si dice **regola** e la congiunzione di atomi $a_1 \wedge ... \wedge a_m$ ne costituisce il **corpo**
  - se $m = 0$ la clausola si dice clausola **atomica** o **fatto**
- le variabili contenute sonod a intendersi implicitamente quantificate universalmente, ad esempio $h(X) \leftarrow b(X, Y)$ è da intendersi come $\forall X \forall Y(h(X) \leftarrow b(X, Y))$, che è equivalente a $\forall X(h(X) \leftarrow \exists Y b(X, Y))$.

Esempio 36 *(Impianto elettrico)* **.** Esempio, Scheda impianto elettrico, rivisitato con individui e relazioni.

1. *individui*: secondo il livello di astrazione scelto
   - ogni deviatore, luce, presa;
   - ogni cavo tra deviatori o tra deviatore e luce;
   - si assume un modello di flusso dell'elettricità in cui l'energia fluisca dall'esterno della casa attraverso i cavi e verso le luci, appropriato dovendo determinare se una luce dev'essere accesa o meno, ma potrebbero non esserlo per altri task
2. *nomi* da dare a ciascun individuo al quale ci si vorrà riferire, ad esempio c_0 è il cavo tra la luce l_1 e il deviatore d_2
3. *relazioni* da rappresentare: predicato con le interpretazioni intese associate
   - `luce(L)` è vero se l'individuo denotato da L è una luce;
   - `accesa(L)` è vero se la luce L è accesa ed emette luce;
   - `alimentato(W)` è vero se passa corrente attraverso W, ossia se W è in tensione;
   - `su(S)` è vero se il deviatore S è su;
   - `giu(S)` è vero se il deviatore S è giù;
   - `ok(E)` è vero se E non è guasto; E salvavita o luce;

- `connesso_con(X, Y)` è vero se il componente X è connesso con Y in modo che la corrente passi da Y a X

4. base di *assiomi* per la macchina
   - *regole* generali come $\text{accesa}(L) \leftarrow \text{luce}(L) \wedge \text{alimentato}(L) \wedge \text{ok}(L)$ anche ricorsive, come $\text{alimentato}(X) \leftarrow \text{connesso_con}(X, Y) \wedge \text{alimentato}(Y)$ con alimentato(esterno).
   - *fatti* per la sua configuraszione di un impianto specifico: $\text{luce}(l_1), \text{luce}(l_2), \text{giu}(d_1), \text{su}(d_2), \text{ok}(\text{interruttore}_1)$ e inoltre:
     - $\text{connesso_con}(c_0, c_1) \leftarrow \text{su}(d_2)$
     - $\text{connesso_con}(c_0, c_2) \leftarrow \text{giu}(d_2)$
     - $\text{connesso_con}(c_1, c_3) \leftarrow \text{su}(d_1)$
     - $\text{connesso_con}(c_3, \text{esterno}) \leftarrow \text{ok}(\text{interruttore}_1)$
5. la macchina saprà quindi rispondere a query su questo impianto domestico in particolare.

Query con variabili

Una **query** serve a chiedere se un enunciato sia conseguenza logica di una base di conoscenza. Le query *decisionali* sono quelle tipiche della logica proposizionali e hanno come risposta `yes` o `no`. Le query *con variabili* consentono, in aggiunta, di determinare e restituire tuple di individui per le quali la query si avvera.
Si dirà **istanza** di una query la formula ottenuta sostituendo termini a variabili: ogni occorrenza di una variabile dev'essere sostituita con uno stesso termine. L'**estrazione della risposta** serve a determinare quali istanze seguano dalla base di conoscenza. Le **risposte** possibili per una query con variabili libere sono:

- *istanze* della query che seguono logicamente dalla base, una per ciascuna distinta tupla di valori assegnabile alle variabili della query, oppure
- `no`, se nessuna istanza segue logicamente dalla base (ciò non significa che la query sia falsa nell'interpretazione intesa).

Esempio 37. Dati i seguenti fatti riguardanti i paesi del SudAmerica

- *paese(C)* – vero se C è un paese
  - *paese(argentina).*
  - *paese(brasile).*
  - *paese(cile).*
  - *paese(paraguay).*
  - *paese(peru).*
- *superficie(C, A)* – vero se C ha superficie A in Kmq
  - *superficie(argentina, 2780400).*
  - *superficie(brasile, 8515767).*
  - *superficie(cile, 756102).*

- *superficie(paraguay, 406756).*
- *superficie(peru, 1285216).*

- *lingua(C, L)* – vero se L lingua principale di C
  - *lingua(argentina, spagnolo).*
  - *lingua(brasile, portoghese).*
  - *lingua(cile, spagnolo).*
  - *lingua(paraguay, spagnolo).*
  - *lingua(peru, spagnolo).*
- *confina_cona*(C_1, C_2) – vero se C_1 e C_2 confinano e $C_1 \leq C_2$ alfabeticamente
  - *confina_cona(argentina, brasile).*
  - *confina_cona(argentina, cile).*
  - *confina_cona(argentina, paraguay).*
  - *confina_cona(brasile, paraguay).*
  - *confina_cona(brasile, peru).*
  - *confina_cona(cile, peru).*
- *confina_con*(C_1, C_2) – vero se C_1 e C_2 confinano
  - *confina_con(X, Y)* $\leftarrow$ *confina_cona(X, Y).*
  - *confina_con(X, Y)* $\leftarrow$ *confina_cona(Y, X).*

Si possono formulare le seguenti query per le quali si ottengono le risposte riportate:

- ask *lingua(cile, spagnolo).*
  risposta: yes;
- ask *lingua(venezuela, spagnolo).*
  no, la query non è conseguenza logica (conoscenza insufficiente) ma non dice che sia falsa in generale;
- ask *lingua(X, spagnolo).*
  4 risposte fra cui quella con $X = cile$ per la quale *lingua(cile, spagnolo)* risulta conseguenza logica della base di conoscenza;
- ask *confina_cona(paraguay, X).*
  nessuna risposta;
- ask *confina_con(paraguay, X).*
  risposte $X = argentina$ e $X = brasile$.
- ask *confina_con(X, Y).*
  12 risposte;
- ask *confina_con(cile, Y)* $\wedge$ *superficie(Y, A)* $\wedge$ $A > 2000000$.
  si noti che il predicato $>$ (tipicamente predefinito) ha argomenti numerici ed è qui scritto in forma infissa.

Aggiungendo altri fatti

- *capitale(A, B)* – vero se B capitale di A
  - *capitale(argentina, buenos_aires).*
  - *capitale(cile, santiago).*
  - *capitale(peru, lima).*
  - *capitale(brasile, brasilia).*
  - *capitale(paraguay, asuncion).*
- *nome(E, N)* – vero se la stringa N è il nome di E
  - *nome(buenos_aires, «Buenos Aires»).*
  - *nome(santiago, «Santiago»).*
  - *nome(lima, «Lima»).*
  - *nome(brasilia, «Brasilia»).*
  - *nome(asuncion, «Asunción»).*
  - *nome(argentina, «Argentina»).*
  - *nome(cile, «Cile»).*
  - *nome(peru, «Perù»).*
  - *nome(brasile, «Brasile»).*
  - *nome(paraguay, «Paraguay»).*

Una query potrebbe chiedere il nome della capitale del Cile:
ask *capitale(cile, C)* $\wedge$ *nome(C, N).*

5.4. Sostituzioni e Dimostrazioni

Per implementare il ragionamento su basi di conoscenza e query Datalog si possono generalizzare le procedure bottom-up e top-down per basi di clausole definite proposizionali. Si ponga attenzione al fatto che in clausola Datalog una variabile *libera* indica che tutte le istanze della clausola dovranno essere vere, al variare delle possibili assegnazioni. Una dimostrazione potrà anche basarsi su istanze diverse di una stessa clausola.

5.4.1. Istanze e Sostituzioni

Come per le query, un'**istanza** di clausola si ottiene sostituendo variabili con termini uniformemente: ogni occorrenza di una data variabile dev'essere sostituta con lo stesso termine. Una **sostituzione**. Una **sostituzione** specifica, per ciascuna variabile, il termine da sostituire:

$$\{V_1/t_1, ..., V_n/t_n\}$$

- ogni V_i è una distinta variabile e ogniu t_i è un termine;
- ogni V_i/t_i si dice **binding** per la variabile V_i e si dirà in **forma normale** se nessuna V_i occorre in un t_j.

Esempio 38. Sostituzioni:
- $\{X/Y, Z/$ cile$\}$ è una sostituzione in forma normale;
- $\{X/Y, Z/X\}$ non è in forma normale: X occorre sia a sinistra sia a destra di associazioni diverse.

Un'*espressione* è un termine, un atomo o una clausola. Un'**istanza** $e\sigma$ dell'espressione e si ottiene dall'**applicazione** di $\sigma = \{V_1/t_1, ..., V_n/t_n$ a e: ogni occorrenza di V_i va sostituita con t_i. L'istanza si dice **ground** se non contiene variabili.

Esempio 39. Diverse applicazioni di sostituzioni ad atomi:

- *confina_con(peru, X)* $\{X/$ *cile*$\}$ = *confina_con(peru, cile)*
- *confina_con(Y, cile)* $\{Y/$ *peru*$\}$ = *confina_con(peru, cile)*
- *confina_con(peru, X)* $\{Y/$ *peru*$, Z/X\}$ = *confina_con(peru, X)*
- $p(X, X, Y, Y, Z)\{X/Z, Y/$ *brasile*$\} = p(Z, Z, brasile, brasile, Z)$

Le sostituzioni si applicano anche alle clausole: data $\sigma = \{X/Y, Z/$ *peru*$\}$,
$[p(X, Y) \leftarrow q(peru, Z, X, Y, Z)]\sigma = p(Y, Y) \leftarrow q(peru, peru, Y, Y, peru)$

Un **unificatore** delle espressioni e_1 e e_2 è una sostituzione σ tale che

$$e_1\sigma = e_2\sigma$$

Quando esiste un tale unificatore si dice che e_1 e e_2 sono *unificabili* o che si *unificano*.

Esempio 40 *(Esempi di unificatori)* **.**
- $\{X/$ *cile*$, Y/$ *peru*$\}$ è un unificatore per *confina_con(peru, X)* e *confina_con(Y, cile)*
  dalla cui applicazione si ottiene: *confina_con(peru, cile)*
- $\{X/a, Y/b\}$ unificatore di $t(a, Y, c)$ e $t(X, b, c)$
  per cui: $t(a, Y, c)\{X/a, Y/b\} = t(X, b, c)\{X/a, Y/b\} = t(a, b, c)$

Diversi unificatori possibili di $p(X, Y)$ e $p(Z, Z)$ sono:
$\{X/b, Y/b, Z/b\}$, $\{X/c, Y/c, Z/c\}$, $\{X/Z, Y/Z\}$, $\{Y/X, Z/X\}$, ecc.

- i primi due specificano precisamente i valori sostituiti
- gli altri due sono *più generali*.

L'**unificatore più generale**, *most general unifier, MGU* σ di e_1 ed e_2 è l'unificatore tale che, considerato qualunque altro loro unificatore σ', risulta che $e\sigma'$ è un'istanza di $e\sigma$, per ogni espressione e.
Si dirà che e_1 è una **ridenominazione** di e_2 se e solo se esse sono istanze l'una dell'altra, ossia differiscono solo nei nomi delle variabili. Due espressioni unificabili avranno almeno un MGU e, applicando loro degli MGU, si otterranno renaming

reciproci: dati σ e σ' MGU di e_1 ed e_2 si ha che $e_1\sigma$ è un renaming di $e_1\sigma'$ (analogamente per e_2).

Esempio 41. Due MGU degli atomi $p(X,Y)$ e $p(Z,Z)$ sono $\{X/Z, Y/Z\}$ e $\{Z/X, Y/X\}$. Applicando entrambi a $p(X,Y)$ si ottengono: $p(X,Y)\{X/Z,Y/Z\} = p(Z,Z)$ e $p(X,Y)\{Z/X,Y/X\} = p(X,X)$ che è un renaming di $p(Z,Z)$.

5.4.2. Procedura Bottom-up con Variabili

Per estendere la procedura bottom-up proposizionale al Datalog, si deve effettuare preventivamente il **grounding** degli assiomi della base di conoscenza ottenendo le *istanze ground* delle clausole, sostituendo uniformemente nelle clausole costanti a variabili. Le costanti da considerare sono quelle che occorrono nella base di conoscenza o nella query. Qualora non ve ne fossero, se ne deve inventare una nuova.

Esempio 42. Data la base di conoscenza con le clausole Datalog;

- $q(a)$
- $q(b)$
- $r(a)$
- $s(W) \leftarrow r(W)$
- $p(X,Y) \leftarrow q(X) \wedge S(Y)$

Tutte le istanze ground saranno:

- $q(a)$
- $q(b)$
- $r(a)$
- $s(a) \leftarrow r(a)$
- $s(b) \leftarrow r(b)$
- $p(a,a) \leftarrow q(a) \wedge s(a)$
- $p(a,b) \leftarrow q(a) \wedge s(b)$
- $p(b,a) \leftarrow q(b) \wedge s(a)$
- $p(b,b) \leftarrow q(b) \wedge s(b)$

Applicando la procedura BU proposizionale si derivano atomi *ground*. È facile desumere che possibili conseguenza logiche sono: $q(a), q(b), r(a), s(a), p(a,a), p(b,a)$

Esempio 43. Data la base di conoscenza con:

- $p(X,Y)$
- $g \leftarrow p(W,W)$

e la query ask g, la procedura BU introduce ad hoc la nuova costante c. Il grounding della base sarà:

- $p(c,c)$

- $g \leftarrow p(c, c)$

La BU proposizionale deriva $\{p(c, c), g\}$, per cui la rispota è `yes`.
Per la query ask $p(b, d)$, il grounding della base sarà:

- $p(b, b)$
- $p(b, d)$
- $p(d, b)$
- $p(d, d)$
- $g \leftarrow p(b, b)$
- $g \leftarrow p(d, d)$

La BU proposizionale deriva $\{p(b, b), p(b, d), p(d, b), p(d, d), g\}$ per cui la risposta è `yes`.

Si può dimostrare che la procedura BU, applicata al grounding di una base di conoscenza, è **corretta** e **completa**.

5.4.3. Unificazione

Dati due termini o atomi, occorre determinare se si unificano e, nel caso, restituire un loro unificatore.
Il seguente algoritmo consente di trovare un eventuale MGU di due atomi o termini e, altrimenti, restituisce $\perp$ per indicare la mancata unificabilità.

ALGORITMO 19 — *Algoritmo di unificazione*

```
1:  procedure Unify(t_1, t_2)
2:  Inputs
3:      t_1, t_2: atomi o termini
4:  Output
5:      MGU di t_1 e t_2 se esiste, altrimenti ⊥
6:  Local
7:      E: insieme di uguaglianze
8:      S: sostituzione
9:  E ← {t_1 = t_2}
10: S = ∅
11: while E ≠ ∅ do
12:     selezionare e rimuovere α = β da E
13:     if β non identica ad α then
14:         if α variabile then
15:             sostituire α con β ovunque in E e S
16:             S ← {α/β} ∪ S
17:         else if β variabile then
```

```
        sostituire β con α ovunque in E e S
        S ← {β/α} ∪ S
    else if α è p(a_1, ..., a_n) e β è p(b_1, ..., b_n) then
        E ← E ∪ {a_1 = b_1, ..., a_n = b_n}
    else return ⊥
return S
```

L'algoritmo lavora su un insieme E di uguaglianze ($\alpha = \beta$) che implicano e sono implicate dall'unificazione e un insieme S di binding che formeranno la sostituzione cercata. Se $\alpha/\beta \in S$ allora, per costruzione, α sarà una variabile che non appare altrove in S o in E. Nel caso in cui α e β siano atomi, essi devono avere stesso simbolo di predicato e stessa arietà, altrimenti l'unificazione fallisce.

Esempio 44. Volendo unificare $p(X, Y, Y)$ e $p(a, Z, b)$:

- $E = \{p(X, Y, Y) = p(a, Z, b)$ e $S = \{\}$, inizialmente;
- $E = \{X = a, Y = Z, Y = b\}$, dopo la prima iterata;
- $E = \{Y = Z, Y = b\}, S = \{X/a\}$;
- $E = \{Z = b\}, S = \{X/a, Y/Z\}$
- $E = \{\}, S = \{X/a, Y/b, Z/b$

Il risultato finale è S.
Provando a unificare $p(a, Y, Y)$ e $p(Z, Z, b)$:

- $E = \{p(a, Y, Y) = p(Z, Z, b)\}, S = \{\}$, inizialmente;
- $E = \{a = Z, Y = Z, Y = b\}$
- $E = \{Y = a, Y = b\}$
- $E = \{a = b\}$

resta $a = b$ ma le costanti a e b non sono uficabili, quindi si restituisce $\perp$.

5.4.4. Risoluzione Definita con Variabili

La proceudura top-down proposizionale può essere estesa per gestire le variabili ammettendo istanze di regole nella derivazione.
Una **clausola di risposta generalizzata** avrà la forma:

$$yes(t_1, ..., t_k) \leftarrow a_1 \wedge a_2 \wedge ... \wedge a_m$$

dove $t_1, ..., t_k$ sono termini e gli $a_1, ..., a_m$ sono atomi.
L'uso del predicato `yes` consente l'estrazione della risposta, ossia di determinare quali istanze ella query seguano logicamente da una base di clausole definite.
Data la query q, si considera in partenza la clausola di risposta iniziale:

$$yes(V_1, ..., V_k) \leftarrow q$$

dove $V_1, ..., V_k$ sono le variabili della query q. Intuitivamente, un'istanza di $yes(V_1, ..., V_k)$ risulta vera se la corrispondente istanza di q è vera. In ogni fase successiva, l'algoritmo

1. seleziona un atomo nel corpo della clausola di risposta corrente;
2. sceglie una clausola di KB la cui testa si unifichi con tale atomo.

Nella **risoluzione SLD**, avendo selezionato a_1 della clausola di risposta generalizzata corrente $yes(t_1, ..., t_k) \leftarrow \underline{a_1} \wedge a_2 \wedge ... \wedge a_m$, se la clausola scleta dalla base di conoscenza è:

$$a \leftarrow b_1 \wedge ... \wedge b_p$$

con a_1 e a unificabili da un MGU σ, la risolvente sarà la nuova clausola di risposta:

$$\big[yes(t_1, ..., t_k) \leftarrow b_1 \wedge ... \wedge b_p \wedge a_2 \wedge ... \wedge a_m\big]\sigma$$

Ripetendo passi di risoluzione si ottiene una **derivazione SLD**, ossia una sequenza $\gamma_0, \gamma_1, ..., \gamma_n$ di clausole di risposta in cui:

- γ_0 è una clausola di risposta corrispondente alla query originaria q; date $V_1, ..., V_k$ variabili libere di q : $yes(V_1, ..., V_k) \leftarrow q$
- ogni γ_i si ottiene per risoluzione SLD:
  - selezionando a_1 nel corpo di γ_{i-1};
  - scegliendo dalla base di conoscenza una copia $a \leftarrow b_1 \wedge ... \wedge b_p$ la cui testa a si unifichi con a_i tramite un certo MGU σ;
  - sostituendo a_1 con il corpo $b_1 \wedge ... \wedge b_p$;
  - applicando σ alla clausola di risposta risultante;
- γ_n sarà la **risposta** della forma $yes(t_1, ..., t_k) \leftarrow$ di una dimostrazione terminata con successo. In risposta alla query si restituirà: $V_1 = t_1, ..., V_k = t_k$ dove i t_i sono i termini determinati dai binding delle variabili della query V_i.

ALGORITMO 20 — *Algoritmo di dimostrazione top-down per il Datalog*

```
1: non-deterministic procedure Prove_datalog_TD(KB, q)
2: Input
3:     KB: insieme di clausole definite
4:     Query q: insieme di atomi da provare, con variabili V_1, ..., V_k
5: Output
6:     sostituzione θ se KB ⊨ qθ altrimenti fallisce
7: Local
8:     G: clausola di risposta generalizzata
9: Impostare G a yes(V_1, ..., V_k) ← q
10: while G non è una risposta do
```

11: Sia $G = \textbf{yes}(t_1, ..., t_k) \leftarrow a_1 \wedge a_2 \wedge ... \wedge a_m$
12: Selezionare l'atomo a_1 nel corpo di G
13: Scegliere una clausola $a \leftarrow b_1 \wedge ... \wedge b_p \in KB$
14: ridenominando tutte le variabili con nuovi nomi
15: Sia $\sigma \leftarrow \text{Unify}(a_1, a)$
16: **if** $\sigma = \perp$ **then** fallire
17: Assegna a G la clausola $(\textbf{yes}(t_1, ..., t_k) \leftarrow b_1 \wedge ... \wedge b_p \wedge a_2 \wedge ... \wedge a_m)\sigma$
18: **return** $\{V_1 = t_1, ..., V_k = t_k\}$ dove G è $\textbf{yes}(t_1, ..., t_k) \leftarrow$

La procedura top down per KB Datalog è non deterministica: si possono trovare tutte le derivazioni tentando altre scelte che portino al successo. Essa fallisce se tutte le scelte portano al fallimento: non esiste alcuna derivazione.
La scelta della clausola può essere implementata come algoritmo di ricerca, come nel caso proposizionale, mantenendo la lista degli atomi da dimostrare.

Esempio 45 *(Shakira)* **.** Data una base di conoscenza:

- *luogo_nascita(shakira, barranquilla).*
- *luogo_nascita(P, L)* $\leftarrow$ *parte_di(S, L)* $\wedge$ *luogo_nascita(P, S).*
- *parte_di(barranquilla, atlantico).*
- *parte_di(atlantico, colombia).*
- *parte_di(colombia, america_del_sud).*

per rispondere alla query
ask *luogo_nascita(P, colombia).*
si può costruire la *derivazione* seguente:

- *yes(P)* $\leftarrow$ *luogo_nascita(P, colombia).*
  risolta con *luogo_nascita*(P_1, L_1) $\leftarrow$ *parte_di*(d_1, L_1) $\wedge$ *luogo_nascita*(P_1, d_1).
  usando $\{P_1/P, L_1/\ colombia\}$;
- *yes(P)* $\leftarrow$ *parte_di*$(d_1,$ *colombia)* $\wedge$ *luogo_nascita*(P, d_1).
  risolta con *parte_di(atlantico, colombia).*
  usando $\{d_1/\ atlantico\}$;
- *yes(P)* $\leftarrow$ *luogo_nascita(P, atlantico).*
  risolta con *luogo_nascita*(P_2, L_2) $\leftarrow$ *parte_di*(d_2, L_2) $\wedge$ *luogo_nascita*(P_2, d_2).
  usando $\{P_2/P, L_2/\ atlantico\}$;
- *yes(P)* $\leftarrow$ *parte_di*$(d_2,$ *atlantico)* $\wedge$ *luogo_nascita*(P, d_2).
  risolta con *parte_di(barranquilla, atlantico).* usando $\{d_2/\ barranquilla\}$;

- *yes(P)* ← *luogo_nascita(P, barranquilla).*
  risolta con *luogo_nascita(shakira, barranquilla).*
  usando $\{P/\ shakira\}$;
- *yes(shakira)* ← .

5.5. Simboli di Funzione e Strutture dati

Il Datalog richiede un nome (simbolo di costante) per ogni individuo sul quale si debba ragionare. Spesso risulta più semplice identificare un individuo indirettamente, ossia *in termini di altri individui.*
Considerando una costante per individuo, si può rappresentare solo un numero inito di invididui, fissato alla costruzione della base di conoscenza. Per ragionare su un dominio potenzialmente *infinito* si fa ricorso alla **programmazione logica**, e in particolare, al linguaggio Prolog.

Esempio 46. Vediamo alcuni esempi:
1. Riferimenti temporali:
   - *orari*:
     - una costante per ogni orario, ad esempio `inizio-lezione: 1.30 p.m.` ;
     - numero di ore dopo mezzanotte e numero di minuti dopo l'ora.
   - *date*:
     - una costante per data (sono infinite);
     - più facile in termini di `anno, mese, giorno`
2. Sistema QA:
   - se gli individui sono le *frasi* servirebbero troppi nomi;
   - se le frasi fossero raprpesentate come sequenze di parole:
     - nella pratica si potrebbero usare solo un vocabolario finito di parole;
     - oppure aveva parole costituite come sequenze di sillabe o lettere.
3. Liste (di studenti):
   - lista come individuo con sue proprietà come `lunghezza, elemento_i`
   - oppure scegliendo un nome a ciascuna lista, ma è poco pratico;
   - o definendo le liste in termini dei loro elementi.

Le funzioni consentono di descrivere individui indirettamente, in termini di altri individui. Alla sintassi si aggiunge la nozione di *simbolo* di **funzione**, una parola che comincia con una lettera minuscola. Quindi il linguaggio viene esteso nella nozione di **termine** che potrà essere una variabile, una costante o avere la forma

$$f(t_1, ..., t_n)$$

dove f è un simbolo di funzione (n-aria) e i t_i sono termini. Nelle clausole i termini possono comparire esclusivamente all'interno di atomi: le funzioni sono distinte dai predicati.
In ogni interpretazione $\langle D, \varphi, \pi \rangle$ la φ dev'essere estesa: si assegna una funzione $D^n \mapsto D$ a ogni simbolo di funzione n-aria: essa, per ogni termien ground, deve specificare l'individuo denotato. Le costanti possono essere viste come funzioni 0-arie, cioè senza argomenti.

Esempio 47. Per definire delle date si possono usare *costanti*:
- numeri interi naturali;
- *gen, feb, mar, apr, mag, giu, lug, ago, set, ott, nov, dic*;

funzioni: (definizione *estensionale*)
- *ce* per date *common era*: $ce(Y, M, D)$ date con anno Y, mese M e giorno D
- *bce* per date prima della *common era*;

predicati:
- *mese(M, N)* vero se M mese dall'anno con numero d'ordine N, ad esempio *mese(gen, 1)*
- $precede(D_1, D_2)$ vero se D_1 precede D_2

Il predicato $<$ rappresenta la relazione `minore_di` sugli interi, può essere descritto in termini di clausole, ma più spesso è predefinito.

Programmazione Logica
Qualunque funzione computabile può essere calcolata usando una base di clausola con simboli di funzione ossia è interpretabile come **programma logico** (adottando una *semantica operazionale*).
Il linguaggio dei programmi logici è *Turing equivalente*. Con un solo simbolo di funzione e una sola costante, si può definire un numero infinito di termini o atomi ground che consente di ragionare su un numero di individui potenzialmente infinito. Inoltre, con le funzioni si possono definire le tipiche **strutture dati** per i linguaggi di programmazione.

Esempio 48. Struttura di albero (con etichette).
funzioni:
- *nodo(N, LT, RT):* denota un nodo interno di un albero con il nome N e due (sotto)-alberi sinistro LT e destro RT;
- *foglia(L)*: indica un nodo-foglia con etichetta L;

relazioni definita in forma ricorsiva:
- *alla_foglia(L, T)* vera se L è l'etichetta di una foglia dell'albero T:
  - *alla_foglia(L, foglia(L))*

  - *alla_foglia(L, nodo(N, LT, RT))* ← *alla_foglia(L, LT)*
  - *alla_foglia(L, nodo(N, LT, RT))* ← *alla_foglia(L, RT)*
- *al_nodo(L, T)* vera se L è l'etichetta di un nodo interno dell'albero T:
  - *al_nodo(L, nodo(L, LT, RT))*;
  - *al_nodo(L, nodo(N, LT, RT))* ← *al_nodo(L, LT)*
  - *al_nodo(L, nodo(N, LT, RT))* ← *al_nodo(L, RT)*

5.5.1. Procedure di Dimostrazioni con Funzioni

Per gestire i termini con funzioni vanno estese le procedure definite per il Datalog. Il problema principale è che il numero di termini possibili è infinito.
Nel definire una procedura bottom-up sulla base di quella per basi di clausole definite proposizionali, se si operasse preventivamente il grounding delle clausole, una clausola potrebbe generare un'infinita sequenza di conseguenza sulla base del numero di termini formabili usando le funzioni.
Una procedura ingenua di grounding potrebbe innescare un problema di **starvation**, con clausole che vengano sistematicamente trascurate.

Esempio 49. Base di conoscenza con le clausole:
1. *num(0)*
2. *num(s(N))* ← *num(N)*
3. $a \leftarrow b$
4. b

Senza selezione fair, nel *forward chaining* si selezionerebbe prima la 1. e, successivamente, sempre la 2. che porta ripetutamente a derivare una nuova conseguenza ad ogni iterata: non arrivando a selezionare anche 3. e 4., non si potrà mai derivare a o b.

Va pertanto considerata una *proprietà* come la **fairness** del criterio di selezione delle clausole da elaborare che assicura che ogni clausola della base prima o poi debba essere selezionata. La procedura BU con un criterio di selezione *equo (fair)* risulta completa: ogni conseguenza potrà essere generata.
Per estendere la procedura TD per il Datalog con il trattamento di termini costruiti da funzioni, occorre una procedura di *unificazione* che possa seguire ricorsivamente la struttura dei termini in profondità, considerando anche le applicazioni di funzioni a diversi livelli. Nell'algoritmo esteso per trovare MGU, una variabile X non potrà unificarsi con termini t (con $t \neq X$) in cui essa occorre come, ad esempio, $g(f(X))$. Serve quindi un **controllo di occorrenza** aggiuntivo, senza del quale la procedura non risulterebbe più corretta.

Esempio 50. Data una base di conoscenza con una sola clausola:

$$\{lt(X, s(X))\}$$

nella sua interpretazione intesa il predicato *lt* corrisponde al classico *minore di* definito sul dominio degli interi ee la funzione *successore* $s(X)$ serve a denotare l'intero $X + 1$.
Per la query `ask lt(Y, Y)`, la procedura dovrebbe *fallire*: l'atomo è falso nell'interpretazione intesa perchè nessun numero è minore di se stesso.
Tuttavia se non si impedisse l'unificazione di X e $s(X)$ (per mancato controllo di occorrenza) la dimostrazione avrebbe successo e la correttezza della procedura sarebbe compromessa.

In un *algoritmo di unificazione* con simboli di funzione e *occurs-check*, avendo selezionato $\alpha = \beta$, si restituisce $\perp$ se α è una variabile e β è un termine che la contiene essendo diverso da α stesso. Omettendo il controllo, tipicamente per aumentarne l'efficienza, la procedura non sarà più corretta. Una procedura non sound potrebbe derivare un goal g anche quando questo non fosse una conseguenza logica della base di conoscenza.

Esempio 51 *(Risoluzione SLD)* **.** Considerata una base di conoscenza con le clausole

1. *append(c(A, X), Y, c(A, Z)) ← append(X, Y, Z)*
2. *append(nil, Z, Z)*

una derivazione per la query

$$\text{ask } append(F, c(L, nil), c(l, c(i, c(s, c(t, nil)))))$$

è la seguente:

- *yes(F, L) ← append(F, c(L, nil), c(l, c(i, c(s, c(t, nil)))))* risolvendo con *append(c(A_1, X_1), Y_1, c(A_1, Z_1)) ← append(X_1, Y_1, Z_1)* copia della 1. con variabili ridenominate aggiungendo l'indice 1:
  - sostituzione: $\{F/c(l, X_1), Y_1/(L, nil), A_1/l, Z_1/c(i, c(s, c(t, nil)))$
- *yes(c(l, X_1), L) ← append(X_1, c(L, nil), c(i, c(s, c(t, nil))))*: risolvendo con *append(c(A_2, X_2), Y_2, c(A_2, Z_2)) ← append(X_2, Y_2, Z_2)*;
  - sostituzione: $\{X_1/c(i, X_2), Y_2/c(L, nil), A_2/i, Z_2/c(s, c(t, nil))$;
- *yes(c(l, c(i, X_2)), L) ← append(X_2, c(L, nil), c(s, c(t, nil))):* rilvendo con *append(c(A_3, X_3), Y_3, c(A_3, Z_3)) ← append(X_3, Y_3, Z_3)*
  - sostituzione: $\{X_2/c(s, X_3), Y_3/c(L, nil), A_3/s, Z_3/c(t, nil)\}$
- *yes(c(l, c(i, c(s, X_3))), L) ← append(X_3, c(L, nil), c(t, nil))*: applicabili entrambe le clausole, scegliendo la 1.: si risolve con *append(c(A_4, X_4), Y_4, c(A_4, Z_4)) ← append(X_4, Y_4, Z_4)*
  - sostituzione: $\{X_3/c(t, X_4), Y_4/c(L, nil), A_4/t, Z_4/nil$;
- *yes(c(l, c(i, c(s, c(t, X_4)))), L) ← append(X_4, c(L, nil), nil)*

qui la dimostrazione fallisce: le teste delle clausole non si unificano con l'atomo nel corpo. Si torna al punto di scelta precedente:

- *yes(c(l, c(i, c(s, X_3))), L)* ← *append(X_3, c(L, nil), c(t, nil))*: scegliendo invece la 2., si risolve con: *append(nil, Z_5, Z_5)*;
  - sostituzione $\{Z_5/c(t, nil), X_3/nil, L/t$;
- *yes(c(l, c(i, c(s, nil))), t)* ←

e la dimostrazione ha successo con risposta $F = c(l, c(i, c(s, nil))), L = t$

Liste: Notazione Prolog

Abbreviazioni ammesse nella notazione del Prolog:

- [] o *nil* denotano la lista vuota;
- $[E \mid R]$ è la lista con primo elemento E e resto della lista R, scritta anche *cons(E, R)*;
- semplificazione: $[X \mid [Y]]$ si può scrivere $[X, Y]$, se Y è una sequenza di valori: ad esempio $[a]$ per $[a \mid []]$, $[b \mid [a \mid nil]]$ e $[a, b \mid C]$ per $a \mid [b \mid C]]$

Esempio 52. Definizione che usa la notazione:

- *append([A | X], Y, [A | Z])* ← *append(X, Y, Z)*
- *append([ ], Z, Z)*

Data la query ask $append(F, [L], [l, i, s, t])$
una risposta che si ottiene è $F = [l, i, s], L = t$.
La dimostrazione resta la stessa: vengono ridenominate una funzione e una costante.

5.6. Uguaglianza

A volte è utile usare più termini per denotare uno stesso individuo: ad esempio i termini $3 * 5, F, 273 - 258$ e 15 possono denotare lo stesso numero. Altre volte serve che ogni nome si riferisca a un diverso individuoL ad esempio un nome distinto per insegnamenti differenti. Spesso non si sa due nomi denotino lo stesso individuo: ad esempio se `postino_delle_8` e `postino_delle_15` siano la stessa persona. Negli esempi di ragionamento in Datalog presentati in precedenza, tutte le risposte erano valide a prescindere dal fatto che i termini denotassero individui diversi o meno.
Può essere utile considerare il predicato speciale «=» avente un'interpretazione intesa standard *indipendente* dal dominio da rappresentare. Dati due termini t_1 e t_2 si può scrivere l'atomo

$$t_1 = t_2$$

e sarà vero in un'interpretazione I se e solo se t_1 e t_2 in I denotano lo stesso individuo.

Non si tratta di semplice similarità o identicità ma di *identità*: due nomi per un solo individuo, e non due individui simili del dominio.

5.6.1. Ammettere Asserzioni d'Uguaglianza

Spesso è utile poter concludere che termini distinti debbano denotare lo stesso individuo. Se non si ammettono atomi con predicato d'uguaglianza come teste delle clausole, un termine può essere uguale solo a se stesso in ogni interpretazione. Per poter derivare relazioni d'uguaglianza, occorrono clausole con questo tipo di atomi nella testa. Le alternative possibili sono:

1. *assiomatizzare* l'uguaglianza come un qualunque altro predicato: aggiungere clausole che codifichino l'interpretazione del predicato $=$;
2. definire *procedure speciali* d'inferenza per l'uguaglianza: attraverso regole di riscrittura, si mappano termini diversi che denotino uno setsso individuo su una forma standard.

5.6.2. Unique Names Assumption

In alternativa dell'assiomatizzazione dell'uguaglianza si può adottare una *convezione*. Nella semantica delle clausole definite data in precedenza, la funzione φ non è necessariamente iniettiva, quindi termini diversi possono denotare lo setsso individuo o individui distinti.

Con l'**assunzione di unicità dei nomi**, o *Unique Names Assumption (UNA)*, termini ground diversi denotano individui distinti. Tale assunzione è tipica del contesto delle basi di dati. Per ogni coppia di termini ground distinti t_1 e t_2 si assumerà:

$$t_1 \neq t_2$$

dove $\neq$ corrisponde ad assumere la verità di $\neg(t_1 = t_2)$ in ogni interpretazione. Sotto UNA, un atomo con $\neq$ può occorrere nel corpo delle clausole.

Quindi sotto UNA, termini ground sono identici solo se si unificano. Ciò non vale per termini non ground, ad esempio l'atomo $a \neq X$ ha istanze vere nelle quali X assume un certo valore, diciamo b, e un'istanza falsa in cui X assume il valore a. La UNA è utile a integrare conoscenza proveniente dal database, senza essere costretti ad esplicitare troppe distinzioni, come ad esempio quelle tra le persone con nomi diversi. Tuttavia la UNA risulta inappropriata in certi altri casi, come $2 + 2 \neq 4$.

5.7. Assunzione di Conoscenza Completa

Come visto in precedenza per la Logica Proposizionale, l'**assunzione di conoscenza completa**, consente di derivare conclusioni altrimenti non ammissibili rispetto alla semantica standard della Logica. Così un enunciato che non segua logicamente dalla base di conoscenza potrà essere considerato falso. Come visto

in precedenza, questo consente anche di definire una forma di **negazione come fallimento** (NAF).
Per estendere l'assunzione di conoscenza completo al caso dei programmi logici con variabili e funzioni si devono considerare: *assiomi d'uguaglianza*, la prorietà di *chiusura del dominio* e una nozione più sofisticata di *completamento*.

Esempio 53. Sia data la relazione *student* definita in una base di conoscenza con le sole clausole:

- *student(gianni)*
- *student(mario)*
- *student(carla)*

Assumendo che la conoscenza sia completa, i tre individui sarebbero gli unici studenti;

$$student(X) \leftrightarrow X = \text{gianni} \vee X = \text{mario} \vee X = \text{carla}$$

ossia si potrebbe dire che, se X è *gianni, mario o carla*, allora è uno studente e se X è studente allora dev'essere uno dei tre.
L'assunzione di conoscenza completa includa la UNA. Ad esempio, la dimostrazione dell'atomo $\neg\ student(gino)$ richiederebbe di dimostrare $\text{gino} \neq \text{gianni} \vee \text{gino} \neq \text{mario} \vee \text{gino} \neq \text{carla}$, atomi immediatamente provati sotto UNA.

Dato un predicato p, la clausola

$$p(t_1, ..., t_k) \leftarrow B$$

in **forma normale di Clark** diventa

$$p(V_1, ..., V_k) \leftarrow \exists c_1 \cdots \exists c_m \quad V_1 = t_1 \wedge \cdots \wedge V_k = t_k \wedge B$$

dive, se la clausola è atomica allora B sarà *true*, le variabili $c_1, ..., c_m$ sono quelle originaria della clausola mentre le variabili $V_1, ..., V_k$ sono nuove variabili aggiuntive. Ponendo tutte le clausole per il dato predicato p in forma normale, usando uno stesso insieme di nuove variabili si può scrivere:

$$p(V_1, ..., V_k) \leftarrow B_1, \quad \cdots \quad p(V_1, ..., V_k) \leftarrow B_n$$

riassumibili in

$$p(V_1, ..., V_k) \leftarrow B_1 \vee \cdots \vee B_n$$

Tale enunciato è equivalente all'insieme di clausole originario.
Il **completamento** del predicato p sarà la formula logica:

$$\forall V_1 \cdots \forall V_k p(V_1, ..., V_k) \leftrightarrow B_1 \vee \cdots \vee B_n$$

dove, nei corpi, la **negazione come fallimento** ($\sim$) viene sostituita dlla negazione logica standard ($\neg$). Dal punto di vista della semantica, $p(V_1, ..., V_k)$ sarà vero se e solo se è vero almeno uno dei corpi B_i.
Il **completamento** di una base di conoscenza comprende i completamenti di ogni predicato che occorre nella base.
Sotto l'assunzione di conoscenza completa, si possono definire relazioni per la cui definizione le clausole definite non sono sufficientemente espressive.

Esempio 54. Date le clausole considerate in precedenza:
- *student(gianni)*
- *student(mario)*
- *student(carla)*

la forma normale sarà:
- $student(V) \leftarrow V = gianni$
- $student(V) \leftarrow V = mario$
- $student(V) \leftarrow V = carla$

Questa definizione è equivalente a

$$student(V) \leftarrow V = \text{gianni} \vee V = \text{mario} \vee V = \text{carla}$$

quindi il completamento di *student* è il seguente

$$\forall V\, student(V) \leftrightarrow V = \text{gianni} \vee V = \text{mario} \vee V = \text{carla}$$

Esempio 55 *(Esami superati)* **.** Si consideri la definzione ricorsiva di un predicato
- $lista_superati([\,], St, MinPass)$
- $al_nodo([C|R], St, MinPass) \leftarrow$
  $ha_superato(St, C, MinPass) \wedge al_nodo(R, St, MinPass)$

In forma normale, cambiando i nomi delle variabili:
- $al_nodo(L, S, M) \leftarrow L = []$
- $al_nodo(L, S, M) \leftarrow \exists C \exists R L = [C \mid R] \wedge$
  $ha_superato(S, C, M) \wedge al_nodo(R, S, M)$

Il completamento è il seguente:

$$\forall L \forall S \forall M\ al_nodo(L, S, M) \leftrightarrow L = [\,] \vee$$
$$\exists C \exists R (L = [C \mid R] \wedge ha_superato(S, C, M) \wedge al_nodo(R, S, M))$$

Esempio 56. Si consideri una base di conoscenza con:
- *corso(C)* vero se C è un corso;
- *iscritto(S, C)* vero se S è iscritto a C.

Senza assunzione di conoscenza completa, non si potrebbe dimostrare *senza_iscritti(C)*, vero se non ci sono iscritti al corso C.
Con l'assunzione, usando la NAF, la definizione sarebbe:

- *senza_iscritti(C)* $\leftarrow$ *corso(C)* $\wedge \sim$ *con_iscritti(C)*
- *con_iscritti(C)* $\leftarrow$ *iscritto(S, C)*

da cui il completamento risultante è il seguente:

- $\forall C$ *senza_iscritti*$(C) \leftrightarrow$ *corso*$(C) \wedge \neg$ *con_iscritti*(C)
- $\forall c$ *con_iscritti*$(C) \leftrightarrow \exists S$ *iscritto*(S, C)

Occorre cautela nell'inclusione di variabili libere in atomi con la NAF: in genere cambiano il significato inteso. Il predicato *con_iscritti* serve ad evitare di avere una varibile libera nel contesto di una negazione tipi $\sim$ *iscritto*(S, C)

Procedure Complete di Dimostrazione con NAF

Risulta problematico adottare una procedura TD che possa trattare oltre a variabili e funzioni anche la NAF:

Esempio 57. Si consideri la base di conoscenza:

- $p(X) \leftarrow\sim q(X) \wedge r(X)$
- $q(a)$
- $q(b)$
- $r(d)$

e la query

$$\text{ask } p(X)$$

Per la semantica, ci sarebbe una sola risposta: $X = d$ essendo $r(d)$ e $\sim q(d)$ vere, $p(d)$ segue logicamente dalla base di conoscenza.
Ma la dimostrazione di $p(X)$ con la procedura TD fallisce:

- selezionato $\sim q(X)$, la procedura riesce a dimostrare $q(X)$ con $\{X/a\}$
- mentre $p(X)$ vero se $\{X/d\}$ essendo $\sim q(d)$ e $r(d)$

Questo mostra che la procedura TD risulta *incompleta* e *non corretta*: ad esempio, aggiungendo alla base di conoscenza la clausola $s(X) \leftarrow\sim q(X)$, dal fallimento di $q(X)$ si arriverebbe a poter derivare erroneamnte $s(X)$.

Per evitare i problemi causati da *variabili libere nei goal negati* la procedura dovrebbe posticipare tali sotto-obiettivi fino a quando le variabili libere non vengano legate. Qualora ciò non fosse possibile in alcun modo, la dimostrazione del goal si inceppa (*flounders*) e non si potrà concludere nulla su tale goal.

Esempio 58. Data la base di conoscenza:

- $p(X) \leftarrow\sim q(X)$

- $q(X) \leftarrow\sim r(X)$
- $r(a)$

con completamento:
- $p(X) \leftrightarrow \neg q(X)$
- $q(X) \leftrightarrow \neg r(X)$
- $r(X) \leftrightarrow X = a$

e la query

$$\text{ask } p(X)$$

Sostituendo $X = a$ ad $r(X)$ si ha $q(X) \leftrightarrow \neg(X = a)$ quindi: $p(X) \leftrightarrow X = a$.
La risposta giusta sarebbe $X = a$ ma il differimento del goal non aiuterebbe a trovarla. La procedura dovrebbe essere capace di analizzare i casi nei quali il goal è fallito.

Knowledge Graph e Ontologie

6.1. Knowledge Graph

6.1.1. Triple

Dato un linguaggio di rappresentazione logico e un mondo su quale ragionare, i progettisti devono scegliere individui e relazioni, ossia come decomporre il dominio d'interesse per formalizzarne un suo modello. Il livello di dettaglio dipende dal compito da svolgere. Ad esempio, la proprietà di essere di colore blu, `blu`, ascrivibile a diversi oggetti del mondo reale, può essere rappresentata in base allo *spettro di frequenze* della luce assorbite o riflesse.
Le relazioni andranno definite seguendo alcune linee guida ingegneristiche.

Esempio 59. *blu* può essere una categoria di classificazione appropriata per gli individui rappresentata come *relazione unaria*:
- *l'oggetto a è blu* si traduce con *blu(a)*;
- una query possibile sarebbe: «Cosa si conosce di colore blu?» traducibile in: ask $blu(X)$
- i valori di X restituiti rappresentano gli oggetti di colore blu.

Con questa rappresentazione, però, è difficile chiedere «Di che colore è l'oggetto *a*?» Nel linguaggio delle clausole definite, non si può chiedere ask $X(a)$. I nomi dei

predicati non possono essere variabili. Ciò diventa possibile in logiche di ordine superiore per qualsiasi proprietà di a.

Si può pensare a una forma di **reificazione**, ossia alla riduzione a oggetto di un concetto astratto, ad esempio la relazione fra un individuo e il suo colore, quindi il colore stesso pùo essere modellato come individuo:

- usando la costante *blu* per denotare il colore blu che diventa un individuo referenziabile come gli altri;
- definendo un predicato *colore(Ind, Val)*, dove *Val* è il colore dell'individuo *Ind*, si ha una relazione binaria tra individui fisici e i loro colori.
- si potrà allora chiedere: «Cose è di colore blu?» con la query ask $colore(X, blu)$

Esempio 60 *(Estensioni)* **.** *colore* come predicato binario non consente domande come «Quale proprietà di questo oggetto ha valore blu?», con risposta *colore*.
Un'ulteriore trasformazione può quindi prevedere la modellazione della proprietà *colore* come individuo e con la nuova relazione *prop*: ad esempio, per rappresentare l'enunciato «l'individuo a ha per la proprietà *colore* il valore *blu*» si può scrivere *prop(a, colore, blu)*.
Sono anche possibili tutte le query viste prima, riscrivendo le relazioni in termini di *prop*.

Il predicato ternario *prop* avrà la forma:

$$prop(Ind, Prop, Val)$$

con l'individuo *Ind* ha per la proprietà *Prop* il valore *Val*.
In alternativa si può considerare la struttura di **tripla** $\langle s, p, o \rangle$ con:

- s **soggetto**;
- p **predicato verbale**;
- o **oggetto**.

che può anche essere scritta come *enunciato*:

$$soggetto\ verbo\ oggetto$$

equivalente all'atomo *prop*(*soggetto*, *verbo*, *oggetto*) che, in notazione funzionale, si può scrivere anche *verbo(soggetto, oggetto)*.
In una tripla, il *verbo* è una **proprietà** p con un **dominio**, l'insieme di individui che possono essere soggetti in triple con verbo p e un **codominio**, l'insieme di valori che possono essere oggetti in triple con verbo p.
Un **attributo** è una coppia *proprietà-valore*, ad esempio una certa auto ha *colore blu*.

Esempio 61. Per trasformare in forma di tripla l'atomo *auto(a)*:

1. *auto* può essere rappresentato come *concetto*:

$$prop(a, type, auto)$$

- l'individuo a è nella classe *auto*;
- *type* è una proprietà speciale che collega individui a classi, spesso indicata con `is_a`
- la costante *auto* denota una classe di individui: l'insieme di tutte le cose, reali o potenziali, che sono automobili;

1. *auto* può essere rappresentato come *proprietà booleana*, con valore *true* per soggetti che sono auto:

$$prop(a, auto, true)$$

- una proprietà booleana ha codominio $\{true, false\}$, dove *true* e *false* sono costanti.

Le relazioni con specifiche prorpietà possono essere rappresentate con parole, numeri, ad esempio *num_prenotazione*, *num_volo*, *num_ordine*.

Esempio 62. L'azione del verbo *prestare* coinvolge tre attori, detti *agente*, *ricevente* e *paziente*. Data la frase «Lara ha prestato a Nino il libro 342», una sua rappresentazione possibile è: *prestitito(lara, nino, l342)*.
Introducendo una costante per l'azione specifica come *prestito3545* e una per il libro, si può scrivere in forma di triple:

- *prop(prestito3545, type, prestito)*
- *prop(prestito3545, agente, lara)*
- *prop(prestito3545, paziente, l342)*
- *prop(prestito3545, ricevente, nino)*
- *prop(l342, type, libro)*.

dove agente/ricevente/paziente sono relazioni tematiche ossia **ruoli** semantici.
La reificazione consente di aggiunge altre proprietà, come ad esempio la data dell'evento, il prezzo del libro, ...

6.1.2. Individui e Identificatori

Gli individui vanno denotati usando identificatori univoci. Ad esempio, nel contesto universitario si usa la matricola per riferirsi univocamente a uno studente, essendo il solo nominativo meno adeguato a evitare casi di omonimia.
Nel conesto del web, si può usare uno *Uniform Resource Identifier (URI)* o anche un *Internationalized Resource Identifier (IRI)* come nome univoco per identificare qualsiasi **risorsa**.

6.1.3. Rappresentazioni Grafiche

La relazione *prop* può essere interpretata in termini di *grafo orientato*: l'atomo *prop(Ind, Prop, Val)* può essere raffigurato con i *nodi Ind* e *Val* congiunti da un arco orientato etichettato con *Prop*. Il grafo risultante dalla rappresentazione di tali relazioni sarà un **knowledge graph** o **rete semantica**, con una mappatura diretta su una base di conoscenza tramite *prop*.

Esempio 63. La seguente figura rappresenta parte del KG che riguarda la calciatrice *Christine Sincalir* in Wikidata.

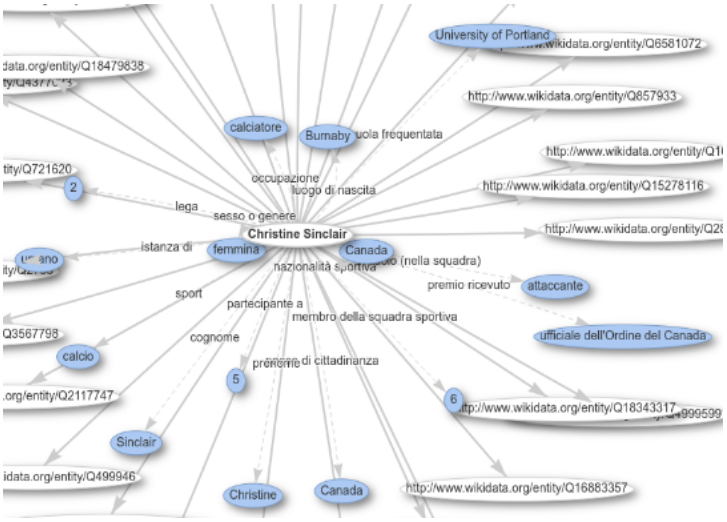


Figura 13: Frammento di grafo su Christine Sinclair da Wikidata

Diversi sono i vantaggi della notazione grafica:

- la facilità di visualizzazione delle relazioni senza essere costretti a imparare la sintassi di un dato linguaggio logico: ciò è d'ausilio ai progettisti nel'organizzazione della conoscenza essendo disponibili strumenti specifici per costruire mappe concettuali.
- la possibilità di ignorare le etichette con nomi privi di significato (come *prestitito3545* dell'esempio precedente): sono ammessi i cosiddetti nodi **blank**, ossia privi di etichetta, che possono servire a dare nomi arbitrari solo in caso di mappatura su un formalismo logico;
- l'efficienza della memorizzazione in un **triple store**: mentre un relational database ha bisogno della progettazione delle chiavi usate per gli indici, un triple store utilizza esattamente 8 indici per ritrovare le triple nelle diverse posizioni; una query basta a determinare se una particolare tripla sia in memoria, mediante semplice enumerazione, e sono possibili casi di query con soggetto, verbo, oggetto eventualmente non specificati (variabili).

6.2. Classi e Proprietà

Tipicamente, di un dominio si conoscono e formalizzano il database di fatti e le regole generali tramite le quali è possibile derivare altri fatti. La modalità con cui farlo costituisce una scelta progettuale.
Si distingue la **conoscenza primitiva** specificata esplicitamente e la **conoscenza derivata**, inferita da quella primita e/o altra conoscenza derivata.
Le regole permettono una rappresentazione più compatta della conoscenza: dato che non tutto è osservabile, attraverso relazioni derivate si possono trarre conclusioni a partire da osservazioni. La conoscenza su un dato dominio sarà in gran parte *inferita*, oltre che da fatti osservati e da conoscenza più generale disponibile o anche appresa. Grazie alle regole si potranno raggruppare gli individui in classi ed anceh associare proprietà generali alle classi, in modo che i loro individui le ereditino. In tal modo si hanno rappresentazioni più concise: le istanze di una classe condividono attributi comuni, senza necessità di specificarli caso per caso.
Una **classe** è un insieme di individui che sono sue istanze, sia **effettivi** sia **potenziali**. Essa viene definita in una delle due forme:

- *intensionale*, ossia tramite una **funzione caratteristica** che avrà valore *1/true* per i membri dell'insieme e *0/false* per gli altri individui,
- *estensionale*, ossia come elenco delle sue istanze.

L'*equivalenza* tra classi non dipende solo dalle solo istanze conosciute. La definizione data consente di descrivere qualsiasi insieme come classe: ad esempio una strana classe che comprenda il numero 18, il `Dipartimento_di_Informatica_di_Bari`, e il `primo_goal_della_SerieA`. In tal caso, però, bisogna chiedersi se tale classe sia effettivamente utile.
Occorrerà cercare di definire una classe come **tipo naturale**, ossia dovrebbe ammettere una descrizione dell'insieme più concisa. Ad esempio la classe `mammifero` è un tipo naturale: descrivere attributi comuni ai mammiferi e rende più compatta la KB, evitando ripetizioni per ogni singolo individuo.

6.2.1. Gerarchie di Classi e Proprietà

S è una **sottoclasse** di C se fra di esse interocorre una relazione di *sottoinsieme*: ogni individuo di tipo S è anche di tipo C.

> **Esempio 64** *(Squadre di calcio)* **.** Nella seguente figura viene illustrata la struttura delle classi per le nazionali brasiliana e canadese.

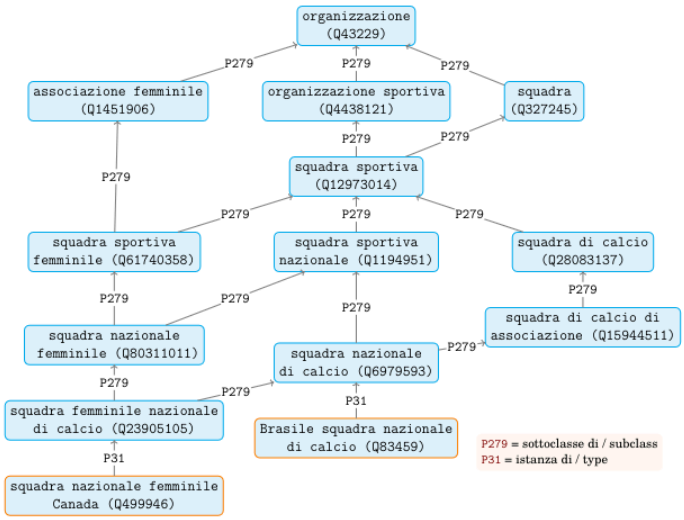


Figura 14: Struttura delle classi per le nazionali

La nazionale brasiliana è istanza di `Q6979593`, classe denominata *natioanl association football team* che, a sua volta, è sottoclasse delle classi denominate *national football team* e *association football team* denotate dai rispettivi URI.

La relazione tra tipi e sottoclassi è definibile come *clausola definita* nel modo seguente:

$$prop(X,\ type,\ C) \leftarrow prop(S,\ subClassOf,\ C) \wedge prop(X,\ type,\ S)$$

o, passando alla notazione funzionale, usando le proprietà speciali *type* e *subClassOf*:

$$\text{se } subclassOf(S,\ C) \text{ e } type(E,\ S) \text{ allora } type(E,\ C)$$

Per definire l'**ereditarietà di proprietà**, il valore di una proprietà, specificato a livello di classe, sarà ereditato da tutte le sue istanze. Per specificare che tutti gli individui di classe c hanno il valore v per la proprietà p, in Datalog si può scrivere:

$$prop(Ind,\ p,\ v) \leftarrow prop(Ind,\ type,\ c)$$

che, insieme alla regola precedente che collega tipi e sottoclassi, serve a far ereditare valori di proprietà.

Le **proprietà** rappresentano relazioni binarie p con:

- un **dominio**, la classe C dei soggetti delle triple con p come verbo, per cui se $p(x, y)$ allora $x \in C$, quindi se p ha dominio C_1 e dominio C_2, allora ogni soggetto apparterrà sia a C_1 sia a C_2;
- un **codominio**, detto *range*: la classe C per gli oggetti delle triple con p, per cui se $p(x, y)$ allora $y \in C$.

La proprietà p è **funzionale** se c'è al più un oggetto associato a ogni soggetto: se $p(x, y_1)$ e $p(x, y_2)$ allora $y_1 = y_2$; in matematica si dice che p è una funzione parziale. Una gerarchia di ereditarietà è possibile anche fra proprietà. Si dirà che p_1 è **sotto-proprietà** di p_2 se e solo se ogni coppia in p_1 è anche in p_2. In notazione funzionale si può scrivere $p_1(x, y)$, o anche, usando le triple, (x, p_1, y) implica (x, p_2, y).

6.2.2. Progettazione delle Classi

La categorizzazione degli oggetti è alla base delle moderne ontologie ma, storicamente, già Aristotele aveva proposto un metodo per definire una classe C in termini di:

- **genus**, una super-classe di C;
- **differentia**, gli attributi che distinguono le istanze di C dal resto delle istanze delle super-classe di C.

Per costruire un'ontologia:

- per ogni classe da definire, occorre determinare una super-classe rilevante e poi selezionare gli attributi che la distinguono dalle altre sottoclassi. Per ogni attributi si definirà una proprietà e un valore;
- per ogni proprietà, si definiscono dominio e codominio le classi più generali che abbia senso considerare, anceh definendole tramite semplice enumerazione dei valori.

> **Esempio 65.** Si consideri la classe:
>
> $$nazionale = \text{"}squadra\ che\ rappresenta\ una\ nazione\ in\ uno\ sport\text{"}$$
>
> con genus "*squadra*" e differentia "*rappresenta una nazione in uno sport*"
>
> - una *squadra di calcio* è una squadra sportiva che gioca a calcio;
> - una *squadra nazionale di calcio* è una *squadra che rappresenta una nazionale nel calcio*, per cui è sottoclasse di entrambe;
> - una *squadra* è un *gruppo con scopi comuni.*
>
> Nella gerarchia vista in precedenza, nell'**Figura 14**, la differentia che distingue le classi nella parte sinistra è che le istanze delle squadre devono essere femminili:
>
> - si possono concepire anche una classe "*squadra di calcio femminile*" e una classe "*squadra femminile*", pur non avendo identificatori specifici in Wikidata;
> - non esiste in Wikidata la classe "*squadra di calcio maschile*": le squadre possono tesserare donne, anche se poi nessuna gioca effettivamente nella squadra maschile.

La gerarchia dele classi costituisce un *grafo aciclico orientato, DAG*, con archi delle sottoclassi alle rispettive super-classi immediate.
Si tratta di un *reticolo*: sono inutili definizioni con cicli, dato che si creerebbero equivalenze. Si noti che la metodologia non porta necessariamente a gerarchie ad

albero, alcuni oggetti possono appartenere a più classi distinte e ogni classe non ha una sola super-classe specifica.

Esempio 66 *(Figure geometriche)* **.** Si considerino le seguenti definizioni:

- rettangolo: quadrilatero con tutti angoli retti al suo interno;
- rombo: quadrilatero con lati di pari lunghezza;
- quadrato: quadrilatero con lati di pari lunghezza e tutti gli angoli retti:
  - è sia rettangolo sia un rombo : potrebbe essere definito come rettangolo con lati di pari lungehzza oppure come rombo con gli angoli interni retti;
  - un quadrilatero è una figura piana costituta da quattro lati quindi un quadrato è una figura piana con quattro lati di pari lungehzza e angoli interni retti.

Raramente le gerarchie naturali sono definibili come alberi per ragioni evolutive. Storicametne imporre forzatamente una struttura ad albero ha avuto scarso successo.
Può essere definita una struttura aciclica, con una radice, detta thing :

- definendo ogni classe in termini di una super-classe e attributi con una *forma normale* costituita da thing congiunta con gli attributi, ottenuta espandendo ogni super-classe con la sua definizione;
- se gli attributi sono coppie proprietà-valore allora in forma normale, una classe è sotto-classe di un'altra per inclusione, come quadrato nell'esempio precedente.

6.3. Ontologie e Condivisione della Conoscenza

Diversi fattori rendono complessa la costruzione di grandi sistemi basati su conoscenza. La conoscenza viene spesso progettata integrando più sorgenti. Queste, a loro volta, potrebbero non condividere uno stesso modo per analizzare il mondo, ognuna potrebbero semplificarlo secondo specifiche priorità originate in campi diversi e con terminologie peculiari. Inoltre, i sistemi evolvono nel tempo e risulta difficile anticipare distinzioni che potranno essere utili in futuro. Il mondo appare spesso *indistinto* e i progettisti devono scegliere *individui e relazioni* da rappresentare accordandosi su una decomposizione conveniente del dominio. Risulta difficile tenere presenti contemporaneamente sia la propria notazione con il suo significato sia quella altrui. Dato un simbolo utilizzato, se ne deve saper determinare il significato, ovvero, dato un concetto, occor saper determinare con quale simbolo rappresentarlo: il concetto potrebbe essere stato già definito e associato a un certo simbolo oppure, in alternativa occorre determinare quali siano concetti correlati con cui definirlo.
Per condividere e comunicare conoscenza è importante sviluppare un *vocabolario* con un suo *significato* comunemente accettato. Una **concettualizzazione** è

l'associazione tra un vocabolario di simboli usati nella macchina e individui / relazioni del mondo che si itnende rappresentare. Essa costituisce una particolare *astrazione* del mondo e la sua *notazione*. In piccolo si tratta di una forma di documentazione curata del progettista, spesso informale ma difficilmente scalabile. Nel caso di grandi sistemi occorre una concettualizzazione condivisa.

Esempio 67 *(Mappe)* **.** Un'ontologia riguardante le *mappe stradali* potrebbe specificare che `Immobile di appartamenti` rappresenti stabili con appartamenti, non necessariamente una definizione formale, ma almeno in modoche gli altri ne comprendano la natura. Altri potrebbero usare nomi/simboli diversi, `Condominio, Appartamenti` o `Complesso di appartamenti` , ma essere comunque in grado di ritrovare il simbolo appropriato nell'ontologia.
Si devono creare associazioni fra il concetto, il suo simbolo e il suo significato. Mediante l'uso di assiomi si può vincolare meglio l'uso dei simboli: ad esempio:

- specificando che un `Immobile di Appartamenti` sia un `Immobile` , eqindi *opere* costruite da uomini;
- imponendo qualche restrizione sulle dimensioni delle abitazioni in modo da escludere, ad esempio, `Box` o `Isolati` o intere `Città` ;
- dichiarando che un edificio non possa trovarsi simultaneamente in locazioni geograficamente distanti, dato che se si staccasse una sua parte spostandola in un posto diverso, non sarebbe più un edificio singolo;
- essendo un `Immobile di appartamenti` anche un `Immobile` , le relative restrizioni si applicano anche ad ognuna delle sue istanze.

Un'**ontologia**, generalmente definita indipendentemente dalle sue applicazioni, richiede l'accordo di una comunità sul significato dei simboli che vi occorrono. Essa si compone dei seguenti elementi:

- *vocabolario* delle categorie di cose da rappresentare: classi e proprietà;
- *organizzazione* delle categorie, ad esemio la gerarchia d'ereditarietà definita attraverso proprietà speciali come *subClassOf* o *subPropertyOf*, o altre modalità;
- insieme di *assiomi* che vincolano la definizione di alcuni simboli in modo da riflettere meglio il significato inteso, ad esempio la transitività d'una proprietà, restrizioni su dominio, codominio, o sul numero di valori che la proprietà può assumere per individuo; a volte alcune relazioni sono definite in termini di più relazioni primitive, non hanno una vera e propria definizione.

Non serve provvedere a definire altri individui ancora sconosciuti in fase progettuale, bastano quelli ritenuti necessari e da condividere per la specifica applicazione come, ad esempio, i giorni della settimana o i colori.

Esempio 68. In un sistema per il settore immobiliare:

- i clienti possono descrivere una sistemazione desiderata;

- il sistema potrà:
  - cercare su più KB le sistemazioni più consone;
  - contattare gli utenti quando si libera una sistemazione appropriata;
- per suggerire di affitare una casa / un appartamento, ma non un intero condominio, può essere utile considerare come immobili residenziali solo case indipendenti e condomini;
- si può definire il concetto di *unità abitativa*, gruppo di stanze in cui si convive, che costituisce la tipica offerta da parte delle agenzie immobiliari: singola stanza, o persino una parte / posto letto;
- è sufficiente definire conoscenza stabile e generale: descrizioni/offerte reali sono ignoti in fase di progettazioni: casi limite, non previsti in partenza, o spesso non definiti chiaramente, possono essere delineati in seguito nel corso dell'evoluzione dell'ontologia.

Usi delle Ontologie

Lo scopo primario delle ontologie è documentare il significato dei simboli, associare simboli a concetti:

- dato un simbolo, si usa l'ontologia per determinare cosa significhi;
- dovendo rappresentare un concetto, si sfrutta l'ontologia per trovare il simbolo approrpiato o per evidenziare la necessità di una nuova definizione.

Scopi secondari sono l'inferenza o individuare le eventuali contraddizioni tramite l'uso degli assiomi. Il problema principale nella progettazione è definire l'organizzazione dei concetti in modo che la macchina possa inferire conoscenza utile dai fatti asseriti.

6.3.1. Web Semantico

Il **Web Semantico** costituisce una prospettiva che prevede la distribuzione di conoscenza attraverso l'infrastruttura del Web: a differenza dei documenti HTML del Web, destinati alle persone, si mira a conoscenza *interpretabile anche delle macchine*, con una semantica esplicitata attraverso la definizione di ontoogie formali che permettano il ragionamento automatico.
Gli ingredienti base sono costituiti dagli identificatori URI utilizzati in rappresentazioni / linguaggi quali RDF, RDF-Schema e OWL.

Interoperabilità

XML (*Extensible Markup Language*) è un linguaggio che fornisce una sintassi progettata per l'elaborazione automatica leggibile anche dalle persone. Si tratta di un linguaggio testuale, con elementi costituiti da *tag* che possono essere organizzati gerarchicamente. La sintassi, anche complessa, prevede al livello basilare ambiti di tag della forma `<tag.../>` oppure `<tag...>...</tag>`.
A livello semantico occorre adottare ontologie di riferimento, riusando quelle

esistenti anche per svilupparne di nuove in proprio. Ai fini dell'*interoperabilità semantica*, si dovrebbe tendere a riusare ontologie standard per i domini interessati e/o definire mapping della propria verso ontologie standard. Diversi sforzi sono stati fatti in passato tesi alla costruzioni di grandi ontologie universali come, ad esempio, *Cyc*.

Identificatori

Un **URI**, *Uniform Resource Identifier*, identifica univocamente una risorsa, ovvero qualsiasi cosa debba essere identificata: individui, classi e proprietà. La sintassi è basata su quelli degli URL: `<url#>` dove `url` è l'indirizzo di una pagina Web, con HTTP si può negoziare il tipo di risposta in base alla richiesta del client; si usano anche IRI, con un set-caratteri esteso. Alcuni esempi sono i seguenti:

- individuo `<http://example.org/#spiderman>`
- proprietà `<http://xmlns.com/foaf/0.1/name>`

Un URI si può esprimere in forma abbreviata, detta **CURIE**, `abbr:name` , dove `abbr` è un prefisso dell'URI completo dichiarato localmente. Ogni URI avrà un significato convenzionale condiviso determinato dal suo uso.

> **Esempio 69** *(FOAF)* **.** L'ontologia **FOAF** (*friend-of-a-friend*) serve a pubblicare informazioni su persone, reti di amici, ...
>
> - gli URI di foaf sono associato al namespace `http://xmlns.com/foaf/0.1/` abbreviato tipicamente con il prefisso `foaf` ;
> - `foaf:name` è la proprietà che correla una persona a una rappresentazione del suo nome; essa consetirà di sapere esattamente a quale proprietà ci si riferisca; si noti che l'URI della proprietà è formato premettendo il prefisso del namespace;
> - `foaf:knows` serve per collegare una persona ai suoi amici;
> - ecc.

RDF (*Resorce Description Framework*) definisce un modelli di dati in forma di triple

individuo-proprietà-valore

La sintassi (serializzazione) è tipicamente sull'XML, in al caso si parla di RDF/XML, ma esistono altri formati pìu leggibili come Jason-LD, N3 o Turtle; in quest'ultimo si scrive:

*URI*_1 *URI*_2 *Valore* oppure *URI*_1 *URI*_2 *URI*_3

Un esempio conreto potrebbe essere il seguente:

http://example.org/#spiderman http://xmlns.com/foaf/0.1/name "Uomo ragno"@it.

È amessa la reificazione di enunciati, formule logiche arbitrarie, quindi in generale, non è decidibile. Ciò non costituisce sempre un problema: significa solo non poter limitare il tempo necessario a un dato calcolo, analogamente a quanto accade con i programmi logici quando si ammettono le funzioni.
SPARQL è il nome del protocollo e del linguaggio per l'interrogazione di KB costituite da grafi di triple RDF. A tale scopo si utilizzano specifici *endpoint*, quali, ad esempio: DBpedia, Min. Istruzione, INPS, ...
Le query sono definite da pattern costituiti da triple contenenti URI o variabili, id, preceduti da "?".

Esempio 70 *(query SPARQL)* **.** Testabile attraverso l'endpoint di DBpedia:

```
select ?canzone ?data where {
dbr:The_Sugarcubes dbo:formerBandMember ?componente .
?componente rdf:type yago:Female109619168 .
?canzone dbo:artist ?componente .
?canzone dbo:releaseDate ?data .
} limit 3
```

risultati:

```
http://dbpedia.org/resource/Cosmogony_(song) 2011-07-19
http://dbpedia.org/resource/Hunter_(Bjork_song) 1998-10-05
http://dbpedia.org/resource/Declare_Independence 2008-01-01
```

RDF-S (*RDF Schema*) consente di definire risorse, classi, proprietà, in termini di altre risorse, ad esempio è possibile restringere domini e codomini di proprietà.
Esso fornisce anche contenitori: set, sequenze e alternative.

Esempio 71 *(Uso di RDF e RDF-S)* **.**

```
@prefix : <http://www.example.org/sample.rdfs#>.
@prefix rdf: <http://www.w3.org/1999/02/22-rdf-syntax-ns#>.
@prefix rdfs: <http://www.w3.org/2000/01/rdf-schema#>.
:Dog rdfs:subClassOf :Animal.
:Person rdfs:subClassOf :Animal.
:hasChild rdfs:range :Animal;
rdfs:domain :Animal.
:hasSon rdfs:subPropertyOf :hasChild.
:Max rdf:type :Dog.
:Abel a :Person.
:Adam :hasSon :Abel.
```

6.3.2. Logiche Descrittive e Rappresentazioni per Ontologie

I linguaggi ontologici come OWL si basano sulle **logiche descrittive (DL)** che servono a descrivere **concetti** (classi), **ruoli** (proprietà) e **individui**. L'idea fondante è la distinzione nella base di conoscenza di due parti $\mathscr{K} = \langle \mathscr{T}, \mathscr{A} \rangle$

- $\mathscr{T}$ costituisce la parte **terminologica** o **TBox** che descrive la terminologia, ossia assiomi per la definizione del significato dei simboli. Ad esempio, in notazione logico-matematica:

  $$C \subseteq (C_1 \wedge \exists R_1.C_2) \vee \forall R_2.(C_3 \wedge \neg C_4)$$

  Per la descrizione in OWL degli assiomi sono possibili diverse sintassi. Essa viene definita in fase di progettazione del sistema e ne specifica l'ontologia. Tende, quindi, ad essere stabile, a meno che non si debba modificare il significato del vocabolario ma è un caso raro.

- $\mathscr{A}$ costituisce la parte **asserzionale** o **ABox** che specifica verità fattuali. Ad esempio in DL:

  $$C(a), R(a,b), P(b,v)$$

  facilmente descrivibili come asserzioni in forma di triple RDF. Esse riguardano conoscenza su situazioni contingent, lo stato del mondo, di solito completamente noto solo al momento dell'utilizzo.

Ontologie per il Web

OWL (*Web Ontologu Language*), è il linguaggio con cui vengono rappresentate le ontologie pubblicate attraverso il Web. Con OWL è possibile descrivere mondi/ domini in termini di:

- **Individui** - *entità* del mondo che si descrive, come l'URI di una data casa o una particolare prenotazione.
- **Classi** - *insiemi di individui*, tutte le entità reali o potenziali che potrebbero appartenervi; ad esempio `House` insieme di tutte le cose, anche future, classificabili come *case*.
- **Proprietà** - *relazioni* che descrivono individui associandoli ad altri *individui*, **object property**, oppure a *dati, valori* di tipi predefiniti, come gli interi o le stringhe, dette in tal caso **datatype property** come, ad esempio: `nextTo`, relazione tra case e `onStreet` tra case e vie, o `streetName` chepuò associare vie a stringhe.

Le varianti di OWL differiscono nelle restrizioni su classi/proprietà e nell'implementazione:

- in **OWL-DL** una classe non può essere un individuo o una proprietà e una proprietà non è un individuo.

- in **OWL-Full**, individui, proprietà e classi non devono essere necessariamente disgiunti.

Con l'introduzione di OWL2, vi sono profili orientati verso specifiche applicazioni che limitano i costrutti usabili, per garantire l'efficienza dell'inferenza:

- **OWL2 EL** consente descrizioni con molti dettagli strutturali, utili, ad esempio, con le grandi ontologie biomediche;
- **OWL2 QL** pensato come front-end per i linguaggi di interrogazione per DB;
- **OWL2 RL** progettato per l'uso di regole.

Default in OWL:

- non si assume la UNA: due nomi/URI non denotano necessariamente individui o classi diversi;
- si assume una semantica di mondo aperto: non si può assumere che tutti i fatti rilevanti siano stati dichiarati.

Le principali **classi predefinite** e i **costruttori di classe** di OWL sono elencati ella seguente tabella. La loro semantica è data dall'**estensione** corrispondente. Nella tabella che segue, le varie C_i sono classi, p è una generica proprietà, la *tripla* $x\ p\ y$ corrisponde all'atomo $p(x,\ y)$.

Classe	**Estensione**
owl:Thing	tutti gli individui
owl:Nothing	nessun individuo
owl:ObjectIntersectionOf $(C_1, ..., C_k)$	individui in $C_1 \cap \cdots \cap C_k$
owl:ObjectUnionOf $(C_1, ..., C_k)$	individui in $C_1 \cup \cdots \cup C_k$
owl:ObjectComplementOf (C)	individui non in C
owl:ObjectOneOf $(I_1, ..., I_k)$	$I_1, ..., I_k$
owl:ObjectHasValue (p, v)	$\{x \mid p(x, v)\}$
owl:ObjectAllValuesFrom (p, C)	$\{x \mid \forall y : p(x, y) \rightarrow y \in C\}$
owl:ObjectSomeValuesFrom (p, C)	$\{x \mid \exists y \in C : p(x, y)\}$
owl:ObjectMinCardinality (n, p, C)	$\{x \mid \lvert\{y \mid p(x, y) \wedge y \in C\}\rvert \geq n\}$
owl:ObjectMaxCardinality (n, p, C)	$\{x \mid \lvert\{y \mid p(x, y) \wedge y \in C\}\rvert \leq n\}$
owl:ObjectHasSelf (p)	$\{x \mid p(x, x)\}$

I **predicati predefiniti** OWL hanno un'interpretazione prefissata. Nelle seguenti tabelle si userà la **notazione funzionale**, inoltre x e y s'intendono universalmente quantificate:

Predicato	**Semantica**
rdf:type (I, C), owl:ClassAssertion (C, I)	$I \in C$
rdfs:subClassOf (C_1, C_2), owl:SubClassOf (C_1, C_2)	$C_1 \subseteq C_2$
rdfs:domain (p, C), owl:ObjectPropertyDomain (p, C)	se $p(x, y)$ allora $x \in C$

rdfs:range (p, C),	se $p(x, y)$ allora $y \in C$
owl:ObjectPropertyRange (p, C)	
owl:EquivalentClass $(C_1, C_2, ..., C_k)$	$C_i \equiv C_j$ per ogni i, j
owl:DisjointClass $(C_1, C_2, ..., C_k)$	$C_i \cap C_j = \emptyset$ per ogni $i \neq j$
rdfs:subPropertyOf (p_1, p_2)	$p_1(x, y)$ implica $p_2(x, y)$
owl:EquivalentObjectProperties (p_1, p_2)	$p_1(x, y)$ sse $p_2(x, y)$
owl:DisjointObjectProperties (p_1, p_2)	$p_1(x, y)$ implica $\neg p_2(x, y)$
owl:InverseObjectProperties (p_1, p_2)	$p_1(x, y)$ sse $p_2(y, x)$
owl:SameIndividual $(I_1, ..., I_n)$	$\forall j \forall k \quad I_j = I_k$
owl:DifferentIndividuals $(I_1, ..., I_n)$	$\forall j \forall k \quad j \neq k$ implica $I_j \neq I_k$
owl:InverseFunctionalObjectProperty (p)	se $p(x_1, y)$ e $p(x_2, y)$ allora $x_1 = x_2$
owl:TransitiveObjectProperty (p)	se $p(x, y)$ e $p(y, z)$ allora $p(x, z)$
owl:SymmetricObjectProperty (p)	se $p(x, y)$ allora $p(y, x)$
owl:AsymmetricObjectProperty (p)	$p(x, y)$ implica $\neg p(y, x)$
owl:ReflexiveObjectProperty (p)	$p(x, x)$ per ogni x
owl:IrreflexiveObjectProperty (p)	$\neg p(x, x)$ per ogni x

Esempio 72 *(Costruttori di classe)* **.**

- `ObjectHasValue(country_of_citizenship, Q16)` classe dei cittadini del Canada (`Q16`);
- `ObjectSomeValuesFrom(country_of_citizenship, Q113489728)` classe delle persone con cittadinanza in un paese membro dell'OCSE, *Organizzazione per la Cooperazione e lo Sviluppo Economico*, dove `Q113489728` identifica la classe dei paesi membri dell'OCSE; in caso di più cittadinanze, almeno una deve riguardare un paese dell'OCSE;
- `MinCardinality(2, country_of_citizenship, Q113489728)` classe di persone con cittadinanza in 2 o più paesi dell'OCSE.

Enunciati

I costuttori di classe vanno usti negli *enunciati*, ad esempio per dire che un individuo appartiene a tale classe o che una classe sia equivalente a un'altra.
OWL non può essere espresso, in modo equivalente, attraverso clausole definite; per dire che tutti gli elementi di S hanno il valore v per un dato predicato p, si dice che S è sottoinsieme di quello di tutte le cose con valore v per p (*assioma di inclusione,* $\subseteq$)

Esempio 73. Definizione di immobile con appartamenti, edificio residenziale con più unità abitative che sono date in affitto; si noti la differenza con il condominio (unità vendute separatamente) o la casa (una sola unità).

```
1 FunctionalObjectProperty(numberOfunits)
2 ObjectPropertyDomain(numberOfunits, ResidentialBuilding)
```

```
3  ObjectPropertyRange(numberOfunits, ObjectOneOf(two,one,moreThanTwo))
4
5  FunctionalObjectProperty(ownership)
6  ObjectPropertyDomain(ownership, ResidentialBuilding)
7  ObjectPropertyRange(ownership,
8                              ObjectOneOf(rental,ownerOccupied,coop)
9  )
10 EquivalentClasses(ApartmentBuilding,
11    ObjectIntersectionOf(ResidentialBuilding,
12       ObjectHasValue(numberOfunits, moreThanTwo),
13       ObjectHasValue(ownership,rental)
14    )
15 )
```

definizione utile a rispondere a query sulle loro proprietà.

Fra gli altri costrutti disponibili, c'è il costruttore di proprietà `owl:ObjectInverseOf(p)` utile a rappresentare la proprietà inversa di p, denotata anche con $p^{-1} : p^{-1}(x, y)$ se e solo se *p(x, y)* vale solo per *object-property*: le *datatype-property* non hanno proprietà inverse, in quanto i valori di *tipi concreti* nno possono fungere da soggetto di triple.
Ci sono anche classi *datatype* corrispondenti ai codomini di proprietà, come `owl:DataSomeValuesFrom` e `owl:EquivalentDataProperties`, con definizioni analoghe a quelle per proprietà su individui ma con domini concreti come codomini, presi in prestito da DML-Schema.
Infine, sono disponibili anche costrutti per definire proprietà, commenti, annotazioni, versioning e import da altre ontologie.

Editor OWL
Gli editor di ontologie, come Protégé forniscono un modo per definire ontologie a un livello di astrazione appropriato:

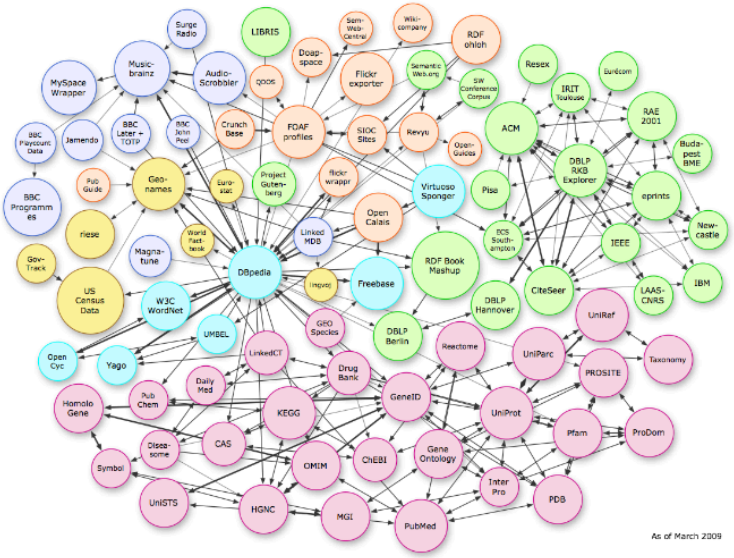
- volendo usare un concetto, ne facilitano la ricerca nella terminologia o può segnalarne l'eventuale assenza;
- aiutando a determinare immediatamente il significato di un termine;
- permettono controlli di correttezza sulle ontologie, ad esempio sulla corrispondenza con l'interpretazione intesa per i termini;
- facilitano la riusabilità spingendo a usare il più possibile un linguaggio standard.

Ontologie di Dominio
Un'**ontologia di dominio** riguarda un particolare dominio d'interesse: molte delle ontologie esistenti riguardano un dominio ristretto definito per specifiche applicazioni.
Linee Guida per definire ontologie di dominio sono le seguenti:

- Se possibile, conviene usare ontologie esistenti: la KB potrà interagire con altre che la adottano;
- Se esiste un'ontologia che non corrisponda esattamente ai requisiti, la si può importare facendo poi delle aggiunte in modo da non partire da zero: se la propria ontologia include e migliora l'altra, altri la vorranno adottare, aumentando l'interoperabilità della loro applicazione;
- Occorre assicurarsi che l'ontologia si integri con ontologie affini, tentando di assicurare l'uso della stessa terminologia per le stesse cose;
- Tentare di conformarsi a ontologie di livello superiore poichè questo rende molto più facile l'integrazione della conoscenza di/con altre fonti;
- Nel progettare una nuova ontologia, conviene consultarsi con altri utenti potenziali, ciò la rende più utile e più facilmente adottabile;
- Vanno seguite le convenzioni di denominazione, ad esempio chiamare una classe con il nome, al singolare, delle istanze:
  - pensare all'uso delle classi/proprietà;
  - di un individuo `r1` meglio dire che "è un `Resort`" rispetto a "è un `Resorts`" oppure "è un `Concetto_di_resort`"
- Specificare la corrispondenza tra ontologie: a volte serve un allineamento quando le ontologie sono sviluppate separatamente, evitando, se possibile, la ridondanza che le rende più complicate da usare.

Web of Data

Il **Web of Data** è una prospettiva del Web Semantico tesa a sfruttare l'infrastruttura del Web per creare un grafo globale di sorgenti distribuite di dati collegati, come aad esempio la seguente figura:



La semantica dei dati viene resa disponibile anche alle macchine sulla base di ontologie RDF/OWL, e quindi attraverso query SPARQL, o veri e propri servizi di ragionamento automatico (tramite *reasoner*). A tale scopo sono disponibili anche server ad hoc detti *triple store* o altre forme di DB NoSQL, come ad esempio *document DB* basati sulla serializzazione JSON-LD.
I principi-guida dei **Linked Data** sono i seguenti:
1. l'uso di URI come nomi per le cose;
2. in particolare URI HTTP per permetterne la ricerca sull'infrastruttura del Web;
3. le informazioni vengono fornite usando linguaggi standard quali RDF, SPARQL, ...
4. l'uso di link verso URI di risorse esterne che abilitano la scoperta di altra conoscenza.

La qualità degli *Open Data* può essere valutata in termini di una categorizzazione 1-5 stelle di Berners-Lee. In cima, 5 $\star$, si trovano i *Linked Open Data, LOD*. I LOD sono navigabili attraverso strumenti come *LodLive*.

6.3.3. Ontologie Top-Level

Ogni ontologia di dominio implicitamente o esplicitamente assume un'ontologia di più alto livello alla quale conformarsi.
Ad esempio l'ontologia degli appartamenti può essere riusata da chi voglia definire una KB che si riferisca a cose che possono comparire in mappe, assumendo che gli edifici siano già definiti altrove.
Tipicamente, in un'ontologia **top-level** si troveranno definizioni a un livello di astrazione molto elevato. Essa fornirà una categorizzazione di base alla quale altre ontologie potranno conformarsi esplicitamente per facilitare la loro *integrazione*; inoltre consentirà a diverse applicazioni di riferirsi a più KB, ognuna della quali potrà adottare ontologie diverse.
Progettare ontologie top-level è un compito complesso ma il loro uso abilita la connessione fra diverse basi di conoscenza.

Apprendimento Supervisionato

L'**apprendimento** è la capacità di sfruttare l'esperienza per migliorare il comportamento nello svolgimento di specifici compiti:
- l'*estensione* della abilità / dei comportamenti possibili: fare di più;
- il miglioramento dell'*accuratezza* nei compiti svolti: far meglio;
- il miglioramento dell'*efficienza*: fare prima.

Informalmente si può anche dire che l'obiettivo dell'apprendimento è comprendere il mondo attraverso i **dati**. Occorre modellare non tanto i dati quando il mondo che li genera per consentire il miglioramento delle decisioni/azioni del sistema intelligente. La conoscenza del passato non è fine a se stessa ma dev'essere utile per il futuro.
Verranno trattate problematiche specifiche legate alla predizione tramite apprendimento supervisionato: dato un insieme di *esempi* di addestramento costituito da coppie input-output, si dovrà predire l'*output* per nuovi esempi dato il solo input. Gli esempi si chiamano anche *campioni* mentre l'output da predire si chiama anche *obiettivo* o *target*.

7.1. Problematiche dell'Apprendimento

In un *problema di apprendimento automatico* si distinguono:

- il **task**, ovvero il *comportamento* o *compito* nel quale migliorare;
- i **dati**, ossia le *esperienze* usate per migliorare le prestazioni nello svolgimento del compito, di solito disponibili come sequenza di *esempi*;
- la **misura del miglioramento**: occorre stabilire *come* e *cosa* misurare come, ad esempio, l'incremento di abilità, l'efficacia, l'efficienza nella soluzione del problema.

Ai fini della predizione, si considerano la *conoscenza di fondo* (*background knowledge*, BK) e i *dati*, ossia l'esperienza pregressa, tipicamente in forma di esempi, ossia come `input-output`, per creare una *rappresentazione interna*, un **modello**, che potrà costituire parte della KN, da usare per future *predizioni*.
Nel seguito sono elencate le diverse problematiche legate alla soluzione dei problemi di apprendimento automatico:

- **Task**: il compito per cui si devono acquisire dati/esperienza. Nell'**apprendiment supervisionato**, dato un insieme di **esempi di traning** descritti in termini di *feature* di *input* e *target*, si deve imparare a predire il valore ignoto delle variabili-obiettivo per nuove osservazioni. Nei problemi di *classificazione* il target è discreto mentre in quelli di *regressione* esso è continuo. Quando le variabili-obiettivo hanno una struttura si parla di *predizione strutturata*. Altri problemi sono legati a forme di *apprendimento non-supervionato*, in cui si cercano regolarità o *pattern*, senza avere a disposizione dati con variabili-obiettivo esplicite. Nell'*apprendimento relazionale* si costruiscono modei per *rappresentazioni più espressive* dei dati, quindi relazioni, concetti / programmi logici (ILP), grafi. Nell'*apprendimento per rinforzo* l'obiettivo è pianificare comportamenti ovvero piano su azioni da svolgere. Nei problemi di *ranking* si impara a ordinare le istanze, ad esempio gli item trattati dai sistemi di raccomandazione. Infine nell'*apprendimento analitico* l'obiettivo è imparare a ragionare ovvero a prendere decisioni più velocemente.

- **Feedback**: il tipo di feedback che si riceve dipende dal task di apprendimento. Nei task supervisionati, gli *esempi di training* forniti da un esperto/addestratore, contegono il valore-obiettivo corretto per ognuno di essi. Nei task non-supervisionati non è specificato un output desiderato, si hanno solo *osservazioni* con le sole variabili di input avvalorate, quindi ci si basa sulla valutazione di funzioni che misurano le prestazioni già menzionate. Nei task per rinforzo si hanno *ricompense* e *punizioni* che danno un valore alle diverse sequenze di azioni svolte in base al modello appreso.
- **Misura delle prestazioni**, ossia del miglioramento dei modelli su nuovi dati. Tipicamente nella valutazione si dividono i dati in due gruppi, *training* e *test*: costruito un *modello*, usando gli esempi di training, se ne misura l'*accuratezza predittiva* su *nuovi* esempi, quelli di test. Si ottiene una misura *approssimata* delle prestazioni, dato l'insieme limitato di dati, che va *ripetuta* al variare delle diverse suddivisioni del campione di dati. Nel caso supervisionato, le ipotesi, indotte da *campioni* della popolazione, devono tendere a *generalizzare* il training set, senza farsi fuorviare da sue specificità, altrimenti risulterebbero *scarsamente predittive* rispetto a nuovi dati. Ad esempio in un *problema di classificazione binario*, in cui si decide l'appartenenza ad una classe, si potrebbe formulare facilmente un'ipotesi h_P che decide sempre la predizione positiva, tranne che per i soli esempi negativi del training set e un'ipotesi h_N che decida sempre per la predizione negativa, tranne che per i soli positivi del training set; tali ipotesi sono *modelli estremi*: per entrambe si avrebbe il 100% di accuretezza sui dati di training ma risulterebbero in totale disaccordo sul resto degli esempi.
- **Bias**: tendenza a preferire certe ipotesi rispetto ad altre. Senza bias, non si sa come stabilire che un'ipotesi sia migliore di un'altra. Nell'esempio precedente le ipotesi h_N e h_P sono entrambe accurate al 100% sui dati di training: quindi occorre stabilire quale si preferisce tra le due. Serve un *fattore esterno* che prescinda anche dai dati, in grado di ottimizzare le predizioni sui nuovi esempi. La scelta del bias è un problema empirico da risolvere attraverso al pratica. Tipicamente, ci si basas su misure di *complessità* delle ipotesi.
- **Rappresentazione**, ossia la *codifica interna* dell'esperienza ovvero la forma dell'ipotesi. La più semplice è la forma *grezza*, in cui si memorizzano le esperienze stesse, gli esempi. Una forma *compatta* è più comune perchè permette la generalizzazione dei dati. La scelta fra le rappresentazioni possibili viene detta **bias di rappresentazione** ed è correlata alla scelta fra i diversi modelli, **bias di preferenza**. Come *linea-guida*, si sa che optando per rappresentazioni più ricche sarà più facile esprimere ipotesi più generali che sono però più difficili da apprendere: servono più dati per scegliere fra le più numerose ipotesi coerenti con i dati stessi. Occorre trovare soluzioni di compromesso e/o ricorrere a metodi di apprendimento della rappresentazione ottimale.

- **Ricerca**: scelti rappresentazione e bias, l'apprendimento può essere visto come un *problema di ricerca* da risolvere attraversando lo *spazio delle ipotesi*, dato un **bias di ricerca**, per trovare quella che meglio si adatta agli esempi. Tipicamente gli spazi di ricerca sono molto estesi, spesso infiniti, quindi risulta impossibile una ricerca sistematica e si deve ricorrere a forme di *ricerca locale*. Per la definizione dell'*algoritmo*, quindi, si richede la definizione di uno spazio di riecrca, di una funzione di valutazione e di un metodo di ricerca.
- **Dati imperfetti** nelle situazioni reali, a seguito di diverse cause fra le quali: il *rumore* dovuto a variabili (*feature*) osservate che risultano inadeguate a fare predizioni; i *dati mancati* ossia valori di alcune variabili non disponibili per alcuni esempi; gli *errori*, quando i valori di alcune variabili risultano errati.
- **Ordine** naturale del dominio delle feature. L'ordine permette di distinguere problemi di **interpolazione**, in cui si devono fare predizione per casi *ricompresi* nelle regioni dei dati osservati (training), da quelli di **estrapolazione**, in cui le predizioni riguardano casi distanti dagli esempi di training. I modelli per tali problemi risultano in genere meno accurato (è più facile predire il passato che il futuro) in quanto determinare il valore incognito di una variabile in base a valori di input già osservati subito prima o dopo, risulta molto più facile che predire valori futuri. Per questo, ipotesi con valori dei parametri ottimizzati ai fini dell'*interpolazione* possono rivelarsi pessime su successivi problemi di *estrapolazione*.
- **Dimensionalità**: essendo gli esempi descritti in termini di variabili (una *dimensione* per ciascuna) il numero di esempi possibili cresce esponenzialmente aumentando le dimensioni (*curse of dimensionality*). Al crescere della dimensionalita, le singole dimensioni diventano poco importanti: in problemi dell'ambito medico, se gli esempi sono costituiti da immagini e altri attributi la modifica di un singolo pixel non dovrebbe influenzare la diagnosi.
- *Acquisizione* **offline/online** degli esempi: nel primo caso tutti gli esempi sono disponibili prima dell'azione/decisione, nel secondo caso essi si rendono disponibili nel tempo, nel corso del processo di learning. La rappresentazione degli esempi potrebbe essere determinata prima di averli visti tutti per cui nuovi esempi si rende necessario un aggiornamento della rappresentazione. Nell'*active learning*, il sistema ragione e decide sugli esempi utili da acquisire per svolgere il suo compito.

7.2. Fondamenti

7.2.1. Problema Supervisionato

Una **feature** è una funzione F definita sugli *esempi*, ossia sullo spazio della loro rappresentazione:

- $F(e)$ denota il *valore* di F per l'esempio e;
- il *dominio* della feature è l'insieme dei valori che essa può assumere, ossia il codominio della funzione F.

Il **problema** di apprendimento **superivisionato** si può descrivere come segue:

- dati :
  - le **feature di input** $X_1, ..., X_m$;
  - le **feature-obiettivo** (o **target**) $Y_1, ..., Y_k$;
  - un insieme di **esempi** $e = (x_e, y_e)$
    con $x_e = \big(X_1(e), ..., X_{m(e)}\big)$ e $y_e = \big(Y_1(e), ..., Y_{k(e)}\big)$
- determinare un **predittore**, ossia una funzione atta a predire i valori delle variabili-obiettivo Y_j, noti i valori delle variabili X_i, per esempi non osservati, ossia nuovi rispetto a quelli usati per l'addestramento.

Vi sono diverse varianti dei problemi di apprendimento supervisionato:

- problema di **regressione**: predire un obiettivo a valori continui, in un sottoinsieme dei numeri reali;
- problema di **classificazione**: predire un valore-obiettivo ricompreso in un insieme finito prefissato, ad esempio binario / booleano {false, true}, o a valori multipli;
- problema **relazionale**: predire relazioni, come ad esempio chi sia la madre di una data persona; in tal caso i nuovi esempi per la valutazione saranno tratti da un'altra popolazione rispetto a quelli usati nell'addestramento;
- problema **strutturale**: predire una struttura.

Esempi di applicazione dei modelli superivisionati sono i seguenti: predire *attività* svolte (come camminare, correre, guidare, ecc.) dalla frequenza cardiaca e dal movimento, così come rilevati da uno smartwatch; stimare la probabilità di inondazione di un sito nella prossima decade in base in base ai dati topografici, climatici, geologici, ecc.; individuare parole scritte a mano su smartphone/tablet in base alla grafia; determinare la traduzione di un testo dal cinese all'hindi.

Esempio 74 *(Problema di classificazione)* **.** Decisione sull'eventuale visione di un video sulla piattaforma:

- variabili di input (booleane):
  - *Virale*: viralità del video;
  - *Nuovo*: novità del video;
  - *Lungo*: lunghezza non breve;
  - *A_casa*: visione domestica o altrove.
- variabile-*obiettivo* booleana: *Da_vedere*;
- esempi di *training*: $e_1, ..., e_{18}$ e di test: e_{19}, e_{20}

Tabella di esempi ottenuta dalle decisioni prese dagli utenti:

#Es	*Virale*	*Nuovo*	*Lungo*	*A_casa*	*Da_vedere*
e_1	true	true	true	true	false
e_2	false	true	false	false	true
e_3	false	false	true	false	false
e_4	true	false	true	true	false
e_5	true	true	false	true	true
e_6	true	false	true	false	false
e_7	false	false	false	false	false
e_8	false	true	false	false	true
e_9	true	false	true	true	false
e_{10}	true	true	true	false	false
e_{11}	false	false	false	true	false
e_{12}	true	true	true	false	false
e_{13}	true	false	false	true	true
e_{14}	true	true	false	false	true
e_{15}	true	true	false	true	true
e_{16}	true	false	false	false	true
e_{17}	true	true	false	true	true
e_{18}	false	false	false	false	true
e_{19}	false	true	true	false	?
e_{20}	false	false	false	true	?

Esempio 75 *(Problema di regressione)* **.** Predire il valore di Y a valori reali:

#Es	X	Y
e_1	0.7	1.7
e_2	1.1	2.4
e_3	1.3	2.5
e_4	1.9	1.7
e_5	2.6	2.1
e_6	3.1	2.3
e_7	3.9	7.0
e_8	2.9	?
e_9	5.0	?

- predire il valore di Y per e_8: problema di *interpolazione*, il valore $X(e_8)$ ricade tra quelli degli altri esempi di training;
- predire il valore di Y per e_9: problema di *estrapolazione*, il valore $X(e_9)$ è fuori dall'intervallo di valori degli esempi di training.

7.2.2. Valutazione delle Predizioni

Dato il *predittore* $\hat{Y}$ per le feature obiettivo Y, $\hat{Y}(e)$ denoterà una **stima puntuale** del valore di Y per l'esempio $e \in Es$, ossia la predizione del vero valore $Y(e)$, detto *ground truth*; il predittore $\hat{Y}$, appreso sulla base degli esempi di training, potrà essere applicato in seguito a qualsiasi altro esempio.
Si dice **loss** (o *errore*) di $\hat{Y}(e)$ una misura della *distanza* della stima $\hat{Y}(e)$ dal vero valore $Y(e)$. Essa viene definita come funzione $\text{loss}(p, a)$ su $\mathbb{R}_+$: errore della predizione di p quando il valore effettivo è a. Tipicamente se ne considera la media sull'insieme Es di esempi, o **loss media** (*mean loss*)

$$\frac{1}{|Es|} \sum_{e \in Es} \text{loss}\Big(\hat{Y}(e), Y(e)\Big)$$

o, in alternativa, la semplice sommatoria che ha lo stesso punto di minimo. Si preferisce la loss media perchè può essere interpretata senza conoscere il numero di esempi $|Es|$.

Feature-Obiettivo a Valori Reali

In caso di feature con valori *totalmente ordinati*, le differenze sono significative. Ad esempio, altezze in cm, voti, numero bambini, ecc.
Le funzioni di *loss* più utilizzate in problemi di *regressione*, essendo dati il valore vero e quello predetto $a, p \in \mathbb{R}$, rispettivametne, sono elencate di seguito:

- **errore 0-1** o **loss** L_0:

$$\text{loss}(p, a) = \begin{cases} 1 & p \neq a \\ 0 & p = a \end{cases}$$

anche con la funzione $1(p \neq a)$ che vale 1 se l'argomento è vero e 0 altrimenti. La loss media su un dataset sarà il numero medio di predizioni sbagliate, che non tiene conto di *quante* siano errate. L'**accuratezza** ne costituisce il complemento a 1, ossia il numero medio di predizioni corrette e viene massimizzata minimizzando la loss. Il test d'uguaglianza non è affidabile nel confronto fra numeri reali quindi non è utile calcolare la loss media, mentre potrebbero esserlo il calcolo di moda o mediana.

- **errore assoluto** o **loss** L_1:

$$\text{loss}(p, a) = |p - a|$$

È sempre non negativa e per un dataset risulta nulla se tutte le predizioni sono corrette; a differenza della precedente, tiene conto della precisione delle predizioni.

- **errore quadratico** o **loss** L_2:

$$\text{loss}(p, a) = (p - a)^2$$

Si tratta di un errore amplificato, ad esempio un errore di 2 vale quanto 4 errori di 1; ai fini della minimizzazione, si considera la *loss media quadratica* su Es o,

equivalentemente, la **radice dell'errore quadratico medio** (*root-mean-square error*, RMSE) che ha gli stessi punti di minimo delle sommatorie sul dataset; spesso si antepone il fattore $\frac{1}{2}$ per semplificare le derivate.

- **errore nel caso pessimo** o **loss** L_∞ su Es:

$$\text{loss}(Es) = \max_{e \in Es} \left| \hat{Y}(e) - Y(e) \right|$$

Essa rappresenta una stima pessimistica basata sull'errore massimo del predittore quindi non corrisponde a sommatorie o medie.

Esempio 76. Per il problema di regressione dell'esempio **Problema di regressione** si possono considerare i modelli lineari nella seguente figura, utili a predire Y minimizzando gli errori L_1, L_2 e L_∞:

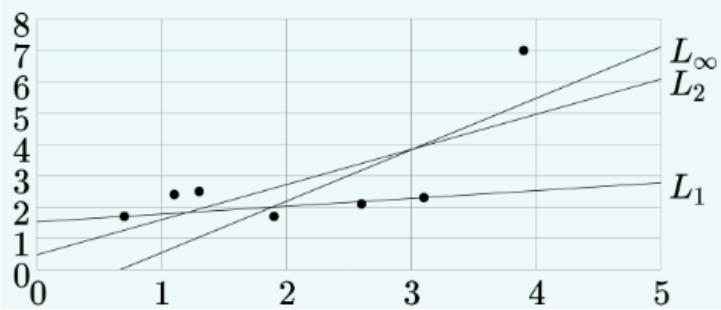


Figura 16: rette di regressione e loss

- ogni retta passante per due punti minimizza l'errore L_0: le triple di esempi sono tutte *non co-lineari*;
- per il punto con $X = 1.1$ e $Y = 2.4$ effettivo, si hanno predizioni simili dalle rette L_1 e L_2 (rispettivamente 1.805 e 1.709) mentre L_∞ predice 0.7;
- *interpolando* in $[1, 3]$ si fano predizioni distnati al più di 1.5;
- *estrapolando*, essi *divergono*: ad esempio per $X = 5$, L_1 e L_∞ forniscono predizioni molto differenti.

Un **outlier** è un esempio che non segue schemi che accomunano altri esempi. La differenza tra le diverse rette è più evidente nel trattamento di outlier come, ad esempio, nel caso di $(3.9, 7)$:

- la predizione con L_∞ dipende solo da $(1.1, 2.4)$, (3.1, 2.3) e (3.9, 7), con lo stesso errore di caso pessimo mentre gli altri punti sono influenti se questi non sono più lontani dalla retta;
- la predizione con L_1 non cambia in base al valore effettivo di Y per gli esempi, se i punti restano al di sopra e al di sotto, rispettivamente: ad esempio, si ha la stessa predizione considerando il punto (3.0, 107), anzichè (3.9, 7);

- la predizione con L_2 è sensibile a tutti i dati: cambiando la Y di qualche esempio, cmabia la retta e i cambiamenti negli outlier hanno maggiori effetti sulla retta rispetto a quelli relativi a punti ad essa vicini.

Feature-Obiettivo Categoriche

Una feature **categorica** Y ha un dominio finito $D = \{v_1, ..., v_k\}$. Ad esempio, in base al dataset a disposizione, potrebbe rappresentare l'argomento principae di un articolo, la specie di un animale, ecc.

La tipica *stima puntuale* per tale tipo di feature è la **predizione certa** di uno fra i possibili valori $v_1, ..., v_k$, ovvero una tupla binaria con un solo 1 nella posizione binaria corrispondente (*one-hot encoding*). In alternativa, è possibile una **predizione probabilistica**, tramite una funzione p, rappresentabile come dizionario che associ gli elementi di D a numeri reali non negativi in modo tale che $\sum_{v \in D} p[v] = 1$, dove $p[v]$ è il valore della predizione di p per v; la predizione certa può essere definita equivalentemente se $\exists j : p\left[v_j\right] = 1$ e p è nulla per gli altri valori.

Esempio 77. Imparare le preferenze sulla lunghezza di una vacanza. Dataset semplice (senza input):

Es	Y
e_1	1
e_2	6
e_3	6
e_4	2
e_5	1

- per una Y a valori reali, la predizione per un nuovo e potrebbe essere un generico numero reale, ad esempio $\hat{Y}(e) = 3.5$
- per Y categorica, con dominio $\{1, 2, 3, 4, 5, 6\}$:
  - predizione *certa* per e: un valore del dominio, come $\hat{Y}(e) = 3$
  - predizione *probabilistica* per e: rappresentando $\hat{Y}(e)$ come dizionario

$$p : p[1] = 0.25,\ p[2] = 0.2,\ p[3] = 0.1,\ p[4] = 0.1,\ p[5] = 0.1,\ p[6] = 0.25$$

Al caso categorico possono essere applicate le stesse loss del caso continuo. Per $Y(e) = a$:

$$\text{loss}(p[a], 1)$$

essendo $p[a]$ la probabilità associata al caso corretto.

Ad esempio l'errore quadrato per la predizione probabilistica sarà definito $(1 - p[a])^2$.

Una tipica misura delle prestazioni è l'**accuratezza media**:

- predizione *certa*: 1 per predizioni corrette, nulla altrimenti;
- predizione *probabilistica*: 1 quando c'è un'*unica moda* in corrispodenza al valore effettivo (v con max $p[v]$ associata). Dipendendo solo dalla moda, l'accuratezza risulta una misura approssimativa per questo tipo di predizione.

La distribuzione p può essere ottimizzata anche usando la **log-loss** o *entropia incrociata*:

$$\text{logloss}(p, a) = -\log(p[a])$$

misura semore non negativa, nulla se $p[a] = 1$ con le altre a 0.
Dato il dataset Es, la **log-loss media** del predittore $\hat{Y}$ sarà:

$$-\frac{1}{|Es|}\sum_{e}\log\Big(\hat{Y}(e)[Y(e)]\Big)$$

dove $\hat{Y}(e)[Y(e)]$ è il valore della redizione $p = \widehat{Y(e)}$ per l'effettivo $a = Y(e)$.

Esempio 78. Predizioni probabilistiche per il dataset visto in precedenza:

$$\{(e_1, 1), (e_2, 6), (e_3, 6), (e_4, 2), (e_5, 1).$$

- Se la predizione per gli esempi e_1, e_2, e_3, e_5 avesse probabilità $0.25 = p[1] = p[6]$, mentre per e_4 questa fosse $0.2 = p[2]$, la log-loss media sarà:

$$-\frac{1}{5}(4 \cdot \log_2 0.25 + \log_2 0.2) \approx 2.064$$

- Se le predizioni avessero probabilità $p[1] = p[6] = 0.4$ e $p[2] = 0.2$ e nulle per gli altri valori, la log-loss media sarà:

$$-\frac{1}{5}(4 \cdot \log_2 0.4 + \log_2 0.2) \approx 1.522$$

Si noti che la seconda predizione, che adotta la proporzione osservata nel dataset per ciascun valore, risulta essere migliore della prima.

Il miglior predittore è un modello per quale si massimizza la probabilità dei dati osservati, ossia la *verosomiglianza* degli esempi Es dato $\hat{Y}$:

$$\prod_{e \in Es} \hat{y}(e)[Y(e)]$$

assumendo che gli esempi siano fra loro indipendenti. Passando al logaritmo, si ottiene la cosidetta **log-likelihood**:

$$\sum_{e \in Es}\log\Big(\hat{Y}(e)[Y(e)]\Big)$$

Quindi la *log-loss media* si ottiene cambiando il segno alla log-likehood e dividendo per il numero di esempi. Essa sarà minima quando la log-likelihood è massima.
La log-loss media risulta appropriata per predizioni nel ragionamento sotto incertezza: ad esempio, sotto loss quadratica, i valori 10^{-7} e 10^{-6} sono molto vicini: una predizione di 10^{-7} avrà un errore simile a quello di 10^{-6}. Invece, in termini di probabilità, rappresenterebbero casi molto diversi. Tale differenza può essere apprezzata adottando la log-loss ma non con le loss basate sulle differenze fra valori predetto ed effettivo.
Essendo $\log(0)$ indefinito, la log-loss per la predizione di 0 e trattata come se fosse infinita. Dovrebbe perciò essere scoraggiata qualsiasi predizione di probabilità nulla per un valore che invece possa essere osservato per qualche esempio futuro. La log-loss è correlata con l'***entropia***: numero di simboli per codificare i dati, con un codice basato su $\hat{Y}$ come distribuzione di probabilità.

Feature-Obiettivo Binarie
Si consideri il caso in cui le feature obiettivo Y abbia il dominio $\{0, 1\}$ (= {false, true}); tale valore potrebbe indicare, ad esempio, uno degli argomento di un articolo di giornale, usando una variabile booleana Y_k per ciascun argomento possibile. In tal caso la predizione può essere data da un valore reale $p = \hat{Y}(e) \in [0, 1]$, il che è equivalente alla predizione categorica di p per il valore 1.
Si definisce la **log-loss binaria**, o *entropia incrociata binaria*, come mostrato di seguito, la funzione:

$$\text{logloss}(p, a) = -[a \log p + (1 - a) \log(1 - p)]$$

dove p è la predizione e a il valore effettivo, ricavabile dalla verosomiglianza. Per convenzione $\text{logloss}(1, 1) = \text{logloss}(0, 0) = 0$, anche se $\log 0$ non è definito. La log-loss sarà pari a $\log p$ se $a = 1$, altrimenti sarà $\log(1 - p)$, come la log-loss categorica per la quale la predizione per 1 è p e per 0 è $1 - p$. Il termine *log-loss* le ricomprende entrambe.

7.2.3. Stime Puntuali di Riferimento senza Feature di Input
Si consideri il caso in cui la predizione sia basata solo sui valori delle feature obiettivo Y osservata per i diversi esempi del dataset, senza usare le variabili di input X_i. Si avrà un modello costante (ossia una **base di riferimento** naive) per il quale si predice uno stesso valore $v = \hat{Y}(e)$ per tutti gli esempi e. Il valore ottimale da predire si sceglie in base alla funzione da ottimizzare (la loss) e potrà essere calcolato e ottimizzato *analicamente* sulla base degli n esempi di training.
Nel caso di Y a valori reali, il modello fornisce la stima puntuale $p = \hat{Y}(e) \quad \forall e$:

Criterio	Errore per p	Predizione ottimale
loss *0-1* media	$\frac{1}{n} \sum_e \mathbf{1}(Y(e) \neq p)$	moda

loss *assoluta* media	$\frac{1}{n}\sum_e \lvert Y(e) - p\rvert$	mediana
loss *quadratica* media	$\frac{1}{n}\sum_e (Y(e) - p)^2$	media
loss *caso pessimo*	$\max_e \lvert Y(e) - p\rvert$	$\frac{\min + \max}{2}$

Per una feature-obiettivo X binaria, i dati possono essere riassunti da due semplici statistiche $n_1 = \sum_e Y(e)$ e $n_0 = n - n_1$. La media o **frequenza empirica**, ossia la proporzione di 1 nel training set è $\frac{n_1}{n}$. Essa costituisce anche una *stima di massima verosomiglianza* quindi anche la predizione con la minima log-loss. Gli errori 0-1 ed assoluto sono minimizzato considerano il valore binario pìu frequente.

Criterio	Errore per p	Predizione ottimale
log-loss media	$-\left[\frac{n_1}{n}\log p + \frac{n_0}{n}\log(1-p)\right]$	$\frac{n_1}{n}$

Nel caso di una Y *categorica*, con un dominio $\{v_1, ..., v_k\}$, il dataset può essere sintetizzato dalle frequenze $n_1, ..., n_k$. La log-loss sarà minimizzata dalla predizione della frequenza empirica sul training set. L'errore 0-1 viene minimizzato dalla predizione della moda, che porta anche a massimizzare l'accuratezza.

Criterio	Errore per p	Predizione ottimale
log-loss media	$-\sum_i \frac{n_i}{n}\log p_i$	$p[v_i] = \frac{n_i}{n}$

Quindi la predizione preferibile dipende dalla rappresentazion di Y e dalla misura da ottimizzare. Per esempi non ancora osservati la frequenza empirica può risultare problematica se si massimizza la verosomiglianza o minimizza la logg. Ad esempio se $n_i = 0$ allora il valore b_i sarà da considerarsi mai osservato. Un nuovo esempio di test con valore v_i comporterebbe una likelihood nulla e una log-loss infinita, costituendo un caso di *sovradattamento*.
Come *riferimento* di partenza si possono considerare predizioni naive, determinate riima di osservare i dati.

7.2.4. Tipi di Errore

Gli errori non sono tutti uguali, alcuni tipi possono essere peggiori di altri in base alle loro conseguenze.

> **Esempio 79** *(Medicina)* **.** Non diagnosticare una malattia a un paziente, che sarà indotto a non curarsi, può risultare più grave rispetto a predire una malattia che non ha, per cui sarebbero consigliati ulteriori accertamenti.

Per un esperimento si può compilare una **matrice di confusione**. Nelc aso più semplice si supponga che Y sia booleana. La valutazione della predizione sarà indipendente dalla decisione. In tal caso la matrice è la seguente:

	ap realmente positivi	an realmente negativi
pp predetti positivi	tp veri positivi	fp falsi positivi
pn predetti negativi	fn falsi negativi	tn veri negativi

Errori:
- *falsi positivi* o errore di *I tipo*: predizioni positive sbagliate (`true` invece dell'effettivo valore `false`);
- *falsi negativi* o errore di *II tipo*: predizioni negative sbagliate (`false` invece dell'effettivo `true`).

Le tipiche misure definite per un **modello predittivo** *binario* sono le seguenti:
- **precisione**: $\frac{tp}{tp+fp}$ proporzione di veri positivi (tp) rispetto ai casi predetti come positivi (pp)
- **richiamo** (*recall* o *true-positive rate*, TPR): $\frac{tp}{fp+tn}$ proporzione di falsi positivi (fp) su tutti i negativi (an).
- analogamente *false-positive rate (FPR)*: $\frac{fp}{fp+tn}$ proporzione di falsi positivi fp su tutti i negativi an.

Nella scelta del modello predittivo occorrerebbe massimizzare precisione e richiamo e minimizzare il FPR, ma nella pratica tali obiettivi risultano *incompatibili*: si può massimizzare la precisione e minimizzare il FPR facendo predizioni positive solo se si è sicuro, ma ciò abbassa il richiamo; per massimizzare il richiamo si possono ammettere previsioni più azzardate ma questo tende ad abbassare la precisione e a incrementare il FPR.
Si supponga a titolo d'esempio che i falsi positivi rappresentano cai c volte peggiore dei falsi negativi:

Si tratta di costi additivi, quindi il **costo** di una predizione sarebbe proporzionale a $c \cdot fp + fn$. Si dovrebbe scegliere il predittore con il costo più basso.
Nel confronto di modelli, si dice che un predittore A **domina** B se A ha più TPR e meno FPR di B. In tal caso A avrà un costo inferiore di B per tutte le funzioni che dipendono solo da numero di FP e FN, assumendo un costo additivo non negativo.
Indipendentemente dai costi, si possono considerare lo **spazio ROC** (*receiver operating characteristic*), ossa il grafico del FPR control il TPR e lo **spazio P-R** ossia il grafico della precisione contro il richiamo. Ogni modello produce un punto in ciascuno spazio.

Esempio 80. Caso di 100 esempi positivi (ap) e 1000 esempi negativi (an). Metrici di confusione di diversi modelli:

Confronto tra a e c:
- `a` : TPR, richiamo 0.7, FPR 0.15, precisione $\frac{20}{220} \approx 0.318$
- `c` : TPR, richiamo 0.98, FPR 0.2, precisione $\frac{98}{298} \approx 0.329$

per cui c risulta migliore di a in termini di precisione e richiamo ma peggiore in termini di FPR.
Se i falsi positivi fossero considerati più importanti dei falsi negativi, allora `a` sarebbe preferibile rispetto a `c` (si vede nello spazio ROC, ma non in quello P-R).
Risulta peggiore un modello più in basso e più a destra di altri, ad esempio `d` è peggiore di `c`: non sarebbe logico preferire `d` a `c`.

Per alcuni modelli, è possibile individuare un *iperparametro* che, variato, porta a diversi valori di TPR e FPR. Un modello che restituisce un valore reale potrebbe predire `true` o `false` in base al superamento di una *soglia*. Tale modello può essere rappresentato con una curva nello spazio ROC al variare di tale parametro e si potrà dire che domina un altro modello se la sua curva è al di sopra e più a sinistra. Se la situazione è più complessa si può ricorrere a funzioni di costo che dipendono dai due tipi di errore oppure si può adottare l'**area sotto la curva** ROC (AUROC o AUC) una misura numerica per confrontare modello nello spazio dei parametri. Risulterà migliore il modello con l'AUC maggiore.

7.3. Modelli-Base

I **modelli di predizione** da apprendere sono funzioni, saranno anche chiamati *classificatori* e *regressori*. L'obiettivo di un algoritmo supervisionato può essere sintetizzato come segue:

dato un insieme di esempi descritti in termini delle variabili di input e obiettivo;

restituire la rappresentazione compatta di una funzione utile a predire il valore della feature-obiettivo di nuovi esempi per i quali siano disponibili solo valori delle variabili di input.

Le differenze fra i diversi algoritmi dipenderanno dalla scelta fra le diverse possibili rappresentazioni delle funzioni. Analizzeremo *modelli base*, essenzialmente *funzioni costanti a pezzi* o *lineari*, che torneranno utili a costruirne di più complessi.

7.3.1. Alberi di Decisione

Un **albero di decisione** è albero binario costituito da:

- nodi *interni* etichettati con *condizioni*, ossia test booleani basati sui valori delle feature negli esempi e connessi con due figli, radici di sotto-alberi, attraverso archi tipicamente etichettato con `vero` e `falso`;
- nodi *foglia* etichettati con una stima puntuale per la feature obiettivo: la classe in un *albero di classificazione* oppure un valore reale in un *albero di regressione*.

Tale struttura rappresenta una *funzione* definita *per parti* ovvero un programma fatto di strutture condizionali annidate. Per la *predizione*, dato un esempio con i valori delle variabili di input: partendo dalla radice, ogni condizione incontrata viene valutata per tale esempio seguendo l'arco corrispondente al risultato di ogni test; raggiunta una foglia, si restituisce la stima puntuale associata.

Esempio 81 *(Alberi di decisione come programmi)* **.** Si considerino i due alberi di decisione dell'esempio **Problema di classificazione** illustrati nella seguente figura:

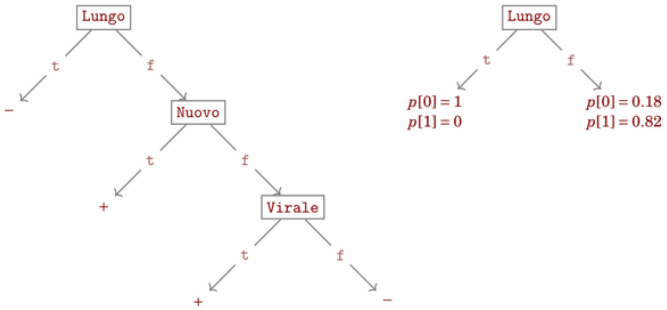


Figura 17: Alberi di decisione: standard e probabilistico

- Funzione di classificazione per l'albero a sinistra:

Algoritmo 21 — *Funzione Da_vedere*

```
1: define Da_vedere(e)
2: if Lungo(e) then return false
3: else
4:     if Nuovo(e) then return true
5:     else
6:         if Virale(e) then return true
7:         else return false
```

- L'albero a destra ammette predizioni probabilistiche nelle foglie ossia distribuzioni di `Da_vedere` :

Algoritmo 22 — *Funzione Da_vedere*

```
1: define Da_vedere(e)
```

```
2: if Lungo(e) then return 0
3: else
4:     return 0.82
```

Le due questioni principali nell'apprendimento di alberi di decisione sono le seguenti: dati gli esempi di training:

- **Quale** albero generare? Dovrebbe essere possibile rappresentare *qualsiasi funzione* con feature X_i discrete; il *bias* è insito nel criterio di preferenza tra i diversi alberi: andrebbero favoriti alberi più piccoli ossia con la minima profondità o con meno nodi.
- **Come** generarlo? Si può effettuare una ricerca in uno spazio di alberi a partire dal più piccolo che si adatti ai dati, ma tale spazio è enorme per cui una ricerca esaustiva non è proponibile; ci si affida, quindi, a un metodo di ricerca *greedy*, puntendo a minimizzare l'errore.

Si può considerare un albero di decisione come un programma che sappia determinare la predizione per qualunque esempio e arbitrario: ciascuna foglia conterrà una predizione del valore di Y; i nodi interni conterranno test di condizioni seguiti da diramazioni come in `if c(e) then t1(e) else t0(e)`, dove `c` è la condizione booleana da testare e `t1` e `t0` sono i sotto-alberi, ovvero sotto-programmi.
L'algoritmo *ricorsivo* seguente costruisce, in modalità top-down, un albero partizionando gli esempi ricevuti; la crescita viene fermata anche in base a una soglia $\gamma \geq 0$, passata come parametro, che definisce il minimo miglioramento richiesto per proseguire nella ramificazione dell'albero:

Algoritmo 23 — *Algoritmo di apprendimento di alberi di decisione*

```
1: procedure DT_Learner(Cs, Y, Es, γ)
2: Input
3:     Cs: insieme delle possibili condizioni utilizzabili
4:     Y: feature-obiettivo
5:     Es: insieme di esempi di training
6:     γ: miglioramento minimo per l'espansione
7: Output
8:     funzione per predire il valore di Y per un esempio
9: c ← selezione_partizionamento(Es, Cs, γ)
10: if c = ⊥ then {criterio di stop raggiunto}
11:     v ← valore_foglia(Es)
12:     define T(e) = v
```

```
    return T
else
    partizione_1 ← {e ∈ Es : c(e)}
    t_1 ← DT_Learner(Cs \ {c}, Y, partizione_1, γ)
    partizione_0 ← {e ∈ Es : ¬c(e)}
    t_0 ← DT_Learner(Cs \ {c}, Y, partizione_0, γ)
    define T(e) = if_0 c(e) then t_1(e) else t_0(e)
    return T

procedure selezione_partizionamento(Es, Cs, γ)
miglior_valore ← somma_loss(Es) − γ
migliore_condizione ← ⊥
for each c ∈ Cs do
    val ← somma_loss({e ∈ Es | c(e)}) + somma_loss({e ∈ Es | ¬c(e)})
    if val < miglior_valore then
        miglior_valore ← val
        migliore_condizione ← c
return migliore_condizione
```

Nell'algoritmo si effettua una scelta miope della condizione c ottimale, **greedy optimal split**, basata sulla somma delle loss prima e dopo il partizionamento e una soglia γ; l'aggiunta di un livello di bipartizione aumenta le dimensioni dell'albero di un'unità mentre γ serve a penalizzare tale incremento: se positiva, essa è utile a evitare che si verifichi val $<$ miglior_valore per meri errori di arrotondamento.
Il *criterio di stop* viene determinato dall'esaurimento delle condizioni ovvero da esempi che risultano d'una stessa classe, il che porta ad avere una loss nulla.
L'*output* rappresenta una stima puntuale. Come stima puntuale si sceglie, in genere, il valore più probabile, la moda, oppure la mediana o la media; in alternativa si può optare per la restituzione di una distribuzione di probabilità delle classi per gli esempi finiti in quella foglia, che corrisponderà a una regione ristretta dello spazio degli esempi.

Esempio 82 *(Problema preferenze video)* **.** Usando l'algoritmo visti nell'esempio **Problema di classificazione**:

- chiamata iniziale:
  `DT_Learner(` $\{$virale, nuovo, lungo, a_casa$\}$, Da_vedere, $\{e_1, e_2, ..., e_{18}\}, 0)$
  si supponga che il criterio di stop non si avveri e si scelga il test `lungo`, ossia `Lungo = true` ;
- chiamata per costruire t_1, partizione con `Lungo = true` :
  `DT_Learner(` $\{$virale, nuovo, a_casa$\}$, Da_vedere, $\{e_1, e_3, e_4, e_6, e_9, e_{10}, e_{12}\}, 0)$

- tutti gli esempi concordano sulla classe negativa quindi t_1 si riduce a un nodo-foglia con `Da_vedere = false` ;

- chiamata per costruire t_0, partizione con `Lungo=false` : `DT_Learner(` $\{$virale, nuovo, a_casa$\}$, Da_veder
  - gli esempi non concordano sulla classe;
  - se non scatta il criterio di stop, si deve scegliere un nuovo test come, ad esempio, `nuovo` ; continuando, la struttura risultante per t_0 sarà:

Algoritmo 24

```
1: if Nuovo(e) then return true
2: else
3:     if Virale(e) then return true
4:     else return false
```

Il risultato finale è l'albero / programma visto in precedenza.

Usando log-loss con base 2, la media delle loss `somma_loss(Es)/|Es|` corrisponde all'entropia della distribuzione empirica di *Es*. Se *val* è il numero di bit per descrivere *Es* sopo il test di c allora l'entropia della distribuzione creata dal partizionamento sarà $\frac{\text{val}}{|\text{Es}|}$. Si definisce **information gain, IG,** la differenza fra le due entropie. Questo viene spesso usato anche assieme ad altre misure da ottimizzare, ad esempio si può puntare a massimizzare l'accuratezza selezionando la condizione c in base alla log-loss, ma restituendo la moda come valore per le foglie.

Esempio 83. Ancora con il dataset con le preferenze sui video: operando una scelta (miope) del test, ai fini di minimizzare la log-loss dell'Eq. (7.5), ovvero massimizzare la likelihood, si ha che

- prima del test iniziale, la predizione ottimale basata sulla *frequenza empirica* è $p[0] = |\{e \in Es : \texttt{Da_vedere}(e) = \texttt{false}\}|\frac{1}{18} = \frac{9}{18} = 0.5$, $p[1] = |\{e \in Es : \texttt{Da_vedere}(e) = \texttt{true}\}|\frac{1}{18} = \frac{9}{18} = 0.5$, per cui la log-loss risulta: $-\frac{9 \cdot \log_2 0.5 + 9 \cdot \log_2 0.5}{18} = -\frac{18 \cdot \log_2 0.5}{18} = 1$

- test su `Virale` : $[e_1, e_4, e_5, e_6, e_9, e_{10}, e_{12}, e_{13}, e_{14}, e_{15}, e_{16}, e_{17}]$ sono gli esempi con `Virale = true` , mentre $[e_2, e_3, e_7, e_8, e_{11}, e_{18}]$ sono quelli con `Virale = false` ; in ciascuna partizione si ha la stessa frequenza di esempi delle due classi (feature-obiettivo), per cui la predizione ottimale è 0.5 per entrambe con log-loss 1; non essendoci alcuna diminuzione si verifica che tale test non aiuti la predizione;

- test su `Nuovo` : $[e_1, e_2, e_5, e_8, e_{10}, e_{12}, e_{14}, e_{15}, e_{17}, e_{18}]$ sono gli esempi con `Nuovo = true` e $[e_3, e_4, e_6, e_7, e_9, e_{11}, e_{13}, e_{16}]$ sono quelli con `Nuovo = false` ; nella

prima partizione 3 esempi sono negativi e 7 positivi, per cui la predizione di `true` ha una probabilità stimata di $\frac{7}{10}$; nell'altra partizione 2 esempi positivi e 6 di negativi, per cui la predizione di `true` ha una probabilità di $\frac{2}{8}$; la log-loss *dopo* il partizionamento sarebbe: $-\frac{[3\log_2(\frac{3}{10})+7\log_2(\frac{7}{10})+2\log_2(\frac{2}{8})+6\log_2(\frac{6}{8})]}{18} \approx \frac{15.3}{18} \approx 0.85$

- test su `Lungo`: $[e_1, e_3, e_4, e_6, e_9, e_{10}, e_{12}]$ sono gli esempi con `Lungo = true` e $[e_2, e_5, e_7, e_8, e_{11}, e_{13}, e_{14}, e_{15}, e_{16}, e_{17}, e_{18}]$ sono quelli con `Lungo = false`; nella prima partizione ci sono solo esempi negativi per cui la predizione `false` ha probabilità 1; nell'altra partizione si osserva la proporzione di $9:2$ tra le classi; la log-loss risulta: $-\frac{7\cdot\log_2 1+9\cdot\log_2(\frac{9}{11})+2\cdot\log_2(\frac{2}{11})}{18} \approx \frac{7.5}{18} \approx \underline{0.417}$

Quindi, per in nodo radice, il test su `Lungo` risulta il migliore.

Definizione delle Condizioni

Se le variabili di input sono booleane è facile definire le condizioni per i test. In caso contrario ci sono diverse possbilità:

- se X è categorica, con dominio $\{v_1, ..., v_k\}$, si può associare una **variabile indicatrice** binaria X_i a ciascun valore: $X_{i(e)} = 1$ se $X(e) = v_i$ e $X_{i(e)} = 0$ altrimenti: per ogni esempio e, una sola fra $X_1(e), ..., X_{k(e)}$ vale 1.
- Se X è **ordinale** (a valori reali o discreti) allora essa ha un dominio *totalmente ordinato*; in tal caso, per ciascun valore v, si può introdurre una **variabile** booleana di **taglio** / *cut* che varrà 1 se $X > v$ e 0 altrimenti; da una combinazione di tagli si possono definire intervalli; ad esempio il caso in cui la variabile per $X > 9$ sia vera e quella per $X > 17$ sia falsa corrisponde a $9 < X \leq 17$; valori di taglio ottimali possono essere trovati ordianndo gli esempi in base al valore di X e selezionando quei valori che partizionino al meglio rispetto alla Y.
- **binning**: dato un insieme di soglie si crea una feature per ogni intervallo / *bin*: date le soglie $\alpha_1 < \alpha_2 < ... < \alpha_k$ si ottengono $k+1$ feature booleane, una vera per X tale che $X \leq \alpha_1$, una per $\alpha_k < X$ e una per $\alpha_i < X \leq \alpha_{i+1}$ per ogni $1 \leq i < k$; si noti che il bin $\alpha_i < X \leq \alpha_{i+1}$ richiede 2 partizionamenti tramite tagli; i valori α_i possono essere predefiniti, ad esempio si possono adottare i *percentili* rilevati sui dati di training, oppure scelti in base a quelli della Y;
- per feature X categoriche, si possono definire condizioni $X \in S$ con $S \subset \text{dom}(X)$ dato l'*insieme* di valori $|S| \geq 1$; se Y è booleana per scegliere gli S, avendo ordinato $\text{dom}(X)$ in base alle proporzioni di Y veri, si trova la selezione migliore, *greedy optimal split*, della lista ordinata;
- si può pensare anche a un'estanzione che preveda la possibilità di condizioni n-arie (*multiway split*) quindi per variabili con più valori nel dominio si potrà considerare un figlio per ciascun valore: si ottiene un albero *n-ario*, con struttura più complessa di quelli con test della forma `if-then-else`, più difficili da apprendere in quanto per alcuni valori delle condizioni potrebbe non essere disponibile alcun

esempio di training; con euristiche greedy, come IG, una condizione su variabile con domini più grandi porta ad avere più figli e a un miglior adattamento ai dati a scapito della compattezza del modello; si osservi ad esempio che una condizione a 4 vie equivale a 3 bipartizioni per cui si potrebbero avere 4 foglie.

Scelte di Progetto Alternative

Quando `selezione_partizionamento` restituisce $\perp$ non si procede a ulteriore partizionamento. Ciò può accadere a seguito dell'esaurimento degli esempi o delle condizioni, oppure quando gli esempi hanno tutto lo stesso valore per ciascuna condizione, o hanno tutti la stessa classe. Si può avere un miglioramento con l'aggiunta di una condizione con una soglia $< \gamma$. Altri criteri di stop anticipato che eviti ulteriori partizionamenti possono essere la *minimun child size*, allorchè un nodo-figlio abbia meno esempi rispetto a una data soglia, o la *maximum depth*, che segnala il raggiungimento di una profondità massima.

È possibile che una condizione funzioni bene solo con altre ma un metodo greedy potrebbe non funzionare quando questo si verifica. Si tratta di un *caso difficile*: ad esempio si consideri di dover trovare un albero che approssimi una funzione di parità di k variabili booleane, vera se un numero dispari (o pari) di essa sono vere; conosceere i valori di meno di k variabili non dà alcuna informazione sul valore della funzione; si possono approssimare funzioni di parità più semplici ($k = 2$) come lo XOR o l'equivalenza, ma in genere gli alberi di decisione possono essere molto complessi. Quando dal partizionamento greedy risultano alberi troppo complicati conviene procedere alla loro *semplificazione* (ad esempio con tecniche di *pruning*).

Esempio 84. Si consideri un dataset con feature di input x, y, z e obiettivo t per la funzione: `if x then t=y else t=z`, ossia t è vera se x è vera e y è vera oppure se x è falsa e z è vera. Un dataset che ricalca la tabella di verità è il seguente:

Si possono costruire i seguenti alberi:

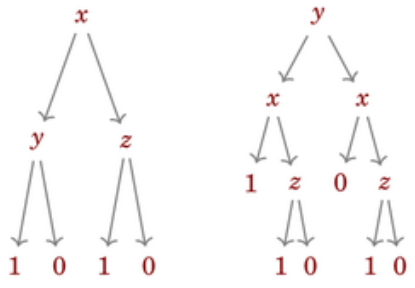


Figura 18: Alberi per `if-then-else`

L'albero a sinistra risulta migliore ma parte da x non informativa: stessa proporzione di esempi con t vera per x vera o falsa. L'algoritmo partizionerebbe su y,

come nell'albero a destra: se y è vera allora la proporzione di t vere risulta più grande riuspetto ai casi in cui y è falsa; quando y è vera, partizionare su x predice facilmente t quando x è vera: seguendo i percorsi verso $t = 1$ nell'albero destro si osserva che t è vera se $(x \wedge y)(y \wedge \neg x \wedge z) \vee (\neg y \wedge \neg x \wedge z)$ da cui, semplificando $(x \wedge y) \vee (\neg \wedge z)$ da cui si ottiene facilmente l'albero a sinistra.

7.3.2. Regressione e Classificazione Lineari

Si prnderanno in considerazione algoritmi che apprendono *modelli lineari* per risolvere problemi di regressione (obiettivo continuo) e classificazione (obiettivo discreto).

Con la **regressione lineare** si mira all'adattamento di una funzione *lineare* a un training set con feature *numeriche*. Si supponga che le feature di input siano $X_1, ..., X_m \in \mathbb{R}$ e che la feature obiettivo sia $Y \in \mathbb{R}$.

Il moello è una **funzione lineare** delle feature di input:

$$\hat{Y}_{\overline{w}}(e) = w_0 + w_1 \cdot X_1(e) + \cdots + w_m \cdot X_{m(e)} = \sum_{i=0}^{m} w_i \cdot X_{i(e)}$$

dove $\overline{w} = \langle w_0, ..., w_m \rangle$ vettore di **pesi** che costituiscono i *parametri* da determinare. Si ottiene una forma più compatta assumendo la feature aggiuntiva costante $X_0 = 1$.

Per definire il problema di ottimizzazione, dato l'insieme di esempi Es, si considera l'errore quadratico medio, su Es per Y:

$$\text{errore}(Es, \overline{w}) = \frac{1}{|Es|} \sum_{e \in Es} \left(Y(e) - \hat{Y}_{\overline{w}(e)}\right)^2 = \frac{1}{|Es|} \sum_{e \in Es} \left(Y(e) - \sum_{i=0}^{m} w_i \cdot X_{i(e)}\right)^2$$

Questa funzione ha un unico minimo. Considerando le derivate parziali rispetto ai pesi: $\frac{\partial}{\partial w_i}\text{errore}(Es, \overline{w}) = \frac{1}{|Es|} \sum_{e \in Es} 2\sigma(e) \cdot X_{i(e)}$ dove $\sigma(e) = \hat{Y}_{\overline{w}}(e) - Y(e)$ è una funzione lineare sui pesi. Il minimo può essere calcolato analiticamente risolvendo le equazioni lineari ottenute annullando tali derivate, utilizzando il cosidetto **metodo dei minimi quadrati**.

Funzioni Lineari Compresse

Per la *classificazione binaria* si ha una feature-obiettivo Y con dominio $\{0, 1\}$. Come modello non basta una funzione lineare: le predizioni non possono superare 1 o essere minori di 0. Si considera allora una **funzione lineare compressa** (*squashed*):

$$\hat{Y}_{\overline{w}}(e) = \varphi\big(w_0 + w_1 + X_1(e) + \cdots + w_m \cdot X_{m(e)}\big) = \varphi\left(\sum_i w_i \cdot X_{i(e)}\right)$$

dove φ è detta anche **funziuone di attivazione** da $\mathbb{R}$ a $R \subset \mathbb{R}$, tipicamente si considera $R = [0, 1]$. Un predittore basato su tale funzione si dice **classificatore lineare**.

Lo **step** o *gradino di Heaviside* è una funzione di ativazione semplice definita come segue:

$$\text{step}_0(x) = \begin{cases} 0 & x < 0 \\ 1 & x \geq 0 \end{cases}$$

Essa viene impiegata in unità dette **percettroni** alla base delle reti neurali. Tuttavia risulta difficile adattare la discesa di gradiente a funzioni non ovunque differenziabili: con una funzione quasi ovunque differenziabile come **step**, l'ampiezza dello scalino dovrebbe tendere a zero per garantire la convergenza. Il grafico della funzione step è mostrato qui di seguito.

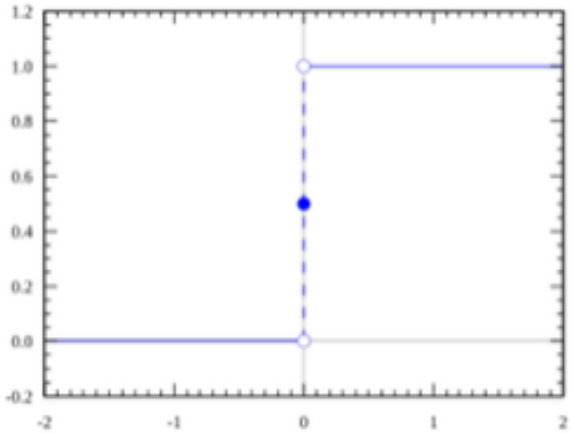


Figura 19: Funzione step

Si considerano allora in alternativa funzioni come la sigmoide (un tipo di **funzione logistica**):

$$\text{sigmoide}(x) = \frac{1}{1 + e^{-x}}$$

il cui grafico è rappresentato nella seguente figura:

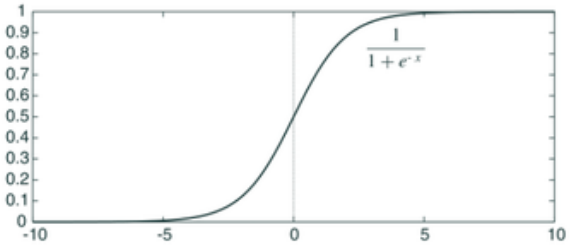


Figura 20: Funzione sigmoidale

Essa comprime le predizioni nell'intervallo $]0,1[$, appropriato ai fini della classificazione, e risulta differenziabile, con derivata:

$$\frac{d}{dx}\text{sigmoide}(x) = \text{sigmoide}(x) \cdot (1 - \text{sigmoide}(x))$$

Nella **regressione logistica** il modello di classificazione è costituito da una funzione lineare compressa dalla sigmoide

$$\hat{Y}(e) = \text{sigmoide}\left(\sum_{i=0}^{m} w_i \cdot X_{i(e)}\right)$$

Per trovare i pesi $\overline{w}$ si minimizza la *log-loss* (ovvero la *log-likelihood negativa*) media di cui si è trattato in precedenza:

$$LL(Es, \overline{w}) = -\frac{1}{|Es|}\left[\sum_{e \in Es} Y(e)\log\big(\hat{Y}(e)\big) + (1 - Y(e))\log\big(1 - \hat{Y}(e)\big)\right]$$

con derivate parziali:

$$\frac{\partial}{\partial w_i} LL(Es, \overline{w}) = \frac{1}{|Es|}\sum_{e \in Es} \sigma(e) \cdot X_{i(e)}$$

dove $\sigma(e) = \hat{Y}_{\overline{w}}(e) - Y(e)$. Tale funzione risulta difficile da minimizzare analiticamente, essendo $\hat{Y}_{\overline{w}}$ non lineare nei parametri per cui si ricorre ad una soluzione algoritmica.

Discesa di Gradiente Stocastica

La **discesa di gradiente** è un metodo *iterativo* per la ricerca locale dei minimi di funzioni d'errore.

Dopo aver inizializato $\overline{w}$ in maniera casuale, a ogni iterata, ogni w_i verrà decrementato in proporzione alla sua derivata parziale:

$$w_i \leftarrow w_i - \eta \cdot \frac{\partial}{\partial w_i}\text{errore}(Es, \overline{w})$$

dove η è detta *passo* o **learning rate**. Le derivate misurano l'influenza sull'errore di piccole variazioni dei pesi.

Per un modello lineare, l'errore quadratico risulta una funzione *convessa* con unico minimo locale, quindi anche globale. Con un passo sufficientemente piccolo, l'algortimo converge al minimo locale. Le derivate parziali di $\text{errore}(Es, \overline{w})$ o log-loss media si possono scrivere come segue:

$$\frac{\partial}{\partial} w_i \text{ errore}(Es, \overline{w}) = \frac{1}{|Es|}\sum_{e \in Es} \sigma(e) \cdot X_i(e)$$

con $\sigma(e) = \hat{Y}_{\overline{w}}(e) - Y(e)$ e costante 2 assorbita da η.
Normalmente l'aggiornamento dei pesi avviene dopo aver iterato su tutti gli esempi; in alternativa, si può ricorrere alla **discesa di gradiente stocastica** nella quale si prevede un aggiornamento dopo aver visto un campione di b esempi, detto **batch** o **minibatch**; in tal caso un passaggio completo sul dataset si chiama **epoca**, costituita da $\frac{|Es|}{b}$ batch.
L'algortimo di apprendimento del modello è descritto di seguito.

ALGORITMO 25 — *Algoritmo per l'apprendimento di modelli lineari*

```
1: procedure Linear_learner(Xs, Y, Es, η, b)[cite: 24]
2: Input
3:     Xs: insieme di feature input, Xs = {X_1, ..., X_m}, X_0 = 1[cite: 24]
4:     Y: feature obiettivo[cite: 24]
5:     Es: insieme di esempi di training[cite: 24]
6:     η: learning rate[cite: 24]
7:     b: dimensione del batch[cite: 24]
8: Output
9:     funzione di predizione su esempi[cite: 24]
10: Local
11:     w_0, ..., w_m: reali[cite: 24]
12:     d_0, ..., d_m: reali[cite: 24]
13: inizializzare casualmente w_0, ..., w_m[cite: 24]
14: define pred(e) = φ(Σ_i w_i · X_{i(e)})[cite: 24]
15: repeat
16:     for each i ∈ [0, m] do d_i ← 0[cite: 24]
17:     selezionare il batch B ⊆ Es di dimensioni b[cite: 24]
18:     for each esempio e ∈ B do
19:         errore ← pred(e) − Y(e)[cite: 24]
20:         for each i ∈ [0, m] do
21:             d_i ← d_i + errore · X_{i(e)}[cite: 24]
22:     for each i ∈ [0, m] do
23:         w_i ← w_i − η * d_i/b[cite: 24]
24: until terminazione[cite: 24]
25: return pred[cite: 24]
```

Le possibili condizioni di terminazione per l'algoritmo sono:
1. un numero massimo di passi (utile a evitare di divergere);
2. un errore vicino a 0;
3. ridotte variazioni di $\overline{w}$ fra iterate successive.

Sono possibili alcune varianti: regolando le dimensioni dei batch, con b più piccole l'apprendimento risulta più veloce dato che si richiedono meno esempi per l'aggiornamento; considerando, invece, tutti gli esempi, si termina quando tutte le d_i sono nulle: tipicamente si parte con batch piccolo e si aumenta b fino alla convergenza.
Nella **discesa di gradiente incrementale** l'aggiormanto dei pesi va fatto dopo ogni esempio, quindi, in tal caso, $b = 1$. Non si devono memorizzare i d_i, i pesi sono aggiornati direttamente. Ciò torna utile per esempi acquisiti in streaming. Nel caso di esempi non selezionati casualmente, si corre il rischio della cosidetta **dimenticanza catastrofica**, ossia dell'adattamento ai dati più nuovi, dimenticando quelli meno recenti.

Separabilità Lineare
In uno spazio m-dimensionale, con m feature, si definisce **iperpiano** l'insieme di punti che soddisfano un vincolo espresso come equazione lineare sulle variabili. Esso determina uno spazio di $(m-1)$ dimensioni.
Un **problema** di classificazione binaria si dice **linearmente separabile** quando esiste un iperpiano che separi gli esempi dalle diverse classi. Un problema siffatto può essere risolto con la regressione logistica (usando un algortimo di discesa di gradiente stocastica): l'errore è riducibile arbitrariamente se e solo se il problema linearmente separabile. L'iperapiano separatore sarà l'insieme di punti per i quali $\sum_i w_i \cdot X_i = 0$, dove $\overline{w}$ contiene i coefficienti appresi. Dato un nuovo esempio, per la predizione della classe il modello avrà un valore maggiore di 0.5 da un lato e minore dall'altro.

Esempio 85 *(Separabilità lineare)* **.** Risultano problemi *linearmente separabili* quelli leagti alle funzioni `or` e `and`.
Sono, invece *non linearmente separabili* il problema dello `xor`, dato che nessuna retta può separare le due classi di esempi, ossia la funzione non è rappresentabile con un classificatore lineare.

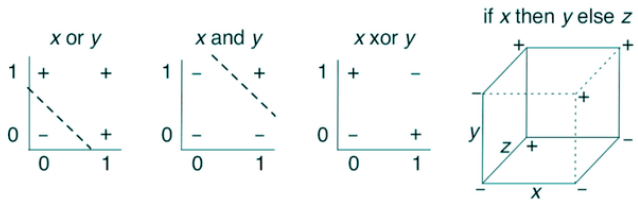


Figura 21: Problemi linearmente separabili (`or` e `and`) e non (`xor` e condizionale)

Esempio 86. Problema su variabili booleane con obiettivo t vero se x vera e y vera, o se x falsa e z vera:
- risulta non linearmente separabile: `t = if x then y else z` ;

- usando la GD, dopo 1000 epoche con $\eta = 0.05$, si ottiene un modello con i pesi seguenti:

$$\text{lin}(e) = -0.1 \cdot x(e) + 4.06 + y(e) + 4.06 \cdot z(e) - 3.98$$

da cui $\hat{t}(e) = \text{sigmoide}(\text{lin}(e))$.

x	y	z	t	lin	$\hat{t}$
0	0	0	0	−3.98	0.02
0	0	1	1	0.08	0.52
0	1	0	0	0.08	0.52
0	1	1	1	4.14	0.98
1	0	0	0	−4.10	0.02
1	0	1	0	−0.04	0.49
1	1	0	1	−0.04	0.49
1	1	1	1	4.14	0.98

- solo per quattro esempi si hanno predizioni corrette, per gli altri si hanno valori vicini a 0.5;
- il modello risultante è abbastanza stabile anche ripetendo l'algoritmo con diverse inizializzazioni;
- l'incremento del numero di iterazioni avvicina le predizioni $\hat{t}$ a $0, 1\ 0\ 0.5$.

Feature-Obiettivo Categoriche

Quando Y è categorica con più di due classi, essa può essere rappresentata usando variabili indicatrici binarie da imparare separatamente. Essendoci solo un valore di Y per ogni esempio, il modello dovrebbe essere capace di predire probabilità per ciascuna variabile indicatrice, con somma unitaria. È possbile apprendere modelli per tutte tranne una e ricavare la probabilità del suo valore dalle altre. Ciò introduce una forma di *asimettria* che può risultare problematica con predizione debole del valore per l'accumularsi di errori sulle altre variabili.

In alternativa si può considerare, per ogni valore, l'esponenziale d'una funzione lineare, da normalizzare. Si avranno così più parametri del necessario nel modello (*sovra-parametrizzazione*), ma anche uno stesso trattamento per tutti i valori.

Data Y categorica con dominio rappresentato dalle tuple $\langle v_1, ..., v_k$, si definisce la **funzione softmax** $\langle a_1, ..., a_k\rangle \in \mathbb{R}^k \mapsto \mathbb{R}^k$ che calcola un vettore la cui i-esima componente sarà:

$$\text{softmax}(\langle a_1, ..., a_k\rangle) = \frac{\exp(a_i)}{\sum_{j=1}^{k} \exp(a_j)}$$

Tale funzione assicura la positività e la somma unitaria potendo così definire una distribuzione di probabilità. Essa è correlata con la sigmoide, essendo:

$$\text{sigmoide}(x) = \frac{1}{\exp(-x)+1} \overset{(*)}{=} \frac{\exp(x)}{\exp(0)+\exp(x)} = \text{softmax}(\langle 0, x\rangle)_2$$

la coppia $(0,\ x)$ corrisponde ai valori (false, true); $\text{softmax}(\langle 0, x\rangle)_2$ è la seconda componente della coppia risultante della softmax; si ha l'uguaglianza $(*)$ moltiplicando numeratore e denominatore per $\exp(x)$ quindi equivale al caso in cui la prima componente sia fissata a 0. Si noti che la softmax, come la sigmoide, non può rappresentare probabilità nulle.

La **regressione softmax** è una generalizzazione della regressione logistica (detta anche *regressione logistica multinomiale*): si ha un'equazione lineare per ogni valore di Y, dove $dom(Y) = \{v_1, ..., v_k$. Per la predizione per un esempio e e $\text{softmax}\Big(\langle u_1(e), ..., u_{k(e)}\rangle\Big)$ calcola una tupla di k valori con j-esima componente corrispondente alla predizione per $Y = v_j$ e $u_{j(e)} = w_{0,j} + X_1(e) \cdot w_{1,j} + \cdots X_{m(e)} \cdot w_{m,j}$.

Il modello viene tipicamente ottimizzato usando la log-loss categorica: sia w_{ij} per X_i e v_j, e sia $Y(e) = v_q$:

$$\begin{aligned}
\frac{\partial}{\partial w_{ij}}\text{logloss}(\text{softmax}\Big(\langle u_1(e), ..., u_{k(e)}\rangle\Big), v_q) &= \frac{\partial}{\partial w_{ij}} - \log\left(\frac{\exp\Big(u_{q(e)}\Big)}{\sum_k \exp\Big(u_{j(e)}\Big)}\right) \\
&= \frac{\partial}{\partial w_{ij}}\left(\log\left(\sum_j \exp\Big(u_{j(e)}\Big)\right) - u_{q(e)}\right) \\
&= \left[\Big(\hat{Y}(e)\Big)_j - \mathbf{1}(j = q)\right] \cdot X_i
\end{aligned}$$

con $\mathbf{1}(j = q) = 1$ se j è l'indice del valore osservato v_q e $\Big(\hat{Y}(e)\Big)_j$ la j-esima componente della predizione, valore predetto meno quello effettivo.

Nell'implementazione del modello vi sono problematiche connesse con la rappresentazione dei numeri:

- l'esponenziale di numeri grandi potrebbe non essere rappresentabile portando a un caso di *overflow*, come $\exp(800)$
- l'esponenziale di numeri grandi negativi tende a 0, comportando possibili casi di *underflow*, ad esempio $\exp(-800)$.

Osservato che l'aggiunta di una costante a ogni a_i nella softmax non ne cambia il valore, per la prevenzioni casi di over/under flow, conviene sotrarre il massimo da ciascun valore per cui ci sarà sempre uno 0 e il resto dei valori risulteranno negativi. Su GPU e HW paralleli a bassa precisione le correzioni sono importanti. Per grandi numeri di valori possbili il calcolo del denominatore diventa costoso. Si può ricorrere a una modalità di predizione in termini di un albero binario di valori, definita **softmax gerarchica**, simile alla softmax, ma più efficiente per grandi domini. Ad esempio in NLP può essere necessario predire prossima parola in un testo.

Creazione di Feature di Input

Nella regressione lineare e in quella logistica, si considerano feature di input numeriche. In caso di altri tipi si devono fare delle trasformazioni:

- feature *categoriche*: vanno convertire in feature con dominio $\{0, 1\}$, tramite **one-hot encoding**, usando le variabili indicatrici;
- feature a *valori reali*: si possono usare direttamente in modelli lineari per Y, una volta aggiustate le altre feature di input; spesso si adottano anche trasformazioni per crearne di nuove, dotate di proprietà desiderabili;
- feature *ordinali*, comprese quelle a valori reali: si possono considerare dei *tagli* per definire feature booleane, ad esepio da x, scegliendo un valore v del suo dominio, si considera una nuova feature, vera se $x > v$, oppure $x - v > 0$; nel *binning* si sceglie un insieme di soglie, $a_1 < a_2 < \cdots < a_k$, ricavando una feature booleana per ogni intervallo fra a_i e a_{i+1}, come per una funzione costante a pezzi; una feature può essere anche derivata da $\max(x - v, 0)$, funzione alla base delle *rectified linear unit (ReLU)*.

La progettazione di feature appropriate ai diversi problemi e relativi modelli è il tema principale della cosidetta **feature engineering**. Spesso risulta difficile progettare buone feature. In seguito si considererà il problema dell'apprendimento delle feature il quale è alla base del cosidetto **representation learning**.

7.4. Sovradattamento

Il **sovradattamento**, *overfitting*, è il problema che si manifesta con l'apprendimento di modelli basati su *regolarità apparenti* presenti nei dati di training, ma non in quelli di test o, in generale, nel mondo da cui essi sono tratti. Il fenomeno è tipico nella ricerca di segnali in dati distribuiti casualmente: si tratta di correlazioni *spurie* nei dati che non si riflettono sull'intero dominio del problema; si verifica un *eccesso di fiducia* nelle predizioni del modello rispetto a quanto autorizzino i dati a disposizione.

> **Esempio 87** *(Ristoranti)* **.** Sito con giudizi su ristoranti: da 1 a 5 stelle. Si vogliano riconoscere e mettere in evidenza i ristoranti eccellenti: bisogna capire se serve usare il giudizio medio. Per ristoranti con molti giudizi risulta difficile avere una media eccellente.
> Non è difficile osservare che un ristorante con un solo giudizio pari a 5 stelle: apparentemente rientrerebbe tra quelli eccellenti ma è improbabile che lo sia davvero; analogo problema si manifesterebbe con ristoranti con uno o pochi giudizi molto bassi.

Previsioni estreme possono diventare problematiche con la disponibilità di nuovi dati. Questa forma di sovradattamento è legata alla cosiddetta **regressione verso**

la media. I valori delle osservazioni sono determinati da *qualità* e *caso*: più dati abbassano l'impatto della casualità.
Il sovradattamento può dipendere anche dalla *complessità del modello* scelto: un modello più complesso, con più parametri, risulta più facile da adattare ai dati di training rispetto a uno più semplice. Si può considerare il caso estremo in cui si preveda un modello con un parametro per ciascun esempio. Tuttavia esso andrà giudicato sulla base di nuovi esempi di test, non utilizzati per l'addestramento. Dalla Statistica, l'**errore** sul test-set può essere descritto come segue:

$$\text{Errore}_2(\text{Test}) = \text{Bias}^2 + \text{Varianza} + \text{Errore_irriducibile}$$

Qui il **bias** è l'errore dovuto all'imperfezione del modello appreso, risulta basso quando esso ha una complessità vicina quella ideale, detta **ground truth**, del processo reale che governa la generazione dei dati. Può essere scomposto in *bias di rappresentazione*, la differenza tra tipo di modello scelto e ground truth e *bias di ricerca*, influenza dell'algoritmo che non cerca esaustivamente nello spazio di ipotesi. La **varianza** è la parte di errore dovuta all'insufficienza di dati disponibili; un modello più complesso richiede più dati per cui, se il quantitativo di dati è fisso, si deve trovare un **compromesso** fra bias e varianza. Per un modello complesso, se non è disponibile il quantitativo di dati necessario allora il bias sarà basso e la varianza alta; per un modello semplice, se i dati disponibili sono sufficienti alla stima dei parametri si ha una bassa varianza ma un bias alto. Il **rumore** è l'errore intrinseco dovuto a dati che dipendono da *feature non considerate* nel modello e alla *naturale aleatorietà* nel processo di generazione dei dati.

7.4.1. Pseudoconteggi

Nella predizione il calcolo della media costituisce spesso una scelta ottimale rispeto a molte misure basate su dati di training. Ma la *media empirica* su *Es* non è sempre valida per stime riguardanti le nuove istantze. Ma, in mancanza di dati a sufficeinza, si può verificare il caso di un valore fra quelli del dominio mai osservato in *Es* che avrebbe media nulla e, se si deve stimare la probabilità, anche la frequenza relativa sarebbe nulla.
Per porre rimedio a tali problemi si possono considerare *pseudo-esempi* aggiuntivi come *conoscenza pregressa* addizionale da usarsi per calcolare i cosidetti **pseudoconteggi** (*prior counts*) di partenza. Esesi saranno non negativi ma non necessariamnente interi.
Disponendo dei valori osservati $v_1, ..., v_n$, per predire il successivo $\hat{v}$, si assume di usare una predizione media a_0, ottenuta da conoscenza pregressa, prima ancora di avere i dati a disposizione, ossia quando $n = 0$; per i casi successivi si stimerà la media come segue;

$$\hat{v} = \frac{c \cdot a_0 + \sum_i v_i}{c + n}$$

con $c \in \mathbb{R}_+$ numero di dati fittizi assunti, ciascun con valore a_0. Quando $c = 0$ la predizione corrisponde a quella della media empirica, non utilizzabile senza dati osservati a disposizione. Il valore di c regola l'importanza relativa fra ipotesi iniziale e dati osservati.

> **Esercizio 1.** Derivare uno stimatore $\hat{p}$ dalle frequenze n_0 e n_1. Una buona stima $\hat{p}$ dovrà minimizzare l'errore su casi di test. Adottando errore quadratico o log-loss, la media empirica fornisce una stima ottimale: $\hat{p} = \frac{n_1}{n_0+n_1}$. Tuttavia, pur minimizzando errore sul training set, non ci sono garanzie sul test set. Tipicamente, se uno dei valori non occorre mai nel training set, si registrerebbe una log-loss infinita.
> In tali casi si può ricorrere allo **smoothing addititivo di Laplace**:
>
> $$\hat{p} = \frac{n_1 + 1}{n_0 + n_1 + 2} = \frac{n_1 + 1}{n + 2}$$
>
> Fra tutti gli stimatori, esso minimizza log-loss ed errore quadratioc sul test set. L'aggiustamento equivale all'aggiunta di due pseudo-esempi, uno con $Y = 0$ e uno con $Y = 1$

7.4.2. Regolarizzazione

Secondo il *Rasoio di Occam* si dovrebbero preferire modelli semplici a quelli complessi. A tale scopo si può considerare l'uso di un **regolarizzatore**, ossia un termine da aggiungere alla misura di adattamento del modello ai dati in modo da *penalizzare* la complessità dell'ipotesi da apprendere.
Si dovrà pertanto scegliere un'ipotesi h che minimizzi

$$\left[\sum_e \text{loss}\left(\hat{Y}(e), Y(e)\right)\right] + \lambda \cdot \text{regularizer}\left(\hat{Y}\right)$$

dove:

- $\text{loss}\left(\hat{Y}(e), Y(e)\right)$ misura della qualità dell'adattamento su e;
- $\text{regularizer}\left(\hat{Y}\right)$ penalizza la complessità del modello;
- il **parametro di regolarizzazione** λ, media tra adattamento e semplicità; esso può servire anchhe a sommare quantità su scale diverse e può essere determinato in base a conoscenza pregresa o tramite *cross-validation*.

Si osservi che con molti esempi la somma a sinistra tende a dominare sul regolarizzatore, mentre con pochi esempi il regolarizzatore ha maggiore effetto.
Il parametro di regolarizzazione è un esempio di iperparametro del modello. Formalmente un **iperparametro** è un parametro usato per definire cosa/come si ottimizza

e viene scelto in base a conoscenza pregressa, esperienza con problemi simili, o anche via **tuning** tramite *cross-validation.*
Ad esempio, nel caso degli alberi di decisione, una misura della complessità è il numero di test, il quale dipende a sua volta dal numero delle foglie. Nella minimizzazione della loss si può aggiungere una funzione delle dimensioni dell'albero T:

$$\left(\sum_{e\in Es}\text{loss}\big(\hat{Y}(e),Y(e)\big)\right)+\gamma|T|$$

dove $|T|$ è la misura sopra indicata: un nuovo nodo-test risulta utile se riduce l'errore di γ.
Nelc aso di modelli con parametri a valori reali, un regolarizzatore L_2 penalizza la somma dei quadrati dei parametri. Ad esempio, nella cosidetta **ridge regression** esso viene sommato all'*errore quadratico*:

$$\left[\sum_{e\in Es}\left(Y(e)-\sum_{i=0}^{m}w_i\cdot X_{i(e)}\right)^2\right]+\lambda\sum_{i=0}^{m}w_i^2$$

Anche nella regressione logistica, si adotta un regolarizzatore L_2 puntando a minimizzare la seguente log-loss:

$$-\left[\sum_{e\in Es}\Big(Y(e)\log\big(\hat{Y}(e)\big)+(1-Y(e))\log\big(1-\hat{Y}(e)\big)\Big)\right]+\lambda\left(\sum_{i=0}^{m}w_i^2\right)$$

dove $\hat{Y}(e)=\text{sigmoide}\big(\sum_{i=0}^{m}w_i\cdot X_{i(e)}\big)$.
Nell'implementazione della *regolarizzazione* L_2, si introduce il passo:

$$w_i\leftarrow w_i-\eta\cdot\lambda\cdot\left(\frac{b}{|Es|}\right)\cdot w_i$$

con $\frac{b}{|Es|}$ perchè λ è relativo all'intero dataset ma l'aggiormento va operato su ciascun batch di dimensione b; è possbile manche regolarizzare dopo ogni iterata su tutti gli esempi. Il fattore $\eta\lambda b/|Es|$ cambia di rado per cui può essere pre-calcolato.
Un *regolarizzatore* L_1 si bassa solla somma dei valori assoluti dei parametri. Ad eseempio, nel modello detto LASSO si aggiunge $\lambda\big(\sum_i|w_i|\big)$ all'errore quadratico. Usando la log-loss:

$$-\left[\sum_{e\in Es}\Big(Y(e)\log\big(\hat{Y}(e)\big)+(1-Y(e))\log\big(1-\hat{Y}(e)\big)\Big)\right]+\lambda\left(\sum_{i=0}^{m}|w_i|\right)$$

con

- derivata parziale del termine $\text{sign}(w_i)=w_i/|w_i|\in\{-1,1\}$: non definita in 0, ma non serve spostarsi da 0 si è già sul valore minimo;

- si implementa facendo tendere a 0 ogni parametro di una costante: diventa nullo nel caso si cambi il segno del parametro;
- nell'**iterative soft-thresholding**, GD per la retgressione logistica, si ha:

$$w_i \leftarrow \text{sign}(w_i) \cdot \max(0, |w_i| - \eta \cdot \lambda \cdot b/|Es|)$$

In caso di feature numerose, il regolarizzatore L_1 tende ad annullare molti pesi, facendo ignorare le relative feature, per cui diventa un meccanismo implicito per la **selezione delle feature**.

7.4.3. Validazione incrociata

Risulta difficile determinare la giusta complessità dei modelli da impiegare prima di aver visto i dati: essa dipende dal numero di parametri e/o da altri iperparametri dell'algoritmo.
A tale scopo si può adottare uno *schema generale* di **ricampionamento** (*resampling*) per l'apprendimento e valutazione, come quello sintetizzato nella seguente figura:

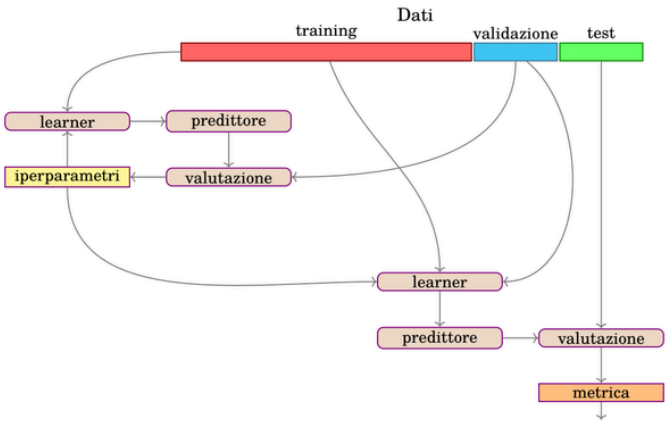


Figura 22: Schema di ricampionamento

Si noti come il test set venga messo da parte per essere usato solo per la valutazione finale. Dev'essere composto da esempi *mai visti*, non utilizzati nella fase di addestramento, da impiegare come surrogato di nuovi esempi futuri.
Nella **validazione incrociata** o *cross validation* (CV) si trattiene parte dei dati di training per valutare un modello appreso sulla base del resto degli esempi di training. Si dividono i dati non di test in due parti: un insieme di *training*, per l'apprendimento dei modelli e un insieme di **validazione** (*validation set, dev set, holdout*) per valutare diversi modelli (o diverse configurazioni degli iperparametri). Trovato iil modello migliore, si userà il dataset per apprendere un modello.
La CV va ripetuta più volte scambiando i ruoli degli esempi per ottenere modelli diversi. Alla fine si sceglierà il modello migliore ossia quello con la migliore configurazione degli iperparametri.

L'errore sul training set, tende a decresce al crescere delle dimensioni dell'albero emtnre si l'errore sul validation set si abbassa e poi prende a risalire.
La CV aiuta a scegliere la configurazione corrispondente al minimo dell'errore sul validation set. L'ipotesi è che si abbia lo stesso punto di minimo anche per l'errore calcolato sul test set. Si può considerare come iperparametro da regolare anche il numero `#passi` di training prima di restituire un predittore, una forma di **early stopping**. Tipicamente l'addestramento ha bisogno di molti esempi per avere modelli migliori, ma ciò non deve andare a scalpito del set per la validazione.
Per confrontare modelli diversi si deve ripetere anche la CV esterna su diversi partizionamenti in training / test set. Ciò per evitare l'influenza di un fattore casuale come la scelta del test set che potrebbe favorire solo alcuni dei modelli considerati. Si confrontano i modelli sulla base delle medie delle misure calcolate su più test set e possibilmente anche della varianza per valutare la stabilità dei modelli.

k-Fold Cross Validation
Disponendo solo di dataset limitati, si può puntare al riuso degli esempi per il training e la validazione per regolare ii parametri del modello appreso, scambiandone i ruoli.
Nella **k-Fold Cross Validation** i passi per valutare una scelta di parametri sono:

- suddividere casualmente il dataset in k parti di uguali dimensioni, dette **fold**
- si valutano i modelli con le diverse impostazioni: addestrando il modello k volte, ognuna con una distinta fold usata per la validazione;
- si determinano e restituiscono le impostaioni ottimali.

Ad esempio, ripetendo per $k = 10$ volte, si addestrano modelli sul 90% e si valida sul 10% dei dati considerati. In tal modo la validazione coinvolge ogni esempio esattamente in una folda.

Leave-One-Out Cross Validation
Nel caso estremo di un numero ancor più limitato di esempi, si può adottare una k-fold CV con k pari al numero di esempi di training, detta **Leave-One-Out Cross Validation**. Avendo n esempi di training, si apprendono n modelli: per ogni esempio e, si usano tutti gli altri per addestrare un modello da valutare infine su e. La complessità cresce col numero di esempi di training: il metodo diventa poco pratico con modelli prodotti in fase di training indipendenti fra loro, mentre risulta adeguato se il modello creato in un'esecuzione può essere modificato in modo efficiente nel successivo, sostituendo un solo esempio con un altro.

7.5. Modelli Compositi

7.5.1. Estensioni dei Modelli Lineari

I modelli d'apprendimento visti fin qui forniscono le basi per altre tecniche di apprendimento. Sebbene qualsiasi funzione discreta possa essere rappresentata attraverso alberi di decisione, alcune funzioni, anche semplici, richiedono albero molto complessi. Anche i modelli lineari possono risultare spesso limitati, a meno che non si introducano meccanismi di costruzione di *nuove feature*.
Una possibile estensione considera l'uso di funzioni *non lineari* degli input originari in modo da creare nuovi input per i modelli lineari. La costruzione di nuove feature aumenta la dimensionalità dello spazio e funzioni che non erano lineari in origine possono diventarlo nel nuovo spazio o almeno rendere i problemi *linearmente separabili*.

Esempio 88. La funzione `xor` risulta linearmente separabile nello spazio 3D con le feature x_1, x_2 e x_1x_2:
- $x_1x_2 = 1$ quando $x_1 = x_2 = 1$
- $x = x_1, y = x_2$ e $z = x_1x_2$, ad esempio $\langle 1, 1\rangle$ viene mappato su $\langle 1, 1, 1\rangle$
- per la separazione basta considerare un piano nel nuovo spazio.

Metodi basati su Kernel

Si possono definire modelli lineari su nuovi spazi di feature multidimensionali. Tali metodi si basano sulla trasformazione di nuovi problemi di ottimizzazione la cui soluzione dipende da una funzione **kernel** definita come prodotto nel nuovo spazio vettoriale:

$$\mathscr{K}(\mathbf{x}, \mathbf{z}) = \langle \varphi(\mathbf{x}, \varphi(\mathbf{z}))$$

con $\varphi : \mathbf{X} \to \mathbf{Es}$ che rappresenta la trasformazione implicita/esplicita verso $\mathbf{Es} = \mathbb{R}^n$, $n > m$, detto *embedding space*.
Tale approccio risulta utile in casi di non separabilità lineare nello spazio originario delle $\mathbf{X}$. Il kernel generalizza il concetto di *prodotto vettoriale*, interpretabile come misura di *similarità* basata sulle nuove feature, ad esempio, prodotto di feature aggiuntive/sostitutive rispetto a quelle iniziali. Sono stati proposti molti tipi di kernel, anche per rappresentazioni delle istanze non vettoriali in origine, come stringhe, liste, alberi, ...
Con uno spazio delle feature esteso il problema del sovradattamento diventa più vincolante.
Una **SVM** è un classificatore basato su kernel: esso definisce un iperpiano, *superficie di decisione* ottimale, che divide esempi positivi dai negativi. In particolare si considera il margine, la distanza minima degli esempi dall'iperpiano: la SVM mira

a trovare l'iperpiano di massimo margine. Gli esempi sul margine, che determinano tale iperpiano, si dicono vettori di supporto. La soluzione sarà calcolata sulla base di prodotti applicati a tali vettori nello spazio di embedding. Il modello è sparso perchè determinato da pochi vettori di supporto, i più vicini all'iperpiano, per cui, put aumentando la dimensionalità, può evitare il sovradattamento.

Ulteriori estensioni

- **Reti neurali**: ammettono input alla funzione lineare di appiattimento che sono a loro volta frutto di funzioni lineari compresse con coefficienti da determinare: con diversi layer siffatti si possono rappresentare funzioni più complesse.
- **Alberi di regressione**: sono alberi con funzioni alle foglie, che possono costituire modelli lineari di regressione, potendo così rappresentare *funzioni lineari per parti*. Estensioni possono considerare foglie contenenti reti neurali o altri modelli non lineari. In fase di apprendimento, la scelta delle condizioni può essere fatta adottando un criterio di minimizzazione della varianza. Per la predizione dell'output per un nuovo esempio, a partire dalla radice, lo si instrada giù per l'albero fino ad individuare una foglia, quindi si userà il modello di regressione in essa contenuto.

7.5.2. Ensamble Learning

In generale, nell'**ensamble learning** si *combinano* le predizioni di un dato numero di modelli, ciascuno appreso da un learner di base a volte anche da parte del dataset. Ad esempio nelle foreste di alberi di decisione, le predizioni finali si otterranno attraverso medie ovvero meccanismi di voto. Vi sono diversi approcci di *ensamble learning* (*bagging, boosting, stacking*, ...) accomunati dall'essere costituiti da un certo numero di modelli base addestrati sui dati e poi combinati attraverso meccanismi di voto o medie di tipo diverso.

Bagging: Random Forest

La **random forest** è un modello composto da più alberi di decisione. L'idea è quella di addestrare un certo numero di alberi su parte differenti del dataset. Per ogni esempio da classificare ognuno darà una predizione; le predizioni saranno aggregate per formare la predizione finale per l'esempio dato.
L'efficacia dipende dalla *diversità* degli alberi generati in modo da ottenere da ciascuno predizioni anche diverse. A tale scopo per ogni albero si potrebbe considerare un sottoinsieme casuale di feature. In alternativa, le feature per i test nei nodo possono essere scelte in un *insieme ristretto*, variabile per ciascun albero.
Nel **bagging** (o *bootstrap aggregating*) si considerano diversi sottoinsiemi degli esempi di training: dati m esempi di training ogni modello base ne usa un poccolo numero. Ad esempio si possono considerare sottoinsiemi di m esempi estratti casualmente con rimpiazzo: in ognuno, risulteranno esempi assenti oppure anche duplicato il che porta a circa il 63.2% degli esempi originari per ciascun modello

base. Nella *predizione* finale si dovrà mediare; ad esemio si può considerare la classe di amggioranza sulle predizioni, ossia un meccanismo di voto basato sulla moda, che predica la classe più probabile / predetta da più modelli base. Per foreste di ableri di regressione sono previste medie di tipo diverso.

Boosting

Nel **boosting** i modelli sono appresi in *sequenza* imparando dagli errori dei precedenti: si una, in genere, lo stesso tipo di *learner di base* quali, ad esempio, alberi did ecisione o funzioni lineari compresse. Essi vanno via via adattati agli esempi sui quali il modello precedente commette errori: è come seg li esempi fossero ordinati in base agli errori. La predizione finale si ottiene aggregando le predizioni dei modelli prodotti nelle diverse iterate tramite somma, media pesata, moda, ...
Si osservi come i modelli base possano anche essere *deboli*, non necessariamente ottimali, si chiamano infatti anche **weak learner**: essi devono giusto superare le prestazioni di un predittore casuale. L'ensemble risultante avrà prestazioni migliori garantite rispetto a ciascuno di essi. **AdaBoost** (*ADAptive BOOSTing*) è fra gli algoritmi più noti.

Functional Gradient Boosting

Il **functional gradient boosting** prevede un iperparametro K che corrisponde al numero di iterate da ripetere e quindi di modelli base di regressione da apprendere. La *predizione finale* viene operata in funzione degli input nel modo seguente:

$$p_0 + d_1(X) + \cdots + d_{K(X)}$$

dove p_0 rappresenta la predizione iniziale, ad esempio la media, e d_i è la differenza dalla predizione precedente.
L'i-esima predizione si può scrivere come:

$$p_{i(X)} = p_0 + d_1(X) + \cdots + d_{i(X)} = p_{i-1}(X) + d_{i(X)}$$

dove d_i viene costruito dal weak learner minimizzando l'errore di p_i (fissato p_{i-1}):

$$\sum_e \text{loss}\big(p_{i(e)}, Y(e)\big) = \sum_e \text{loss}\big(\hat{d}_{i(e)}, Y(e) - p_{i-1}(e)\big)$$

usando una qualsiasi loss, anche una per obiettivi continui, ma non la log-loss; $\hat{d}_{i(e)}$ deve ottimizzare $Y_{i(e)} - p_{i-1}(e)$.

Algoritmo 26 — *Algoritmo per l'apprendimento di un modello di boosting*

```
1: procedure Boosting_learner(Xs, Y, Es, L, K)
2: Input
```

```
    Xs: insieme di feature di input
    Y: feature obiettivo
    Es: insieme di esempi di training
    L: learner di base
    K: numero di componenti dell'ensemble
Output
    funzione per fare predizioni sugli esempi
media ← ∑_{e∈Es} Y(e)/|Es|
define p_0(e) = media
for each i = 1 to K do
    E_i ← {⟨Xs(e), Y(e) − p_{i−1}(e)⟩ | e ∈ Es}
    d_i ← L(E_i)
    define p_{i(e)} = p_{i−1}(e) + d_{i(e)}
return p_K
```

- p_i è la funzione di predizione sugli esempi;
- E_i è in nuovo insieme di esempi, generabile anche *on demand*: per ogni $e \in Es$, l'ultima predizione, $p_{i-1}(e)$, viene sottratta da $Y(e)$;
- d_i si calcola applicando il modello base a E_i.

Esempio 89. La seguente figura mostra il plot dell'errore quadratico sul validation set per K crescente. Tali grafici utili alla scelta dell'iperparametro γ fissato `minimum_child_size`.

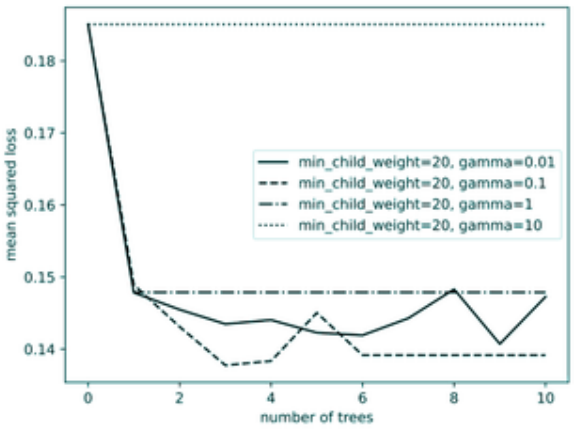


Figura 23: Plot errore

- per $\gamma = 10$ si hanno alberi degeneri, predizione della media;
- per $\gamma = 1$ gli alberi successivi al primo non estraggono info utile; errori simili a quello di un albero singolo;

- per $\gamma = 0.1, 0.01$, il boosting migliora le predizioni.

Cenni sullo stacking

Lo **stacking**, o *stacked generalization*, è un modello ensemble costituito da modelli base di tipi diversi, come ad esempio alberi, modelli lineari, SVM, ecc. e un *meta-learner* che apprende come aggregare al meglio le decisioni. Uno schema generale è rappresntato nella seguente figura:

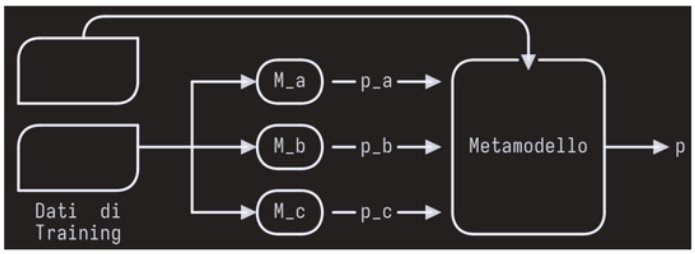


Figura 24: Schema dello stacking

Reti Neurali e Apprendimento Profondo

Adottare una rappresentazione degli esempi in termini di input grezzo spesso non risulta fruttuoso: servono feature più utili. A talescopo si può ricorrere a una *progettazione* delel feature utili, generate a partire dall'input, mediante la **feature engineering**. I metodi per tali scppi apprendono feature utili per il probleam da risolvere anche se spesso queste si rilevano poco interpretabili. Un altro vantaggio dall'apprendiento di feature è che possono anche essere reimpiegate nella soluzione di problemi affini.

Imparare le feature è l'obiettovo del cosidetto **feature representation learning** svolto utilizzando **reti neurali artificiali** (ANN) le quali sono ispirate alla struttura dei neuroni del cervello umano. Le **unità artificiali** risultano diverse dai corrispettivi biologici in quanto molto più semplici e meno numerose di quelle nel cervello umano.

Un esempio di neurone artificiale è rappresentato nella seguente figura.

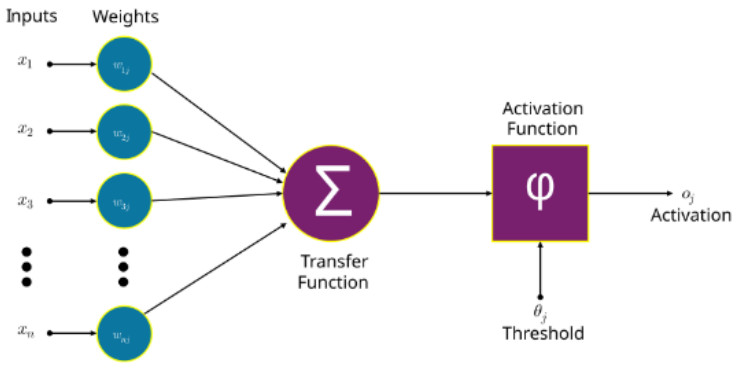


Figura 25: Neurone artificiale

Tali modelli sono impiegati per risolvere problemi che comportano un ragionamento di basso livello, con molti dati disponibili, come ad esempio l'interpretazione delle immagini, il riconoscimento del parlato e la traduzione automatica, risultando molto flessibili e capaci di inventare nuove feature.
Alcuni motivi d'interesse per le reti neurali artificiali sono i seguenti:

- nell *neuroscienze*, comprendere i sistemi naturali, ad esempio per la simulazione di sistemi propri di animali semplici;
- la comprensione dei *meccanismo* funzionali e astratti *dell'intelligenza*: ipotizzando di poter replicare i meccanismi del cervello per realizzarne le funzionalità, testandoli confrontando forme d'intelligenza con e senza tali meccanismi; l'ipotesi alternativa parte da osservazione come quella degli aerei che, pur sfruttando gli stessi principi del volo degli uccelli, non si basano sugli stessi meccanismi;
- progettare nuovi *modelli comutazionali*: mentre i modelli convenzionali sono costituiti da pochi porcessori e molta memoria, nel cervello si attvano moltissimi processi asincroni distribuiti, senza un master; difatti le ANN vengono spesso implementate su architetture massivamente parallele; si consideri anche il nuovo paradigma di programmazione detto *differentiable programming*;
- putnare a modelli di diversa complessità, ossai diversi *learning bias*, rispetto ad altri: le ANN possono rappresentare qualsiasi funzione su feature discrete, come gli alberi di decisione, ma anche molte altre funzioni non sempre realizzabili attraverso alberi.

8.1. Reti Neurali Artificiali Feed Forward

Essenzialmente, una *rete neurale* ***feed-forward*** implementa una funzione di predizione come segue: dato l'input (vettoriale) x:

$$f(x) = f_{n(f_{n-1}(\cdots f_2(f_1(x))))}$$

Si consideri la struttura della rete nella seguente figura:

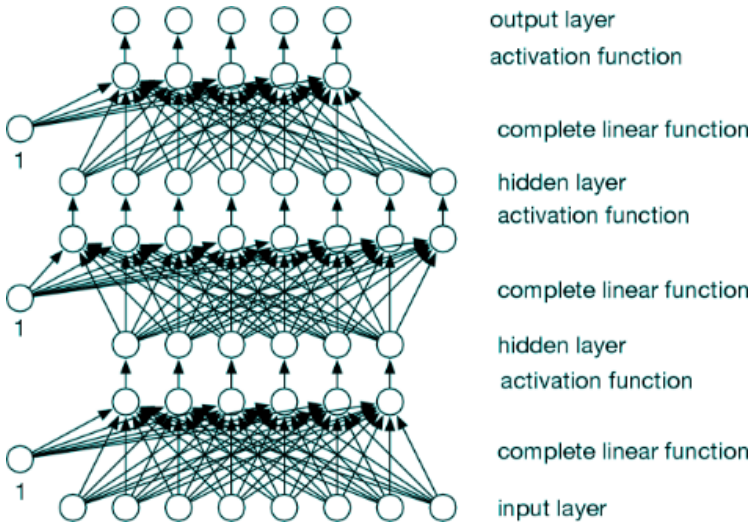


Figura 26: Rete neurale feed-forward

- ogni **layer** / *strato* è costituito da una funzione f_i che mappa un vettore di input su un vettore di output;
- ciacsuna componente del vettore di output di un layer costituisce un'*unità*;
- la *profondità* delle rete è n, con l'ultimo strato, f_n, detto di *output* della rete mentre gli altri layer sono detti *nascosti / hidden*, trenne quello di *input*, con x.

In genere le ANN hanno più feature di input ma anche più feature/target, tipicamente a valori reali; feature discrete possono essere trasformate in variabili-indicatrici o feature ordinali.
Ogni layer di unità opera in funzione dei precedenti: il layer di input ha un'unità per feature di input e viene avvalorato da ciascun esempio; un layer nascosto prevede la composizione di una funzione *lineare* f_i con una funzione φ di attivazione non-lineare, da cui si calcola l'output dello strato *out[j]* in funzione dei valori in input *in[k]* verso lo strato

$$out[j] = \varphi\left(\sum_k in[k] \cdot w[k,j]\right)$$

si noti l'input aggiuntivo costante $i[0] = 1$ per il *bias*; occorrerà apprendere ciascun peso $w[k,j]$, uno per ogni coppia input-output del layer.
Si noti che layer lineari *consecutivi* sarebbero inutili perchè trasformabilli in un unico layer lineare.
Le funzioni di attivazione φ, tipicamente, sono differenziabili. Ad esempio, si può usare un *rettificatore* o **Rectified Linear Unit** (ReLU) definito

$$\varphi(x) = \max(0, x)$$

assumendo che la derivata sia nulla in $x = 0$.
La scelta di φ per il layer di output può variare in base al tipo di y e alla loss da ottimizzare:

- per y reale e loss quadratica medai si può usare la *funzione identità* $\varphi(x) = x$;
- per y booleana e log loss binaria, tipicamente si usa la funzione *sigmoide* $\varphi(x) = 1/(1 + e^{-x})$, giustificabile anche in termini probabilistici;
- per y categorica e log loss categorica si usa invece una *softmax*, considerando un *output layer* con un'unità per ciascun valore di y.

Queste scelte comportano derivate semplici dall'errore, proporzionali a $\hat{Y}(e) - Y(e)$.

Esempio 90. Si consideri la rete neurale per la funzione `if-then-else` nella seguente figura:

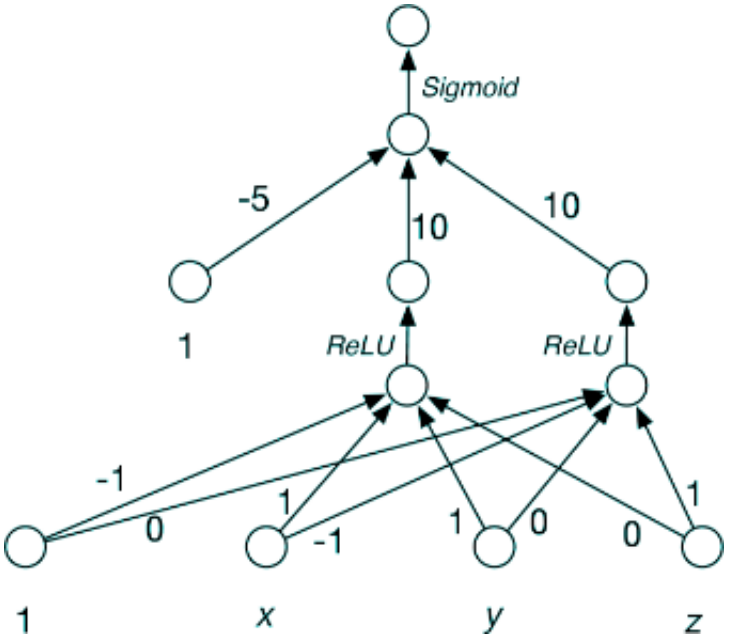


Figura 27: Rete neurale per l'apprendimento della funzione `if-then-else`

- x, y, z costituiscono l'input;
- la funzione è equivalente a $(x \wedge y) \vee (\neg x \wedge z)$, rappresentabile in termini di ReLU o sigmoidi;
- daot un primo layer con due output: $h_1 = relu(x + y - 1)$ e $h_2 = relu(-x + z)$ si avrà che $h_1 = 1$ se $(x \wedge y)$ vera e $h_2 = 1$ se $(\neg x \wedge z)$ vera, altrimenti sono entrambe nulle;
- per l'output, $\text{sigmoid}(-5 + 10 \cdot h_1 + 10 \cdot h_2)$ approssima $h_1 \vee h_2$ con un errore vicino al 0.7%

L'*ampiezza* di un layer è pari alle dimensioni del vettore di output. L'ampiezza della rete è paria ll'ampiezza massima fra i suoi layer. La sua *profondità* è pari al numero

di layer. Le dimensioni dell'input dipendono dal problema.
Si può dimostrare che una rete con un solo layer nascosto, purchè sufficientemente ampio, può approssimare qualsiasi funzione continua su un intervallo di numeri reali o discreta con input / output discreti. I layer a lvielli bassi costruiscono feature utili a quelle dei livelli più alti, che li rende più semplici.

8.1.1. Apprendimento dei parametri

L'algoritmo **back-propagation, BP,** implementa la DG Stocastica per determinare i pesi del modelli; per ogni esempio e del batch, si aggiorna ogni peso w in ragione di $-\frac{\partial}{\partial w}\text{errore}(e)$ usando le proprietà delle derivate, ossia le regole di decomposizione lineare e di concatenazione.
La predizione per e, con feature di input x_e, sarà

$$f(e) = f_n(f_{n-1}(\cdots f_2(f_1(x_e))))$$

con le f_i parametrizzate dai pesi sulle connessioni in input. Supponendo che $v_i = f_i(f_{i-1}(\cdots f_2(f_1(x_e))))$, ossia $v_i = f_i(v_{i-1})$. posto $v_0 = x_e$, i valori v_i per $1 \leq i \leq n$ possono essere calcolati in una passata attraverso le funzioni annidate.
Definire le derivate per gli aggiornamenti è più difficile perchè è più difficile calcolare la variazione dell'errore determinata da pesi di strati inferiori rispetto a quello di output.
Sia w uno dei pesi nella definizione di una certa f_j. La derivata dell'errore risspetto al peso è data da:

$$\begin{aligned}
\frac{\partial}{\partial w}\text{errore}(f(e)) &= \text{errore}'(v_n) \cdot \frac{\partial}{\partial w} f_n(v_{n-1}) \\
&= \text{errore}'(v_n) \cdot \frac{\partial}{\partial w} f_n(f_{n-1}(v_{n-2})) \\
&= \text{errore}'(v_n) \cdot f_n'(v_{n-1}) \cdot \frac{\partial}{\partial w}(f_{n-1}(v_{n-2})) \\
&= \text{errore}'(v_n) \cdot f_n'(v_{n-1}) \cdot f_{n-1}'(v_{n-2}) \cdot \frac{\partial}{\partial w}(f_{n-2}(v_{n-3})) \\
&= \text{errore}'(v_n) \cdot f_{n(v_{n-1})}' \cdot f_{n-1}'(v_{n-2}) \cdots \frac{\partial}{\partial w}\big(f_j\big(v_{j-1}\big)\big)
\end{aligned}$$

con f_i' derivata di f_i rispetto ai suoi input. L'espansione prosegue fino a f_j. L'ultima derivata parziale non è istanza della regola di concatenazione non essendo v_{j-1} funzione di w, quindi si usa la regola della decomposizione lineare e w viene moltiplicato per la componente di v_{j-1} appropriata.
BP determina l'aggiornamento per ogni peso in due passate per ogni esempio:

- *Predizione*: per ogni layer, dati i valori degli input, si calcola il valore degli output, v_i;

- *Retro-propagazione*: andando a ritroso attraverso i layer, si determina l'aggiornamento di ciascun peso; si calcolano $\text{errore}'(v_n) \cdot \prod_{i=0}^{k} f'_{n-1}(v_{n-i-1})$ per essere passati ai layer inferiori; tale input costituisce il *termine d'errore* per un layer, combinato con i valori calcolati al passo di predizione per aggironare tutti i pesi del layer e calcolare il termine d'errore per il layer inferiore.

BP combina la GD stocastica con la *programmazione dinamica* memorizzando i risultati intermedi.

Modularizzazione

Un layer viene costruito come modulo indipendente che implementa le due passate, predizione e retro-propagazione, con l'aggiornamento dei pesi dopo ogni batch di esempi.

La classe `Dense`, definita di seguito, implementa una funzione lineare *densa* in cui ogni unità di output è connessa a tutte quelle di input. Dato l'array w dei pesi, $w[i, j]$ è il peso per la connessione dell'unità di input i all'output j e $w[n_i, j]$ costituisce il bias per l'output j. I metodi `output` e `Backprop` vengono chiamati su ogni esempio.

- `output(in)` restituisce i valori di output per i valori di input del vettore *in*;
- `Backprop(errore)` restituisce il vettore degli errori in input e aggiorna i gradienti;
- `update()` aggiorna i pesi per un batch di esempi

Ogni classe memorizza *in* e *out* se utili a `Backprop`.

ALGORITMO 27 — *Classe Dense*

```
1:  class Dense(n_i, n_o) {n_i: n. di input, n_o: n. di output}
2:  for each 0 ≤ i ≤ n_i e 0 ≤ j < n_o do
3:      d[i, j] ← 0
4:      w[i, j] ← valore casuale
5:  method output(in) {in array di lunghezza n_i}
6:      for each j do out[j] ← w[n_i, j] + Σ_i in[i] · w[i, j]
7:      return out
8:  method Backprop(errore) {errore array di lunghezza n_o}
9:      for each i, j do d[i, j] ← d[i, j] + in[i] · errore[j]
10:     for each i do i_errore[i] ← Σ_j w[i, j] · errore[j]
11:     return i_errore
12: method update() {aggiorna tutti i pesi: implementa la SGD}
13:     for each i, j do
14:         w[i, j] ← w[i, j] − η/b · d[i, j] {η learning rate}
15:         d[i, j] ← 0
```

L'algoritmo mostra la procedura per l'apprendimento di una rete neurale, in cui:

- *funzioni* è una sequenza di funzioni parametriche che definisce la rete, tipicamente, per ciascun layer, una lineare e una di attivazione, implementata da una classe che implementi le due passate e memorizzi l'informazione necessaria;
- la prima funzione del layer più basso ha input corrispondenti alle feature di input; per le successive, il numero di input è pari al numero di output della funzione precedente, mentre il numero di output della funzione finale è pari al numero di feature target, o al numero di valori per una feature di output categorica non binaria;
- si assume che il tipo di output della funzione di attivazione sia utile alla funzione di errore, in modo che la derivata sia proporzionale a valore predetto meno valore effettivo, questo vale per l'identità, la sigmoide e la soft-max; φ_0 è la funzione di attivazione finale usata in `Neural_network_learner`, ma non viene implementata come classe; altre combinazioin con funzinoi d'errore / loss potrebbero avere forme diverse che vengono automatizzate nelle librerie (*derivazione simbolica*).

Algoritmo 28 — *Algoritmo di apprendimento della rete neurale*

```
1:  procedure Neural_network_learner(Xs, Ys, Es, funzioni, η, b)
2:  Input
3:      Xs: feature di input, Xs = (X_1, ..., X_n)
4:      Ys: feature target
5:      Es: insieme di esempi di training
6:      «funzioni»: sequenza di funzioni che definiscono la rete
7:      b: n. di esempi in ogni batch
8:      η: learning rate (passo della GD)
9:  repeat
10:     batch ← campione casuale di b «esempi»
11:     for each esempio e ∈ batch do
12:         for each unità di input i do valori[i] ← X_{i(e)}
13:         for each fun in «funzioni» in ordine ascendente do
14:             valori ← fun.output(valori)
15:             for each unità di output j do errore[j] ← φ_{o(valori[j])} − Ys[j]
16:         for each fun in «funzioni» in ordine discendente do
17:             errore ← fun.Backprop(errore)
18:     for each fun in «funzioni» che contiene pesi do
19:         fun.update()
20: until terminazione
```

Algoritmo 29 — *Classi per unità ReLU e sigmoid*

```
1:  class ReLU()
2:  method output(in)
3:      for each i : 0 ≤ i < n_i do out[i] ← max(0, in[i])
4:      return out
5:  method Backprop(errore)
6:      for each i : 0 ≤ i < n_i do
7:          i_errore[i] ← errore[i] if (in[i] > 0) else 0
8:      return i_errore
9:
10: class sigmoid()
11: method output(in)
12:     for each i : 0 ≤ i < n_i do out[i] := 1 / (1+ exp(−in[i]))
13:     return out
14: method Backprop(errore)
15:     for each i : 0 ≤ i < n_i do i_errore[i] := out[i] · (1 − out[i]) · errore[i]
16:     return i_errore
```

Esempio 91. La rete vista in precedenza per l'`if-then-else` con i dati visti nell'esempio precedente.

- si invoca `Neural_network_learner` assegnando a *funzioni* la lista `[Dense(3, 2), ReLU(), Dense(2, 1)]`
- un run con 1000 epoche, learning rate = 0.01 e batch di 8 esempi produce i seguenti pesi:
  - $h_1 = relu(2.47 \cdot x + 0.0000236 \cdot y - 2.74 \cdot z + 2.74)$
  - $h_2 = relu(3.62 \cdot +4.01 \cdot y + 0.228 \cdot -3.84)$
  - $output = sigmoid(-4.42 \cdot h_1 + 6.64 \cdot h_2 + 4.95)$
- la funzione risultante approssima con un errore nel caso pessimo dell'1%; predizione con la massima log loss 0.99 per l'esempio $\neg x \wedge \neg y \wedge z$, per il quale doveva essere 1;
- al variare dei run si ottengono diversi pesi;
- in tale caso semplice si ottiene un output intermedio interpretabile:
  - h_1 positiva a meno che $x = 0, z = 1$
  - h_2 grande solo quando $x = 1, y = 1$.

L'apprendimento *sub-simbolico* è in apparente contrasto con l'ipotesi di sistema di simboli fisico intrinseco: la rete codifica un significato che si può solo intravedere attraverso i valori delle unità nascoste alle quali, però, non è associato un significato

preciso. Solo in dati casi si può interpretare cosa rappresentino ed esprimerlo in forma concisa. Questo è uno degli scopi della cosidetta ***eXplainable AI*, XAI**.

8.2. Estensione

8.2.1. Migliorare l'Ottimizzazione

Le seguenti tecniche sono state studiate per rendere più efficace l'ottimizzazione dei parametri, specie nei casi in cui siano molti. In particolare va settato opportunamento il passo di apprendimento per permettere alla GD stocastica di risolveer problemi di minimizzazione in cui lo spazio si configura con cosidetti **canyon** con una funzione d'errre a U in una data dimensione mentre nelle altre presenta una pendenza, oppure con **punti di sella** dove un minimo in una dimensione si incontra con un massimo in un'altra.
Per ovviare a tali problemi si deve adattare il passo nel corso del processo di ottimizzazione. I modi principali sono due e prevedono passi diversi per diverse dimensioni:

- se il segno del gradiente non cambia, si può estendere il passo, se, invece, continua a cambiare allora lo si deve ridurre;
- ogni aggiornamento dovrebbe seguire la direzione del gradiente e la grandezza dovrebbe dipendere dal fatto che il gradiente sia maggiore o minore del suo valore storico.

I due modi possono essere combinati.
Il **momentum** per ciascun parametro costituisce la velocità dell'aggiornamento del parametro, mentre l'aggiormento della GD stocastica si comporta come l'accelerazione. Il momentum determina la dimensione del passo: va incrementato se l'accelerazione ha lo stesso segno, e decrementato altrimenti. Può servire a risolvere problemi come quelli del canyon o del rumore comportato dal fatto che un batch non contenga molti esempi.
Il metodo di ottimizzazione **RMS-Prop** (*root mean squared proagation*) si basa sull'idea che la grandezza del cambiamento per ogni peso dipende dal confronto fra il quadrato del gradiente e il suo valore storico. Per ogni peso si aggiorna una media mobile del quadrato del gradiente. Ciò serve a determinare di quanto il peso debba cambiare. Server anche una correzione utile a non incappare nelle problematiche relative alla divisione per numeri molto piccoli.
Adam (*adaptive moments*) è un ottimizzatore che usa sia il momentum sia il gradiente quadratico e correzioni necessarie per l'inizializzazione comune a 0 dei parametri, stima non buona per calcolare medie.
Inizializzazione: ai fini della convergenza conviene normalizzare i parametri in input e usare circospezione nell'inizializzare i pesi. Le feature di input potrebbero avere diverse unità di misura e utilità per cui andrebbero standardizzate. Per

feature di input categoriche tipicamente rappresentate attraverso *variabili indicatrici* binarie per i diversi valori del dominio (*one-hot encoding*). I pesi delle unità latenti non possono essere inizializzate tutti con lo stesso valore per evitare che tutte le funzioni dello stesso layer convergano verso una stessa funzione (*lockstep*). Pertanto sarà meglio partire da valori casuali. Per le unità di output, il bias andrebbe inzializzato con il miglior valore da predire quando gli input sono tutti a zero. Ad esempio la media sul datset per problemi di regressione o la sigmoide inversa della probabilità empirica nei problemi categorici binari. Gli altri pesi possono partire dal valore nullo. Ciò consente di apprendere dagli input e non da medie pregresse.

8.2.2. Migiorare la Generalizzazione

Occorre anche assicurare in partenza che il modello possa adattarsi al training set, evitando il sovradattamento.
Per assicurarsi che si stia apprendendo qualcosa l'errore sul training set dovrebbe almeno essere inferiore a quello dei modelli-base più semplici. Altrimenti bisogna cambiare la configurazione del modello.
Se risulta migliore dei modelli base ma non abbastanza occorre cambiare modello. Se già non va benissimo sul training set non potrà migliorare sul test set o su nuovi esempi. Una performance non ottimale è un indice di sotto-adattamento: il modello scelto è troppo semplice. Il problema, in ultima analisi, potrebbe dipendere da feature non abbastanza informative per cui le stime di base potrebbero rappresentare il meglio di quello che si può fare.
Se l'algoritmo funziona sul training set ma non su un validation set allora non riesce a generalizzare e va in sovradattamento, pertanto il modelo andrebbe semplificato. Se i dati sono pochi i modelli da usare dovrebbero essere semplici.
Sarebbe utile operare il tuning degli iperparametri via *cross validation*, Tale processo può essere automatizzato prendendo il nome di **autoML**. Gli iperparametri da considerare comprendono:

- l'algoritmo,
- il numero di layer, l'ampiezza di ciascun layer,
- il numero di epoche (per consentire l'early stopping),
- il learning rate,
- le dimensioni del batch di esempi,
- i parametri di regolarizzazione.

Nel caso delle reti profonde si può prendere in considerazione il meccanismo di **dropout** che porta a ignorare casualmente alcune unità in fase di training, ossia settare temporaneamente l'output a 0. Tale meccanismo viene controllato dal parametro `rate`, ossia la proporzione di valori annullati.
Altri metodi:

- raccogliere più dati può essere il modello più economico;

- *data augmentation*: nuovi esempi, trasformando quelli disponibili anche con l'aggiunta di rumore o cambiando i contesti;
- usando la *feature engineering*;
- riusare esempi disponibili per problemi correlati, condividendo rappresentazioni delle feature a basso livello. Ad esempio nel *multi-task learning* si condividono i layer inferiori appresi per un problema nella soluzione di altri.

8.2.3. Reti convolutive

Una **rete convolutiva** (*convulation neural network, CNN*) è specializzata nel riconoscere immagini o nella visione sfruttando il principio di *località* e la *condivisione* dei parametri. Un esempio è mostrato nell'immagine seguente:

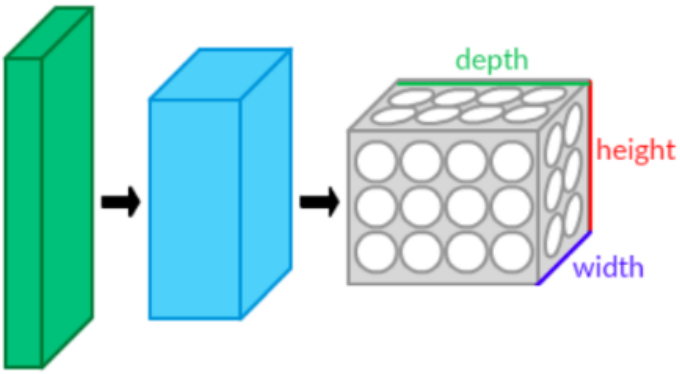


Figura 28: Layer convolutivi

Una CNN utilizza un **kernel**, o *convulation mask*, come operatore lineare parametrico, da applicarsi a regioni locali. Tipicamente si usano kernel monodimensionali (per sequenze di parole) o bidimensionali (per immagini e video). I parametri del kernel vanno appresi dai dati. Feature locali determinano i loro valori in funzione di punti vicini. Lo stesso kernel viene applicato in parti diverse dell'istanza in input. Si possono applicare più kernel in maniera concorrente. In tal caso si avranno più output, ad esempio più array, detti *canali*. Questa suddivisione può essere prevista già in input.
In un **pooling layer**, si applica una funzione prefissata degli output delle unità in un kernel lineare. Un tipico pooling layer è il *max-pooling*, che è come la circonvuluzione, ma applica il massimo invece di una funzione lineare. Una tipica architettura di CNN usa un layer convolutivo, seguito da una funzione non lineare, come la ReLU, seguita da un pooling layer, il cui output va in input a layer convolutivo e così via.

8.2.4. Modelli per Sequenze

A volte i dati si presentano come sequenze di lunghezza diversa, non prefissata. Si pensi alle frasi nel linguaggio naturale.
Una **rete ricorrente** (*recurrent neural network*, RNN) vanno oltre il meccanismo

di *feed-forward*, ammettendo connessioni con un'unità in layer non superiore per formare cicli.
Ciò permette l'utilizzo di uno dei layer come *memoria di stato*, e consente, fornendo in input una *sequenza temporale* di valori, di modellarne un comportamento dinamico dipendente dalla informazioni ricevute in istanti di tempo precedenti.
Tale tipo di reti è molto utilizzato per predizioni su *serie temporali* in cui vada previsto il prossimo output.
Le reti **Long Short-Term Memory, LSTM,** costituiscono un tipo speciale di RNN progettate in modo che sia mantenuta la memoria a meno di sostituzioni con nuova informazione. Ciò consente una migliori cattura delle dipendenze di lungo termine rispetto alle RNN tradizionali. Intuitivamente, invece di apprendere la funzione da $h^{(t-1)}$ a $h^{(t)}$, si apprende il cambiamento $\delta h^{(t)}$.
Un modo per aumentare l'efficacia dei modelli sequenziali è quello di mettere in grado il modello di soffermarsi su particolari parti delle sequenze. Il meccanismo di **attention** prevede l'uso di una distribuzione di probabilità sulle diverse parti dell'input per assegnare loro un diverso perso all'interno di una stessa finestra, consentendo così di sfruttare informazioni di contesto.
Questo calcolo di pesi può avvenire in maniera simultanea attraverso modelli **transformer**, basati su più meccanismi di attenzione (*multi-heads*), vanno a inframmezzarsi con layer densi e le funzioni di attivazione. Essi trasformano sequenza in sequenze operando una **codifica posizionale**, risultando più facili da apprendere rispetto a RNN e LSTM.

8.2.5. Altri Modelli Neurali Generativi

Un **autoencoder** è una rete con uno strato/modello *encoder* con input e output uguali ricostruiti da uno strato/modello **decoder** ed è atta a costruire una *rappresentazione* interna vettoraile che può essere riusata come modello generativo.
Uno schema di autoencoder è mostrato nella seguente figura:

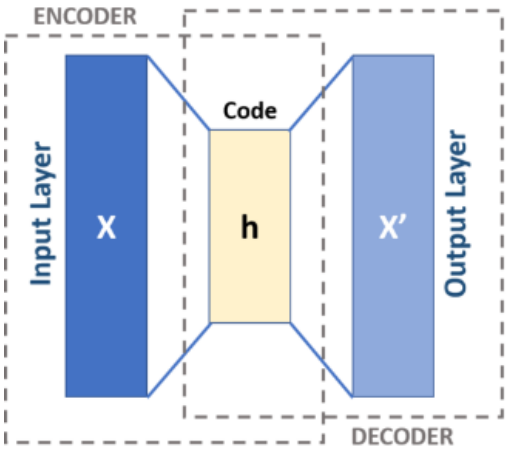


Figura 29: Schema di autoencoder

Con tali modelli si mira a trasformare i datiin ingresso in forma vettoriale con un meccanismo di codifica dell'input in una rappresentazione intermedia in uno strato latente che garantisca la loro ricostruzione nello strato di output. Un tipico utilizzo può essere quello di generare immagini artificiali a partire da testo. In generale, tale meccanismo è molto utilizzato in NLP, ad esempio nei modelli **Word2vec** e derivati, come quelli relativi al *Knowledge Gragh embedding* rappresentati da triple. Una *adversarial network* come la **generative adversarial network, GAN**, impara a generare esempi con una distribuzione simile a quella degli esempi di training. Essa viene allenata sia a predire parte dell'output, sia a non essere in grado di predire altro output. È formata da un *generatore* di esempi con l'obiettivo di ingannare il *discriminatore* che invece deve determinare se siani veri o falsi.
Un possibile utilizzo delle GAN può essere quello di escludere dal modello alcune feature sensibiili (*debiasing GAN*), ad esempio per evitare predizioni che riguardino persone, ad esempio per sezioni di lavoro, vengano influenzate dal genere o dal colore della carnagione.
Un **modello di diffusione** rappresenta un metodo efficace di IA generativa (*image generation*): esso costruice una sequenza di esmepi più rumorose, a partire dai dati disponibili, aggiungendo ripetutamente rumore fino ad avere solo rumore, imparando poi a invertire questo processo. DALL-E è una tipica applicazione di questo modello combinato con alcuni dei precedenti.
Un esempio di GAN è mostrato nella seguente figura:

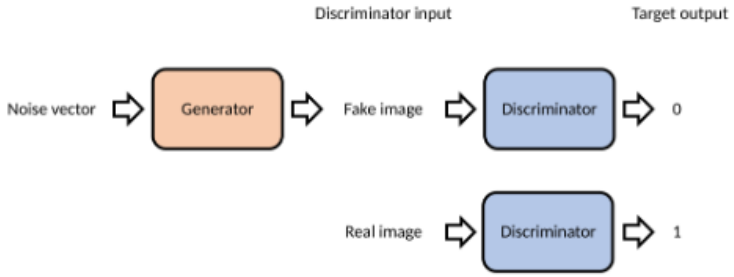


Figura 30: GAN

Ragionamento su Modelli di Conoscenza Incerta

9.1. Probabilità

Nel mendo reale spesso si devono prendere decisioni in base a informazioni *incomplete*. In tal casi è difficile capire l'esatto stato del mondo. Per prendere decisioni un KBS deve cercare di sfruttare tutta la conoscenza disponibile. Essendo tale conoscenza limitata, il sistema dovrà essere in grado di ragionare sotto **incertezza**, facendo ipotesi e valutandone l'attendibilità.
Se non si può assumere una conoscenza completa del mondo, per prendere decisioni spesso si formulano diverse ipotesi.
L'**incertezza** può essere caratterizzata come **ontologica** o **epistemologica**. Nel primo caso essa riguarda il mondo in sé (si tratta di una forma di *imprecisione* nella rappresentazione), ad esempio *persona molto alta* rappresenta una conoscenza vaga sul valore esatto dell'altezza. Nel secondo caso l'incertezza concerne le credenze sullo stato del mondo: essendo spesso le situazioni non completamente conosciute, si devono fare valutazioni soggettive.
Sorge il problema di come aggiornare tale credito con la disponibilità di nuove informazioni. Si devono considerare in due momenti successivi: valutazioni **a priori**, ossia prima di osservare qualsiasi osservazione, e **a posteriori**, ossia dopo l'acquisizione di nuove informazioni, il che porta all'aggiormaneto delle credenze sullo stato del mondo.
Il ragionamento in presenza di incertezza è un problema studiato in *Teoria della probabilità* e in *Teoria delle decisioni*. Si basa sulla valutazione dell'azzardo, ovvero dell'incertezza sulle conseguenze di decisioni da prendere.
La misura delle credibilità rientra nella prospettiva che si chiama **bayesiana** o **soggettiva**: lo studio di come la conoscenza impatti sulle credenze del soggetto. Soggetti diversi potranno assumere diverse probabilità. Tale prospettiva è diversa da quella **oggettiva** detta anche **frequentistica**.
La *credibilità* di una proposizione α viene misurata con un valore in $[0, 1]$: si ha probabilità nulla se si crede che α sia del tutto falsa e che nessuna nuova evidenza possa cambiarla; si avrà probabilità pari a 1 se si ritiene α assolutamente vera; altrimenti la probabilità sarà un valore in $]0, 1[$ che misura l'incertezza sulla credibilità della sua verità; ciò non significa che α sia solo parzialmente vera, bensì che il suo valore di verità non sia determinabile con certezza.

9.2. Semantica della Probabilità

Definiamo alcune nozioni base:

- **variabile**: *aleatoria / casuale*, denotata con inziale maiuscola e dotata di *dominio* di valori; per il momento si considerano variabili booleane; variabili discrete con dominio finito o almeno enumerabile;
- **mondo**: funzione che associa ad ogni variabile un valore, viceversa una variabile può essere vista come una funzione dai mondi al suo dominio;
- **proposizione primitiva**: assegnazione di un valore a una variabile o diseguaglianza tra variabili e valori/variabili, come ad esempio: $A = \text{true}, X < 7, ...$;
- **proposizione**: si costruisce applicando i connettivi logici a proposizioni più semplici, a partire dalle primitive.

Dato l'insieme di *mondi possibili* Ω, *finito*, una **misura di probabilità** $\mu : \Omega \to \mathbb{R}_+$ verifica le seguenti proprietà:

- $\mu(\omega_1 \cup \omega_2) = \mu(\omega_1) + \mu(\omega_2)$ se ω_1 e ω_2 disgiunti;
- $\mu(\Omega) = 1$, valore convenzionale.

La **probabilità** di una proposizione α sarà definita come

$$P(\alpha) = \mu(\{\omega \in \Omega : \alpha \text{ vera in } \omega\})$$

una misura coerente con la probabilità dei mondi.
Data una variabile discreta X, la **distribuzione di probabilità** di X è la funzione $P(X) : \text{dom}(X) \to \mathbb{R}$, definita ponendo $P(x)$ come probabilità della proposizione $X = x$, con $x \in \text{dom}(X)$.
Questa definizione può essere estesa al caso di un insieme di variabili $\{X_1, ..., X_n\}$: la distribuzione $P(X_1, ..., X_n)$ va dai valori assegnati alle variabili alla probabilità; ad esempio, per $P(X, Y)$, distribuzione su X e Y: dati $x \in \text{dom}(X)$ e $y \in \text{dom}(Y)$

$$P(X = x, Y = y) = P(X = x \wedge Y = y)$$

La **distribuzione di probabilità congiunta** per l'insieme di variabili $\{X_1, ..., X_n\}$ è la distribuzione su tutti i mondi possibili.
Nel caso di variabili continue si devono considerare infiniti mondi, per la precisione un insieme non enumerabile di insiemi di mondi: in caso di variabili con dominio infinito o numero infinito di variabili. Esso non può essere descritto con un linguaggio finito.
In realtà non serve una misura definita su tutti gli insiemi di mondi ma solo quelli rappresentabili con formule logiche. Questo costituisce la base per la definizione di una cosiddetta σ-algebra.
Per una variabile X continua si definisce una funzione di **densità di probabilità** $p : \mathbb{R} \to \mathbb{R}_+$, con integrale unitario. La misura della probabilità su intervalli sarà:

$$P(a \leq X \leq b) = \int_a^b p(X)dX$$

Anche se $\forall v : P(X = v) = 0$ è possibile avere $P(v_0 \leq X \leq v_1) > 0$, essendo $v_0 \leq v_1$.
Una distribuzione di densità si dice:

- *parametrica*: se la formula ha un numero finito di parametri prefissati;
- *non parametrica*: se non si fissa il numero dei parametri, potenzialmente anche infiniti.

Un altro approccio per trattare variabili continue è la *discretizzazione* in un numero finito di mondi.

9.2.1. Probabilità Condizionata

Con la disponibilità di fatti nuovi si può operare un aggiornamento della credibilità di proposizioni.
La **probabilità condizionata** $P(h \mid e)$ di h *data* e è una misura del credito di h (*ipotesi*), assumendo la verità di e (*evidenza*). $P(h \mid e)$ si chiama anche probabilità **a posteriori** di h: e rappresenta la congiunzione di osservazioni dirette del mondo, tutte le osservazioni riguardanti una data situazione, non solo una selezione, per la correttezza della probabilità condizionata. $P(h)$ si dice anche probabilità **a priori** di h e corrisponde a $P(h \mid \text{true})$, ossia precede qualunque osservazione.

Semantica della probabilità condizionata

L'evidenza e elimina i mondi incompatibili. Come nella conseguenza logica, essa seleziona i mondi possibili, quella in cui e vera.
Si definisce una nuova misura μ_e su insiemi di mondi, data l'evidenza e:

$$\mu_{e(S)} = \begin{cases} 0 & e \text{ falsa in } \omega, \forall \omega \in S \\ c \cdot \mu(\omega) & e \text{ vera in } \omega, \forall \omega \in S \end{cases}$$

dove c è una costante di normalizzazione.
Ogni mondo in cui e sia falsa ha probabilità condizionata nulla. Per gli altri mondi, si considerano probabilità normalizzate: perchè risulti una misura di probabilità, dato e:

$$\begin{aligned} 1 = \mu_e(\Omega) &\overset{\text{per casi}}{=} \mu_e(\{\omega \mid e \text{ vera in } \omega\}) + \mu_e(\{\omega \mid e \text{ falsa in } \omega\}) \\ &= c \cdot \mu(\{\omega \mid e \text{ vera in } \omega\}) + 0 = c \cdot P(e) \end{aligned}$$

per cui $c = \frac{1}{P(e)}$, quindi la misura può essere definita solo se $P(e) > 0$; difatti $P(e) = 0$ indica che e è impossibile.
La **probabilità condizionata** della proposizione h data e può essere definita sommando le probabilità condizionate dei mondi in cui h è vera:

$$\begin{aligned} P(h \mid e) &= \mu_e(\{\omega \mid h \text{ vera in } \omega\}) \\ &= \mu_e(\{\omega \mid h \wedge e \text{ vera in } \omega\}) + \mu_e(\{\omega \mid h \wedge \neg e \text{ vera in } \omega\}) \\ &= \frac{1}{P(e)} \cdot \mu(\{\omega \mid h \wedge e \text{ vera in } \omega\}) + 0 = \frac{P(h \wedge e)}{P(e)} \end{aligned}$$

Per estensione si definisce la **distribuzione di probabilità condizionata** $P(X \mid Y)$ in funzione di X e Y variaibli: dati $x \in \text{dom}(X)$ e $y \in \text{dom}(Y)$, si considera la probabilità condizionata delle proposizioni $P(X = x \mid Y = y)$.
Si considererà la *decomposizione* di una congiunta per semplificare i calcoli.

Proposizione 3 *(Regola di concatenazione.)* **.** *Date le proposizioni* $\alpha_1, ..., \alpha_n$*:*

$$\begin{aligned} P(\alpha_1 \wedge \alpha_2 \wedge \cdots \wedge \alpha_n) = P(\alpha_1) &\cdot \\ P(\alpha_2 \mid \alpha_1) &\cdot \\ P(\alpha_3 \mid \alpha_1 \wedge \alpha_2) &\cdot \\ &\vdots \\ P(a_n \mid a_1 \wedge \cdots \wedge a_{n-1}) & \\ = \prod_{i=1}^{n} P(\alpha_i \mid \alpha_1 \wedge \cdots \wedge \alpha_{i-1}) & \end{aligned}$$

La parte destra si annulla se è nullo uno dei prodotti, anche in caso alcuni fossero indefiniti; il caso base è $P(\alpha_1 \mid \text{true}) = P(\alpha_1)$*.*

Teorema di Bayes

Vediamo come aggiornare le probabilità in base a nuova evidenza.

Esempio 92 *(Regola di Bayes)* **.** Se $P(e) \neq 0$, si può scrivere:

$$P(h \mid e) = \frac{P(e \mid h) \cdot P(h)}{P(e)}$$

dove $P(h \mid e)$ è la probabilità **a posteriori**, $P(e \mid h)$ si chiama **verosomiglianza** o *likelihood* e $P(h)$ è la probabilità **a priori** di h.

Estendendo a distribuzioni condizionate da k, evidenza pregressa o conoscenza di fondo implicita, se $P(e \mid k) \neq 0$ si ha:

$$P(h \mid e \wedge k) = \frac{P(e \mid h \wedge k) \cdot P(h \mid k)}{P(e \mid k)}$$

ossia partendo da $P(h \mid k)$, data una nuova evidenza e, si ha la nuova misura $P(h \mid e \wedge k)$.

In genere, una tra $P(e \mid h)$ o $P(h \mid e)$ può essere stimata più facilmente dell'altra, che potrà essere ricavata dal teorema.

Probabilità Condizionata e Implicazione
Ci si può chiedere se valga sempre l'uguaglianza:

$$P(f \leftarrow e) \stackrel{?}{=} P(f \mid e)$$

Ciò non è necessariamente vero. Si osseri che, per l'equivalenza $e \rightarrow f \equiv \neg e \vee f$, si ha che $P(f \leftarrow e) = P(f \vee \neg e)$ misura delle interpretazioni per le qualui f è vera oppure e è falsa. Un caso in cui l'uguaglianza non vale è il seguente:

- $P(\text{oviparo} \mid \text{mammifero})$ risulta bassa, i mammiferi che depongono uova sono rari;
- $P(\text{oviparo} \leftarrow \text{mammifero}) = P(\text{oviparo} \vee \neg \text{ mammifero})$ è alta essendo la proporzione dominata da animali non mammiferi; per lo stesso motivo, anche $P(\neg \text{ oviparo} \leftarrow \text{mammifero})$ risulta alta.

9.2.2. Valori Attesi

Per le predizioni, si possono definire *medie ponderate* su tutti i mondi possibili dei valori di funzioni numeriche.
Data f, funzione sui mondi, il **valore atteso** di f rispetto a P è definito come segue:

$$\mathcal{E}_P(f) = \sum_{w \in \Omega} f(w) \cdot P(w)$$

Se f è definita sulle proposizioni, ossia data α:

$$f(\alpha) = \begin{cases} 1 & \alpha \text{ vera} \\ 0 & \alpha \text{ falsa} \end{cases}$$

allora:

$$\text{cal}_P(f) = P(\alpha)$$

Nel caso di distribuzioni condizionate, si definisce il *valore atteso* **condizionato** di f data l'evidenza e:

$$\mathscr{f} \mid e = \sum_{\omega \in \Omega} f(\omega) \cdot P(\omega \mid e)$$

Data una variabile booleana, il valore atteso coincide con la probabilità della variabile.

9.3. Indipendenza

Per definire distrubuzioni su molte variabili serve molta conoscenza. Gli assiomi della probabilità risultano deboli per certi scopi: pongono pochi vincoli sulle probabilità condizionate da sfruttare, ad esempio con n variabili binarie, ci saranno $2^n - 1$ probabilità da conoscere per avere una completa distribuzione dalla quale derivare quelle condizionate.
Per limitare il quantitativo di informazioni richiesto, si può assumere che una variabile dipenda direttametne solo da alcune altre. Altre assunzioni dovrebbero far sì che si richiedano meno dati per specificare un modello: con strutture più semplici il ragionamento sarà svolto in modo più efficiente.
In generale $P(h \mid e) \in]0, 1[$ non determina vincoli sui valori di $P(h \mid f \wedge e)$, se non in casi limite: $P(h \mid f \wedge e) = 1$ quando f implica h oppure $P(h \mid f \wedge e) = 0$, quando f implica $\neg h$.
Spesso è però disponibile un tipo comune di *conoscenza quantitativa* riassumibile con:

$$P(h \mid e) = P(h \mid f \wedge e)$$

cioè f risulta irrilevante per la probabilità di h data e.
Estendendo l'idea a un dato insieme di variabili Zs: X si dice *condizionatamente* **indipendente** da Y dato Zs se e solo se:

$$P(X \mid Y, Zs) = P(X \mid Zs)$$

cioè $\forall x \in \text{dom}(X), \forall y \in \text{dom}(Y), \forall z \in \text{dom}(Zs)$, se $P(Y = y \wedge Zs = z) > 0$ allora

$$P(X = x \mid Y = y \wedge Zs = z) = P(X = x \mid Zs = z)$$

ossia noto il valore di ogni variabile in Zs, conoscere il valore di Y non influenza la credibilità dell'assegnazione di un valore a X. L'indipendenza condizionata è spesso facile da accertare e torna utile nell'inferenza. È, invece, più raro disporre di una tabella della probabilità dei mondi da cui verificare l'indipendenza per via numerica.

> **Proposizione 4.** *Se le probabilità condizionate sono ben definite, i seguenti enunciati sono equivalenti:*
> 1. *X è condizionatamente indipendente da Y data Z;*
> 2. *Y è condizionatamente indipendente da X data Z;*
> 3. *$\forall x, y, y', z : P(X = x \mid Y = y \wedge Z = z) = P(X = x \mid Y = y' \wedge Z = z)$ ossia, noto il valore di Z, cambiare Y non influenza la credibilità del valore di X;*
> 4. *$P(X, Y \mid Z) = P(X \mid Z)P(Y \mid Z)$*

X e Y sono *incondizionatamente* **indipendenti** se

$$P(X,Y) = P(X)P(Y)$$

ossia condizionatamente indipendenti ma senza osservazioni date: ciò non implica che siano pure condizionamente indipendenti, data qualche altra evidenza Z. Raramente tale proprietà può essere determinata per via numerica da dati disponibili.

9.4. Belief Network

Poter fare assunzioni di indipendenza condizionata consente una rappresentazione concisa dei domini. Data una variabile X, solo alcune variabili influenzano direttamente il suo valore. L'insieme di variabili che la influenzano localmente si chiama *Markov blanket* e tale località può essere sfruttata, difatti, date queste variabili, X sarà condizionatamente indipendente dalle altre. Le assunzioni di *indipendenza* condizionata inducono un ordinamento delle variabili che può essere rappresentato attraverso un grafo orientato.
Una *rete bayesiana* è un modello in forma di grafo che evidenzia la dipendenza condizionata fra le variabili. Definito un *ordinamento totale* sull'insieme delle sue variabili $\{X_1, ..., X_n\}$, la *distribuzione* di probabilità congiunta può essere decomposta in termini di probabilità condizionate, tramite la *regola di concatenazione*:

$$P(X_1 = v_1 \wedge X_2 = v_2 \wedge \cdots \wedge X_n = v_n) = \prod_{i=1}^{n} P(X_i = v_i \mid X_1 = v_1 \wedge \cdots \wedge X_{i-1} = v_{i-1})$$

ossia:

$$P(X_1, X_2, ..., X_n) = \prod_{i=1}^{n} P(X_i \mid X_1, ..., X_{i-1})$$

I **genitori** di ciascuna variabile X_i saranno costituiti dal sottoinsieme minimale di *predecessori* di X_i nell'ordinamento totale, $\text{gen}(X_i) \subseteq \{X_1, ..., X_{i-1}\}$, tale che gli altri predecessori di X_i siano condizionatamente indipendenti da X_i dato $\text{gen}(X_i)$. Così X_i dipende dai genitori, ma è indipendente dagli altri predecessori:

$$P(X_i \mid X_1, ..., X_{i-1}) = P(X_i \mid \text{gen}(X_i))$$

Se più insiemi minimali soddisfano tale condizione, allora si può operare una scelta casuale. Alcuni dei predecessori possono dipendere deterministicamente da altri. Riscrivendo la regola di concatenazione, la **fattorizzazione** della *congiunta* sarà:

$$P(X_1, ..., X_2, ..., X_n) = \prod_{i=1}^{n} P(X_i \mid \text{gen}(X_i))$$

Formalmente, una **belief network** o **rete bayesiana (BN)** è rappresentata da un *grafo aciclico orientato (DAG)* con una variabile, X per ciascun nodo, archi verso X da ciascuno dei nodi relativi ai suoi genitori $\text{gen}(X)$ e quindi una *distribuzione di*

probabilità condizionata (CPD) $P(X \mid \text{gen}(X))$. Il grafo è aciclico per costruzione con una fattorizzazione che dipende dall'ordinamento: a diversi ordinamenti corrisponderanno diverse BN. Una BN codifica relazioni di indipendenza condizionata fra variabili: dati i genitori, ogni variabile è indipendente da tutte le variabili che non sono sue discendenti.

Esempio 93 *(Voti)* **.**

Dato l'ordinamento *Intelligenza*, *Impegno*, *Risposte*, *Voto* delle variabili in un esempio precedente, le dipendenze potrebbero essere quelle rappresentate nella seguente figura:

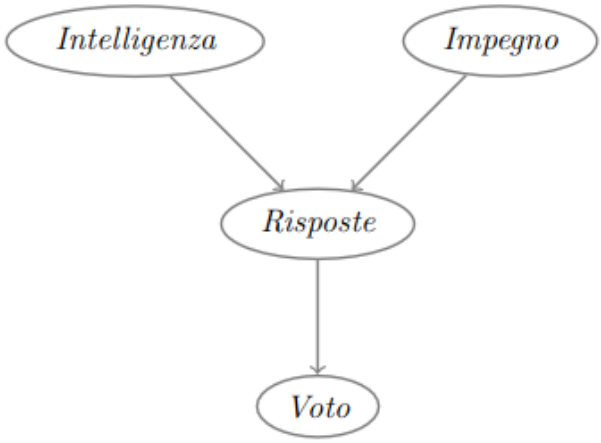


Figura 31: BN sui voti

- *Intelligenza* non ha predecessori, quindi nemmeno genitori: $\text{gen}(Intelligenza) = \emptyset$;
- *Impegno* è indipendente da *Intelligenza* e $\text{gen}(Impegno) = \emptyset$;
- *Risposte* dipende da *Intelligenza* e *Impegno*: $\text{gen}(Risposte) = \{Intelligenza, Impegno\}$;
- *Voto* è indipendente da *Intelligenza* e *Impegno* data *Risposte*: $\text{gen}(Voto) = \{Risposte\}$.

La fattorizzazione della distribuzione congiunta è:

$$P(Intelligenza, Impegno, Risposte, Voto) =$$
$$P(Intelligenza) \cdot P(Impegno) \cdot P(Risposte \mid Intelligenza, Impegno) \cdot P(Voto \mid Risposte).$$

Per le risposte si possono considerare domini semplificati, come ad esempio $Risposte = \{$ approfondite , chiare , superficiali , vacue $\}$, oppure anche il testo stesso delle risposte.

9.4.1. Osservazioni e Query

Data una BN che specifica una distribuzione congiunta, il problema di *inferenza probabilistica* più comune è il calcolo della *distribuzione a posteriori* di **variabili di query** data l'evidenza, ossia la congiunzione di assegnazioni di valori osservate riguardanti altre variabili.

> **Esempio 94.**
>
> Prima delle osservazioni, $P(Intelligenza)$ fornita dalla BN, dopo si può usare l'*inferenza* per determinare $P(Voto)$:
>
> - *query* $P(Intelligenza \mid Voto = 10)$: distribuzione a posteriori, ossia saputo che il voto conseguito è 10 (un valore di *Voto*);
> - *query* $P(Intelligenza \mid Voto = 10 \wedge Impegno = \texttt{false})$: distribuzione a posteriori, noto pure che $Impegno = \texttt{false}$;
> - *Intelligenza* e *Impegno* sono indipendenti quando non siano date altre informazioni ma, se si conosce il voto, esse diventano *dipendenti*; ciò spiega perché ci si vanti se si hanno buoni voti senza studiare molto: aumenta la probabilità di risultare intelligenti.

Le dipendenze modellate con le CPD non impongono la direzione da utilizare nelle inferenze per rispondere a query. Per ricavare le probabilità a posteriori necessarie a rispondere alle query, anche in verso opposto alle dipendenza della BN, si possono usare i teromi della Teoria della probabilità, in particolare quello di Bayes.

9.4.2. Costruzione di Belief Network

Per modellare un dominio attraverso una BN occorre:

- individuare le *variabili rilevanti*: cosa può essere osservato del dominio, ogni feature osservata costituirà una *variabile osservata* utile a potere poi condizionare le query sulla base dei valori assegnati; le feature che costituiranno le *variabili di query* ossia le informazioni di cui interessi determinare la probabilità a posteriori; potrebbero essere individuate anche altre variabili *nascoste* o **latenti**, né osservate né di query, utili a considerare dipendenze dirette e a semplificare il modello, perchè vi saranno meno probabilità condizionate da specificare.
- decidere i *domini di valori*, ossia il livello di dettaglio del ragionamento che poterà a rispondere alle query. Per ogni variabile, si specifica di ogni valore in ottemperanza al **principio di chiarezza** che richiede l'onniscenza del sistema riguardo il valore di ogni variabile, ossia sappia cosa deve acceder eperchè una variabile assuma un dato valore; va quindi documentatno il significato delle variabili e dei loro valori.
- specificare le *relazioni* di dipendenza diretta tra le variabili, ossia gli archi da considerare per definire la funzione gen.

- definire le CPD per ognuna variaible in dipendenza dai genitori, soliutamente in forma di tabelle *(CPT)*.

Esempio 95 *(Diagnostica di allarme anti-incendio)* **.**

Si tiene anche conto di manomissioni, rumore dei sensori di rilevamento (fumo, uscita persone) che portino a informazioni contraddittorie sulla situazione nella figura seguente.

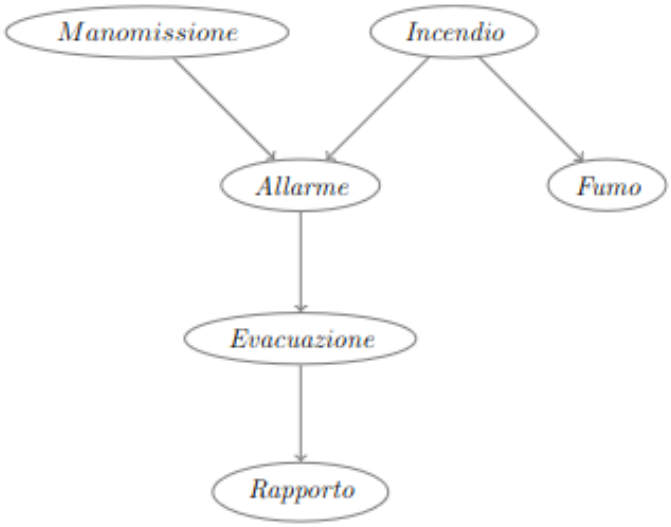


Figura 32: BN: allarme antiincendio

In particolare, l'arrivo di un rapporto segnala che è in corso un'evacuazione ma è una variabile *rumorosa* perché a volte non è in corso un'evacuazione segnalata (*falso positivo*) o altre volte potrebbe non segnalare un'evacuazione davvero in corso (*falso negativo*); l'evacuazione dipende dal fatto che sia scattato l'*allarme*; una *manomissione* o un *incendio* possono influenzare l'attivazione dell'allarme: la segnalazione di *fumo* dipende solo dalla rilevazione dell'incendio.

Modello risultante:

- *variabili* booleane (elenco ordinato):
  - *Manomissione* vera sse c'è stata la *manomissione* dell'impianto;
  - *Incendio* vera sse c'è un *incendio*;
  - *Allarme* vera sse si sente l'*allarme*;
  - *Fumo* vera sse c'è *fumo*;
  - *Evacuazione* vera sse la gente *lascia* in massa l'edificio;
  - *Rapporto* vera sse si invia un *avviso* di abbandono dell'edificio in corso;
- relazioni di *indipendenza condizionata*:
  - *Incendio* indipendente da *Manomissione* (senza condizioni);

- *Allarme* dipende solo da *Incendio* e *Manomissione*, senza altre dipendenze dalle precedenti;
- *Fumo* dipende solo da *Incendio* ed è indipendente da *Manomissione* e *Allarme* data *Incendio*;
- *Evacuazione* dipende solo da *Allarme* e non direttamente da *Incendio*, *Manomissione* o *Fumo*, ossia, data *Allarme*, è indipendente dalle altre variabili;
- *Rapporto* dipende direttamente solo da *Evacuazione*;

- *fattorizzazione* risultante:

$$\begin{aligned} &P(\mathit{Manomissione}, \mathit{Incendio}, \mathit{Allarme}, \mathit{Fumo}, \mathit{Evacuazione}, \mathit{Rapporto}) = \\ &\quad P(\mathit{Manomissione}) \cdot P(\mathit{Incendio}) \\ &\quad \cdot P(\mathit{Allarme} \mid \mathit{Manomissione}, \mathit{Incendio}) \cdot P(\mathit{Fumo} \mid \mathit{Incendio}) \\ &\quad \cdot P(\mathit{Evacuazione} \mid \mathit{Allarme}) \cdot P(\mathit{Rapporto} \mid \mathit{Evacuazione}) \end{aligned}$$

  Si noti che l'allarme non è sensibile al fumo ma al calore sprigionato dal fuoco: da qui l'indipendenza di *Allarme* da *Fumo* dato *Incendio* e la dipendenza di *Fumo* da *Incendio*;

- *domini*: variabili booleane per cui si userà il nome in minuscolo per denotare l'assegnazione di `true`, preceduto dalla negazione $\neg$ nel caso opposto, ad esempio: *Manomissione* = `true` si abbrevia con `manomissione`, e *Manomissione* = `false` con $\neg$ `manomissione`

- specifica delle CPD usate negli esempi che seguiranno:
  - $P(\texttt{manomissione}) = 0.02$;
  - $P(\texttt{incendio}) = 0.01$;
  - $P(\texttt{allarme} \mid \texttt{incendio} \wedge \texttt{manomissione}) = 0.5$;
  - $P(\texttt{allarme} \mid \texttt{incendio} \wedge \neg\, \texttt{manomissione}) = 0.99$;
  - $P(\texttt{allarme} \mid \neg\, \texttt{incendio} \wedge \texttt{manomissione}) = 0.85$;
  - $P(\texttt{allarme} \mid \neg\, \texttt{incendio} \wedge \neg\, \texttt{manomissione}) = 0.0001$;
  - $P(\texttt{fumo} \mid \texttt{incendio}) = 0.9$;
  - $P(\texttt{fumo} \mid \neg\, \texttt{incendio}) = 0.01$;
  - $P(\texttt{evacuazione} \mid \texttt{allarme}) = 0.88$;
  - $P(\texttt{evacuazione} \mid \neg\, \texttt{allarme}) = 0.001$;
  - $P(\texttt{rapporto} \mid \texttt{evacuazione}) = 0.75$;
  - $P(\texttt{rapporto} \mid \neg\, \texttt{evacuazione}) = 0.01$.
  - le probabilità a posteriori delle assegnazioni negative si possono ottenere per complemento, ad esempio:
    $P(\neg\, \texttt{fumo} \mid \texttt{incendio}) = 1 - P(\texttt{fumo} \mid \texttt{incendio}) = 0.1$ e
    $P(\neg\, \texttt{fumo} \mid \neg\, \texttt{incendio}) = 1 - P(\texttt{fumo} \mid \neg\, \texttt{incendio}) = 0.99$;

- probabilità a priori prima di ogni osservazione (evidenza):

- $P(\texttt{manomissione}) = 0.02$;
- $P(\texttt{incendio}) = 0.01$;
- $P(\texttt{fumo}) = P(\texttt{fumo} \wedge \texttt{incendio}) + P(\texttt{fumo} \wedge \neg\, \texttt{incendio})$
  $= P(\texttt{fumo} \mid \texttt{incendio}) \cdot P(\texttt{incendio}) + P(\texttt{fumo} \mid \neg\, \texttt{incendio}) \cdot P(\neg\, \texttt{incendio})$
  $= 0.9 \cdot 0.01 + 0.01 \cdot 0.99 = 0.009 + 0.0099 = 0.0189$;
- $P(\texttt{rapporto}) = 0.028$.

- avendo osservato l'arrivo di un *rapporto* (ossia data l'evidenza rapporto) si ha che:
  - $P(\texttt{manomissione} \mid \texttt{rapporto}) = 0.399$;
  - $P(\texttt{incendio} \mid \texttt{rapporto}) = 0.2305$;
  - $P(\texttt{fumo} \mid \texttt{rapporto}) = 0.215$
    si noti che le probabilità di manomissione e incendio sono aumentate a causa di rapporto quindi anche quella di fumo che dipende da incendio.

- avendo osservato (solo) fumo:
  - $P(\texttt{manomissione} \mid \texttt{fumo}) = 0.02$,
    ossia la probabilità di manomissione non è influenzata dall'osservazione di fumo;
  - $P(\texttt{incendio} \mid \texttt{fumo}) = 0.476$ e $P(\texttt{rapporto} \mid \texttt{fumo}) = 0.320$,
    si noti come entrambe aumentino dopo aver osservato del fumo;

- avendo osservato rapporto e fumo:
  - $P(\texttt{manomissione} \mid \texttt{rapporto} \wedge \texttt{fumo}) = 0.0284$,
    il caso di incendio diventa ancora più probabile;
  - $P(\texttt{incendio} \mid \texttt{rapporto} \wedge \texttt{fumo}) = 0.964$
    quindi se è pervenuto un rapporto, la presenza di fumo rende la manomissione meno probabile, essendo rapporto *spiegabile* da incendio che adesso è molto più probabile;

- ancora, avendo osservato rapporto ma non fumo si ha che
  - $P(\texttt{manomissione} \mid \texttt{rapporto} \wedge \neg\, \texttt{fumo}) = 0.501$;
  - $P(\texttt{incendio} \mid \texttt{rapporto} \wedge \neg\, \texttt{fumo}) = 0.0294$,
    quindi osservato rapporto, incendio diventa molto meno verosimile e la probabilità di manomissione aumenta per poter spiegare quanto osservato.

9.4.3. Probabilià Condizionate e Fattori

Un **fattore** è una funzione definita su un insieme di variabili. Il suo **ambito** / *scope* è costituito da tali variabili e data un'assegnazione a ciascuna di esse, il fattore calcolerà un valore numerico.
Nel caso della *probabilità condizionata* si prenderà in considerazione il fattore $P(Y \mid X_1, ..., X_k)$, funzione da $Y, X_1, ..., X_k$ in $\mathbb{R}_+$ con il vincolo:

$$\forall x_1 ... \forall x_k \sum_{y \in \text{ dom}(Y)} P(Y = y \mid X_1 = x_1, ..., X_k = x_k) = 1$$

Normalmente una distribuzione condizionata si rappresenta con una CPT. Questo è possibile con insiemi finiti di variabili e domini di valori.
Una possibile rappresentazione per una tabella multidimensionale per la CPD $P(Y = y \mid X_1 = v_1, ..., X_k = v_k)$ nella notazione Python per array e dizionari potrebbe essere la seguente: `p[v_1]...[v_k][y]` .

Esempio 96.

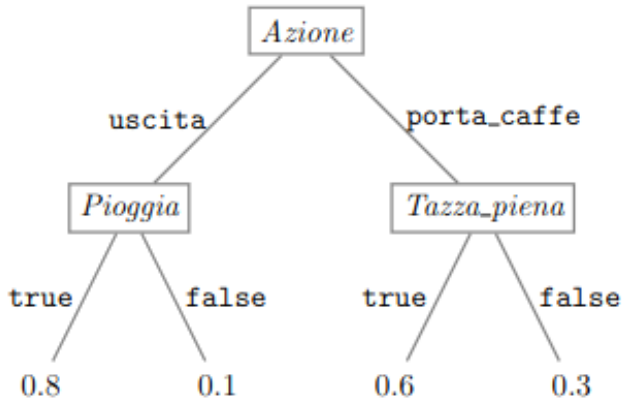
Robot con azioni possibili indicate dalla variabile *Azione*, $\text{dom}(Azione) = \{\texttt{uscita}, \texttt{porta_caffe}\}$. Si considera lo stato di *bagnato* (indicato dalla variabile *Bagnato*) causato dalla pioggia (indicato da *Pioggia* = `true`) nel contesto di un'uscita da un luogo al coperto (*Azione* = `uscita`) o per colpa del trasporto *Azione* = `porta_caffe` d'una tazza piena (*Tazza_piena*) di caffè: *Bagnato* sarà indipendente da *Pioggia* quando *Azione* = `porta_caffe` , ma dipendente da *Pioggia* se *Azione* = `uscita` ; *Bagnato* sarà indipendente da *Tazza_piena* dato che *Azione* = `uscita` , ma dipendente da *Tazza_piena* dato *Azione* = `porta_caffe` . Una CPT corrispondente può essere:

Azione	*Pioggia*	*Tazza_piena*	$P($`bagnato` | azione, pioggia, tazza)
uscita	false	false	0.1
uscita	false	true	0.1
uscita	true	false	0.8
uscita	true	true	0.8
porta_caffe	false	false	0.3
porta_caffe	false	true	0.6
porta_caffe	true	false	0.3
porta_caffe	true	true	0.6

Alberi di Decisione

In caso di CPT molto grandi ci saranno troppe probabilità da determinare. A tale scopo conviene sfruttar la struttura della rete. Considerando l'**indipendenza specifica per il contesto** , si sfrutta l'indipendenza condizioanta al fine di definire un albero di decisione.

Esempio 97. La CPD dell'esempio precedente può essere riassunta attraverso l'albero nella seguente figura:



Sistema Deterministico con Input Rumorosi

Si può descriver eun fattore anche attraverso un sistema deterministico rappresentato da una formula logica ovvero anche da programma avente come *input* variabili genitrici e input stocastici, dette **variabili-rumore** o **esogene**, fra loro indipendenti, mentre le **variabili endogene**, quelle interne alla BN, potranno essere specificate deterministicamente in funzione di quelle esogene e delle genitrici.

Esempio 98. Nel caso precedente relativo al robot, si può ridefinire il modello attraverso la formula:

$$\begin{aligned}\text{bagnato} \leftrightarrow ((&\text{uscita} \wedge \text{pioggia} \wedge n_0) \vee \\ &(\text{uscita} \wedge \neg\ \text{pioggia} \wedge n_1) \vee \\ &(\neg\ \text{uscita} \wedge \text{tazza_piena} \wedge n_2) \vee \\ &(\neg\ \text{uscita} \wedge \neg\ \text{tazza_piena} \wedge n_3))\end{aligned}$$

dove le n_i sono variabili-rumore indipendenti, con $P(n_0) = 0.8$, $P(n_1) = 0.1, P(n_2) = 0.6, P(n_3) = 0.3$, ad esempio se `uscita = true` e `pioggia=false`, allora `bagnato=true` quando n_1 `=true`, il che accade con probabilità 0.1.
Il corrispondente modello in forma di programma sarà:

```
if uscita:
    if pioggia:
        bagnato := flip(0.8)
    else:
        bagnato := flip(0.1)
else:
    if tazza_piena:
        bagnato := flip(0.6)
    else:
        bagnato := flip(0.3)
```

```
11
12  flip(x) = (random() < x)
```

dove: `random()` restituisce un numero casuale nell'intervallo $[0, 1)$ e `flip(x)` crea una nuova variabile aleatoria indipendente, vera con probabilità x, ossia una n_i nella formula logica.

Come sistema deterministico si usa:
- il completamento di Clark di un programma logico nella **programmazione logica probabilistica**;
- un programma nella **programmazione probabilistica**;
- una formula logica nel **conteggio pesato del modello**.

Noisy-Or

Si possono modellare i fattori come casi in cui qualcosa si avvera a causa di qualcos'altro: ad esempio si può avvertire la presenza di un sintomo a causa di una malattia.

Il **noisy-or** è un modello di probabilità condizionata in cui una variabile figlia è vera se si attiva almeno una delle variabili genitrici. Sia Y la figlia definita come *disgiunzione* delle attivazioni delle genitrici $X_1, ..., X_k$ (booleane). I *parametri* $\omega_0, ..., \omega_k$ costituiscono un sistema deterministico con input rumorosi, in cui:

$$Y \equiv n_0 \vee (n_1 \wedge x_1) \vee ... \vee (n_k \wedge x_k)$$

con n_i variabili di rumore indipendenti, dove $P(n_i) = \omega_i$ e ogni x_i per indicare che $X_i = \text{true}$.

La BN per $P(Y \mid X_1, X_2, ..., X_k)$ può essere definita introducendo le variabili booleane $A_0, A_1, ..., A_k$ con:
- $P(A_i = \text{true} \mid X_i = \text{true}) = \omega_i$ e $P(A_i = \text{true} \mid X_i = \text{false}) = 0$;
- $P(A_0 = \text{true}) = \omega_0$: si osservi che $P(Y \mid A_0, A_1, ..., A_k) = 1$ se almeno una delle A_i è vera quindi ω_0 è la probabilità di Y quando tutte le X_i sono false.

La probabilità di Y aumenta in base alla numerosità di X_i vere.

Modelli Log-lineari e Regressione Logistica

Un modello log-lineare specifica probabilità, non normalizzate, tramite un prodotto di termini che andrà normalizzato per inferire probabilità. I termini sono tutti positivi quindi si può descrivere il prodotto come esponenziale di una somma, più facile da trattare. Date h ed e booleane:

$$P(h \mid e) = \frac{P(h \wedge e)}{P(e)} = \frac{P(h \wedge e)}{P(h \wedge e) + P(\neg h \wedge e)} = \frac{1}{1 + \frac{P(\neg h \wedge e)}{P(h \wedge e)}}$$

$$= \frac{1}{1 + \exp\Big(-\log\Big(\frac{P(h \wedge e)}{P(\neg h \wedge e)}\Big)\Big)} = \text{sigmoide}(\log(\text{odds}(h \mid e)))$$

ricordando che

$$\text{sigmoide}(x) = \frac{1}{1 + \exp(-x)}$$

e i rapporti fra probabilità detti **odds condizionti** sono definiti nel seguente modo:

$$\text{odds}(h \mid e) = \frac{P(h \wedge e)}{P(\neg h \wedge e)} = \frac{P(h \mid e)}{P(\neg h \mid e)} = \frac{P(h \mid e)}{1 - P(h \mid e)} = \frac{P(e \mid h)}{(P(e \mid \neg h))} \cdot \frac{P(h)}{P(\neg h)}$$

Qui $\frac{P(e \mid h)}{P(e \mid \neg h)}$ si chiama anche **likelihood ratio** e $\frac{P(h)}{P(\neg h)} = \frac{P(h)}{1-P(h)}$ sono detti **prior odds**.
Se $\frac{P(e \mid h)}{P(e \mid \neg h)}$ si può scrivere come prodotto allora il suo logaritmo sarà una somma.
Si può considerare anche un modello della probabilità condizionata $P(Y \mid X_1, ..., X_k)$ basato sulla *regressione logistica* definito come segue:

$$P(Y = \text{true} \mid X_1, ..., X_k) = \text{sigmoide}\left(\sum_i \omega_i \cdots X_i\right)$$

Asusmendo un input fittizio aggiuntivo $X_0 = 1$ con termine noto ω_0, esso corrisponde a una decomposizione della probabilità condizionata, con una *likelihood ratio* pari a un prodotto di termini, uno per ogni X_i. Si noti che $P(Y \mid X_1 = 0, ..., X_k = 0) = \text{sigmoide}(\omega_0)$ quindi ω_0 corrisponde alla probabilità del caso in cui tutti i suoi genitori sono nulli mentre ogni ω_i specifica un valore da aggiungere al cambiare di $X_i : P(Y \mid X_1 = 0, ..., X_i = 1, ..., X_k = 0) = \text{sigmoide}(\omega_0 + \omega_i)$. Assumendo l'esclusiva influenza sul figlio di ciascun genitore, gli odds sono decomponibili in prodotti di termini dipendenti da una sola variabile.

9.5. Inferenza Probabilistica

Lo scopo dell'inferenza è quello di rispondere a query su un dato modello probabilistico essenzaialemente trattato attraverso il calcolo di distribuzioni. Un tipico task è quello di calcolare la **distribuzione a posteriori** di una o più variabili di query data l'evidenza disponibile. Il problema risulta complesso. Si può dimostrare che sia *NP-hard* e #NP per il calcolo delle probabilita a posteriori o a priori di una variabile. Ciò nel caso pessimo, ma in genere si può sfruttare la struttura per rendere il compito più agevole.

Gli approcci principali all'inferenza probabilistica con le BN si caratterizzano in termini di inferenza esatta ed approssimata.

9.5.1. Inferenza Esatta

Tale forma di inferenza richiede che le probabilità vengano calcolate precisamente. Fondamentalmente gli approcci relativi a tale forma si dividono in due modalità principali:

1. *Enumerazione* dei mondi consistenti con l'evidenza;
2. Sfruttamento della struttura della rete: ad esempio l'algortimo di *eliminazione di variabili per BN*, simile all'algoritmo per CSP, basato sulla programmaziuone dinamica, che sfrutta le relazioni di indipendenza condizionata.

9.5.2. Inferenza Approssimata

Esistono diversi metodi per stimare le probabilità che variano in base al tipo di approssimazione desiderata:

- metodi che forniscono **limiti garantiti** $[l, u]$ di variazione entro i quali ricada la probabilità esatta p, ad esempio un algoritmo *anytime* garantisce che l e u tendano ad avvicinarsi reciprocamente col passare del tempo;
- metodi che forniscono **limiti probabilistici** sull'errore garantendo un errore contenuto in un'alta percentuale di casi, ovvero stime di probabilità che convergono nel tempo verso quella esatta e una certa velocità di convergenza, come ad esempio gli algoritmi di *simulazione stocastica*;
- metodi di **inferenza variazionale** capaci di fornire generalmente buone approssimazioni: seclta di una classe di rappresentazioni più semplici, ad esempio BN non connesse, si trova in tale classe il modello più vicino al problema originario ossia una distribuzione a posteriori, facile da calcolare, più vicina a quella cercata in modo da trasformare il problema in uno di minimizzazione dell'errore, seguito da quello di inferenza vera e propria.

9.6. Modelli Probabilistici Sequenziali

Si considerino BN speciali con una struttura che si ripete. Essi rendono possibile il ragionamento su sequenza non solo temporali ma anche nello spazio, come ad esempio, le parole in una frase. È possibile estendere le strutture anche a un numero non limitato di variabili casuali.

9.6.1. Catene di Markov

Una **catena di Markov (MC)** è una BN con nodi/variabili disposti in una sequenza, quindi ogni variabile dipenderà direttametne solo dalla precedente, come mostrato nella seguente figura:

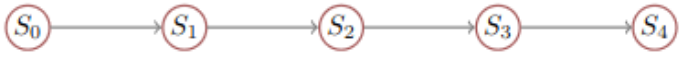


Figura 34: MC come BN

Tramite queste strutture è possibile rappresentare sequenze di *stati*. Ad esempio si possono considerare sequenze di stati in un sistema dinamico o parole di un testo. Ogni *posizione* nella sequenza sarà indicato come **stage**.
Le sequenze sono spesso intese come successioni nel tempo. Essendo reti bayesiane in cui ogni nodo, tranne il primo, dipende solo dal genitore, si dice che viene fatta una **assunzione di Markov** (mancanza di memoria) che può essere descritta dalla seguente proprietà della distribuzione

$$P(S_{i+1} \mid S_0, ..., S_i) = P(S_{i+1} \mid S_i)$$

dove S_t rappresenta lo **stato** al tempo t: intuitivamente, S_t porta con sè tutte le informazioni storiche che possono influenza gli stati futuri.
Una catena di Markov è un **modello stazionario** se tutte le variabili condividono un unico domibnio e stesse probabilità di transizione per ogni stage:

$$\forall i \geq 0 : P(S_{i+1} \mid S_i) = P(S_1 \mid S_0)$$

il che la rende definibile attraverso da due sole distribuzioni:

- $P(S_0)$ che specifica le condizioni iniziali;
- $P(S_{i+1} \mid S_i)$ che specifica le dinamiche, le stesse per ogni $i \geq 0$.

Quindi con pochi parametri si specifica una struttura potenzialmente non limitata. Sarà poi possbile porre domande su punti arbitrari nel futuro o nel passato.
Per determinare le distribuzioni:

- per $P(S_i)$: si può usare l'eliminazione di variabili sommando su tutte le precedenti;
- per $P(S_i \mid S_k)$: se $i > k$, basta considerare solo le variabili tra S_i e S_k, altrimenti solo quelle di indice inferiore a k.

La **distribuzione** di una catena di Markov si dice **stazionaria** se ciò che vale una volta varrà anche per la successiva: P stazionaria se per ogni stato s si ha che $P(S_{i+1} = s) = P(S_i = s)$, per cui:

$$P(S_i = s) = \sum_{s_i} P(S_{i+1} == s \mid S_i) \cdot P(S_i)$$

Proprietà delle Catene di Markov

- Una catena si dice **ergodica** se e solo se per ogni (s_1, s_2) probabilità non nulla di raggiungere s_2 da s_1;

- una catena si dice **periodica** se e solo se $\exists p$, *periodo*, tale che la differenza tra passaggi per uno stesso stato divisibile per p, altrimenti **aperiodica** ($p = 1$).

Una MC ergodica e aperiodica ha una sola distribuzione stazionaria detta di **equilibrio** raggiungibile a partire da qualunque stato: per ogni distribuzione su S_0, la distribuzione su S_i si avvicinerà sempre di più a quella di equilibrio al crescere di i.

9.6.2. Modelli di Markov Nascosti

Un **modello di Markov nascosto** o *Hidden Markov Model (HMM)* è costituito da una catena di Markov estesa con l'aggiunta dei noid per le osservazioni per ciascuno stage, come mostrato nella figura seguente.

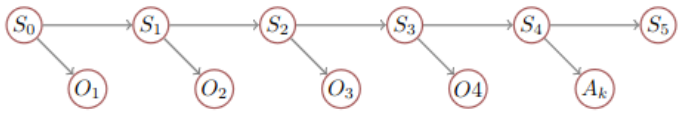


Figura 35: HMM

Oltre alle transizioni di stato, per ogni istante di tempo t c'è l'osservazione O_t che dipende da S_t con dominio costituito dall'insieme delle possibili osservazioni; tali osservazioni sono *parziali* e *rumorose*, cioè in uno stesso stato, ma in momenti diversi, si possono avere osservazioni differenti in maniera casuale.
Sono necessarie anche le seguenti assunzioni di base:

- lo stato al tempo $t + 1$ dipende direttamente solo dallo stato del tempo t per $t \geq 0$, come nelle catene di Markov;
- l'osservazione a tempo t dipende direttamente solo dallo stato al tempo t.

Un HMM stazionario è quindi definito attraverso le seguenti distribuzioni:

- $P(S_0)$ specifica le condizioni iniziali;
- $P(S_{t+1} \mid S_t)$ specifica della dinamica;
- $P(O_t \mid S_t)$ specifica del modello del sensore.

Sono possibili diverse inferenze su tali modelli, come ad esempio ricostruire la sequenza di stati data una sequenza di osservazioni (ovvero la sua probabilità).

9.7. Simulazione Stocastica

Spesso i problemi di inferenza sono troppo complessi per un'efficiente inferenza esatta: ci sono molte variabili e molte dipendenze in gioco. In tali casi, conviene ricorrere all'*inferenza approssimata* con metodi basati sulla generazione di campioni casuali della distribuzione specificata dalla rete.
Nella **simulazione stocastica** si costruisce un insieme di campioni mappati su e

da probabilità. Per l'inferenza si va dalle probabilità ai campioni e viceversa.
I problemi tipicamente correlati con la simulazione stocastica sono i seguenti:
1. come *generare* i campioni;
2. come *inferire* probabilità dai campioni;
3. come *incorporare* nel meccanismo le osservazionia a disposizione.

I metodi **Monte Carlo** forniscono le basi per soluzioni che usano il campionamento per calcolare la distribuzione a posteriori di una variabile in una BN.

9.7.1. Campionamento di una Variabile

Per la *generazione di campioni* dalla distribuzione di una sola variabile X occorre ordinare i valori del dominio per definire la *distribuzione cumulativa* f in funzione di x come segue:

$$f(x) = P(X \leq x)$$

Quindi, per ottenere un *campione casuale* v per X, si genera y da una distribuzione uniforme su $[0, 1]$ e si ricava il valore $v \in \text{dom}(X)$ che abbia y come immagine nella cumulativa, ossia tale che $f(v) = y$, ovvero $v = f^{-1}(y)$.
Avendo a disposizione un insieme di campioni, per la *stima delle probabilità* da tale insieme basta ricorrere alla *media campionaria*: data una proposizione α sulle variabili, sia s la proporzione di campioni per i quali α è vera rispetto al totale n.
Per la **legge dei grandi numeri**, s si avvicina asintoticamente alla probabilità esatta $p = P(\alpha)$ al crescere di n.
Per una *stima dell'errore* ε si può utilizzare la ***disuguaglianza di Hoeffding***:

$$P(|p - s| > \varepsilon) \leq 2e^{-2n\varepsilon^2}$$

da cui si può ricavare il numero di campioni n che garantisce una stima *probabilmente approssimativamente corretta* della probabilità.

9.7.2. Forward Sampling su BN

Campionando tutte le variabili di una BN ogni campione sarà generato in proporzione alla sua probabilità. Ciò consente di stimare le probabilità a priori di qualsiasi variabile.
Dato un ordinamento $X_1, ..., X_n$ delle variabili, tale che ognuna sia preceduta dai propri genitori, per estrarre un campione/tupla dalla distribuzione congiunta:
- si parte campionando x_1 usando la cumulativa;
- per ogni i da 2 a n:
  si campiona un valore per X_i da $P(X_i \mid \text{gen}(X_i))$, distribuzione condizionata di X_i, dati i valori già campionati per i genitori.

La stima della distribuzione di una variabile di query si ottiene considerando la proporzione di campioni assegnati a ogni valore di tale variabile.

Esempio 99.

Per la BN vista in **Figura 32**, ordinamento come in tabella. Si deve ripetere la costruzione di un campione, con un valore per variabile, nell'ordine:

1. campionando *Manomissione* con la cumulativa si ottiene,
   ad esempio, *Manomissione* = false ;
2. analogamente, campionando *Incendio* si ha,
   ad esempio, *Incendio* = true ;
3. campionando *Allarme* da $P(Allarme \mid Manomissione = \texttt{false}, Incendio = \texttt{true})$
   si potrebbe avere, ad esempio, *Allarme* = true ;
4. poi si campiona *Fumo* usando $P(Fumo \mid Incendio = \texttt{true})$;
5. ecc…

Ciò va ripetuto fino a ottenere il numero desiderato di campioni/tuple $\{s_1, ..., s_n\}$.

campione	*Manomissione*	*Incendio*	*Allarme*	*Fumo*	*Evacuazione*	*Rapporto*
s_1	false	true	true	true	false	false
s_2	false	false	false	false	false	false
s_3	false	true	true	true	true	true
s_4	false	false	false	false	false	true
s_5	false	false	false	false	false	false
s_6	false	false	false	false	false	false
s_7	true	false	false	true	true	true
s_8	true	false	false	false	false	true
⋮	⋮	⋮	⋮	⋮	⋮	⋮
s_{1000}	true	false	true	true	false	false

Ad esempio, per la stima di $P(Rapporto = \texttt{true})$ andrà considerata la proporzione dei campioni per i quali *Rapporto* è vera sui 1000 campioni.

9.7.3. Markov Chain Monte Carlo

Si considera ora un metodo che prescinde dall'ordine di campionamento. La distribuzione stazionaria di una catena di Markov è la distribuzione delle sue variabili che non cambia in base alla funzione di transizione della catena: se la catena mescola sufficientemente, c'è un'unica distribuzione stazionaria. Tale distribuzione può essere approssimata facendo girare il meccanismo di campionamento sufficientemente lungo.

Nei metodi detti **Markov Chain Monte Carlo (MCMC)** per generare campioni da una distribuzione si costruisce una catena di Markov di campioni avente, a lungo andare, la distribuzione desiderata come sua distribuzione stazionaria, quindi si campiona da tale catena perchè i suoi campioni saranno distribuiti secondo la

distribuzione-obiettivo. Può occorrere una fase iniziale di *riscaldamento*: andrebbero scartati i primi campioni, probabilmente lontati dalla distribuzione stazionaria.
In particolare, nel **Gibbs sampling** si crea una catena di campioni da una rete bayesiana, fissando i valori per le variabili osservate e campionando le altre. Si genera un nuovo campione a a partire dal precedente, modificando i valori per le variabili non fissate. Si può anche considerare una sola variabile alla volta: la singola variabile sarà campionata in base alla distribuzione condizionata ai valori correnti delle altre variabili. SI noti che una variabile X in una rete dipende solo dai valori delle variabili nel suo **Markov blanket** $mb(X)$ contenente i suoi genitori, i suoi figli e gli altri genitori dei suoi figli, come si vede nella seguente figura.

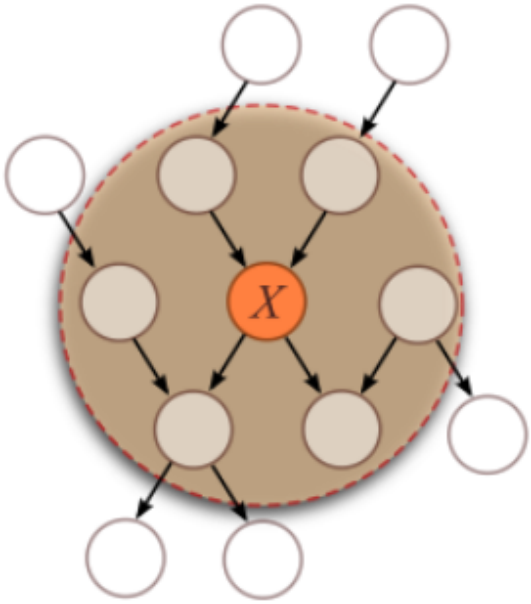


Figura 36: Markov blanket

L'algoritmo può essere formalizzato come segue.

Algoritmo 30 — *Gibbs Sampling*

1: **procedure** Gibbs_sampling(B, e, Q, n, burn_in)
2: **Input**
3: B: belief network
4: e: evidenza; assegnazione di valori ad alcune variabili
5: Q: variabile di query
6: n: numero di campioni da generare
7: burn_in: numero di campioni iniziali da scartare
8: **Output**

```
    distribuzione a posteriori su Q
Local
    campione[], array in cui campione[var] ∈ dom(var)
    real freq[k], array inizializzato a 0 per ogni k ∈ dom(Q)
Inizializzare campione[X] ← e[X] se X osservata
{ altrimenti con un valore casuale da dom(X) }
repeat burn_in volte
    for each variabile X non osservata do
        campione[X] ← campione casuale da P(X | mb(X))
repeat n volte
    for each variabile X non osservata do
        campione[X] ← campione da P(X | mb(X))
    v ← campione[Q]
    freq[v] ← freq[v] + 1
return counts / Σ_v freq[v] { normalizzazione dell'array }
```

Esempio 100.

Data la BN vista precedentemente sui voti, per campionare $P(\text{Manomissione} \mid \text{Fumo} \wedge \neg\ \text{Rapporto})$, si costruiscono i campioni:

campione	Manomissione	Incendio	Allarme	Fumo	Evacuazione	Rapporto
s_1	true	true	false	true	false	false
s_2	true	true	false	true	false	false
s_3	true	true	false	true	false	false
s_4	true	true	true	true	false	false
s_5	true	true	true	true	true	false
s_6	false	true	true	true	true	false
$v...$	$v...$	$v...$	$v...$	$v...$	$v...$	$v...$
$s_{\{1000\}}$	false	true	true	true	true	false

- *Fumo* e *Rapporto* sono fissate a `true` e `false`, rispettivamente;
- si genera s_1 casualmente e si seleziona *Manomissione*
- *Incendio* e *Allarme* formano il Markov blanket per *Manomissione* quindi si estrae un campione casuale da $P(\text{Manomissione} \mid \text{incendio} \wedge \neg\ \text{allarme})$; supponendo sia `true` si ottiene così s_1;

- dato s_2, si estrae un valore casuale da $P(\text{Incendio} \mid \text{manomissione} \wedge \neg\, \text{allarme} \wedge \text{fumo})$; si supponga sia `true` per ottenere quindi s_3; poi si campiona un valore da $P(\text{Allarme} \mid \text{manomissione} \wedge \text{incendio} \wedge \neg\, \text{evacuazione})$, ad esempio `true`;
- alla fine la stima della probabilità di *Manomissione* sarà la proporzione dei casi `true` nei campioni, generati dopo il periodo di burn-in.

La distribuzione dei campioni si avvicina alla distribuzione congiunta reale se non si sono probabilità nulle. La velocità dipende da quella del rimescolamento delle probabilità che a sua volta dipende da quanto esse risultino estreme. In genere il metodo funziona bene per probabilità non estreme.

Apprendimento e Incertezza

10.1. Apprendimento Probabilistico

Le forme di apprendimento viste possono essere estese con l'uso esplicito del ragionamento probabilistico: i dasti forniscono l'evidenza fattuale sulla quale si può effettuare il condizionamento. Ciò è alla base dell'apprendimento supervisionato e non.
Dato il *dataset Es*, per determinare un modello ottimale, m, per i dati a disposizione, Es, si può utilizzare il *teorema di Bayes*:

$$P(m \mid Es) = \frac{P(Es \mid m) \cdot P(m)}{P(Es)}$$

ove:

- $P(Es \mid m)$ rappresenta la **verosomiglianza** o *likelihood* del fatto che Es sia stato generato da m: è alta se m fornisce una buona approssimazione della distribuzione dei dati reale;
- $P(m)$ è la **probabilità a priori** che codifica il *bias di apprendimento*, indicando i modelli più verosimili a priori e può essere usata per la *regolarizzazione* inducendo a scegliere modelli più semplici attribuendo loro una maggiore probabilità;
- $P(Es)$, detta **funzione di partizione**, viene usata ai fini della *normalizzazione*.

Selezione dei Modelli
Nella *selezione* di un singolo modello, il modello **MAP** (*maximum a posteriori*) è quello che massimizza la probabilità a posteriori, determinabile in base al numeratore

$$P(Es \mid m) \cdot P(m)$$

essendo trascurabile il denominatore in quanto non dipende da m. Essa si basa, quindi, sulla verosomiglianza, che misura l'adattamento ai dati, e sulla distribuzione a priori dei modelli, la quale è utile come bias di apprendimento per codificare la preferenza verso modelli più semplici (*rasoio di Occam*).
In alternativa, si può puntare a determinare il modello di **massima verosomiglianza (ML)** massimizzando solo

$$P(Es \mid m)$$

Quando lo *spazio dei modelli* è molto ricco, sorge il problema di avere spesso più di un modello m per cui $P(Es \mid m) = 1$; ad esempio tale caso è possibile quando si adottano modelli come gli alberi di decisione: essi possono rappresentare qualunque funzione discreta, quindi anchesovradattarsi ai dati; pertanto anche un modello molto poco probabile a priori non andrebbe escluso: potrebbe essere quello corretto e, se i dati sono sufficienti, risultare anche il migliore.
Per la regola di Bayes, se $P(m)$ è uniforme (caso di massima incertezza sui modelli), il modello ML coincide con il modello MAP. Altrimenti conviene preferire m più semplici, adottando distribuzioni a priori che li rendano più probabili, in quanto meno soggetti a *sovradattamento*.

10.2. Apprendimento Bayesiano

L'**apprendimento Bayesiano** offre un'*alternativa* alla scelta di un singolo modello più probabile: si sfruttano le distribuzioni a posteriori di più modelli (ipotesi).
Dati gli esempi di training, Es, per predire Y per un nuovo esempio $\overline{x}$, si deve determinare la probabilità a posteriori:

$$P(Y \mid \overline{x} \wedge Es)$$

Lo scopo di un modello è quello di generare esempi. Dato un insieme esaustivo M di modelli disgiunti, si può scrivere (ragionando per casi e sfruttando la definizione della probabilità condizionata):

$$P(Y \mid \overline{x} \wedge Es) \overset{\text{casi}}{=} \sum_{m \in M} P(Y \wedge m \mid \overline{x} \wedge Es)$$
$$\overset{\text{p.cond}}{=} \sum_{m \in M} P(Y \mid m \wedge \overline{x} \wedge Es) \cdot P(m \mid \overline{x} \wedge Es)$$
$$= \sum_{m \in M} P(Y \mid m \wedge \overline{x}) \cdot P(m \mid Es)$$

L'ultimo passaggio dipende da due assunzioni sul modello m:

1. m racchiude tutte le in formazioni su Es necessarie a una predizione, $P(Y \mid m \wedge \overline{x} \wedge Es) = P(Y \mid m \wedge \overline{x})$;
2. m non cambia per un solo nuovo esempio, ossia $P(m \mid \overline{x} \wedge Es) = P(m \mid Es)$.Invece di scegliere il modello migliore, nel **model averaging** si mediano le predizioni di tutti i modelli, ponderando con $P(m \mid Es)$:

$$P(Y \mid \overline{x} \wedge Es) = \sum_{m \in M} P(Y \mid m \wedge \overline{x}) \cdot \underline{P(m \mid Es)}$$

dove $P(m \mid Es)$, calcolabile con la regola di Bayes, dipende dalla capacità di generare i dati osservati e dalla probabilità a priori di m, mentre $P(Es)$ serve solo alla normalizzazione e risulta difficile da calcolare se M contiene molti modelli, inutile se si deve solo massimizzare il numeratore.
Un'assunzione comune è che gli esempi $Es = \{e_1, ..., e_k\}$ siano **indipendenti e identicamente distribuiti (i.i.d)** dato m ossia che, per ogni coppia di esempi $\langle e_i, e_j \rangle, i \neq j$, essi siano indipendenti dato m. In tal caso si può scrivere:

$$P(Es \mid m) = \prod_{i=1}^{k} P(e_i \mid m)$$

Nel ragionamento con questa rete si possono applicare metodi di inferenza esatta o approssimata, condizionando su ogni e_i osservato. Tipicamente si fanno interrogazioni su un e_i non osservato, ossia predizioni su esempi non visti oppure anche su m.

10.2.1. Appredere Probabilità

Un possibile *obiettivo* può essere quello di imparare le probabilità, ossia i parametri di un modello probabilistico in una delle diverse formulazioni possibili.

> **Esempio 101.** Si considerino dei lanci di una moneta con esito `Testa` o `Croce`. Dato un certo numero di lanci indipendenti si avranno le osservazioni Es, nelle quali n_0 saranno `Croce` e n_1 `Testa`. Detta φ la probabilità di Testa, la likelihood sarà $P(Es \mid \varphi) = \varphi^{n_1} \cdot (1 - \varphi)^{n_0}$ da cui si può ottener la log-likelihood:
>
> $$\log(P(Es \mid \varphi)) = n_1 \cdot \log(\varphi) + n_0 \cdot \log(1 - \varphi)$$

che risulta massima per $\varphi = \frac{n_1}{n_0+n_1}$, valore per cui si ha una minima log-loss.

Nell'approccio bayesiano si trattano i parametri, φ, non come costanti ma come variabili aleatorie a valori reali.

Variabili-obiettivo Binarie

Si consideri il caso più semplice: variabile Y booleana e nessun input a disposizione. Per tale Y, si può considerare φ come variabile su $[0, 1]$ tale che $P(Y = \text{true} \mid \varphi) = \varphi$e $P(Y = \text{false} \mid \varphi) = 1 - \varphi$. Quindi φ determina l'insieme M dei diversi modelli. Gli esemi in Es saranno del tipo $Y = \text{true}$ o $Y = \text{false}$.
Per $P(\varphi)$ non c'è alcuna informazione pregressa su Y, oltre agli esempi in Es. In tal caso i valori sono equiprobabili ossia φ ha una distribuzione uniforme su [0,1]. $P(\varphi \mid Es)$ può essere considerata come l'aggiornamento di φ dopo aver osservato gli esempi in Es:

$$P(\varphi \mid Es) \overset{Bayes}{=} \frac{P(Es \mid \varphi) \cdot P(\varphi)}{P(Es)} \overset{i.i.d.}{\propto} \varphi^{n_1} \cdot (1-\varphi)^{n_0} \cdot P(\varphi)$$

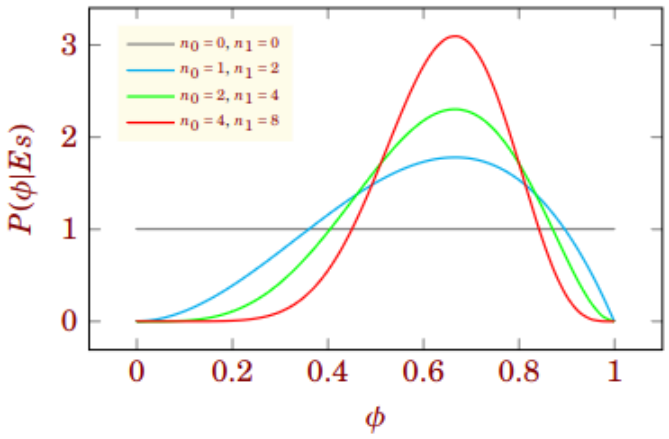
dove n_0 è il numero di esempi con $Y = \text{false}$ e n_1 quelli con $Y = \text{true}$.
Sia φ il parametro per la distribuzione di una variabile Y binaria. Si definisce la *distribuzione Beta* nel modo seguente:

$$\mathrm{B}_{\alpha_0,\alpha_1} = \frac{1}{Z}\varphi^{\alpha_1-1} \cdot (1-\varphi)^{\alpha_0-1}$$

ove:

- i parametri α_0 e α_1 sono conteggi iniziali, convenzionalmente si considerano $a_i = n_i + 1 \quad i \in \{0, 1\}$ e Z è una costante di normalizzazione;
- la sua *moda* (valore più probabile) risulta $\varphi = \frac{a_1-1}{a_0+a_1-2}$
- il suo *valore atteso* è $\varphi = \frac{a_1}{a_0+a_1}$, il che giustifica lo *smoothing di Laplace*.

Segue una figura che illustra la densità Beta al variare dei parametri.



La distribuzione di $P(\varphi)$ non è necessariamente uniforme. Tipicamente si ha che: $P(\varphi) = \varphi^{c_1 - 1} \cdot (1 - \varphi)^{c_0 - 1}$, come nel caso in cui si considerino c_1 *pseudo-esempi* con $Y = \text{true}$, e c_0 con $Y = \text{false}$.
Quindi, la distribuzione a posteriori è

$$P(\varphi \mid Es) \propto \varphi^{c_1 + n_1 - 1} \cdot (1 - \varphi)^{c_0 + n_0 - 1}$$

ossia mantiene la stessa forma di quella a priori. La stima MAP per φ è:

$$\hat{\varphi}_{MAP} = \frac{c_1 + n_1 - 1}{c_0 + n_0 + c_1 + n_1 - 2}$$

e il valore atteso è:

$$E[\varphi] = \frac{c_1 + n_1}{c_0 + n_0 + c_1 + n_1}$$

In caso si disponesse solo delle statistiche n_0 e n_1, queste possono corrispondere a sequenze diverse di esempi e si rocrre alla distrubuzione binomiale.

Variabili-obiettivo Categoriche
Nel caso di Y categorica, parametro con k valori, si considera la *distribuzione Dirichlet*, un'estensione della Beta a più dimensioni:

$$\text{Dirichlet}_{\alpha_1, ..., \alpha_k}(p_1, ..., p_k) = \frac{1}{Z} \prod_{j=1}^{k} p_j^{\alpha_j - 1}$$

dove gli $\alpha_j \geq 0$ sono i conteggi iniziali dei diversi valori $j = 1, ..., k$, e si considera in genere $\alpha_j = n_i + 1$ come un conteggio, p_j è la probabilità del j-esimo valore ($Y = y_j$) e Z è la costante di normalizzazione. Il *valore atteso* per il risultato i-esimo (mediando su tutti i p_j) sarà $\alpha_i / \sum_j \alpha_j$, con gli α_j tutti non-negativi e non tutti nulli.
Per predire un valore per Y, partendo da *pseudo-conteggi* $c_j > 0$ per ogni y_j (invece che da una distribuzione a priori uniforme) ottenuti prima di osservare dati (ossia $\forall j : n_j = 0$) considerata una Dirichlet anche quella a posteriori sarà Dirichlet e avendo osservato poi n_j esempi con $Y = y_j$, la probabilità di Y può essere stimata usando il *valore atteso*:

$$P(Y = y_j) = \frac{c_j + n_j}{\sum_h c_h + n_h}$$

Si noti che con pseudo-conteggi tutti unitari si ottiene il cosiddetto *smoothing di Laplace*.

Opinioni degli esperti

Gli pseudo-conteggi si possono ottenere *integrando* l'opinione di esperti con i dati a disposizione. Questa integrazione comporta le seguenti problematiche:

- la difficoltà nel dare *valori esatti* di probabilità non modificabili nel seguito;
- la rappresentazione dell'incertezza associata a una *stima* della probabilità;
- la *combinazione* di stime fatte da più esperti;
- l'*integrazione* tra *opinione* degli esperti e *dati* effettivi.

Una possibile *soluzione* è quella in cui le probabilità (numeri reali) provengano da conteggi (interi): invece di una stima di $P(A)$, l'esperto si limiterà a fornire $\langle n_A, m \rangle$, ossia il numero n_A occorrenze di un dato risultato A sulle m prove effettuate, una stima (non sempre credibile) delle *dimensioni* dei dati su cui fonda il parere.

10.2.2. Classificatori Probabilistici

Un **classificatore Bayesiano** è un modello probabilistico di classificazione per il quale la distribuzione *a posteriori* viene calcolata mediante la regola di Bayes.
L'idea di fondo è che la *classe* influenzi / predica i valori delle feature di input per le istanze che vi appartengono: gli esempi sono raggruppati in classi perché hanno valori comuni delle feature, per cui apprendendo le *dipendenze* delle feature dalla classe, si userà il modello risultante per predire la classificazione di nuove istanze.
Nel classificatore **Naive Bayes** (NB) si fa l'assunzione di *indipendenza condizionata* reciproca tra le feature X_i nota la classe Y. Questo caso può essere descritto da una semplice rete bayesiana con un nodo genitore relativo alla classe e nodi figli per ciascuna delle feature di input X_i (si veda la figura nel seguente esempio). Tale rete richiede la specifica delle distribuzioni $P(Y)$ per Y e $P(X_i \mid Y)$ per ogni X_i. Per predire la classe per un nuovo esempio si dovrà calcolare $P(Y \mid Xs)$, condizionando sui suoi valori osservati delle diverse X_i.
Nel caso di più variabili-obiettivo Y_j si possono apprendere di modelli separati.

$$
\begin{aligned}
P(Y \mid X_1 = v_1, ..., X_k = v_k) &\overset{\text{Bayes}}{=} \frac{P(X_1 = v_1, ..., X_k = v_k \mid Y) \cdot P(Y)}{P(X_1 = v_1, ..., X_k = v_k)} \\
&\overset{\text{indip.}}{=} \frac{P(X_1 = v_1 \mid Y) \cdot ... \cdot P(X_k = v_k \mid Y) \cdot P(Y)}{P(X_1 = v_1, ..., X_k = v_k)} \\
&= \frac{P(Y) \cdot \prod_{i=1}^{k} P(X_i = v_i \mid Y)}{\sum_Y P(Y \wedge (X_1 = v_1, ..., X_k = v_k))} \\
&\overset{\text{p.cong.+indip.}}{=} \frac{P(Y) \cdot \prod_{i=1}^{k} P(X_i = v_i \mid Y)}{\sum_Y P(Y) \cdot \prod_{i=1}^{k} P(X_i = v_i \mid Y)}
\end{aligned}
$$

Si noti come il denominatore funga da costante di normalizzazione.
Il modello NB è capace di trattare anche esempi con **dati mancanti** ossia con

valori non osservati per alcune X_i: si condiziona sulle feature osservate, facendo un'assunzione detta MAR, *Missing at Random*. Il NB risulta ottimale con X_i univa feature osservata: al crescere del numero di X_i osservate, l'accuratezza delle predizioni dipende dalla reciproca indipendenza delle X_i data Y.
Nel caso in cui Y sia booleana e siano X_i tutte osservate si ha un modello simile a quello di *regressione logistica (RegLog)*. Essi fanno le stesse predizioni quando per X_i il peso è $\omega_i = \log[P(X_i \mid h)/P(X_i \mid \neg h)]$. La differenza sta nel fatto che RegLog usa la DG per minimizzare la log-loss, quindi ha il punto debole di non essere non applicabile in caso di valori mancanti, mentre NB apprende i parametri della stima MAP, valida anche in caso di valori mancanti, ma con il punto debole dell'assunzione di indipendenza condizionata tra X_i data Y, spesso non giustificata.
Per apprendere un classificatore, ossia la distribuzione a posteriori $P(Y \mid \overline{x})$, serve determinare dai dati le distribuzioni $P(Y)$ e $P(X_i \mid Y)$ per ogni i. La stima di $P(X_i \mid Y)$ costituisce un sotto-problema di apprendimento, uno per ogni valore di Y.
Una soluzione semplice è quello data dalla stima ML nella quale si deve calcolare $P(X_i = x \mid Y = y)$ come proporizione empirica osservata nei dati di training, il rapporto tra numero dei casi in cui $X_i = x_i \wedge Y = y$ e quello dei casi in cui $Y = y$. Casi di *probabilità nulle* possono avere effetti indesiderati. Alcune feature diventano *molto predittive*: con un solo valore nullo si potrebbe escludere un'intera categoria, ma un insieme finito di dati potrebbe essere insufficiente a fornire l'evidenza necessaria per supportare una tale conclusione. Alcune combinazioni di osservazioni possono risultare impossibili: nel classificatore si avrebbe una divisione per zero. Il problema nasce dall'uso delle frequenze empiriche come stime di probabilità. Vi si può ovviare incorporando pseudo-conteggi da scegliere accuratamente.
In conclusione un classificatore NB risulta spesso efficace. Funziona bene quando l'assunzione di indipendenza è appropriata nel caso in esame.
Il modello NB può essere ampliato ammettendo estensioni in cui alcune X_i possano essere anche in nodi-genitori, mentre le altre rimangono figlie di Y: la probabilità della classificazione ati i genitori può essere rappresentata attraverso alberi di decisioni, funzioni lineari compresse oppure reti neurali.
In altre estensioni sono ammesse figlie di Y non necessariamente indipendenti:

- **Tree Augmented Naive-Bayes (TAN)** *network*: oltre alla classe possono avere un solo altro genitore (purchè il grafo resti aciclico), un modello semplice ed efficiente delle dipendenze tra X_i;
- **Latent Tree**: prevede uan struttura più complessa della Y, decomponibile in un numero di *variabili latenti* connesse ad albero, tale che ogni variabile osservata figlia di una variabile latente; si avrà così un modello della dipendenza tra variabili osservate.

10.2.3. Apprendimento MAP di Alberi di Decisione

Nell'apprendimento degli alberi di decisione serve un bias che tipicamente andrà a favorire alberi più piccoli e può essere imposto attraverso la scelta della distribuzione a priori.

Più alberi potranno adattarsi perfettamente ai dati, a meno di *rumore*. Ad esempio, se fra gli esempi di addestramento alcuni presentassero gli stessi valori delle X_i ma valori diversi per la Y oppure valori mancanti per qualche X_i, per ogni *assegnazione non osservata*, si possono adattare perfettamente all'insieme di training alberi che potranno fornire predizioni discordanti su esempi non visti. In tali casi, nessuno degli alberi che si adattano perfettamente al training set potrà risultare ottimale. Questa pùo essere conseguenza del *No Free Lunch Theorem* per il quale modelli apparentemente efficaci possono sempre rivelarsi peggiori su problemi ovvero data-set diversi. Conviene quindi tenere in considerazione anche alberi che si adattino meno perfettamente ai dati, sfruttando anche la *distribuzione a priori* dei modelli.

10.2.4. Lunghezza delle Descrizioni

In base al criterio MAP, si deve massimizzare $P(Es \mid m) \cdot P(m)$. Passando ai logaritmi e negando, la funzione da ottimizzare risulta:

$$(-\log_2(P(Es \mid m))) + (-\log_2(P(m)))$$

Questo obiettivo trova corrispondenza con la *Teoria dell'informazione*, in particolare con il criterio della **minima lunghezza di descrizione** (*minimum description length, MDL*): vanno preferiti i modelli che minimizzano la somma precedente dove, $-\log_2(P(Es \mid m))$ rappresenta il numero di bit per descrivere i dati Es, in base a m, e $-\log_2(P(m))$ è il numero di bit per descrivere m. Il *bit* è un'unità di misura che accomuna probabilità e complessità del modello.

Si può interpretare il modello ottimale per il criterio MDL come il più efficiente per la codifica e trasmissione dei dati: prima va comunicato il modello m e poi anche i dati, in termini di m. Essendo la funzione log monotona, il modello MAP coincide con quiello MDL.

La definizione esatta di una codifica ottimale risulta in genere difficile: spesso si ricorre a una misura approssimata della complessità del modello.

Si possono considerare:

- $|t|$, il numero di *parametri probabilistici*: per un albero $|t|$ = numero delle foglie; per una funzione lineare o una rete neurale $|t|$ = numero di parametri numerici;
- $|Es|$, numero dei esempi: ci sono al più $|Es| + 1$ diverse probabilità da distinguere nel modello quindi servono $\log_2(|Es| + 1) \approx \log_2(|Es|)$ bit.

Come approssimaszione della misura da minimizzare si può usare un indice detto **BIC** (*Bayesian information criterion*):

$$-\log_2(P(Es \mid m)) + |m| \cdot \log_2(|Es|)$$

10.3. Apprendimento non Supervisionato

Nell'**apprendimento non supervisionato** il training set non contiene valori per la feature-obiettivo. Si cercano o costruiscono pattern nei dati.
Ci sono diversi compiti di tipo non superivisionato. Un *obiettivo* può essere quello di costruire una classificazione naturale dei dati. Ciò sign ifica che la feature-obiettivo può essere considerata come variabile *latente* (i suoi valori non sono osservati).
Il metodo generale per ricostruire i valori della classificazione naturale è il **clustering**. Si partizionano gli esempi in **cluster**, le classi naturali, in modo tale che ogni cluster predica i valori delle feature per gli esempi in esso contenuti. Per ogni partizionamento dei dati si può calcolare il relativo *errore di predizione*, quindi si deve trovare il clustering migliore minimizzando tale errore.
Si distinguono l'**hard clustering** in cui ogni esempio viene assegnato a un cluster preciso e il **soft clustering** che calcola una distribuzione di appartenenza degli esempi ai cluster: la predizione dei valori delle feature di un esempio si può ottenere come *media ponderata* delle predizioni per cluster, pesata attraverso la distribuzione trovata.

10.3.1. Hard Clustering

K-Means è un classico algoritmo per l'hard clustering. Esso richiede in input le istanze di training e il numero k di cluster da cercare. Nel seguito si assumerà che il dominio di ogni feature sia *numerico*, ossia con differenze tra valori significative.
L'algortimo produce come output i k cluster, ovvero una funzione per l'assegnazione delle istanze ai cluster. A ogni cluster è associato un indice intero $c \in \{1, ..., k\}$. Ogni cluster sarà rappresentato da un vettore medio, o *prototipo* del cluster, che conterrà la predizione del valore di ogni feature.
Dato l'insieme di training Es con istanze descritte dalle feature $X_1, ..., X_n$, si indicherà con $X_{j(e)}$ il valore osservato di X_j per l'istanza $e \in Es$: si assume che tali valori siano osservati direttamente.
Essenzialmente K-Means costruisce una funzione $\text{cluster} : Es \to \{1, ..., k\}$ tale che $\text{cluster}(e) = c$ indica che e appartiene al cluster di indice c. Per fare questo si basa su una funzione $\text{pred}(j, c)$ che restituisce il valore di X_j per il cluster di indice c: $\text{pred}(j, c)$ sarà il valore di X_j predetto per ogni sua istanza. Si noti che uno stesso valore viene predetto per ogni e del suo cluster quindi, il valore di X_j per il prototipo del suo clusetr sarà $\text{pred}(j, \text{cluster}(e))$.
L'obiettivo dell'algoritmo è quindi quello di trovare cluster e pred ottimali, ossia che minimizzano la somma delle **loss**:

$$\sum_{e \in Es} \sum_{j=1}^{n} \left[\text{pred}(j, \text{cluster}(e)) - X_{j(e)}\right]^2$$

La predizione per un cluster verrà calcolata come media delle predizioni delle sue istanze.
Una soluzione ottimale ottenuta da una ricerca tra tute le possibili assegnazioni delle istanze ai k cluster che minimizzano l'errore è NP-hard, proponibile solo in caso di pochi esempi. Con molte istanze, invece, ci saranno moltissime k-partizioni possibili e una ricerca esaustiva non risulta praticabile.
L'algoritmo K-Means è capace, iterativamente, di abbassare via via la loss quadratica per trovare un punto di minimo. Esso può essere schematizzato come segue:

- Inializzare casualmente le assegnazioni delle istanze ai cluster;
- Ripeter fino a un'assegnazione stabile:
  1. Per ogni feature X_j e ogni cluster c, definire $\text{pred}(j, c)$ con il valore medio di $X_{j(e)}$ per ogni e nel cluster c:

$$\text{pred}(j, c) \leftarrow \frac{1}{|\{e : \text{cluster}(e) = c\}|} \left(\sum_{e:\ \text{cluster(e)}=c} X_{j(e)} \right)$$

  2. Ridefinire *cluster* riassegnando ogni istanza e al cluster di indice c che minimizzi la loss:

$$\sum_{j=1}^{n} \left[\text{pred}(j, c) - X_{j(e)} \right]^2$$

L'algoritmo converge quando nno si hanno cambiamenti nelle assegnazioni.

ALGORITMO 31 — *k-Means*

```
1:  procedure k-means(Xs, Es, k)
2:  Input
3:      Xs insieme di feature, Xs = {X_1, ..., X_n}
4:      Es insieme di istanze di training
5:      k numero di cluster
6:  Output
7:      cluster: funzione dalle istanze ai cluster
8:      pred: funzione dalle coppie feature-cluster ai valori delle feature per i cluster
9:  Local
10:     integer cc[c], cc'[c] { contatori per il cluster c }
11:     real fs[j, c], fs'[j, c] { somme valori di X_j per il cluster c }
12:     Boolean stabile
13: Inizializzare fs e cc in base ai dati o casualmente
14: define pred[j, c] = fs[j,c]/c c[c] { stima di pred(j, c) }
15: define cluster[e] = arg min_{c∈{1,...,k}} Σ_{j=1}^{n} (pred[j, c] − X_{j(e)})^2
16: repeat
```

```
    azzerare fs' e cc'
    for each e ∈ Es do
        c ← cluster[e]
        cc'[c] ← cc'[c] + 1
        for each X_j ∈ Xs do
            fs'[j, c] ← fs'[j, c] + X_{j(e)}
    stabile ← (fs' = fs) ∧ (cc' = cc)
    fs ← fs'
    cc ← cc'
until stabile
return cluster, pred
```

Esso converge verso un minimi locale stabile: l'errore tende a ridursi mentre c'è solo un numero finito di possibili riassegnazioni. Spesso bastano poche iterate.
Le statistiche sufficienti a calcolare la media di ogni cluster sono $cc[c]$, il numero di esempi nel cluster c, e $fs[j, c]$, la frequenza del valore $X_{j(e)}$ per gli esempi nel cluster c; per calcolare $\text{pred}(j, c)$, stima più recente di $\text{pred}(j, c)$ in $\text{cluster}(e)$, si usano i valori correnti di *fs* e *cc* per determinare i successivi, *fs'* e *cc'*.
Nell'inizializzazione l'assegnazione casuale degli esempi ai cluster si possono selezionare a caso k esempi come prototipi dei cluster oppure si possono calcolare le statistiche sufficienti iniziali su pochi esempi, evitando così un passaggio sull'intero dataset.
Si raggiunge la stabilità del partizionam,ento quando le assegnazioni di *cluster* e quindi *fs* e *cc*, non cambiano: ciò richiede che *argmin* si comporti in modo coerente per ogni esempio nei casi in cui più di un cluster minimizzi l'errore.
Ottenute diverse assegnazioni stabili da più esecuzioni si può scegliere il partizionamento migliore confrontandoli in termini dell'errore.
È importante notare la sensibilità dell'errore alle diverse scale delle feature. Pertanto conviene lavorare su valori preventivamente *riscalati* per poter essere poi confrontati.
È importante anche la scala dell'iper-parametro k che dovrebbe rappresentare un compormesso fra complessità e adattamento ai dati. È possibile usare il BIC score, la ricerca del *gomito* nella curva dell'errore al variare dei diversi valori di k: curva decrescente al crescere di k. Il valore naturale per k sarebbe quello con maggiore riduzione dell'errore rispetto a $k-1$. Si noti che il clustering ottimale per k può spesso risultare molto diverso da quello ottimale per $k+1$.

10.3.2. Soft Clustering

I classificatori bayesiano possono costituire una base per l'*apprendimento non supervisionato* se si considera la classe come variabile *latente*, ossia non osservata.
L'algoritmo **Expectation Maximization (EM)** consente di apprendere modelli

probabilistici con variabili latenti, quindi può essere utilizzato per problemi di *soft clustering* se combinato con un classificatore probabilistico come NB. Il suo schema è analogo a quello di K-Means, con gli stessi argomenti in input, l'insieme di esempi *Es* e il numero di cluster k, ma gli esempi saranno assegnati ai cluster in senso probabilistico.
Dato *Es*, EM costruisce un modello NB con un nodo genitore con la variabile latente C che indicherà la classe, quindi con dominio $\{1, ..., k\}$, e come nodi figli uno per ogni feature X_i osservatata nei dati in *Es*. Si devono apprendere le distribuzioni $P(C), P(X_i \mid C)$ che si adattino meglio a *Es*.
Rispetto a K-Means si può considerare l'estensione della tabella dati con due colonne: una colonna C per la classe, ogni esempio originario replicato per k righe della tabella, una per classe; una colonna *Cont* per il contatore normalizzato, con le k assegnazioni dell'esempio alle classi di C, che insieme rappresentano la distribuzione $P(C \mid e)$.
Iterativamente, EM ricalcola i conteggi dal modello e poi il modello dai conteggi.

Esempio 102. Problema con $k = 3$ classi:

X_1	X_2	X_3	X_4	C	*Cont*
vd	vd	vd	vd	vd	vd
t	f	t	t	1	.4
t	f	t	t	2	.1
t	f	t	t	3	.5
vd	vd	vd	vd	vd	vd

$\leftarrow$ E
M $\rightarrow$

$P(C)$
$P(X_1 \mid C)$
$P(X_2 \mid C)$
$P(X_3 \mid C)$
$P(X_4 \mid C)$

I passi dell'algoritmo sono i seguenti.

- **Expectation**: aggiorna *Cont* in base alle distribuzioni correnti del modello
  - per ogni esempio originario $\langle X_1 = v_1, ..., X_n = v_n \rangle$, e per ogni classe $c = 1, ..., k$, il contatore associato a $\langle X_1 = v_1, ..., X_n = v_n, C = c \rangle$ viene aggiornato con $P(C = c \mid X_1 = v_1, ..., X_n = v_n)$;
  - il valore atteso va calcolato tramite inferenza probabilistica;
- **Maximization**: inferisce le probabilità del modello dagli esempi estesi
  - in tabella: esempi completi con valori per tutte le variabili, come nell'apprendimento supervisionato di probabilità;
  - per la stima delle probabilità del modello si considera la massimizzazione ML (o MAP).

EM parte con distribuzioni o conteggi casuali e punta a convergere a un massimo locale della likelihood dei dati fornendo come output un modello probabilistico, utile anche a classificare nuovi esempi:

$$P(C = c \mid X_1 = v_1, ..., X_n = v_n) = \frac{P(C = c) \cdot \prod_{i=1}^{n} P(X_i = v_i \mid C = c)}{\sum_{c'} P(C = c') \cdot \prod_{i=1}^{n} P(X_i = v_i \mid C = c')}$$

Per il calcolo delle probabilità tramite statistiche sufficienti

- a ogni iterata, si calcolano dai dati:
  - cc: *contatori-classe*, vettore k-dimensionale, con $cc[c]$ somma dei contatori degli esempi per la classe c nella tabella dei dati estesa;
  - fc: *contatori-feature*, matrice tridimensionale in cui per i tra 1 ed n, per ogni $v \in \text{dom}(X_i)$ e ogni classe c : $fc[i, v, c]$ è la somma dei contatori per ogni esempio t per c;
  - le statistiche sono usate per derivare quelle dell'iterata successiva; si noti che cc può essere anche calcolato da fc, ma è più comodo tenere un contatore separato;
- la stima delle probabilità può essere fatta in base a cc e fc: $P(C = c) = cc[c]/|Es|$, con $|Es|$ numero di esempi nel dataset originario, o somma dei conteggi in quello esteso. Inoltre $P(X_i = v \mid C = c) = fc[i, v, c]/cc[c]$.

ALGORITMO 32 — *EM*

```
1:  procedure EM(Xs, Es, k)
2:  Input
3:      Xs insieme di feature, Xs = {X_1, ..., X_n}
4:      Es insieme di esempi di training
5:      k numero di classi
6:  Output
7:      statistiche sufficienti per il modello probabilistico su Xs
8:  Local
9:      real cc[c], cc'[c] { conteggi di classe/cluster vecchi e nuovi }
10:     real fc[i, v, c], fc'[i, v, c] { conteggi di feature vecchi e nuovi }
11:     real dc { distribuzione per esempio e classe/cluster corrente }
12:     Boolean stabile
13: repeat
14:     azzerare cc'[c] e fc'[i, v, c]
15:     for each (v_1, ..., v_n) ∈ Es do
16:         for each c ∈ [1, k] do
17:             dc ← P(C = c | X_1 = v_1, ..., X_n = v_n) { dai conteggi }
18:             cc'[c] ← cc'[c] + dc
19:             for each i ∈ [1, n] do
20:                 fc'[i, v_i, c] ← fc'[i, v_i, c] + dc
21:     stabile ← (cc ≈ cc') ∧ (fc ≈ fc')
22:     cc ← cc'
```

```
    fc ← fc′
until stabile
return cc, fc
```

Si osservi che per valutare dc, ossia $P(C = c \mid X_1 = v_1, ..., X_n = v_n)$, ci si basa su cc ed fc.
Per l'inizializzazione si può partire con una distribuzione casuale poi si calcolano i conteggi dai dati. In alternativa si possono considerare conteggi casuali prima di vedere i dati.
Si raggiunge la convergenza quando cc e fc cambiano poco in una data iterata. La soglia può essere regolata trovando un compromesso tra accuratezza e velocità. In alternativa si può considerare un numero fissato di iterazioni.
Si noti la similarità con K-Means: il passo E assegna gli esempi alle classi mentre il passo M determina quanto viene predetto dalle classi.
Un problema tipico è che EM ha pressoché sempre massimi locali e globali multiplis: con qualsiasi permutazione delle etichette delle classi stesse probabilità. Per trovare il massimo globale si possono effettuare più restart e infine scegliere il modello con log-likelihood massima.

10.4. Apprendimento di Reti Bayesiane

Una rete bayesiano definisce una distribuzione su un insieme di variabili. Dato che è difficile per un esperto fornire modelli accurati da codificare come rete bayesiana, si può cercare di imparare la rete da dati disponibili.
La complessità di tale problema dipende dalla disponibilità di conoscenza a priori sulla struttura e sulle variabili coinvolte e dalla completezza del dataset disponibile.
L'*obiettivo* dell'apprendimento della rete bayesiana varia dal caso più semplice in cui la struttura è nota e tutte le variabili note e osservabili, disponendo di un dataset completo, fino al caso più difficile in cui la struttura non è data, le variabili non siano tutte note e il dataset sia incompleto, ovvero ci siano dati mancanti.
L'*obiettivo* si riduce a imparare, per ogni X_i, la distribuzione condizionata $P(X_i \mid \text{gen}(X_i))$. Questo si può vedere come un problema di apprendimento *supervisionato* con feature-target X_i e feature di input $\text{gen}(X_i)$.
Essendo, solitamente, i genitori in numero limitato ogni probabilità potrà essere appresa separatamente sfruttando gli esempi di training e altra conoscenza a priori comunicata dagli esperti, come ad esempio pseudo-conteggi che migliorano la stima delle probabilità.

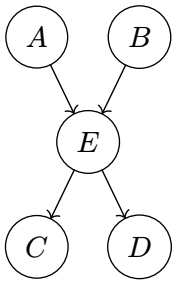
Esempio 103.

Tipica istanza del caso semplice (variabili booleane):

Dati

A	B	C	D	E
t	f	t	t	f
f	t	t	t	t
t	t	f	t	f
⋮	⋮	⋮	⋮	⋮

Modello



$\rightarrow$ *Probabilità*

$P(A)$
$P(B)$
$P(E \mid A, B)$
$P(C \mid E)$
$P(D \mid E)$

Ad esempio, nel determinare $P(E \mid A, B)$:

$$P(E = t \mid A = t \wedge B = f) = \frac{n_t + c_t}{n_f + n_t + c_f + c_t}$$

dove:

- n_t è il numero di casi in cui $E = t \wedge A = t \wedge B = f$ con $c_t \geq 0$ pseudo-conteggio corrispondente, noto prima di osservare i dati;
- n_f è numero di casi in cui $E = f \wedge A = t \wedge B = f$ con $c_f \geq 0$ pseudo-conteggio corrispondente.

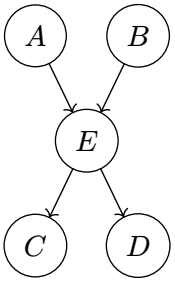
10.4.1. Variabili Latenti

Un caso un po' più difficile è quello in cui il modello contenga anche variabili latenti ossia variabili i cui valori non siano osservabili per nessun esempio. Nella tabella dei dati non ci saranno colonne per tali variabili. Senza queste variabili nel modello aumentano i paraemtri per cui si hanno maggiori rischi di sovradattamento. Ad esempio escludendo la variabile E dal modello precedente occorrerebbe determinare le distribuzioni $P(A), P(B), P(C \mid A, B), P(D \mid A, B, C)$, passando quindi da 10 a 14 parametri.

Esempio 104.

BN con E variabile *nascosta*:

Modello



Dati

A	B	C	D
t	f	t	t
f	t	t	t
t	t	f	t
⋮	⋮	⋮	⋮

$\rightarrow$

Probabilità

$P(A)$
$P(B)$
$P(E \mid A, B)$
$P(C \mid E)$
$P(D \mid E)$

L'*obiettivo* sarà quello di apprendere i parametri del modello, ossia 10 valori di probabilità nelle diverse distribuzioni.

Per imparare le probabilità di BN con variabili latenti si può usare EM:
- nel passo E, tramite inferenza probabilistica, per ogni esempio, si deriva la distribuzione delle variabili latenti, date quelle osservate;
- nel passo M, si deriva le probabilità del modello dei dati estesi, come visto in precedenza.

Esempio 105. Continuando il caso precedente:

A	B	C	D	E	$Cont$
⋮	⋮	⋮	⋮	⋮	⋮
t	f	t	t	t	.71
t	f	t	t	f	.29
f	f	t	t	f	4.2
⋮	⋮	⋮	⋮	⋮	⋮
f	t	t	t	f	2.3

$\leftarrow$ E
M $\rightarrow$

$P(A)$
$P(B)$
$P(E \mid A, B)$
$P(C \mid E)$
$P(D \mid E)$

- E calcola $P(E \mid A, B, C, D)$ per ogni esempio;
- M impara le probabilità dai dati completi.

10.4.2. Dati Mancanti

Oltre al caso delle variabili latenti, i dati potrebbero risultare incompleti per altre cause. Ci potrebbero essere valori mancanti per alcune variabili in qualche tupla.
Serve cautela nel trattamento di tali esempi: la mancanxas potrebbe non essere casuale ma risultare correlata con il fenomeno d'interesse.
Nel caso più semplice vi sono valori mancanti per variabili categoriche senza genitori da interrogare. Per poter interrogare altre variabili, la distribuzione potrebbe essere modellata aggiungendo il valore *missing* al dominio delle variabili con valori mancanti oppure considerando una variabile indicatrice binaria per ogni valore del dominio della variabile: con 0 a indicare un valore mancante nelle variabili indicatrici.

Esempio 106 *(Fornitura volontaria dei dati personali)* **.** Se non si hanno sorelle o fratelli, si tende a non dichiararlo. Inoltre si tende a non menzionare problemi o patologie di cui non si soffre, ad esempio l'ansia. È più facile che si indichino altre problematiche di cui si soffre.
Si pensi a un modello di regressione logistica riguardante la *paura di isolamento* (variabile-target F) in dipendenza del fatto di avere sorelle o fratelli (variabile S booleana) e dell'essere ansiosi ansietà (variabile A booleana):

$$P(F) = \text{sigmoide}\big(w_0 + w_1 \cdot S_t + w_2 \cdot S_f + w_3 \cdot A_t + w_4 \cdot A_f\big)$$

dove S_t, S_f, A_t, A_f sono tutte variabili indicatrici (binarie) con $S_t = 1$ se S è vera, $S_f = 1$ se S è falsa, ed entrambe nulle se il valore è mancante (analogamente per A_t e A_f). Il bias w_0 rappresenterebbe il valore per il caso di valore mancante per entrambe le variabili S e A.

I casi di dati mancanti non vanno ignorati. Si può ricorrere ai modelli casuali.

10.4.3. Apprendimento della Struttura

Si supponga di conoscere le variabili della rete da costruire e che nessuna sia latente ma non si conosca la *struttura*, disponendo però di un dataset completo.
In tal caso gli approcci principali all'**apprendimento della struttura** sono i seguenti:

- si definisce la struttura in termini di *indipendenza condizionata*: dato un *ordinamento totale* delle variabili, occorre determinare i sottoinsiemi $\text{gen}(\cdot)$ di predecessori in base a relazioni di *indipendenza condizionata* quindi occorre prima determinare il *miglior* ordinamento totale e in seguito verificare l'effettiva indipendenza, il che risulta difficile a causa della limitatezza dei dati disponibili.
- si conduce una ricerca basata su una misura di *valutazione* (*score*) delle diverse reti con l'obiettivo di trovare una struttura che minimizzi l'errore, ad esempio usando una misura basata sul criterio MAP, quindi facendo un compromesso tra adattamento ai dati e complessità.

Assumendo la disponibilità di un dataset di esempi Es completo, si punta a trovare un modello m che massimizzi:

$$P(m \mid Es) \propto P(Es \mid m) \cdot P(m)$$

con $P(Es \mid m)$ calcolabile como prodotto delle probabilità per ogni esempio, ulteriormente fattorizzabili in ragione delle distribuzioni di ogni X_i dati i genitori $\text{par}(X_i, m)$ in m:

$$\begin{aligned} P(Es \mid m) \cdot P(m) &= \left(\prod_{e \in Es} P(e \mid m) \right) \cdot P(m) \\ &= \left(\prod_{e \in Es} \prod_{X_i} P_m^e(X_i \mid \text{par}(X_i, m)) \right) \cdot P(m) \end{aligned}$$

dove $P_m^e(\cdot)$ distribuzione relativa a e secondo m.
Passando ai logaritmi si può scrivere:

$$\log P(Es \mid m) + \log P(m) = \left(\sum_{e \in Es} \sum_{X_i} \log P_m^e(X_i \mid par(X_i, m)) \right) + \log P(m)$$

$$\overset{(*)}{=} \left(\sum_{e \in Es} \sum_{X_i} \log P_m^e(X_i \mid par(X_i, m)) \right) + \sum_{X_i} \log P(m(X_i))$$

$$= \sum_{X_i} \left(\sum_{e \in Es} \log P_m^e(X_i \mid par(X_i, m)) \right) + \sum_{X_i} \log P(m(X_i))$$

$$= \sum_{X_i} \left(\sum_{e \in Es} \log P_m^e(X_i \mid par(X_i, m)) + \log P(m(X_i)) \right)$$

dove in (*) si assume che si possa fattorizzare $P(m) = \prod_i P(m(X_i))$ con $m(X_i)$ modello locale per X_i.
L'obiettivo finale diventa:

in cui ogni variabile può essere ottimizzata separatamente purchè si mantenga la rete aciclica: va trovato un buon ordinamento ttoale sulle variabili tramite ricerca locale o branch-and-bound. Risultano diversi problemi supervisionati indipendenti da risolvere determinando per ogni variabile le distribuzioni $P_m^e(X_i \mid \text{par}(X_i, m))$ e una possibile approssimazione di $\log(P(m(X_i)))$, ad esempio usando il BIC.

10.4.4. Caso Generale

Se la struttura non è data, alcune variabili sono latenti e vi sono anche dati mancanti ci sono diversi problemi da risolvere: oltre a quello dei dati macanti c'è la complessità computazionale data dalla ricerca in uno spazio circoscritto ma troppo esteso per pensare di testare tutte le combinazioni possibili di ordinamenti e variabili latenti, anche laddove si considerino solo variabili latenti che semplifichino il modello. Lo spazio sarà finito ma è troppo vasto.
Possibili soluzioni a tali problemi sono la selezione del miglior modello, ad esempio adottando il criterio MAP oppure effettuare predizioni mediando su tutti i modelli. Questa seconda soluzione fornisce in genere prestazioni migliori ma risultà più difficile da spiegare/giustificare.