Reti di calcolatori

Alessandro Carella

Indice

1. Reti di calcolatori e Internet 5
   1.1. Storia di Internet 5
   1.2. Gli «ingranaggi» di Internet 5
      1.2.1. I protocolli 6
   1.3. I componenti della rete 6
      1.3.1. Le reti di acceso 6
   1.4. Il nucleo della rete 6
      1.4.1. Commutazione di pacchetto 6
      1.4.2. Commutazione di circuito 7
      1.4.3. Una rete di reti 9
   1.5. Tipi di reti 9
   1.6. Ritardi, perdite e throughput nelle reti a commutazione di pacchetto . . 10
      1.6.1. Ritardo nelle reti a commutazione di pacchetto 10
2. Architetture a livelli 11
   2.1. Stratificazione dei protocolli 11
   2.2. Incapsulamento 14
3. Livello di applicazione 14
   3.1. Web e HTTP 14
      3.1.1. Architettura del Browser e del Server 15
      3.1.2. Differenza tra URI, URN e URL 15
      3.1.3. Panoramica di HTTP 15
      3.1.4. HTTP/1 16
      3.1.5. Connessioni persistenti e non persistenti 17
      3.1.6. Formato dei messaggi HTTP 18
      3.1.7. Interazione utente-server: i cookie 21
      3.1.8. Web caching 22
      3.1.9. HTTP/2 23
      3.1.10. HTTP/3 23
      3.1.11. Streaming video e reti per la distribuzione di contenuti 24
   3.2. DNS: il servizio directory di Internet 28
      3.2.1. Servizi forniti da DNS 28
      3.2.2. Panoramica del funzionamento di DNS 30
      3.2.3. Record e messaggi DNS 33
      3.2.4. Registrazione di un dominio e Zone Transfer 35
4. Livello di Trasporto 36
   4.1. Introduzione e servizi a lviello di trasporto 36

4.1.1. Relazione tra i livello di trasporto e di rete 36
4.1.2. Panoramica del livello di trasporto di Internet 37
4.2. Multiplexing e demultiplexing 37
4.2.1. Multiplexing e demultiplexing non orientati alla connessione ... 39
4.2.2. Multiplexing e demultiplexing orientati alla connessione 40
4.3. Trasporto non orientato alla connessione: UDP 41
4.3.1. Struttura dei segmenti UDP 42
4.3.2. Checksum UDP 43
4.4. Trasporto orientato alla connessione: TCP 44
4.4.1. Connessione TCP 45
4.4.2. Struttura dei segmenti TCP 46
4.4.3. Timeout e stima del tempo di andata e ritorno (RTT) 49
4.4.4. Trasferimento dati affidabile 50
4.4.5. Controllo di flusso 56
4.4.6. Gestione della connessione TCP 57
4.4.7. Controllo di congestione TCP 60
4.4.8. Notifica esplicita di congestione dalla rete 65
4.4.9. Fairness 65
4.5. QUIC: Quick UDP Internet Connection 66
5. Livello di rete: il piano dei dati 67
5.1. Panoramica del livello di rete 67
5.1.1. Inoltro e instradamento: piano dei dati e piano di controllo 68
5.1.2. Modelli di servizio del livello di rete 70
5.2. Panoramica sui router 71
5.2.1. Elaborazione alle porte di ingresso e inoltro basato sull'indirizzo di destinazione 73
5.2.2. Struttura di commutazione (switching) 75
5.2.3. Elaborazione alle porte di uscita 76
5.2.4. Problema dell'accodamento 77
5.2.5. Schedulazione dei pacchetti 79
5.3. Il protocollo Internet (IP) 81
5.3.1. Formato dei datagrammi IPv4 82
5.3.2. Indirizzamento IPv4 84
5.3.3. NAT (Network Address Translation) 92
5.3.4. IPv6 94
5.3.5. Passaggio DA IPv4 A IPv6 97
5.4. Inoltro generalizzato e SDN 99
5.4.1. Match 100
5.4.2. Action 101
6. Livello di rete: il piano di controllo 102

6.1. Algoritmi di instradamento 103
6.1.1. Instradamento link-state (LS) 105
6.1.2. Instradamento distance-vector (DV) 108
6.2. Instradamento interno ai sistemi autonomi: OSPF 114
6.3. Instradamento fra ISP: BGP 116
6.3.1. Il ruolo di BGP 117
6.3.2. Distribuzione delle informazioni dei percorsi in BGP 117
6.3.3. Formato dei pacchetti BGP 119
6.3.4. Selezione delle rotte migliori 120
6.3.5. Anycast IP 122
6.3.6. Politiche di instradamento 123
6.4. ICMP (Internet Control Message Protocol) 124

Reti di calcolatori e Internet

1.1. Storia di Internet

1.2. Gli «ingranaggi» di Internet

Internet è una rete di calcolatori che interconnette miliardi di dispositivi di calcolo in tutto il mondo. Spesso ci si connette a Internet tramite smartphone e tablet, anche se, oggi, molti più dispositivi come TV, console di gicoo, automobili, elettrodomestici, ecc. vengono via via connesse. Tutti questi dispositivi sono detti **host** o **sistemi periferici** (*end systems*). I sistemi periferici sono connessi tra loro tramite una **rete di collegamenti** (*communication link*) e **commutatori di pacchetti** (*packet switch*). I collegamenti possono essere di molti tipi, costituiti da varie tipologie di mezzi fisici, come cavi coassiali. fili di rame, fibre ottiche, ecc. Collegamenti diversi trasmettono dati a velocità differenenti, e tale **velocità di trasmissione** viene misurata in but/secondo (bps). Quando un host vuole inviare dati a un altro sistema periferico, suddivide i dati in sottoparti e aggiunge un'intestazione a ciascune di esse: l'insieme delle informazioni risultati, viene chiamato **pacchetto**. Un commutatore di pacchetto prende un pacchetto che arriva da uno dei collegamenti in ingresso e lo ritrasmette su uno di quelli in uscita. I princiapli commutatori di pacchetto sono i **router** e i **commutatori a livello di collegamento** (*link-layer switch*). Dal sistema di invio a quello di ricezione, la sequenza di collegamenti e di commuttatori di pacchetto attraversata dal singolo pacchetto è nota come **percorso** (*route* o *path*) attraverso la rete.
I sistemi perferici accedono a Internet tramite i cosiddetti **Internet Service Provider (ISP)**. Un provider è un insieme di commutatori di pacchetto e di collegamenti. GLi ISP forniscono agli host svariati tipi di acceso alla rete, tra cui quello residenziale a larga banda come la DSL, quello in rete locale ad alta velocità e quello wireless.
Sistemi perferici, commutatori di pacchetto e altre parti di Internet fanno uso di protocolli che controllano l'invio e la ricezione di informazioni all'interno della rete. Due dei principali protocolli Internet sono il **Transmission Control Protocol (TCP)** e l'**Internet Protocol (IP)**. Quyest'ultimo specifica il formato dei pacchetti scambiati tra router e sistemi periferici. I principali protocolli Internet sono noti con il nome collettivo di **TCP/IP**.

1.2.1. I protocolli

Diamo una definizione specifica di un protocollo di rete.

> **Definizione 1** *(Protocollo di rete)* **.** Un **protocollo** di rete definisce il formato e l'ordine dei messaggi scambiati tra due o più entità in comunicazione, così come le azioni intrapese in fase di trasmissione e/o di ricezione di un messaggio o di un altro evento.

Internet, e le reti di calcolatori in generale, fanno un uso estensivo di protocolli. Si impiegano protocolli differenti per realizzare compiti diversi.

1.3. I componenti della rete

Precedentemente abbiamo visto che nelle reti di calcolatori, i calcolatori e gli atri dispositivi connessi a Internet sono detti **sistemi periferici** o **end system**, in quanto si trovano ai confini di Internet.
I sistemi periferici vengono anche detti **host** quando ospitano programmi applicativi quali browser, web browser o software di lettura e getsione della posta elettronica. Gli host, inoltre, vengono suddivisi in due categorie: **client** e **server**. I client sono host che richiedono servizi e tendono ad essere PC, laptop, smartphon e cosi via, mentre i server si occupano di erogare dei servizi e sono sostanzialmente macchine più potenti che memorizzano e distribuiscono pagine web o flussi video, ritrasmettono la posta elettronica e così via.

1.3.1. Le reti di acceso

Esaminiamo ora le **reti di access**, detti *access network*, cioè la rete che connette fisicamente un sistema al suo **edge router**, che è il primo router sul percorso dal sistema d'origine a un qualsiasi altro sistema di desetinazione collocato al di fuori della stessa rete di accesso.

1.4. Il nucleo della rete

Esaminati i confini di Internet, approfondiamo il nucleo della rete: una maglia di commutatori di pacchetti e collegamenti che interconnettono i sistemi periferici di Internet.

1.4.1. Commutazione di pacchetto

Le applicazioni distribuite scambiano **messaggi** che possono contenere qualsiasi cosa il progettista del protocollo desideri. Possono svolgere una funzione di controllo o contenere dati come in un messaggio di posta elettronica, un'immagine JPEG o un file audio. La sorgente suddivide i messaggi lunghi in parti più piccole note come **pacchetti**. Tra la sorgente e la destinazione, questi pacchetti viaggiano attraverso

collegamenti e **commutatori di pacchetto**. I pacchetti vengono trasmessi su ciascun collegamento a una velocità pari alla velocità totale di trasmissione del collegamento stesso.

1.4.2. Commutazione di circuito

Per spostare i dati in una rete di collegamenti e commutatori esistono due approcci fondamentali: la **commutazione di circuito** e la **commutazione di pacchetto**. Nelle reti a commutazione di circuito le risorse richieste lungo un perocrso per consentire la comunicazione tra sistemi periferici sono riservate per l'intera durata della sessione di comunicazione. Nelle reti a commutazioni di pacchetto, tali risorse non sono riservate; i messaggi di una sessione utilizzano le risorse quando necessario, e di conseguenza potrebbero dover attendere per accedere a un collegamento.
Le reti telefoniche sono esempi di reti a commutazione di circuito. Si consideri che cosa avviene quando una persona vuole inviare informaizoni a un altro soggetto. Prima che possa iniziare l'invio, la rete deve stabilire una connessione tra mittente e destinatario. Questo è un collegamento «a regola d'arte» in cui i commutatori sul percorso tra mittente e destinatario mantegono lo stato della connessione per tutta la durata della comunicazione. Nel gergo della telefonia questa connessione è detta **circuito**.

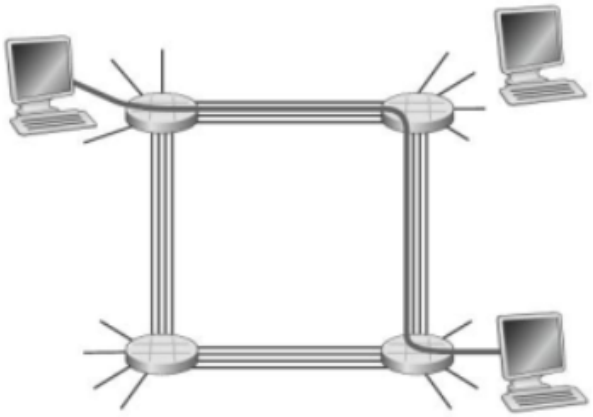
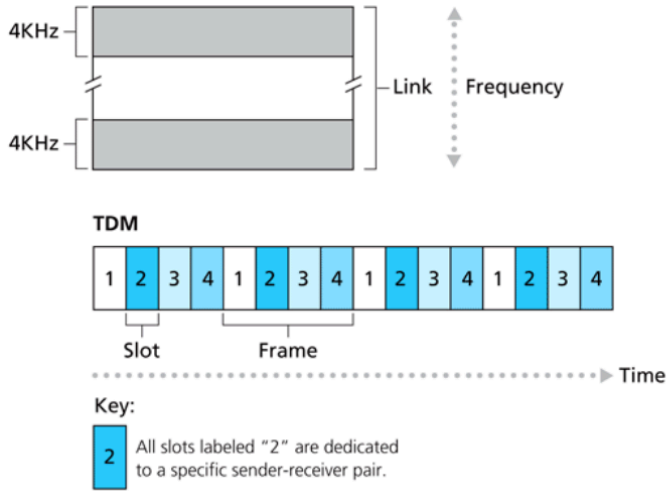


Figura 1: Rete a commutazione di circuito

La Figura 1 mostra una rete a commutazione di circuito in cui i quattro commutatori sono interconnessi tramite quattro colegamenti. Gli host sono tutti direttamente connessi a uno dei commutatori. Quando due host desiderano comunicare le rete stabilisce una **connessione end-to-end** dedicata a loro. Affinchè A invii messaggi a B, la rete deve prima riservare un circuito su ciascuno dei due collegamenti.
Si consideri invece che cosa accade quando un host invia un pacchetto a un altro host su una rete a commutazione di pacchetto, quale è Internet. Come nella commutazione a circuito, il pacchetto viene trasmesso su di una sequenza di collegamenti

ma, a differenza della commutazione di circuito, il pacchetto viene immesso nella rete senza che vengano riservate risorse. Se un collegamento è congestionato perchè vi sono altri pacchetti che devono essere trasmessi nello stesso istante, allora dovrà aspettare nel buffer del lato mittente e subire un ritardo.

Multiplexing nelle reti a commutazione di circuito
Un circuito all'interno di un collegamento è implementato tramite **multiplexing a divisione di frequenza (FDM, *frequency-division multiplexing*)** o **multiplexing a divisione di tempo (TDM, *time_division multiplexing*)**. Con FDM, lo spettro di frequenza di un collegamento viene suddiviso tra le connessioni stabilite tramite il collegamento. Nello specifico, il collegamento dedica una banda di frequenza a ciascun connessione per la durata della connessione stessa. La larghezza della banda viene detta **ampiezza di banda** o *bandwidth*.
Per un collegamento TDM il tempo viene suddiviso in frame di durata fissa, a lroo volta ripartiti in un numero fisso di slot temporali. Quando la rete stabilisce una connessione attraverso un collegamento, le dedica uno slot di tempo in ogni frame. Tali slot sono dedicati unicamente a quella connessione, con uno slot temporale disponibile in ciascun frame alla trasmissione dei dati di connessione.



La Figura 2 mnostra FDM e TDM per uno specifico collegamento di rete che supporta fino a 4 circuiti. Nel caso di FDM il dominio delle frequenze viene ripartito in quattro bande, ciascuna con ampiezza di 4 kHz. Nel caso di TDM, il dominio del tempo viene suddiviso in frame, con quattro slot di tempo per ciascun intervallo; a ogni circuito viene assegnato lo stesso slot dedicato in tutti i frame. Nel caso di TDM, la velocità di trasmissione di un circuito è uguale alla frequenza di frame moltiplicata per il numero di bit in uno slot.
Un'ulteriore strategia di multiplazione è la **WDM, Wavelength-Division Mul-**

tiplexing che viene usata per connessioni e fibra ottica e prevede una multiplazione e demultiplazione dei flussi che sfruttano diverse lunghezze d'onda della luce laser.

1.4.3. Una rete di reti

Abbiamo visto che i sistemi periferici si collegano a Internet tramite un ISP di accesso che può fornire connettività attraverso una rete cablata o senza fili. Tuttavia, la connessione degli utenti finali e dei fornitori di contenuti alla rete di un ISP è solouna piccola parte del puzzle per connettere i miliardi di utenti che costituiscono Internet. Per completare il puzzle bisogna interconnettere gli stessi ISP. Ciò avviene creando una **rete di reti**.
Per connettere gli ISP, un approccio ingenuo sarebbe quello di connettere direttamente ogni ISP di accesso con tutti gli altri, ma una struttura simile, detta a *maglia*, è troppo costosa.
Si adotta, quindi, una struttura gerarchica basata su livelli. Ci sono gli ISP di accesso di livello 3, gli ISP regionali di livello 2 e gli ISP globali di livello 1. Ogni ISP è cliente di uno del livello superiore e il cliente paga il fornitore per il transito verso il resto di Internet.
Un altra soluzione è quella di avere al centro poche decine di ISP di livello 1 e ciascuno è connesso a un gran numero di ISP di livello inferiore.
Il problema di questo tipio di connessione è il costo. Infatti gli ISP di livello inferiore pagano gli ISP di livello superiore e il costo riflette la quantità di traffico che l'ISP cliente scambia con il fornitore. Per ridurre tali costi, una coppia di ISP vicini e di pari livello gerarchico può fare uso di **peering**, cioè connettere direttametne le redi in modo che tutto il traffico tra di esse passi attraverso una connessione diretta. In questo modo due ISP si scambiano traffico senza pagarsi. L'**IXP**, Internet eXchange Point, è la sede fisica dove molte resi si interconnettono e fanno peering.

1.5. Tipi di reti

Esiste una grande varietà di tecnologie di rete e di modelli organizzativi. In particolare, le reti possono essere classificate in base all'estensione geografica:

- Rete personale, dette **PAN (Personal Area Network)**, sono reti in ambitoo personale e connettono apparati personali nel raggio di pochi metri: smartphone, cuffie, smartwatch, stampanti e così via. I collegamenti possono essere guidati tramite USB oppure via wireless;
- Rete locale, dette **LAN (Local Area Network)** e sono reti che si estendono all'interno di un edificio o di un comprensorio, con un'estensione nell'ordine del centinaio di metri. Le LAN hanno velocità trasmissive elevate (1-10 Gbps su cavo). Le LAN oggi sono reti commutate con collegamenti punto-punto e i collegamenti sono guidati e wireless;

- Rete metropolitana, dette **MAN (Metropolitan Area Network)** e sono reti in ambito cittadino. Il mezzo trasmissivo tipico è la fibra ottica sul backcon, oppure cavi in fibra/rame;
- Rete geografica, dette **WAN (Wide Area Network)** e sono reti in ambito nazionale o internazionale. I collegamenti sono indiretti guidati e wireless. Possono essere reti a commutazione di circuito e di pacchetto e le topologie possono essere svariate.

1.6. Ritardi, perdite e throughput nelle reti a commutazione di pacchetto

1.6.1. Ritardo nelle reti a commutazione di pacchetto

Un pacchetto parte da un host, passa attraverso una serie di router e conclude il viaggio in un altro host. A ogni tappa, il pacchetto subisce vari tipi di ritardo a ciascun nodo del tragitto. Di tali ritardi, i principali sono il **ritardo di elaborazione**, il **ritardo di accodamento**, il **ritardo di trasmissione** e il **ritardo di propagazione** che complessivamente formano il **ritardo totale di nodo**. Esaminiamoli nel dettaglio.

- il *ritardo di elaborazione* è il tempo richiesto per esaminare l'intestazione del pacchetto e per determinare dove dirigerlo. Questo può anche includere altri fattori, tra i quali il tempo richiesto per controllare errori a livello di bit.
- il *ritardo di accodamento* è dato dalla somma dei tempo di attesa per ogni coda
- il *ritardo di trasmissione* è dato dal tempo di immissione del pacchetto sul collegamento. È pari al rapporto delle dimensione del pacchetto (in bit) e la velocità di trasmissione (in bps).
- il *ritardo di propagazione* è dato dalla distanza/velocità del segnale sul mezzo trasmissivo.

Inoltre, ci sono altri tipi di ritardo, quali:

- **ritardo end-to-end** che è dato dalla somam dei ritardi impeigato da un pacchetto per andare da un nodo di partenza a quello di destinazione;
- **round trip time** (tempo di andata e ritorno) è il tempo impiegato da un pacchetto per andare da un punto all'altro della rete e tornare al unto di partenza ed è dato da $2 \cdot$ ritardo end-to-end

Per ottenere una misura efficiente dei ritardi utilizziamo due strumenti:

1. *ping* calcola il ritardo rispetto ad una destinazione finale per un messaggio di dimensioni standard;
2. *traceroute (tracert)* calcola il ritardo per ogni nodo intermedio fino alla destinazione finale per un messaggio di dimensioni standard.

Architetture a livelli

Precedentemente abbiamo descritto come è costituita la rete Internet, che è, quindi, un sistema complicato ed esiste un'organizzazione per organizzare l'architettura delle reti.
Un'architettura a livelli consente di discutere una parte specifica e ben definita di un sistema articolato e complesso. Questa semplificazione ha un valore importante grazie all'introduzione della modularità, che rende molto più facile cambiare l'implementazione del servizio fornito da un determinato livello. Fino a quando il livello fornisce lo stesso servizio allo strato superiore e utilizza gli stessi servizi dello strato inferiore, la parte rimanente del sistema rimane invariata al variare dell'implementazione del livello. In sistemi grandi e complessi, che vengono costantemente aggiornati, la capacità di cambiare l'implementazione di un servizio senza coinvolgere altre componenti del sistema costituisce un ulteriore importante vantaggio legato alla stratificazione.

2.1. Stratificazione dei protocolli

Per dare una struttura ai protocolli di rete, i progettisti organizzano protocolli e l'hardware che li implementano in **strati**, detti *layer*. Ciascun protocollo appartiene a uno dei livelli. Adesso rivolgiamo l'attenzione ai **servizi** offerti da un livello superiore: si tratta del cosidetto **modello di servizio**, detto *service model*, di un livello. Un livello di protocolli può essere implementato via software, hardware o con una combinazione dei due. I protocolli a livello di applicazione, quali HTTP e SMTP, sono quasi sempre implementati via software nei sistemi periferici; e così è anche per i protocolli a livello di trasporto. Dato che i livelli fisico e di data link si occupano della comunicazione su un collegamento specifico, sono di regola implementati nella scheda di rete associata. Il livello di rete è spesso un'implementazione mista di hardware e software.
La stratificazione dei protocolli presenta vantaggi concettuali e strutturali. Fornisce un modo strutturato per trattare i componenti dei sistemi. La modularità rende più facile aggiornare la componentistica. Uno svantaggio legato alla stratificazione è la possibilità che un livello duplichi le funzionalità di quello inferiore. Ad esempio, molte pile di protocolli forniscono meccanismi di correzione degli errori ai livelli sia di collegamento sia di connessione end-to-end. Un secondo potenziale svantaggio è che la funzionalità a un livello possa richiedere informazioni presenti solo in un altro livello e questo viola lo scopo insito nella separazione dei livelli.
Considerati assieme, i protocolli dei vari livelli sono detti **pila di protocolli**, detto

protocol stack. La pila di protocolli di Internet, mostrata nella seguente figura, consiste di cinque livelli: fisico, collegamento, rete, trasporto e applicazione.



Figura 3: Pila di protocolli di Internet

Analizziamo brevemente i vari livelli:

- il livello di *applicazione* è la sede delle applicazioni di rete e dei relativi protocolli. Per quanto riguarda Internet, questo livello include molti protocolli, come HTTP che consente la richiesta e il trasferimento dei documenti web, SMTP che consente il trasferimento dei messaggi di posta elettronica e FTP che consente il trasferimento di file tra due sistemi remoti. I pacchetti di informazione vengono chiamati **messaggi**.
- il livello di *trasporto* di Internet trasferisce i messaggi del livello di applicazione tra punti periferici gestiti dalle applicazioni. In Internet troviamo due protocolli di trasporto: TCP e UDP. TCP fornisce alle applicazioni un servizio orientato alla connessione, che include la consegna garantita dei messaggi a livello di applicazione alla destinazione e il controllo di flusso. Inoltre, TCP fraziona i messaggi lunghi in segmenti più piccoli e fornisce un meccanismo di controllo della congestione.
  Il protocollo UDP fornisce alle proprie applicazioni un servizio non orientato alla connessione che è un servizio senza affidabilità, né controllo di flusso e della congestione. I pacchetti a livello di trasporto si chiamano **segmenti**.
- Il lviello di rete di Internet si occupa di trasferire i pacchetti a livello di rete, detti **datagrammi**, da un host a un altro. Il livello di rete di Internet comprende il famoso protocollo IP, che definisce i campi dei datagrammi e come si sistemi periferici e i router agiscono su tali campi. Il livello di rete di Internet contiene svariati protocolli di instradamento che determinano i percorsi che i datagrammi devono seguire tra la sorgente e la destinazione.
- Il livello di *collegamento* si occupa di trasferire il datagramma al livello di rete superiore. I servizi forniti da questo livello dipendono dallo specifico protocollo utilizzato. Esempi di livello di collegamento includono Ethernet, Wi-fi e il proto-

collo di accesso alla rete DOCSIS. I pacchetti a livello di collegamento vengono chiamati **frame**.

- Il livello *fisico* è trasferire i singoli bit del frame da un nodo a quello successivo. Anche i protocolli di questo livello dipendono dal collegamento e in più dipendono dall'effettivo mezzo trasmissivo.

Un architettura a livelli alternativa al modello presentato prima, detto modello TCP/IP è il modello ISO/OSI, presentato nella seguente figura:



Figura 4: Modello ISO/OSI

ISO sta per International Organization for Standardization e OSI per Open Systems Interconnection. Il modello ISO/OSI è un sistema aperto con caratteristiche di interoperabilità. Esso è composto da 7 livelli:

1. il livello *fisico* che si occupa di trasmetter bit lungo un canale di comunicazione;
2. il livello di *collegamento* che si occupa di trasmettere i frame tra nodi adiacenti collegati direttamente, con rilevazione degli errori;

3. il livello di *rete* che si occupa di instradare i datagrammi tra reti a commutazione di pacchetto;
4. il livello di *trasporto* che si occupa di far comunicare, in modalità end-to-end, i processi trasmettendo segmenti;
5. il livello di *sessione* che si occupa di organizzare il dialogo di sincronizzare i programmi applicativi;
6. il livello di *presentazione* che si occupa di come rappresentare i dati da trasferire;
7. il livello di *applicazioni* che si occupa del trasferimento di messaggi tra le parti di una applicazione.

2.2. Incapsulamento

Quando un messaggio attraversa i vari livelli della rete si applica il cosiddetto meccanismo di **incapsulamento**. Presso un host mittente, un **messaggio a livello di applicazione**, *application-layer message*, viene passato a livello di trasporto. Questo livello prende il messaggio e gli concatena informazioni aggiuntine, dette informazioni di intestazione che saranno utilizzate dalla parte ricevente del livello di trasporto. Il messaggio a livello di applicazione e le informazioni di intestazione a livello di trasporto costituiscono il **segmento a livello di trasporto**, *transport-layer segment* che incapsula il messaggio a livello di applicazione. Le informazioni aggiunte potrebbero includere dati che consentono al livello di trasporto di consegnare il messaggio all'applicazione desiderata. Il livello di trasporto passa il segmento al livello di rete, che aggiunge informazioni di intestazioni proprie, quali gli indirizzi dei sistemi perfiferici di sorgente e di destinazione, creando un **datagramma a livello di rete**, *network-layer datagram*. A questo punto, il datagramma viene passato al livello di collegamento, il quale aggiunge le proprie informazioni di intestazioni creando un **frame a livello di collegamento**, *link-layer frame*. Quindi a ciascun livello, il pacchetto ha due tipi di campo: quello di intestazione e quello di **payload** (il carico utile trasportato). Il payload è tipicamente un pacchetto proveniente dal livello superiore.

Livello di applicazione

3.1. Web e HTTP

Fino agli anni "90 Internet veniva principalmente utilizzata da ricercatori, docenti e studenti universati per raggiungere host remoti, trasferire file, ricevere e inviare

notizie e per la posta elettronica. Poi, comparve il World Wide Web. Il Web è stata la prima applicazione Internet che ha cambiato profondamente il modo di interagire all"interno e all'esterno degli ambienti di lavoro.
Ciò che attira del Web è che opera su richiesta , si può avere ciò che si vuole, quando lo si vuole. Oltre a questo, il Web presenta molte altre interessanti caratteristiche. È facilissimo per tutti rendere disponibili informazioni sul Web: chiunque può diventare editore a costi estremamente bassi. Inoltre il Web fornisce una piattaforma a molte applicazioni killer, tra cui YouTube, servizi di posta elettronica come Gmail, Instagram e Google Maps.

3.1.1. Architettura del Browser e del Server

L'architettura di un web browser comprende diversi moduli specializzati: un Display manager, la gestione delle Estensioni/Plug-in, un Cache manager, un Request processor, il motore JavaScript (JS engine), un HTML interpreter e lo stack di rete HTTP/TCP.
Parallelamente, l'architettura di un web server (o **http daemon**) svolge le funzioni di gestire le connessioni con i browser e ritrovare o creare documenti dal File System. Include anche un modulo per l'interpretazione CGI/HTTP, un manager delle richieste e un Path Resolver per gestire le autorizzazioni di accesso. I web server oggi più diffusi sul mercato sono Apache, Nginx, Cloudflare e LiteSpeed, con IIS ormai marginale.

3.1.2. Differenza tra URI, URN e URL

Il sistema di indirizzamento del Web si basa formalmente sugli URI (Uniform Resource Identifier), definiti nella RFC 3986, che identificano una risorsa attraverso il nome o la posizione. Gli URI si dividono principalmente in due categorie:

- **URN (Uniform Resource Name):** Associa un identificatore univoco alla risorsa senza implicarne la disponibilità e senza specificare il meccanismo di accesso (es. un codice ISBN per un libro).
- **URL (Uniform Resource Locator):** Specifica sia il metodo di accesso sia la locazione fisica della risorsa, dandone per implicita la disponibilità; se la locazione cambia, il link si rompe («broken link»).

La sintassi generale di un URL è strutturata in questo modo: `scheme:["//"] [user [":"password] "@"] host [":"port] ["/"url-path]` . Lo **scheme** indica il protocollo (es. http, https, mailto, file), l'**host** è il nome DNS o l'indirizzo IP, la **port** è il numero di porta (opzionale, default 80 per HTTP o 443 per HTTPS) e l'**url-path** è il percorso gerarchico della risorsa seguito da eventuali parametri di query.

3.1.3. Panoramica di HTTP

HTTP, acronimo di *HyperText Transfer Protocol*, protocollo a livello di applicazione del Web, costituisce il cuore del Web. Questo protocollo è implementato in due

programmi, client e server, in esecuzione su sistemi periferici diversi che comunicano tra loro scamiandosi messaggi HTTP. Il protocollo definisce sia la struttura dei messaggi sia la modalità con cui client e server si scambiano i messaggi.
Una **pagina web**, detta anche documento, è costituita da oggetti. Un **oggetto** è semplicemente un file indirizzabile tramite un URL. La maggioranza delle pagine web consiste di un **file HTML principale** e diversi oggetti referenziati da esso. Ogni URL ha due componenti: il nome dell'host del server che ospita l'oggetto e il percorso dell'oggetto. Per esempio, l'URL

http.//www.someSchool.edu/someDepartment/picture.gif

ha *www.someSchool.edu* come nome dell'host e */someDepartment/picture.gif* come percorso. Un **browser web** implementa il lato client di HTTP. Un **web server**, che implementa il lato server di HTTP, ospita oggetti web, indirizzabili tramite URL.
HTTP definisce in che modo i client web richiedono le pagine ai web server e come questi ultimi le trasferiscono ai client. Quando l'utente richiede una pagina web, il browser invia al server messaggi di richiesta HTTP per gli oggetti nella pagina. Il server riceve le richieste e risponde con messaggi di risposta HTTP contenenti gli oggetti.
HTTP utilizza TCP (anzichè UDP) come protocollo di trasporto. Il client HTTP per prima cosa inizia una connessione TCP con il server. Una volta stabilita, i processi client e server accedono a TCP attraverso le proprie socket. L'interfaccia socket è la porta tra un processo e la sua connessione TCP. Il client invia richieste e riceve risposte HTTP tramite la propria interfaccia socket, analogamente il server riceve richieste e invia messaggi di risposta attraverso la propria interfaccia socket.
Quando il client ha mandato un messaggio alla sua interfaccia socket, questo non è più in suo possesso, ma si trova «nelle mani» di TCP. TCP mette a disposizione di HTTP un servizio di trasferimento dati affidabile. Questo è uno dei grandi vantaggi di un'architettura organizzata a livelli: HTTP non si deve preocuppare dei dati smarriti o di come TCP recuperi le perdite o riordini i dati all'interno della rete: questi sono compiti di TCP e dei protocolli di livello inferiore.
Il server invia i file richiesti ai clienti senza memorizzare alcuna informazione di stato a proposito dei client. Per cui, in caso di ulteriore richiesta dello stesso oggetto da parte dello stesso client, anche nel giro di pochi secondi, il server procedera nuovamente all'invio. Dato che i server HTTP non mantengono informazioni sui client, HTTP è classificato come **protocollo senza memoria di stato**. Un web server è sempre attivo, ha un indirizzo IP fisso e risponde potenzialmente alle richieste provenienti da milioni di diversi browser.

3.1.4. HTTP/1

La versione originale di HTTP si chiama HTTP / 1.0 e risale agli inizi degli anni "90. A partire dal 2020, la maggior parte delle transazioni HTTP avviene su HTTP/1.1.

Tuttavia, sempre più browser e web server supportano una nuova versione di HTTP chiamata HTTP/2.

3.1.5. Connessioni persistenti e non persistenti

In molte applicazioni per Internet, client e server comunicano per un lungo periodo di tempo, con il client che inoltra una serie di richieste e il server che risponde a ciascuna di esse. Quando tale interazione ha luogo su TCP, gli sviluppatori dell'applicazione devono prendere una decisione importante: devono decidere se ciascuna coppia richiesta/risposta deve essere inviata su TCP *separata* oppure devono essere inviate tutte sulla stessa connessione TCP. Nel primo approccio si dice che l'applicazione usa **connessioni non persistenti**, mentre nel secondo usa **connessioni persistenti**.

HTTP con connessioni non persistenti

Analizziamo il trasferimento di un file nel caso di connessione non persistente. Supponiamo che la pagina consista di un file HTML principale e di 10 immagini JPEG, e che tutti gli undici oggetti risiedano sullo stesso server. Ipotezziamo che l'URL del file HTML principale sia:

http://wwww.someSchool.edu/someDepartment/home.index

Le fasi della connessione sono le seguenti.

1. Il processo client HTTP inizializza una connessione TCP con il server *www.someSchool.edu* sulla porta 80, che è la porta di default per HTTP. Associate alla connessione TCP ci saranno una socket per il client e una per il server.
2. Il client HTTP, tramite la propria socket, invia al server un messaggio di richiesta HTTP che include il percorso */someDeparment/home.index*.
3. Il processo server HTTP riceve il messaggio di richiesta attraverso la propria socket associata alla connessione, recupera l'oggetto */someDeparment/home.index* dalla memoria, lo incapsula in un messaggio di risposta HTTP che viene inviato al client attraverso la socket.
4. Il processo server HTTP comunica a TCP di chiudere la connessione. Questo, però, non termina la connessione finchè non sia certo che il client abbia ricevuto integro il messaggio di risposta.
5. Il client HTTP riceve il messaggio di risposta. La connessione TCP termina. Il messaggio indica che l'oggetto incapsulato è un file HTML. Il client estrae il file dal messaggio di risposta, esamina il file HTML e trova i riferimenti ai 10 oggetti JPEG.
6. Vengono quindi ripetuti i primi 4 passi per ciascuno degli oggetti JPEG referenziati.Questi passi illustrano l'utilizzo di connessioni non persistenti in cui ogni connessione TCP viene chiusa dopo l'invio dell'oggetto da parte del

server: vale a dire che ciascuna trasporta soltanto un messaggio di richiesta e un messaggio di risposta.

Possiamo fare un calcolo approssimativo per stimare l'intervallo di tempo che intercorre tra la richiesta di un file HTML da parte del client e il momento in cui l'intero file viene ricevuto dal client/ A questo scopo, definiamo il **round-trip time (RTT)**, che rappresenta il tempo impiegato da un singolo pacchetto per viaggiare dal client al server e poi tornare al client. RTT include i ritardi di propagazione, di accodamento nei router e nei commutatori intermedi nonchè di elaborazione del pacchetto. Quando l'utente clicca su un collegamento ipertestuale, invece, questo comporta un **handshake a tre vie**: il client invia un piccolo segment TCP al server e quest'ultimo manda una conferma per mezzo di un piccolo segmento TCP. Infine il client dà anch'esso una conferma di ritorno al server. Le prime due parti dell'handshare a tre vie richiedono un RTT. Dopo il loro completamento, il client invia un messaggio di richiesta HTTP combinano con la terza parte dell'handshake, la conferma di avvenuta ricezione, tramite la connessione TCP>Quando il messaggio di richiesta arriva al server, quest'ultimo inoltra il file HTML sulla connessione TCP. La richiesta-risposta HTTP consuma un altro RTT. Pertanto, il tempo di risposta è approssivamente di due RTT più il tempo di trasmissione da parte del server del file HTML.

HTTP con connessioni persistenti

Le connessioni non persistenti presentano alcuni limiti:

1. per ogni oggetto richiesto occorre stabilire e mantenere una nuova connessione. Per ogni connessione si devono allocare buffer e mantenere variabili TCP sia nel client sia nel server.
2. ciascun oggetto subisce un ritardo di consegna di due RTT, uno per stabilire la connessione TCP e uno per richiedere e ricevere un oggetto.

Con HTTP 1.1 nelle connessioni persistenti il server lascia la connessione TCP aperta dopo l'invio di una risposta, per cui le richieste e le risposte successive tra gli stessi client e server possono essere trasmesse sulla stessa connessione. Inoltre, il server può inviare un'intera pagina web o anche più pagine web allo setsso client. Queste richieste di oggetti possono essere effettuate una di seguito all'altra senza aspettare le risposte delle richieste pendenti (meccanismo di *pipeling*). In generale, il server HTTP chiude la connessione quando essa rimane inattiva per un dato lasso di tempo. La modalità di default di HTTP impiega connessioni persistenti con pipeling.

3.1.6. Formato dei messaggi HTTP

Le specifiche HTTP includono la definizione dei due formati dei messaggi HTTP, di richiesta e di risposta.

Messaggio di richiesta HTTP

Un messaggio tipico di richiesta HTTP si presenta nel seguente modo:

```
GET /somedir/page.html HTTP/1.1
Host: www.someschool.edu
Connection: close
User-agent: Mozilla/5.0
Accept-language: fr
```

Il messaggio è scritto in testo ASCII, in modo che l'utente sia in grado di leggerlo. Inoltre, consiste di cinque righe, ciascuna seguito da un carattere di ritorno a capo e un carattere di nuova linea aggiuntivi. In generale, i messaggi di richiesta possono essere costituito da un numero indefinito di righe, anche una sola. La prima riga è detta **riga di richiesta** (*request line*), quelle successive **righe di intestazione** (*header lines*). La riga di richiesta presenta tre campi: il campo metodo, il campo URL e il campo versione di HTTP. Il campo metodo può assumere diversi valori, tra cui `GET, POST, HEAD, PUT` e `DELETE`. La maggioranza dei messaggi di richiesta HTTP usa il metodo `GET`, adottato quando il browser richiede un oggetto identificato dal campo URL. La versione è auto esplicativa.
Consideriamo le righe di intestazione dell'esempio. La riga *Host: www.someSchool.edu* specifica l'host su cui risiede l'oggetto. Includendo la linea di intestazione *Connection: close*, il browser sta comunicando al server che non si deve occupare di connessioni persistenti, ma vuole che questi chiuda la connessione dopo aver inviato l'oggetto richiesto. La riga di intestazione *User-agent:* specifica il tipo di browser che sta effettuando la richiesta al server. Questa riga è utile in quanto il server può inviare versioni diverse dello stesso oggetto a browser di tipi diversi. Infine, *Accept-language:* indica che l'utente preferisce ricevere una versione in francese dell'oggetto se disponibile; altrimenti, il server dovrebbe inviare la versione di default.
Dopo le linee di intestazione si trova un «corpo». Nel caso di metodo GET è vuoto, ma viene utilizzato nel metodo POST, il quale viene usato per inviare dati al server. Le richieste generate con il form non devono necessariamente usare il metodo POST. Anzi, spesso i form HTML utilizzano il metodo GET E includono i dati immessi nell'URL richiesto. Ad esempio:

www.somesite.com/animalsearch?scimmie&banane

Il metodo HEAD è simile a GET. Quando un server riceve una richiesta con il metodo HEAD, risponde con un messaggio HTTP, ma tralascia gli oggetti richiesti. Gli sviluppatori spesso utilizzano il metodo HEAD per verificare la correttezza del codice prodotto. Il metodo PUT, consente agli utenti di inviare un oggetto a un percorso specifico su uno specifico web server.

Messaggio di risposta HTTP

Analizziamo un tipico messaggio di risposta HTTP che potrebbe rappresentare la risposta al messaggio di richiesta dell'esempio precedente.

```
HTTP/1.1 200 OK
Connection: close
Date: Thu, 18 Aug 2015 15:44:04 GMT
Server: Apache/2.2.3 (CentOS)
Last-Modified: Tue, 18 Aug 2015 15:11:03 GMT
Content-Length: 6821
Content-Type: text/html
(data data data data data ...)
```

Analizzando questo messaggio di risposta ci sono tre sezioni:

1. una **riga di stato** iniziale. Questa presenta tre campi:
   1. la versione del protocollo
   2. un codice di stato
   3. un corrispettivo messaggio di stato;
2. sei **righe di intestazione**. Il server utilizza la riga di intestazione *Connection: close* per comunicare al client che ha intenzione di chiudere la connessione TCP dopo l'invio del messaggio. La riga *Date:* indica l'ora e la data di creazione e invio, da parte del server, della riposta HTTP. La riga *Server:* indica che il messaggio è stato generato da un web server Apache. La riga *Last-Modified*: indica l'istante e la data in cui l'oggetto è stato creato o modificato per l'ultima volta. La riga di intestazione *Content-Length:* contiene il numero di byte dell'oggetto inviato. La riga *Content-Type* indica che l'oggetto nel corpo è testo HTML. ;
3. il **corpo**: questo è il fulcro del messaggio contiene l'oggetto richiesto.

Analizziamo alcuni codici di stato e le relative espressioni.

1. 200 OK: la richiesta ha avuto successo e in risposta si invia l'informazione;
2. 301 Moved Permanently: l'oggetto richiesto è stato trasferito in modo permanente; il nuovo URL è specificato nell'intestazione *Localtion:* del messaggio di risposta.
3. 400 Bad Request: si tratta di un codcie di errore generico che indica che la richiesta non è compresa dal server;
4. 404 Not Found: il documento richiesto non esiste sul server.
5. 505 HTTP Version Not Supported: il server non dispone della versione di protocollo HTTP richiesta.

Il campo `Content-Type` sfrutta lo standard MIME (Multipurpose Internet Mail Extensions) per indicare la natura dei dati trasmessi. Tra i tipi e sottotipi più comuni troviamo testo (`text/plain` , `text/html` , `text/xml`), immagini (`image/gif` , `image/jpeg`), audio (`audio/basic`), video (`video/mpeg`) e file applicativi (`application/pdf`).

Per quanto riguarda i codici di stato, il protocollo HTTP li suddivide in grandi categorie:

- 2xx (Successful): Include 200 OK, 201 Created (utilizzato per POST/PUT) e 204 No Content.
- 3xx (Redirection): Include 301 Moved Permanently, 302 Found (trasferimento temporaneo) e 304 Not Modified (indica che la cache è ancora valida).
- 4xx (Client Error): Include 400 Bad Request, 401 Unauthorized, 403 Forbidden e 404 Not Found.
- 5xx (Server Error): Include 500 Internal Server Error, 501 Not Implemented, 502 Bad Gateway, 503 Service Unavailable e 504 Gateway Timeout.

Inoltre, per velocizzare il caricamento con connessioni persistenti (HTTP/1.1), va notato che i browser moderni adottano un approccio fuori dallo standard originario (che suggeriva max 2 connessioni), aprendo in parallelo fino a 6 connessioni TCP per ciascun hostname.

3.1.7. Interazione utente-server: i cookie

Abbiamo detto che i server HTTP sono privi di stato. Ciò semplifica la progettazione e consente di sviluppare web server ad alte prestazioni, in grado di gestire migliaia di connessioni TCP simultanee. Spesso i web server possono autenticare gli utenti, sia per limitare l'accesso da parte di questi ultimi sia per fornire contenuti in funzione della loro identità. A questo scopo HTTP adotta i **cookie**. I cooie, consentono ai server di tener traccia degli utenti. La tecnologia dei cookie presenta quattro componenti:

1. una riga di intestazione nel messaggio di risposta HTTP;
2. una riga di intestazione nel messaggio di richiesta HTTP;
3. un file mantenuto sil sistema dell'utente e gestito dal browser;
4. un database sul sito.

Quando un utente visita per la prima volta un sito, il sito crea un identificativo unico e una voce nel proprio database, indicizzata dal numero identificativo. A questo punto il server risponde, includendo nella risposta HTTP l'intestazione *Set-cookie:* che contiene il numero identificativo. Quando il browser del client riceve il messaggio di risposta HTTP, vede l'intestazione *Set-cookie* e aggiunge una riga al file dei cookie che gestisce. Questa riga include il nome dell'host del server e il numero identificativo. Quando l'utente visita nuovamente lo stesso sito, il suo browser consulta il suo file di cookie, estrae il suo numero identificativo per il sito e pone nella richiesta HTTP una riga di intestazione del cookie che include tale numero. Aggiunge la riga di intestazione *Cookie:* seguita dal numero identificativo. I cookie, quindi, possono essere usati per identificare gli utenti. La prima volta che visita un sito, un utente può fornire un'identificazione. Successivamente il browser passa un'intestazione di cookie al server durante tutte le successive visite al sito,

identificando l'utente sul server.
Le informazioni dei cookie sono memorizzate lato client dal browser in uno spazio dedicato (il «cookie store»), che oggigiorno è tipicamente implementato come un database SQLite. Non dovrebbero mai essere utilizzati per memorizzare password o altre informazioni sensibili in chiaro. Quando il server risponde con un'intestazione `Set-Cookie`, può specificare una serie di attributi predefiniti per regolarne il ciclo di vita e la sicurezza, come `Expires`, `Max-Age` (scadenza), `Domain`, `Path`, `Secure` e `HttpOnly`.

3.1.8. Web caching

Una **web cache**, nota anche come **proxy server**, è un'entità di rete che soddisfa richieste HTTP al posto del web server effettivo. Il proxy ha una propria memoria sul disco (una cache) in cui conserva copie di oggetti recentemente richiesti. Il browser di un utente può essere configurato in modo che tutte le richieste HTTP dell'utente vengano innanzitutto dirette al proxy server. Una volta configurato il browser, ogni richiesta di oggetto da parte del browser viene diretta al proxy. Quando un browser richiede un oggetto, accade che:

1. Il browser stabilisce una connessione TCP con il proxy server e invia una richiesta HTTP per l'oggetto specificato.
2. Il proxy controlla la presenza di una copia dell'oggetto memorizzata localmente. Se l'oggetto viene rilevato, il proxy lo inoltra all'interno di un messaggio di risposta HTTP al browser.
3. Se, invece, la cache non dispone dell'oggetto, il proxy apre una connessione TCP verso il server di origine. Quindi, il proxy invia al server una richiesta HTTP per l'oggetto. Una volta ricevuta tale richiesta, il server di origine invia al proxy l'oggetto all'interno di una risposta HTTP.
4. Quando il proxy riceve l'oggetto, ne salva una copia nella propria memoria locale e ne inoltra un'altra copia, all'interno di messaggio di risposta HTTP, al browser.

Il proxy è contemporaneamente server e client: quando riceve richiesta da un browser e gli invia risposte agisce da server, quando invia richieste e riceve risposte da un server di origine funziona da client.
Il web caching si è sviluppato in Internet per due ragioni. Innanzitutto, un proxy può ridurre in modo sostanziale i tempo di risposta alle richieste dei client, in particolare se l'ampiezza di banda che costituisce il collo di bottiglia tra il client e il server di origine è molto inferiore rispetto all'ampiezza di banda minima tra client e proxy. In secondo luogo, i proxy possono ridurre il traffico sul collegamento di accesso a Internet, con il vantaggio di non dover aumentare l'ampiezza di banda frequentemente e ottenere quindi una riduzione dei costi.
Un'altra alternativa al proxy server è il **reverse proxy server** che è un proxy che sta davanti ai server di origine. Un client manda la richiesta al proxy credendo che sia il web server e il proxy la inoltra a uno dei server di orogine, che restano nascosti

al client. Il reverse proxy server è il simmetrico del forward proxy: quello agisce per conto dei client, questo per conto dei server. Il reverse proxy server è importante per la sicurezza perchè nasconde l'indirizzo IP dei server, è importante per il load balancing e per le funzionalità di caching.

3.1.9. HTTP/2

La maggior parte dei browser, supporta HTTP/2. Gli obiettivi principali di HTTP/2 sono quello di ridurre la latenza percepita attivando il multiplexing di richiesta e risposta su singola connessione TCP, di fornire supporto per la priorità delle richieste e il server push e di fornire una compressione efficiente dei campi di intestazione HTTP. HTTP/2 non modifica metodi, codici di stato, URL e campi di intestazione di HTTP, ma cambia il modo in cui i dati vengono formattati e trasportati tra il client e il server. Abbiamo detto che HTTP/1.1 utilizza connessioni TCP persistenti ma l'invio di tutti gli oggetti web su una singola connessione web ha il problema dell'**HEAD OF LINE (HOL) blocking**. Per comprendere il blocco HOL, si consideri una pagina web che include una pagina di base HTML, un grande video clip e molti piccoli oggetti sotto il video. Supponiamo inoltre che ci sia un collegamento a collo di bottiglia con velocità medio-bassa sul percorso tra server e client. Utilizzando una singola connessione TCP, il video clip impiegherebbe molto tempo per passare attraverso il collegamento a collo di bottiglia e gli oggetti piccolo subirebbero un ritardo.
Per aggirare questo problema è possibile aprire più connessioni TCP parallele per trasportare una singola pagina web, «imbrogliando» e prendersi una parte maggiore della larghezza di banda del collegamento. Uno degli obiettivi principali di HTTP/2 è eliminare o ridurre il numero di connessioni TCP parallele per il trasporto di una singola pagina web.
Per implementare il multiplexing e aggirare il blocco HOL, HTTP/2 utilizza il «framing», suddividendo la risposta in frame binari di dimensione limitata (la dimensione massima è negoziata, con un default di 16 KB). Questo permette un «interleaving» (intervallamento) fluido dei frame di oggetti diversi. HTTP/2 (basato in origine sul protocollo SPDY di Google) fornisce anche supporto per la priorità: il client può indicare per ogni richiesta un livello di urgenza da 0 a 7 (RFC 9218). Inizialmente era previsto anche il **server push** (l'invio non richiesto di asset per la pagina), ma questa funzionalità è stata di fatto abbandonata e rimossa dai browser basati su Chromium a partire dal 2022.

3.1.10. HTTP/3

QUIC è un nuovo protocollo di trasporto implementato nel livello di applicazione sul portocollo UDP. QUIC offre diverse opportune funzionalità per HTTP, come il multiplexing dei messaggi (*interleaving*), il controllo di flusso per ogni stream e la creazione di connessioni a bassa latenza. HTTP/3 è un altro, nuovo protocollo

HTTP progettato per funzionare su QUIC. HTTP/3 non è ancora stato completmente standardizzato. Molte delle funzionalità HTTP/2 sono incluse in QUIC, facilitando la progettazione di HTTP/3.
HTTP/3 implementa in modo nativo la sicurezza: integra infatti il protocollo TLS (Transport Layer Security), ovvero lo stesso protocollo alla base delle connessioni HTTPS, garantendo comunicazioni sicure di default.

3.1.11. Streaming video e reti per la distribuzione di contenuti

Lo streaming video rappresenta circa l'80% del traffico Internet (statistica del 2020).Analizziamo come i servizi streaming vengano implementati nell'Internet di oggi.

Video su Internet

Nelle applicazioni di streaming di video registrati, i contenuti sono video, memorizzati su server a disposizione degli utenti su richiesta. Innanzitutto, analizziamo le caratteristiche dei video. Un video è una sequenza di immagini, visualizzate a velocità costante di, ad esempio, 24 o 30 immagini al secondo. Un'immagine non compressa e codificata digitalmente consiste di un array di pixel, ognuno dei quali codificato con un numero di bit per rappresentare luminanza e crominanza. I video possono essere compressi in modo da raggiungere un compromesso tra qualità del video e bit rate. Gli algoritmi di compressione oggi disponibili sono in grado di comprimere un video a qualsiasi bit rate si desideri. Più è alto il bit rate, migliore è la qualità dell'immagine e l'esperienza visiva globale dell'utente.
Dal punto di vista del networking, la caratteristica più importante è l'elevata velocità con cui è necessario inviare i bit sulla rete (**bit rate**). La misura in assoluto più importante per lo streaming video è il throughput medio, il cui valore deve essere almeno pari a quello del bit rate del video per avere una riproduzione continua.
La compressione può essere usata anche per creare versioni multiple dello stesso video, a livello di qualità diversi. Ad esempio, si può usare la compressione per creare tre versioni dello stesso video, a 300 kbps, 1 Mbps e 3 Mbps e gli utenti possono decidere quale versione guardare in funzione della larghezza di banda disponibile.

Streaming HTTP e DASH

Nello streaming HTTP il video viene semplicemente memorizzato in un server HTTP come un file ordinario con un URL specifico. Quando un utente vuole vedere un video, il client stabilisce una connessione TCP con il server e invia una richiesta GET HTTP per il suo URL. Il server invia il file video, all'interno di un messaggio di risposta HTTP, più velocemente possibile dati il traffico e i protocolli di rete. Sul lato client i byte vengono memorizzati in un buffer dell'applicazione client. Quando il numero di byte nel buffer supera una soglia fissata, l'applicazione client inizia la riproduzione: periodicamente prende i frame video dal buffer, li decomprime e li visualizza all'utente. Quindi l'applicazione di video streaming consiste nel visua-

lizzare i frame mentre li riceve, memorizzando nel buffer gli ultimi.
Lo streaming HTTP presenta un ande svantaggio: i client ricevono tutti la stessa versione codificata del video, nonstante abbiano a disposizione una larghezza di banda che può variare sensibilmente da un caso all'altro e nel tempo. Per superare questo problema è stato sviluppato un nuovo tipo di streaming basato su HTTP, chiamato **streaming dinamico adattativo su HTTP**, *Dynamic Adaptive Streming Over HTTP*, detto **DASH**. In DASH, i video vengono codificati in diverse versioni, ognuna avente un bit rate differente e quindi un differente livello di qualità. Il client richiede pezzi di segmenti video lunghi alcuni secondi da versioni differenti in modo dinamico. Quando la banda disponibile è elevata, il client seleziona automaticamente i blocchi da una versione con alto bit rate, mentre quando la banda disponibile è pcoa, seleziona una versione a basso bit rate. Il client seleziona un blocco alla volta con un messaggio di richiesta GET HTTP.
Da una parte, DASH permette a client con accessi a Internet diversi di fare streaming del video con codifiche diverse: client con connessioni lente possono ricevere versioin a basso bit rate e quindi a bassa qualtià, mentre client con connessioni in fibra possono ricevere una versione ad alta qualità. D'altra canto, DASH permette anche a un client di adattare la scelta della versione alla banda disponibile se varia durante la sessione. Tale caratteristica è importante per gli utenti mobili, per i quali la banda disponibile fluttua quando cambiano stazione base.
Con DASH, i video nelle varie versioin sono memorizzati nel server HTTP, ognuno a un URL diverso. Il server HTTP ha anche un file di descrizione, detto **manifest file**, che per ogni versione fornisce il rispettivo URL insieme al bit rate. Il client richiede questo file per venire a conoscenza delle varie versioni disponibili. Quindi seleziona a ogni istante un blocco, specificando nel messaggio di richiesta GET di HTTP un URL e un intervallo di byte. Mentre scarica i blocchi, il client misura la banda di ricezione ed esegue un algoritmo per selezionare il blocco successivo. Naturalmente il client, se ha molti dati del video memorizzati nel buffer e la banda di ricezione misurata è large, sceglie una versione ad alto bit rate per il blocco successivo; al contrario, se ha pochi dati nel buffer e banda bassa, sceglie una versione basso rate. Pertanto DASH permette al client di cambiare liberamente il livello di qualità.

Reti per la distribuzione di contenuti

Oggigiorno molte aziende di video in Internet distribuiscono quotidianamente video on demand con streaming dell'ordine dei Mbps a milioni di utenti. Mandare in streaming una tale mole di traffico a utenti sparsi in tutot il mondo, fornendo riproduzione continua e alta interattività è complesso. L'approccio più diretto sarebbe costruire un unico enorme data center, memorizzare in esso tutti i video e mandarli in streaming direttamente. Questo approccio però presenta tre grandi problemi:

1. Se il client è lontano dal data center, i pacchetti dal server al client devono percorrere un lungo cammino passando per molti ISP, magari in continenti diversi.

Se uno dei collegamenti ha un throughput minore della velocità di consumo del video, anche il throughput totale end-to-end lo sarà, causando continui e fastidiosi fermi immagine.

2. Un video molto popolare verrebbe inviato molte volte sullo stesso collegamento, non solo sprecando banda, ma constrigendo anche l'azienda a pagare tutte le volte il suo ISP per inviare gli stessi dati.
3. Un singolo data center rappresenta un singolo punto di rottura: se il data center o il collegamento da esso a Internet si interrompesse, l'azienda non sarebbe più in grado di distribuire alcun video.

Per superare questi problemi, quasi tutte le maggiori aziende di video streaming usano le **CDN** (*Content Distribution Networks*). Una CDN gestisce server distribuiti in molti posti diversi, memorizza copie dei video e di altri contenuti web nei server e cerca di dirigere le richieste degli utenti al punto della CDN in grado di offrire il servizio migliore. La CDN può usare una **CDN privata**, cioè proprietaria del fornitore di contenuti. Alternativamente può essere usata la **CDN di terze parti** che distribuisce contenuti per conto di molti fornitori di contenuti. Le CDN generalmente adottano una delle due politiche di dislocazione dei server che seguono:

- **Enter deep** («entrare in profondità»). Una filosofia è quella di entrare in profondità nelle reti di accesso degli ISP installando gruppi di server, detti anche cluster, negli ISP di accesso sparsi in tutto il mondo. Questo approccio viene usato distribuendo server in migliaia di posti diversi. L'obiettivo è quello di essere vicini agli utenti finali in modo da migliorare il ritardo percepito dall'utente e il throughput, diminuendo il numero di collegamenti e router tra l'utente finale e il cluster CDN da cui riceve i contenuti. Questo approccio pone però grandi sfide nella manuntenzione e gestione dei cluster.
- **Bring home** («portare a casa»). Il secondo approccio è quello di portarsi in caso l'ISP costruendo grandi cluster in pochi punti chiave e interoconneterli usando una rete privata ad alta velocità. invece di entrare negli ISP di accesso, queste CDN pongono i loro cluster negli IXP. Tale approccio presenta meno problemi di gestione e manutenzione, ma spesso anche una minore qualità di servizio.

Una volta posizionati i cluster, la CDN replica i contenuti su di essi. I video raramente richiesti non vengono copiati su tutti i cluster.
Molte CDN non spingono i loro video verso i cluster, ma usano una semplice strategia per cui se un client richiede un video a un cluster che non lo ha memorizzato, il cluster recupera il video da un archivio centrale o da un altro cluster e ne memorrizza localmente una copia mentre lo manda in streaming al client.

Come funziona la CDN

Quando un browser nell'host di un utente chiede il recupero di uno specifico video identificato da un URL, la CDN deve interecettare la richiesta in modo d poter

1. determinare il cluster di server più appropriato per quel client a quell'istante
2. dirigere la richiesta del client a uno dei server di quel cluster.

Esaminiamo i meccanismi che stanno dietro l'intercettazione e il reindirizzamento di una richiesta, discutendo poi come una CDN decida quale sia il cluster più adatto. Molte CDN sfruttano il servizio DNS per intercettare e ridirigere le richieste. Consideriamo un esempio dove un fornitore di contenuti, *NetCinema*, impieghi una CDN di terza parte, *KingCDN*, per distribuire i suoi video. A ogni video viene assegnato un URL che include la stringa «video» e un identificatore univoco per tale video. Vengono compiuti 6 passi:

1. L'utente visita la pagina web di *NetCinema*;
2. Quando l'utente seleziona il link *http://video.netcinema.com/6Y7B23V* , il suo host invia un'interrogazione DNS a *video.netcinema.com*
3. Il **DNS server locale (LDNS)** dell'utente invia l'interrogazione DNS a un DNS server autoritativo per *NetCinema* che osserva la stringa «video» nel nome dell'host *video.netcinema.com*. Il DNS server autoritativo per *NetCinema* per passare l'interrogazione DNS a *KingCDN*, invece di restituire un indirizzo IP, restituisce all'LDNS il nome di un host nel dominio di *KingCDN*.
4. Da questo momento l'interrogazione DNS entra nell'infrastruttura DNS privata di *KingCDN*. Lo LDNS dell'utente invia una seconda interrogazione e infine il sistema DNS di *KingCDN* restituisce gli indirizzi IP di un server *KingCDN* all'LDNS. È quindi qui, all'interno del sistema DNS di *KingCDN*, che viene specificato il server CDN da cui il client riceverà il contenuto.
5. LDNS inoltra l'indirizzo IP del nodo CDN che fornirà il contenuto all'host dell'utente.
6. Il client, una volta ricevuto l'indirizzo IP del server di *KingCDN*, stabilisce una connessione TCP diretta con il server a quell'indirizzo IP e gli invia una richiesta GET HTTP per il video. Nel caso venga impiegato DASH, il server innanzitutto inverià al client il file manifesto con una lista di URL.

Strategie di selezione dei cluster

Il cuore dell'installazione di una CDN è la **strategia di selezione dei cluster**: un meccanismo per dirigere dinamicamente i client a un cluster di server o a un data center della CDN. La CDN apprende l'indirizzo IP del server LDNS del client attraverso la richiesta DNS del client. Dopo aver appreso tale indirizzo IP, la CDN deve selezionare un cluster appropriato. Le strategie di selezione del cluster sono generalmente proprietarie.

Una semplice strategia consiste nell'assegnare a un client il cluster *geograficamente più vicino*. Usando un database commerciale di geo-localizzazione, gli indirzzi IP degli LDNS vengono associati a un luogo geografico. La CDN, quando riceve una richiesta DNS da un particolare LDNS, sceglie il cluster a esso più vicino geograficamente in linea d'aria. Tale soluzione potrebbe non andare bene per alcuni client,

in quanto il cluster più vicino potrebbe essere diverso da quello più vicino dal punto di vista del percorso in rete. Un altro problema derivato da tutti gli approcci basati sul DNS deriva dal fatto che alcunu utenti sono configurati per usare LDNS remoti. Inoltre questa strategia non tiene conto delle variazioni temporali del ritardo di rete e della banda disponibile.
Un secondo approccio determina il cluster migliore per un client basandosi sulle condizioni di traffico correnti, effettuando **misure in tempo reale** delle prestazioni di ritardo e perdita tra cluster e client. Un problema di questo approccio è che molti LDNS sono configurati per non rispondere a tali richieste.

3.2. DNS: il servizio directory di Internet

Gli host Internet possono essere identificati in vari modi. Gli **hostname** quali *www.facebook.com*, *www.google.com*, risultano abbastanza approprati per le persone, ma forniscono poca informazione sulla loro collocazione all'interno di Internet.
Un nome quale *www.eurecom.fr*, che termina con il suffisso del paese, *.fr*, ci dice che l'host si trova probabilmente in Francia, ma niente di più. Inoltre, dato che questi nomi sono costituiti da un numero variabile di caratteri alfanumerici, sarebbero difficilmente elaborabili dai server. Per tali motivi, gli host vengono identificati dai cosiddetti **indirizzi IP**.
Un indirizzo IP consiste di quattro byte e presenta una rigida struttura gerarchica. Ha una forma del tipo 121.7.106.83, in cui ogni punto separa uno dei byte espressi con un numero decimale compreso tra 0 e 255. Un indirizzo IP è gerarchico perchè, leggendolo da sinistra a destra, otteniamo informazioni semper più specifiche sulla collocazione dell'host in Internet.

3.2.1. Servizi forniti da DNS

Quindi, esistono due modi per identificare gli host: il nome e l'indirizzo IP. Le persone preferiscono il primo, mentre i router prediligono gli indirizzi IP a lunghezza fissa e strutturati in modo gerarchico. Al fine di conciliare i due approcci è necessario un servizio che traduce gli hostname nei loro indirizzi IP (o viceversa). Si tratta del principale compito del *domain name system*, **DNS**. DNS è

1. un database distribuito implementato in una gerarchia di **DNS server**
2. un protocollo a livello di applicazione che consente agli host di interrogare il database.

I DNS server sono generalmente macchine UNIX che eseguono un software chiamato BIND, Berkley Internet Name Domain. Il protocollo DNS utilizza UDP e la porta 53 per mantenere una bassa latenza. Il protocollo DNS utilizza, invece, il protocollo TCP sulla porta 53 quando ci sono molti dati, che superano i 512 byte, da trasferire in modo affidabile. L'estensione EDNS permette oggi di inviare risposte UDP più grandi, fino a 1232 byte, limitando la necessità di passare a TCP.

DNS viene utilizzato da altri protocolli a livello di applicazione, tra cui HTTP e SMTP, per tradurre i nomid i host forniti dall'utente in indirizzi IP.
Analizziamo cosa succede quando un browser in esecuzione sull'host di un utente richiede l'URL *www.someschool.edu/index.html*. L'host dell'utente, per essere in grado di inviare un messaggio di richiesta HTTP al web server *www.someschool.edu*, deve ottenere prima il suo indirizzo IP. Ciò avviene come segue.

1. La stessa macchina utente esegue il lato client dell'applicazione DNS.
2. Il browser estrae il nome dell'host, *www.someschool.edu*, dall'URL e lo passa al lato client dell'applicazione DNS.
3. Il client DNS invia un'interrogazione contenente l'hostname a un DNS server.
4. Il client DNS prima o poi riceve una risposta, che include l'indirizzo IP corrispondente all'hostname.
5. Una volta ricevuto l'indirizzo IP dal DNS, il browser può dare inizio a una connessione TCP verso il processo server HTTP collegato alla porta 80 di quell'indirizzo IP.

Il DNS introduce un ritardo aggiuntivo, talvolta sostanziale, alle applicazioni Internet che lo utilizzano. Per evitare ciò, l'indirizzo IP desiderato si trova spesso nella cache di un DNS server vicino, il che aiuta a ridurre il traffico DNS in rete e il ritardo medio del servizio.
Oltre alla traduzione degli hostname in indirizzi IP, DNS mette a disposizione altri importanti servizi.

1. **Host aliasing**. Un host dal nome complicato può avere uno o più sinonimi, detti *alias*. Per esempio, *relay1.west-coast.enterprise.com* potrebbe avere, diciamo, due sinonimi quali *enterprise.com* e *www.enterprise.com*. In questo caso, si dice che il nome *relay1.west-coast.enterprise.com* è un **hostname canonico**. Gli alias sono generalmente più facili da ricordare rispetto agli hostname canonici. Il DNS può essere invocato da un'applicazione per ottenere l'hostname canonico di un sinonimo.
2. **Mail server aliasing**. È auspicabile che gli indirizzi di posta elettronica siano facili da ricordare. Ad esempio se un'utente ha un account Hotmail, il suo indirizzo di posta elettronica potrebbe essere «bob@yahoo.com». Tuttavia, l'hostname del server di posta Hotmail è molto più complicato da ricordare rispetto a *yahoo.com*. Ad esempio, il nome canonico potrebbe essere simile a *relay1.west-coast.yahoo.com*. Un'applicazione di posta può invocare il DNS per ottenere il nome canonico di un sinonimo fornito.
3. **Distribuzione del carico di rete (load distribution)**. Il DNS viene utilizzato per distribuire il carico tra server replicati, per esempio dei web server. I siti con molto traffico, vengono replicati su più server, ognuno eseguito su un host diverso con indirizzo IP differente. Nel caso di web server replicati, va associato a ogni hostname canonico un insieme di indirizzi IP. Il database DNS contiene

questo insieme di indirizzi. Quando i client effettuano una query DNS per un nome associato a un insieme di indirizzi, il server risponde con l'intero insieme di indirizzi, ma ne varia l'ordinamento a ogni risposta. Dato che un client invia il suo messaggio di richiesta HTTP al primo indirizzo IP elencato nell'insieme, la rotazione DNS distribuisce il traffico sui server replicati. La rotazione viene anche utilizzate affinchè più server di posta possano condividere lo stesso nome. Inoltre, le società di distribuzione dei contenuti hanno fatto uso del DNS in mdoi più sofisticati per effettuare la diffusione di contenuti web.

DNS è specificato nelle RFC 1034 e 1035 ed è stato aggiornato nelle successive RFC aggiuntive.

3.2.2. Panoramica del funzionamento di DNS

Analizziamo il servizio di traduzione da hostname a indirizzo IP.
Supponiamo che una certa applicazione in esecuzione sull'host di un utente abbia necessità di trudurre un hostname in indirizzo IP. L'applicazione invocherà il lato client del DNS, specificando l'hostname da tradurre. Su molte macchine basate su UNIX, `gethostbyname()` è la chiamata di funzione effettuata da un'applicazione per ottenere il servizio di traduzione. Il DNS sull'host prende poi il controllo, inviando un messaggio di richiesta sulla rete. Tutte le query DNS e i messaggi di risposta vengono inviati all'interno di datagrammi UDP diretti alla porta 53. Dopo un ritardo che varia dai millisecondi ai secondi, il client DNS sull'host dell'utente riceve un messaggio di risposta contenente la corrispondenza desiderata, che viene poi passata all'applicazione che ne ha fatto richiesta. Dal punto di vista dell'applicazione, il DNS è una scatola nera che fornisce un servizio di traduzione semplice e diretto. La scatola nera è costituita da un gran numero di DNS server distribuiti per il mondo e da un protocollo a livello di applicazione che specifica la comunicazione tra DNS server e host richiedenti.
Un primo approccio potrebbe essere quello di utilizzare un DNS server contenente tutte le corrispondenze. Questa semplicità progettuale è inappropriata per l'attuale Internet, dotata di un vasto e sempre crescente numero di host.
Tra i problemi legati a uno schema centralizzato ricordiamo i seguenti.

- **Un solo point of failure** (*punto di vulnerabilità*). Se il DNS server si guasta, ne soffre l'intera Internet.
- **Volume di traffico**. Un singolo DNS server dovrebbe gestire tutte le richieste.
- **Database centralizzato distante**. Un singolo DNS server non può essere vicino a tutti i client.
- **Manutenzione**. Il singolo DNS server dovrebbe contenere record relativi a tutti gli host di Internet. Non solo tale database centralizzato sarebbe vasto, ma dovrebbe essere aggiornato frequentemente per tener conto di ogni nuovo host.

Un database centralizzato su un singolo DNS server non è in grado di adattarsi alla crescita esponenziale della rete. Quindi, il DNS è stato progettato in maniera distribuita.

Un database distrubuito e gerarchico

Per trattare il problema della scalabilità, il DNS utilizza un grande numero di server, organizzati in maniera gerarchica e distribuiti nel mondo. In prima approssimazione, esistono tre classi di DNS server: i **root server**, i **top-level domain (TLD) serve** e i **server autoritativi**, organizzati in una gerarchia, come mostrato nella seguente figura.

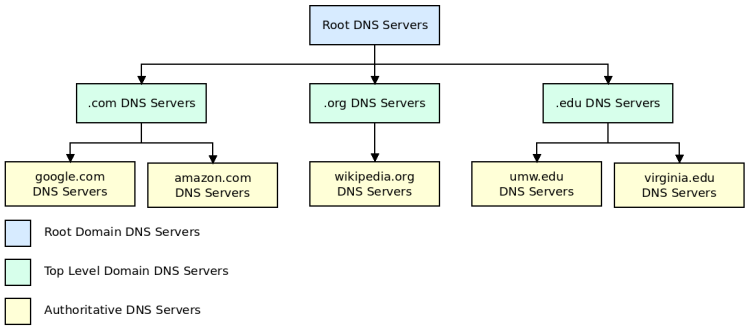


Figura 5: Gerarchia parziale dei server DNS

Per comprendere l'interazione tra le classi, supponiamo che un client DNS voglia determinare l'indirizzo IP relativo all'hostname `www.amazon.com`. Per fare ciò, il client contatta uno dei root server, che gli restituisce uno o più indirizzi IP relativi al TDL server per il dominio `com`. Contatta uno di questi TLD server,che gli restituisce uno o più indirizzi IP del server autoritativo per `amazon.com`. Infine, contatta uno dei server autoritativi per `amazon.com`, che gli restituisce l'indirizzo IP dell'hostname `www.amazon.com`. Analizziamo le tre classi di DNS server.

- **Root server**. In Internet esistono più di 1000 root server, dislocati in tutto il mondo. Tali root server sono copie di 13 differenti root server gestiti da 12 diverse organizzazioni, coordinate attraverso la *Internet Assigned Numbers Authority*. I root server forniscono gli indirizzi IP dei TLD server.
- **Top-level domain (TLD) server**. Questi server si occupano dei domini di primo livello quali com, org, net, edu e gov, e di tutti i domini di primo livello relativi ai vari paesi, come it, uk, fr, ca e jp. I TLD server forniscono gli indirizzi IP dei server autoritativi. L'assegnazione dei domini che indicano una nazione o un tipo di organizzazione è gestita dall'ICANN (Internet Corporation for Assigned Names and Numbers).
- **DNS server autoritativi**. Ogni organizzazione dotata di host pubblicamente accessibili tramite Internet deve fornire record DNS pubblicamente accessibili che associno i nomi di tali host a indirizzi IP. Il DNS server autoritativo dell'organizzazione ospita questi record. Un'organizzazione può scegliere di im-

plementare il proprio server autoritativo o di pagare un fornitore di serverizi per ospitare questi record su un suo server. La maggior parte delle università e delle grandi società implementa e gestisce dei propri server autoritativi primario e secondario.

I DNS server appena descritti sono tutti collocati in una gerarchia di DNS server. Esiste un altro importante tipo di DNS, detto **DNS server locale**, che non appartiene strettamente alla gerarchia di server, ma che è comunque centrale nell'architettura DNS. Ciascun ISP ha un DNS server locale, detto anche **default name server**. Quando un host si connette a un ISP, quest'ultima gli fornisce un indirizzo IP tratto da uno o piu dei suoi DNS server locali, generalmente tramite DHCP. Si può facilmente determinare l'indirizzo IP del proprio DNS server locale accedendo alla finestra di stato della rete in Windows o UNIX. Un DNS server locale è solitamente «vicino» all'host. Quando un host effettua una richiesta DNS, la query viene inviata al DNS server locale, che opera da proxy e inoltra la query alla gerarchia dei DNS server.
Le richieste DNS possono essere di due tipi:

- **query ricorsive**: è una richiesta in cui un client chiede a un server DNS (detto *resolver ricorsivo*) di ottenere l'indirizzo IP completo e definitivo per un nome di dominio, oppure di restituire un errore se non lo trova. Il server ha tutta la responsabilità: se non ha il dato in cache, contatta altri server per conto del client finchè non ottiene la risposta definitiva e gliela consegna.
- **query iterativa**: il server DNS interpellato non fa tutto il lavoro per conto del richiedente. Se conosce la risposta la fornisce, altrimenti, resituisce la «migliore risposta possibile», ovvero un **rinvio (referral)**, indicando al client quale altro server DNS conviene contattare subito dopo. Il client stesso prosegue l'esplorazione passo dopo passo.

I root server e i TLD server sono generalmente configurati per essere non-ricorsivi e non accettano query ricorsive a causa dell'eccessivo traffico.

DNS Caching

Il **DNS caching** è una caratteristica di fondamentale importanza. Il DNS sfrutta in modo estensivo il caching per migliorare le prestazioni di ritardo e per ridurre il numero di messaggi DNS che «rimbalzano» su Internet. L'idea del DNS caching è semplice. In una concatenazione di richieste, il DNS server che riceve una risposta DNS può mettere in cache le informazioni contenute.
Se una ⟨hostname/indirizzo IP⟩ è nella cache di un DNS server e giunge al server un'altra richiesta con lo stesso hostname, il DNS server può fornire l'indirizzo IP desiderato, anche se non è autoritativo per tale indirizzo. Dato che gli host e le associazioni tra nome e indirizzo IP non sono in alcun modo permanenti, i DNS server invalidano le informazioni in cache dopo un periodo di tempo fissato. Un DNS

server locale, può, inoltre, memorizzare in cache gli indirizzi IP dei TLD server, consentendogli di aggirare i root server nella catena di richieste.

3.2.3. Record e messaggi DNS

I server che implementano il database distribuito di DNS memorizzano i cosiddetti **record di risorsa** (RR, *resource record*), tra cui quelli che forniscono le corrispondenze tra nomi e indirizzi. Ogni messaggio di risposta DNS trasporta uno o più record di risorse. Un record di risorsa contiene i seguenti campi:

(Name, Value, Type, TTL)

TTL è il time to live, ossia il tempo residuo di un record e determina quando una risorsa vada rimossa dalla cache. Il significato di `Name` e `Value` dipene da `Type`:

- Se `Type=A`, allora `Name` è il nome dell'host e `Value` è il suo indirizzo IP. Pertanto un record di tipo A fornisce la corrispondenza tra hostname standard e indirizzo IPv4.
- Se `Type=AAAA`, allora `Name` è il nome dell'host e `Value` è il suo indirizzo IPv6.
- Se `Type=NS`, allora `Name` è un dominio e `Value` è l'hostname del DNS server autoritativo che sa come ottenere gli indirizzi IP degli host nel dominio. Questo record viene usato per instradare le richieste DNS successive alla prima nella concatenazione delle query.
- Se `Type=CNAME`, allora `Value` rappresenta il nome canonico dell'host per il sinonimo `Name`. Questo record può fornire agli host richiedenti il nome canonico relativo a un hostname.
- Se `Type=MX`, allora `Value` è il nome canonico di un mail server che ha il sinonimo `Name`. Questo tipo di record consente agli hostname dei mail server di avere sinonimi semplici. Per ottenere il nome canonico del server di posta, un client DNS dovrebbe interrogare un record MX. Per ottenere il nome canonico dell'altro server, il client DNS dovrebbe interrogare il record CNAME.

Un DNS server autoritativo per un certo hostname contiene un record di tipo A per l'hostname. Anche se il server non fosse autoritativo, potrebbe tuttavia contenere un record di tipo A nella propria cache. Se un server non è quello autoritativo per un certo hostname, allora conterrà un record di tipo NS per il dominio che include l'hostname, e conterrà anche un record di tipo A che fornisce l'indirizzo IP del DNS server nel campo `Value` del record NS.

Messaggi DNS

Abbiamo fatto riferimento agli unici due tipi di messaggio DNS: le query e i messaggi di risposta che presentano, entrambi, lo stesso formato, mostrati nella seguente figura.

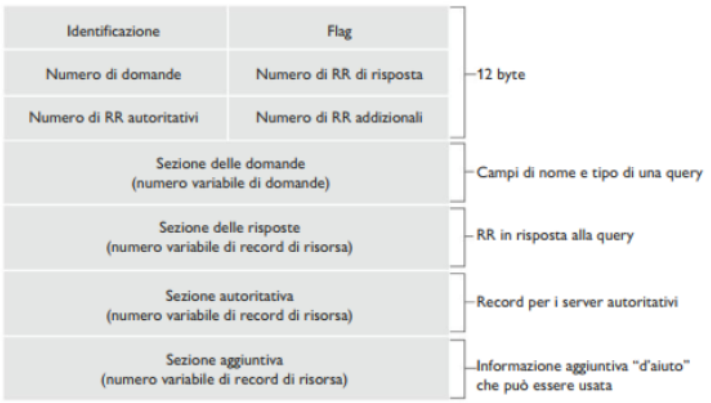


Figura 6: Formato dei messaggi DNS

La semantica dei campi dei messaggi DNS è la seguente.

- I primi 12 byte rappresentano la *sezione di intestazione (header section)*, che a sua volta contiene un certo numero di campi.
  - Il primo è un numero di 16 bit che identifica la richiesta. Tale identificatore viene copiato nei messaggio di risposta a una richiesta, consentendo al client di far corrispondere le risposte ricevute con le query inviate.
  - Il campo flag è composto da una serie di bit: il primo, il bit di richiesta/risposta indica se è il messaggio è una richiesta (0) o una risposta (1). Un bit viene impostato nei messaggi di risposta quando il DNS server è autoritativo per il nome richiesto. Un ulteriore bit, chiamato **richiesta di ricorsione**, viene impostato quando un client desidera che il DNS server effettui ricorsione quando non dispone del record. Si imposta un campo da 1 bit di ricorsione disponibile all'interno di una risposta se il DNS server supporta la ricorsione.

  Nell'intestazione troviamo anche quattro campi il cui nome comincia con «numero di», che indicano il numero di occorrenze delle quattro sezioni di tipo dati che seguono l'intestazione.
- La *sezione delle domande* contiene informazioni sulle richieste che stanno per essere effettuate. Inoltre, include
  - un campo nome con il nome che sta per essere richiesto;
  - un campo tipo che indica il tipo della domanda sul nome.
- In una risposta proveniente da DNS server, la *sezione delle risposte* contiene i record di risorsa relativi al nome originariamente richiesto. Una risposta può restituire più RR, dato che un hostname può avere più indirizzi IP. È il caso dei web server replicati.
- La *sezione autoritativa* contiene i record di altri server autoritativi.
- La *sezione aggiuntiva* racchiude altri record utili: ad esempio, se il campo di risposta relativo a una richiesta MX contiene un record di risorsa che fornisce

l'hostname canonico del server di posta, la sezione aggiuntiva contiene un record di tipo A che fornisce l'indirizzo IP relativo all'hostname canonico del server di posta.

3.2.4. Registrazione di un dominio e Zone Transfer

Per inserire un nuovo dominio nel database DNS (ad esempio `networkutopia.com`), è necessario rivolgersi a un **registrar**. Un registrar è un'azienda commerciale, tipicamente accreditata dall'ICANN (Internet Corporation for Assigned Names and Numbers), che verifica l'unicità del nome di dominio, richiede un compenso per il servizio e si occupa di inserirlo nel sistema DNS.
Al momento della registrazione, l'utente deve fornire al registrar i nomi e gli indirizzi IP dei propri DNS server autoritativi, generalmente un primario e un secondario (es. `dns1.networkutopia.com` e `dns2.networkutopia.com`, insieme ai relativi IP). Il registrar provvede a inserire nei TLD server di competenza (ad esempio i server responsabili per il suffisso `.com`) due tipologie di record: i record di tipo NS e quelli di tipo A. Nello specifico, per il server primario dell'esempio verrebbero inseriti i seguenti record di risorsa:

- `(networkutopia.com, dns1.networkutopia.com, NS)`
- `(dns1.networkutopia.com, 212.2.212.1, A)`

Successivamente, è responsabilità del proprietario del dominio assicurarsi che nei propri server autoritativi vengano inseriti i record di risorsa specifici per i servizi ospitati. Ad esempio, deve essere configurato il record di tipo A per il server web (`www.networkutopia.com`) e il record MX per il server di posta elettronica (`mail.networkutopia.com`). L'aggiunta di questi record può avvenire configurando staticamente i server oppure, più recentemente, in modo dinamico inviando messaggi DNS grazie all'opzione UPDATE (specificata nelle RFC 2136 e 3007).
Completata la configurazione, la risoluzione procede normalmente: il DNS server locale di un utente che vuole visitare il sito interrogherà il TLD server, il quale risponderà fornendo l'IP del server autoritativo grazie ai record precedentemente inseriti dal registrar. Interrogando infine il server autoritativo, il client otterrà l'indirizzo IP del web server desiderato.

Zone Transfer

Per garantire disponibilità e affidabilità, i record DNS appena creati devono essere replicati. I record vengono copiati dal server autoritativo primario a quelli secondari tramite un'operazione chiamata **Zone Transfer**. Essendo un'operazione che comporta spesso il trasferimento di un'intera zona e di molti dati (superando il classico limite di 512 byte del protocollo UDP), il trasferimento avviene in modo affidabile su protocollo TCP. Le query utilizzate dai server secondari per allinearsi al primario sono principalmente due:

- **AXFR**: per richiedere una copia completa e integrale dei record della zona.

- **IXFR**: per richiedere un trasferimento incrementale, ottenendo solamente le modifiche più recenti.

Livello di Trasporto

4.1. Introduzione e servizi a lviello di trasporto

Un protocollo a livello di trasporto mette a disposizione una **comunicazione logica** tra processi applicativi di host differenti.
Per comunicazione logica si intende, dal punto di vista dell'applicazione, che tutto proceda come se gli host che eseguono i processi fossero direttamente conessi. I processi applicativi usano la comunicazione logica fornita dal livello di trasporto per scambiare messaggi, senza preocupparsi dei dettagli dell'infrastruttura fisica utilizzata per trasposrtarli.
I protocolli a livello di trasporto sono implementati nei sistemi periferici, ma non nei router della rete. Nel mittente, il livello di trasporto converte i messaggi che riceve da un processo applicativo in pacchetti a livello di trasposrto, noti come **segmenti**. Questo avviene spezzando i messaggi applicativi in parti più piccole e aggiungendo a ciascuna di esse un'intestazione di trasporto per creare un segmento. Il livello di rete del ricevente estrae il segmento del datagramma e lo passa al livello di trasporto. Quest'ultimo elabora il segmento ricevuto, rendendo disponibili all'applicazione destinataria i dati del segmento.
Internet fornisce due protocolli a livello di trasporto, TCP e UDP, che forniscono servizi diversi alle applicazioni che ne fanno uso.

4.1.1. Relazione tra i livello di trasporto e di rete

Il livello di trasposrto è collocato sopra quello di rete nella pila di protocolli, ricordiamo la **Figura 3**. Un livello di trasporto mette a disposizione una comunicazione logica tra processi che vengono eseguiti su host diversi, un protocollo a livello di rete fornisce comunicazione logica tra host. La distinzione è sottile, ma importante. Determinati servizi possono essere garantiti da un protocollo di trasporto anche se il sottostante protocollo di rete non offre un servizio corrispondente. Ad esempio, un protocollo di trasporto può offrirre il servizio di trasferimento dati affidabile anche quando il sottostante protocollo di rete non lo è. Considerando un altro aspetto, un protocollo di trasposrto può usare la cifratura per garantire che i messaggi delle applicazioni non vengano letti da intrusi, anche quando il livello di rete non può garantire la riservatezza dei segmenti a livello di trasporto.

4.1.2. Panoramica del livello di trasporto di Internet

Internet mette a disposizione del livello di applicazione due protocolli. Uno è **UDP**, *User Datagram Protocol*, che fornisce alle applicazioni un servizio non affidabile e non orientate alla connessione, l'altro è **TCP**, *Transmission Control Protocol*, che offre un servizio affidabile e orientato alla connessione.
Prima di entrare nel dettaglio dei due protocolli è meglio analizzare brevemente il livello di rete. Il protocollo di rete in Internet ha un nome: IP (Internet Protocol). Tale protocollo fornisce comunicazione logica tra host. Il suo modello di servizio prende il nome di **best-effort delivery service** o, **best-effort**. Questo significa che IP fa del suo meglio per consegnare i segmenti tra host comunicanti ma non offre garanzie. NOn assicura né la consegna dei segmenti né il rispetto dell'ordine originario e non garantisce neppure l'integrità dei dati all'interno dei segmenti. Per queste ragioni si dice che IP offra un **servizio non affidabile**.
Il compito dei protocolli TCP e UDP è l'estensione del servizio di consegna di IP «tra sistemi periferici» a quello di consegna «tra processi in esecuzione sui sistemi periferici». Il passaggio, da consegna host-to-host a consegna process-to-process, viene detto **multiplexing** e **demultiplexing a livello di trasporto**. Inoltre, TCP e UDP, forniscono un controllo di integrità includendo campi per il riconoscimento di errori nelle intestazioni dei propri segmenti. UDP, come IP, costituisce un servizio inaffidabile: non garantisce che i dati inviati da un processo arrivino intatti (e neanche che arrivino) al processo destinatario.
TCP offre diversi servizi aggiuntivi. Innanzitutto, fornisce un **trasferimento dati affidabile** e, quindi, garantisce che i dati vengano trasferiti da un processo a un altro in modo corretto e ordinato. Pertanto TCP converte il servizio inaffidabile tra sistemi periferici, tipico di IP, in un servizio affidabile di trasporto dati tra processi. TCP fornisce anche il **controllo di congestione**, un servizio offerto alle applicazioni e a Internet nel suo complesso. In pratica, evita che le connessioni TCP intasino i collegamenti e i router tra gli host comunicanti con un'eccessiva quantità di traffico. Questo è reso possibile regolando la velocità alla quale il lato mittente della connessione TCP immette traffico in rete. Il traffico UDP, al contrario, non viene regolato. Le applicazioni che usano UDP possono spedire a qualsiasi velocià desiderata e per tutto il tempo voluto.

4.2. Multiplexing e demultiplexing

Analizziamo il servizio di multiplexing e demultiplexing in Internet, anche se è un servizio presente in tutte le reti di calcolatori.
Nell'host destinatario il livello di trasposrto riceve segmenti dal livello di rete immediatamente sottostante. Il livello di trasposrto ha il compito di consegnare i dati di questi segmenti al processo applicativo appropriato in esecuzione nell'host.

Esaminiamo come viene realizzato.
Ricordiamo che un processo può gestire una o più **socket**, attraverso le quali i dati fluiscono dalla rete al processo e viceversa. Di conseguenza, il livello di trasposrto nell'host di ricezione non trasferisce i dati direttamente a un processo, ma a una socket che fa da intermediario. Siccome, a ogni dato istante, può esserci più di una socket nell'host di ricezione, ciascuna avrà un identifcatore univoco il cui formato dipende dal fatto che si tratti di socket UDP o TCP.
Vediamo come l'host in ricezione indirizzi verso la socket appropriata il segmento a livello di trasporto in arrivo. Ciascun segmento a lviello di trasporto ha vari campi che permettono di fare ciò. Nel lato del ricevente, il livello di trasporto esamina questi campi per identificare la socket di ricezione e quindi vi dirige il segmento. Il compito di trasportare i dati dei segmenti a livello di trasporto verso la giusta socket viene detto **demultiplexing**. Il compito di radunare frammenti di dati da diverse socket sull'host di origine e incapsulare ognuno con intestazioni a livello di trasporto per creare dei segmenti e passarli al livello di rete, viene detto **multiplexing**.
Le funzioni di multiplexing e demultiplexing hanno specifico interesse ogni volta che un protocollo a un qualsiasi livello è utilizzato da più entità al livello immediatamente superiore.
Vediamo come le funzioni di multiplexing e demultiplexing vengono realizzati negli host. Da quanto visto in precedenza, il multiplexing a livello di trasporto richiede

1. che le socket abbiano identificatori unici
2. ogni segmenti presenti campi che indichino la socket cui va consegnato il segmento.

Questi sono, come indicati nella figura seguente, il **campo del numero di porta** e il **campo del numero di porta di destinazione**.

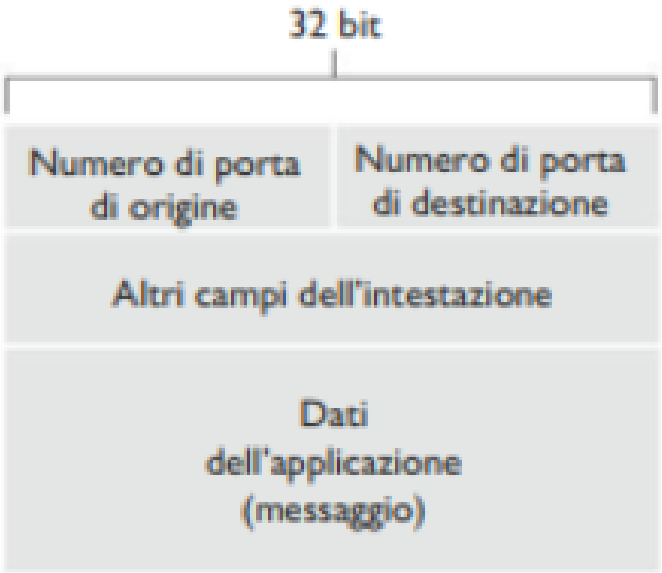


Figura 7: I campi del numero di porta di origine e di destinazione nei segmenti a livello di trasporto

I segmenti UDP e TCP presentano anche altri campi. I numeri di porta sono di 16 bit e vanno da 0 a 65535, quelli che vanno da 0 a 1023 sono chiamati **numeri di porta noti** e sono riservati per essere usati da protocolli applicativi ben noti, come HTTP (porta 80), FTP (porta 21) e così via. L'elenco dei numeri di porta noti è fornito nell'RFC 1700. Le porte da 1024 a 49151 sono **porte registrate**, *registered ports*, che sono registrate da IANA su richiesta di terze parti. Queste sono dette anche *porte utente*, perchè utilizzabili da applicazioni non di sistema. Le porte da 49152 a 65535 sono dette **porte private** o **dinamiche** che vengono assegnate automaticamente e temporaneamente quando un'app client avvia una connessione.

4.2.1. Multiplexing e demultiplexing non orientati alla connessione

Descriviamo il processo di multiplexing/demultiplexing sul protocollo UDP. Supponiamo che un processo nell'host A, con porta UDP 19157, voglia inviare un blocco di dati applicativi a un processo con porta UDP 46428 nell'host B. Il livello di trasporto di A crea un segmento che include i dati applicativi, i numeri di porta di origine e di destinazione e altri valori. Il livello di trasporto passa, il segmenti risultante al livello di rete, che lo incapsula in un datagramma IP, ed effettua un tentivo best-effort di consegna del segmento all'host in ricezione. Se il segmento arriva all'host B, il suo livello di trasporto esamina il numero di porta di destinazione del segmento e lo coonsegna alla propria socket identificata da tale porta. L'host B potrebbe avere in esecuzione più processi, ciascuno con la propria socket UDP e relativo numero di porta. Quando i segmenti UDP giungono dalla rete, l'host B

dirigie ciascun segmento alla socket appropriata.
Una socket UDP viene identificata da una coppia formata da indirizzo IP e numero di porta di destinazione. Due segmenti UDP che hanno diversi indirizzi IP e/o diversi numeri di porta, ma hanno stesso indirizzo IP e stesso numero di porta di destinazione, vengono diretti allo stesso protocollo di destinazione tramite la medesima socket.
Il numero di porta di origine serve come parte di un «indirizzo di ritorno»: quando B vuole restituire il segmento ad A, la porta di destinazione del segmento da B verso A assumerà il valore della porta di origine del segmento da A verso B. L'indirizzo di ritorno completo è costituito dall'indirizzo IP di A più il numero di porta di origine.

4.2.2. Multiplexing e demultiplexing orientati alla connessione

Per comprendere il demultiplexing TCP, dobbiamo analizzare le socket TCP e come si stabiliscono connessioni TCP. Una differenza tra socket TCP e UDP risiede nel fatto che la prima è identificata da quattro parametri: indirizzo IP di origine, numero di porta di origine, indirizzo IP di destinazione e numero di porta di destinazione. Pertanto, quando un segmento TCP giunge dalla rete in un host, quest'ultimo utilizza i quattro valori per dirigere il segmento verso la socket appropriata. Al contrario di UDP, due segmenti TCP in arrivo, aventi indirizzi IP di origine o numero di porta di origine diversi, vengono diretti a due socket differenti, anche a fronte di indirizzo IP e porta di destinazione uguali, con l'eccezione dei segmenti TCP che trasportano la richiesta per stabilire la connessione.
L'host server può ospitare più socket TCP contemporanee collegate a processi diversi, ognuna identificata da una specifica quaterna di valori. Quando il segmento TCP arriva all'host, i quattro campi citati prima vengono utilizzati per fare demultiplexing e dirigere il segmento verso la socket appropriata.
La situazione è schematizzata nella seguente figura:

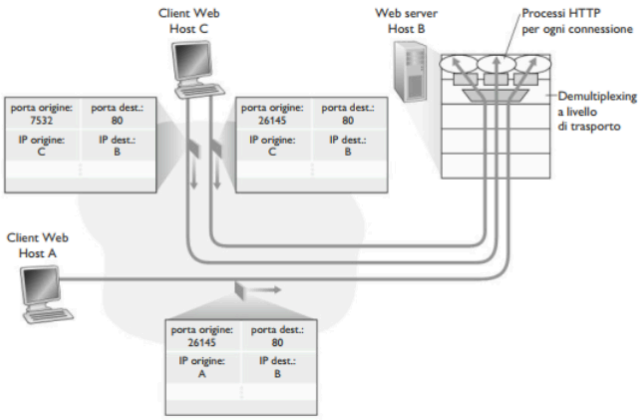


Figura 8: Due client usano stesso numero di porta di destinazione per comunicare con stessa applicazione sul web server

4.3. Trasporto non orientato alla connessione: UDP

Il protocollo UDP fa il minimo che un protocollo di trasporto debba fare. A parte la funzionalità di multiplexing/demultiplexing e una forma di controllo degli errori molto semplice, non aggiunge nulla a IP. Quando lo sviluppatore sceglie UDP anzichè TCP, l'applicazione dialoga quasi in modo diretto con IP. UDP prende i messaggi dal processo applicativo, aggiunge il numero di porta di origine e di destinazione per il multiplexing/demultiplexing, aggiunge altri due piccoli campi e passa il segmento risultante a livello di rete. Questi incapsula il segmento in un datagramma IP e quindi effettua un tentativo di consegnarlo all'host di destinazione in modalità best-effort. Se il segmento arriva a destinazione, UDP utilizza il numero di porta di destinaizone per consegnare i dati del segmento al processo applicativo corretto. Notiamo che in UDP non esiste handhsaking tra le entità di invio di ricezione a lviello di trasporto. Infatti si dice che UDP è *non orientato alla connessione*. UDP fornisce un sercizio senza connessione non solo unicast, ma anche **multicast** e **broadcast**.
DNS è un tipico esempio di protocollo applicativo che utilizza UDP. Anche **SNMP (Simple Network Management Protocol)** si affida ad UDP e anche applicazioni basate su semplici servizi richiesta-risposta.
Ci sono diversi motivi per i quali uno svilupattore dovrebbe scegliere di costruire un'aplicazione su UDP anzichè su TCP.

- *Controllo più preciso a livello di applicazione su quali dati sono inviati e quando.* Non appena un processo applicativo passa dei dati a UDP, quest'ultimo li impacchetta in un segmento che trasferisce immediatamente al livello di rete. TCP, invece, dispone di un meccanismo di controllo della congestione che ritarda l'invio a livello di trasposrto quando uno o più collegamenti tra origine e destinazione diventano eccessivamente congestionati. TCP continua, inoltre, a inviare il segmenti fino a quando viene notificata la sua ricezione da parte della destinazione. Dato che le applicazioni in tempo reale spesso richiedono una velocità minima di invio e non sopportano ritardi eccessivi e tollerano una certa perdita di dati, il modello TCP non si adatta bene a queste esigenze.
- *Nessuna connessione stabilita.* TCP utilizza un handshake a tre vie prima di iniziare il trasferimento dei dati. UDP invece invia dati a raffica senza alcun preliminare formale. Pertanto, UDP non introduce alcun ritardo nello stabilire una connessione. Questo è, probabilemente, il motivo per cui DNS utilizza UDP anzichè TCP. HTTP, invece, usa TCP, dato che l'affidabilità risulta critica per le pagine web con testo. Il protocollo QUIC (Quick UDP Internet Protocol) utilizza UDP come protocollo di trasporto e implementa l'affidabilità in un protocollo a livello di applicazione.

- *Nessun stato di connessione.* TCP mantiene lo stato della connessione nei sistemi perferici. Questo stato include buffer di ricezione di invio, parametri per il controllo di congestione e parametri sul numero di sequenza e di acknowledgement. UDP, invece, n on conserva lo stato della connessione e non tiene traccia di questi parametri. Per questo motivo, un server dedicato a una particolare applicazione può generalmente supportare molti più client attivi quando l'applicazione utilizza UDP anzichè TCP.
- *Minor spazio usato per l'intestazione del pacchetto.* L'intestazione dei pacchetti TCP aggiunge 20 byte, mentre UDP solo 8.

La seguente figura elenca alcune diffuse applicazioni per Internet e i relativi protocolli di trasporto usati.

Applicazione	Protocollo a livello di applicazione	Protocollo di trasporto sottostante
Posta elettronica	SMTP	TCP
Accesso a terminali remoti	Telnet	TCP
Accesso sicuro a terminali remoti	SSH	TCP
Web	HTTP, HTTP/3	TCP (per HTTP), UDP (per HTTP/3)
Trasferimento file	FTP	TCP
Server di file remoti	NFS	generalmente UDP
Dati multimediali in streaming	DASH	TCP
Telefonia su Internet	generalmente proprietario	UDP o TCP
Gestione di rete	SNMP	generalmente UDP
Traduzione di nomi	DNS	generalmente UDP

Figura 9: Protocolli di trasporto delle più diffuse applicazioni Internet

Prima di analizzare la struttura dei segmenti UDP menzionamio che le applicazioni possono ottenere un trasferimento dati affidabile anche con UDP. Ciò avviene se l'affidabilità è insita nell'applicazione stessa. Il protocollo QUIC utilizza UDP come protocollo di trasporto e implementa l'affidabilità in un protocollo a livello di applicazione. Avere affidabilità direttamente nell'applicazione consentirebbe ai processi applicativi di comunicare in modo affidabile senza essere soggetti ai vincoli sulla velocità di trasmissione imposti dai meccanismi del controllo di congestione di TCP.

4.3.1. Struttura dei segmenti UDP

L'RFC 768 definisce la struttura dei segmenti UDP, come mostrato nella seguente figura:

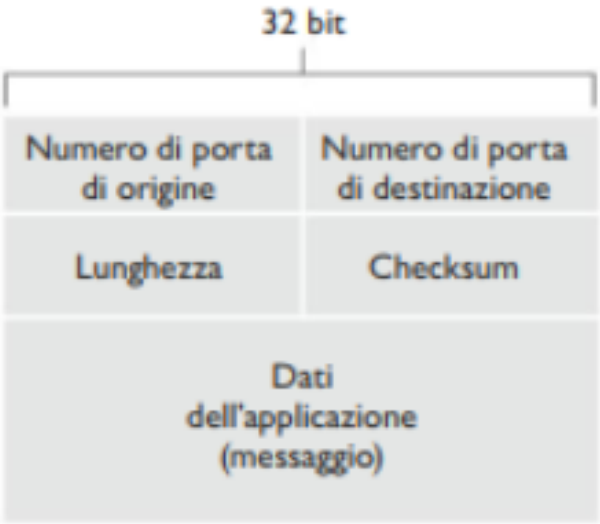


Figura 10: Struttura dei segmenti UDP

L'intestazione UDP presenta solo quattro campi di due byte ciascuno. Il campo *Lunghezza* specifica il numero di byte del segmento UDP e la lunghezza massima è $\leq$ 64 KB. Un valore esplicito di lunghezza è necessario perchè la grandezza del campo *Dati* può essere diversa tra un segmento e quello successivo. L'host ricevente utilizza il checksum per verificare se sono avvenuti errori nel segmento. In realtà, oltre che sul segmento UDP, il checksum è calcolato anche su alcuni campi dell'intestazione IP.

4.3.2. Checksum UDP

Il checksum UDP server per il ritrovamento degli errori. In altre parole, viene utilizzato per determinare se i bit del segmento UDP sono stati alterati durante il loro trasferimento da sorgente a destinazione. Il lato mittente UDP effettua il complemento a 1 della somma di tutte le parole da 16 bit nel segmento, e l'eventuale riporto finale viene sommato al primo bit. Tale risultato viene posto nel campo *Checksum* del segmento UDP.

Esempio 1. Supponiamo di avere le seguenti tre parole di 16 bit

0110011001100000
0101010101010101
1000111100001100

La somma delle prime due è:

$$\begin{array}{r} 0110011001100000 + \\ \underline{0101010101010101 =} \\ 1011101110110101 \end{array}$$

Sommando la terza parola al risultato precedente otteniamo:

$$\begin{array}{r} 1011101110110101 + \\ \underline{1000111100001100 =} \\ 0100101011000010 \end{array}$$

Notiamo che il riporto di quest'ultima è stato sommato al primo bit. Il complemento a 1 si ottiene convertendo i bit 0 in 1 e viceversa. Di conseguenza, il checksum sarà 1011010100111101. In ricezione, si sommano le tre parole iniziali e il checksum. Se non ci sono errori nel pacchetto, l'addizione darà 1111111111111111, altrimenti se un bit vale 0 sappiamo che è stato introdotto almeno un errore nel pacchetto.

Il motivo per il quale UDP metta a disposizione un checksum è che non c'è garanzia che tutti i collegamenti tra origine e destinazione controllino gli errori. Inoltre, anche se i segmenti fossero trasferiti correttametne lungo un collegamento, si potrebber verificare un errore mentre il segmento si trova nella memoria di un router. Dato che non sono garantiti né affidabilità del singolo collegamento né il rilevamento di errori in memoria, UDP deve mettere a disposizione a livello di trasporto un meccanismo di verificare su base end-to-end se si vuole che il servizio trasferimento dati sia ing rado di rilevare eventuali errori. Questo è un esempio del principio **end-to-end** nella progettazione di sistemi in base al quale, dato che determinate funzionalità devono essere implementate su base end-to-end, le funzioalità posizionate ai livelli inferiori possono diventare ridondanti o di scarso valore se confrontate con le stesse funzioanalità offerete dai livelli superiori.
UDP non a nulla per risolvere le situazioni di errore; alcune implementazioni UDP si limitano a scartare il segmento danneggiato, altre lo trasmettono all'applicazione con un avvertimento.
Il controllo degli errori basato su checksum in UDP è **opzionale in IPv4** mentre in **IPv6 è obbligatorio**.

4.4. Trasporto orientato alla connessione: TCP

Per offrire trasferimento dati affidabile, TCP si basa su principi fondamentali come la rilevazione degli errori, le ritrasmissioni, gli acknowledgement cumulativi, i contatori e i campi nell'intestazione per numeri di sequenza e acknowledgement.

4.4.1. Connessione TCP

TCP viene detto **orientato alla connessione** in quanto, prim di effettuare lo scambio dei dati, i processi devono effettuare l'handshake, ossia devono inviarsi reciprocamente alcuni segmenti preliminari per stabilire i parametri del successivo trasferimento dati.
La connessione TCP non è un circuito end-to-end TDM o FDM, come in una rete a commutazione di circuito, in quanto lo stato della connessione riside completamente nei due sistemi perfierici e non negli elementi di rete intermedi, questi ultimi non salvano lo stato della connessione TCP.
Una connessione TCP offre un **servizio full-duplex**: su una connessione TCP tra il processo A su un host e il processo B su un altro host, i dati a livello di applicazione possono fluire dal processo A al processo B nello stesso momento in cui fluiscono in direzione opposta. Una connessione TCP è anche **punto a punto**, ossia ha luogo tra singolo mittente e singolo destinatario.
Per instaurare una connessione TCP, il client invia per primo uno speciale segmento TCP; il server rispende con un secondo segmento speciale TCP; infine il client risponde con un terzo segmento speciale. I primi due non trasportano payload, ossia non hanno dati a livello applicativo; il terzo può invece trasportare informzioni utili. Dato che i due host si scambiano tre segmenti, questa procedura viene chiamata **handshake a tre vie**.
Una volta instaurata una connessione TCP, i due processi applicativi si possono scambiare dati. Consideriamo l'invio di dati dal processo client al processo server. Il primo manda un flusso di dati attraverso la socket. Questi, quando hano attraversato il punto di uscita, sono nelle mani di TCP in esecuzione nel client. TCP dirige i dati al **buffer di invio** della connessione, uno dei buffer riservato durante l'handshake a tre vie, da cui, preleverà blocchi di dati e li passerà al livello di rete.
Le specifiche TCP non indicano quando TCP debba inviare i dati nel buffer, ma afferma che TCP dovrebbe spedire tali dati in segmenti quando è più conveniente. La massima quantità di dati prelevabili e posizionabili in un segmento viene limitata dalla **dimensione massima di segmento (MSS)**. Questo valore viene impostato determinando prima la lunghezza del grame più grande che può essere inviato a livello di collegamento dall'host mittente locale, la cossidetta **unità trasmissiva massima (MTU)** e poi scegliendo un MSS tale che il segmento TCP stia all'interno di un singolo frame a livello di collegamento, considerando anche la lunghezza dell'intestazione TCP/IP normalmente pari a 40 byte.
Con IPv6 la formula tipica per calcolare l'MSS è

$$\text{MSS} = \text{MTU} - 60$$

TCP accoppia ogni blocco di dati del client a un'intestazione TCP, andando a formare **segmenti TCP**. Questi vengono passati al sottostante livello di rete, dove sono incapsulati nei datagrammi IP a livello di rete che vengono poi immessi

nella rete. Quando all'altro capo TCP riceve un segmento, i dati dael segmento vengono memorizzati nel buffer di ricezione della connessione TCP. Ogni lato della connessione presenta un proprio buffer di invio e di ricezione.
TCP offre un'**interfaccia a stream** (sequenza continua di byte) e non c'è alcuna garanzia che i dati arrivino al destinatario suddivisi negli stessi blocchi con cui sono stati spediti.

4.4.2. Struttura dei segmenti TCP

Esaminiamo la struttura dei segmenti TCP. Il segmento TCP consiste di campi *Intestazione* e di un campo contenente un blocco di dati proveniente dall'applicazione. Come detto prima, la MSS limita la dimensione massima del campo *Dati* di un segmento. TCP, quando invia un file di grandi dimensioni, di solito frammenta il file in porizioni di dimensione MSS.
La seguente figura mostra la **struttura dei segmenti TCP**.

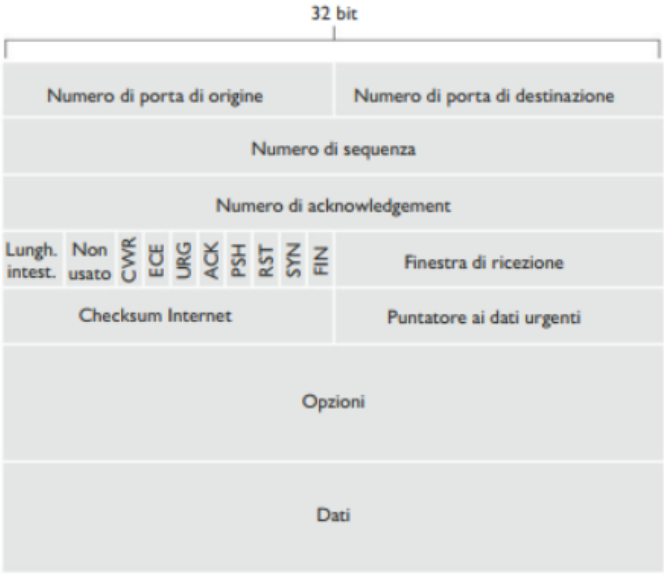


Figura 11: Struttura dei segmenti tcp

Come in UDP, l'intestazione include **numeri di porta origine** e di **destinazione**, utilizzati per il multiplexing/demultiplexing dei dati da e verso le applicazioni del livello superiore, e un campo **Checksum**. L'intestazione dei segmenti TCP comprende poi i seguenti campi.

- Il campo **Numero di sequenza** e il campo **Numero di acknowledgement**, entrambi di 32 bit, vengono utilizzati dal mittente e dal destinatario TCP per implementare il trasferimento dati affidabile.
- Il campo **Finestra di ricezione**, di 16 bit, viene utilizzato per il controllo di flusso.

- Il campo **Lunghezza dell'intestazione**, di 4 bit, specifica la lunghezza dell'intestazione TCP in multipli di 32 bit. L'intestazione TCP ha lunghezza variabile a causa del campo delle opzioni TCP. Generalmente il campo opzioni è vuoto e quindi la lunghezza consueta è di 20 byte. La lunghezza può variare da 20 a 60 byte, poichè il campo *Options* ha una lunghezza variabile di massimo 40 byte.
- Il campo **Opzioni**, facoltativo e di lunghezza variabile, viene utilizzato quando mittente e destinatario negoziono la dimensione massima del segmento (MSS) o come fattore di scala per la finestra nelle reti ad alta velocità. Inoltre, viene definita l'opzione di time-stamping.
- Il campo **Flag** è di 6 bit. Il bit **ACK** viene usato per indicare che il valore trasportato nel campo di acknowledgement è valido. I bit **RST, SYN** e **FIN** vengono utilizzati per impostare e chiudere la connessione. I bit **CWR** ed **ECE** sono usati nel controllo di congestione esplicito. Se il bit **PSH** ha valore 1 il destinatario dovrebbe inviare immediatamente i dati al livello superiore. Infine, si utilizza il bit **URG** per indicare nel segmento la presenza di dati che l'enetità mittente a livello superiore ha marcato come «urgenti». La posizione dell'ultimo byte di dati urgenti viene denotata dal campo **Puntatore ai dati urgenti**, di 16 bit. Quando ci sono dati urgenti, TCP deve informare l'entità destinataria al livello superiore e passarle un puntatore alla fine dei dati urgenti.

Numeri di sequenza e numeri di acknowledgement

Due tra i campi più importanti dell'intestazione del segmento TCP contengono il numero di sequenza e il numero di acknowledgement, che rappresentano una parte critica del servizio di trasferimento dati affidabile proprio di TCP.

TCP vede i dati come un flusso di byte non strutturati, ma ordinati. L'uso dei numeri di sequenza in TCP riflette questa visione, in quanto i numeri di sequenza si applicano al flusso di byte trasmessi. Il **numero di sequenza per un segmento** è pertanto il numero nel flusso di byte del primo byte del segmento.

Consideriamo ora i numeri di acknowledgement. Ricordiamo che TCP è full-duplex, di conseguenza l'host A può contemporaneamente inviare e ricevere dasti dall'host B. I segmenti che provengono dall'Host B presentano un numero di sequenza relativo ai dati che fluiscono da B ad A. Il *numero di acknowledgement che l'host A attende dall'host B*. Consideriamo alcuni esempi.

Supponiamo che l'host A abbia ricevuto da B tutti i byte numerati da 0 a 535 e che A stia per mandare un segmento all'host B. L'host A è in attesa del byte 536 e dei successivi byte nel flusso di dati di B. Pertnato, l'host A scrive 536 nel campo di acknowledgement del segmento che spedisce a B.

Supponiamo, adesso, che l'host A abbia ricevuto un segmento dall'host B contenente i byte da 0 a 535 e un altro segmento contenente i byte da 900 a 1000 ma, per qualche motivo, non ha ricevuto i byte da 536 a 899. In questo esempio, l'host A sta ancora

attendendo il byte 536 per ricreare il flusso di dati di B. Perciò il prossimo segmento di A destinato a B conterrà 536 nel campo del numero di acknowledgement. Dato che TCP effettua l'acknowledgement solo dei byte fino al primo byte mancante nel flusso, si dice che tale protocollo offre **acknowledgement cumulativi**.
Se un host, ad esempio, riceve prima il terzo segmento e non il secondo, ovvero arrivano in disordine, gli RFC non impongono regole su questo aspetto e lasciano la decisione a chi implementa TCP. Esistono due scelte:

1. il destinatario scarta immediatamente i segmenti non ordinati;
2. il destinatario mantiene i byte non ordinati e attende quelli mancanti per colmare i vuoti.

Chiaramente, la seconda scelta è più efficiente in termini di banda occupata e rappresenta l'approccio solitamente utilizzato.

Telnet

Telnet è un protocollo a livello di applicazione per il login remoto che utilizza TCP. Oggigiorno molti utenti preferiscono usare il protocollo SSH, *secure shell*, anzichè Telnet, in quanto con quest'ultimo i dati inviati non vengono criptati rendendolo vulnerabile agli attacchi di intercettazione.
Una comunicazione Telnet avviene nel seguente modo mostrato in figura.

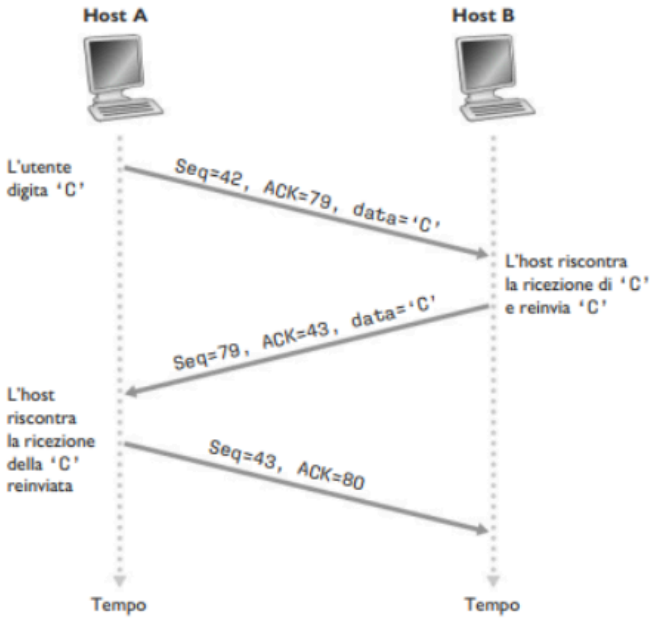


Figura 12: Numeri di sequenza e acknowledgement per applicazioni Telnet su TCP

Notiamo che ogni carattere immesso dall'utente verrà spedito all'host remoto che restituirà una copia di ciascun carattere.

Notiamo che vengono spediti tre segmenti. Il primo è inviato dal client al server e contiente nel campo dati il byte ascii per la lettera "C". Il campo numero di sequenza del primo segmento contiene 42 e, inoltre, visto che il client non ha ancora rivevuto dati dal server, questo primo segmento avrà 79 nel proprio campo di acknowledgement.
Il secondo segmento spedito dal server al client ha un duplice scopo. Innanzitutto, fa un acknowledgement dei dati ricevuti dal server. Ponendo 43 nel camo di acknowledgement, il server indica al client di aver ricevuto con successo i primi 42 byte e di attendere i byte dal 43 in poi. L'altra finalità di questo segmento è di mandare indietro una «eco» della lettera "C". Il secondo segmento ha numero di sequenza 79, ossia il numero iniziale del flusso di dati da server a client in questa connessione TCP. Notiamo che l'acknowledgement dei dati dal client al server viene trasportato in un segmento che a sua volta trasporta dati dal server al client; si dice che tale acknowledgement è **piggybacked** sul segmento dati dal server al client.
Il terzo segmento viene inviato dal client al server e ha come scopo dare un acknowledgement ai dati inviati dal server. Il segmento ha 80 nel suo campo di numero di acknowledgement, in quanto il client ha ricevuto con successo il flusso di byte fino al numero di sequenza 79 e ora è in attesa dei byte dall'80 in avanti.

4.4.3. Timeout e stima del tempo di andata e ritorno (RTT)

TCP utilizza un meccanismo di timeout e ritrasmissione per recuperare i segmenti persi. Sebbene tutto questo sia concettualmente semplice, l'implementazione crea alcuni problemi. La questione più ovvia è la durata degli intervalli di timeout. Il timeout dovrebbe essere più grande del tempo di andata e riutorno sulla connessione (**RTT, Round-Trip Time**), ossia del tempo trascorso da quando si invia un segmento a quando se ne riceve l'acknowledgement, altrimenti ci sarebbero trasmissioni inutili. Il problema è di quanto dovrebbe essere maggiore e come dovrebbe essere stimato RTT.

Stima del tempo di andata e ritorno (RTT)

L'RTT misurato di un segmento, denotato come `SampleRTT`, è la quantità di tempo che intercorre tra l'istante di invio del segmento e quello di ricezione dell'acknowledgement del segmento. ANzichè misurare un `SampleRTT` per ogni segmento, la maggior parte delle implementazioni TCP eeffettua una sola misurazione di `SampleRTT` alla volta. Ossia, in ogni instante di tempo, `SampleRTT` viene valutato per uno solo dei segmenti trasmessi e per cui non si è ancora ricevuto acknowledgement, il che comporta approssimativamente la misurazione di un nuovo valore di `SampleRTT` a ogni RTT. Inoltre, TCP non calcola mai il `SampleRTT` per i segmenti ritrasmessi.
Ovviamente, i campioni variano da segmento a segmento in base alla congestione nei router e al diverso carico sui sistemi periferici. A causa di tale fluttuazione, ogni

valore di SampleRTT può essere atipico.
Per effettuare una stima risulta naturale calcolare una media dei valori si SampleRTT, che TCP chiama EstimatedRTT. Quando si ottiene un nuovo SampleRTT, TCP aggiorna EstimatedRTT secondo la formula:

$$\text{EstimatedRTT} = (1 - \alpha) \cdot \text{EstimatedRTT} + \alpha \cdot \text{SampleRTT}$$

Il valore raccomandato per α è 0.125.
Si noti che EstimatedRTT è una media ponderata dei valori SampleRTT. Tale media attribuisce maggiore importanza ai campioni recenti rispetto a quelli vecchi. In statistica, tale media è detta **media mobile esponenziale ponderata** (EWMA, Exponential Weighted Moving Average).
Oltre ad avere una stima di RTT è importante possedere una misura della sua variabilità. La variazione è denotata con DevRTT e calcolata come:

$$\text{DevRTT} = (1 - \beta) \times \text{DevRTT} + \beta \cdot | \text{ SampleRTT} - \text{EstimatedRTT} |$$

Il valore suggerito per β è 0.25s.

Impostazione e gestione del timeout di ritrasmissione
Dati i valori di EstimatedRTT e DevRTT bisogna capire quali valori bisogna utilizzare per l'intervallo di timeout in TCP. L'intervallo non può essere inferiore a EstimatedRTT. Ma l'intervallo stesso non deve essere molto maggiore di EstimatedRTT, altrimenti TCP non ritrasmetterebbe rapidamente il segmento perduto, il che comporterebbe gravi ritardi sul trasferimento dei dati. Quindi bisogna impostare il timeout a EstimatedRTT più un certo margine che dovrebbe essere grande quanto c'è molta fluttuazione nei valori di SampleRTT e piccolo in caso contrario. Qui entra in gioco il valore di DevRTT. L'intervallo di timeout viene calcolato come segue:

$$\text{TimeoutInterval} = \text{EstimatedRTT} + 4 \cdot \text{DevRTT}$$

In RFC 6298 viene raccomandato un valore iniziale di TimeoutInterval pari a 1 secondo. Inoltre, quando si verifica un timeout, TimeoutInterval vien raddoppiato per evitare un timeout prematuro riferito a un segmento successivo per cui si riceverà presto un acknowledgement. Quando si riceve un segmento ed EstimatedRTT viene aggiornato, TimeoutInterval viene ricalcolato secondo la formula precedente.

4.4.4. Trasferimento dati affidabile

TCP crea un **servizio di trasporto dati affidabile** al di sopra del servizio inaffidabile e best-effort di IP, assicurando che il flusso di byte che i processi leggono dal buffer di ricezione TCP non sia alterato.
Presentiamo una descrizione molto semplificata di un mittente TCP che fa uso solo di timeout per recuperare i segmenti persi e poi una più completa che utilizza anche gli acknowledgement duplicati. Supponiamo che i dati vengano inviati solo in una

direzione, da A a B, e che il primo stia trasmettendo file di grandi dimensioni.
Esistono tre eventi principali relativi alla trasmissione e ritrasmissione dei dati: dati provenienti dall'applicazione, timeout e ricezione di un ACK. Quando si verifica il primo evento, TCP incapsula i dati che gli giungono dall'applicazione in un segmento e lo passa a IP. Inoltre, se il timer non è gia in funzione per qualche altro segmento, TCP lo avvia quando il segmento viene passato a IP. È utile pensare che il timer sia associato al più vecchio segmento che non ha ricevuto acknowledgement. L'intervallo di scandenza per il timer è il `TimeoutInterval`.
Il secondo evento è il timeout, cui TCP risponde ritrasmettendo il segmento che lo ha causato e quindi riavviato il timer.
Il terzo evento, che deve essere gestito dal mittente TCP, è l'arrivo del segmento di acknowledgement con un valore valido nel campo ACK. Quando si verifica tale evento, TCP confronta il valore di ACK con la propria variabile `SendBase`. La variabile di stato TCP `SendBase` è il numero di sequenza del più vecchio byte che non ha ancora ricevuto un acknowledgement. Di conseguenza SendBase -1 è il numero di sequenza dell'ultimo byte che si sa essere ricevuto correttamente e nell'ordin giusto. Tutto ciò è rappresentato nel seguente algoritmo:

Algoritmo 1 — *Algoritmo del mittente TCP*

```
1:  NextSeqNum ← InitialSeqNumber
2:  SendBase ← InitialSeqNumber
3:  loop (per sempre) do
4:      switch (evento) do
5:          evento: dati ricevuti dall'applicazione a livello superiore crea il segmento TCP con
            numero di sequenza NextSeqNum
6:              if il timer attualmente non è in funzione then
7:                  avvia il timer
8:              passa il segmento a IP
9:              NextSeqNum ← NextSeqNum + lunghezza(dati)
10:         evento: timeout del timer
11:             ritrasmetti il segmento che non ha ricevuto ACK con il più piccolo numero di
                sequenza
12:             avvia il timer
13:         evento: ACK ricevuto, con valore del campo ACK pari a y
14:             if y > SendBase then
15:                 SendBase ← y
16:                 if esistono attualmente segmenti senza ACK then
17:                     avvia il timer
```

L'ACK si riferisce a uno o più segmenti che precedentemente non avevano ricevuto conferma. Quindi, il mittente aggiorna la propria variabile `SendBase` e poi, se ci sono segmenti che necessitano di acknowledgement, riavvia il timer.

Scenari interessanti

Abbiamo visto coem TCP fornisca un trasferimento dati affidabile. Per comprendere come funziona il protocollo consideriamo qualche scenario. Consideriamo la seguente figura:

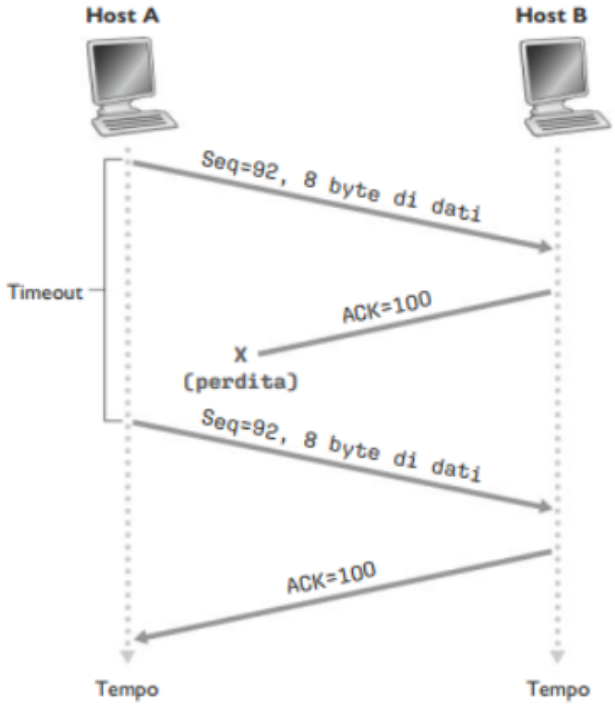


Figura 13: Ritrasmissione dovuta alla perdita di un acknowledgement

Questa figura mostra un caso in cui l'host A spedisce un segmento all'host B. Dopo aver inviato il segmento, A attende un segmento da B con numero di acknowledgement 100. Sebbene il segmento sia stato ricevuto da B, l'acknowledgement sul percorso inverso viene smarrito. In questo caso si verifica l'evento di timeout e l'host A ritrasmette lo stesso segmento. Quando l'host B riceve la ritrasmissione, rileva dal numero di sequenza che il segmento contiene dati che sono stati già ricevuti. Quindi, l'host B scarta i byte del segmento ritrasmesso e ritrasmette comunque l'ACK al mittente.

Consideriamo adesso la seguente figura.

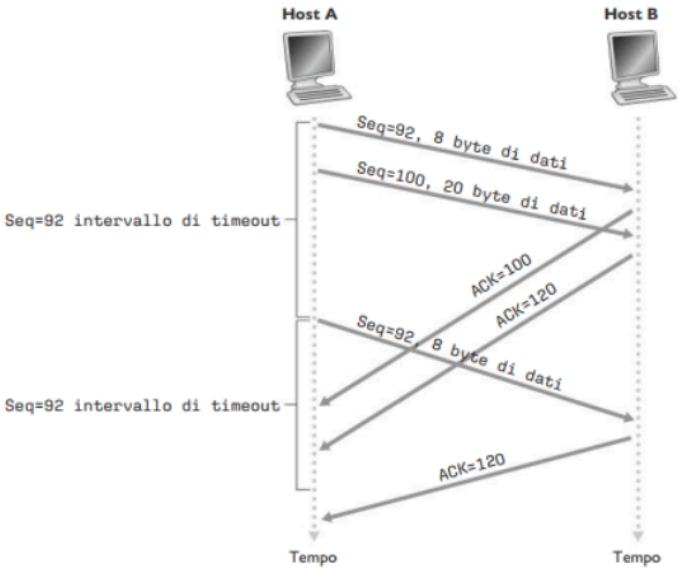


Figura 14: Segmento 100 non ritrasmesso

In questa figura A invia due segmenti. Supponiamo che entrambi arrivino intatti a B e che questo invii due acknowledgement separati per i segmenti, il primo numero 100, il secondo 120. Supponiamo che nessuno degli acknowledgement arrivi all'host A prima del timeout. Quando si verifica il timeout, l'host A rispedisce il primo segmento e riavvia il timer. Fino a quando l'ACK el secondo segmento non arriva prima el nuovo timeout, il secondo segmento non sarà ritrasmesso.
Consideriamo ora la seguente figura.

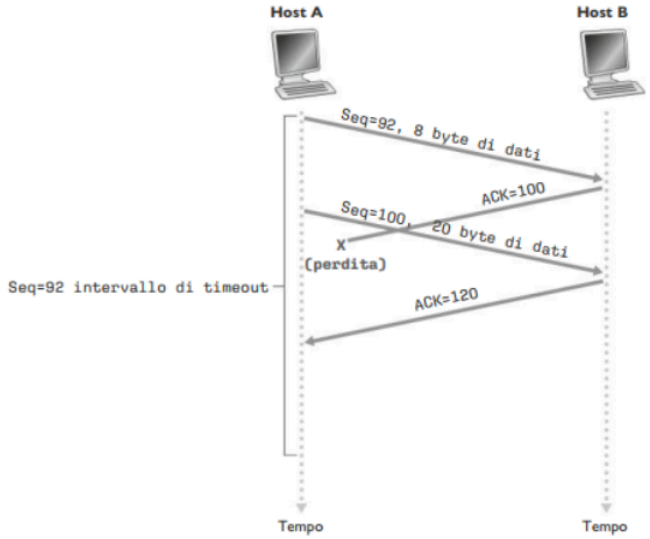


Figura 15: Acknowledgement cumulativo che evita le ritrasmessioni del primo segmento

In questa figura l'host A invia due segmenti, esattamente come nell'esempio precedente. L'acknowledgement del primo segmento viene perso nella rete ma, appena prima dell'evento di timeout, l'host A riceve un acknowledgement con numero 120. È pertanto, a conoscenza che l'host B ha ricevuto tutto fino al byte 119, quindi non rispedisce nessuno dei due segmenti.

Raddoppio dell'intervallo di timeout

Vediamo alcune varianti utilizzate dalla maggior parte delle implementazioni TCP. Las prima riguarda la lunghezza dell'intervallo di timeout dopo la scadenza di un timer. Con questa modifica, in tutti i casi in cui si verifica un timeout, TCP, ritrasmette il segmento con il più basso numeri di sequenza che non abbia ancora ricevuto acknowledgement. Ogni volta che questo si verifica, TCP imposta il successivo intervallo di timeout al doppio del valore precedente. Di conseguenza, gli intervalli crescono esponenzialmente a ogni ritrasmissione.
Questa modifica offre una forma limitata di controllo di congestione. La scadenza del timer viene causata, probabilemente, dalla congestione nella rete, ossia troppi pacchetti arrivano presso una (o più) code dei router nel percorso tra l'origine e la destinazione, provocando eliminazioni di pacchetti o lunghi ritardi di accodamento.

Ritrasmissione rapida

Uno dei problemi legati alle ritrasmissioni è che il periodo di timeout può rilevarsi relativamente lungo. Quando si smarrisce un segmento, il lungo periodo di timeout impone al mittente di ritardare il nuovo invio del pacchetto perso, aumentando il ritardo end-to-end. Però, il mittente potrebbe rilevare la perdita dei pacchetti ben prima che si verifichi l'evento di timeout grazie agli **ACK duplicati** relativi a un segmento il cui ACK è già stato ricevuto dal mittente.
Quando il destinatario TCP riceve un segmento con numero di sequenza superiore al successivo numero di sequenza atteso e in ordine, rileva un buco nel flusso di dati, ossia un segmento mancante. Tale vuoto potrebbe essere il risultato di segmenti persi o riordinati all'interno della rete. Il destinatario non può inviare un acknowledgement negativo esplicito al mittente, dato che TCP non lo prevede, ma si limita a mandare nuovamente un acknowledgement relativo all'ultimo byte di dati che ha ricevuto in ordine.
Dato che in molti casi il mittente invia un gran numero di segmenti, se uno di questi viene smarrito ci saranno molti ACK duplicati. Se il mittente TCP riceve tre ACK duplicati per lo stesso dato, consdiera questo evento come indice che il successivo segmento sia andato perduto. Nel caso incui siano stati ricevuti tre ACK duplicati, il mittente TCP effettua una **ritrasmissione rapida**, ripredendno il segmento mancante prima che scada il timer. In TCP con ritrasmissione rapida il

seguente frammento di codice sostituisce l'evento di ACK ricevuto nell'Algoritmo del mittente TCP.

Algoritmo 2 — *Gestione ACK e Ristrasmissione Rapida*

```
1:  evento: ACK ricevuto, con valore del campo ACK pari a y
2:      if y > SendBase then
3:          SendBase ← y
4:          if esistono attualmente segmenti senza ACK then
5:              avvia il timer
6:      else
7:          incrementa il numero di ACK duplicati ricevuti per y
8:          if numero di ACK duplicati ricevuti per y = 3 then
9:
10:             rispedisci il segmento con numero di sequenza y
```

Go-Back-N (GBN) o ripetizione selettiva (SR)?

Ci chiediamo se TCP sia un protocollo GBN o SR. Ricordiamo che gli acknowledgement TCP sono cumulativi e che i segiemtni ricevuti correttamente, ma in modo disordinato, non vengono notificati singolarmente dal destinario. Quindi, il mittente TCP deve solo memorizzare il numero di sequenza più basso tra i byte trasmessi che non hanno ancora ricevuto acknowledgement (`SendBase`) e il numero di sequenza del successivo byte da inviare (`NextSeqNum`). In questo senso, TCP assomiglia molto a un protocollo di tipo GBN ma esistono molte differenze chiave. Molte implementazioni TCP memorizzano in un buffer i segmenti ricevuti correttamente, ma non in ordine. Consideriamo che il mittente invia una sequenza di segmenti $1, 2, ..., N$ che arrivano al destinatario in ordine e senza errori. Ipotizziamo che l'acknowledgement per il pacchetto $n < N$ vada perduto, ma che i restanti $N - 1$ giugano al mittente prima dei rispettivi timeout. In questo esempio GBN ritrasmetterebbe non solo il pacchetto n, ma anche tutti i pacchetti da $n + 1$ a N. TCP, invece, ritrasmetterebbe solo il segmento n. Inoltre, TCP nbon ritrasmetterebbe neppure questo segmento se ricevesse l'acknowledgement del segmento $n + 1$ prima della scandenza del timeout del segmento n.

Una modifica proposta di TCP, è l'**acknowledgement selettivo** che consente al destinatario di mandare acknowledgement in modo selettivo per i segmenti non in ordine anzichè cumulativamente per l'ultimo segmento ricevuto senza errori e nell'ordine giusto. Se combinato con la ritrasmissione selettiva, TCP è molto simile a un generico protocollo SR. Quindi, il meccanismo di ripristino degli errori è classifcato come un ibrido tra GBN e SR.

4.4.5. Controllo di flusso

Gli host agli estremi delle connessioni TCP riservano dei buffer di ricezione per la connessione. Quando la connessione TCP riceve byte corretti e in sequenza, li posiziona nel buffer di ricezione. Il processo applicativo associato legge i dati da questo buffer, ma non per forza nello stesso momento in cui vengono caricati. Se l'applicazione è relativamente letna nella lettura dei dati può accadere che il mittente mandi in overflow il buffer di ricezione inviando molti dati troppo rapidamente.
TCP offre un **servizio di controllo di flusso** alle proprie applicazioni per evitare che il mittente saturi il buffer del ricevente. Il controllo di flusso è pertanto un servizio di confronto sulla velocità, dato che paragona la frequenza di invio del mittente con quella di lettura dell'applicazione ricevente. I mittenti TCP possono anche essere rallentati dalla congestione nella rete IP. Questa forma di controllo del mittente viene detta **controllo di congestione**. Il controllo di flusso e controllo di congestione vengono gestiti in maniera simili ma sono causati da ragioni differenti.
TCP offre il controllo di flusso facendo mantenere al mittente una variabile chiamata **finestra di ricezione**, detta anche ***advertised window***,che fornisce al mittente un'indicazione dello spazio libero disponibile nel buffer del destinatario. Dato che TCP è full-duplex, i due mittenti mantengono finestre di ricezione distinte.
Supponiamo che l'host A stia inviando un file di grandi dimensioni all'host B su una connessione TCP. Quest'ultimo alloca un buffer di ricezione per la conessione, la cui dimensione è denotata con `RcvBuffer`. Definiamo le seguenti variabili.

- `LastByteRead`: numero dell'ultimo byte nel flusso di dati che il processo applicativo in B ha letto dal buffer;
- `LastByteRcvd`: numero dell'ultimo byte, nel flusso di dati, che proviene dalla rete e che è stato copiato nel buffer di ricezione di B.

Per non andare in overflow, dovremo per forza avere:

$$\text{LastByteRcvd} - \text{LastByteRead} \leq \text{RcvBuffer}$$

La finestra di ricezione, indicata con `rwnd`, viene impostata alla quantità di spazio disponibile nel buffer:

$$\text{rwnd} = \text{RcvBuffer} - [\text{LastByteRcvd} - \text{LastByteRead}]$$

Adesso vediamo come viene utilizzata questa variabile. L'host B comunica all'host A quanto spazio disponibile sia presente nel buffer della connessione, scrivendo il valore corrente di `rwnd` nel campo apposito dei segmenti che manda ad A. L'host B inizializza `rwnd` con il valore di `RcvBuffer` e, ovviamente, deve tenere traccia di variabili specifiche per ogni connessione.
A sua volta, l'host A tiene traccia di due variabili, `LastByteSent` e `LastByteAcked`, il cui significato è rispettivamente «ultimo byte mandato» e «ultimo byte per cui si è ricevuto acknowledgement». La differenza tra queste esprime la quantità di dati

spediti da A per cui non si è ancora ricevuto un acknowledgement. Mantenendo questa quantità sotto il valore di `rwnd`, si garantisce che l'host A non mandi in overflow il buffer di ricezione dell'host B. Quindi l'host A si assicura che per tutta la durata della connessione sia rispettata la seguetne disuguaglianza:

$$\text{LastByteSent} - \text{LastByteAcked} \leq \text{rwnd}$$

$$\text{EffectiveSendWindow} = \text{rwnd} - (\text{LastByteSent - LastByteAcked})$$

In questo schema esiste un problema tecnico secondario. Supponiamo che il buffer di ricezione dell'host B è pieno (`rwnd` $= 0$) e che, dopo averlo notificato all'host A, non abbia più nulla da inviare ad A. Quando il processo applicativo in B svuota il buffer, TCP non invia nuovi segmenti con nuovi valori di `rwnd`. Di conseguenza, l'host A non viene informato del fatto che si sia liberato un po' di spazio nel buffer di ricezione dell'host B. Per risolvere questo problema, le specifiche TCP richiedono che l'host A continui a inviare segmenti con un byte di dati quando la finestra di ricezione di B è zero. Il destinatario risponderà a questi segmenti con un acknowledgement. Prima o poi il buffer inizierà a svuotarsi e i riscontri conterranno un valore non nullo per `rwnd`.

4.4.6. Gestione della connessione TCP

Analizziamo come viene stabilita e rilasciata una connessione TCP. Supponiamo che un processo in esecuzione su un host, il client, voglia inizializzare una connessione con un altro processo in un altro host, il server. Il processo applicativo client informa il lato client di TCP di voler stabilire una connessione verso un processo nel server. Il TCP nel client procede a stabilire una connessione TCP con il TCP nel server nel modo descritto di seguito.

1. TCP lato client invia uno speciale segmento al TCP lato server. Questo segmento non contiene dati, ma uno dei bit nell'intestazione del segmento (Figura 11), il bit SYN, è posto a 1. Tale segmento viene detto segmento SYN. Inoltre il client sceglie a caso un numero di sequenza iniziale (`client_isn`) e lo pone nel campo numero di sequenza del segmento SYN inziale. Questo viene incapsulato in un datagramma IP e inviato al server.
2. Quando il datagramma IP contenente il segmento TCP SYN arriva all'host server, il server estrae il segmento dal datagramma, alloca il buffer e le variabili TCP alla connessione e invia un segmento di connessione approvata al client TCP. Questo segmento non contiene dati, ma nella sua intestazione ci sono tre informazioni importanti. Il bit SYN è posto a 1. Il campo ACK viene posto a `client_isn + 1`. Infine, il server sceglie il proprio numero di sequenza iniziale (`server_isn`) e lo pone nel campo numero di seguenza. Il segmento di connessione approvata viene detto **segmento SYNACK**
3. Alla ricezione del segmento SYNACK, anche il client alloca buffer e variabili alla connessione. L'host invia al server un altro segmento in risposta al segmento di

conenssione approvata dal server. Tale operazione viene svolta dal client ponendo il valore `server_isn + 1` nel campo ACK dell'intestazione del segmento TCP. Il bit SYN è posto a 0. In questo terzo passo dell'handshake a tre vie il campo dati del segmento può contenere informazioni che vanno dal client al server.

Questa procedura, come abbiamo detto, viene chiamata **handshake a tre vie**.

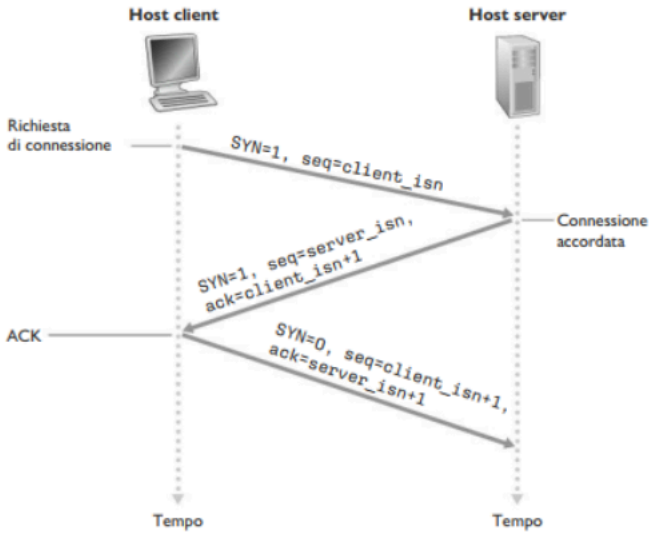


Figura 16: Handshake a tre vie di TCP

Ciasuno dei due processi che partecipano alla connessione può terminarla. In tal caso le risorse negli host vengono deallocate. Supponiamo che il client decida di chiudere la connessione. Il processo applicativo client invia un comando di chiusura, che forza il client TCP a inviare un segmento TCP speciale al processo server. Nell'intestazione di tale segmento troviamo il bit FIN con valore 1. Quando il server riceve questo segmento, rispondo inviando un acknowledgement al client. Il server spedisce il proprio segmento di shutdown, con il bit FIN pari a 1. Infine, il client manda a sua volta un acknowledgement a quest'ultimo segmento del server. A questo punto, tutte le risorse degli host risultano deallocate.
Nell'aco di una connessione TCP, i protocolli TCP attraverso vari **stati TCP**.
Gli stati attraversati da un client TCP sono raffigurati nella seguente figura:

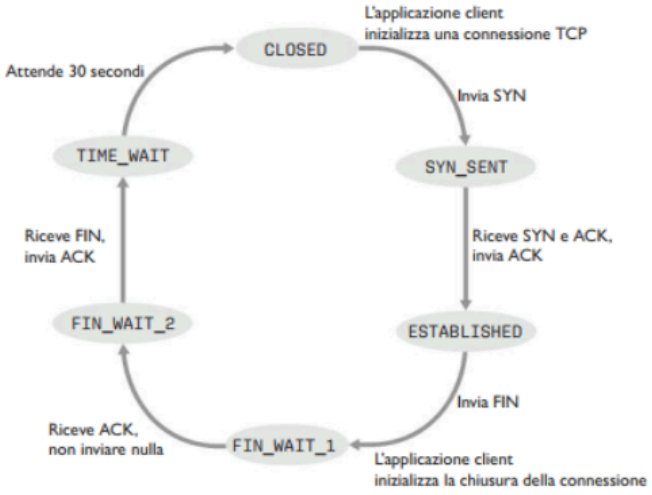


Figura 17: Sequenza di stati visitati da un client TCP

Gli stati attraversati da un server TCP sono rappresentati nella seguente figura:

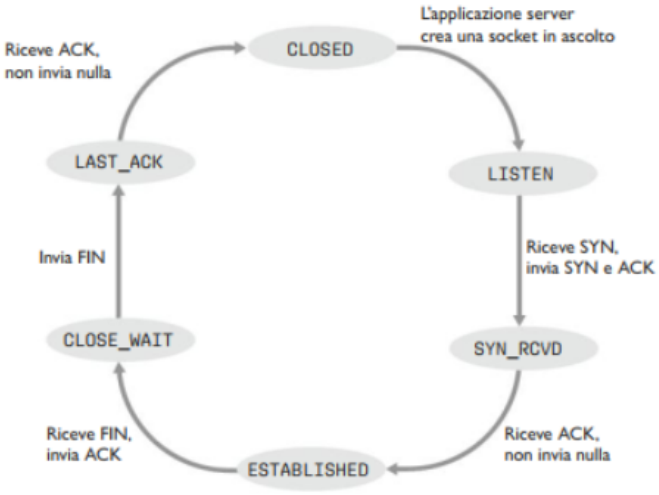


Figura 18: Sequenza di stati visitati da un server TCP

Esiste anche un'altra flag per chiudere una connessione TCP e si tratta del flag **RST**. Il flag RST (reset) interrompre bruscamente una connessione, senza deallocare buffer e variabili. Ad esempio, se arriva un SYN verso una porta su cui nessun processo è in ascolto, l'host risponde con un segmento con RST = 1 che sta ad indicare che non c'è una socket per quel segmento e quindi di non ritrasmettere il messaggio.

4.4.7. Controllo di congestione TCP

La ritrasmissione dei pacchetti, in caso di perdita di questi, tratta un sintomi della congestione di rete, ma non le cause della congestione di rete: il tentativo da parte di troppe sorgenti di invidare dati a ritmi troppo elevati. In questo caso sono richiesti meccanismi per adeguare l'attività dei mittenti in relazione al traffico.
Il protocollo TCP utilizza il controllo di congestione end-to-end anzichè il controllo di congestione assistito dalla rete, in quanto il livello IP non fornisce ai sistemi perficerici alcun feedback per quanto riguarda la congestione della rete.

Controllo di congestione TCP classico

L'approccio scelto da TCP consiste nell'imporre a ciascun mittente un limite al tasso di invio sulla propria connessione in funzione della congestione di rete percepita. Se il mittente TCP si accorge di condizioni di scarso traffico sul percorso che porta alla destinazione, incrementa il proprio tasso di trasmissione, altrimenti, lo riduce.
Dobbiamo capire:

1. come il mittente TCP limita il tasso di invio del traffico sulla propria rete;
2. come percepisce congestione sul percorso che porta alla destinazione;
3. quale algoritmo dovrebbe essere usto dal mittente per variare il tasso di invio in funzione della congestione end-to-end.

Capiamo prima come TCP possa ridurre la velocità di invio del traffico sulla proprio connessione. Sappiamo che gli estremi di una connessione TCP gestiscono un buffer di ricezione, uno di invio e diverse variabili tra cui `LastByteRead` e `rwnd`.
Il meccanismo di controllo di congestione TCP fa uso di una nuova variabile: la **finestra di congestione**, indicata con `cwnd`, che impone un vincolo alla velocità di immissione di traffico sulla rete da parte del mittente. Nello specifico, la quantità di dati che non hanno ancora ricevuto acknowledgement da un mittente non può eccedere il minimo tra i valori di `cwnd` e `rwnd`, ossia:

$$\text{LastByteSent} - \text{LastByteAcked} \leq \min(\text{cwnd}, \text{rwnd})$$

$$\text{EffectiveSendWindow} = \min(\text{cwnd}, \text{rwnd}) - (\text{LastByteSent - LastByteAcked})$$

Assumiamo che il buffer di ricezione sia sufficientemente capiente da poter ignorare il limite sulla finestra di ricezione; pertanto, la quantità di dati ceh non hanno ricevuto acknowledgement è limitata soltanto da `cwnd`. Assumiamo, inoltre, che il mittente abbia sempre dati da inviare, per cui la finestra di congestione è sempre in uso.
Il vincolo sopra citato limita il tasso di trasmissione del mittente soltanto in modo indiretto. Consderiamo una connessione in cui la perdita di pacchetti e i ritardi di trasmissione siano trascurabili. Quindi, all'inizio di ogni RTT, il vincolo consente al mittente di trasmettere `cwnd` byte di dati sulla connessione; al termine del RTT il mittente riceve gli acknowledgement relativi ai dati. Il tasso di invio del mittente è

approssivamente $\frac{\text{cwnd}}{\text{RTT}}$ byte/s. Modificando `cwnd` il mittente può regolare la velocità di invio dei dati sulla propria connessione.
Consideriamo ora come il mittente TCP percepisce la presenza di congestione sul percorso verso la destinazione. Definiamo «evento di perdita» per il mittente TCP l'occorrenza o di un timeout o della ricezione di tre ACK duplicati da parte del destinatario. In presenza di una congestione eccessiva, uno o più buffer dei router lungo il percorso vanno in overflow, causando l'eliminazione di un datagramma. Il datagramma eliminato, costituisce un evneto di perdita presso il mittente che lo considera come un'indicazione di congestione sul percorso tra se e il destinatario.
Quando gli acknowledgement relativi ai vari segmenti verranno ricevuti dal mittente TCP, TCP interpreta l'arrivo di essi come un'indicazione che tutto va bene e utilizza gli acknowledgement per aumentare l'ampiezza della propria finestra di congestione (e quindi, la velocità di trasmissione). Se gli acknowledgement arrivano con frequenza relativamente bassa, allora la finestra di congestione verrà ampliata piuttosto lentamente. Al contrario, la finestra di congestione verrà ampliata più rapidamente. Per questo si dice che TCP è **auto-temporizzato** (*self-clocking*).
Dobbiamo capire come un mittente TCP debba determinare il tasso a cui dovrebbe trasmettere. Se tutti i mittenti TCP trasmettessero troppo velocemente potrebbero congestionare la rete. Se, invece, i mittenti TCP trasmettessero troppo lentamente potrebbero sottoutilizzare l'ampiezza di banda della rete; potrebbero trasmettere a tasso più elevato senza congestionare la rete.
Possiamo analizare i dettagli dell'**algoritmo di controllo di congestione TCP** che presenta tre fasi principali:
1. *slow start*;
2. *congestion avoidance*;
3. *fast_recovery.*

Slow start e congestion avoidance sono componenti obbligatorie di TCP e differiscono nel modo in cui aumentano la grandenza di `cwnd` in risposta agli acknowledgement ricevuti. Slow start aumenta la dimensione di `cwnd` molto più rapidamente di congestion avoidance. La fast recovery è suggerita, ma non obbligatoria, per i mittenti TCP.

Slow start
Quando si stabilisce una connessione TCP, il valore di `cwnd` viene in genere inizializzato a 1 MSS, l che comporta una velocità di invio iniziale di circa $\frac{\text{MSS}}{\text{RTT}}$.
Dato che la banda disponibile può essere molto più grande di $\frac{\text{MSS}}{\text{RTT}}$, il mittente TCP gradirebbe scoprire velocemente la banda disponibile. Quindi, durante la fase iniziale, detta **slow start**, il valore di `cwnd` parte da 1 MSS e si incrementa di 1 MSS ogni volta che un segmento trasmesso riceve un acknowledgement. Questo processo ha come effetto il raddoppio della velocità di trasmissione a ogni RTT.

Quindi la velocità di trasmissione parte lentamente, ma cresce in modo esponenziale durante la fase di slow start.
Se c'è un evento di perdita indicato da un evento di timeout, il mittente TCP pone il valore di `cwnd` pari a 1 e inizia di nuovo il processo di slow start. Inoltre, pone il valore di una seconda variabile di stato, `ssthresh` (*soglia di slow start*) a $\frac{\text{cwnd}}{2}$.
Il secondo modo in cui la fase di slow start può terminare è legato direttamente al valore di `ssthresh` . Poichè `ssthresh` è impostato a metà del valore di `cwnd` all'ultimo rilievo di congestione, potrebbe essere temerario continuare a raddoppiare il valore di `cwnd` quando raggiunge o sorpassa il valore di `ssthresh` . Quindi, quando cwnd = ssthresh, la fase di slow start termina e TCP entra in modalità di congestion avoidance.
Inizialmente il valore di `ssthresh` viene inizializzato a un valore costante arbitrariamente alto e solo dopo il primo evento di perdita viene impostato a $\frac{\text{cwnd}}{2}$. L'ultimo modo in cui la fase di slow start può terminare è quando vengono rilevati tre acknowledgement duplicati, nel qual caso TCP opera una ritrasmissione rapida ed entra nello stato di fast recovery.
Il comportamento di TCP in questa fase è racchiuso in questo automa:

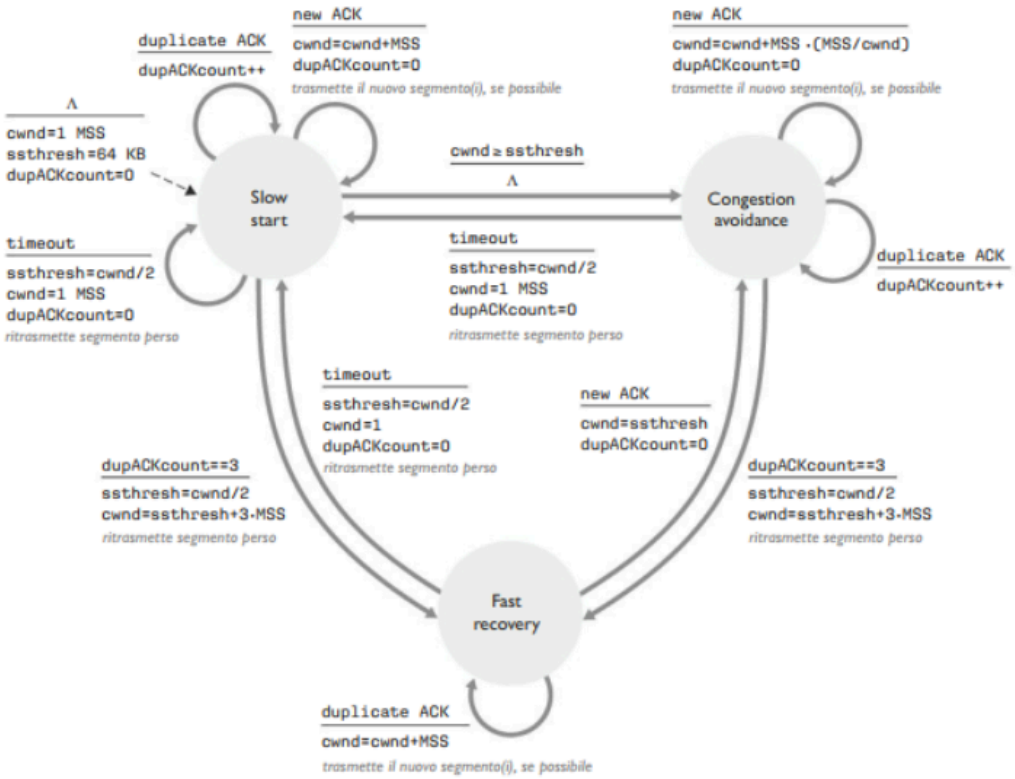


Figura 19: Descrizione tramite DFA del controllo di conestione TCP

Congestion avoidance

Quando TCP entra nello stato di congestion avoidance, il valore di `cwnd` è circa la metà di quello che aveva l'ultima volta in cui era stata rilevata la congestione. Quindi, invece di raddoppiare il valore di `cwnd` ogni RTT, TCP adotta un approccio più conservativo, incrementando `cwnd` di 1 MSS ogni RTT. Ciò si può ottenere in diversi modi: un approccio comune è l'incremento da parte del mittente TCP della propria `cwnd` di MSS $\times \left(\frac{\text{MSS}}{\text{cwnd}}\right)$ byte ogni qualvolta riceva un nuovo acknowledgement.

Dobbiamo capire quando termina l'incremento lineare (1 MSS per RTT) durante la congestion avoidance. L'algoritmo di congestion avoidance, quando si verifica un timeout, si comporta nello stesso modo di slow start: il valore di `cwnd` è posto uguale a 1 MSS e il valore di `ssthresh` viene impostato alla metà del valore di `cwnd` al momento del timeout. In caso di acknowledgement duplicati TCP dimezza il valore di `cwnd` (aggiungendo 3 MSS per tenere conto dei duplicati) e imposta il valore di `ssthresh` pari a metà del valore di `cwnd` al momento del ricevimento dei tre ACK duplicati. Infine, TCP entra nello stato di fast recovery.

Fast recovery

Durante la fase di fast recovery il valore di `cwnd` è incrementato di 1 MSS per ogni ACK duplicato ricevuto relativamente al segmento perso che ha causato l'entrata di TCP nello stato di fast recovery. Infine, quando arriva un ACK per il segmento perso, TCP entra nello stato di congestion avoidance dopo aver ridotto il valore di `cwnd`. Se si verifica un timeout vi è invece una transizione dallo stato di fast recovery a quello di slow start dopo aver effettuato le stesse azioni presenti sia in slow start che in congestion avoidance

$$\text{ssthresh} = \frac{\text{cwnd}}{2}$$
$$\text{cwnd} = 1 \text{ MSS}$$

Fast recovery è un componente raccomandato ma non obbligatorio. Una prima versione di TCP, nota come **TCP Tahoe**, portava in modo incondizionato la finestra di congestione a 1 MSS ed entrava nella fase di slow start dopo qualsiasi evento di perdita. La versione più recente, **TCP Reno**, adotta invece fast recovery. Una versione alternativa di TCP Reno è **TCP NewReno** che introduce un'evoluzione intelligente dell'algoritmo di Fast Recovery per gestire le perdite multiple di pacchetti senza uscire prematuramente dalla fase di recupero.

- **Riconoscimento dell'ACK parziale**: NewReno sa distinguere chiaramente tra un ACK parziale (che conferma solo una parte di dati) e un ACK cumulativo definitivo (conferma tutti i dati).
- **Permanenza in Fast Recovery**: qundo riceve un ACK parziale, NewReno comprende che si è perso un altro pacchetto oltre al primo. Invece di uscire da

Fast Recovery, il mittente ritrasmette immediatamente il pacchetto successivo indicato dall'ACK parziale e rimane in Fast Recovery.

- **Uscita corretta**: la fase di Fast Recovery termina solo quando arriva un ACK comulativo che conferma la ricezione di tutti i dati che erano stati spediti prima di entrare in Fast Recovery.
- Tramite l'utilizzo della variabile `recover`, entrando in fast recovery NewReno salva in `recover` il numero dell'ultimo segmento inviato fino a quel momento e rimane in fast recovery finchè un ACK non riscontra tutti i dati fino a `recover`.

La Figura 19 mostra la descrizione completa degli algoritmi di congestione (slow start, congestion avoidance e fats recovery) tramite un automa a stati finiti. La figura indica anche in quali punti può avvenire la trasmissione di nuovi segmenti o la ritrasmissione di segmenti già inviati.

TCP CUBIC

Dato l'approccio al controllo di congestione di TCP Reno con aumento additivo e decremento moltiplicativo, ci si chiede se questo sia il metodo migliore per trovare una velocità di trasmissione dei pacchetti appena inferiore alla soglia di attivazione della perdita dei pacchetti. Infatti una strategia che dimezza la velocità di invio, e quindi la aumenta piuttosto lentamente, può essere eccessivamente cauta. Se lo stato del collegamento congestionato non è cambiato molto, forse è meglio aumentare la velocità di invio rapidamente per avvicinarsi a quella pre-perdita dei pacchetti e quindi sondare con cautela la larghezza di banda. Quest'approccio è al centro di una versione di TCP nota come **TCP CUBIC**.

In TCP CUBIC la finestra di congestione viene aumentata solo alla ricezione di un ACK e nelle flasi di slow start e fast recovery rimane la stessa. CUBIC modifica solo la fase di congestion avoidance nel modo descritto di seguito:

- Sia $W_{\max}$ la dimensione della finestra del controllo di congestione di TCP nell'istante in cui viene rilevata l'ultima perdita e sia K l'istante nel futuro in cui la dimensione della finestra di TCP CUBIC raggiungerà nuovamente $W_{\max}$. Diversi parametri di CUBIC determinano il valore di K che indica quanto velocemente la dimensione della finestra di congestione del protocollo raggiungerebbe $W_{\max}$.
- CUBIC aumenta la finestra di congestione in funzione del cubo della distanza tra l'istante corrente t e K. Pertanto quando t è distante da K, gli incrementi sono molto maggiori rispetto a quando t è vicino. Quindi CUBIC aumenta rapidamente la velocità per avvicinarsi alla velocità di pre-perdita $W_{\max}$ e solo quando si avvicina a $W_{\max}$ esamina con cautela la larghezza di banda. Una volta superato $W_{\max}$ la velocità torna a crescere rapidamente per cercare nuova banda disponibile.

- La regola cubica consente a CUBIC di trovare più rapidamente un nuovo punto di lavoro qualora il livello di congestione del collegamento che ha causato la perdita sia cambiato in modo significativo.

Dopo una perdita in CUBIC `cwnd` scende a $0.7 \cdot \text{cwnd}$ e non alla metà come in Reno. TCP CUBIC è attualmente ampiamente utilizzato.

4.4.8. Notifica esplicita di congestione dalla rete

L'*Explicit Congestion Notification (ECN)* è la forma di controllo di congestione assistita dalla rete effettuata in Internet. Sono coinvolti sia TCP sia IP. A livello di rete vengono utilizzati due bit nel campo *Tipo di Servizio* dell'intestazione IP. Se un router è congestionato, imposta tali bit e invia il pacchetto IP contrassegnato al destinatario, che quindi informa il mittente.
ECN permette di segnalare la congestione prima che si verifichino perdite di pacchetti.
I bit ECN vengono inoltre utilizzati dal mittente per segnalare che mittente e ricevente sono abilitati all'uso di ECN. Il mittenete imposta a 01 o 10 per indicare il supporto a ECN, mentre il router intermedio che rileva congestione li marca con 11. Quando il destinatario TCP riceve indicazione di congestione ECN, ne informa il mittente TCP impostando il bit ECE (*Explicit Conegestion Notification Echo*) all'interno di un segmento ACK. Il mittente TCP reagisce dimezzando la finestra di congestione e imposta il bit CWR (*Congestion Window Reduced*) nell'intestazione el successivo segmento che invia al ricevente.
Il destinatario TCP imposta il flag `ECE = 1` in tutti gli ACK successivi finchè non riceve dal mittente un segmento con il flag `CWR = 1`. Altri protocolli a livello di trasporto usano il protocollo ECN, *Datagram Congestion Control Protocol (DCCP)* che fornisce un controllo di congestione ECN leggero, ma non affidabile. Mentre il protocollo DCTCP (*Data Center TCP*) è progettato specificatamente per infrastrutture di rete all'interno di data center.
Anche DCQCN (Data Center Quantized Congestion Notification), progettato specificatamente per le reti dei data center, si avvale dell'ECN.

4.4.9. Fairness

Consideriamo K connessioni TCP, ciascuna con differente percorso end-to-end, ma che passano tutte da un collegamento con capacità trasmissiva di R bps; con ciò intendiamo che tutti gli altri collegamenti siano congestionati e dispongano di elevata capacità trasmissiva.
Si dice che un meccanismo di controllo di congestione è **fair** se la velocità di trasmissione media di ciascuna connessione è approssimativamente $\frac{R}{K}$; cioè che ciascuna connessione ottiene la stessa porzione di banda del collegamento.

Fairness e UDP

Il meccanismo della finestra di congestione consente al controllo di congestione TCP di regolare il tasso di trasmissione delle applicazioni. Per questo molte applicazioni multimediali non fanno uso di TCP: non vogliono che il loro tasso di trasmissione venga ridotto. Queste applicazioni preferiscono utilizzare UDP, che non incorpora il controllo di congestione, preferendo di immettere i propri dati a frequenza costante e occosionalmente perdere pacchetti piuttosto che non perderli, ma dover ridurre il loro tasso di trasmissione a livelli equi nei momenti ditraffico. Le applicazioni che fanno uso di UDP non sno fair: non cooperano con altre nè adeguano il loro tasso di trasmissione in modo appropriato. Per questo motivo le sorgenti UDP possono soffocare il traffico TCP e per questo sono stati proposti meccanismi di controllo di congestione capaci di evitare che il traffico UDP blocchi il throughput di Internet.

Fairness e connessioni TCP parallele

Anche se UDP si comportasse in modo equo, il problema della fairness non sarebbe completamente risolto, perchè un'applicazione basata su TCP potrebbe usare più connessioni in parallelo. Spesso i browser usano più connessioni TCP in parallelo per trasferire il contenuto elle pagine. Le applicazioni che usano connessioni in parallelo ottengono una porzione di banda maggiore sui collegamenti congestionati. Dato che il traffico web è molto diffuso, le connessioni in parallelo non sono rare.

4.5. QUIC: Quick UDP Internet Connection

Se i modelli di servizio offerti da UDP e TCP non sono adatti ai serviiz del livello di trasporto richiesti da un'applicazione, gli sviluppatori dell'applicazione possono sempre usare un proprio protocollo a livello di applicazione. Questo può succedere anche quando un'applicazione necessita dei servizi forniti da UDP, ma non desidera tutte le funzionalità richieste da TCP o richiede servizi diversi da quelli forniti da TCP. Questo è l'approccio adottato nel protocollo **QUIC**. QUIC è un nuovo protocollo a livello di applicazione, progettato da zero, per migliorare le prestazioni del livello di trasporto per HTTP sicuro.

QUIC utilizza molti degli approcci per il trasferimento dati affidabile, il controllo di congestione e la gestione della connessione affrontata per i protocolli a livello di trasporto.

QUIC utilizza UDP come protocollo del livello di trasporto ed è progettato per interfacciarsi ad una versione semplificata, ma evoluta, di HTTP/2. Adesso è stato standardizzato ufficialmente come HTTP/3. Alcune caratteristiche principali di QUIC sono le seguenti.

- **Orientato alla connessione e sicuro**. QUIC è un protocollo orientato alla connessione tra due endpoint. Ciò richiede una fase di handshaking tra gli endpoint. Due parti dello stato di connessione sono gli ID dell'origine e della

destinazione della connessione. Tutti i pacchetti QUIC sono crittografati e QUIC combina l'handshake e la cifratura. In questo modo richiede 1 RTT prima di inviare i dati, in TCP invece sono necessari 2 RTT. La cifratura del traffico è **obbligatoria** ed è basata su TLS.

- **Flussi (Streams)**. QUIC consente il multiplexing di diversi flussi a livello di applicazione attraverso una singola connessione QUIC; inoltre, una volta stabilita una connessione QUIC, nuovi flussi possono essere raggiunti rapidamente. Un flusso è un'astrazione per la consegna bidirezionale affidabile e in ordine dei dati tra due endpoint QUIC. In HTTP/3, per ogni oggetto in una pagina web ci sarebbe un flusso diverso. Ogni connessione ha un ID e ogni flusso all'interno di una connessione ha un ID di flusso; entrambi questi ID sono contenuti in un'intestazione del pacchetto QUIC.
- **Trasferimento dati affidabile e con controllo di congestione**. QUIC fornisce un trasferimento dati affidabile a ogni flusso QUIC separatamente. Dal momento che TCP fornisce un servizio di consegna dei byte affidabile e in ordine, le richieste HTTP multiple devono essere consegnate in ordine al server HTTP destinazione. Pertanto, se i byte di una richiesta HTTP vengono persi, le restanti richieste HTTP non possono essere consegnate finchè tali byte non vengono ritrasmessi e ricevuti correttamente da TCP sul server HTTP: il cosidetto problema del blocco HOL affrontato in precedenza. Poichè QUIC fornisce una consegna in ordine e affidabile per flusso, un segmento UDP perso influisce solo sui flussi i cui dati sono stati trasportati in tale segmento; i messaggi HTTP di altri flussi possono continuare a essere ricevuti e consegnati dall'applicazione. QUIC fornisce un trasferimento dati affidabile utilizzando meccanismi di acknowledgement simili a quelli di TCP. Il controllo di congestione di QUIC si basa su TCP NewReno, una piccola variante del protocollo TCP Reno.

Livello di rete: il piano dei dati

5.1. Panoramica del livello di rete

Consideriamo la seguente figura:

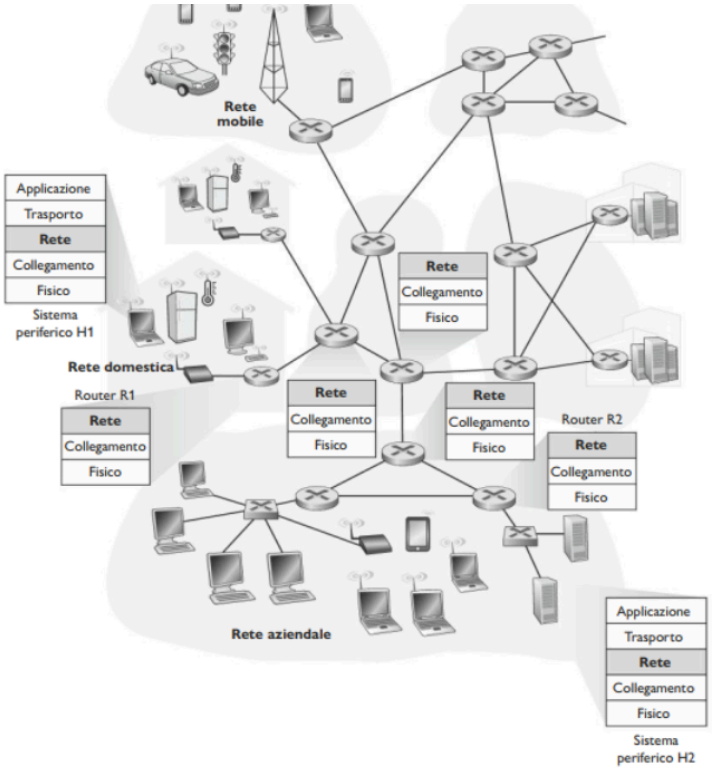


Figura 20: Livello di rete

Consideriamo la funzione svolta dal livello di rete e il ruolo dei router nell'ambito di una trasmissione da H1 a H2. Dal lato del mittente, il livello di rete in H1 prende i segmenti dal livello di trasporto, li incapsula in un datagramma, cioè un pacchetto a livello di rete, che trasmette al proprio router vicino, R1. Dal lato di destinazione, il livello di rete in H2 riceve i datagrammi dal proprio router vicino R2, estrae i segmenti e li consegna al livello di trasporto. Nel tragitto, il ruolo primario del piano dei dati di ciascun router intermedio è quello di inoltrare il datagramma da link d'ingresso a link d'uscita, mentre quello del piano di controllo è coordinare queste azioni di inoltro locali in modo che alla fine i datagrammi vengano instradati da estremo a estremo su percorsi di router tra mittente e destinatario.

5.1.1. Inoltro e instradamento: piano dei dati e piano di controllo

Il ruolo principale del livello di rete è quello di trasferire pacchetti da un host a un altro. Per fare questo è possibile identificare due importanti funzioni.

- **Inoltro** (*forwarding*). Quando un router riceve un pacchetto, lo deve trasferire sull'appropriato collegamento di uscita. Per esempio, un pacchetto che arriva dall'host H1 al router R1, deve essere inoltrato al successivo router sul percorso verso H2. L'inoltro è una funzione implementata nel piano dei dati. Nel caso più generale, un pacchetto può anche essere bloccato o duplicato e inviato su più collegamenti di uscita.

- **Instradamento** (*routing*). Il livello di rete deve determinare il percorso che i pacchetti devono seguire tramite **algoritmi di instradamento**, detti *algoritmi di routing*. Un algoritmo di routing determina il percorso, ad esempio, dei pacchetti da H1 a H2 della **Figura 20**. La funzione di instradamento è implementata nel piano di controllo del livello di rete.

I termini *inoltro* e *instradamento* sono solitamente considerati sinonimi ma hanno significati diversi. Con **inoltro** si fa riferimento all'azione locale con cui il router trasferisce i pacchetti da un'interfaccia di ingresso a quella di uscita. Poichè l'inoltro avviene su scala temporale molto piccola, è usualmente implementato in hardware. Con **instradamento** si denota il processo globale di rete che determina i percorsi dei pacchetti nel loro viaggio dalla sorgente alla destinazione. Poichè l'instradamento avviene su scale temporali più grandi, è usualmente implementato in software.
Per inoltrare i pacchetti, i router estraggono da uno o più campi dell'intestazione i loro valori che utilizzano come indice della **tabella di inoltro**, detta *tabella di forwarding* o *forwarding table*, un elemento chiave di qualsiasi router. Il risultato indica a quale interfaccia di uscita il pacchetto debba essere diretto.

Piano di controllo: l'approccio tradizionale
La configurazione delle tabelle di inoltro nei router costituiscono un argomento cruciale che evidenzia l'interazione tra inoltro e instradamento. L'algoritmo di instradamento determina i valori inseriti nelle tabelle di inoltro dei router. Le funzioni di instradamento nei router comunicano tra di loro per determinare i valori da inserire nelle tabelle di inoltro. Le comunicazioni avvengono tramite messaggi di un protocollo di instradamento.
I diversi scopi delle funzioni di inoltro e di instradamento possono essere descritti considerando il caso di una rete in cui tutte le tabelle di inoltro siano configurate direttamente da un operatore di rete, fisicamente presenti presso i router. In questo caso non sarebbe richiesto alcun protocollo di instradamento. Gli operatori dovrebbero interagire tra loro assicurandosi che i pacchetti raggiungano le proprie destinazioni. Probabilmente la configurazione effettuata da operatori umani sarebbe soggetta a errori e molto più lenta nella risposta ai cambiamenti della topologia di rete rispetto a un protocollo di instradamento.

Piano di controllo: l'approccio SDN
L'approccio di implementare la funzionalità di instradamento in cui ogni router ha una componente di instradamento che comunica con la corrispettiva negli altri router, è stato tradizionalmente adottato dalle aziende produttrici di router.
La seguente figura mostra un approccio alternativo in cui un controller remoto, separato fisicamente dai router, calcola e distribuisce le tabelle di inoltro a tutti i router. In questo caso la funzionalità di instradamento del piano di controllo è separata fisicamente dal router; il dispositivo di instradamento effettua solo l'inoltro,

mentre il controller remoto calcola e distribuisce le tabelle di inoltro. Il controller remoto potrebbe essere implementato in un data center remoto con elevata affidabilità e ridondanza e potrebbe essere gestito da un ISP o da una terza parte.
I router e il controller remoto potrebbero comunicare scambiandosi messaggi contenenti le tabelle di inoltro e altre informazioni di instradamento. Il piano di controllo mostrato nella seguente figura è il nucleo del **Software-Defined Networking (SDN)**, nel quale la rete è gestita da un software perchè il controller che calcola le tabelle di inoltro e interagisce coi router è implementato in software.

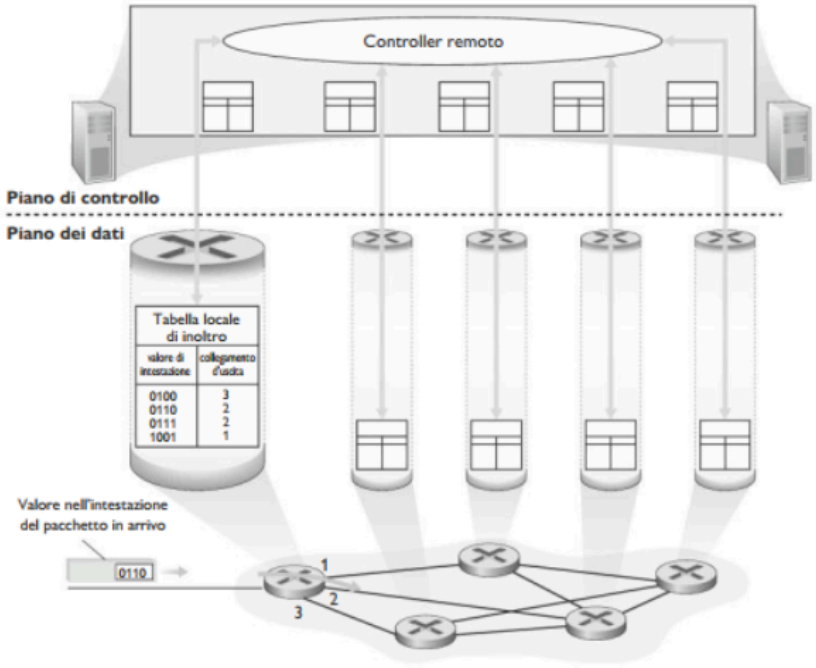


Figura 21: Un controller remoto determina e distribuisce i valori delle tabelle di inoltro

5.1.2. Modelli di servizio del livello di rete

Consideriamo i servizi che il livello di rete può offrire. Il **modello di servizio del livello di rete**, definisce le caratteristiche del trasporto end-to-end di pacchetti tra host di origine e di destinazione.
Consideriamo alcuni servizi che il livello di rete potrebbe offrire:

- **Consegna garantita**. Questo servizio assicura che il pacchetto giunga, prima o poi, alla propria destinazione.
- **Consegna garantita con ritardo limitato**. Questo servizio non solo garantisce la consegna del pacchetto, ma anche il rispetto di un limite di ritardo specificato.

- **Consegna ordinata**. Questo servizio garantisce che i pacchetti giungano alla destinazione nell'ordine in cui sono stati inviati.
- **Banda minima garantita**. Questo servizio a livello di rete emula il comportamento di un collegamento trasmissivo con bit rate specificato tra host di invio e di destinazione, anche se il percorso end-to-end può attraversare diversi collegamenti fisici. Finchè l'host di inviuo trasmette bit a una velocità inferiore al bit rate specificato, non si verifica perdita di pacchetti.
- **Servizi di sicurezza**. Il livello di rete dell'host sorgente può cifrare tutti i datagrammi invati; il livello di rete nell'host di destinazione ha il compito di decifrarli. Con questo tipo di servizio, la riservatezza viene fornita a tutti i segmenti del livello di trasporto.

Questa è solo una lista parziale.
Il livello di rete di Internet mette a disposizione un solo servizio, noto come **servizio best-effort**, ossia con «massimo impegno possibile». Con questo servizio, non c'è garanzia che i pacchetti vengano ricevuti nell'ordine in cui sono stati inviati, così come non è garantita la loro eventuale consegna. Non c'è garanzia del ritardo end-to-end, così come non c'è garanzia su una larghezza di banda minima garantita. Altre architetture di rete hanno definito e implementato modelli di servizi che vanno oltre il servizio best-effort di Internet. Nonostante lo sviluppo di alternative, il modello di servizio best-effort combinato con un'adeguata larghezza di banda e protocolli a livello di applicazione in grado di adattarsi alla banda, come il protocollo DASH, si è dimostrato sufficientemente buono da supportare una stupefacente gamma di applicazioni quali i servizi di streaming video, applicazioni di video-over-IP e di conferenza in tempo reale.

5.2. Panoramica sui router

Analizziamo le architetture dei router per trasferire i pacchetti dai collegamenti di ingresso a quelli in uscita. La seguente figura presenta una visione ad alto livello di una generica architettura di router in cui si possono identificare quattro componenti.

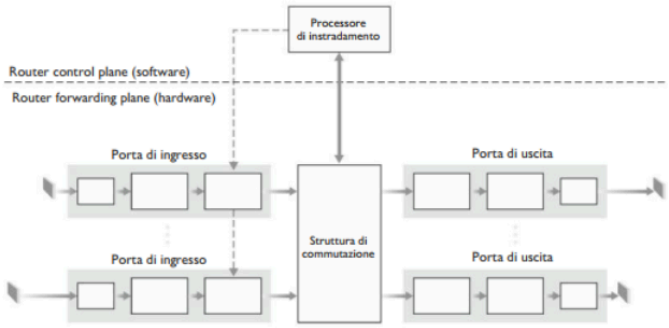


Figura 22: Architettura di un router

- **Porto di ingresso** (*input port*). Svolgono le funzioni a livello fisico di terminazione di un collegamento in ingresso al router; svolgono anche funzioni a livello di collegamento, necessarie per interoperare con le anologhe funzini all'altro capo del collegamento di ingresso. SVolgono inoltre la cruciale funzione di ricerca, in modo che il pacchetto inoltrato nella **struttura di commutazione** del router esca sulla porta di uscita corretta. I pacchetti di controllo, come quelli che trasportano informazioni sul protocollo di instradamento, sono inoltrati dalla porta di ingresso al **processore di instradamento**. Il termine porta si riferisce alle interfacce fisiche di input e output del router.
- **Struttura di commutazione** (*switching fabric*). La struttura di commutazione, che connette fisicamente le porte di ingresso a quelle di uscita, è interamente contenuta all'interno del router.
- **Porte di uscita** (*output port*). Memorizzano i pacchetti che provengono dalla struttura di commutazione e li trasmettono sul collegamento in uscita, operando le funzionalità necessarie del livello di collegamento e fisico. Nei collegamenti bidirezionali, che trasportano traffico in etrambe le direzioni, la porta di uscita è accoppiata, solitamente, alla porta di ingresso di quel collegamento sulla stessa scheda di collegamento, detta *line card*.
- **Processore di instradamento** (*routing processor*). Esegue le funzioni del piano di controllo. Nei router tradizionali, esegue i protocolli di instradamento, gestisce le tabelle di inoltro e le informazioni sui collegamenti attivi, ed elabora la tabella di inoltro per il router. Nei router SDN, il processore di instradamento è responsabile della comunicazione con il controller remoto, in modo da ricevere le occorrenze della tabella di inoltro e installarle alle porte di ingresso. Inoltre, effettua anche le operazioni di gestione di rete.

In un router le porte di ingresso, le porte di uscita e la struttura di commutazione sono implementate quasi sempre in hardware specializzato. Un collegamento di input a 100 Gbps e un datagramma IP di 64 byte, la porta di input ha solo 5,12 ns per elaborare il datagramma prima che il successo possa arrivare. Se ci sono N porte su una line card, la pipeline di elaborazione dei datagrammi deve operare N volte più velocemente, cosa impossibile per un'implementazione software su hardware tradizionale.
Mentre il piano dei dati opera sulla scala temporale dei nanosecondi, le funzioni di controllo dei router, come l'esecuzione dei protocolli di instradamento, la risposta a eventuali malfunzionamento dei collegamenti comunicanti nel caso di SDN e le funzioni di gestione delle prestazioni, operano sulla scala temporale dei millisecondi o dei secondi. Le funzioni del **piano di controllo** sono solitamente implementate via software ed eseguite sul processore di instradamento.

5.2.1. Elaborazione alle porte di ingresso e inoltro basato sull'indirizzo di destinazione

La seguente figura fornisce una visione dettagliata delle funzionalità delle porte di ingresso.

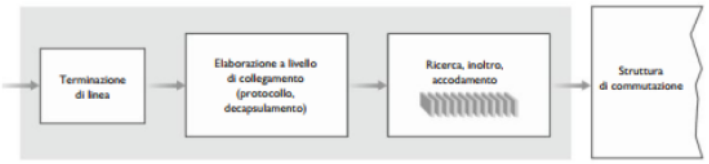


Figura 23: Elaborazione alle porte di ingresso

La funzione di terminazione della linea e l'elaborazione a livello di colegamento implementano rispettivamente il livello fisico e di collegamento associati a un singolo collegamento di ingresso al router. L'elaborazione effettuata alla porta di ingresso è centrale per la funzionalità del router: qui, utilizando le informazioni della tabella di inoltro, viene determinata la porta di uscita a cui dirigere un pacchetto attraverso la struttura di commutazione. La tabella di inoltro viene elaborata e aggiornata dal processore di instradamento o ricevuta da un controller SDN remoto. La tabella di inoltro viene copiata sulla line card dal processore di instradamento tramite un bus separato. Essendoci copie locali della tabella di inoltro, la decisione relativa può essere presa dalle porte di ingresso, senza invocare il processore di instradamento centralizzato.
Consideriamo il caso in cui l'inoltro sia basato sull'indirizzo di destinazione. Supponiamo che tutti gli indirizzi di destinazione siano a 32 bit. Un'implementazione elementare della tabella di inoltro presenterebbe una riga per ogni possibile indirizzo di destinazione ma, dato che esistono più di 4 miliardi di possibili indirizzi, questa opzione non viene presa in considerazione.
Supponiamo che il router abbia quattro collegamenti, numerati da 0 a 3, e che i pacchetti debbano essere inoltrati verso le interfacce di collegamento come segue:

	Intervallo degli indirizzi di destinazione				**Interfaccia**
da	11001000	00010111	00010000	00000000	0
a	11001000	00010111	00010111	11111111	
da	11001000	00010111	00011000	00000000	1
a	11001000	00010111	00011000	11111111	
da	11001000	00010111	00011001	00000000	2
a	11001000	00010111	00011111	11111111	
altrimenti					3

In questo esempio non è necessario avere 4 miliardi di righe nelle tabelle di inoltro dei router. Potremmo avere la seguente tabella con appena 4 voci:

Corrispondenza di prefisso			**Interfaccia**
11001000	00010111	00010	0
11001000	00010111	00011000	1
11001000	00010111	00011	2
altrimenti			3

Con questa struttura il router confronta un **prefisso** dell'indirizzo di destinazione del pacchetto con una riga della tabella; se c'è corrispondenza, il router inoltra il pacchetto al collegamento associato.
Un indirizzo di destinazione può corrispondere a più di una riga. Per esempio, i primi 24 bit dell'indirizzo 11001000 00010111 00011000 10101010 corrispondono alla seconda riga della tabella e primi 21 alla terza riga della tabella. Quando si verificano corrispondenze multiple, il router adotta la **regola di corrispondenza a prefisso più lungo**, cioè, viene determinata la corrispondenza più lunga all'interno della tabella e i pacchetti vengono inoltrati all'interfaccia di collegamento associata. La ricerca nella tabella di inoltro è concettualmente più semplice e viene effettuata cercando il più lungo prefisso corrispondente. A tassi di trasmissione di Gigabit, tale ricerca deve essere effettuata in nanosecondi. Quindi, la ricerca va effettuata in hardware e sono necessarie tecniche che vadano oltre la semplice ricerca lineare su grandi tabelle. Bisona anche porre attenzione ai tempi di accesso alla memoria; si ricorre a memorie DRAM integrate direttamente nei processori e SRAM molto veloci. Per la ricerca vengono anche usate le *Ternary Content Address Memories (TCAM)*. Con una TCAM, un indirizzo IP a 32 bit è passato alla memoria che restituisce il contenuto della tupla nella tabella di inoltro corrispondente a quell'indirizzo in un tempo costante.
Una volta determinata la porta di output di un pacchetto, può essere inviato alla struttura di commutazione. In altre architetture un pacchetto può essere temporaneamente bloccato prima di entrare nella struttura di commutazione quando essa è utilizzato da altre porte di input. Un pacchettoi bloccato verrà accodato sulla porta di input e schedulato per il passaggio alla struttura di commutazione più tardi. Oltre la ricerca, ci sono altre azioni dell'elaborazione alle porte di input:

1. elaborazione a livello fisico e di collegamento,
2. il numero di versione del pacchetto, il checksum e il tempo di vita devono essere controllati e gli ultimi due campi riscritti,
3. i contatori usati per la gestione di rete vanno aggiornati.

5.2.2. Struttura di commutazione (switching)

La struttura di commutazione, *switching fabric*, rappresenta il vero e proprio cuore dei router, attraverso il quale i pacchetti vengono commutati (inoltrati) dalla porta di ingresso alla porta di uscita. La commutazione può essere ottenuta in vari modi, come mostrato nella seguente figura.

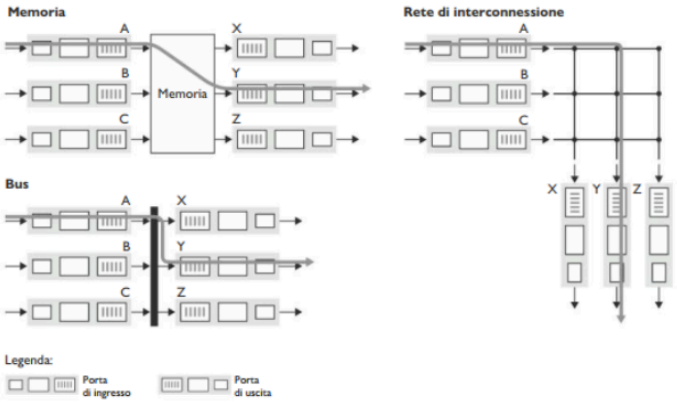


Figura 24: Tre tecniche di commutazione

- **Commutazione in memoria**. I primi e più semplici router erano calcolatori tradizionali, e la commutazione tra porte di ingresso e di uscita veniva effettuata sotto il controllo della CPU. Le porte di ingresso e di uscita funzionavano come dispositivi di I/O. Quando soppraggiungeva un pacchetto, la porta di ingresso ne segnalava l'arrivo tramite interrupt e lo copiava nella memoria del processore di instradamento che procedeva a estrarre dall'intestazione l'indirizzo di destinazione. Tramite tabella di inoltro individuava l'appropriamta porta di uscita nel cui buffer copiava il pacchetto. Due pacchetti non possono essere inoltrati contemporaneamente, anche se hanno porte di destinazioni diverse, perchè può essere solo effettuata un'operazione alla volta di scrittura/lettura tramite bus di sistema.

  Anche router attuali effettuano la commutazione in memoria, ma rispetto ai primi router la ricerca dell'indirizzo di destinazione e la memorizzazione del pacchetto nella locazione di memoria opportuna vengono effettuate dai processori direttamente sulle line card di ingresso.
- **Commutazione tramite bus**. In questo approccio le porte di ingresso trasferiscono un pacchetto direttamente alle porte di uscita tramite un bus condiviso e senza intervento da parte del processore di instradamento. Questo viene tipicamente fatto aggiungendo un'etichetta intera di commutazione al pacchetto che indica la porta locale di output alla quale il pacchetto deve essere trasferito quando viene trasmesso sul bus. Il pacchetto viene ricevuto da tutte le porte di output, ma solo la porta corrispondente all'etichetta lo raccoglierà. Se più pacchetti arrivano contemporaneamente al router, ognuno su porta di input

diversa, tutti tranne uno dovranno aspettare. Poichè ciascun pacchetto deve attraversare il bus, la larghezza di banda della commutazione è limitata da quella del bus.

- **Commutazione attraverso reti di interconnessione**. Un modo per superare la limitazione di banda di un singolo bus condiviso è l'utilizzo di una rete di interconnessione più sofisticata. Una matrice di commutazione, detta *crossbar switch* è una rete di interconnessione che consiste di $2n$ bus che collegano n porte di ingresso a n porte di uscita. Ogni bus verticale interseca tutti i bus orizzontali a un punto di incrocio che può essere in qualsiasi momento aperto o chiuso dal controller della struttura di commutazione. Quando un pacchetto giunge ad una porta di ingresso A e deve essere inoltrato alla porta Y, il controller chiude l'incrocio di A e Y e la porta A invia il pacchetto sul suo bus e solo il bus Y lo riceverà. Un pacchetto di un'altra porta B può essere inoltrato a X nello stesso tempo. La commutazione attraverso rete di interconnessione è in grado di inoltrare più pacchetti in parallelo. Una matrice di commutazione è **non-blocking**: un pacchetto in via di inoltro verso una porta di uscita non viene bloccato a meno che non esista un altro pacchetto in via di inoltro sulla stesssa porta di uscita. Se due pacchetti provenienti da due diverse porte di input sono destinati alla stessa porta dia output, uno dovrà accordarsi alla porta di input.
  Reti di interconnessione più sofisticate usano elementi di commutazione a più stadi per permettere che pacchetti provenienti da porte di input diverse, ma con la stessa porta di output, possano attraversare la struttura di commutazione contemporaneamente. La capacità di commutazione di un router può scalare utilizzando un numero N di strutture di commutazione in parallelo. La portadi ingresso suddivide il pacchetto in K pezzi, detti *chunk*, più piccola, e li invia attraverso K di queste N strutture alla porta di uscita selezioanta, che li riassembla nel pacchetto originale.

5.2.3. Elaborazione alle porte di uscita

L'elaborazione alle porte di uscita prende i pacchetti dalla memoria delle porte di suscita e li trasmette sul collegamento di uscita. Tale operazione comprende selezionare e togliere dalla coda i pacchetti per la trasmissione e operare le necessarie funzioni a livello di collegamento e fisico.



Figura 25: Elaborazione alle porte di uscita

5.2.4. Problema dell'accodamento

Si possono formare code di pacchetti sia presso le porte di ingresso e sia presso quelle di uscita. Il luogo e la lunghezza della coda dipendono dalla quantità di traffico di rete, dalle velocità relative della struttura di commutazione e della linea. Quando queste code crescono, la memoria del router può esaurirsi e quindi può avvenire una **perdita di pacchetti** nel caso non vi sia più memoria per immagazzinare quelli in arrivo.

Supponiamo che la velocità di linea di input e output abbiano tutte lo stesso tasso di trasmissiuone di R_{line} pacchetti al secondo e che si siano N porte di input e N di output. Supponiamo inoltre, che tutti i pacchetti abbiano la stessa lunghezza e arrivino alle porte di input in modo sincrono, ovvero che il tempo di invio di un pacchetto sia pari al tempo di ricezione di un pacchetto e che in tale intervallo possa arrivare su un collegamento di input un pacchetto oppure nessun pacchetto. Definiamo il tasso di trasferimento della struttura di commutazione R_{switch} come il tasso al quale i pacchetti vengono trasferiti dalla porta di input a quella di output. Se R_{switch} è N volte più veloce di R_{line}, l'accodamento alle porte di input è trascurabile perchè, anche nel caso peggiore in cui i pacchetti arrivino su tutte le N linee di input e debbano essere inoltrati alla medesima porta di output, ogni gruppo di N pacchetti, uno per porta di input, può essere elaborato dalla struttura di commutazione prima dell'arrivo del successivo.

Accodamento in ingresso

Se la struttura di commutazione non è sufficientemente rapida può verificarsi accodamento anche alle porte di ingresso. Per illustrare una conseguenza di tale accodamento consideriamo una struttura di commutazione facente uso di una rete di interconnessione e supponiamo che

1. la velocità di tutti i collegamenti siano identiche;
2. un pacchetto può essere trasferito da qualsiasi porta di ingresso a una data porta di uscita nello stesso intervallo di tempo richiesto perchè un pacchetto sia ricevuto su un collegamento diverso;
3. i pacchetti vengono trasferiti da una coda di ingresso alla relativa coda di uscita con procedura FCFS (*first-come-first-served*).

È possbile trasferire più pacchetti in parallelo quando le relative porte di uscita sono differenti. Tuttavia, se due pacchetti in testa a due code di ingresso sono destinati alla stessa coda di uscita, allora uno dei pacchetti sarà bloccato e dovrà attendere: istante per istante, la struttura di commutazione può traferire solo un pacchetto a una certa porta di uscita.

Questo fenomeno è noto come **blocco in testa alla coda** (**HOL**, *Head-Of-The-Line blocking*): un pacchetto nella coda di ingresso deve attendere il trasferimento attraverso la struttura in quanto risulta bloccato da un altro pacchetto che lo

precede. Sotto determinate ipotesi, a causa del blocco la coda di ingresso cresce idefinitamente (e quindi si verificheranno sostanziose perdite di pacchetti) quando il tasso di arrivo dei pacchetti sui collegamenti di ingresso raggiunge solo il 58% della loro capacità.

Accodamento in uscita

Supponiamo che R_{switch} sia N volte più rapida di R_{line} e che i pacchetti giungono a ciascuna delle N porte di ingresso siano destinati alla stessa porta di uscita; quindi nel tempo richiesto per ricevere un singolo pacchetto, a questa porta di uscita arrivano N nuovi pacchetti. Dato che la porta di uscita può trasmettere un solo pacchetto in un intervallo prestabilito, gli N pacchetti in arrivo dovranno mettersi in coda per la trasmissione sul collegamento in uscita. Di conseguenza, è possibile che giugano altri N pacchetti nel periodo necessario per trasmettere solo uno degli N pacchetti già accodati, e così via. Il numero di pacchetti in coda può continuare a crescere fino a esaurire lo spazio di memoria sulla porta di uscita.
In assenza di sufficiente memoria per inserire nel buffer il nuovo pacchetto in ingresso, occorre stabilire se scartarlo (processo noto come **drop-tail**, eliminazione in coda) o se rimuoverne uno o più, fra quelli già in coda, per far posto al nuovo arrivato. In alcuni casi può risultare vantaggioso eliminare un pacchetto prima che il buffer sia pieno, al fine di fornire al mittente un segnale di congestione. Sono state proposte numerose politiche di eliminazione e marcatura dei pacchetti, tecniche che presentano il nome collettivo di algoritmi di **AQM** (**Active Queue Management**). Tra questi uno dei più studiati e implementati è detto algoritmo **RED** (**Random Early Detection**). Più recenti policy AQM includono PIE (*Proportional Integral controller Enhanced*) e CoDel.
Consideriamo la seguente figura:

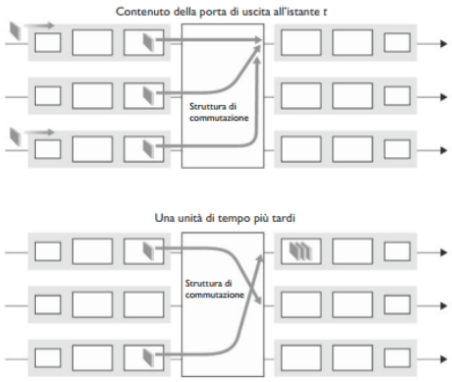


Figura 26: Accodamento alle porte di uscita

All'istante t, a ciascuna delle porte di ingrersso giunge un pacchetto destinato alla porta in uscita superiore. Ipotizzando velocità di linea identiche e un commutatore che opera al triplo della velocità di linea, nell'unità di tempo dopo, cioè dopo il

tempo richiesto per ricevere o inviare un pacchetto, i tre pacchetti originali sono stati trasferiti sulla porta in uscita e sono accodati in attesa di trasmissione. Nell'unità di tempo successiva verrà tramesso uno di questi tre pacchetti. Nel nostro esempio, due nuovi pacchetti sono giunti al commutatore, uno di questi è destinato alla porta di uscita superiore. Quando vi sono più pacchetti accodati sulle porte di uscita, uno **schedulatore di pacchetti** deve stabilire in quale ordine trasmetterli.

5.2.5. Schedulazione dei pacchetti

Per determinare l'ordine con cui i pacchetti vengono trasmessi sulla porta di uscita esistono diverse procedure. Esiste la procedura FCFS, *first-come-first-served*, anche nota come FIFO, *first-in-first-out*. Alternativamente, esistono le code con priorità oppure le code round-robin.

FIFO

I pacchetti che arrivano alla coda di uscita del collegamento aspettano di essere trasmessi se quest'ultimo è occupato nella trasmissione di un altro pacchetto. Se non c'è spazio a sufficienza per contenere il pacchetto che arriva, la politica di scarto dei pacchetti determina se il pacchetto va eliminato o se bisogna rimuovere dei pacchetti dalla coda per fare spazio al pacchetto in arrivo.
I pacchetti, con questa procedura, vengono trasmessi nello stesso ordine con cui sono arrivati in coda. La seguente figura mostra un esempio di coda FIFO.

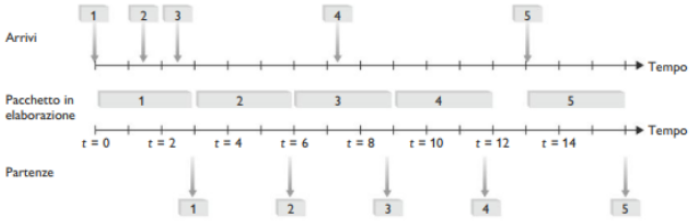


Figura 27: Coda FIFO

Le frecce numerate in alto inidcano l'ordine di arrivo dei pacchetti, con il numero che indica l'ordine con cui il pachetto è arrivato, quelle in basso mostrano la sequenza con cui i pacchetti sono trasmessi. L'intervallo durante il quale un pacchetto viene trasmesso è contrassegnato dal rettangolo ombreggiato fra le due linee orizzontali.

Code con priorità

Nel modello di accodamento con priorità, *priority queuing*, i pacchetti sono classificati in hbase a classi di priorità, come mostrato nella seguente figura.

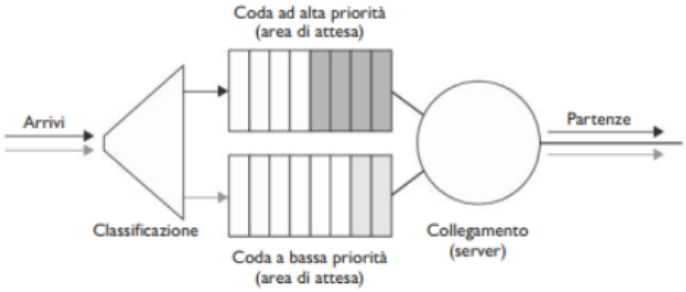


Figura 28: Coda con priorità

In pratica, un operatore di rete può configurare una coda in modo che i pacchetti con informazioni di gestione di rete abbiano la priorità rispetto al traffico utenti; inoltre i pacchetti che trasportano dati di applicazioni voice-over-IP in tempo reale possono ricevere priorità rispetto al traffico non in tempo reale. Ciascuna classe di priorità ha la propria coda. La modalità di accodamento con priorità decide quindi di trasmettere i pacchetti non più nell'ordine generale di arrivo, ma selezioanndo di volta in volta il pacchetto dalla coda non vuota con priorità più alta. La scelta fra i pacchetti di una classe è di solito effettuta secondo la strategia FIFO.
Nella modalità di **accodamento a priorità senza prelazione** (*non-preemptive priority queuing*), la trasmissione dei pacchetti non può essere interrotta una volta iniziata.

Round Robin e Weighted Fair Queuing (WFQ)
Anche nella modalità di accodamento round robin, *round robin queuing*, i pacchetti sono suddivisi in classi, senza una rigida priorità di servizio, ma con un'alternanza tra le classi. La forma più semplice di roun robin prevede l'alternanza della trasmissione: prima viene inviato un pacchetto della classe 1 e poi uno della classe 2, quindi nuovamente un pacchetto di classe 1, e così via. Nella **modalità conservativa**, il collegamento non resta mai inattivo fintanto che ci sono pacchetti, di qualsiasi classe, da trasmettere; se la coda di una classe è vuota viene immediatamente controllata quella successiva.
Un esempio di modalità round robin con due classi è mostrato nella seguente figura.

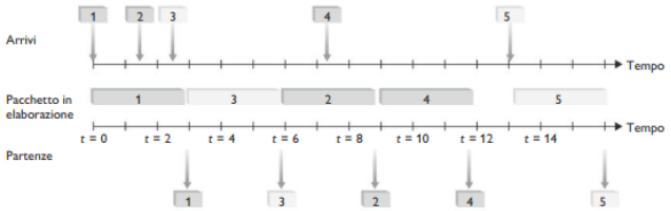


Figura 29: Operazioni di una coda round robin con due classi

Nello schema i pacchetti 1, 2, e 4 sono assegnati alla prima classe e gli altri alla seconda. Il pacchetto 1 inizia a essere tramsesso subito dopo che il suo ingresso nel buffer. Nel frattempo sopraggiungono i pacchetti 2 e 3 che vengono posti nelle rispettive code. Terminato il primo invio, lo scheduling cerca un pacchetto del secondo gruppo e quindi trasmette il pacchetto numero 3; poi estrae il pacchetto 2 e lo invia. Terminata la trasmissione e non essendoci pacchetti del secondo gruppo viene immediatamente invaito il pacchetto 4.
Un'astrazione generalizzata di questa strategia che ha trovato vasto impiego nei router è la cosidetta modalità di **accodamento equo ponderato** (**WFQ**, *Weighted Fair Queuing*). Nello schema WFQ, i pacchetti in arrivo sono classificati e accodati in base alla classe. Anche WFQ offre un servizio di tipi ciclico. Inoltre, anche WFQ è conservativa e pertanto quando la coda di una classe è vuota si sposta immediatamente a quella successiva.
Diversamente da round robin, con WFQ le varie classi possono ricevere un servizio differenziato. In particolare, a ciascuna classe i è assegnato un peso w_i. In qualsiasi momento in cui nella coda i siano presenti pacchetti che debbano essere spediti, WFQ garantisce che questi ricevano una frazione di servizio pari a: $\frac{w_i}{\sum w_i}$, dove al denominatore è indicata la somma effettuata su tutte le classi che hanno pacchetti da trasmettere. Anche nel caso peggiore, quando tutte le classi hanno pacchetti accodati, la classe i acrà la garanzia di ricevere una certa frazione di larghezza di banda. Quindi, per un collegamento con capacità trasmissiva R, la classe i avrà sempre un rendimento pari a $R \cdot \frac{w_i}{\sum w_i}$. Lo schema di WFQ è mostrato nella seguente figura.

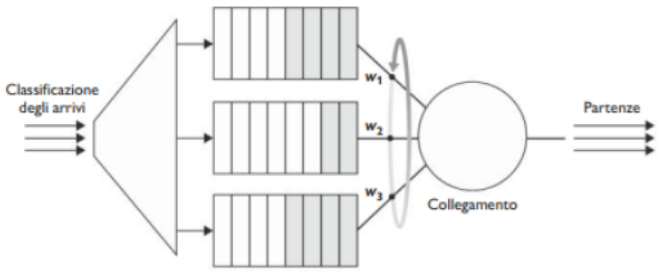


Figura 30: Accodsamento equo ponderato (WFQ)

5.3. Il protocollo Internet (IP)

Analizziamo nel dettaglio il Protocollo Internet **IP**, *Internet Protocol*.
Attualmente sono in uso due versioni di IP, la versione 4 e la versione 6 proposta in sostituzione alla versione 4. Inoltre, analizzeremo l'indirizzamento Internet.

5.3.1. Formato dei datagrammi IPv4

Ricordiamo che il pacchetto a livello di rete è noto come *datagramma*. Il formato dei datagrammi IPv4 è mostrato nella seguente figura.

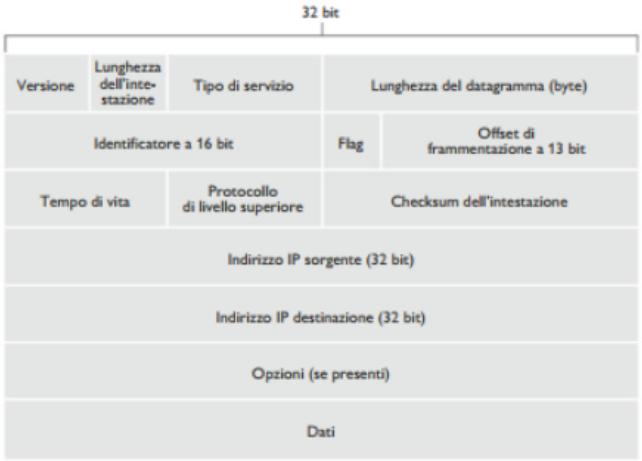


Figura 31: Formato dei datagrammi IPv4

I principali campi dei datagrammi IPv4 sono i seguenti:

- **Numero di versione**. Questi 4 bit, che specificano la versione del protocollo IP del datagramma, consentono al router la corretta interpretazione del datagramma.
- **Lunghezza dell'intestazione**. Dato che un datagramma IPv4 può contenere un numero variabile di opzioni, questi 4 bit indicano dove iniziano effettivamente i dati del datagramma. La maggior parte dei datagrammi IP non contiene opzioni, pertanto il tipico datagramma IP ha un'intestazione di 20 byte.
- **Tipo di servizio**. I bit relativi al tipo di servizio (TOS, *type of service*) sono stati inclusi nell'intestazione IPv4 per distinguere diversi tipi di datagrammi. Spesso è utile distinguere datagrammi in tempo reale da altro traffico.
- **Lunghezza del datagramma**. Rappresenta la lunghezza totale del datagramma IP, intestazione più dati, misurata in byte. Considerando che questo campo è lungo 16 bit, la massima dimensione dei datagrammi IP è 65.535 byte.
- **Identificatore, flag, offset di frammentazione**. Questi tre campi servono per la cossidetta frammentazione: un datagramma IP grande viene frammentato in datagrammi IP più piccoli che vengono inoltrati in modo indipendente alla destinazione dove vengono riassemblati prima che i dati di payload vengano passati al livello di trasporto dell'host di destinazione. La versione IPv6 non consente la frammentazione sui **router intermedi**, ma la consente agli host sorgente e destinazione.

  Il campo flag è composto da 3 bit:

  ▸ bit 0: **RS** (*Reserved*, sempre 0);

- bit 1: **DF** (*Don't fragment*, vieta la frammentazione);
- bit 2: **MF** (*More Fragments*, vale 1 per tutti i frammenti tranne l'ultimo).

Inoltre, abbiamo detto che l'**MTU** (Maximum Transmission Unit) è la massima quantità di dati che un frame di livello collegamento può trasportare. La tecnica usata per trovare la più piccola MTU lungo il percorso tra sorgente e destinazione è la **Path MTU Discovery (PMTUD)**. Si inviano datagrammi col flag `DF = 1` ; se un router incontra un link con MTU inferiore alla dimensione del pacchetto, lo scarta e invia un messaggio ICMP tipo 3 codice 4 (*Fragmentation Needed / packet too big*) indicando la MTU del link successivo. Il mittente riduce la dimensione e ripete finchè il pacchetto non arriva a destinazione.

- **Tempo di vita**. Il *time-to-live, TTL*, è stato incluso per assicurare che i datagrammi non restino in circolazione per sempre nella rete. Questo campo viene decrementato di un'unità ogni volta che il datagramma è elaborato da un router; quando raggiunge 0, il datagramma viene scartato.
- **Protocollo**. Questo campo è usato quando il datagramma raggiunge la destinazione finale. Il valore del campo indica lo specifico protocollo a livello di trasporto al quale vanno passati i dati del datagramma. Ad esempio, il valore 6 indica che i dati sono destinati a TCP, il valore 17 designa UDP.
- **Checksum dell'intestazione**. Consente ai router di rilevare gli errori sui bit nei datagrammi ricevuti. È calcolato trattando ogni coppia di byte dell'intestazione come numeri che sono poi sommati in complemento a 1. Un router calcola tale valore per ciascun datagramma IP ricevuto e rileva una condizione di errore se il checksum trasportato nell'intestazione del datagramma non corrisponde a quello calcolato. I router normalmente scartano i datagrammi in cui si verifica un errore. Il checksum deve essere ricalcolato e aggiornato a ogni router, come anche il campo TTL e i campi opzione, che possono cambiare.
- **Indirizzi IP sorgente e destinazione**. Quando un host crea un datagramma, inserisce il proprio indirizzo IP nel campo indirizzo IP sorgente e quello della destinazione enl campo indirizzo IP destinazione. Spesso l'host sorgente determina l'indirizzo di destinazione attraverso uan ricerca DNS.
- **Opzioni**. Questi campi consentono di estendere l'intestazione IP. Le opzioni dell'intestazione sono state concepite per un utilizzo sporadico. Tuttavia, le opzioni costituiscono un problema: dato che possono avere lunghezza variabile, non è possibile determinare a priori dove comincerà il campo **Dati**. Inoltre, dato che i datagrammi possono richiedere o non richiedere l'elaborazione delle opzioni, il tempo necessario per questa operazione su un router può variare in modo significativo. Le opzioni sono state eliminate dall'intestazione IPv6.
- **Dati**. Nella maggior parte dei casi, il campo dati contiene il segmento a livello di trasporto da consegnare alla destinazione. Tuttavia, può trasportare anche altri tipi di dati.

5.3.2. Indirizzamento IPv4

Generalmente un host ha un solo collegamento con la rete; quando il livello IP dell'host vuole inviare un datagramma, lo fa su tale collegamento. Il confine tra host e collegamento fisico viene detto **interfaccia**. Un router, invece, dato che ha il compito di ricevere datagrammi da un collegamento e inoltrarli su un altro, deve essere connesso ad almeno due collegamenti. Anche il confine tra un router e i suoi collegamenti è chiamato interfaccia. Il router presenta più interfaccia, una su ciascuno dei suoi collegamenti. Dato che un host e router sono in grado di inviare e ricevere datagrammi, IP richiede che tutte le interfacce abbiano un proprio indirizzo IP. Pertanto, un indirizzo IP è tecnicamente associato a un'interfaccia.
Gli indirizzi IP sono lunghi 32 bit e quindi ci sono in totale 2^{32} indirizzi IP. Tali indirizzi sono solitamente scritti nella cosidetta **notazione decimale puntata**, in cui ciascun byte dell'indirizzo viene indicato in forma decimale ed è separato con un punto dagli altri byte dell'indirizzo.
Ogni interfaccia di host e router di Internet ha un indirizzo IP globalmente univoco. Tuttavia, tali indirizzi non possono essere scelti in modo arbitrario. Una parte dell'indirizzo di un'interfaccia è determinata dalla sottorete cui è collegata.
Consideriamo la seguente figura.

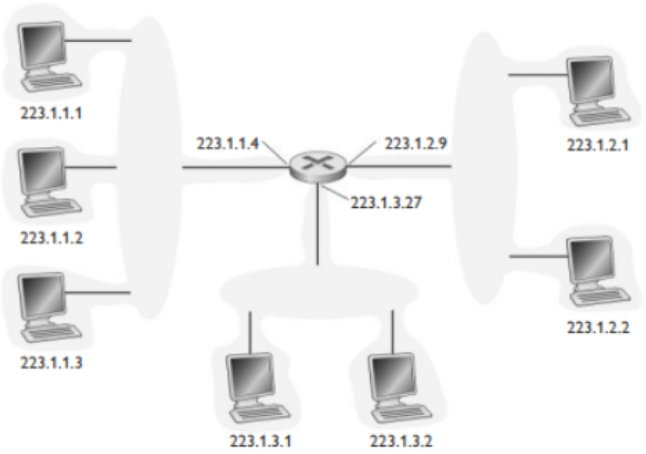


Figura 32: Indirizzi delle interfacce e sottoreti

Questa figura mostra un router con tre interfacce che connette sette host. I tre a sinistra hanno un indirizzo IP della forma 223.1.1.xxx.
Per IP, questa rete che interconnette tre interfacce di host e l'interfaccia di un router forma una **sottorete**. IP assegna a questa sottorete l'indirizzo 223.1.1.0/24, dove la notazione /24, detta anche **maschera di sottorete**, *subnet mask*, indica che i 24 bit può a sinistra dell'indirizzo definiscono l'indirizzo della sottorete. Ogni altro host connesso alla sottorete 223.1.1.0/24 deve avere un indirizzo della forma 223.1.1.xxx.

La strategia di assegnazione degli indirizzi Internet è detta **Classless Interdomain Routing**. **CIDR**, detto in inglese *cider*, generalizza la nozione di indirizzamento di sottorete. L'indirizzo IP viene diviso in due parti e mantiene la forma puntata $a.b.c.d/x$, dove x indica il numero di bit nella prima parte dell'indirizzo.
Gli x bit più a sinistra costituiscono la porzione di rete dell'indirizzo IP e sono spesso detti **prefisso** dell'indirizzo. A un'organizzazione viene generalmente assegnato un blocco di indirizzi contigui con un prefisso comune per tutti gli indirizzi IP dei dispositivi che si trovano al suo interno. I rimanenti $32 - x$ bit di un indirizzo possono essere usati per distinguere i dispositivi interni dell'organizzazione, che hanno tutti lo stesso prefisso di rete. Saranno quindi i router della rete interna che utilizzeranno i restanti bit dell'indirizzo per indirizzarli al dispositivo destinatario.
Prima dell'adozione di CIDR, le parti di rete di un indirizzo IP dovevano essere lunghe 8, 16 o 24 bit. Tale schema di indirizzamento era noto come **classful addressing**, dato che le sottoreti con indirizzi di sottorete da 8, 16 e 24 bit erano note rispettivamente come reti di classe A, B e C. Il requisito che la parte di sottorete di un indirizzo IP fosse lungo esattamente 1, 2 o 3 byte si rivelò presto problematico nel supportare il numero di organizzazioni in rapida crescita con sottoreti di piccole e medie dimensioni. Una sottorete di classe C (/24) poteva ospitare solo fino a $2^8 - 2 = 254$ host, due dei 256 indirizzi sono riservati per usi speciali. Altre sottoreti di classe B (/16), che possono avere 65.534 host, risultavano sovradimensionate. Ciò portò a un rapido esaurimento degli indirizzi della classe B e a uno scarso utilizzo dello spazio di indirizzamento assegnato.
Consideriamo l'IP broadcast 255.255.255.255. Quando un host emette un datagramma con destinazione 255.255.255.255, il messaggio viene consegnato a tutti gli host sulla stessa sottorete.
Per ottenere un blocco di indirizzi IP da usare in una sottorete, un amministratore di rete deve contattare il proprio ISP, che potrebbe fornire degli indirizzi attingendo da un blocco più grande che gli è già stato allocato. Anche lo stesso ISP deve richiedere un blocco di indirizzi. Esiste un'autorità globale che ha la responsabilità di gestire lo spazio di indirizzamento IP e di allocare i blocchi di indirizzi: l'*Internet Corporation for Assigned Names and Numbers* (ICANN).

Struttura dell'indirizzo, classi (Classful), indirizzi speciali e privati
Ogni indirizzo IPv4 a 32 bit è logicamente suddiviso in due parti:

- **Prefisso** (**netid**): identifica univocamente la rete ed è assegnato da un'autorità di registrazione globale (IANA o un *Regional Internet Registry*, RIR).
- **Suffisso** (**hostid**): identifica l'host (o meglio, l'interfaccia) all'interno della rete ed è gestito localmente dall'amministratore di rete.

Nello schema storico **classful** (oggi legacy), il confine tra *netid* e *hostid* era rigido e determinato dai primi bit dell'indirizzo IP, definendo cinque classi:

Classe	Bit iniziali	Range 1° ottetto	Bit Netid / Hostid	Maschera di default	Max Reti	Max Host validi per rete
A	0	0 - 127	7 / 24	255.0.0.0 (/8)	2^7	$2^{24} - 2$
B	10	128 - 191	14 / 16	255.255.0.0 (/16)	2^{14}	$2^{16} - 2$
C	110	192 - 223	21 / 8	255.255.255.0 (/24)	2^{21}	$2^8 - 2$
D	1110	224 - 239	—	—	—	Indirizzi **multicast**
E	1111	240 - 255	—	—	—	Riservati per usi futuri

All'interno dello spazio di indirizzamento IPv4 esistono inoltre degli **indirizzi speciali** e dei blocchi riservati alle **reti private** (non annunciabili né instradabili direttamente sull'Internet pubblica):

Prefisso (Netid)	Suffisso (Hostid)	Tipo di indirizzo	Scopo / Utilizzo
Tutti 0	Tutti 0	*Questo computer* (0.0.0.0)	Usato dagli host durante la fase di bootstrap (es. DHCP)
network	Tutti 0	Indirizzo di rete	Identifica la rete o sottorete stessa (*netid*)
network	Tutti 1	*Directed broadcast*	Broadcast diretto verso tutti gli host di una specifica rete
Tutti 1	Tutti 1	*Limited broadcast* (255.255.255.255)	Broadcast limitato alla sottorete locale del mittente

Prefisso (Netid)	Suffisso (Hostid)	Tipo di indirizzo	Scopo / Utilizzo
`127`	Qualsiasi	*Loopback* (es. `127.0.0.1`)	Comunicazione interna all'host stesso per testing di rete

I tre blocchi di **indirizzi IPv4 privati** (RFC 1918), utilizzati all'interno delle LAN domestiche o aziendali dietro router NAT, sono:

- **Classe A privata**: `10.0.0.0 - 10.255.255.255` (`10.0.0.0/8`)
- **Classe B privata**: `172.16.0.0 - 172.31.255.255` (`172.16.0.0/12`, ovvero 16 reti `/16` contigue)
- **Classe C privata**: `192.168.0.0 - 192.168.255.255` (`192.168.0.0/16`, ovvero 256 reti `/24` contigue)

Subnetting e calcolo delle sottoreti

Il **subnetting** (RFC 950) permette a un'organizzazione di suddividere un singolo blocco di indirizzi IP assegnatole in più **sottoreti** fisiche distinte, prendendo in prestito i primi k bit dalla porzione *hostid* per estendere il *netid*.

La **maschera di sottorete** (*subnet mask*) è una sequenza di 32 bit composta da tutti `1` in corrispondenza dei bit di rete e di sottorete, e da tutti `0` in corrispondenza dei bit riservati agli host.

Dato un blocco iniziale con prefisso `/x` che viene partizionato estendendo la maschera di k bit fino a un nuovo prefisso `/(x + k)`:

- **Numero di sottoreti ottenibili**: 2^k.
- **Bit rimanenti per gli host**: $m = 32 - (x + k)$.
- **Indirizzi totali per sottorete**: 2^m.
- **Indirizzi validi (assegnabili agli host)**: $2^m - 2$, poiché il primo indirizzo del blocco (bit host tutti a `0`) identifica il **netid** della sottorete e l'ultimo indirizzo (bit host tutti a `1`) è riservato al **broadcast** della sottorete. **(Nota: fanno eccezione i collegamenti punto-punto tra due router configurati con maschera `/31` secondo la RFC 3021, che mettono a disposizione esattamente $2^1 = 2$ indirizzi utilizzabili senza indirizzo di broadcast).**
- **Calcolo del Netid di appartenenza**: dato un indirizzo IP e la sua subnet mask, il *netid* si ottiene applicando l'operazione logica bitwise **AND** bit a bit tra l'indirizzo IP e la maschera: Netid = IP $\wedge$ Mask.

Nota topologica: per contare quante sottoreti sono presenti in una rete fisica, occorre isolare i gruppi di interfacce (di host e router) che comunicano direttamente senza attraversare un router; **anche ogni collegamento diretto punto-punto tra due router costituisce una sottorete a sé stante**.

Esempio 2 *(Calcolo di appartenenza e partizionamento in sottoreti)* **. 1. Verifica di appartenenza tramite AND bitwise**

Determiniamo il *netid* dell'indirizzo `192.168.23.87/26` e verifichiamo se appartiene alla stessa sottorete di `192.168.23.67/26` .

La maschera `/26` ha 26 bit a `1` e $32 - 26 = 6$ bit a `0` per gli host: corrisponde a `255.255.255.192` (poiché nel quarto ottetto $128 + 64 = 192$). I primi tre ottetti rimangono invariati (`192.168.23`); effettuiamo l'AND sul quarto ottetto:

- `87` in binario: `01010111`
- `192` in binario: `11000000`
- `87 AND 192` : `01000000` $= 64$.

Metodo rapido: con 6 bit di host, le sottoreti procedono a blocchi di dimensione $2^6 = 64$ nel quarto ottetto (`0, 64, 128, 192`). Il più grande multiplo di 64 inferiore o uguale a 87 (e a 67) è `64` . Pertanto:

- **Netid**: `192.168.23.64/26`
- **Range host validi**: `192.168.23.65 - 192.168.23.126` ($2^6 - 2 = 62$ host)
- **Broadcast**: `192.168.23.127`

Entrambi gli indirizzi `.87` e `.67` cadono nel range `65 - 126` , quindi **appartengono alla stessa sottorete**.

2. Partizionamento di una rete su ottetti diversi

Data la rete `134.65.0.0/16` (maschera di default `255.255.0.0`), vogliamo partizionarla in almeno 6 sottoreti:

- Per ottenere almeno 6 sottoreti servono $k = 3$ bit prestati dal terzo ottetto, poiché $2^3 = 8 \geq 6$ sottoreti.
- Il nuovo prefisso diventa `/19` $(16 + 3)$, corrispondente alla subnet mask `255.255.224.0` $(128 + 64 + 32 = 224)$.
- Restano $32 - 19 = 13$ bit per gli host, ovvero $2^{13} - 2 = 8190$ host validi per sottorete.
- Nel terzo ottetto i blocchi avanzano di $2^{8-3} = 32$: i *netid* delle prime 6 sottoreti saranno `134.65.0.0/19` , `134.65.32.0/19` , `134.65.64.0/19` , `134.65.96.0/19` , `134.65.128.0/19` e `134.65.160.0/19` (con `134.65.192.0/19` e `134.65.224.0/19` disponibili).

VLSM (Variable Length Subnet Mask)

Nel subnetting «classico» (a maschera fissa), tutte le sottoreti ricavate hanno la stessa identica dimensione: questo comporta un enorme spreco di indirizzi se nella stessa organizzazione coesistono LAN grandi (es. 100 host) e piccoli collegamenti punto-punto tra router (2 host).

La tecnica **VLSM** (**Variable Length Subnet Mask**) estende il subnetting per-

mettendo di applicare maschere di lunghezza diversa all'interno dello stesso blocco di partenza, cucendo ogni sottorete esattamente sul numero di host richiesti.

Regola di allocazione e allineamento (boundary validi): Una sottorete IPv4 di dimensione 2^m **non può iniziare da un indirizzo IP arbitrario**, ma deve sempre iniziare da un indirizzo (**boundary**) che sia un **multiplo esatto della dimensione del suo blocco** (2^m).
Per evitare «buchi» di indirizzi non allineati, il metodo standard VLSM prevede di:

1. **Ordinare le richieste** di sottorete dalla più grande (maggior numero di host) alla più piccola.
2. Per ciascuna richiesta di H host, trovare il più piccolo esponente m tale che $2^m - 2 \geq H$, fissando il prefisso a `/(32 - m)`.
3. **Assegnare i blocchi in sequenza** nello spazio di indirizzi disponibile. **(Se invece si deve frazionare uno spazio residuo che parte da un indirizzo non multiplo di potenze grandi, occorre rispettare prima i boundary validi, allocando eventualmente dal blocco più piccolo a quello più grande per riallinearsi ai multipli di 4, 8, 16, ecc.).**

Esempio 3 *(Progettazione VLSM su blocco 10.10.0.0/24)* **.** Partizioniamo la rete `10.10.0.0/24` per soddisfare le seguenti richieste (già ordinate in senso decrescente): **LAN A** (100 host), **LAN B** (50 host), **LAN C** (20 host), **LAN D** (10 host) e un **Link punto-punto** (2 host):

Rete	**Richiesti**	**Disponibili**	**Spreco**	**Subnet (Netid/ Slash)**	**Range Host Validi**	**Broadcast**
LAN A	100	126 ($2^7 - 2$)	26	`10.10.0.0/25`	`10.10.0.1` – `10.10.0.126`	`10.10.0.127`
LAN B	50	62 ($2^6 - 2$)	12	`10.10.0.128/26`	`10.10.0.129` – `10.10.0.190`	`10.10.0.191`
LAN C	20	30 ($2^5 - 2$)	10	`10.10.0.192/27`	`10.10.0.193` – `10.10.0.222`	`10.10.0.223`
LAN D	10	14 ($2^4 - 2$)	4	`10.10.0.224/28`	`10.10.0.225` – `10.10.0.238`	`10.10.0.239`
Link	2	2 (2^1, RFC 3021)	0	`10.10.0.240/31`	`10.10.0.240` – `10.10.0.241`	Nessuno

Rimangono liberi 14 indirizzi (`10.10.0.242 - 10.10.0.255`). Poiché `242` è multiplo di 2 ma non di 4 né di 8 ($242 \bmod 4 = 2$), in `10.10.0.242` non può iniziare una `/30` o una `/29` , ma solo una `/31` (`242-243`), seguita da una `/30` in `10.10.0.244/30` (`244-247` , dato che 244 è multiplo di 4) e infine una `/29` in `10.10.0.248/29` (`248-255` , dato che 248 è multiplo di 8).

Supernetting (Route Aggregation)

Il **supernetting** (o *route aggregation*) è l'operazione duale rispetto al subnetting: consiste nell'accorpare più reti IP contigue in un unico blocco più grande (**super-rete**) rappresentato da un singolo prefisso più corto. Reso possibile dall'introduzione di CIDR, è ampiamente utilizzato nel routing inter-dominio (BGP) per aggregare i blocchi di indirizzi di un Sistema Autonomo e ridurre drasticamente il numero di righe nelle tabelle di routing globali.

Più reti aventi la stessa dimensione (stesso prefisso) possono essere aggregate in un'unica super-rete **solo se** rispettano tre requisiti:

1. **Contiguità**: i blocchi di indirizzi si susseguono senza «buchi» (nessun indirizzo mancante nel mezzo).
2. **Potenza di 2**: il numero n di reti da aggregare deve essere una potenza di 2 ($n = 2, 4, 8, 16, ...$); ad esempio, 3 reti `/24` (768 indirizzi) non possono essere rappresentate da alcun singolo prefisso CIDR.
3. **Allineamento**: il primo indirizzo della prima rete deve essere divisibile per la dimensione totale della super-rete risultante.

Il **prefisso della super-rete** è costituito dai bit iniziali che rimangono identici in tutte le reti da aggregare.

> **Esempio 4** *(Aggregazione di 4 reti /24 in una super-rete)* **.** Consideriamo le 4 reti contigue ($n = 4 = 2^2$): `193.0.0.0/24`, `193.0.1.0/24`, `193.0.2.0/24` e `193.0.3.0/24`. Osserviamo la rappresentazione binaria dei primi tre ottetti:
>
> - `193.0.0.0/24` → `11000001 00000000 00000000 00000000`
> - `193.0.1.0/24` → `11000001 00000000 00000001 00000000`
> - `193.0.2.0/24` → `11000001 00000000 00000010 00000000`
> - `193.0.3.0/24` → `11000001 00000000 00000011 00000000`
>
> I bit iniziali in comune a tutti e quattro gli indirizzi sono i primi $16 + 6 = 22$ bit. La super-rete risultante è quindi **`193.0.0.0/22`**, che copre l'intero intervallo da `193.0.0.0` a `193.0.3.255` ($4 \times 256 = 1024$ indirizzi).

Ottenere indirizzo di un host tramite DHCP

Un'organizzazione che ha ottenuto un blocco di indirizzi li può assegnare individualmente alle interfacce di host e router nelal propria struttura. Per gli indirizzi delle interfacce dei router, l'amministratore del sistema configura manualmente gli indirizzi IP nel router. Gli indirizzi degli host possono essere configurati manualmente, ma più spesso questo compito è svolto utilizzando il **Dynamic Host Configuration Protocol (DHCP)**. DHCP consente a un host di ottenere un indirizzo IP in modo automatico, così come di apprendere informazioni aggiuntive, quali la sua maschera di sottorete, l'indirizzo del router per uscire dalla sottorete e l'indirizzo del suo DNS server locale. È possibile configurare DHCP di modo che

un dato host riceva un indirizzo IP persistente, in modo che ogni volta che l'host entra in rete gli venga assegnato sempre lo stesso indirizzo IP, oppure in modo da assegnare a ciascun host che si connette un **indirizzo IP temporaneo**.
DHCP viene spesso detto protocollo **plug-and-play** o **zero-conf** per la sua capacità di automatizzare la connessione degli host alla rete.
DHCP è un protocollo client-server. Un client è di solito un host appena connesso che desidera ottenere informazioni sulla configurazione della rete. Nel caso più semplice, ogni sottorete dispone di un server DHCP. In caso contrario, è necessario un agente di relay DHCP che conosca l'indirizzo di un server DHCP per quella rete.
Per i nuovi host, il protoccolo DHCP si articola in quattro punti. I quattro passi sono:

- **Individuazione del server DHCP**. Il primo compito di un host appena collegato è l'identificazione del server DHCP con il quale interagire. Questa operazione è svolta utilizzando un messaggio **DHCP discover**, che un client invia in un pacchetto UDP attraverso la porta 67. Il pacchetto UDP è incapsulato in un datagramma IP. L'host non conosce ancora l'indirizzo IP della rete alla quale è collegato e neanche l'indirizzo del server DHCP. Detto ciò, il client DHCP crea un datagramma IP contenente il suo messaggio DHCP con indirizzo di destinazione broadcast 255.255.255.255 e l'indirizzo sorgente 0.0.0.0, cioè questo host. Il client DHCP inoltra il datagramma IP al suo livello di collegamento, che invia il frame in broadcast a tutti i nodi collegati alla sottorete.
- **Offerta del server DHCP**. Un server DHCP, che riceve un messaggio di inteficazione, risponde al client con un messaggiuo **DHCP offer**, che viene inviato in broadcast a tutti i nodi della sottorete. Dato che in una sottorete possono esssere presenti diversi server DHCP, il client dovrebbe trovarsi nella condizione di scegliere tra le diverse offerte disponibili. Ciascun messaggio di offerta con tiene l'ID di transazione del messaggio di identificazione ricevuto, l'indirizzo IP proposto al client, la maschera di sottorete e la durata della concessione (**lease time**) dell'indirizzo IP.
- **Richiesta DHCP**. Il client appena collegato sceglierà tra le offertre dei server e risponderà con un messaggio **DHCP request**, che riporta i paramaetri di configurazione.
- **Conferma DHCP**. Il server risponde al messaggio di richiesta DHCP con un messaggio **DHCP ACK**, che conferma i parametri richiesti.

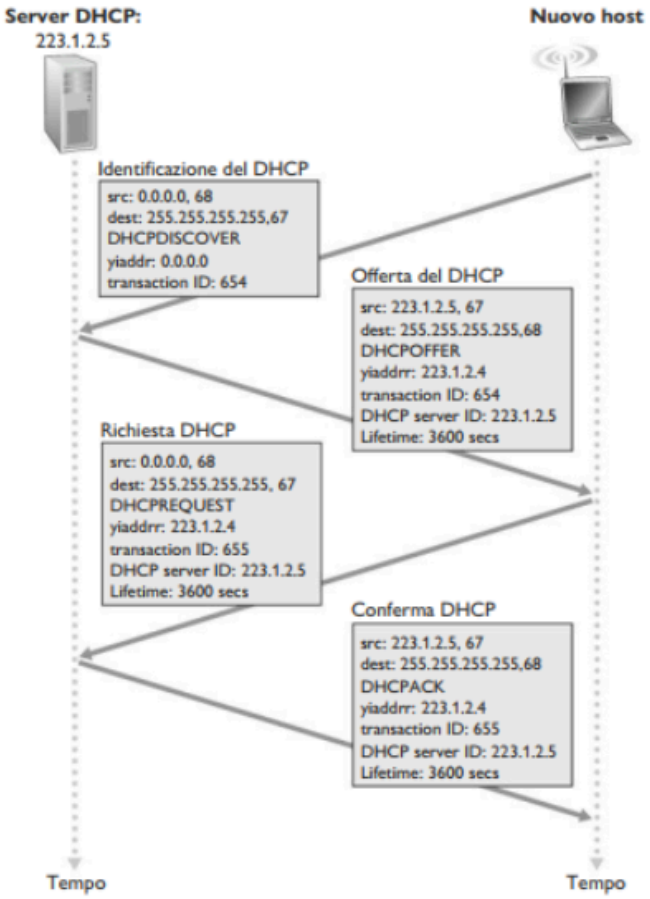


Figura 33: Interazione client-server DHCP

Dal punto di vista del trasporto, DHCP opera secondo il modello client-server su protocollo UDP: il **client DHCP** invia e riceve sulla porta **UDP 68**, mentre il **server DHCP** è in ascolto sulla porta **UDP 67**. All'interno dei messaggi DHCP (come mostrato in figura), il campo `yiaddr` (*your IP address*) indica l'indirizzo IP proposto/assegnato al client (posto a `0.0.0.0` nel *DHCP discover*), mentre il `transaction ID` permette di associare richieste e risposte della medesima transazione. Oltre all'allocazione dinamica con *lease* temporaneo, DHCP supporta anche l'assegnazione statica associando permanentemente uno specifico indirizzo IP all'indirizzo fisico **MAC** della scheda di rete dell'host.

5.3.3. NAT (Network Address Translation)

La proliferazione di sottoreti «small office, home office» (o SOHO, piccoli uffici in ambiente domestico), sembrerebbe implicare che ogni volta che si voglia installarne una, l'ISP debba allocare un intervallo di indirizzi per coprire tutte le macchine della sottorete. Di conseguenza, al crescere della LAN dovrebbe esserle assegnato

un blocco maggiore di indirizzi. Bisogna capire cosa accade se l'ISP ha già allocato la parte contigua all'intervallo di indirizzi dell'attuale rete SOHO e bisogna anche capire cosa dovrebbe sapere il normale utente per gestire gli indirizzi IP.
Esiste un approccio più semplice, il **NAT**, *Network Address Translation.*
La seguente figura mostra l'attività di un router abilitato al NAT.

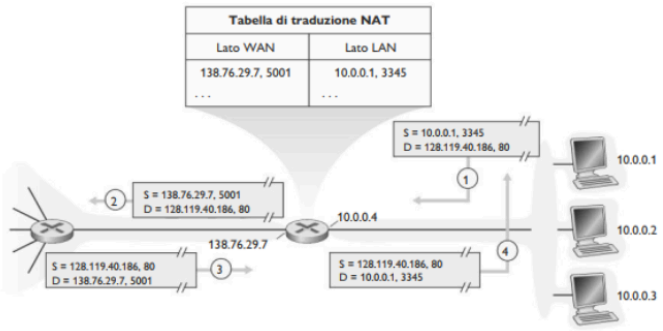


Figura 34: NAT

Le quattro interfacce della rete domestica in figura hanno lo stesso indirizzo di sottorete, 10.0.0.0/24. Lo spazio di indirizzamento 10.0.0.0/8 è una delle tre parti dello spazio di indirizzi IP riservato alle **reti privati**: ossia, una rete i cui indirizzi hanno significato solo per i dispositivi interni. Ovviamente i pacchetti inviati sull'Internet globale non possono utilizzare questi indirizzi come sorgente o destinazione. Per capire come viene gestito l'indirizzamento dei pacchetti relativi all'Internet globale, in cui gli indirizzi sono univoci, bisogna analizzare il servizio offerto dal NAT.
I router abilitati al NAT non appaiono come router al mondo esterno, ma si comportano come un unico dispositivo con un unico indirizzo IP. In sostanza, il router abilitato al NAT nasconde i dettagli della rete domestica al mondo esterno.
Se tutti i datagrammi in arrivo al router NAT della rete geografica hanno lo stesso indirizzo IP di destnazione, il router per capire a quale host interno deve inoltrare un determinato datagramma utilizza una **tabella di traduzione NAT** nel router NAT e nell'includere nelle righe di tale tabella i numeri di porta oltre che gli indirizzi IP.
Facendo riferimento alla **Figura 34**, supponiamo che un utente che si trovi nella rete domestica dietro l'host 10.0.0.1 richieda una pagina web da un server con indirizzo IP 128.119.40.186. L'host 10.0.0.1 assegna il numero di porta di origine 3345 e invia il datagramma nella rete locale. Il router NAT riceve il datagramma, genera per esso un nuovo numero di porta di origine 5001, sostituisce l'indirizzo IP sorgente conm il proprio indirizzo IP e sostituisce il numero di porta di origine con il nuovo numero 5001. Quando genera il nuovo numero di porta di origine, il router NAT può selezionare qualsiasi numeri di porta che attualmente non si trova nella tabella di traduzione NAT. Il web server risponde con un datagramma con l'indirizzo IP

del router NAT come destinazione e il cui numero di porta di destinazione è 5001. Quando questo datagramma arriva al router NAT, quest'ultimo consulta la tabella di traduzione NAT usando l'indirizzo IP di destinazione e il numero di porta di destinazione per ottenere l'appropriato indirizzo IP e il corretto numero di porta di destinazione del browser nella rete domestica.
In base alla direzione in cui avviene la traduzione degli indirizzi, si distingue tra due modalità operative del NAT:

- **SNAT** (**Source NAT**): è la traduzione dell'indirizzo IP e della porta **sorgente** descritta sopra, effettuata automaticamente dal router per le connessioni originate dagli host della rete privata in uscita verso Internet.
- **DNAT** (**Destination NAT**, comunemente noto come **Port Forwarding**): è la traduzione dell'indirizzo IP e della porta di **destinazione** per i pacchetti provenienti dall'esterno. Poiché gli host su Internet vedono solo l'IP pubblico del router NAT, se si desidera ospitare un server (es. un server Web sulla porta 80 o FTP sulla porta 21) su una macchina interna alla LAN privata (es. `192.168.0.100`), l'amministratore deve configurare manualmente una regola statica di *port forwarding* sul router: ogni pacchetto in ingresso dall'esterno diretto a una specifica porta pubblica del router viene riscritto nell'header di destinazione e inoltrato all'IP privato e alla porta privata del server interno.

5.3.4. IPv6

Col passare degli anni uno spazio di indirizzamento a 32 bit stava cominciando a esaurirsi. Per soddisfare l'esigenza di un grande spazio di indirizzamento venne sviluppato un nuovo protocollo: IPv6 e i progettisti colsero l'opportunità per apportare migliorie e modifiche rispetto alla precedente versione.

Formato dei datagrammi IPv6

La seguente figura mostra il formato dei datagramma e illustra i cambiamenti più significativi.

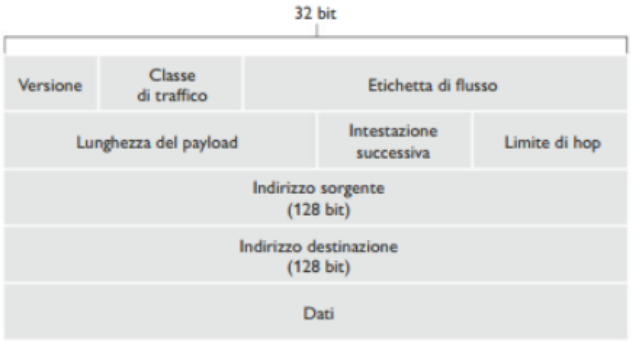


Figura 35: Formato dei datagrammi IPv6

- **Indirzzamento esteso**. IPv6 aumenta la dimensione dell'indirizzo IP da 32 a 128 bit, in modo che gli indirizzi IP diventino praticamente inesauribili. Oltre agli indirizzi unicast e multicast, IPv6 supporta anche indirizzi anycast, che consentono di consegnare un datagramma a un qualsiasi host all'interno di un gruppo.
- **Intestazione ottimizzata di 40 byte**. Alcuni cambi IPv4 sono stati eliminati o resi opzionali. La risultante intestazione a 40 byte a lunghezza fissa consente una più rapida elaborazione dei datagrammi IP, mentre una nuova codifica delle opzioni ne consente l'elaborazione in maniera più flessibile.
- **Etichettatura dei flussi**. IPv6 presnta una definizione elusiva di **flusso**. L'RFC 2460 afferma che ciò consente l'etichettatura di pacchetti che appartengono a flussi particolari per i quali il mittente richiede una gestione speciale, come una qualità di servizio diversa da quella di default o un servizio in tempo reale.

Un confronto tra la **Figura 31** e la **Figura 35** evidenzia la struttura più semplice e più efficiente dei datagrammi del protocollo IPv6 in cui sono definiti i seguenti campi.

- **Versione**. Campo a 4 bit che identifica il numero di versione. Porre 4 in questo campo non basta per creare un datagramma IPv4 valido.
- **Classe di traffico**. Campo a 8 bit, simile al campo TOS di IPv4. Può essere utilizzato per attribuire priorità a determinati datagrammi all'interno di un flusso o provenienti da specifiche applicazioni rispetto a quelli di altri servizi.
- **Etichetta di flusso**. Campo a 20 bit utilizzato per identificare un flusso di datagrammi.
- **Lunghezza del payload**. Questo valore a 16 bit è trattato come un intero senza segno e indica il numero di byte nel datagramma IPv6 che seguono l'intestazione a lunghezza fissa di 40 byte.
- **Intestazione successiva**. Campo che identifica il protocollo a cui verranno consegnati i contenuti del datagramma, per esempio TCP o UDP. Utilizza gli stessi valori del campo protocollo nell'intestazione IPv4.
- **Limite di hop**. Il contenuto di questo campo è decrementato di 1 da ciascun router che inoltra il datagramma. Quando il suo valore raggiunge 0, il datagramma viene eliminato.
- **Indirizzi sorgente e destinazione**. I diversi formati degli indirizzi IPv6 a 128 bit sono descritti nell'RFC 4291.
- **Dati**. Payload che viene passato al protocollo specificato nel campo di intestazione successiva quando il datagramma IPv6 raggiunge la sua destinazione.

Confrontando il formato IPv6 (**Figura 35**) con IPv4 (**Figura 31**) notiamo che sono stati eliminati vari campi.

- **Frammentazione/riassemblaggio**. IPv6 non consente frammentazione né riassemblaggio sui router intermedi; queste operazioni possono essere effettuate

soltanto da sorgente o destinazione. Se un router riceve un datagramma IPv6 che risulta troppo grande per essere inoltrato, non fa altro che eliminarlo e inviare al mittente un messaggio d'errore ICMP «Pacchetto troppo grande». Il mittente può quindi inviare nuovamente i dati, con una dimensione di dataagramma IP inferiore.

- **Checksum dell'intestazione**. Dal momento che i protocolli Internet a livello di trasporto e di collegamento calcolano un loro checksum, i progettisti di IP hanno ritenuto questa funzionalità ridondante nel livello di rete da decidere di rimuoverla. La preoccupazione è stata l'elaborazione rapida dei pacchetti IP, pertanto, il checksum era un'operazione onerosa da calcolare ogni volta che il pacchetto attraversava router differenti.
- **Opzioni**. Il campo opzioni non fa più parte dell'intestazione IP standard, anche se non è del tutto scomparso. Infatti, è una delle possibili intestazioni successive a cui punta l'intestazione IPv6.

Rappresentazione e struttura degli indirizzi IPv6

Gli indirizzi IPv6 hanno una lunghezza di **128 bit** (16 byte) e vengono scritti in **notazione esadecimale** suddivisi in **8 blocchi da 16 bit** (4 cifre esadecimali ciascuno) separati dal carattere due punti (`:`), ad esempio:

`2001:0000:1234:0000:0000:00d0:abcd:0532`

Per compattare la scrittura si applicano due regole di semplificazione:

1. **Omissione degli zeri iniziali**: gli zeri non significativi a sinistra all'interno di ciascun blocco da 16 bit possono essere omessi (es. `00d0` → `d0` , `0532` → `532` , `0000` → `0`). L'indirizzo precedente diventa: `2001:0:1234:0:0:d0:abcd:532` .
2. **Compressione dei blocchi di zeri consecutivi (`::`)**: una sequenza contigua di due o più blocchi composti interamente da zeri può essere sostituita da un doppio due punti (`::`). Questa abbreviazione può essere usata **una sola volta** all'interno di un indirizzo (altrimenti la ricostruzione a 128 bit sarebbe ambigua); se ci sono più sequenze di blocchi nulli, si comprime quella più lunga o, a parità di lunghezza, quella più a sinistra.
   - Esempio 1: `2001:0:1234:0:0:d0:abcd:532` → `2001:0:1234::d0:abcd:532` .
   - Esempio 2 (parità di lunghezza): `2001:0db8:0000:0000:0001:0000:0000:0001` → `2001:db8::1:0:0:1` .
   - Indirizzo di **loopback** IPv6: `0:0:0:0:0:0:0:1` → `::1` .

In IPv6 non esiste la notazione decimale puntata per le maschere di sottorete, ma si usa esclusivamente la lunghezza del prefisso (es. `/64`). Tipicamente un indirizzo IPv6 unicast globale è diviso in:

- **Subnet Prefix (primi 64 bit)**: costituiscono il *netid*, a loro volta solitamente ripartiti in 48 bit per il routing globale Internet e 16 bit per definire le sottoreti interne all'organizzazione.

- **Host Identifier / Interface ID (ultimi 64 bit)**: identificano univocamente l'interfaccia dell'host nella sottorete (*hostid*).

Autoconfigurazione degli indirizzi: SLAAC

A differenza di IPv4, IPv6 integra nativamente un meccanismo di autoconfigurazione *stateless* denominato **SLAAC** (**Stateless Address Autoconfiguration**), basato su messaggi **ICMPv6**, che permette a un host di configurarsi autonomamente sulla rete senza bisogno di un server DHCP. Il processo si articola in 5 passi:

1. **Generazione dell'indirizzo Link-Local**: appena connesso, l'host genera autonomamente un indirizzo provvisorio valido solo sul collegamento locale con prefisso `fe80::xxxx` (derivando l'identificatore a 64 bit dal proprio indirizzo MAC oppure generandolo in modo casuale).
2. **Router Solicitation (RS — ICMPv6 tipo 133)**: l'host invia in multicast un messaggio di *Router Solicitation* per scoprire la presenza di router IPv6 sul collegamento locale.
3. **Router Advertisement (RA — ICMPv6 tipo 134)**: il router locale risponde con un messaggio di *Router Advertisement* contenente il prefisso globale della sottorete (es. `2001:db8:cafe::/64`), l'indirizzo del default gateway (es. `fe80::1`) e il server DNS.
4. **Generazione dell'indirizzo globale**: l'host combina il prefisso `/64` annunciato dal router con il proprio ID di interfaccia a 64 bit, formando il proprio indirizzo IPv6 globale.
5. **Duplicate Address Detection (DAD — ICMPv6 tipo 135)**: prima di utilizzare stabilmente l'indirizzo (sia link-local che globale), l'host ne verifica l'unicità inviando sulla rete locale un messaggio ICMPv6 di *Neighbor Solicitation* avente come target l'indirizzo appena generato; se nessun altro nodo risponde reclamando quell'indirizzo, la configurazione è completata con successo.

5.3.5. Passaggio DA IPv4 A IPv6

I nuovi sistemi IPv6 sono retrocompatibili, ossia sono in grado d'inviare, instradare e ricevere datagrammi IPv4, i sistemi IPv4 non sono in grado di gestire datagrammi IPv6. Per ovviare a questo problema esistono diverse opzioni.

Tunneling

L'approccio più adottato è noto come **tunneling**. Supponiamo che due nodi IPv6 vogliano utilizzare datagrammi IPv6, ma siano connessi da un insieme di router intermedi IPv4, che chiameremo **tunnel**, come mostrato nella seguente figura:

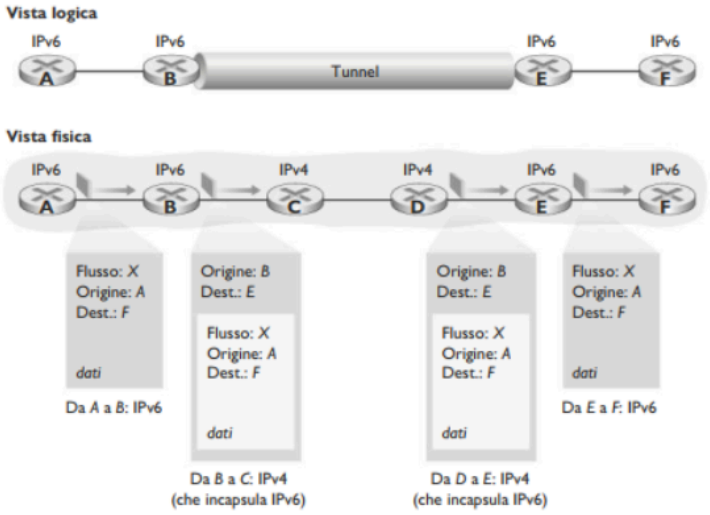


Figura 36: Tunneling

Il nodo *B*, al lato di invio del tunnel, prende l'intero datagramma IPv6 pervenutogli da *A* e lo pone nel campo dati di un datagramma IPv4. Quest'ultimo viene indirizzato al nodo *E*, al lato di ricezione del tunnel e inviato al primo nodo del tunnel *C*. I router IPv4 intermedi instradano il datagramma IPv4, come farebbero per qualsiasi altro datagramma, ignari che questo contenga un datagramma IPv6 completo. Il nodo IPv6, sul lato di ricezione del tunnel riceverà il datagramma IPv4, determinerà che questo ne contiene uno IPv6 osservando che il valore del campo numero di protocollo nel pacchetto IPv4 è 41 corrispondente a payload IPv6, lo estrarrà e lo instraderà esattamente come se l'avesse ricevuto da un nodo IPv6 adiacente.
I vantaggi e gli svantaggi del tunneling sono:

- **Vantaggi**: non richiede alcun aggiornamento dei router IPv4 intermedi.
- **Svantaggi**: introduce overhead per il doppio header (IPv4 + IPv6), riduce la MTU effettiva (rischio di frammentazione) e aggiunge latenza di incapsulamento/decapsulamento.

Dual Stack

In questo approccio i nodi eseguono simultaneamente IPv4 e IPv6 quindi hanno entrambe le tipologie di indirizzi e sono capaci di inviare e ricevere sia datagrammi IPv6 che IPv6. Il doppio indirizzamento viene gestito dal DNS (type `AAAA`). I vantaggi di questo approccio sono i seguenti:

- compatibilità totale con entrambi i protocolli;
- transizione graduale e trasparente;
- **nessuna traduzione o modifica dei pacchetti**.

Gli svantaggi invece sono:

- non risolve l'esaurimento degli indirizzi IPv4;
- c'è un doppio consumo di risorse;
- c'è una maggiore complessità gestionale nei router.

Translation
Mediante questo approccio vengono tradotti gli header IPv6 in header Ipv4 ai bordi di rete IPv4-only. Questo approccio consente di avere reti IPv6-only ma c'è una perdita di informazioni per campi non traducibili.

5.4. Inoltro generalizzato e SDN

L'inoltro basato sull destinazione è caratterizzato da due passi:
1. ricerca dell'indirizzo IP di destinazione (*match*);
2. invio del pacchetto attraverso la struttura di comunicazione a una specifica porta di uscita (*action*).

Consideriamo un paradigma molto più generale, il paradigma *match-action*, dove il match può essere effettuato su più campi dell'intestazione associati a differenti protocolli corrispondenti a diversi livelli della pila di protocolli. La action può includere l'inoltro del pacchetto a una o più porte di uscita, il bilanciamento di carico dei pacchetti attraverso più interfacce di uscita che portano a un servizio (*load-balacing*), la riscrittura dei valori dell'intestazione, il blocco/scarto di un pacchetto, l'invio di un pacchetto a un server speciale per ulteriori elaborazioni e azioni, e altro ancora.
Nell'inoltro generalizzato, una tabella match-action generalizza il concetto delle tabella di inoltro bassata sulla destinazione. Poichè le decisioni di inoltro possono essere effettuate utilizzando indirizzi di sorgente e destinazione del livello di rete e/o del livellodi collegamento, i dispositivi di inoltro sono denominato *packet switch* piuttosto che router o switch.
La seguente figura mostra una tabella match-action in un packet switch, calcolata, installata e aggiornata da un controlelr remoto. È anche possibile che i componenti di controllo di un packet switch interagiscono tra di loro, nella pratica sono implementati da un controller remoto che calcola, installa e aggiorna le tabelle.

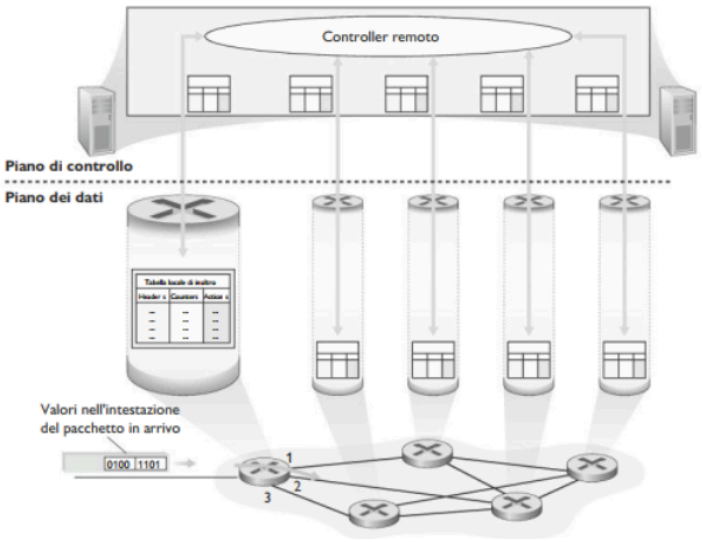


Figura 37: Inoltro generalizzato

Ogni entry corrisponde a una riga in una tabella di inoltro match-action, nota come **tabella dei flussi**, contiene quanto segue.

- *Un insieme di valori dei campi dell'intestazione* con i quali il pacchetto entrante viene confrontato. Il controllo viene implementato a livello hardware è effettuato molto più rapidamente dalle memorie TCAM, che permettono più di un milione di occorrenze di indirizzi di destinazione. Un pacchetto che non abbia riscontrato alcun riscontro in alcuna occorrenza della tabella dei flussi può essere scartato o inviato a un controller remoto per ulteriori elaborazioni.
- *Un insieme di contatori* che vengono aggiornati quando i pacchetti vengono associati a un'occorrenza nella tabella dei flussi. Tali contatori possono contenere il numero di pacchetti associati a tale occorrenza e l'informazione temporale sull'ultimo aggiornamento dell'occorrenza.
- *Un insieme di azioni* che devono essere intrapese quando un pacchetto è associato a un'occorrenza della tabella dei flussi. Tali azioni potrebbero essere l'inoltro di un pacchetto a una data porta di uscita, lo scarto del pacchetto, l'effettuazione delle copie del pacchetto e il loro invio a più porte di uscita e/o la riscrittura di alcuni campi dell'intestazione.

5.4.1. Match

Il seguente schema mostra gli undici campi dell'intestazione del pacchetto e l'ID della porta di ingresso che possono essere confrontati in una regola match-action.

In-gress Port	Src MAC	Dst MAC	Eth Type	VLAN ID	VLAN Pri	IP Src	IP Dst	IP Pro-to	IP TOS	TCP/ UDP Src Port	TCP/ UDP Dst Port

L'astrazione del match permette che un match venga effettuato sui campi delle intestazioni di tre livello di protocollo. Gli indirizzi MAC di sorgente e destinazione sono indirizzi di livello 2 associati alle interfacce di invio e ricezione dei frame.
Un dispositivo OpenFlow può funzione sia come un router, dispositivo di livello 3 che inoltra datagrammi, sia come uno switch, dispositivo di livello 2 che inoltra frame. L'insieme dei 12 valori che possono essere confrontati è cresciuto fino a 41 valori nelle specifiche più recenti.
La porta di ingresso si riferisce alla porta in entrata al packet switch sul quale il pacchetto viene ricevuto.
In funzione della specifica tecnlogia SDN, non tutti i campi dell'intestazione IP possono essere confrontati; per esempio, OpenFlow non permette il confronto sulla base del campo TTL o lunghezza del datagramma. Per capire perchè alcuni campi possono essere confrontati e altri no, è perchè bisogna raggiungere un compromesso tra funzionalità e complessità.

5.4.2. Action

Ogni occorrenza della tabella dei flussi ha una lista di azioni che determinano l'elaborazione da effettuare su un pacchetto che le corrisponde. In caso di molteplici azioni, vengono effettuate nell'ordine specificato dalla lista.
Le azioni più importanti possono essere le seguenti.

- **Inoltro** (*forwarding*). Un pacchetto in entrata può essere inoltrato a una particolare porta di uscita, inviato in broadcast a tutte le porte eccetto quella da cui è entrato o in multicast a un insieme selezionato di porte. Il pacchetto può essere incapsulato e inviato al controller remoto del dispositivo. Il controller può effettuare alcune azioni sul pacchetto, come installare nuove occorrenze nella tabella dei flussi o restituire il pacchetto al dispositivo per effettuare l'inoltro in base alla regole aggiornate della tabella dei flussi.
- **Scarto** (*dropping*). Un'occorrenza della tabella dei flussi senza azioni indica che il pacchetto dovrebbe essere scartato.
- **Modifica dei campi** (*modify-field*). I valori nei dieci campo dell'intestazione del pacchetto possono essere riscritti prima che il pacchetto venga inoltrato alla porta di uscita selezionata.

Livello di rete: il piano di controllo

Le tabelle di inoltro, nel caso di inoltro basato sulla destinazione, e le tabelle dei flussi, nel caso di inoltro generalizzato, sono gli elementi principali che collegano il piano dei dati e il piano di controllo del livello di rete. Tali tabelle specificano il comportamento di inoltro nel piano dei dati locale di un router. Inoltre, nel caso di inoltro generalizzato, le azioni intrapese potrebbero includere non solo l'inoltro di un pacchetto verso una porta di uscita del router, ma anche lo scarto del pacchetto, la duplicazione del pacchetto e la riscrittura dei campi dell'interstazione del pacchetto di livello 2, 3 e 4.
Per calcolare, mantenere e installare le tabelle di inoltro e dei flussi esistono due possibili approcci.

- *Controllo per router*. La seguente figura illustra il caso in cui l'algoritmo di instradamento viene eseguito su ogni singolo router, all'interno del quale vengono effettuate sia le funzioni di inoltro (piano dei dati) che quelle di instradamento (piano di controllo). Ogni router ha una componente di instradamento (piano di controllo). Ogni router ha una componente di instradamento che comunica con le componenti di instradamento degli altri router per calcolare la propria tabella di inoltro. Questo approccio è stato usato in Internet per decenni.

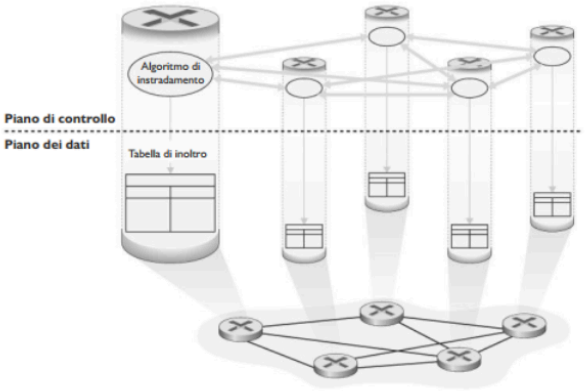


Figura 38: Controllo per router

- *Controllo logicamente centralizzato*. La seguente figura mostra il caso in cui un controller logicamente centralizzato calcola e distribuisce le tabelle di inoltro che devono essere utilizzate da ogni router. Inoltre, l'astrazione del match-action, come visto precedentemente, permette che il router effettui l'inoltro IP tradizionale e moltre altre funzioni che prima erano implementate in middlebox separati.

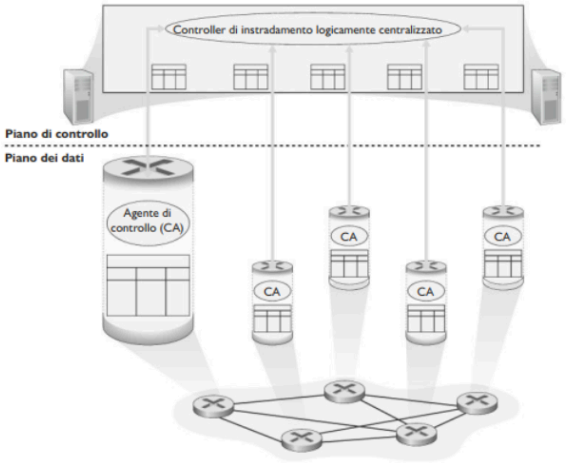


Figura 39: Controllo logicamente centralizzato

Il controller interagisce con l'agente di controllo (CA, *Control Agent*), in ogni router tramite un protocollo che configura e gestisce la tabella dei flussi del router. Tipicamente, il CA ha funzionalità minime: comunica con il cotroller ed esegue quello che il controller gli ordina. A differenza degli algoritmi di instradamenti della **Figura 38**, gli agenti di controllo non interagiscono direttamente tra di loro e non partecipano attivamente all'elaborazione della tabella di inoltro.
Per controllo logicamente centralizzato si intende un servizio di controllo dell'instradamento a cui si accede come se fosse un singolo punto centrale di servizio, anche se il servizio probabilmente viene implementato su più server per ragioni di resistenza ai guasti e scalabilità delle prestazioni.

6.1. Algoritmi di instradamento

Lo scopo degli **algoritmi di instradamento** è determinare i percorsi o cammini, tra le sorgenti e destinatari, attraverso la rete di router. Tipicamente, il percorso migliore è quello che ha costo minimo. Tuttavia, bisogna tenere in considerazione problematiche di interesse concreto quali le policy (ad esempio, il router x appartenente all'organizzazione Y, non può inoltrare pacchetti che abbiamo come sorgente la rete appartenente all'organizzazione Z). È sempre necessario avere una sequenza ben definita di router che il pacchetto attraverso viaggiando dall'host sorgente all'host destinatario, sia che il piano di controllo adotti un approccio per router sia che adotti un approccio logicamente centralizzato. Quindi, gli algoritmi di instradamento sono di importanza basilare.
Per formulare i problemi di instradamento si utilizza un **grafo**. Un grafo $G = (N, E)$ è un insieme N di nodi e un insieme E (*edge*) di archi, ove ciascun arco collega una coppia di nodi di N. Nel contesto dell'instradamento a livello di rete, i nodi

del grafo rappresentano i router e gli archi che connettono tali nodi rappresentano i colleganti fisici tra i router, come mostrato nella seguente figura:

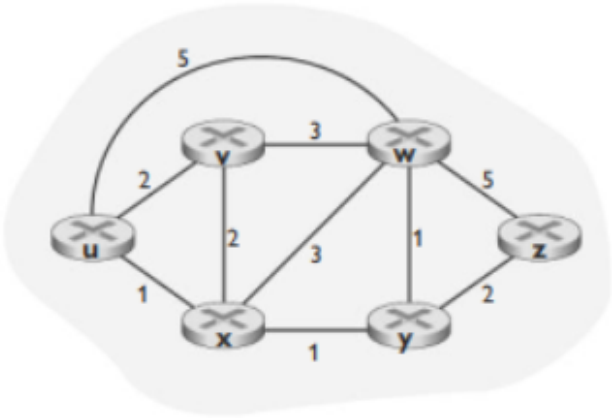


Figura 40: Modello astratto di grafo di una rete di calcolatori

Come mostrato nella figura, ad un arco è associato un valore che ne indica il costo. In genere, ciò può riflettere la lunghezza fisica del collegamento corrispondente, la velocità del collegamento o il suo prezzo. Per ogni arco (x, y) tra i nodi x e y denotiamo con $c(x, y)$ il suo costo. Se la coppia (x, y) non appartiene ad E, poniamo $c(x, y) = +\infty$. Inoltre, consideriamo sempre e solo grafi non orientati ovvero $c(x, y) = c(y, x)$. Inoltre, un nodo y viene detto **adiacente** o **vicino**, *neighbor*, a un nodo x se (x, y) è un arco in E.
Dato che agli archi del grafo sono assegnati dei costi, l'obiettivo di un algoritmo di instradamento è l'individuazione dei percorsi meno costosi tra sorgenti e destinazioni. Un **percorso** in un grafo $G = (N, E)$ è una sequenza di nodi $(x_1, x_2, ..., x_P)$ tali che ciascuna delle coppie $(x_1, x_2), (x_2, x_3), ..., (x_{P-1}, x_P)$ sia un arco appartenente ad E. Il costo di un percorso è la somma di tutti gli archi lungo il percorso. Dati due nodi qualsiasi x e y, esistono più percorsi che li congiungono, ciascun con il proprio costo. Uno o più tali percorsi rappresenta un **percorso a costo minimo**. Se tutti gli archi del grafo hanno lo stesso costo, il percorso a costo minimo rappresenta anche il **percorso più breve**, ossia il percorso con il minor numero di collegamenti tra sorgente e destinazione.
Possiamo classificare gli algoritmi di instradamento come centralizzati o decentralizzto.

- Un **algoritmo di instradamento centralizzato** calcola il percorso a costo minimo tra una sorgente e una destinazione avendo conoscenza globale e completa della rete. In altre parole, l'algoritmo riceve in ingresso tutti i collegamenti tra i nodi e i loro costi. Ciò richede che l'algoritmo in qualche modo ottenga tale informazione prima di effettuare il vero e proprio calcolo, che può svolto in una sola locazione quale potrebbe essere un controller logicamente centralizzato, o

replicato in ognuno dei router della rete. La caratteristica distintiva, è che un algoritmo globale ha informazioni complete su connettività e costi. In pratica, gli algoritmi con informazioni di stato globali sono spesso detti **algoritmi link-state** dato che l'algoritmo deve essere conscio del costo di ciascun collegamento della rete.

- In un **algoritmo di instradamento decentralizzato** il percorso a costo minimo viene calcolato in modo distribuito e iterativo. Nessun nodo possiede informazioni complete sul costo di tutti i collegamenti della rete. Inizialmente i nodi conoscono soltanto i costi dei collegamenti a loro incidenti. Poi, attraverso un processo iterativo e lo scambio di informazioni con i nodi adiacenti, un nodo gradualmente calcola il percorso a costo minimo verso una destinazione o un insieme di destinazioni. L'algoritmo di instradamento decentralizzato è chiamato algoritmo distance-vector DV, o con vettore delle distanze, poichè ogni nodo elabora un vettore di stima dei costi verso tutti gli altri nodi della rete. Tali algoritmi decentralizzati, che prevedono scambi interattivi tra router vicini, possono essere implementati nei piani di controllo nei quali i router interagiscono direttamente, mentre hanno poco senso nel caso di controllo centralizzato.

Un secondo criterio per classificare gli algoritmi di instradamento riguarda il fatto di essere statici o dinamici. Negli **algoritmi di instradamento statici** i percorsi cambiano molto raramente, spesso come risultato di un intervento umano. Gli **algoritmi di instradamento dinamici**, invece, determinano gli instradamenti al variare del volume di traffico o della topologia della rete. Un algoritmo dinamico può essere eseguito periodicamente o come conseguenza diretta di un cambiamento nella topologia o nel costo di un collegamento. Gli algoritmi dinamici rispondono meglio ai cambiamenti della rete, ma sono anche soggetti a problemi quali l'instradamento in loop e l'oscillazione dei percorsi.
Un terzo modo per classificare gli algoritmi di instradamento si basa sull'essere più o meno sensibili al carico della rete (*load-sensitive* o *load-insensitive*). In un **algoritmo sensibile al carico** i costi dei collegamenti variano dinamicamente per riflettere il lviello corrente di congestione. Se si associa un alto costo in una situazione di traffico ad un collegamento, un algoritmo di instradamento eviterà di usarlo. Gli attuali algoritmi di instradamento Internet sono **algoritmi insensibili al carico**, dato che il costo di un collegamento non riflette esplicitamente il suo attuale livello di congestione.

6.1.1. Instradamento link-state (LS)

In un instradamento link-state la topologia di rete e tutti i costi dei colleganenti sono noti. Ciò si ottiene facendo inviare a ciascun nodo paccehtto sullo stato dei suoi collegamenti a tutti gli altri nodi della rete. Questi pacchetti contengono identità e costi dei collegamenti connessi al nodo che li invia. Questo viene spesso ottenuto

tramite un algoritmo di **link-state broadcast**. In tal modo tutti i nodi dispongono di una vista identica e completa della rete e ciascun nodo che esegue l'algoritmo LS ottiene gli stessi risultati.
La distribuzione affidabile dello stato dei collegamenti a tutti i nodi avviene mediante una tecnica chiamata **reliable flooding**. Ogni nodo genera periodicamente (e ogni volta che rileva una variazione nello stato di un suo collegamento diretto) un **Link State Packet (LSP)** contenente:

- l'identificativo (ID) del nodo che ha creato l'LSP;
- l'elenco dei nodi adiacenti con il relativo costo del collegamento diretto;
- un **numero di sequenza** (**SEQNO**, a 32 o 64 bit), inizializzato a `0` al reboot del router e incrementato ad ogni nuova emissione di LSP;
- un campo **tempo di vita** (**TTL**), decrementato periodicamente dai router che conservano il pacchetto (quando il TTL raggiunge `0`, l'LSP viene scartato per eliminare informazioni obsolete).

Quando un router riceve un LSP da un vicino, controlla il `SEQNO`: se l'LSP è più recente di quello già memorizzato per quel nodo origine (ovvero ha un `SEQNO` maggiore), il router lo salva nel proprio database e lo propaga su tutte le altre linee di uscita eccetto quella da cui è arrivato; altrimenti lo scarta.
L'algoritmo di calcolo dei percorsi associato all'instradamento link-state è noto come **algoritmo di Dijkstra**. L'algoritmo di Dijkstra calcola il percorso a costo minimo da un nodo (l'origine, che chiameremo u) a tutti gli altri nodi della rete, è iterativo e ha le seguenti proprietà: dopo la k-esima iterazione, i percorsi a costo minimo sono noti a k nodi di destinazione e, tra i percorsi a costo minimo verso tutti nodi di destinazione, questi k percorsi hanno i k costi più bassi. Si adotta la seguente notazione.

- $D(v)$: costo minimo del percorso dal nodo origine alla destinazione v per quanto concerne l'iterazione corrente dell'algoritmo.
- $p(v)$: immediato predecessore di v lungo il percorso a costo minimo dall'orgine a v.
- N': sottoinsieme di noti contenente tutti i nodi v per cui il percorso a costo minimo dall'origine a v è definitivamente noto.

L'algoritmo di instradamento centralizzato consiste in un passo di inizializzazione seguito da un ciclo che viene eseguito una volta per ogni nodo del grafo. Quando termina, l'algoritmo avrà calcolato il camminimo minimo dal nodo origine u a tutti gli altri nodi.

Algoritmo 3 — *Algoritmo di Dijkstra*

```
1:  Inizializzazione
2:  N' = {u}
3:  per tutti i nodi v
4:      se v è adiacente a u
5:          allora D(v) = c(u,v)
6:      altrimenti D(v) = ∞
7:  Ciclo
8:      determina un w non in N' tale che D(w) sia minimo
9:      aggiungi w a N'
10:     aggiorna D(v) per ciascun nodo v adiacente a w e non in N':
11:         D(v) = min(D(v), D(w) + c(w,v))
12:         /* il nuovo costo verso v è il vecchio costo verso v oppure il costo del percorso minimo
            noto verso w più il costo da w a v */
13:         ripeti in ciclo finchè non si verifica che N' = N
```

Esempio 5 *(Applicazione algoritmo di Dijkstra)* **.** Consideriamo la rete nella **Figura 40** e calcoliamo i percorsi a costo minimo da u a tutte le destinazioni. I passi dell'algoritmo sono mostrati nella seguente tabella, le cui righe forniscono i valori delle variaibili dell'algoritmo al termine dell'iterazione.

- Nel passo di inizializzazione i valori dei percorsi a costo minimo noti da u ai suoi nodi adiacenti, v, w e x, sono posti rispettivamente a 2, 5 e 1. In particolare il costo verso w vale 5 dato che questo è il costo del collegamento diretto da u a w. I costi verso y e z sono posti a infinito dato che tali nodi non sono adiacenti a u.
- Nella prima iterazione prendiamo in considerazione i nodi non ancora aggiunti all'insieme N' e determiniamo il nodo a costo minimo come alla fine della precedente iterazione. Tale nodo è x, di costo 1, e pertanto x viene aggiunto all'insieme N'. Viene poi eseguita ricalcolato $D(v)$ per tutti i nodi, ottenendo i risultati mostrati nella seconda riga. Il costo verso v non è cambiato. Il costo del percorso verso w passando per x è diventato 4. Viene quindi selezionato questo percorso a costo inferiore e il predecessore di w lungo il percorso minimo da u diventa x. Analogamente, il costo verso y viene calcolato essere 2, e la tabella viene aggiornata di conseguenza.
- Nella seconda iterazione si trova che i nodi v e y hanno percorsi a costo minimo, ne scegliamo arbitrariamente uno e aggiungiamo y all'insieme N' che ora conterrà u, x e y. I costi verso i nodi rimanenti non ancora in N', ossia v, w e z sono aggiormati ottenendo i risultati mostrati nella terza riga.
- E così via...

Passo	N'	$D(v), p(v)$	$D(w), p(w)$	$D(x), p(x)$	$D(y), p(y)$	$D(z), p(z)$
0	u	$2, u$	$5, u$	$1, u$	∞	∞
1	ux	$2, u$	$4, x$		$2, x$	∞
2	uxy	$2, u$	$3, y$			$4, y$
3	$uxyv$		$3, y$			$4, y$
4	$uxyvw$					$4, y$
5	$uxyvwz$					

Quando l'algoritmo termina, abbiamo per ciascun nodo il suo predecessore lungo il percorso a costo minimo dal nodo orgine. Per ciascun predecessore abbiamo il rispettivo predecessore, e in questo modo riusciamo a costruire l'intero percorso dall'orgine a tutte le destinazioni.

Calcoliamo la complessità computazionale di questo algoritmo. Nella prima iterazione, dobbiamo cercare se tutti gli n nodi per determinare quello w in in N' avente il costo minimo. Nella seconda iterazione dobbiamo controllare $n-1$ nodi per determinare il costo minimo; nella terza $n-2$ e così via. Complessivametne il numero totale di nodi da cercare in tutte le iterazioni è $\frac{n(n+1)}{2}$ e, di conseguenza, diciamo che la complessità dell'algoritmo di Dijkstra nel caso peggiore è di ordine quadratico: $O(n^2)$. Un'implementazione più sofisticata, utilizzando una struttura dati nota come heap, riesce a determinare il minimo in un tempo logaritmico anzichè lineare.

6.1.2. Instradamento distance-vector (DV)

Mentre l'instradamento LS usa informazioni globali, quello **distance-vector** è iterativo, asincrono e distribuito. È *distribuito* nel senso che ciascun nodo riceve parte dell'informazione da uno o più dei suoi vicini direttamente connessi, a cui, dopo aver effettuato il calcolo, restituisce i risultati. È *iterativo* nel senso che questo processo si ripete fino a quando non avviene ulteriore scambio informativo tra vicini. L'algoritmo è anche auto-terminante: non vi è alcun segnale che il calcolo debba fermarsi, semplicemente si blocca. È *asincrono* nel senso che non richiede che tutti i nodi operino al passo con gli altri.

Consideriamo un'importante relazione tra costi e percorsi a costo minimo. Sia $d_x(y)$ il costo del percorso a costo minimo dal nodo x al nodo y. Allora i costi minimi sono correlati dalla nota **formula di Bellman-Ford**:

$$d_x(y) = \min_v \{c(x,v) + d_v(y)\}$$

dove $\min_v$ riguarda tutti i vicini di x. Se, dopo aver viaggiato da x a v, consideriamo il percorso a costo minino da v a y, il costo del percorso sarà $c(x,v) + d_v(y)$. Il costo

minimo è il minimo di $c(x,v) + d_v(y)$ calcolato su tutti i nodi adiacenti v.
La formula di Bellman-Ford fornisce le righe della tabella di inoltro del nodo x. Sia v^* un qualsiasi nodo vicino che minimizza l'equazione di Bellman-Ford. Allora, se il nodo x vuole inviare un pacchetto al nodo y lungo il percorso a costo minimo, dovrebbe prima inoltrarlo al nodo v^*. Pertanto, la tabella di inoltro al nodo x specificherebbe il nodo v^* come router successivo per la destinazione finale y. Un altro contributo pratico della formula è suggerire la forma della comunicazione tra vicini che avrà luogo nell'algoritmo usato dal DV, detto **algoritmo di Bellman-Ford**.
L'idea è la seguente. Ciascun nodo x inizia con $D_x(y)$, una stima del percorso a costo minimo da sè stesso al nodo y, per tutti i nodi in N. Sia $\boldsymbol{D}_x = [D_x(y) : y \in N]$ il vettore delle distanze dal nodo x, che è il vettore delle stime dei costi da x a tutti gli altri nodi. Con l'algoritmo Bellman-Ford, ciascun nodo x mantiene i seguenti dati di instradamento.

- Per ciascun vicino v, il costo $c(x,v)$ da x al vicino v.
- Il vettore delle distanze dal nodo x, contenente la stima presso x del costo verso tutte le destinazioni y.
- I vettori delle distanze di ciascuno dei suoi vicini, ossia $\boldsymbol{D}_v = [D_v(y) : y \in N]$, per ciascuno vicino y di x.

In questo algoritmo distribuito e asincrono, ogni tanto un nodo invia una copia del proprio vettore delle distanze a ciascuno dei suoi vicini. Quando un nodo x riceve un nuovo vettore da qualunque dei suoi vicini v, lo salva e quindi usa la formula di Bellman-Ford per aggioranre il proprio vettore come segue:

$$D_x(y) = \min_v \{c(x,v) + D_v(y)\} \quad \text{per ciascun nodo } y \text{ in } N$$

Se il vettore delle distanze del nodo x è cambiato per via di tale passo di aggiornamento lo invia a ciascuno dei suoi vicini, i quali a loro volta aggiorneranno il proprio vettore.

Algoritmo 4 — *Algoritmo Bellman-Ford*

A ciascun nodo x:

1: **Inizializzazione**:
2: **per** tutte le destinazioni y **in** N:
3: $D_x(y) = c(x,y)$
4: **per** ciascun vicino w
5: $D_w(y) =?$ per tutte le destinazioni y **in** N
6: **per** ciascun vicino w
7: invia il vettore delle distanze $D_x = [D_x(y) : y$ **in** $N]$ a w

8: **ciclo**
9: attendi (finché vedi cambiare il costo di un collegamento verso qualche vicino w o finché ricevi un vettore delle distanze da qualche vicino w)
10: **per** ogni y **in** N:
11: $D_x(y) = \min_v\{c(x,v) + D_v(y)\}$
12: **se** $D_x(y)$ è cambiato per qualche destinazione y
13: invia il vettore delle distanze $D_x = [D_x(y) : y \text{ in } N]$ a tutti i vicini
14: **ripeti** il ciclo indefinitamente

Un nodo, per aggioranre la propria tabella di inoltro per una da destinazione y, ciò che il nodo ha bisogno di sapere non è la distanza sul percorso minimo verso y, ma il ndoo vicino $v^*(y)$ che rappresenta il router successivo lungo il percorso più breve verso y. Il router $v^*(y)$ è il vicino v che ottiene il valore minimo nella riga 11 dell'**Algoritmo Bellman-Ford**. Se esistono più vicini v che ottengono il minimo, allora se ne sceglie uno qualunque tra questi.
La seguente figura mostra il funzionamento dell'instradamento DV in una semplice rete a tre nodi.

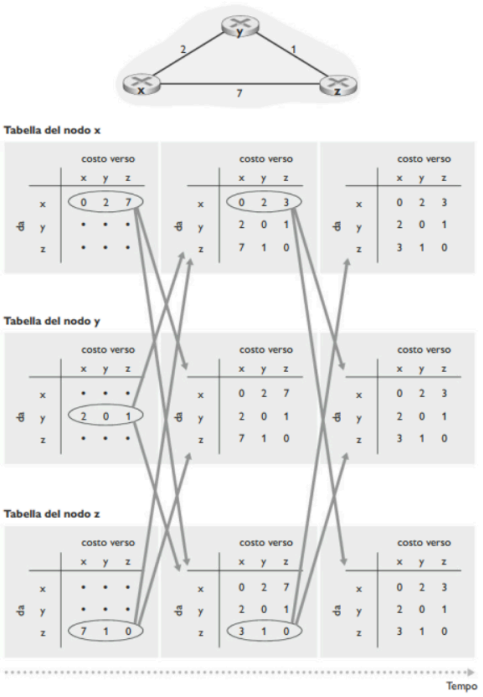


Figura 41: Instradamento distance vector (DV)

La colonna di sinistra della figura mostra tre **tabelle di instradamento** iniziali per ciascuno dei tre nodi. All'interno di una specifica tabella di instradamento le righe rappresentano i vettori delle distanze: più precisamente, la tabella di instradamento

di ciascun nodo include il proprio vettore delle distanze e quello dei suoi vicini.
Dopo l'inizializzazione, ciascun nodo invia il proprio vettore ai suoi vicini. Dopo aver ricevuto gli aggiormanenti, i nodi ricalcolano il vettore delle distanze. Ad esempio, per il nodo x:

$$D_x(x) = 0$$
$$D_x(y) = \min\{c(x,y) + D_y(y), c(x,z) + D_z(y)\} = \min\{2+0, 7+1\} = 2$$
$$D_x(z) = \min\{c(x,y) + D_y(z), c(x,z) + D_z(z)\} = \min\{2+1, 7+0\} = 3$$

La seconda colonna mostra, per ciascun nodo, il nuovo vettore delle distanze del nodo e i vettori delle distanze appean ricevuti dai suoi vicini.
Il processo di ricezione dei vettori aggiornati, di ricalcolo delle righe nella tabella di instradamento e di informazione ai vicini sui costi cambiati nel percorso a costo minimo verso la destinazione continua finchè non viene più inviato alcun messaggio di aggiormanto.
La tecnica per cui un nodo non annuncia mai una rotta al nodo adiacente da cui l'ha appresa prende il nome di **Split Horizon**; la variante in cui la annuncia ponendo esplicitamente il costo a $+\infty$ è detta **Split Horizon with Poisoned Reverse** o inversione avvelenata.

Il protocollo RIP (Routing Information Protocol)
Il principale protocollo storico di routing intra-AS basato sull'algoritmo **Distance-Vector** è **RIP** (**Routing Information Protocol**):

- **Trasporto e metrica**: i messaggi di aggiornamento RIP viaggiano incapsulati in segmenti **UDP** (sulla porta **520** per IPv4, o porta **521** per RIPng in IPv6). La metrica di costo utilizzata è il semplice conteggio dei salti (**hop count**), assumendo costo `1` per ogni collegamento attraversato.
- **Timer e Triggered Updates**: ogni router invia il proprio vettore delle distanze ai router adiacenti periodicamente ogni **30 secondi**, oppure immediatamente non appena rileva una modifica nella propria tabella (**triggered update**). Se una rotta non viene riconfermata dagli annunci di un vicino entro **180 secondi**, viene dichiarata irraggiungibile.
- **Gestione del conteggio all'infinito**: oltre a impiegare lo *split horizon*, RIP fissa convenzionalmente il valore di **infinito a 16 hop**. In questo modo, qualora si verifichi un ciclo di instradamento non coperto dallo split horizon, il conteggio all'infinito si arresta comunque non appena il costo raggiunge 16, dichiarando la destinazione irraggiungibile (ciò limita l'uso di RIP a reti il cui diametro non superi i 15 hop).

Instradamento distance-vetor: modifica dei costi e guasti dei collegamenti
Quando un nodo che esegue l'instradamento DV rivela un cambiamento nel costo dei collegamenti con un vicino aggiorna il proprio vettore delle distanze e, se si

verifica un cambiamento del percorso a costo minimo, trasmette ai suoi vicini il proprio vettore delle distanze. Consideriamo la seguente figura:

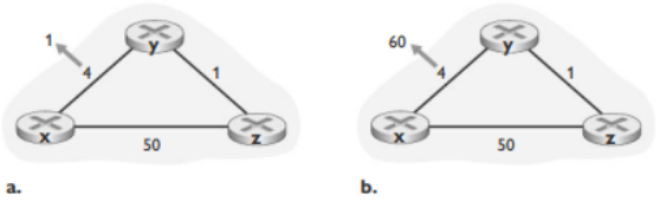


Figura 42: Variazioni nel costo dei collegamenti

Il grafo a sinistra mostra uno scenario in cui il costo del collegamento da y a x passa da 4 a 1. Ci concentriamo solo su y e sulle righe della tabella di distanze di z verso la destinazione x. L'algoritmo provoca la seguente sequenza di eventi:

- All'istante t_0 y rileva il cambiamento nel costo del collegamento, aggioran il proprio vettore delle distanze e informa i vicini del cambiamento.
- All'istante t_1 z riceve l'aggiormento da t e aggiorna la propria tabella, calcola un nuovo costo minimo verso x e invia il nuovo vettore delle distanze ai vicini.
- All'istante t_2 y riceve l'aggiornmento di z e aggiorna la propria tabella delle distanze. I costi minimi di y non cambiano e y non manda alcun messaggio a z. L'algoritmo entra in uno stato di quiete.

Consideriamo ora cosa può avvenire quando il costo di un collegamento aumenta. Supponaimo che il costo del collegamento tra x e y passi da 4 a 60, come mostrato nella figura sopra nel grafo a destra.

1. Prima che il costo del collegamento cambi $D_y(x) = 4, D_y(z) = 1, D_z(y) = 1$ e $D_z(x) = 5$. All'istante t_0, y rivela che il costo del collegamento è passato da 4 a 60 e calcola il suo nuovo percorso a costo minimo verso x con la formula $D_y(x) = \min\{c(y,x) + D_x(x), c(y,z) + D_z(x)\} = \min\{60 + 0, 1 + 5\} = 6$.

Ovviamente con la visione globale della rete, possiamo rilevare che questo nuovo costo attraverso z è *errato*. Ma l'univa informazione che il nodo y possiede è che il costo diretto verso x è 60 e che z ha detto a y di essere in grado di raggiungere x con un costo di 5. Pertanto al fine di arrivare a x, y farebbe passare il percorso per z, aspettandosi che questo sia in grado di giungere a x con un costo pari a 5. All'istante t_1, abbiamo un **instradamento ciclico**: per giungere ad x, y fa passare il percorso per z e z lo fa passare per y. Quindi un pacchetto destinato a x rimbalza sempre tra y e z.

1. Dato che il nodo y ha calcolato un nuovo costo minimo verso x, informa z del suo nuovo vettore delle distanze all'istante t_1
2. In un istante successivo a t_1, z riceve il nuovo vettore delle distanze di y, che indica che il costo minimo di y verso x è 6, sa che può giungere a y a costo 1 e quindi calcola il nuovo costo minimo verso x pari a $D_z(x) = \min\{50 + 0, 1 +$

$6\} = 7$. Dato che il costo minimo di z verso x è aumentato, z informa y del suo nuovo vettore delle distanze a tempo t_2

3. Analogamente, dopo aver ricevuto il nuovo vettore delle distanze di z, y determina $D_y(x) = 8$ e invia a z il suo nuovo vettore delle distanze, z determina $D_z(x) = 9$ e invia a y il suo nuovo vettore delle distanze, e così via.

Il ciclo prosegue per 44 iterazioni, fino a quando z considera il costo del proprio percorso attraverso y maggiore di 50. A questo punto, z determina che il percorso a costo minimo verso x passa attraverso la connessione diretta a x, e y instraderà verso x passando per z. A causa di questi scenari, il processo appena descritto viene detto **problema di conteggio all'infinito**.

Instradamento distance-vector: aggiunga dell'inversione avvelenata

Lo scenario con i cicli può essere evitato utilizzando una tecnica nota come **inversione avvelenata**. L'idea è semplice: se z instrada tramite y per giungere alla destinazione x, alloa z avverità y che la sua distanza verso x è infinita, ossia z comunicherà a y che $D_z(x) = +\infty$. Quindi y non tenterà mai di instradare x passando per z, per tutto il tempo in cui z continua a instradare verso x passando per y.

Vediamo come l'inversione avvelenata risolva il problema dei cicli. Quando il costo del collegamento (x, y) cambia da 4 a 60 all'istante t_0, y aggiorna la propria tabella, continua a instradare direttamente verso x, e informa z del suo nuovo costo verso x, ovvero $D_y(x) = 60$. Una volta ricevuto l'aggiornamento all'istante t_1, z cambia immediatamente il proprio percorso verso x facendolo passare attraverso il collegamento diretto (z, x) al costo 50. Dato che questo è il nuovo percorso a costo minimo e dato che non passa più attraverso y, z informa y che $D_z(x) = 50$. Dopo aver ricevuto l'aggiormanto da z, y adegua la propria tabella ponendo $D_y(x) = 51$. Dato che z si trova sul percorso a costo minimo di y verso x, y avvelena il percorso inverso da z a x informando z che $D_y(x) = +\infty$.

L'inversione avvelenata non risolve il problema del conteggio all'infinito perchè i cicli che non riguardano due nodi adiacenti non verranno rilevati dalla tecnica dell'inversione avvelenata.

Confronto tra gli instradamenti LS e DV

Confrontiamo gli instradamenti LS e DV con un veloce confronto di alcuni dei rispettivi attributi.

- **Complessità dei messaggi**. LS richiede che ciascun nodo conosca il costo di ogni collegamento nella rete. Ciò implica l'invio di $O(|N| \cdot |E|)$ messaggi. Inoltre, ogniqualvolta che cambia il costo di un collegamento, il cambiamento deve essere comunicato a tutti i nodi. A ogni iterazione l'instradamento DV richiede scambi solo tra nodi adiacenti.

- **Velocità di convergenza**. L'implementazione di LS è un algoritmo $O(|N|^2)$che richiede $O(|N| \cdot |E|)$ messaggi. L'algoritmo DV può convergere lentamente e può presentare cicli di instradamento. DV presenta anche il problema del conteggio all'infinito.
- **Robustezza**. Se un router si guasta, con LS un router può comunicare via broadcast un costo sbagliato per uno dei suoi collegamenti connessi. Un nodo può anchea lterare o eliminare i pacchetti ricevuti in broadcast LS. Ma i nodi LS si occupano di calcolare soltanto le prorpie tabelle di inoltro, e gli altri nodi effettuano calcoli simili. Quindi, i calcoli di instradamento sono isolati, il che fornisce un certo grado di robustezza. Con DV un nodo può comunicare percorsi a costo minimo errati a tutte le destinazioni. A ogni iterazione, il calcolo di DV in un nodo viene comunicato ai suoi vicini e quindi ai vicini dei vicini alla successiva iterazione. Un calcolo errato su un nodo si può diffondere sull'intera rete.

Nessuno dei due meccanismi di instradamento è nettamente superiore all'altro ed entrambi vengono utilizzati in Internet.

6.2. Instradamento interno ai sistemi autonomi: OSPF

Precedentemente abbiamo visto la rete semplicemente come una collezione di router interoconessi. Ciascun router era indistinguibile dagli altri nel senso che tutti eseguivano lo stesso algoritmo per calcolare l'instradamento attraverso la rete. Ma questa visione è semplicistica per due motivi.

- **Scalabilità**. Al crescere del numero di router, il tempo richiesto per calcolare, memorizzare e comunicare le informazioni di instradamento diventa proibitivo. Attualmente, Internet è costituita da centinaia di milioni di host. Archiviare le informazioni su ciascuno di essi richiederebbe enorme quantità di memoria, e il traffico generato dalla comunicazione broadcast non lascerebbe banda per i pacchetti di dati. Un algoritmo DV con così tanti host non convergerebbe mai.
- **Autonomia amministrativa**. Internet è una rete di ISP che generalmente desiderano gestire autonomamente i propri router o nascondere all'esterno aspetti dell'organizzazione interna della rete. L'ideale sarebbe che ciascuno fosse in grado di amministrare la propria rete nel modo desiderato, pur mantenendo la possibilità di connetterla alle reti esterne.

Questi problemi possono essere risolti organizzando i router in **sistemi autonomi** (AS, *Autonomous System*), generalmente composti da gruppi di router posto sotto lo stesso controllo amministrativo. I router di un AS eseguono lo stesso algoritmo di instradamento e gli unici hanno informazioni sugli altri. L'algoritmo di instradamento in esecuzione in un AS è detto **protocollo di instradamento interno al sistema autonomo**.
Ogni Sistema Autonomo (AS) può controllare anche intervalli di indirizzi IP non

contigui ed è identificato a livello globale da un numero univoco detto **ASN** (**Autonomous System Number**), assegnato da uno dei cinque **RIR** (**Regional Internet Registry**) mondiali:

- **RIPE NCC**: Europa, Medio Oriente e Asia Centrale;
- **ARIN**: Nord America;
- **APNIC**: Asia e regione del Pacifico;
- **LACNIC**: America Latina e Caraibi;
- **AfriNIC**: Africa.

Gli ASN possono essere a **16 bit** (numeri da `0` a `65535`, dove `0` e `65535` sono riservati e il blocco `64512 - 65534` è destinato ad uso privato, non annunciabile su Internet) oppure nel formato esteso a **32 bit** (fino a circa 4 miliardi, con il range `4200000000 - 4294967294` riservato agli ASN privati).

OSPF (Open Shortest Path First)

OSPF è generalmente impiegato negli ISP di livello superiore. Il termine *open* nell'acronimo indica che le specifiche del protocollo sono pubblicamente disponibili. OSPF è un protocollo link-state che utilizza il **flooding** per inviare in broadcast le informazioni riguardo lo stato dei collegamenti e l'algoritmo di Dijkstra per la determinazione del percorso a costo minimo. In OSPF, un router costruisce una mappa topologica, cioè un grafo, dell'intero sistema autonomo e manda in esecuzione l'algoritmo di Dijkstra per determinare un albero dei cammini minimi verso tutte le sottoreti. I costi dei collegamenti vengono fissati dall'amministratore di rete. L'amministratore può scegliere di impostare i costi di tutti i collegamenti a 1, oppure in modo inversamente proporzionale alla capacità del collegamento. OSPF non impone una politica sulla scleta dei pesi dei collegamenti, ma fornisce meccanismi per determinare l'instradamento con percorso a costo minimo per un dato insieme di pesi dei collegamenti.
In OSPF, ogni qualvolta che si verifica un cambiamento nello stato di un collegamento, il router manda informazioni di instradamento via broadcast a tutti gli altri router nel sistema autonomo. Inoltre, invia periodicamente lo stato dei collegamenti, anche se questo non è cambiato. Gli annunci OSPF sono contenuti in messaggi OSPF che vengono trasportati direttamente da IP come un protocollo di livello superiore con identificativo 89. Quindi, il protocollo OSPF deve implementare funzionalità quali il trasferimento affidabile dei messaggi e il broadcast dello stato dei collegamenti. Inoltre, controlla che i collegamenti siano operativi e consente ai router OSPF di accedere ai database sullo stato dei collegamenti della rete, contenuti nei router confinanti.
I vantaggi di OSPF sono i seguenti.

- **Sicurezza**. Gli scambi tra router OSPF possono essere autenticati: soltanto router fidati possono prendeere parte al protocollo OSPF in un sistema auto-

nomo. Senza autenticazione, i pacchetti OSPF tra router potrebbero essere contraffatti. Si possono configurare due tipi di autenticazione: semplice e tramite MD5. Nel caso di autenticazione semplice, si configura su tutti i router la stessa password che deve essere inclusa, in chiaro nei pacchetti OSPF a essi inviati. L'autenticazione MD5 si basa su chiavi segrete condivise, configurate in ogni router. Per ogni pacchetto OSPF che mandano, i router calcolano l'hash MD5 del contenuto a cui è stata aggiunta la chiave segreta e includono il risultato nel pacchetto MD5. Il router ricevente calcola la funzione hashMD5 del pacchetto e, usando la chiave segreta preconfigurata, la confronta con il valore che il pacchetto trasport, per verificarne l'autenticità. Con autenticazione MD5 vengono usati anche numeri di sequenza come protezione contro i *replay attacks*.

- **Percorsi con lo stesso costo**. Quando più percorsi verso una destinazione hanno stesso costo, OSPF consente di usarli senza doverne svegliere uno per trasportare tutto il traffico.
- **Supporto integrato per l'instradamento unicast e multicast.** Per consentire l'isntradamento multicast viene utilizzata un'estensione di OSPF, MOSPF (multicast OSPF), che utilizza il database dei collegamenti OSPF e aggiunge un nuovo tipo di annuncio sullo stato dei collegamenti al meccanismo di broadcast.
- **Supporto alla gerarchie in un dominio di instradamento**. OSPF fornisce la possibilità di strutturare i sistemi autonomi in modo gerarchico. Un sistema autonomo OSPF può essere configurato in aree che eseguono diversi algoritmi di instradamento OSPF: ciascun router in un'area invai lo stato dei suoi collegamenti agli altri router nell'area. In ogni area, uno o più **router di confine d'area** si fa carico dell'instradamento dei pacchetti indirizzati all'esterno. Un'area di sistema autonomo OSPF è configurata per essere l'**area di dorsale**, il cui ruolo principale è quello di instradare il traffico tra le altre aree nel sistema autonomo. La dorsale contiene sempre tutti i router di confine del sistema autonomo, ma non necessariamente soltanto quelli. L'instradamento nell'area di un sistema autonomo richiede che i pacchetti siano instradati prima verso il proprio router di confine e da questi, attraverso la dorsale, al rotuer di confine dell'area di destinazione, che provvede a farli pervenire alla destinazione finale.

6.3. Instradamento fra ISP: BGP

Per determinare i percorsi per le coppie sorgente-destinazione che interessano più sistemi autonomi è necessario un **protocollo di instradamento inter-AS** (*inter-autonomus system routing protocol*) che coordini più AS. Il **border gateway protocol**, detto **BGP**, rappresenta l'attuale standard dei protocolli di instradamento tra sistemi autonomi in Internet. È un protocollo di tipo distance-vector decentralizzato e asincrono.

6.3.1. Il ruolo di BGP

Si consideri un AS e un suo router qualsiasi. Le occorrenze della tabella di inoltro corrispondneti a destinazioni interne all'AS vengono determinate dal protocollo di instradamento intra-AS, il protocollo BGP ne determina quelle esterne.
In BGP, i pacchetti non vengono instradati verso uno specifico indirizzo, ma piuttosto verso **prefissi** CIDR che rappresentano una sottorete o una collezione di sottoreti. Le occorrenze della tabella di inoltro hanno forma (x, I) dove x è un prefisso di rete e I è un numero di interfaccia del router.
BGP mette a disposizione di ciascun router per:

1. *Ottenere informazioni sulla raggiungibilità dei prefissi di sottorete da parte dei sistemi confinanti.* In particolare, BGP consente a ciascuna sottorete di comunicare la propria esistenza al resto di Internet. Se non fosse per BGP, ogni sottorete sarebbe isolata, sola, sconosciuta e irraggiungibile dal resto di Internet.
2. *Determinare i percorsi ottimi verso le sottoreti.* Un router può venire a conoscenza di più cammini verso uno specifico prefisso; per determinare il migliore, esegue localmente BGP, sulla base delle informazioni di raggiungibilità e delle politiche del sistema.

6.3.2. Distribuzione delle informazioni dei percorsi in BGP

Si consideri la rete della seguente figura con tre AS: AS1, AS2 e AS3, quest'ultimo con una sottorete di prefisso x. Ogni router, in ogni AS, funge sia da **router gateway**, vale a dire un router di bordo direttamente connesso a uno o più router di altri AS, sia da **router interno**, connesso cioè solo a host e router interni dell'AS.

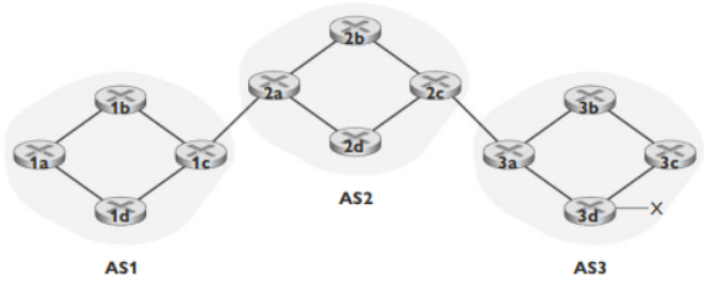


Figura 43: Rete con tre AS

Analizziamo coem BGP distribuirebbe le informazioni di raggiungibilità del prefisso x a tutti i router. AS3 invai un messaggio BGP ad AS2, con l'annuncio dell'esistenza in AS3 di x; denotiamo tale messaggio con *AS3 x*. Quindi AS2 invia un messaggio BGP a AS1 con l'annuncio che x esiste ed è raggiungibile passando prima da AS2 per poi arrivare ad AS3: *AS2 AS3 x*. In questo modo ogni AS verrà a conoscenza non solo dell'esistenza di x, ma anche dei percorsi per raggiungerlo. In realtà, sono i router e non gli AS a inviare gli annunci. In BGP, coppie di router si scambiano

informazioni di instradamento su connessioni TCP semi-permanenti utilizzando la porta 179. Le connessioni TCP semi-permanenti sono mostrare nella seguente figura.

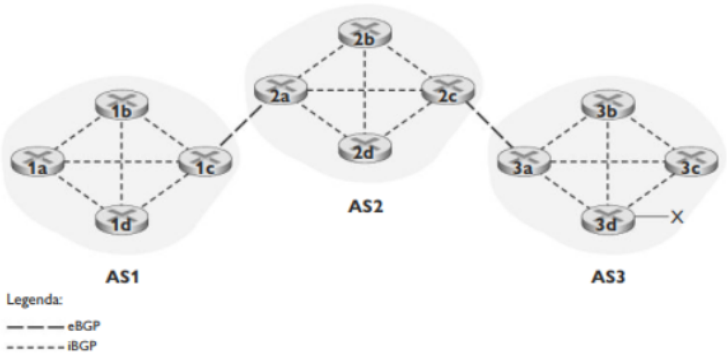


Figura 44: Connessioni eBGP e iBGP

Ogni connessione TCP, con tutti i messaggi BGP che vi vengono inviati, è detta **sessione BGP**. Nel caso in cui questa coinvolga due sistemi autonomi viene detta **sessione BGP esterna** (**sessione eBGP**), mentre quella tra router dello stesso sistema autonomi è chiamata **sessione BGP interna (sessione iBGP)**. Generalmente, in BGP c'è una connessione TCP di questo tipo per ciascun collegamento che connette direttamente due router in diversi sistemi autonomi.
È importante notare una differenza cruciale tra sessioni **eBGP** e **iBGP** (stabilite tra router detti **BGP peer** sulla porta **TCP 179**):

- Le sessioni **eBGP** connettono router di frontiera di AS diversi, tipicamente collegati da un link fisico diretto (1 hop fisico = 1 hop BGP); le rotte apprese via eBGP vengono poi propagate a tutti i router interni dell'AS tramite iBGP.
- Le sessioni **iBGP** sono connessioni logiche TCP end-to-end tra router dello stesso AS e possono attraversare più hop fisici interni. Per prevenire cicli di instradamento all'interno dell'AS (poiché l'attributo `AS-PATH` cambia solo quando si attraversano i confini tra AS diversi), vige la regola di **split horizon iBGP**: **le rotte apprese da un peer tramite una sessione iBGP non vengono mai riannunciate ad altri peer iBGP** (motivo per cui i router BGP di uno stesso AS devono essere connessi in una maglia logica completa, *full mesh*, o usare dei *route reflector*).

Esaminiamo come BGP distribuirebbe le informazioni di raggiungibilità dal prefisso x ad AS1 e AS2. In router gateway 3a invia un messaggio eBGP *AS3* x al router gateway 2c che a sua volta lo invia su una sessione iBGP a tutti i router di AS2 compreso il gateway 2a. Quest'ultimo invia un messaggio eBGP *AS2 AS3* x al router gateway 1c, che infine usa iBGP per inviare il messaggio *AS2 AS3* x a tutti i router di AS1. Completato tale processo, ogni router di AS1 e AS2 è a conoscenza dell'esistenza di tale x e del percorso per raggiungerlo.

6.3.3. Formato dei pacchetti BGP

Tutti i messaggi BGP scambiati su una sessione TCP condividono un'intestazione (**Header**) fissa di 19 byte seguita dal payload del messaggio:

- **Marker (16 byte)**: campo di 128 bit posti tutti a `1`, utilizzato per delimitare l'inizio del messaggio BGP e per scopi di sincronizzazione/autenticazione.
- **Length (2 byte)**: lunghezza totale del messaggio in byte (incluso l'header).
- **Type (1 byte)**: identifica uno dei **5 tipi di messaggio BGP** (RFC 4271, RFC 2918):
  1. **OPEN**: apre una sessione BGP con un peer adiacente negoziando i parametri.
  2. **UPDATE**: messaggio cardine di BGP, usato per annunciare nuove rotte o ritirare rotte non più valide.
  3. **KEEPALIVE**: inviato periodicamente per confermare che il peer e la sessione sono attivi in assenza di altri messaggi.
  4. **NOTIFICATION**: inviato quando viene rilevata una condizione di errore (determina la chiusura della connessione BGP).
  5. **ROUTE-REFRESH**: richiede al peer vicino di inviare nuovamente tutte le sue rotte (utile, ad esempio, dopo che l'amministratore ha modificato le policy di filtraggio in ingresso).

Struttura del messaggio BGP UPDATE

Il messaggio di tipo **UPDATE** consente sia di revocare più prefissi non più raggiungibili, sia di annunciare un nuovo percorso (con i medesimi attributi) per uno o più prefissi. È composto da cinque campi:

1. **Unfeasible Routes Length (2 byte)**: lunghezza in byte del campo successivo; se vale `0`, nessuna rotta viene ritirata in questo messaggio.
2. **Withdrawn Routes (lunghezza variabile)**: elenco dei prefissi IP delle rotte che vengono revocate (ritirate) poiché non più raggiungibili.
3. **Total Path Attribute Length (2 byte)**: lunghezza in byte del blocco *Path Attributes*.
4. **Path Attributes (lunghezza variabile)**: lista degli attributi associati alle rotte annunciate in questo messaggio. Oltre a `LOCAL-PREF`, i tre attributi obbligatori principali sono:
   - **`ORIGIN`**: indica come l'AS di origine ha generato la rotta in BGP (es. `IGP` se appresa dal protocollo di routing interno all'AS, `EGP`, oppure `INCOMPLETE` se derivata da altre fonti come rotte statiche);
   - **`AS-PATH`**: sequenza ordinata degli ASN attraversati dall'annuncio (usato sia come metrica di distanza sia per il rilevamento dei loop);
   - **`NEXT-HOP`**: indirizzo IP dell'interfaccia del router di frontiera dell'AS vicino verso cui inoltrare i pacchetti.
5. **Network Layer Reachability Information (NLRI, lunghezza variabile)**: elenco dei prefissi CIDR annunciati (codificati come coppie

(lunghezza_prefisso, prefisso), es. (24, 193.204.187)) che condividono gli attributi specificati nel campo *Path Attributes*.

Esempio 6 *(Caso di studio: il blackout globale di Facebook del 4 ottobre 2021)* **.** L'importanza critica di BGP per il funzionamento di Internet è emersa chiaramente il 4 ottobre 2021, quando tutti i servizi del gruppo Meta (Facebook, Instagram, WhatsApp) sono risultati completamente irraggiungibili a livello mondiale per circa 6-7 ore.
Durante un'operazione di manutenzione ordinaria sui router della dorsale (*backbone*) che connettono i data center di Facebook, un comando errato ha disconnesso l'intera dorsale interna. I server DNS autoritativi di Facebook (ospitati in strutture periferiche dell'AS di Facebook, **AS32934**) avevano un meccanismo di sicurezza progettato per revocare automaticamente gli annunci BGP verso l'esterno qualora avessero perso il collegamento con la propria dorsale interna, così da non attirare traffico su nodi isolati.
Trovandosi improvvisamente tutti scollegati dal backbone, tutti i router di frontiera di AS32934 hanno inviato messaggi BGP UPDATE contenenti **Withdrawn Routes** per tutti i prefissi IP di Facebook. Di conseguenza, sebbene i server fossero fisicamente accesi e funzionanti, i prefissi dei server DNS di Facebook sono scomparsi dalle tabelle di routing BGP di tutti gli ISP mondiali: nessun utente su Internet poteva più risolvere il nome facebook.com né instradare pacchetti verso AS32934 fino al ripristino manuale degli annunci BGP (**Announce**) avvenuto in serata.

6.3.4. Selezione delle rotte migliori

Prima di analizazre come un router sceglie il percorso migliore tra tutti quelli che riceve, introduciamo della terminologia BGP. Quando un router annuncia un prefisso per una sessione BGP, include anche un certo numero di **attributi BGP**. Un prefisso assieme ai suoi attributi è detto **rotta** (*route*). Due dei più importanti sono AS-PATH e NEXT-HOP. **AS-PATH** elenca i sistemi autonomi attraverso i quali è passato l'annuncio del prefisso. I router usano tale attributi per rilevare ed evitare gli annunci reiterati. Nello specifico, se un router vede che il proprio AS è contenuto nella lista dei percorsi, rifiuta l'annuncio.
Nel fornire il collegamento tra i protocolli di instradamento intra-AS e inter-AS, l'attributo **NEXT-HOP** ha un ruolo importante. In NEXT-HOP è riportata l'interfaccia del router che inizia l'AS-PATH. Ad esempio, ritornando alla figura **Figura 44** l'attributo NEXT-HOP per la rotta *AS2 AS3* x da AS1 a x passando per AS2 è l'indirizzo IP dell'interfaccia a sinistra del router 2a. Ogni rotta è quindi scritta come una lista di tre elementi:
1. NEXT-HOP;
2. AS-PATH;

3. prefisso x.

NEXT-HOP è l'indirizzo IP di un router che non appartiene ad AS1, ma ad una sottorete collegata direttamente ad AS1.

Instradamento hot potato

Uno dei più semplici algoritmi di routing BGP è l'**instradamento hot potato**. Consideriamo il seguente schema:

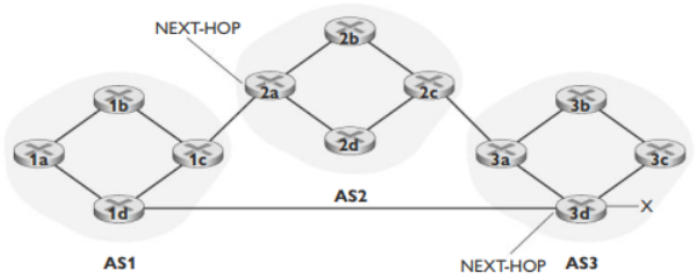


Figura 45: Rete con tre AS

Consideriamo il router 1b della figura. Questo router impara due possibili percorsi BGP verso il prefisso x. Nell'instradamento a patata bollente, il percorso scelto è quello con il minor costo per il router NEXT-HOP che lo inizia. In questo esempio, il router 1b consulterà le informazioni di routing intra-AS per trovare il percorso intra-AS a costo minimo verso il router NEXT-HOP 2a e il percorso a costo minimi verso il router NEXT-HOP 3d, e tra questi seleziona quello a costo minimo. Quando il router trova il percorso a costo minimo consulta la sua tabella di inoltro per trovare l'interfaccia I che si trova sul percorso a costo minimo per il router destinazione. Quindi aggiunge (x, I) alla sua tabella di inoltro.
La procedura per inserire un prefisso fuori-AS nella tabella di inoltro di un router usando l'instradamento hot-potato è riassunto nel seguente schema:

Dal protocollo inter-AS si apprende che la sottorete x è raggiungibile attraverso più gateway.	→	Si usa l'informazione di instradamento proveniente dal protocollo intra-AS per determinare i costi dei percorsi a costo minimo verso i gateway.	→	Instradamento a «patata bollente»: si sceglie il gateway che ha il costo minimo inferiore.	→	Dalla tabella di inoltro si determina l'interfaccia I che conduce al gateway a costo minimo. Si scrive (x, I) nella tabella di inoltro.

Quando si aggiunge un prefisso fuori-AS a una tabella di inoltro vengono utilizzati entrami i protocolli inter-AS e intra-AS.
L'idea alla base è che il router 1b butti fuori i pacchetti dal suo AS quanto prima senza preoccuparsi del costo delle restanti tratte del percorso al di fuori del suo AS; da qui il nome *hot potato*. È quindi un algoritmo egoista che cerca di ridurre i costi per il proprio AS, non badando a quello degli altri. Si noti che due router dello stesso AS potrebbero selezionare diversi percorsi per lo stesso prefisso.

Algoritmo di selezione delle rotte
BGP utilizza un algoritmo più complesso di quello hot potato. L'input del processo di selezione è l'insieme di tutte le rotte apprese e accettate dal router. Se ne esistono due o più verso lo stesso prefisso, BGP invoca in sequenza le seguenti regole di eliminazione fino ad inviduare un'unica possibilità.

1. Alle rotte viene assegnato come attributo un valore di **preferenza locale**, che potrebbe esser stato impostato direttamente dal router o appreso da un altro router nello stesso AS. Si selezionanto le rotte con i più alti valori di preferenza locale.
2. Tra le rotte con stesso valore di preferenza locale, si seleziona quella con AS-PATH più breve. Se questa fosse l'unica regola di selezione, allora BGP utilizzerebbe un algoritmo Bellman-Ford per la determinazione del percorso, con metrica sulla distanza data dal numero di hop tra AS anzichè tra router.
3. Tra le rotte con stesso valore di preferenza locale e la stessa lunghezza AS-PATH si seleziona quella il cui router di NEXT-HOP è più vicino. In questo caso, s'intende quello che presenta il percorso con costo minore, determinato dall'algortimo intra-AS (instradamento a patata bollente).
4. Se rimane ancora più di nuna rotta, il router si basa sugli identificatori BGP.

Si consideri il router 1b della figura **Figura 45** e si ricordi che esistono due rotte BGP verso il prefisso x: una che passa da AS2 e una che lo evita. Con questo algoritmo la regola 2 verrebbe applicata prima della 3 e quindi verrebbe scelta la seconda rotta avente AS-PATH più breve. Tale politica BGP non è egoista e riduce anche il ritardo end-to-end.

6.3.5. Anycast IP
Il protocollo BGP, oltre a essere il protocollo inter-AS di Internet, viene spesso utilizzato anche per implementare il servizio IP anycast, comunemente utilizzato in DNS. Per capire l'utilità di anycast si consideri che in molte applicazioni si è interessati a replicare lo stesso contenuto su server differenti sparsi in diverse aree geografiche e che un utente acceda al contenuto del server che gli è più vicino. È auspicabile che un utente che voglia accedere ad un contenuto utilizzi il server a lui più vicino. L'algoritmo di selezione delle rotte BGP fornisce un meccanismo semplice e naturale per tale operazione.

Analizziamo un caso concreto di come una CDN possa utilizzare l'anycast IP. Come mostrato nella seguente figura, durante la configurazione dell'anycast IP, la CDN assegna stesso indirizzo IP a ognuno dei suoi server e utilizza lo standard BGP per annunciare tale indirizzo IP da ognuno dei suoi server.

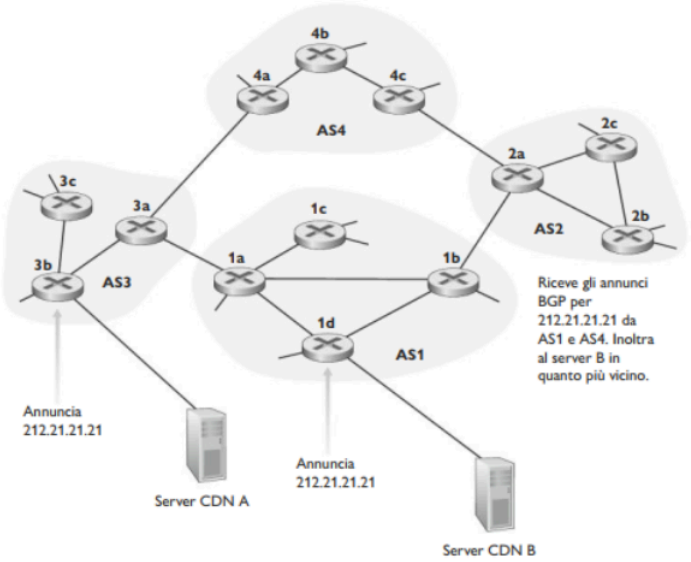


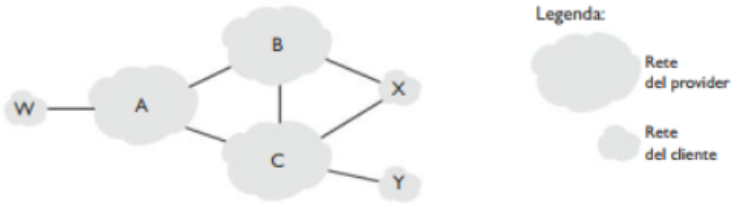
Figura 46: Utilizzo di anycast IP per instradare i client al cluster CDN più vicino

Quando un router BGP riceve l'annuncio di più percorsi da questo indirizzo IP, lo tratta come se fossero forniti da diversi percorsi verso la stessa area fisica, anche se sono percorsi diversi verso luoghi diversi. Ogni router, quando configura la sua tabella di inoltro, utilizza localemente l'algoritmo di selezione dei cammini BGP per scegliere il percorso migliore per quell'indirizzo IP.
Dopo la fase iniziale di annuncio degli indirizzi BGP, la CDN può dedicarsi a distribuire contenuti. Quando un client richiede un video, la CDN gli restituisce l'indirizzo IP usato da tutti i suoi server disparsi geograficamente, indipendentemente dal luogo in cui si trova il client. Quando il client invia una richiesta a quell'indirizzo IP, i router Internet inoltrano il pacchetto richiesto al server più vicino come definito dall'algoritmo BGP.
Nella pratica le CDN non utilizzano anycast IP perchè cambiamenti nell'instradamento BGP potrebbero portare ad avere sulla stessa connessione TCP pacchetti differenti che arrivano a differenti istanze del server web. L'anycast IP viene utilizzato dal sistema DNS per dirigere le richieste DNS al server root più vicino.

6.3.6. Politiche di instradamento

Quando un router sceglie una rotta, le politiche di instradamento dell'AS possono intervenire facendo saltare qualsiasi altra considerazione riguardante per esempio

la brevità del percorso o la procedura hot potato.
Si consideri la seguente figura:



La figura mostra sei sistemi autonomi interconessi. Ipotizziamo che *W, X* e *Y* siano **reti stub** e che *A, B* e *C* siano reti provider di dorsale. Ipotizziamo anche che *A, B* e *C* siano peer l'uno dell'altro e forniscano informazioni BGP complete alle reti dei loro clienti. Tutto il traffico che entra in una **rete di accesso di un ISP** è destinato a tale rete e tutto il traffico in uscita ha origine in tale rete. *W* e *Y* rappresentano chiaramente reti di accesso. *X* è un **ISP di accesso multi-homed**, dato che è connessa al resto della rete attraverso due provider. In ogni caso, come *W* e *Y*, anche *X* deve essere sorgente o destinazione di tutto il traffico in uscita o ingresso attraverso *X*. Dobbiamo analizzare come si implementa questo comportamento e come si impedisce a *X* di smaltire traffico tra *B* e *C*.
Per fare ciò si controllano gli annunci delle rotte BGP. In particolare, *X* opererà come una rete stub se annuncia ai suoi vicini *B* e *C* di non avere altri percorsi verso altre destinazioni tranne sè stessa. Quindi, anche se *X* fosse a conoscenza di un percorso del tipo *XCY*, non l'annuncerà a *B*.
Concentriamoci ora sulla rete di un provider, per un sistema autonomo *B*, e supponiamo che questo abbia appreso (da *A*) che *A* presenta un percorso *AW* verso *W*. Allora *B* può installare il percorso *BAW* nella sua struttura dati per l'instradamento. Chiaramente *B* vuole annunciare tale percorso al suo cliente *X*, per permettergli di raggiungere *W* tramite *B*. Se *B* lo annunciasse anche a *C*, *C* potrebbe instradare il traffico verso *W* via *CBAW*. Se *A, B* e *C* sono provider di dorsale, allora *B* potrebbe pensare di non dover sopportare il costo del traffico in transito da *A* e *C* e che sia compito di *A* e *C* assicurarsi che *C* possa instradare da e verso i clienti di *A* tramite una connessione diretta tra *A* e *C*. Una regola seguita dagli ISP commerciali è quella per cui tutto il traffico che fluisce attraverso la rete di dorsale di un ISP deve avere origine e/o destinazione in una sua rete cliente. Accordi individuali di **peering** vengono negoziati tra coppiue di ISP.

6.4. ICMP (Internet Control Message Protocol)

Il protocollo ICMP, *Internet Control Message Protocol*, viene usato da host e router per scambiarsi informazioni a livello di rete: il suo uso più tipico è la notifica degli

errori. Durante l'esecuzione di una sessione HTTP si può incontrare il messaggio "Rete di destinazione irraggiungibile". Questo messaggio ha origine da ICMP.
ICMP è spesso considerato parte di IP, ma dal punto di vista dell'architettura si trova esattamente sopra IP, dato che i suoi messaggi vengono trasportati nei datagrammi IP: ossia, i messaggi ICMP vengono trasportati come payload di IP. Allo stesso modo, se un host riceve un datagramma IP, che specifica ICMP come protocollo di livello superiore, allora effettua il demultiplexing dei contenuti dal datagramma a ICMP.
I messaggi ICMP hanno un campo tipo e un campo codice e contengono l'intestazione e i primi 8 byte del datagramma IP che ha provocato la generazione del messaggio, in modo che il mittente possa determinare il datagramma che ha causato l'errore. I messaggi ICMP non vengono usati solo per segnalare condizioni d'errore. Il noto programma *ping* invia un ICMP di tipo 8 e codice 0 verso l'host specificato. L'host destinazione, vedendo la richiesta di *echo*, risponde con un messaggio di tipo 0 e codice 0.
Un altro interessante messaggio ICMP è quello di riduzione del tasso di trasmissione. Lo scopo originario di questo messaggio, raramente usato, era un controllo di congestione che consentiva a un router congestionato di inviare un messaggio ICMP a un host, per forzarlo a ridurre il proprio tasso di trasmissione.
Una nuova versione di ICMP è stata definita per IPv6, in cui sono stati introdotti nuovi tipi e codici e ridefiniti quelli vecchi: come ad esempio codici di errore "pacchetto troppo grande" e "opzioni non riconosciute".
Segue una tabella che raffigura dei tipi di messaggio ICMP:

Tipo ICMP	**Codice**	**Descrizione**
0	0	risposta echo (a ping)
3	0	rete destinazione irraggiungibile
3	1	host destinazione irraggiungibile
3	2	protocollo destinazione irraggiungibile
3	3	porta destinazione irraggiungibile
3	4	frammentazione necessaria ma DF=1 (PMTUD)
3	6	rete destinazione sconosciuta
3	7	host destinazione sconosciuto
4	0	riduzione (controllo di congestione)
8	0	richiesta echo
9	0	annuncio di un router
10	0	scoperta di un router
11	0	TTL scaduto

Tipo ICMP	Codice	Descrizione
12	0	intestazione IP errata

Nell'intestazione del datagramma IPv4 che incapsula un messaggio ICMP, il campo *Protocollo* assume valore `1` (mentre per ICMPv6, definito nella RFC 4443, il campo *Next Header* vale `58`).

Traceroute e ICMP

Oltre a `ping`, un celebre strumento diagnostico basato su ICMP è **`traceroute`**, utilizzato per scoprire l'elenco di tutti i router attraversati lungo il percorso da una sorgente a una destinazione e misurare il relativo tempo di andata e ritorno (**RTT**) ad ogni salto:

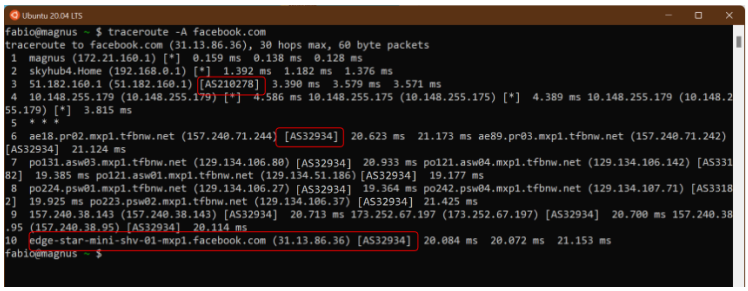


Figura 48: Funzionamento di Traceroute tramite sonde UDP e risposte ICMP

1. La sorgente invia verso la destinazione una serie di segmenti UDP (solitamente **3 sonde** per ogni salto) indirizzati a un numero di porta UDP elevato e improbabile (da `33434` in su), su cui normalmente nessuna applicazione è in ascolto.
2. La prima serie di 3 sonde viene inviata impostando nell'header IP `TTL = 1`, la seconda serie con `TTL = 2`, la terza con `TTL = 3`, e così via.
3. Quando le sonde della serie n-esima (con `TTL = n`) raggiungono l'n-esimo router lungo il percorso, quest'ultimo decrementa il TTL portandolo a `0`: il router scarta quindi i datagrammi e restituisce alla sorgente un messaggio di errore **ICMP «TTL scaduto»** (**tipo 11, codice 0**). Esaminando l'header IP di questo messaggio ICMP, la sorgente apprende l'indirizzo IP dell'n-esimo router e calcola l'RTT delle tre sonde. *(Opzioni come `traceroute -A` o `mtr -z` permettono inoltre di consultare i database RIR per stampare accanto a ciascun IP anche l'ASN del Sistema Autonomo attraversato).*
4. **Condizione di arresto**: quando finalmente una serie di sonde ha un TTL sufficiente per raggiungere l'host di destinazione finale, il datagramma non scade più in transito, ma tenta di consegnare il segmento UDP alla porta alta inesistente. L'host di destinazione risponde allora con un messaggio **ICMP «Porta di destinazione irraggiungibile»** (**tipo 3, codice 3**): ricevendo il tipo 3 codice 3 anziché il tipo 11 codice 0, la sorgente capisce di aver raggiunto l'host finale e termina l'invio di ulteriori sonde.